



上海财经大学
SHANGHAI UNIVERSITY OF FINANCE AND ECONOMICS

《数据科学与数据分析基础》课程

第二讲 Python与网络基础知识

授课教师：袁浩禹

2026 年 03 月

上海财经大学信息管理与工程学院





杂论1

- 以数据科学导论的课程论文为基础完成一个学术项目
- 以发表学术论文为目标
- 未来可以发展为本科生毕设项目/大创项目

时间：3.17前 email我简历 择优选用

yuanhy@sufe.edu.cn



杂论2

课程考核：动态、灵活、整体

课程作业（40%）+完成期末大作业（50%）+课堂表现（10%）

✓课程作业（40%）

4次个人作业

✓完成期末大作业（50%）（个人）

✓课堂表现（10%）（本学期允许请假2次，提前请假）

起记分为6分

参加quiz 每次加1分 缺席quiz每次扣2分

额外加分：

参与每周课程上的课堂展示 加1~3分

参与期末课程汇报 加1~3分



杂论3

教学拓展资料

课程大报告参考模板	
目 录	
1. 研究背景	3
2. 数据采集与存储	3
3. 数据集介绍、预处理与可视化	5
3.1. 数据集介绍	5
3.2. 数据预处理	5
3.2.1. 缺失值处理	5
3.2.2. 离群值检测	5
3.2.3. 相关系数和相关性分析	6
3.2.4. 数据标准化	9
3.2.5. 数据离散化	10
4. 数据挖掘	10
4.1. 算法选择	10
4.2. 岭回归	11
5. 分析和讨论	12
6. 附件	12
6.1. 爬虫程序	12
6.1.1. 获取 URL 列表	12
6.1.2. 获取数据并存储至数据库	14



Recap

- 数据科学的内涵及外延
 - 数据科学的时代背景及特点
 - 数据科学研究目的及内容
 - 数据科学研究流程
 - 数据思维



When Images Backfire: The Effect of Customer-Generated Images on Product Rating Dynamics

Yue Guan,^a Yong Tan,^b Qiang Wei,^{c,*} Guoqing Chen^c

^aSchool of Economics and Management, Communication University of China, Beijing 100024, China; ^bMichael G. Foster School of Business, University of Washington, Seattle, Washington 98195; ^cSchool of Economics and Management, Tsinghua University, Beijing 100084, China

*Corresponding author

Contact: yueguan@cuc.edu.cn, <https://orcid.org/0000-0002-9979-5901> (YG); ytan@uw.edu, <https://orcid.org/0000-0001-8087-3423> (YT); qiangwei@mail.tsinghua.edu.cn, <https://orcid.org/0000-0002-8397-7129> (QW); chengq@sem.tsinghua.edu.cn, <https://orcid.org/0000-0001-7386-1133> (GC)

Received: July 2, 2020

Revised: October 10, 2021; September 23, 2022

Accepted: December 3, 2022

Published Online in Articles in Advance:
February 28, 2023

<https://doi.org/10.1287/isre.2023.1201>

Copyright: © 2023 INFORMS

Abstract. Customer-generated images (CGIs) on e-commerce platforms have been widely adopted as a promotional tool to persuade customers into purchases. Despite their prevalent applications, the effect of CGIs on customer postpurchase satisfaction has not been extensively examined. This study postulates that CGIs could cause expectation disconfirmation and reduce product uncertainty for customers, therefore making their effect on subsequent product ratings complex. We leverage multiple methods and data sets to gain a better understanding of this problem and underlying mechanisms. We employ a difference-in-differences model to empirically test our hypotheses and find that CGIs lead to a decline in subsequent ratings compared with product ratings not exposed to CGIs. Further heterogeneity analyses demonstrate that high CGI review rating and high aesthetic quality exacerbate the negative effect, whereas reviewer face disclosure could alleviate the negative effect. Through cross-product analyses, we find that the negative effect is more prominent for experience goods (e.g., women's dresses) than for search goods (e.g., lightning cables). Finally, the underlying mechanism is further validated through a laboratory experiment that shows participants experience significantly higher expectation and more negative disconfirmation in the CGI group with high review ratings, whereas uncertainty reduction effect is insignificant, which collectively explains the decline of subsequent product ratings. These findings suggest that platforms and retailers should be aware of the potential negative effect of CGIs on the rating dynamics and take appropriate measures to circumvent it.

History: Ravi Bapna, Senior Editor; Gordon Burtch, Associate Editor.

- 研究问题的选择
- 学会抓数据的重要性



本讲纲要

- **Python语言**
- Python的安装与开发环境配置
- Python基本语法
- HTML简介
- 互联网络协议
- 网络爬虫的“盗亦有道”



Python语言

- Python 3.0版本于2008年发布
- 3.5和3.6也已逐步成为Python的主流版本
- Python的应用范围十分广泛
 - 豆瓣
 - 知乎
- 系统编程、图形处理、科学计算、数据库、网络编程、Web应用、多媒体应用




Python语言

- IEEE Spectrum 2021 编程语言排名前十的分别是：**Python, Java, C, C++, JavaScript, C#, R, Go, HTML, Swift**

TIOBE Programming Community Index

Source: www.tiobe.com



Rank	Language	Type	Score
1	Python		100.0
2	Java		95.4
3	C		94.7
4	C++		92.4
5	JavaScript		88.1
6	C#		82.4
7	R		81.7
8	Go		77.7
9	HTML		75.4
10	Swift		70.4



本讲纲要

- Python语言
- **Python的安装与开发环境配置**
- Python基本语法
- HTML简介
- 互联网络协议
- 网络爬虫的“盗亦有道”



Python的安装与开发环境配置

- 访问python.org/download/ 并下载与计算机架构对应的 Python 3 安装程序





Python的安装与开发环境配置*

- Jupyter面向编程过程，非常直观的代码和注释
- 支持插入数学公式、制作演示文稿、特殊关键字等

The screenshot displays a Jupyter Notebook titled 'notebook1 (unsaved changes)'. The interface includes a top menu bar with options: File, Edit, View, Insert, Cell, Kernel, Widgets, and Help. Below the menu is a toolbar with icons for file operations, cell navigation, and execution. The notebook content shows four input cells:

```
In [1]: a = 1
a
Out[1]: 1
```

```
In [2]: b = 2
b
Out[2]: 2
```

```
In [3]: a+b
Out[3]: 3
```

Below the third cell, there is a text cell containing the Chinese text: 这里是Markdown语句

```
In [4]: %timeit
print('Hi there')
Hi there
```



Python的安装与开发环境配置

- PyCharm: JetBrain公司出品的Python开发IDE（集成开发环境）
- 支持Windows、Mac、Linux三大平台
- 提供Professional和Community Edition两种版本选择
- B站视频指导（Python3的环境配置）：
<https://www.bilibili.com/video/av19057145?p=1>



Version: 2023.1.3
Build: 231.9122.46
Released: 2023-01-17

[System requirements](#)
[Installation Instructions](#)
[Previous versions](#)

Download PyCharm

Windows

macOS

Linux

Professional

Full-featured IDE
for Python & Web
development

DOWNLOAD

Free trial

Community

Lightweight IDE
for Python & Scientific
development

DOWNLOAD

Free, open-source




Get the [ToolBox App](#) to download PyCharm
and its future updates with ease



本课程推荐的开发环境

- Jupyter Notebook (Anaconda 3包含)：强烈推荐
- Pycharm (社区版)
- Sublime Text





本讲纲要

- Python语言
- Python的安装与开发环境配置
- **Python基本语法**
- HTML简介
- 互联网络协议
- 网络爬虫的“盗亦有道”



Python基本语法

- Python 会根据每个变量的初始赋值情况分析其类型

```
counter = 100 # 赋值整型变量  
miles = 1000.0 # 浮点型  
name = "John" # 字符串
```

- 注释通过“#”开头的字符串体现

```
# 第一个注释  
print ("Hello, Python!") # 第二个注释
```




Python基本语法

➤ Python内置的基本数据类型

- ✓ **Number:** 数值型，可以是Integers, Float, Fractions（分数）,或者是Complex Number（复数）；
- ✓ **Byte:** 字节；
- ✓ **String:** 字符串；
- ✓ **Boolean:** 布尔型；
- ✓ **List:** 列表，一个包含若干元素的序列；
- ✓ **Dict:** 字典，有若干键值对组成；
- ✓ **Tuple:** 元组，与列表类似，但是值不可变；
- ✓ **Set:** 集合。

➤ Python数值之间的转换

- ✓ 整型和浮点型之间的转换

```
# Exicese 2
```

```
int_num = 100
```

```
float_num = 100.1
```

```
print(float(int_num))
```

```
print(int(float_num))
```



Python基本语法

- 输入

`input("按下 enter 键退出，其他任意键显示...\n")`

```
op = input()
op2 = input()
op3 = int(op) + int(op2)
print("the results is :", op3)
```

- 输出

`print` 默认输出是换行的，如果要实现不换行需要在变量末尾加上逗号,。

```
x="a"
y="b"
# 换行输出
print x
print y

print '-----'
# 不换行输出
print x,
print y,

# 不换行输出
print x,y
```

```
a
b
-----
a b a b
```



Python基本语法

- 列表

List（列表）是 Python 中使用最频繁的数据类型。

列表可以完成大多数集合类的数据结构实现。它支持字符，数字，字符串甚至可以包含列表（即嵌套）。列表用 [] 标识，是 python 最通用的复合数据类型。

```
list = [ 'runoob', 786 , 2.23, 'john', 70.2 ]
tinylist = [123, 'john']
```

```
print list           # 输出完整列表
print list[0]        # 输出列表的第一个元素
print list[1:3]      # 输出第二个至第三个元素
print list[2:]       # 输出从第三个开始至列表末尾的所有元素
print tinylist * 2    # 输出列表两次
print list + tinylist # 打印组合的列表
```

```
['runoob', 786, 2.23, 'john', 70.2]
runoob
[786, 2.23]
[2.23, 'john', 70.2]
[123, 'john', 123, 'john']
['runoob', 786, 2.23, 'john', 70.2, 123, 'john']
```



Python基本语法

- 字典

字典(dictionary)是除列表以外python之中最灵活的内置数据结构类型。列表是有序的对象集合，字典是无序的对象集合。

两者之间的区别在于：字典当中的元素是通过键来存取的，而不是通过偏移存取。

字典用"{"标识。字典由索引(key)和它对应的值value组成。

```
dict = {}  
dict['one'] = "This is one"  
dict[2] = "This is two"
```

```
tinydict = {'name': 'john', 'code': 6734, 'dept': 'sales'}
```

```
print dict['one']      # 输出键为 'one' 的值  
print dict[2]          # 输出键为 2 的值  
print tinydict         # 输出完整的字典  
print tinydict.keys()  # 输出所有键  
print tinydict.values() # 输出所有值
```

```
This is one  
This is two  
{'dept': 'sales', 'code': 6734, 'name': 'john'}  
['dept', 'code', 'name']  
['sales', 6734, 'john']
```



Python基本语法

- 集合

集合是包含一组唯一值的容器，集合中的元素不以任何特定的顺序存储，不能通过位置进行访问。

集合的创建

1. 可以使用带有初始元素的集合；

2. 使用set（）创建集合。

```
1 cast = {"Luiqi", "Gumbys", "Spiny"}
2 cast1 = set()
3 print(len(cast))
4 print(len(cast1))
```

3
0

参考资料：Python程序设计 董付国（译）机械工业出版社



Python基本语法

- 元组

Python中的元组与类别类似，不同之处在于元组的元素不能修改；
元组使用小括号，列表使用中括号；
元组创建很简单，只需要在括号中添加元素，并使用逗号隔开。

```
1 tup1 = ('Phycics', 'Chemistry', 1997, 2000)
2 print("tup1[0]:", tup1[0])
```

```
tup1[0]: Phycics
```



Python基本语法

- 条件语句

Python条件语句是通过一条或多条语句的执行结果（True或者False）来决定执行的代码块。

Python 编程中 if 语句用于控制程序的执行，基本形式为：

if 判断条件：

 执行语句.....

else:

 执行语句.....

```
flag = False
name = 'luren'
if name == 'python':
    flag = True
    print 'welcome boss'
else:
    print name
```

判断变量是否为 python
条件成立时设置标志为真
并输出欢迎信息

条件不成立时输出变量名称

luren

输出结果



Python基本语法

- 条件语句

当判断条件为多个值时，可以使用以下形式：

```
if 判断条件1:  
    执行语句1.....  
elif 判断条件2:  
    执行语句2.....  
elif 判断条件3:  
    执行语句3.....  
else:  
    执行语句4.....
```

```
num = 5  
if num == 3:                # 判断num的值  
    print 'boss'  
elif num == 2:  
    print 'user'  
elif num == 1:  
    print 'worker'  
elif num < 0:                # 值小于零时输出  
    print 'error'  
else:  
    print 'roadman'         # 条件均不成立时输出
```

```
roadman    # 输出结果
```




Python基本语法

- for循环

Python for循环可以遍历任何序列的项目，如一个列表或者一个字符串。

for循环的语法格式如下：

for iterating_var in sequence:

statements(s)

```
1  l1 = []
2  for i in range(11):
3      #range()函数省略start参数时，自动认为从0开始
4      if i % 2 == 1:
5          l1.append(i)
6  print(l1)
```



Python基本语法

- while循环

Python 编程中 while 语句用于循环执行程序，即在某条件下，循环执行某段程序，以处理需要重复处理的相同任务。

其基本形式为： while 判断条件(condition):
 执行语句(statements).....

执行语句可以是单个语句或语句块。判断条件可以是任何表达式，任何非零、或非空（null）的值均为true。当判断条件假 false 时，循环结束。

```
count = 0
while (count < 9):
    print 'The count is:', count
    count = count + 1

print "Good bye!"
```

```
The count is: 0
The count is: 1
The count is: 2
The count is: 3
The count is: 4
The count is: 5
The count is: 6
The count is: 7
The count is: 8
Good bye!
```



Python基本语法*

- 函数和类

➤ **def** **powanddivide**(*x,n=2,m=1*):
 return *x**n/m*

```
print(powanddivide(3,2,5)) # 1.8  
print(powanddivide(3,m=1,n=2)) # 9.0
```

➤ **class** **Player**:
 name = ''
 def **__init__**(*self,name*):
 self.name = name

```
p11 = Player('PlayerX')  
print(p11.name) # PlayerX
```



Python中函数的调用*

- 在python程序中可以定义多个函数，程序在执行时首先调用main()函数，在main()中可以根据需要，调用其他函数；

```
#This program has two functions  
#define the main function  
def main():  
    print('I have a message for you.')  
    message()  
    print('Goodbye!')  
  
#M define message function.  
def message():  
    print('I am Arthur.')  
    print('King of the Britons.')  
  
# call the main function.  
if __name__ == "__main__":  
    main()
```

- ✓ Python每个模块都有一个__name__属性，该属性保存当前模块执行过程中的名称；
- ✓ 当某个程序模块独立运行时，该模块的__name__属性自动被赋予值为__main__的字符串。



本讲纲要

- Python语言
- Python的安装与开发环境配置
- Python基本语法
- **HTML简介**
- 互联网络协议
- 网络爬虫的“盗亦有道”



HTML简介

- HTML（Hyper Text Markup Language，超文本标记语言）

← → ↻

w3school.com.cn

☆

⬇

✖

🔍

🌐

🔧

🌱

📱

应用 建议网站 网页快讯库 Suggested Sites Web Slice Gallery offline GPS navig... 从 IE 中导入 Gmail YouTube 地图 scholar.google.co... 百度 苏宁易购 搜索 » 阅读清单

W3school

HTML/CSS

Browser Side

Server Side

Programming

XML

Web Building

Reference

HTML 教程

HTML

HTML5

XHTML

CSS

CSS3

Bootstrap 5

TCP/IP

浏览器脚本

JavaScript

HTML DOM

jQuery

jQuery Mobile

AJAX

JSON

DHTML

E4X

WMLScript

服务器脚本

PHP

领先的 Web 技术教程 - 全部免费

在 W3School, 你可以找到你所需要的所有的网站建设教程。

从基础的 HTML 到 CSS, 乃至进阶的 XML、SQL、JS、PHP 和 ASP.NET。

从左侧的菜单选择你需要的教程!

完整的网站技术参考手册

我们的参考手册涵盖了网站技术的方方面面。

其中包括W3C标准技术: HTML、CSS、XML。以及其他技术, 诸如 JavaScript、PHP、SQL 等。

在线实例测试工具

在 W3School, 我们提供上千个实例。

参考手册

HTML/HTML5 标签

HTML 颜色

CSS 1,2,3

JavaScript

HTML DOM

jQuery

jQuery Mobile

VBScript

ASP

ADO

ASP.NET

PHP

Python

XML DOM

XSLT 1.0

XPath 2.0

XSL-FO

WML 1.1

W3C 术语表



HTML简介

- 网络页面的三大要素

技术	作用	定义	特点
HTML	负责网页的 结构 和 内容	超文本标记语言（HyperText Markup Language），用于定义网页的内容和布局。	- 由标签（tags）构成，如 <h1>、<p>、<div> - 不能控制样式或行为，仅提供静态内容。
CSS	负责网页的 样式 和 美观	层叠样式表（Cascading Style Sheets），用于控制网页的颜色、字体、布局等外观。	- 通过选择器定义样式，如 h1 { color: red; } - 可控制布局（Flexbox、Grid）和动画效果。
JavaScript	负责网页的 交互 和 行为	一种编程语言，使网页动态化，能与 HTML 和 CSS 交互，处理用户输入等。	- 可操作 DOM（修改 HTML 结构） - 可监听用户事件（如点击、输入） - 可动态修改 CSS



HTML简介

- HTML (Hyper Text Markup Language, 超文本标记语言)

```
<!DOCTYPE html>
<html lang="zh-cn">
  <head>
    <title>w3school 在线教程</title>
  </head>
  <body>
    <h1>My First Heading</h1>
    <p>My first paragraph.</p>
    <a href="http://www.w3school.com.cn">This is a link</a>
    
  </body>
</html>
```





HTML元素

HTML 元素指的是从开始标签（start tag）到结束标签（end tag）的所有代码。

开始标签	元素内容	结束标签
<code><p></code>	My first paragraph	<code></p></code>
<code></code>	This is a link	<code></code>

- HTML 元素以开始标签起始
- HTML 元素以结束标签终止
- HTML 元素允许嵌套
- 某些 HTML 元素具有空内容（empty content）
- 大多数 HTML 元素可拥有属性
- HTML 标签对大小写不敏感：<P> 等同于 <p>

```
<!DOCTYPE html>
<html lang="zh-cn">
  <head>
    <title>w3school 在线教程</title>
  </head>
  <body>
    <h1>My First Heading</h1>
    <p>My first paragraph.</p>
    <a href="http://www.w3school.com.cn">This is a link</a>
    
  </body>
</html>
```





HTML属性

属性为 HTML 元素提供附加信息

元素	属性名称	属性值
<a>	href	http://www.w3school.com.cn
<body>	bgcolor	yellow
<h1>	align	right

- HTML 标签可以拥有属性。
- 属性提供了有关 HTML 元素的更多的信息。
- 属性总是以名称/值对的形式出现，比如： **name="value"**。
- 属性总是在 HTML 元素的开始标签中规定。

```
<!DOCTYPE html>
<html lang="zh-cn">
  <head>
    <title>w3school 在线教程</title>
  </head>
  <body>
    <h1>My First Heading</h1>
    <p>My first paragraph.</p>
    <a href="http://www.w3school.com.cn">This is a link</a>
    
  </body>
</html>
```





HTML 标题与段落

标题是通过 `<h1>` - `<h6>` 等标签进行定义的。

`<h1>` 定义最大的标题。`<h6>` 定义最小的标题。

```
<h1>This is a heading</h1>
```

```
<h2>This is a heading</h2>
```

```
<h3>This is a heading</h3>
```

段落是通过 `<p>` 标签定义的。

```
<p>This is a paragraph</p>
```

```
<p>This is another paragraph</p>
```

HTML 折行

如果希望在不产生一个新段落的情况下进行换行（新行），可以使用 `<br />` 标签：

```
<p>This is<br />a para<br />graph with line breaks</p>
```





HTML 链接

通过使用 `<a>` 标签在 HTML 中创建链接。

有两种使用 `<a>` 标签的方式：

1. 通过使用 `href` 属性 - 创建指向另一个文档的链接

`<a href="http://www.w3school.com.cn/">访问 W3School</a>`

2. 通过使用 `name` 属性 - 创建文档内的书签

`<a name="tips">基本的注意事项 - 有用的提示</a>`

`<a href="#tips">有用的提示</a>`

`<a href="http://www.w3school.com.cn/html/html_links.asp#tips">有用的提示</a>`

```
<html>

<body>

<p>
<a href="#C4">查看 Chapter 4。</a>
</p>

<h2>Chapter 1</h2>
<p>This chapter explains ba bla bla</p>

<h2>Chapter 2</h2>
<p>This chapter explains ba bla bla</p>

<h2>Chapter 3</h2>
<p>This chapter explains ba bla bla</p>

<h2><a name="C4">Chapter 4</a></h2>
<p>This chapter explains ba bla bla</p>

<h2>Chapter 5</h2>
<p>This chapter explains ba bla bla</p>

<h2>Chapter 6</h2>
<p>This chapter explains ba bla bla</p>

<h2>Chapter 7</h2>
<p>This chapter explains ba bla bla</p>

<h2>Chapter 8</h2>
<p>This chapter explains ba bla bla</p>

<h2>Chapter 9</h2>
<p>This chapter explains ba bla bla</p>

<h2>Chapter 10</h2>
<p>This chapter explains ba bla bla</p>

<h2>Chapter 11</h2>
<p>This chapter explains ba bla bla</p>

<h2>Chapter 12</h2>
<p>This chapter explains ba bla bla</p>

<h2>Chapter 13</h2>
<p>This chapter explains ba bla bla</p>

<h2>Chapter 14</h2>
<p>This chapter explains ba bla bla</p>

<h2>Chapter 15</h2>
<p>This chapter explains ba bla bla</p>

<h2>Chapter 16</h2>
<p>This chapter explains ba bla bla</p>
```





HTML 图像

在 HTML 中，图像由 `<img>` 标签定义。

`<img>` 是空标签，意思是说，它只包含属性，并且没有闭合标签。

`<h2>`未设置对齐方式的图像： `</h2>`

`<p>`图像 `<img src ="/i/eg_cute.gif">` 在文本中`</p>`

`<h2>`已设置对齐方式的图像： `</h2>`

`<p>`图像 `` 在文本中`</p>`

`<p>`图像 `<img src ="/i/eg_cute.gif" align="middle">` 在文本中`</p>`

`<p>`图像 `<img src ="/i/eg_cute.gif" align="top">` 在文本中`</p>`

`<p>`请注意， `bottom` 对齐方式是默认的对齐方式。 `</p>`





HTML 表格

表格由 `<table>` 标签来定义。每个表格均有若干行（由 `<tr>` 标签定义），每行被分割为若干单元格（由 `<td>` 标签定义）。字母 **td** 指表格数据（**table data**），即数据单元格的内容。数据单元格可以包含文本、图片、列表、段落、表单、水平线、表格等等。

```
</table>
```

```
<h4>背景图像: </h4>
```

```
<table border="1"
background="/i/eg_bg_07.gif">
<tr>
  <td>First</td>
  <td>Row</td>
</tr>
<tr>
  <td>Second</td>
  <td>Row</td>
</tr>
</table>
```





HTML 表单

<form> 元素

HTML 表单用于收集用户输入， <form> 元素定义 HTML 表单。

<input> 元素

<input> 元素是最重要的表单元素。

```
<form action="action_page.php">
First name:<br>
<input type="text" name="firstname" value="Mickey">
<br>
Last name:<br>
<input type="text" name="lastname" value="Mouse">
<br><br>
<input type="radio" name="sex" value="male" checked>Male
<br>
<input type="radio" name="sex" value="female">Female
<br>
<input type="submit" value="Submit">
</form>
```

类型	描述
text	定义常规文本输入。
radio	定义单选按钮输入（选择多个选择之一）
checkbox	选择0个或多个选项
submit	定义提交按钮（提交表单）
password	定义密码字段





HTML 表单

<form> 元素

HTML 表单用于收集用户输入， <form> 元素定义 HTML 表单。

<input> 元素

<input> 元素是最重要的表单元素。

User name:


```
<input type="text" name="userid">
<br>
```

User password:


```
<input type="password" name="psw">
</form>
```

<p>密码字段中的字符被掩码（显示为星号或圆点）。</p>

类型	描述
text	定义常规文本输入。
radio	定义单选按钮输入（选择多个选择之一）
checkbox	选择0个或多个选项
submit	定义提交按钮（提交表单）
password	定义密码字段





HTML 表单

<form> 元素

```
<form action="/demo/demo_form.asp">
<select name="cars">
<option value="volvo">Volvo</option>
<option value="saab">Saab</option>
<option value="fiat">Fiat</option>
<option value="audi">Audi</option>
</select>
<br><br>
<input type="submit">
</form>
```

元素	描述
<select> <option>	下拉框/待选择的选项。
<textarea>	定义多行输入字段（文本域）。
<output>	计算结果输出。



HTML 表单

<form> 元素

<h2>Textarea</h2>

<p>The textarea element defines a multi-line input field.</p>

```
<form action="/action_page.php">
  <textarea name="message" rows="10" cols="30">The cat
was playing in the garden.</textarea>
  <br><br>
  <input type="submit">
</form>
```

元素	描述
<select> <option>	下拉框/待选择的选项。
<textarea>	定义多行输入字段（文本域）。
<output>	计算结果输出。





HTML 表单

<form> 元素

```
<form action="/action_page.php"
oninput="x.value=parseInt(a.value)+parseInt(b.value)">
0
<input type="range" id="a" name="a" value="50">
100 +
<input type="number" id="b" name="b" value="50">
=
<output name="x" for="a b"></output>
<br><br>
<input type="submit">
</form>
```

元素	描述
<select> <option>	下拉框/待选择的选项。
<textarea>	定义多行输入字段（文本域）。
<output>	计算结果输出。





HTML 表单

<form> 属性

Action Target Method(get/post)

```
<!DOCTYPE html>
```

```
<html>
```

```
<body>
```

```
<h1>form target 属性</h1>
```

<p>在提交这个表单后，将在新浏览器标签页中打开结果： </p>

```
<form action="/demo/html/action_page.php" target="_blank">
  <label for="fname">First name:</label><br>
  <input type="text" id="fname" name="fname" value="Bill"><br>
  <label for="lname">Last name:</label><br>
  <input type="text" id="lname" name="lname"
value="Gates"><br><br>
  <input type="submit" value="Submit">
</form>
</body>
</html>
```

值	描述
_blank	响应显示在新窗口或选项卡中。
_self	响应显示在当前窗口中。
_parent	响应显示在父框架中。
_top	响应显示在窗口的整个 body 中。
frameName	响应显示在命名的 iframe 中。





HTML 表单

<form> 属性

Action Target Method (get/post) Get:网页地址可见 Post: 网页地址不可见

<h1>method Attribute</h1>

<p>该表单会使用 POST 方法提交: </p>

```
<form action="/demo/html/action_page.php" target="_blank"
method="post">
  <label for="fname">First name:</label><br>
  <input type="text" id="fname" name="fname" value="Bill"><br>
  <label for="lname">Last name:</label><br>
  <input type="text" id="lname" name="lname"
value="Gates"><br><br>
  <input type="submit" value="Submit">
</form>
```

<p>提交后，请注意，与 GET 方法不同，表单值在新浏览器的地址栏中不可见。</p>

值	描述
_blank	响应显示在新窗口或选项卡中。
_self	响应显示在当前窗口中。
_parent	响应显示在父框架中。
_top	响应显示在窗口的整个 body 中。
framename	响应显示在命名的 iframe 中。





HTML 样式

HTML 的 style 属性

style 属性的作用：提供了一种改变所有 HTML 元素的样式的通用方法。

```
<body style="background-color:yellow">  
<h2 style="background-color:red">This is a heading</h2>  
<p style="background-color:green">This is a paragraph.</p>  
</body>
```

```
<body>  
<h1 style="font-family:verdana;color:blue ">A heading</h1>  
<p style="font-family:arial;color:red;font-size:20px;">A  
paragraph.</p>  
</body>
```





HTML 样式

HTML 的 style 属性

style 属性的作用：提供了一种改变所有 HTML 元素的样式的通用方法。

标签	描述
<center>	定义居中的内容。
 和 <basefont>	定义 HTML 字体。
<s> 和 <strike>	定义删除线文本
<u>	定义下划线文本
属性	描述
align	定义文本的对齐方式
bgcolor	定义背景颜色
color	定义文本颜色

```
<html>
<body bgcolor="blue">

<body style="background-color:yellow">
<h2 style="background-color:#660000">This is a
heading</h2>
<h2 >This is a heading?</h2>
<center><s> align</s> </center>
<p style="background-color:green;color:red ">This
is a paragraph.</p>
<h2 style="text-decoration:line-through">This is a
heading?</h2>
</body>

</body>
</html>
```





HTML 样式

CSS 指的是层叠样式表* (Cascading Style Sheets)

CSS 描述了如何在屏幕、纸张或其他媒体上显示 HTML 元素

CSS 节省了大量工作。它可以同时控制多张网页的布局

```
<html>
<head>
<style>
body {
  background-color: lightblue;
}
```

```
h1 {
  color: white;
  text-align: center;
}
```

```
p {
  font-family: verdana;
  font-size: 20px;
}
</style>
</head>
<body>
```

```
<h1>我的第一个 CSS 实例</h1>
<p>这是一个段落。</p>
```

```
</body>
</html>
```





CSS

id 选择器使用 HTML 元素的 id 属性来选择特定元素。

元素的 id 在页面中是唯一的，因此 id 选择器用于选择一个唯一的元素！

要选择具有特定 id 的元素，请写一个井号（#），后跟该元素的 id。

```
<!DOCTYPE html>
<html>
<head>
<style>
#para1 {
  text-align: center;
  color: red;
}
#para2 {
  text-align: right;
  color: green;
}
</style>
</head>
<body>

<p id="para1">Hello World!</p>
<p>本段不受样式的影响。</p>
<p id="para2">Hello World!</p>

</body>
</html>
```

W3school





本讲纲要

- Python语言
- Python的安装与开发环境配置
- Python基本语法
- HTML简介
- 互联网络协议
- 网络爬虫的“盗亦有道”




互联网TCP/IP协议

➤ 互联网TCP/IP协议：是一系列协议的总称





网络层协议





IP协议

➤ IP地址


- IPv4: 是一个由32位二进制整数组成的字符串，表示一个地址：192.168.0.1
- IPv6: 是一个由128位二进制整数组成的字符串，
- IP包: 网络传输数据被分割成小块，打包成IP包发送；
 - IP包特点: 按数据块发送，途径多个路由，即不保证到达，也不保证顺序到达；

➤ 端口

- 端口与软件程序对应；
- IP包包含源IP地址、目标IP地址、源端口和目标端口；



传输层协议




TCP和UDP协议

基于IP协议基础上，TCP负责在两台计算机之间建立可靠连接，保证数据按照顺序到达，流式通信；

基于IP协议基础上，UDP是面向无连接的通信协议，不保证数据顺序到达，报文式通信；

TCP和UDP协议

- TCP是面向连接，UDP是面向无连接；
 - TCP通信之前需要进行三次握手；
 - UDP不需要建立连接




- TCP是可靠的；UDP是不可靠的；



TCP和UDP协议

➤ TCP头部开销大，UDP头部开销小

— TCP头部




— UDP头部





应用层常见协议





HTTP和HTTPS协议

➤ HTTP协议是一个基于请求响应模式、无状态的应用层协议，常基于TCP协议的方式连接。

– HTTP的URL格式

- `http://host[“:”port][abs_path]`

– HTTP网络请求

- 请求行
- 请求头信息
- 空行
- 请求数据

Host → 目标服务器

User-Agent: → 浏览器信息

Accept: → 接受的数据类型

Connection → 保持连接（减少多次请求开销）

例1:

```
GET /562f25980001b1b106000338.jpg HTTP/1.1
Host: img.mukewang.com
User-Agent: Mozilla/5.0 (Windows NT 10.0; WOW64) AppleWebKit/537.36 (KHTML, like Gecko) Chrome/51.0.2704.106 Safari/537.36
Accept: image/webp,image/*,*/*;q=0.8
Referer: http://www.imooc.com/
Accept-Encoding: gzip, deflate, sdch
Accept-Language: zh-CN,zh;q=0.8
```

例2:

```
POST / HTTP1.1
Host: www.wrox.com
User-Agent: Mozilla/4.0 (compatible; MSIE 6.0; Windows NT 5.1; SV1; .NET CLR 2.0.50727; .NET CLR 3.0.04506.648; .NET CLR 3.5.21022)
Content-Type: application/x-www-form-urlencoded
Content-Length: 40
Connection: Keep-Alive



name = Professional % 20Ajax&publisher = Wiley
```



Cookie简介

➤ Cookie

- 是保存在用户浏览器端的，并在发出http请求时会默认携带的一段文本片段。它可以用来做用户认证，服务器校验等通过文本数据可以处理的问题。
- Cookie机制VS Session机制





Cookie简介

对比项	Cookie机制	Session机制
存储位置	客户端（浏览器）	服务器端
安全性	安全性较低，易被盗取	更安全（存储在服务器）
存储数据量	4KB 限制（单个 Cookie）	无严格限制
生命周期	过期时间可设置，长久有效	默认短期有效，通常依赖 Session ID
传输方式	随每次请求自动发送	只发送 Session ID，数据存于服务器
典型应用	记住密码、个性化设置	购物车、用户登录状态




本讲纲要

- Python语言
- Python的安装与开发环境配置
- Python基本语法
- HTML简介
- 互联网络协议
- 网络爬虫的“盗亦有道”



爬虫的“盗亦有道”

网络爬虫的尺寸



➤ 爬虫产生的影响

- ✓ 对服务器性能的骚扰
- ✓ 法律风险
- ✓ 隐私泄露



网络爬虫法律专题

➤ 相关法律

- 2017年6月1日起实施 《中华人民共和国网络安全法》
- 2021年9月1日起实施 《中华人民共和国数据安全法》
- 2021年11月1日起实施 《中华人民共和国个人信息保护法》

➤ 相关资料

- 网络爬虫的法律规制
 - http://www.cac.gov.cn/2019-06/16/c_1124630015.htm
- 中国爬虫违法违规案例汇总
 - https://github.com/HiddenStrawberry/Crawler_Illegal_Cases_In_China



网络爬虫法律专题

➤ 网络爬虫法律专题

- 在2019年05月28日国家网信办发布的《数据安全管理办法（征求意见稿）》中，拟通过行政法规的形式，对爬虫的使用进行限制：
 - 第十六条 网络运营者采取自动化手段访问收集网站数据，不得妨碍网站正常运行；此类行为严重影响网站运行，如自动化访问收集流量超过网站日均流量三分之一，网站要求停止自动化访问收集时，应当停止。
- 《刑法》第285条
 - 第一款【非法侵入计算机信息系统罪】违反国家规定，侵入国家事务、国防建设、尖端科学技术领域的计算机信息系统的，处三年以下有期徒刑或者拘役。
 - 第二款：【非法获取计算机信息系统数据、非法控制计算机信息系统罪】违反国家规定，侵入前款规定以外的计算机信息系统或者采用其他技术手段，获取该计算机信息系统中存储、处理或者传输的数据，或者对该计算机信息系统实施非法控制，情节严重的，处三年以下有期徒刑或者拘役，并处或者单处罚金；情节特别严重的，处三年以上七年以下有期徒刑，并处罚金。



网络爬虫的限制

➤ 来源审查：判断User-Agent进行限制

- ✓ 检查来访HTTP协议头的User-Agent域，只响应浏览器或者友好爬虫的访问

➤ 发布公告：Robots协议

- ✓ 告知所有网络爬虫的爬取策略，要求爬虫遵守协议
- ✓ <https://www.ctrip.com/robots.txt>

```
User-agent: *  
Disallow: /bin/  
Disallow: /Member/  
Disallow: /member/  
Disallow: /Service/  
Disallow: /service/  
Disallow: /Email/  
Disallow: /email/  
Disallow: /Pda/  
Disallow: /pda/  
Disallow: /ShareScript/  
Disallow: /sharescript/  
Disallow: /Public/AllianceCardIndex.asp  
Disallow: /public/alliancecardindex.asp  
Disallow: /supermarket/  
Disallow: /*Alliance*  
Disallow: /*alliance*  
Disallow: /*Ouid*  
Disallow: /*ouid*  
Allow: /
```

* 代表通配符，表示 URL 中任何位置出现 Alliance、alliance、Ouid 或 ouid 都会被禁止抓取。



本讲纲要

- Python语言
- Python的安装与开发环境配置
- Python基本语法
- HTML简介
- 互联网络协议
- 网络爬虫的“盗亦有道”



课上练习

- 熟悉Python编程
- 熟悉HTML的元素
- HTML代码练习

https://www.w3ccoo.com/html/exercise.asp?filename=exercise_html_headings1

- 了解自己感兴趣网页的爬虫协议 Robots.txt



推荐学习资料

➤ 推荐MOOC课程

✓ 中国大学MOOC: Python网络爬虫与信息提取 嵩天

- <https://www.icourse163.org/learn/BIT-1001870001?tid=1206951268#/learn/announce>

✓ B站学习资源

- <https://www.bilibili.com/video/av79090497?p=1>

➤ 课程分享[周一中午十二点前报名（邮件/企微） 周二中午12点前PPT发送 5-10分钟]

✓ 爬虫的“盗亦有道”

- Robots.txt 真的能“保护”网站数据不被爬取吗？
- 国内外对于爬虫态度的对比？
- 如果你是某平台的开发者，你会如何保护你的数据不被爬取？及相关案例

谢谢!

Questions & Comments

