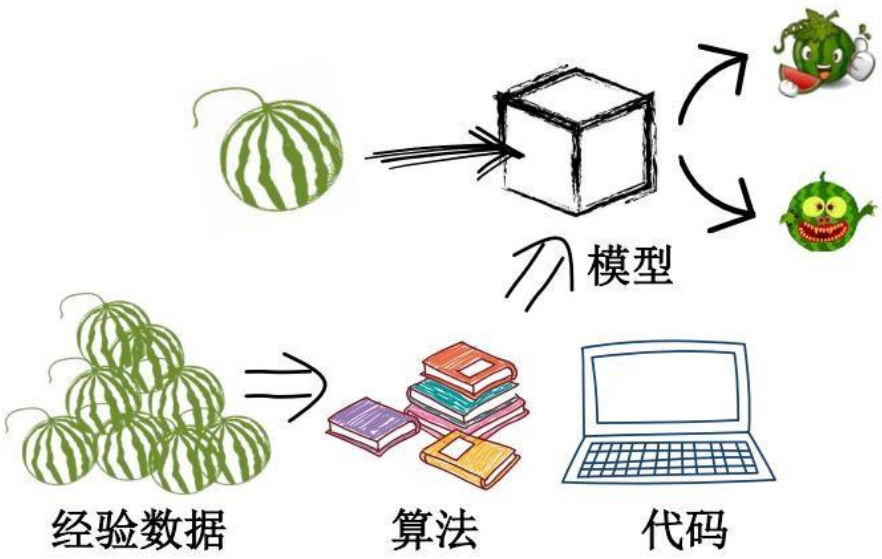
回顾----机器学习

- “经验”通常以“数据”存在
- 从数据中产生“模型”
- 模型对“新情况”进行“判断”

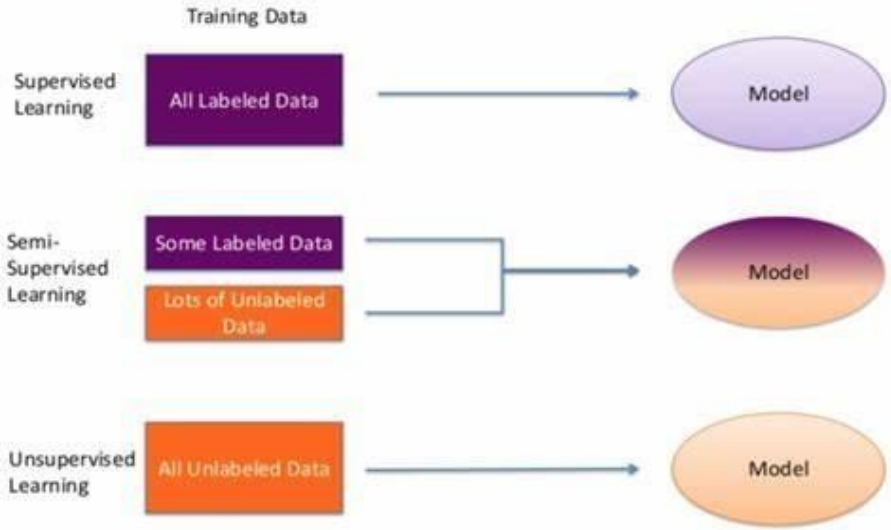


回顾----基本术语

- “数据集”(data set)
- “示例”(instance) 或“样本”(sample)
- “属性”(attribute)或“特征”(feature)
- “学习”(learning)或“训练”(training)
- “训练集”(training set)
- “标记”(label)
- “样例”（example)
- “标记空间”(label space)或“输出空间”
- “测试”(testing)
- “测试样本”(testing sample)
- “泛化”(generalization)能力

回顾----机器学习的任务分类

- 监督式学习(supervised learning)
- 非监督式学习(unsupervised learning)
- 半监督式学习(semi-supervised learning)
- 强化学习(reinforcement learning)



回顾----机器学习框架

$f($  $)=$ “cat”

Training

Testing

函数集合

模型

$f_1, f_2 \cdots$

Step 1

Goodness of function f

Step 2

Pick the “Best” Function

f^*

Step 3

Using f^*

“cat”

Training Data



“monkey”



“cat”



“dog”



机器学习

Chapter 2：线性模型I

丁婧颖
信息管理与工程学院

变量间的统计关系

- **确定性关系或函数关系：**研究的是确定现象非随机变量间的关系。
  - 举例1：商品的销售额与销售量之间的关系 $y = px$

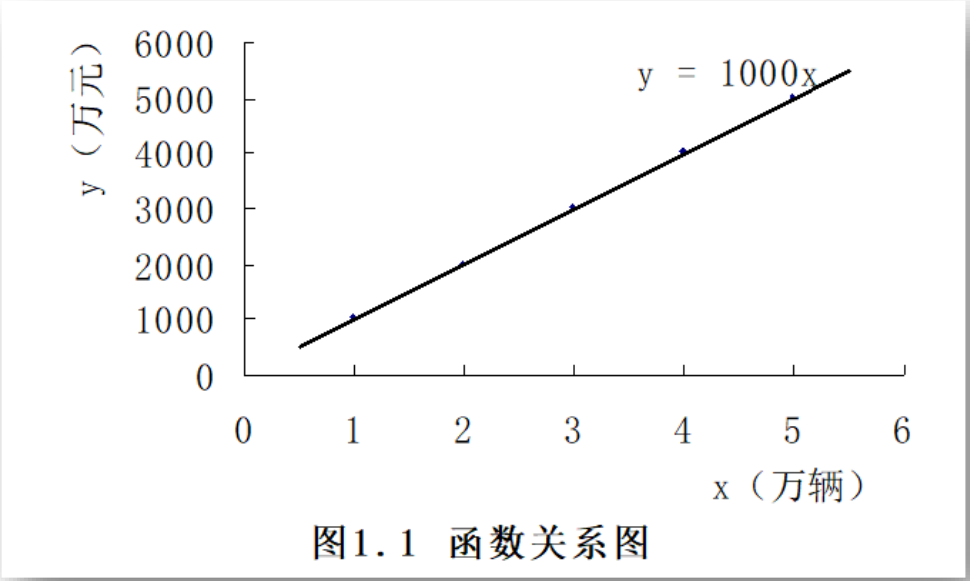


图1.1 函数关系图

  - 举例2：圆的面积与半径之间的关系 $S=\pi R^2$

变量间的统计关系

- 统计依赖或相关关系：研究的是非确定现象随机变量间的关系。
  - 举例：城市生活用电量 Y 与气温 X 有很大的关系，但不能由气温 X 准确地决定用电量 Y。

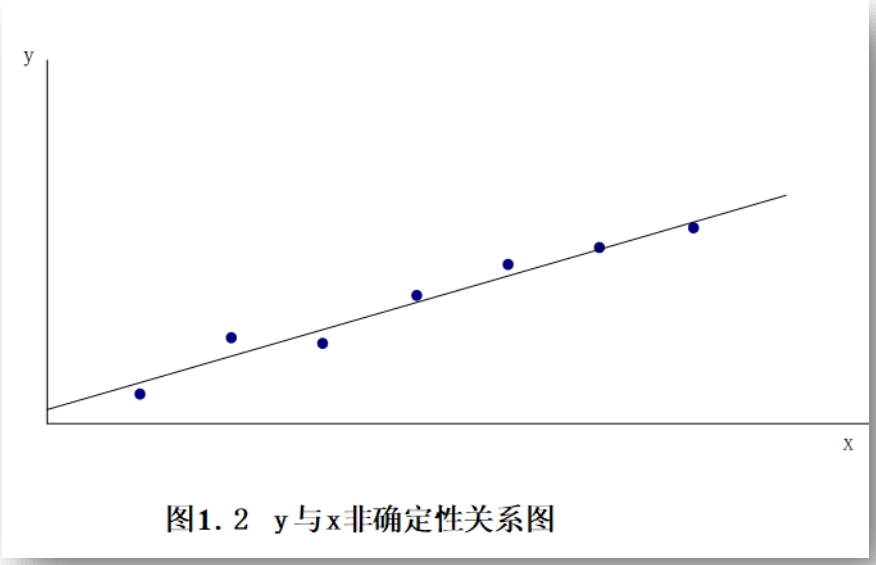
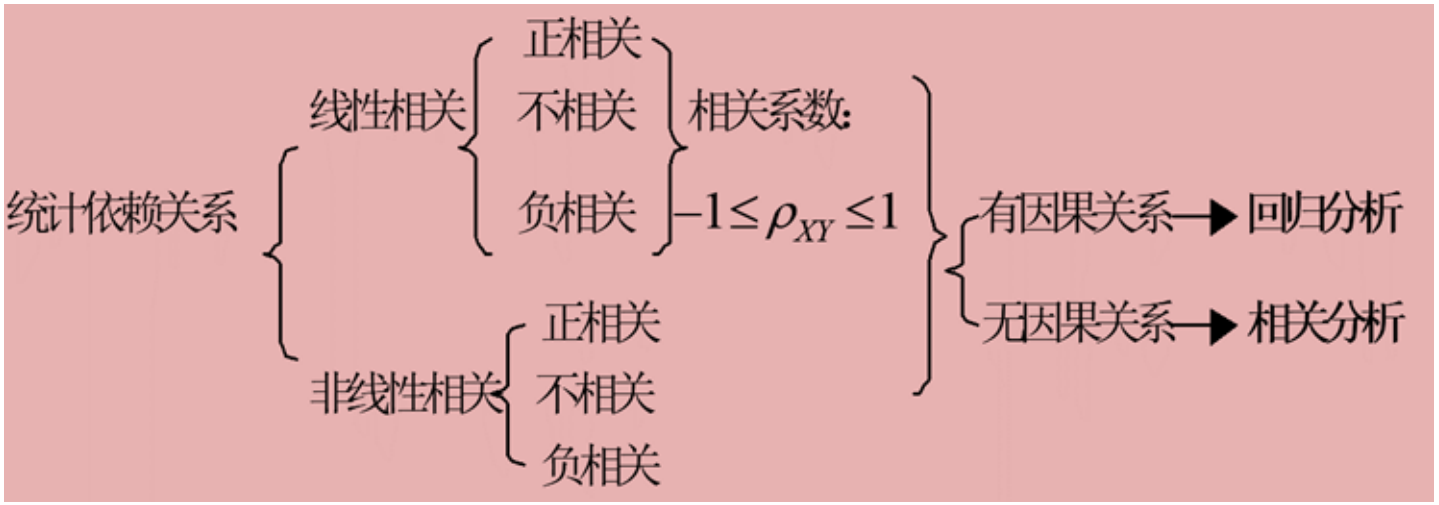


图1.2 y与x非确定性关系图

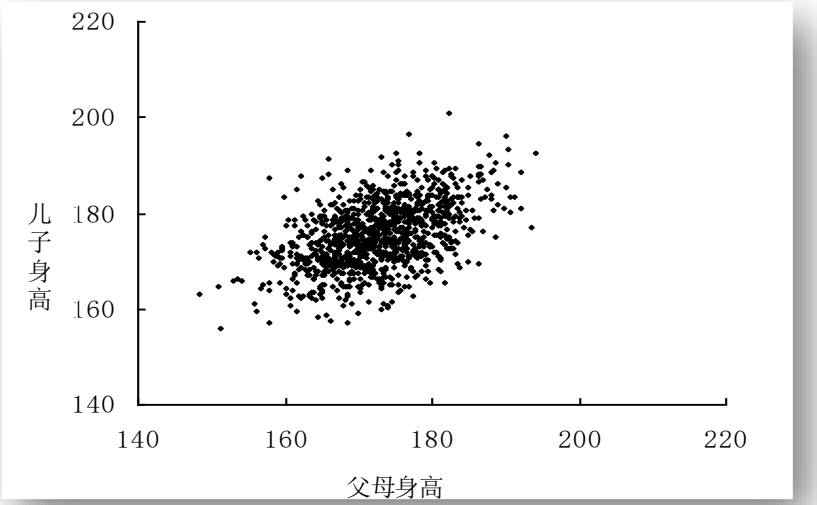
变量间的统计关系

- 变量间统计依赖关系的考察主要是通过相关分析(correlation analysis)或回归分析(regression analysis)来完成的:
  - 相关分析:以测度两个变量之间的线性关联力度为其主要目的。
  - 回归分析:根据其他变量的设定值来估计或预测某一变量的平均值。



回归模型

- 回归名称的由来: “回归”一词的英文是“regression”其基本思想和方法都是由英国著名生物学家、统计学家F. 高尔顿(**F.Galton**:1822-1911)在研究人类遗传问题时提出的。为了研究父代与子代身高的关系,高尔顿和他的学生、现代统计学的奠基者之一K.皮尔逊(**K.Pearson**: 1856-1936)在研究父母身高与其子女身高的遗传问题时,观察了1078 对夫妇,以每对夫妇的平均身高作为x,取他们的成年儿子身高作为y,将结果在平面直角坐标系上绘成散点图,发现趋势近乎一条直线。



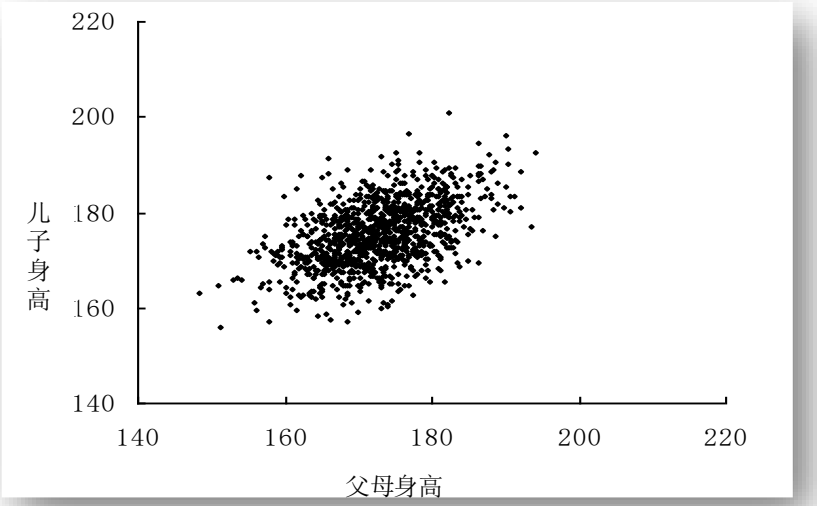
$$\hat{y} = 60.81 + 0.646x$$

成年儿子身高

父母平均身高

回归模型

- 一般来说：身高超过平均值的父亲，他们儿子的平均身高将低于父亲的平均身高，反之，身高低于平均值的父亲，他们儿子的平均身高将高于父亲的平均身高。
- 高尔顿对这个一般结论的解释是：大自然具有一种约束力，使人类的身高分布在一定时期内相对稳定而不产生两极分化，这就是所谓的**回归效应**。从此引进了回归一词。对于以后将要讲到的回归模型，回归效应不一定具有。人们在研究大量的问题中，其变量x与y之间的关系并不总是具有这种“回归”的含义。



$$\hat{y} = 60.81 + 0.646x$$

$$x = 180, \hat{y} = 177.09$$
$$x = 165, \hat{y} = 167.4$$

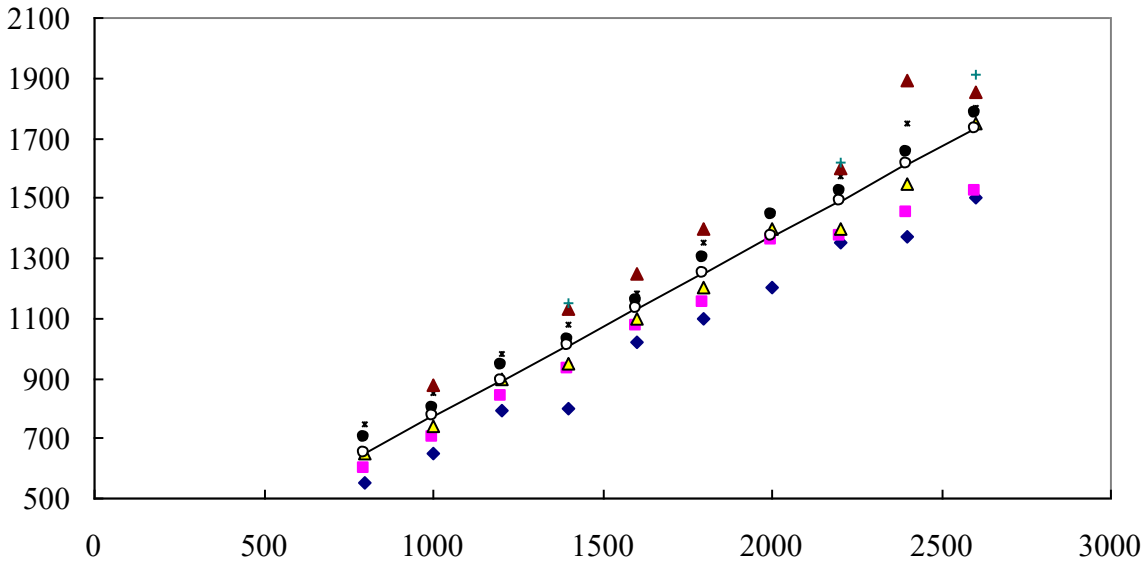
回归模型

引例：一个社区有60户家庭组成，要研究该社区每月家庭消费支出Y与每月家庭可支配收入X的关系。

表1　某社区每月家庭收入与消费支出调查统计表

	每月家庭收入X(元)									
	800	1000	1200	1400	1600	1800	2000	2200	2400	2600
每月家庭消费支出Y（元）	550	650	790	800	1020	1100	1200	1350	1370	1500
	600	700	840	930	1070	1150	1360	1370	1450	1520
	650	740	900	950	1100	1200	1400	1400	1550	1750
	700	800	940	1030	1160	1300	1440	1520	1650	1780
	750	850	980	1080	1180	1350	1450	1570	1750	1800
	0	880	0	1130	1250	1400	0	1600	1890	1850
	0	0	0	1150	0	0	0	1620	0	1910
共计	3250	4620	4450	7070	6780	7500	6850	10430	9660	12110
条件概率	1/5	1/6	1/5	1/7	1/6	1/6	1/5	1/7	1/6	1/7
条件均值	650	770	890	1010	1130	1250	1370	1490	1610	1730

回归模型



从散点图发现：随着收入的增加，消费“平均来讲”也在增加，且Y的条件均值均落在一根正斜率的直线上。

回归模型

回归模型的一般形式

$$y = f(x_1, x_2, \cdots, x_p) + e \qquad (1.1)$$

$f(x_1, x_2, \cdots, x_p)$称为y对$x_1, x_2, \cdots, x_p$的回归函数，（1.1）称为回归模型的一般形式。

- 通常称y为因变量、响应变量或被解释变量，称$x_1, x_2, \cdots, x_p$为自变量，预测变量、协变量或解释变量。
- y的值一部分是由$x_1, x_2, \cdots, x_p$能够决定的部分，它是$x_1, x_2, \cdots, x_p$的函数$f(x_1, x_2, \cdots, x_p)$，另一部分由众多未加考虑的因素（包括随机因素）所产生的影响，称为随机误差，常用e表示，要求$E(e) = 0$。

回归模型

- **随机误差项的影响因素**

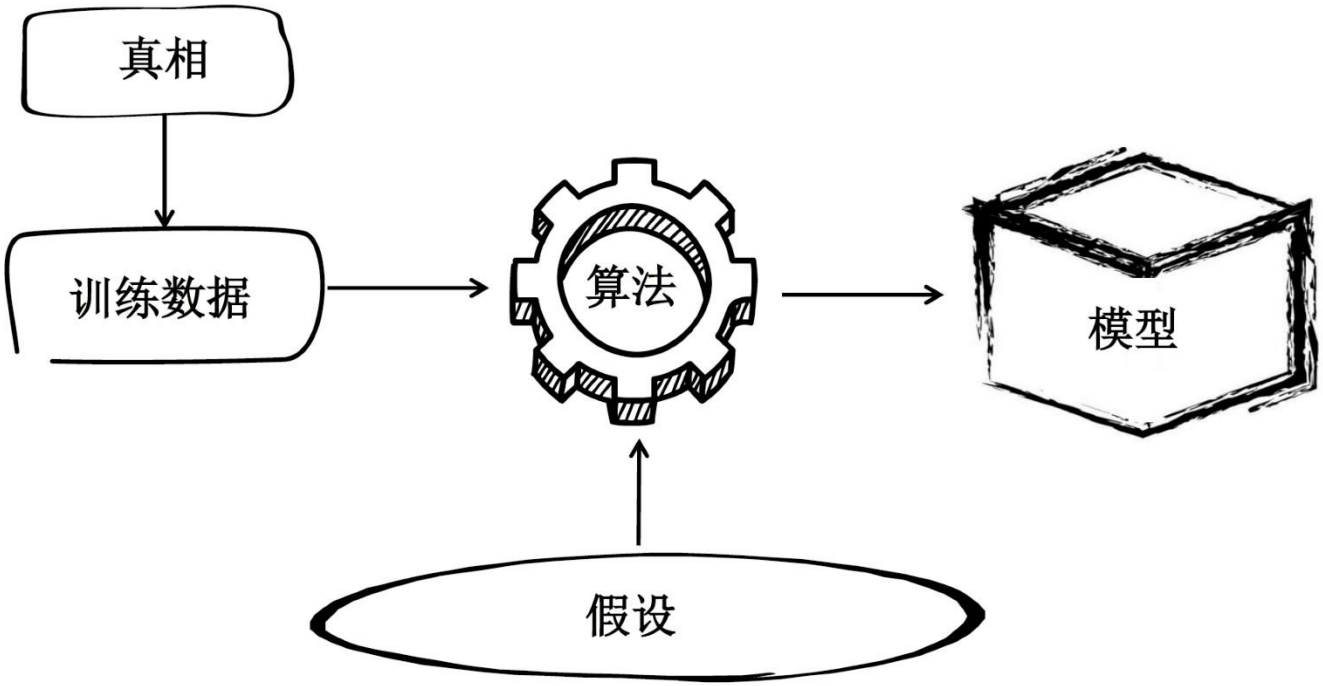
  在解释变量中被忽略的因素的影响；

  变量观测值的观测误差的影响；

  模型关系的设定误差的影响；

  其他随机因素的影响。

线性假设空间

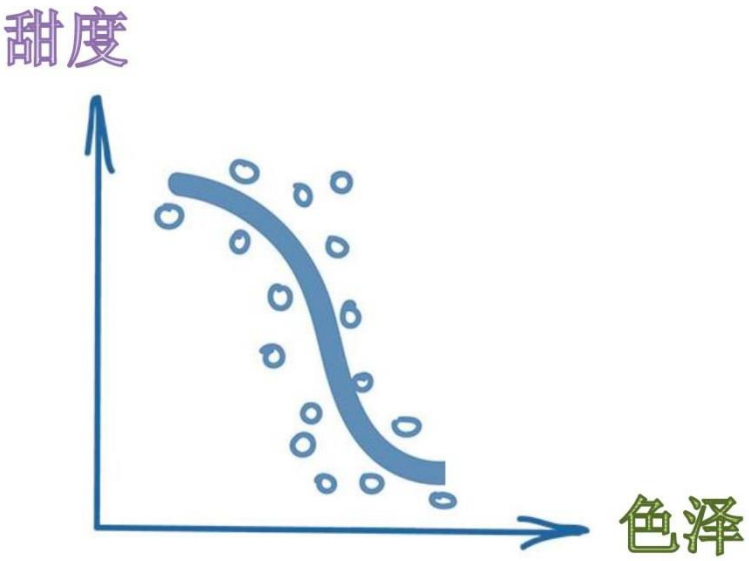


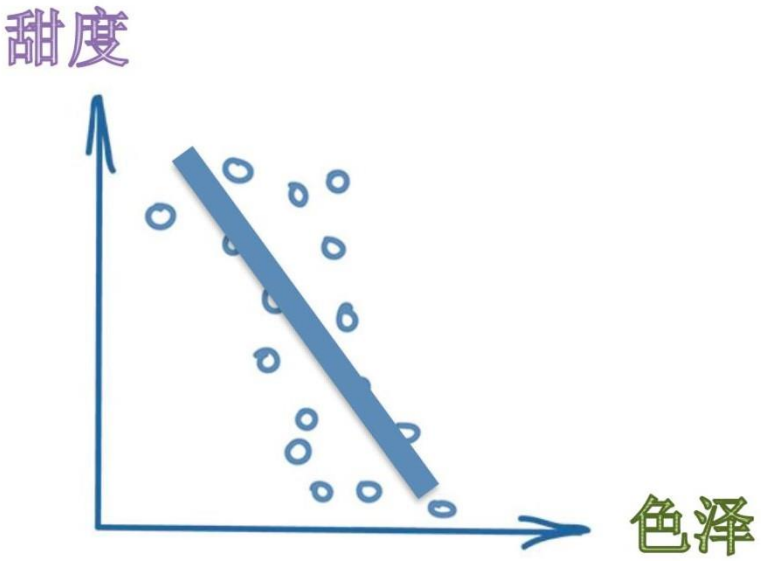
$$f(\boldsymbol{x}) = w_1 x_1 + w_2 x_2 + \cdots + w_d x_d + b$$

$$f(\boldsymbol{x}) = \boldsymbol{w}^{\mathrm{T}} \boldsymbol{x} + b \qquad \boldsymbol{w} = (w_1; w_2; \ldots; w_d) \quad \boldsymbol{x} = (x_1; x_2; \ldots; x_d)$$

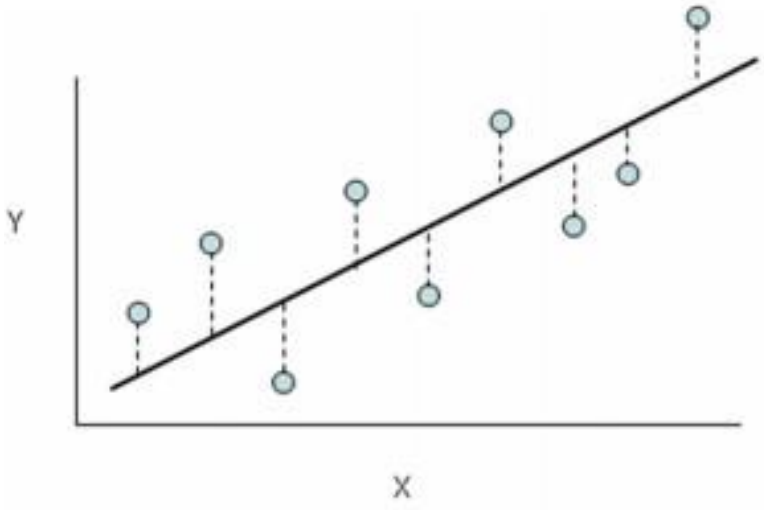
$$f_{\text{好瓜}}(\boldsymbol{x}) = 0.2 \cdot x_{\text{色泽}} + 0.5 \cdot x_{\text{根蒂}} + 0.3 \cdot x_{\text{敲声}} + 1$$

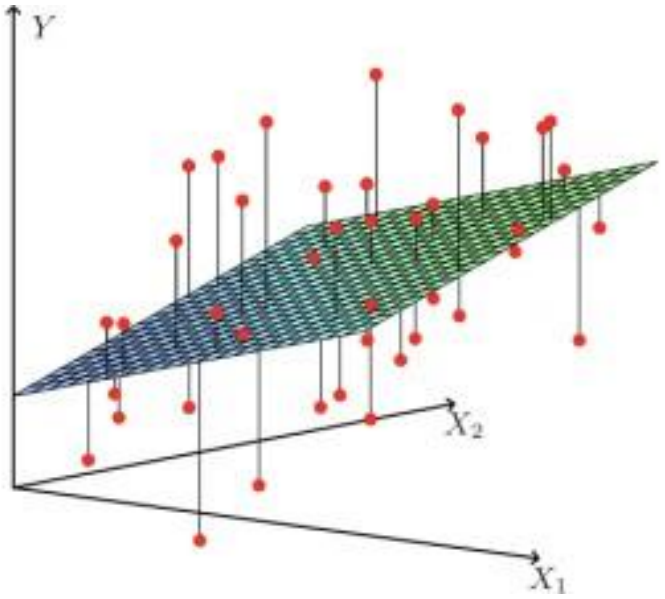
线性拟合函数





线性回归



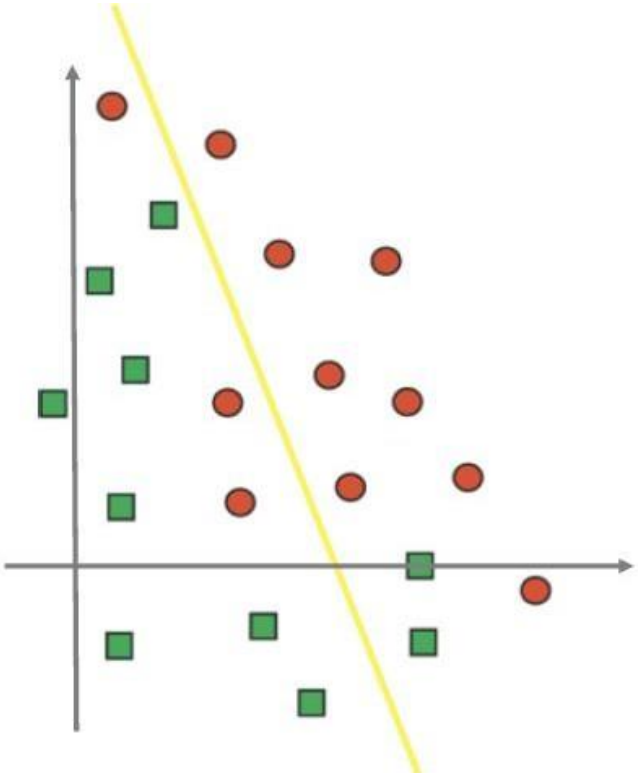


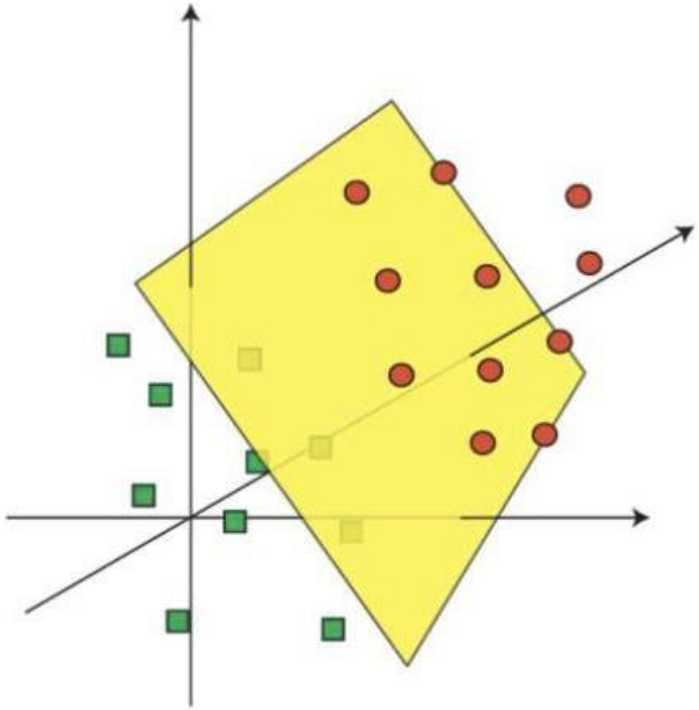
$$f(x) = b + w_1 x$$

$$f(x) = b + w_1 x_1 + w_2 x_2$$

另加误差项

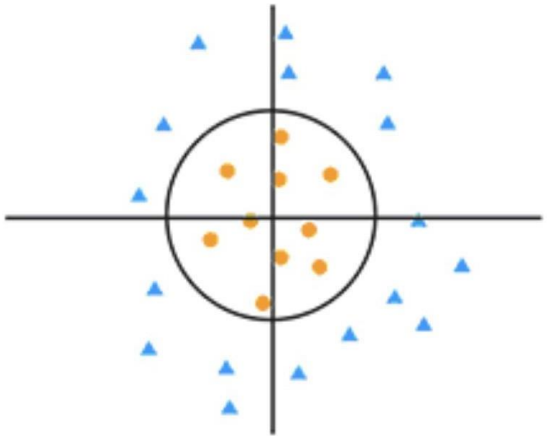
线性分类





线性模型

- 优点
  - 形式简单、易于建模
  - 可解释性
  - 非线性模型的基础
- 缺点
  - 无法处理非线性关系



线性回归

- 给定训练数据集 $D = \{(\boldsymbol{x}_1, y_1), (\boldsymbol{x}_2, y_2), \ldots, (\boldsymbol{x}_m, y_m)\}$
- $\boldsymbol{x}_i = (x_{i1}; x_{i2}; \ldots; x_{id})$ $\quad y_i \in \mathbb{R}$
- 学习模型 $f(\boldsymbol{x}) = \boldsymbol{w}^T \boldsymbol{x} + b$
- 最小经验误差 $\arg\min_f \sum_{i=1}^{m} \ell(f(\boldsymbol{x}_i), y_i)$
- 均方误差

$$\ell(f(\boldsymbol{x}_i), y_i) = (f(\boldsymbol{x}_i) - y_i)^2$$

  - 距离远的样本点对结果影响大
  - 距离小的样本点对结果影响不大
  - 对应欧式距离

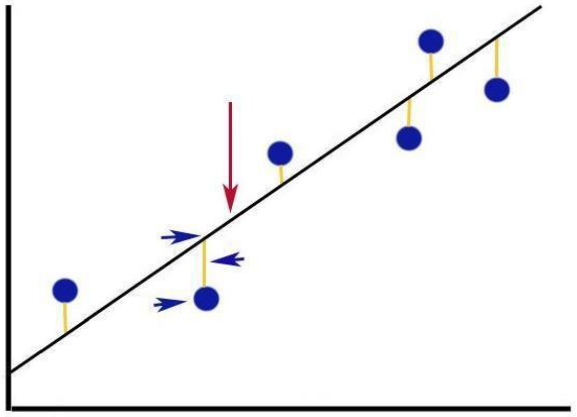
属性是离散值

- 有序关系：连续化为连续值
- 无序关系：有k个属性值，则转换为k维向量

（西瓜，南瓜，黄瓜）

（001，010，100）

线性回归



- 最小经验误差

$$\arg\min_{f} \sum_{i=1}^{m} \ell(f(\boldsymbol{x}_i), y_i) = \arg\min_{(\boldsymbol{w},b)} \sum_{i=1}^{m} \left(f(\boldsymbol{x}_i) - y_i\right)^2$$

$$= \arg\min_{(\boldsymbol{w},b)} \underbrace{\sum_{i=1}^{m} \left(y_i - \boldsymbol{w}^T \boldsymbol{x}_i - b\right)^2}_{\mathcal{L}_{\boldsymbol{w},b}}$$

- 最小二乘法(least square method)：基于最小化均方误差来进行模型求解

线性回归

$$f(\boldsymbol{x}) = \boldsymbol{w}^{\mathrm{T}}\boldsymbol{x} + b$$
$$f(\hat{\boldsymbol{x}}) = \hat{\boldsymbol{w}}^{\mathrm{T}}\hat{\boldsymbol{x}}$$

- 解析解：$\hat{\boldsymbol{w}} = (\boldsymbol{w}; b) \qquad \hat{\boldsymbol{x}} = (\boldsymbol{x}; 1)$

$$\mathbf{X} = \begin{pmatrix} x_{11} & x_{12} & \cdots & x_{1d} & 1 \\ x_{21} & x_{22} & \cdots & x_{2d} & 1 \\ \vdots & \vdots & \ddots & \vdots & \vdots \\ x_{m1} & x_{m2} & \cdots & x_{md} & 1 \end{pmatrix} = \begin{pmatrix} \boldsymbol{x}_1^{\mathrm{T}} & 1 \\ \boldsymbol{x}_2^{\mathrm{T}} & 1 \\ \vdots & \vdots \\ \boldsymbol{x}_m^{\mathrm{T}} & 1 \end{pmatrix}$$

$$\boldsymbol{y} = (y_1; y_2; \ldots; y_m)$$

$$\mathcal{L}_{\hat{\boldsymbol{w}}} = \sum_{i=1}^{m} \left(y_i - \boldsymbol{w}^{\mathrm{T}}\boldsymbol{x}_i - b\right)^2 = (\boldsymbol{y} - \mathbf{X}\hat{\boldsymbol{w}})^{\mathrm{T}}(\boldsymbol{y} - \mathbf{X}\hat{\boldsymbol{w}})$$

$$\Downarrow$$

$$\hat{\boldsymbol{w}}^* = \arg\min_{\hat{\boldsymbol{w}}} (\boldsymbol{y} - \mathbf{X}\hat{\boldsymbol{w}})^{\mathrm{T}}(\boldsymbol{y} - \mathbf{X}\hat{\boldsymbol{w}})$$

$$\Downarrow$$

$$\frac{\partial \mathcal{L}_{\hat{\boldsymbol{w}}}}{\partial \hat{\boldsymbol{w}}} = 0 \rightarrow 2\mathbf{X}^{\mathrm{T}}(\mathbf{X}\hat{\boldsymbol{w}} - \boldsymbol{y}) = 0 \rightarrow \hat{\boldsymbol{w}}^* = \left(\mathbf{X}^{\mathrm{T}}\mathbf{X}\right)^{-1}\mathbf{X}^{\mathrm{T}}\boldsymbol{y}$$

$$\Downarrow$$

$$f(\hat{\boldsymbol{x}}) = \hat{\boldsymbol{x}}^{\mathrm{T}}\left(\mathbf{X}^{\mathrm{T}}\mathbf{X}\right)^{-1}\mathbf{X}^{\mathrm{T}}\boldsymbol{y}$$

$$\frac{\partial \beta^{\mathrm{T}} x}{\partial x} = \beta \qquad \frac{\partial x^{\mathrm{T}} \beta}{\partial x} = \beta$$

$$\frac{\partial x^{\mathrm{T}} A x}{\partial x} = (A + A^{T})x$$

$\mathbf{X}^{\mathrm{T}}\mathbf{X}$的逆矩阵存在 → $\mathbf{X}^{\mathrm{T}}\mathbf{X}$是满秩矩阵

线性回归方差分析

总平方和SST (sum of squares for total) 是：

$$\mathrm{SST} = \sum_{i=1}^{n} (y_i - \bar{y})^2 \quad \text{，其中：} \quad \bar{y} = \frac{1}{n} \sum_{i} y_i$$

回归平方和SSReg (sum of squares for regression。也可写做**模型平方和**，SSM，sum of squares for model) 是：

$$\mathrm{SSReg} = \sum (\hat{y}_i - \bar{y})^2$$

残差平方和SSE (sum of squares for error) 是：

$$\mathrm{SSE} = \sum_{i} (y_i - \hat{y}_i)^2$$

总平方和SST又可写做SSReg和SSE的和：

$$\mathrm{SST} = \sum_{i} (y_i - \bar{y})^2 = \mathrm{SSReg} + \mathrm{SSE}.$$

回归系数R^2是：

$$R^2 = \frac{\mathrm{SSReg}}{\mathrm{SST}} = 1 - \frac{\mathrm{SSE}}{\mathrm{SST}}.$$

线性回归方差分析

- SST可以看做是naïve prediction的SSE
- $SST \geq SSE \geq 0$
- 如果$SSE=0$，那么$R^2 = 1$
  - Perfect prediction, no error
- 如果$SSE=SST$，那么$R^2 = 0$
  - As bad as just use the mean

线性回归方差分析

- R^2的特点：
  1. 非负的统计量
  2. 是样本观测值的函数，是随机变量
  3. 取值范围： $0 \leq R^2 \leq 1$
- R^2的含义：
  - 反应因变量能通过回归关系被自变量解释的比例，衡量的是拟合好坏程度
  - 简而言之：模型可以解释为多大程度是自变量导致因变量的改变
  - 比如R^2等于0.7，那么表示，此回归模型对预测结果的可解释程度为70%
  - 越接近1，模型越精确，回归效果越显著

线性回归

- 若 $\mathbf{X}^{\mathrm{T}}\mathbf{X}$ 是满秩矩阵(full rank matrix)，解析解存在
- 若不是满秩矩阵，无法用该方法求解
  - 输入变量的个数大于样本数 (m<d+1)
  - 例如给定 $D=\{(2,1)\}$，学习线性模型 $f(x)=w_1x+b$

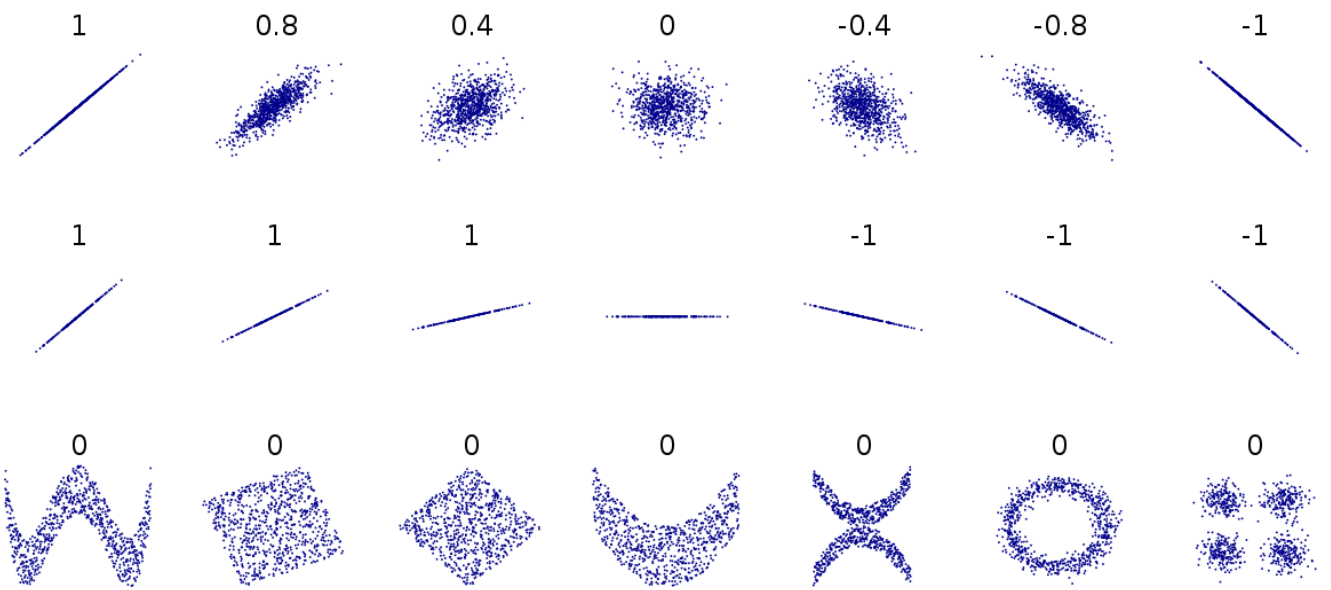
    $\mathcal{L}(\widehat{\boldsymbol{w}})=\frac{1}{2}(y-b-w_1x)^2=\frac{1}{2}(1-b-2w_1)^2$

  - 数据中存在多重共线性(Multicollinearity)：多个自变量之间存在精确/高度相关关系

多重共线性

- 检查相关系数correlation coefficients

$$r = \frac{\sum_{i=1}^{n}(X_i - \overline{X})(Y_i - \overline{Y})}{\sqrt{\sum_{i=1}^{n}(X_i - \overline{X})^2}\sqrt{\sum_{i=1}^{n}(Y_i - \overline{Y})^2}}$$



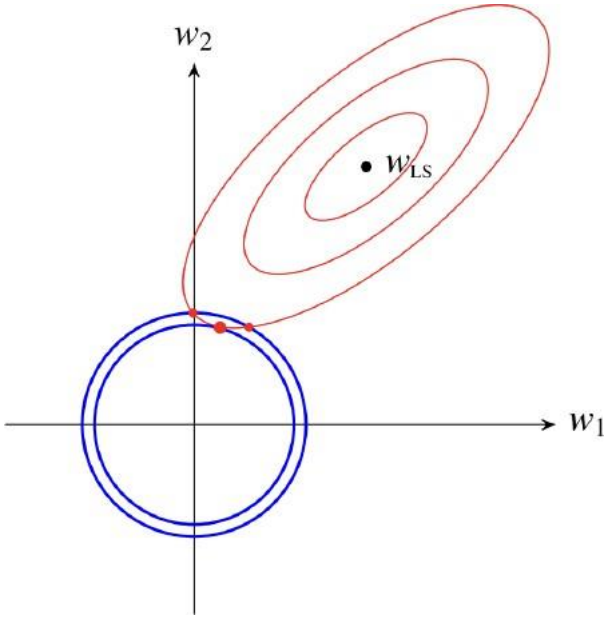
线性回归----正则化

- 岭回归（Ridge)：L2正则化项

<= t （阈值）

$$\mathcal{L}_{\hat{w}} = \sum_{i=1}^{m} \left(y_i - \boldsymbol{w}^T \boldsymbol{x}_i - b \right)^2 + \lambda \sum_{j=1}^{d} w_j^2$$

几何意义：平方和可以表示为 w1,w2 的一个二次函数，是一个在三维空间中的抛物面，可以用等值线来表示。而限制条件相当于在二维平面的一个圆。这个时候等值线与圆相切的点便是在约束条件下的最优点。



线性回归

- 岭回归（Ridge)：L2正则化项

$$\mathcal{L}_{\hat{w}} = \sum_{i=1}^{m} \left(y_i - \boldsymbol{w}^T \boldsymbol{x}_i - b \right)^2 + \lambda \sum_{j=1}^{d} w_j^2$$

岭回归的一些性质

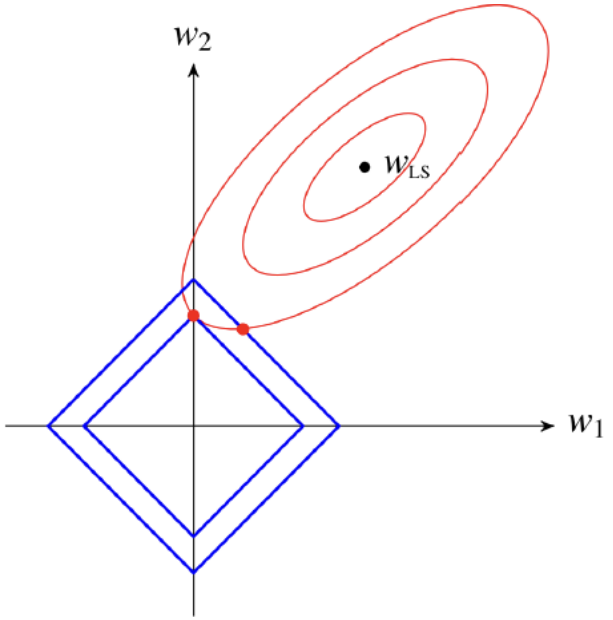
- 当岭参数 λ=0 时，得到的解是最小二乘解
- 当岭参数λ 趋向更大时，岭回归系数w_i趋向于0，约束项t 很小

线性回归

- LASSO(least absolute shrinkage and selection operator)：L1正则化项

$$\mathcal{L}_{\hat{w}} = \sum_{i=1}^{m} \left(y_i - \boldsymbol{w}^T \boldsymbol{x}_i - b\right)^2 + \lambda \sum_{j=1}^{d} |w_j|$$

几何意义：约束条件与岭回归的圆不同，LASSO的约束条件可以用方形表示。
相比圆，方形的顶点更容易与抛物面相交，顶点就意味着对应的很多系数为0，而岭回归中的圆上的任意一点都很容易与抛物面相交很难得到正好等于0的系数。这也就意味着，LASSO起到了很好的筛选变量的作用。



线性回归

- 弹性网络(Elastic Net)： L1,L2正则化项的结合

$$\mathcal{L}_{\hat{w}} = \sum_{i=1}^{m} \left(y_i - \boldsymbol{w}^T \boldsymbol{x}_i - b \right)^2 + r\lambda \sum_{j=1}^{d} |w_j| + \frac{1-r}{2} \lambda \sum_{j=1}^{d} w_j^2$$

- 利用参数r来控制L1和L2的凸组合
- r=0，岭回归； r=1，LASSO
- 弹性网结合了岭回归的计算的优点，同时又结合了LASSO 回归特征选择的优势

线性回归

- 对数线性回归

$$\ln y = \boldsymbol{w}^{\mathrm{T}}\boldsymbol{x} + b$$

- 广义线性回归

$$y = g^{-1}\left(\boldsymbol{w}^{\mathrm{T}}\boldsymbol{x} + b\right)$$

联系函数(link function)

