机器学习

Chapter 2：线性模型II

丁婧颖
信息管理与工程学院

回顾----线性回归

- 给定训练数据集 $D = \{(\boldsymbol{x}_1, y_1), (\boldsymbol{x}_2, y_2), \ldots, (\boldsymbol{x}_m, y_m)\}$
- $\boldsymbol{x}_i = (x_{i1}; x_{i2}; \ldots; x_{id}) \quad y_i \in \mathbb{R}$
- 学习模型 $f(\boldsymbol{x}) = \boldsymbol{w}^T \boldsymbol{x} + b$
- 最小经验误差 $\arg\min_f \sum_{i=1}^{m} \ell(f(\boldsymbol{x}_i), y_i)$
- 均方误差

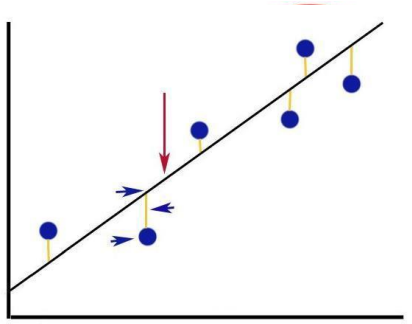
$$\ell(f(\boldsymbol{x}_i), y_i) = (f(\boldsymbol{x}_i) - y_i)^2$$

  - 距离远的样本点对结果影响大
  - 距离小的样本点对结果影响不大
  - 对应欧式距离

属性是离散值
- 有序关系：连续化为连续值
- 无序关系：有k个属性值，则转换为k维向量

（西瓜，南瓜，黄瓜）
（001，010，100）

回顾----线性回归



- 最小经验误差

$$\arg\min_{f} \sum_{i=1}^{m} \ell(f(\boldsymbol{x}_i), y_i) = \arg\min_{(\boldsymbol{w},b)} \sum_{i=1}^{m} (f(\boldsymbol{x}_i) - y_i)^2$$

$$= \arg\min_{(\boldsymbol{w},b)} \sum_{i=1}^{m} \left(y_i - \boldsymbol{w}^T \boldsymbol{x}_i - b\right)^2 \quad \mathcal{L}_{\boldsymbol{w},b}$$

- 最小二乘法(least square method)：基于最小化均方误差来进行模型求解

$$f(\hat{\boldsymbol{x}}) = \hat{\boldsymbol{x}}^{\mathrm{T}} \left(\mathbf{X}^{\mathrm{T}}\mathbf{X}\right)^{-1} \mathbf{X}^{\mathrm{T}} \boldsymbol{y}$$

回顾--线性回归

- 岭回归（Ridge)：L2正则化项

$$\mathcal{L}_{\hat{w}}=\sum_{i=1}^{m}\left(y_i-\boldsymbol{w}^T\boldsymbol{x}_i-b\right)^2+\lambda\sum_{j=1}^{d}w_j^2$$

- LASSO(least absolute shrinkage and selection operator)：L1正则化项

$$\mathcal{L}_{\hat{w}}=\sum_{i=1}^{m}\left(y_i-\boldsymbol{w}^T\boldsymbol{x}_i-b\right)^2+\lambda\sum_{j=1}^{d}|w_j|$$

- 弹性网络(Elastic Net)：L1,L2正则化项的结合

$$\mathcal{L}_{\hat{w}}=\sum_{i=1}^{m}\left(y_i-\boldsymbol{w}^T\boldsymbol{x}_i-b\right)^2+r\lambda\sum_{j=1}^{d}|w_j|+\frac{1-r}{2}\lambda\sum_{j=1}^{d}w_j^2$$

回顾----线性回归

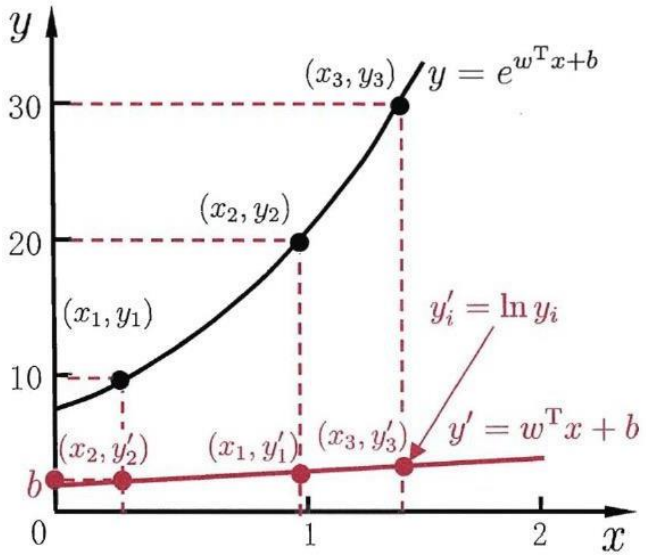
- 对数线性回归

$$\ln y = \boldsymbol{w}^{\mathrm{T}}\boldsymbol{x} + b$$

- 广义线性回归

$$y = g^{-1}\left(\boldsymbol{w}^{\mathrm{T}}\boldsymbol{x} + b\right)$$

联系函数(link function)

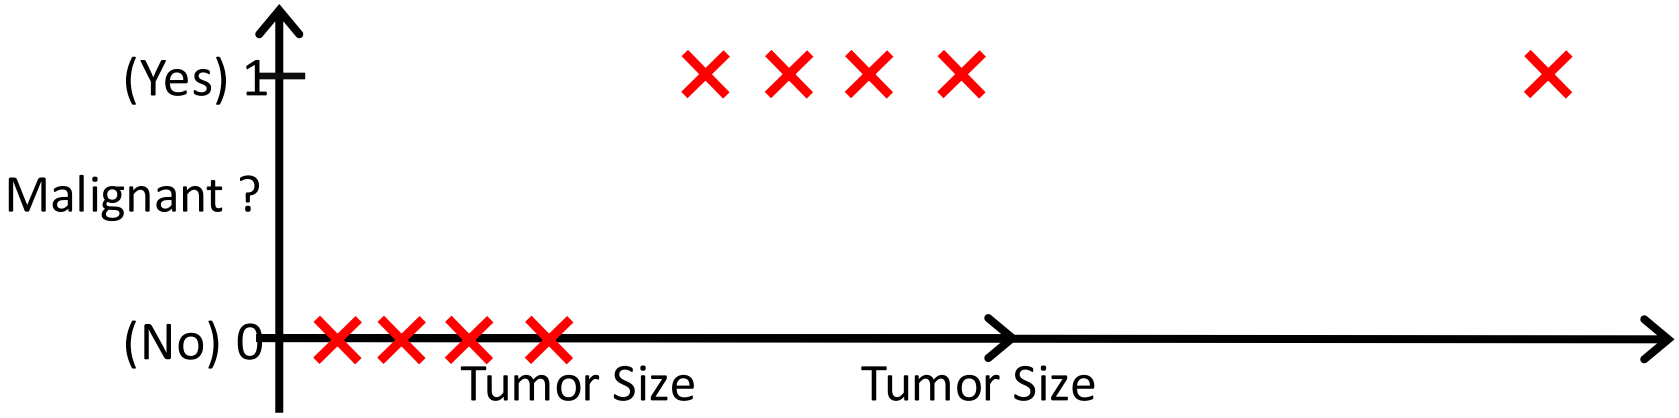


分类

邮件：是垃圾邮件还是非垃圾邮件？
在线交易：是否存在欺诈行为（是/否）？
肿瘤：恶性/良性？

$y \in \{0, 1\}$

0: “Negative Class” (e.g., **良性**肿瘤)
1: “Positive Class” (e.g., 恶性肿瘤)



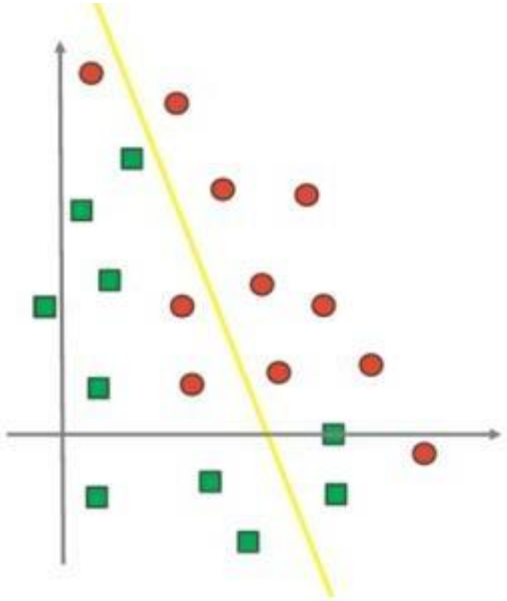
Threshold classifier output $h_\theta(x)$ at 0.5:

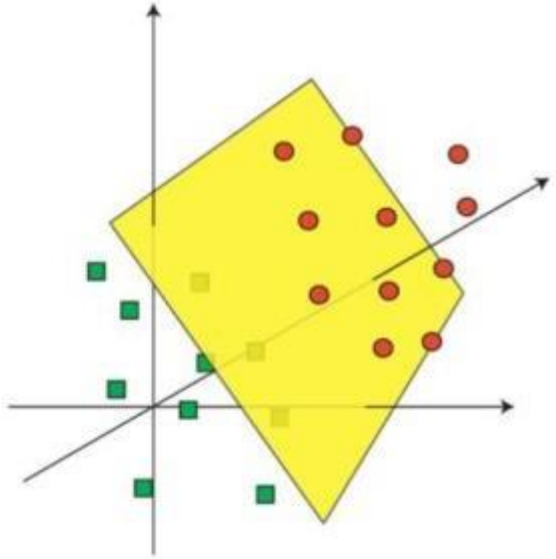
If $h_\theta(x) \geq 0.5$, predict "y = 1"

If $h_\theta(x) < 0.5$, predict "y = 0"

二分类

$$\boldsymbol{w}^{\mathrm{T}}\boldsymbol{x}+b \overset{?}{\longrightarrow} y \in \{0,1\}$$





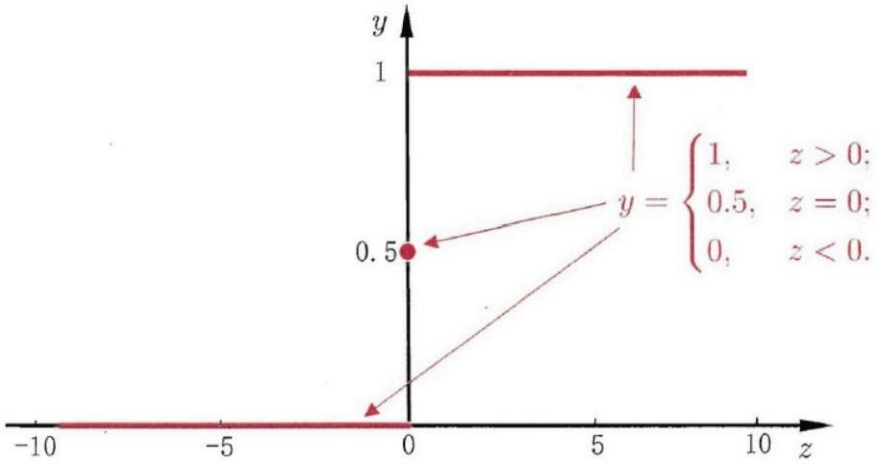
二分类

- 阶跃函数来联系

$$z = \boldsymbol{w}^{\mathrm{T}}\boldsymbol{x} + b$$

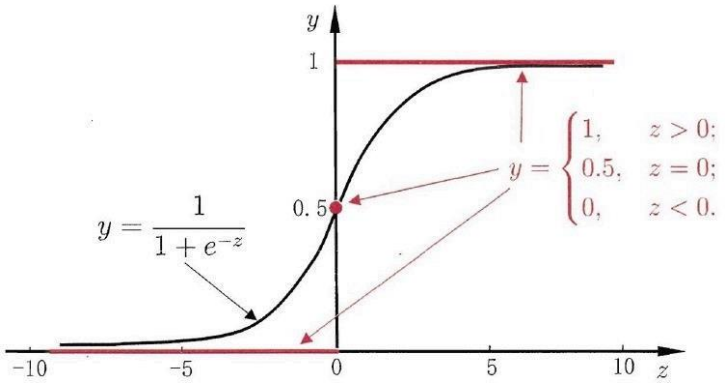
$$y = \begin{cases} 0, & z < 0 \\ 0.5, & z = 0 \\ 1, & z > 0 \end{cases}$$

- 问题：不连续



二分类

- 对数几率回归： Sigmoid函数来联系



$$z = \boldsymbol{w}^{\mathrm{T}}\boldsymbol{x} + b$$
$$y = \sigma(z) = \frac{1}{1+e^{-z}}$$

Sigmoid函数实现了任意实数到 [0,1]的映射。实际上 y 给出了输出为 1 的概率，比如当 y=0.8，那么说明有 80% 的概率输出为 1；输出为0的概率是输出为 1 的补集，也就是20%。

二分类-对数几率回归(logistic regression)

- 线性回归模型预测真实标记的对数几率
- 又叫逻辑回归（虽然它的名字是“回归”，但实际确实是一种分类方法）

$$p(y=1 \mid \boldsymbol{x}) = y = \sigma\left(\boldsymbol{w}^{\top}\boldsymbol{x}+b\right) = \frac{1}{1+e^{-\left(\boldsymbol{w}^{\top}\boldsymbol{x}+b\right)}}$$

$$p(y=0 \mid \boldsymbol{x}) = 1-y = \frac{e^{-\left(\boldsymbol{w}^{\mathrm{T}}\boldsymbol{x}+b\right)}}{1+e^{-\left(\boldsymbol{w}^{\mathrm{T}}\boldsymbol{x}+b\right)}}$$

$$\ln\frac{p(1 \mid x)}{p(0 \mid x)} = \ln\frac{y}{1-y} = \boldsymbol{w}^{\mathrm{T}}\boldsymbol{x}+b$$

对数几率(log odds,也叫logit)，相对可能性

优点

- 不仅预测出“类别”，还可得到近似概率预测，这对许多需利用概率辅助决策的任务很有用
- 对数几率函数是任意阶可导的凸函数，有很好的数学性质，可直接应用现有数值优化算法求取最优解

逻辑回归

- 极大似然法(maximum likelihood method)：即令每个样本属于其真实标记的概率越大越好

$$\mathcal{J}(\hat{\boldsymbol{w}}) = \sum_{i=1}^{m} \log p(y_i \mid \boldsymbol{x}_i; \hat{\boldsymbol{w}})$$

$$\Downarrow$$

$$\mathcal{J}(\hat{\boldsymbol{w}}) = \sum_{i=1}^{m} y_i \log p_{\hat{w}}(1 \mid \boldsymbol{x}_i) + (1 - y_i) \log p_{\hat{w}}(0 \mid \boldsymbol{x}_i)$$

$$\mathcal{L}(\hat{w}) = -\mathcal{J}(\hat{w})$$

$$\Downarrow$$

$$\arg\min_{\hat{w}} \mathcal{L}(\hat{\boldsymbol{w}}) = \arg\min_{\hat{w}} -\sum_{i=1}^{m} [y_i \log p_{\hat{w}}(1 \mid \boldsymbol{x}_i) + (1 - y_i) \log p_{\hat{w}}(0 \mid \boldsymbol{x}_i)]$$

逻辑回归

- 梯度下降法

$$\ell(\hat{\boldsymbol{w}}) = y \log p_{\hat{w}}(1 \mid \boldsymbol{x}) + (1-y) \log p_{\hat{w}}(0 \mid \boldsymbol{x})$$

$$= y \log \sigma(z) + (1-y) \log(1-\sigma(z))$$

$$\frac{\partial \ell(\hat{\boldsymbol{w}})}{\partial \hat{\boldsymbol{w}}} = -y \frac{1}{\sigma\left(\hat{\boldsymbol{w}}^{\mathrm{T}} \boldsymbol{x}\right)} \sigma(z)(1-\sigma(z)) \boldsymbol{x} - (1-y) \frac{-1}{1-\sigma\left(\hat{\boldsymbol{w}}^{\mathrm{T}} \boldsymbol{x}\right)} \sigma(z)(1-\sigma(z)) \boldsymbol{x}$$

$$= \left(\sigma\left(\hat{\boldsymbol{w}}^{\mathrm{T}} \boldsymbol{x}\right) - y\right) \boldsymbol{x}$$

$$\hat{\boldsymbol{w}} \leftarrow \hat{\boldsymbol{w}} + \eta\left(y - \sigma\left(\hat{\boldsymbol{w}}^{\mathrm{T}} \boldsymbol{x}\right)\right) \boldsymbol{x}$$

$$\frac{\partial \sigma(z)}{\partial z} = \sigma(z)(1-\sigma(z))$$

多分类

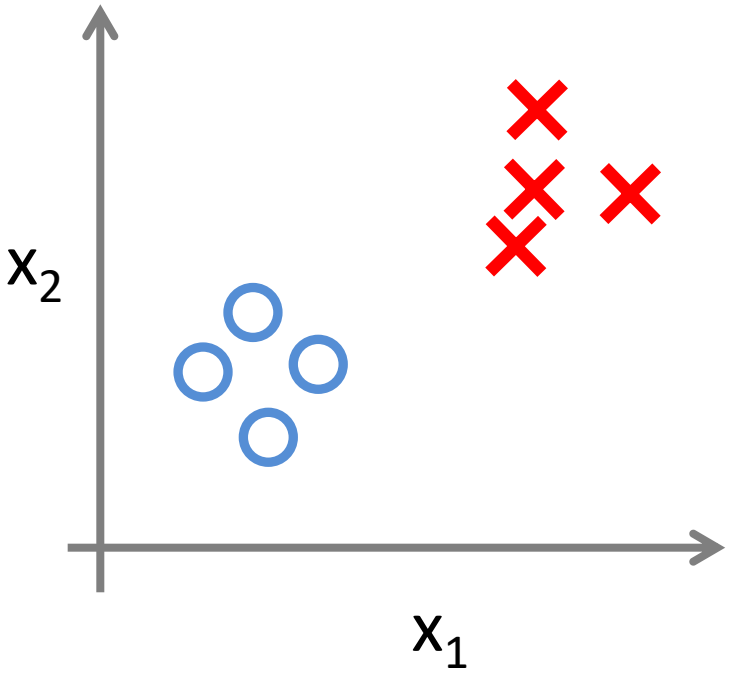
Email foldering/tagging: Work, Friends, Family, Hobby

Medical diagrams: Not ill, Cold, Flu

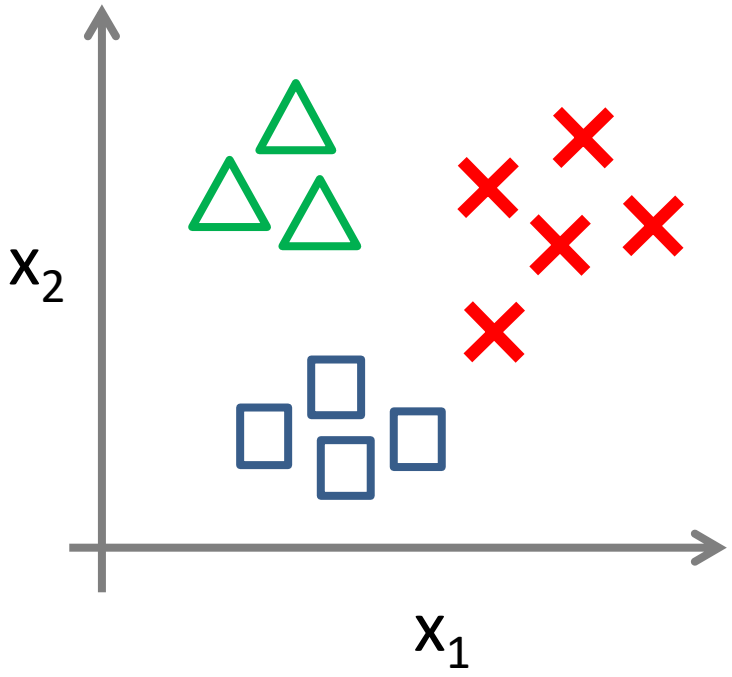
Weather: Sunny, Cloudy, Rain, Snow

多分类

Binary classification:



Multi-class classification:

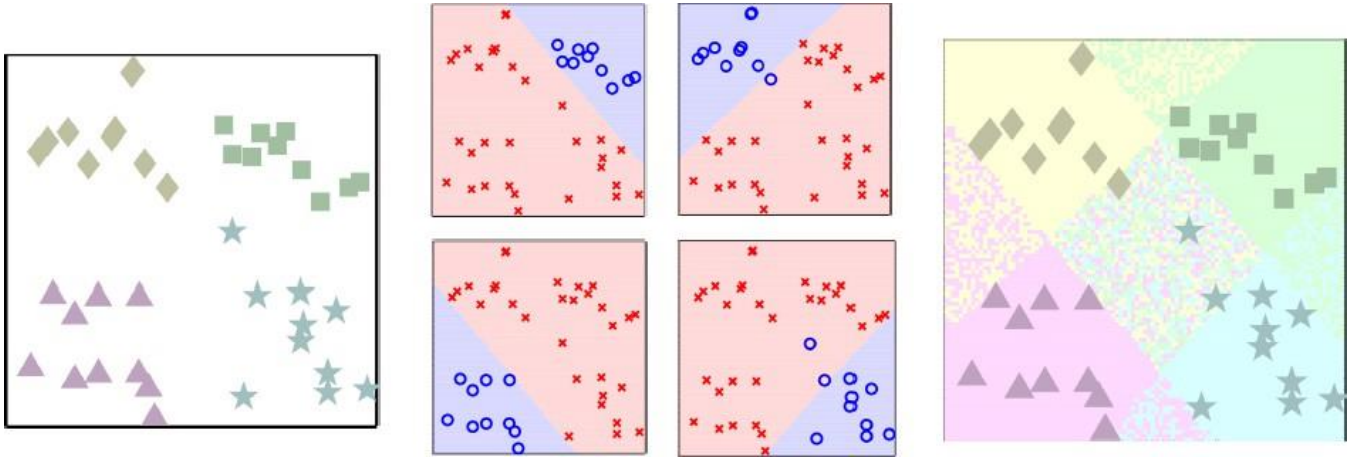


多分类

拆解法！

拆成若干个二分类任务

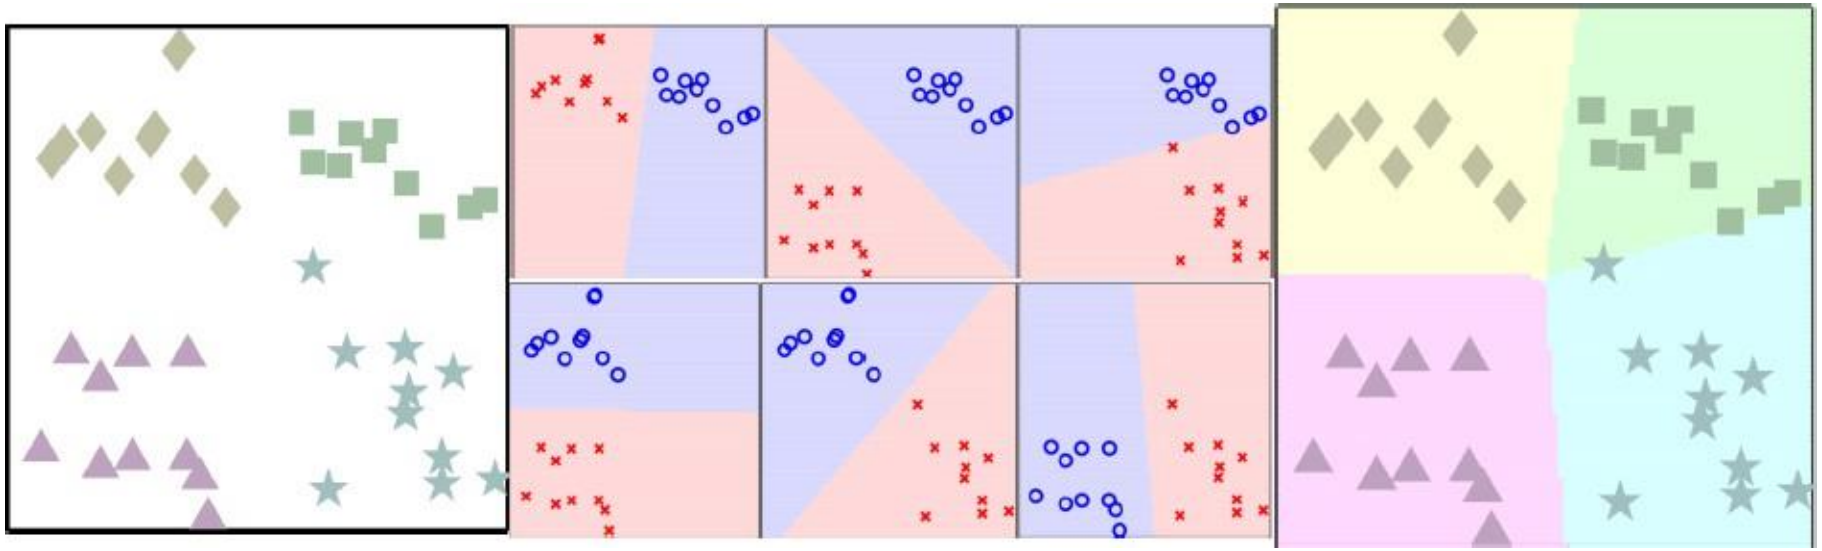
- 一对其余One vs. Rest



- 有一个分类器预测为正例，则对应的标记作为最终的分类结果
- 若有多个分类器预测为正例，则根据分类器预测的置信度进行选择

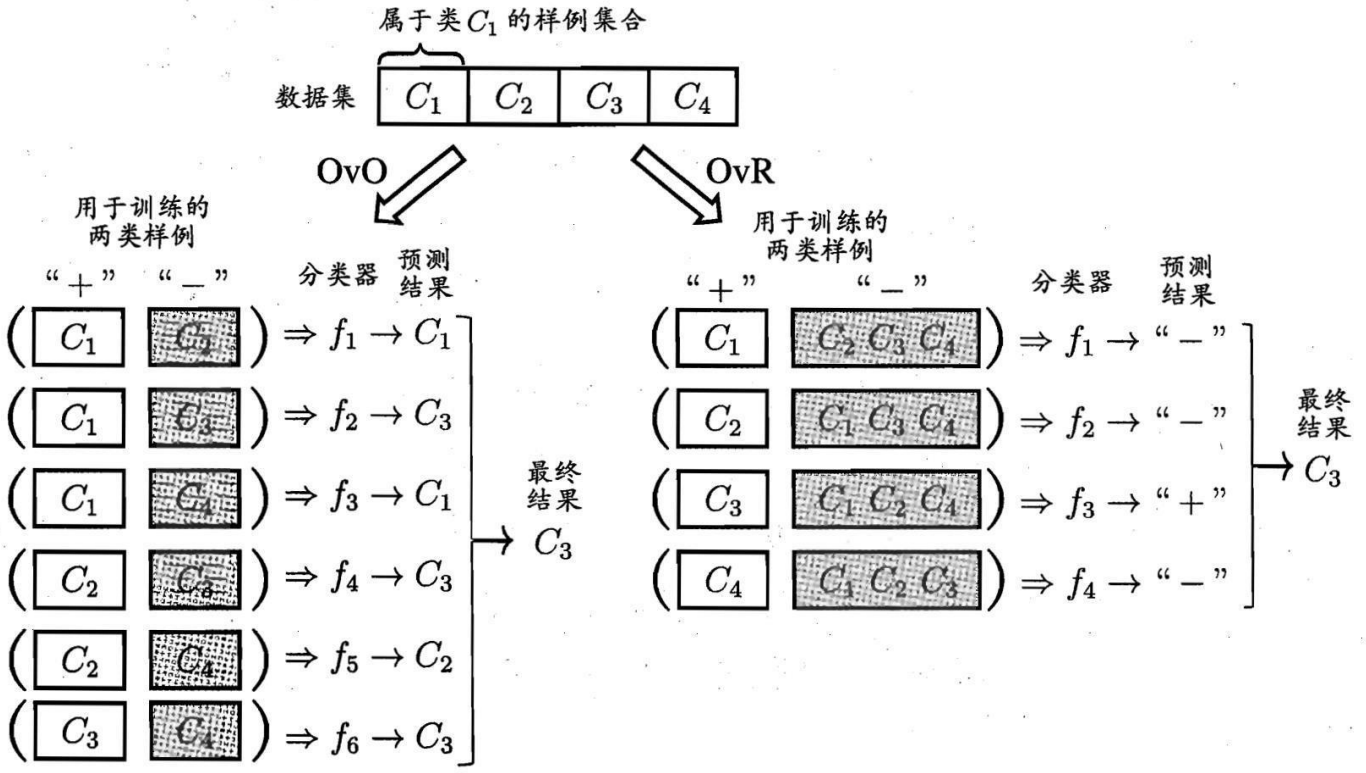
多分类

- 一对一One vs. One



- 两两配对
- 测试阶段投票产生最终的结果

多分类


属于类C_1的样例集合
数据集
C_1 C_2 C_3 C_4
OvO
OvR
用于训练的两类样例
“+” “−”
分类器
预测结果
$(C_1, C_2) \Rightarrow f_1 \rightarrow C_1$
$(C_1, C_3) \Rightarrow f_2 \rightarrow C_3$
$(C_1, C_4) \Rightarrow f_3 \rightarrow C_1$
$(C_2, C_3) \Rightarrow f_4 \rightarrow C_3$
$(C_2, C_4) \Rightarrow f_5 \rightarrow C_2$
$(C_3, C_4) \Rightarrow f_6 \rightarrow C_3$
最终结果
C_3
用于训练的两类样例
“+” “−”
分类器
预测结果
$(C_1, C_2\ C_3\ C_4) \Rightarrow f_1 \rightarrow$ “−”
$(C_2, C_1\ C_3\ C_4) \Rightarrow f_2 \rightarrow$ “−”
$(C_3, C_1\ C_2\ C_4) \Rightarrow f_3 \rightarrow$ “+”
$(C_4, C_1\ C_2\ C_3) \Rightarrow f_4 \rightarrow$ “−”
最终结果
C_3

N(N-1)/2

N

多分类-Softmax回归

- 总共K个类别 $C = \{c_1, c_2, \ldots, c_K\}$
- Softmax函数：对数几率回归在K个可能不同的值上的推广
- 参数 $\hat{\boldsymbol{w}} = \{\hat{\boldsymbol{w}}_1, \hat{\boldsymbol{w}}_2, \ldots, \hat{\boldsymbol{w}}_K\}$
- 第j类的概率

$$p_{\hat{w}}(y = c_j \mid \boldsymbol{x}) = \text{softmax}\left\{\hat{\boldsymbol{w}}_j^{\mathrm{T}} \boldsymbol{x}\right\} = \frac{e^{\hat{w}_j^T \boldsymbol{x}}}{\sum_{k=1}^{K} e^{\hat{w}_k^{\mathrm{T}} \boldsymbol{x}}} \quad \text{for } j = 1, \ldots, K$$

- 极大似然法 $\ell(\hat{\boldsymbol{w}}) = -\sum_k \delta(y = c_k) \log p_{\hat{\boldsymbol{w}}}(y = c_k \mid \boldsymbol{x})$

Softmax回归

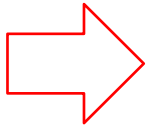
- Softmax要求每个样本必须属于某个类别，且所有可能的样本均被覆盖
- Softmax样本分量之和为1，当只有两个类别时，与对数几率回归完全相同
- Softmax回归分类器预测具有最高估计概率的类
- 一次只能预测一个类，即它是多类，而不是多输出

类别不平衡 (class-imbalance)

不同类别的样本比例相差很大；“小类”往往更重要

基本思路：

若 $\frac{y}{1-y} > 1$ 则 预测为正例.



若 $\frac{y}{1-y} > \frac{m^+}{m^-}$ 则 预测为正例.

基本策略

——“再缩放”(rescaling)：

$$\frac{y'}{1-y'} = \frac{y}{1-y} \times \frac{m^-}{m^+}$$

然而，精确估计 m^-/m^+ 通常很困难！

常见类别不平衡学习方法：

- 过采样 (oversampling)
  例如：SMOTE
- 欠采样 (undersampling)
  例如：EasyEnsemble
- 阈值移动 (threshold-moving)