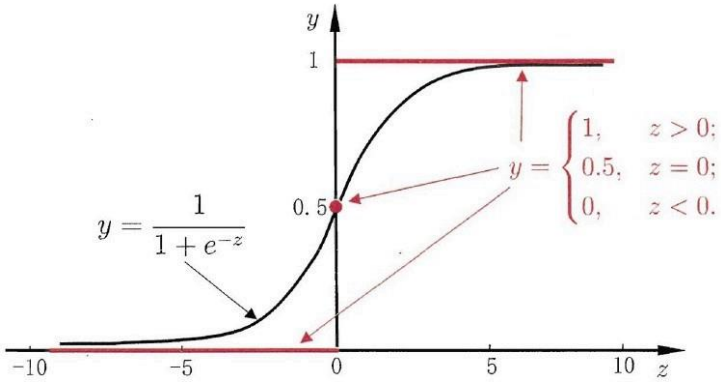
机器学习

Chapter 3：模型评估与选择

丁婧颖
信息管理与工程学院

回顾----二分类

- 对数几率回归： Sigmoid函数来联系



$$z = \boldsymbol{w}^{\mathrm{T}}\boldsymbol{x} + b$$
$$y = \sigma(z) = \frac{1}{1+e^{-z}}$$

Sigmoid函数实现了任意实数到 [0,1] 的映射。实际上 y 给出了输出为 1 的概率，比如当 y=0.8，那么说明有 80% 的概率输出为 1；输出为0的概率是输出为 1 的补集，也就是 20% 。

$$p(y=1 \mid \boldsymbol{x}) = y = \sigma\left(\boldsymbol{w}^{\top}\boldsymbol{x} + b\right) = \frac{1}{1+e^{-\left(\boldsymbol{w}^{\top}\boldsymbol{x}+b\right)}}$$

$$p(y=0 \mid \boldsymbol{x}) = 1 - y = \frac{e^{-\left(\boldsymbol{w}^{\mathrm{T}}\boldsymbol{x}+b\right)}}{1+e^{-\left(\boldsymbol{w}^{\mathrm{T}}\boldsymbol{x}+b\right)}}$$

回顾—二分类-对数几率回归 (logistic regression)

- 线性回归模型预测真实标记的对数几率
- 又叫逻辑回归（虽然它的名字是“回归”，但实际确实是一种分类方法）

$$p(y=1 \mid \boldsymbol{x}) = y = \sigma\left(\boldsymbol{w}^{\top}\boldsymbol{x}+b\right) = \frac{1}{1+e^{-\left(\boldsymbol{w}^{\top}\boldsymbol{x}+b\right)}}$$

$$p(y=0 \mid \boldsymbol{x}) = 1-y = \frac{e^{-\left(\boldsymbol{w}^{\mathrm{T}}\boldsymbol{x}+b\right)}}{1+e^{-\left(\boldsymbol{w}^{\mathrm{T}}\boldsymbol{x}+b\right)}}$$

$$\ln\frac{p(1 \mid x)}{p(0 \mid x)} = \ln\frac{y}{1-y} = \boldsymbol{w}^{\mathrm{T}}\boldsymbol{x}+b$$

对数几率(log odds,也叫logit)，相对可能性

回顾—逻辑回归

- 极大似然法(maximum likelihood method)：即令每个样本属于其真实标记的概率越大越好

$$\mathcal{J}(\hat{\boldsymbol{w}}) = \sum_{i=1}^{m} \log p\left(y_i \mid \boldsymbol{x}_i; \hat{\boldsymbol{w}}\right)$$

$$\Downarrow$$

$$\mathcal{J}(\hat{\boldsymbol{w}}) = \sum_{i=1}^{m} y_i \log p_{\hat{w}}(1 \mid \boldsymbol{x}_i) + (1 - y_i) \log p_{\hat{\boldsymbol{w}}}(0 \mid \boldsymbol{x}_i)$$

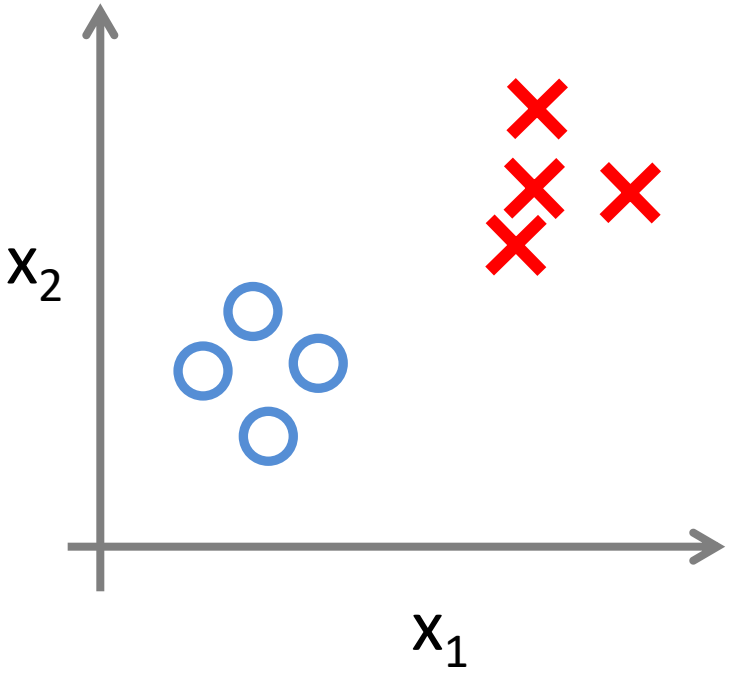
$$\mathcal{L}(\hat{w}) = -\mathcal{J}(\hat{w})$$

$$\Downarrow$$

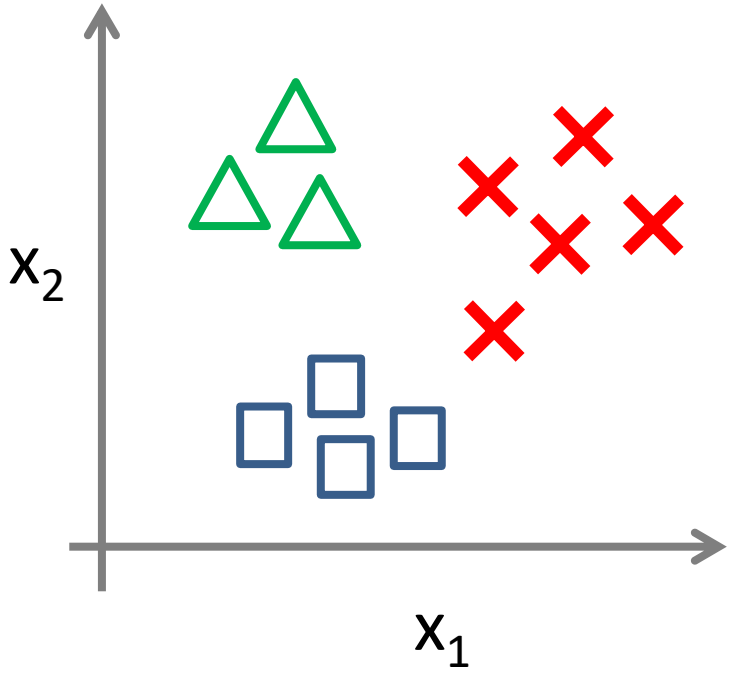
$$\arg\min_{\hat{w}} \mathcal{L}(\hat{\boldsymbol{w}}) = \arg\min_{\hat{\boldsymbol{w}}} - \sum_{i=1}^{m} [y_i \log p_{\hat{w}}(1 \mid \boldsymbol{x}_i) + (1 - y_i) \log p_{\hat{\boldsymbol{w}}}(0 \mid \boldsymbol{x}_i)]$$

回顾--多分类

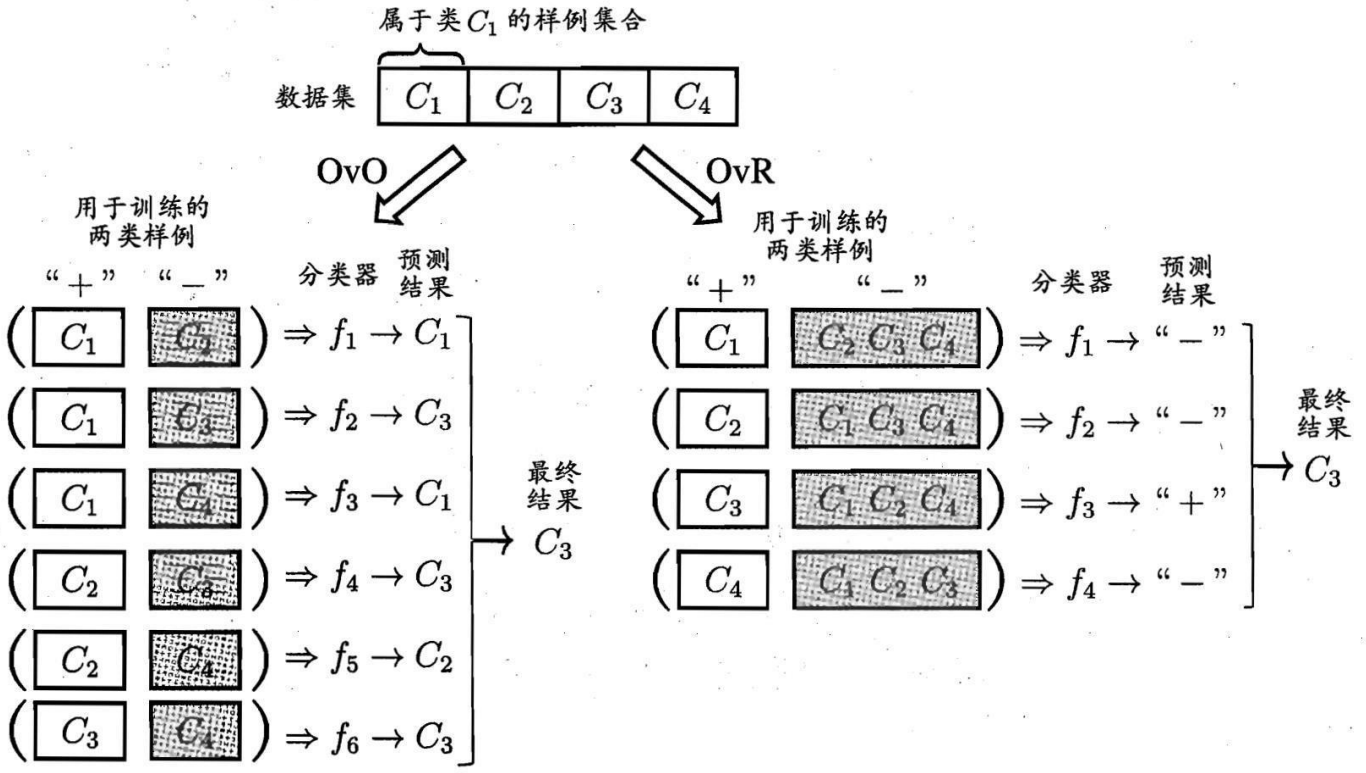
Binary classification:



Multi-class classification:



回顾--多分类


属于类C_1的样例集合
数据集
C_1 C_2 C_3 C_4
OvO
OvR
用于训练的两类样例
“+” “−”
分类器
预测结果
$(C_1, C_2) \Rightarrow f_1 \rightarrow C_1$
$(C_1, C_3) \Rightarrow f_2 \rightarrow C_3$
$(C_1, C_4) \Rightarrow f_3 \rightarrow C_1$
$(C_2, C_3) \Rightarrow f_4 \rightarrow C_3$
$(C_2, C_4) \Rightarrow f_5 \rightarrow C_2$
$(C_3, C_4) \Rightarrow f_6 \rightarrow C_3$
最终结果
C_3
用于训练的两类样例
“+” “−”
分类器
预测结果
$(C_1, C_2\ C_3\ C_4) \Rightarrow f_1 \rightarrow$ “−”
$(C_2, C_1\ C_3\ C_4) \Rightarrow f_2 \rightarrow$ “−”
$(C_3, C_1\ C_2\ C_4) \Rightarrow f_3 \rightarrow$ “+”
$(C_4, C_1\ C_2\ C_3) \Rightarrow f_4 \rightarrow$ “−”
最终结果
C_3

N(N-1)/2

N

回顾—多分类-Softmax回归

- 总共K个类别 $C = \{c_1, c_2, \ldots, c_K\}$
- Softmax函数：对数几率回归在K个可能不同的值上的推广
- 参数 $\hat{\boldsymbol{w}} = \{\hat{\boldsymbol{w}}_1, \hat{\boldsymbol{w}}_2, \ldots, \hat{\boldsymbol{w}}_K\}$
- 第j类的概率

$$p_{\hat{w}}(y = c_j \mid \boldsymbol{x}) = \text{softmax}\left\{\hat{\boldsymbol{w}}_j^{\mathrm{T}} \boldsymbol{x}\right\} = \frac{e^{\hat{w}_j^T \boldsymbol{x}}}{\sum_{k=1}^{K} e^{\hat{w}_k^{\mathrm{T}} \boldsymbol{x}}} \quad \text{for } j = 1, \ldots, K$$

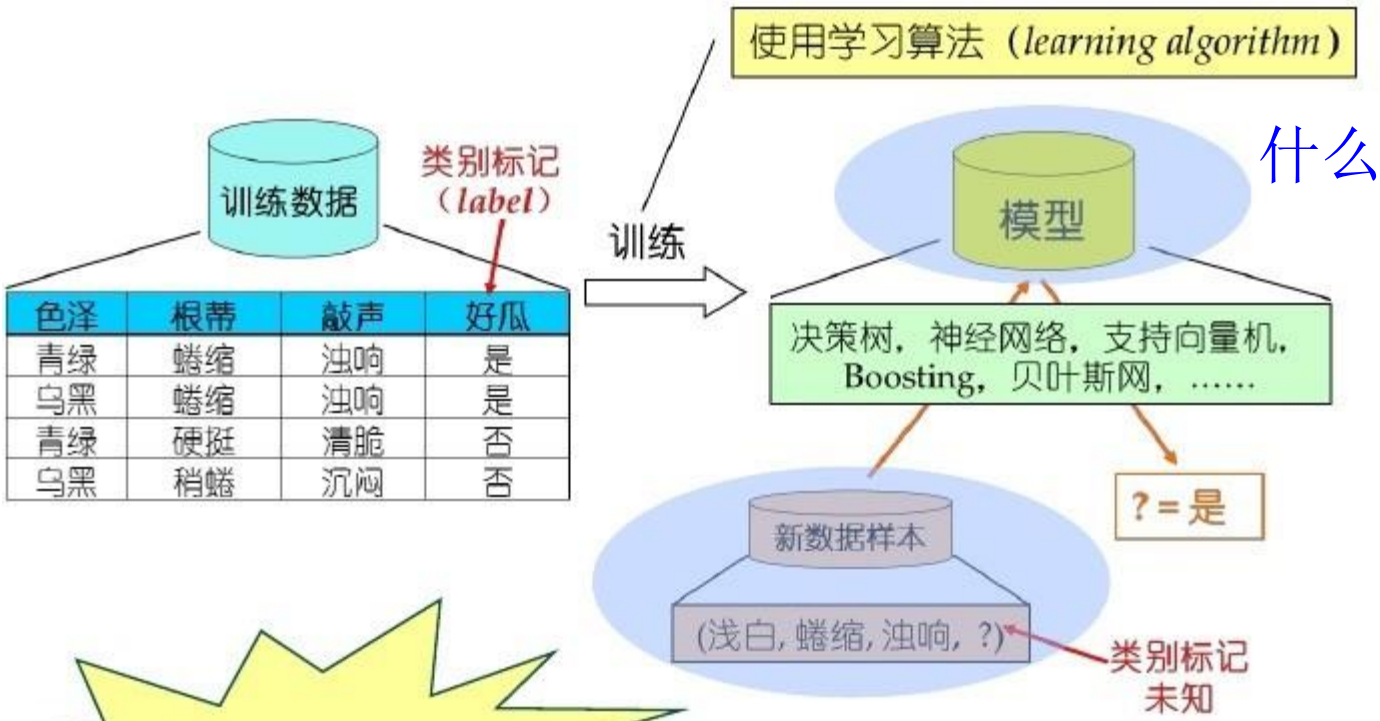
- 极大似然法 $\ell(\hat{\boldsymbol{w}}) = -\sum_k \delta(y = c_k) \log p_{\hat{\boldsymbol{w}}}(y = c_k \mid \boldsymbol{x})$

模型评估与选择

1. 经验误差与过拟合
2. 评估方法
3. 性能度量
4. 比较检验

1. 经验误差和过拟合

典型的机器学习过程



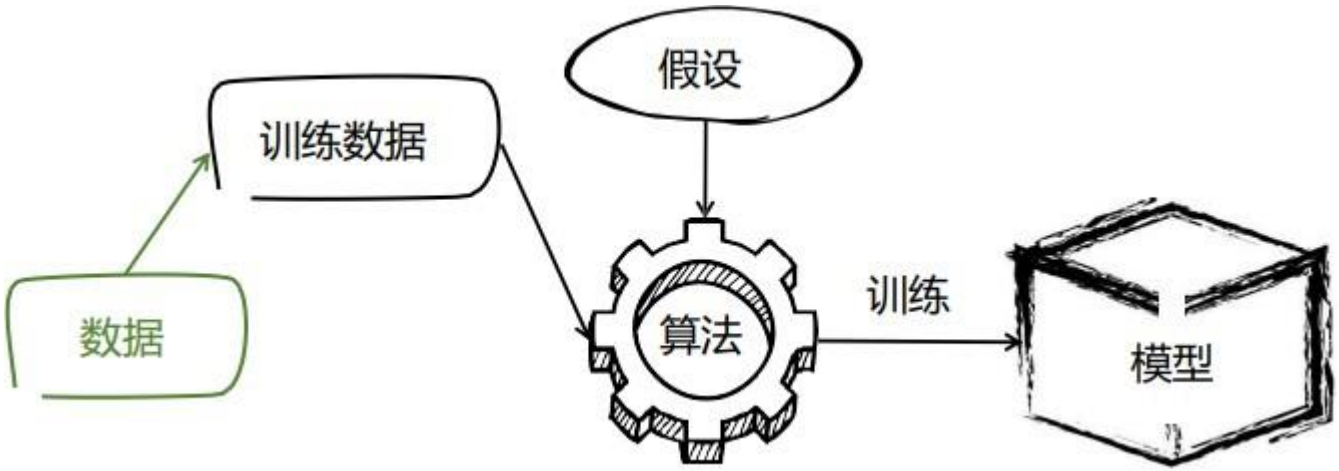
泛化能力强！

能很好地适用于 unseen instance

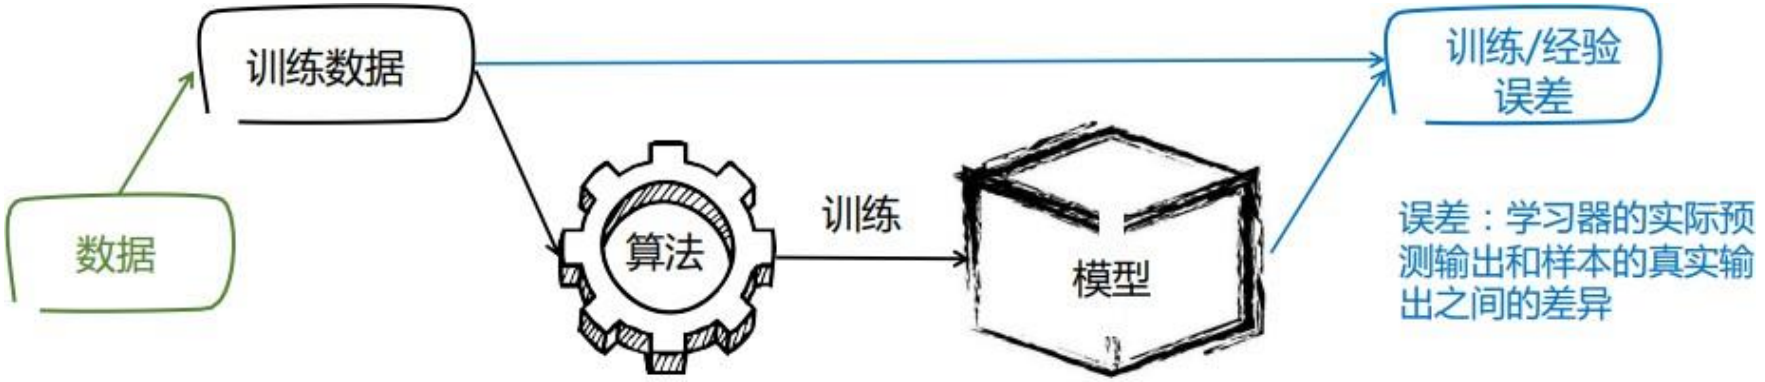
例如，错误率低、精度高

然而，我们手上没有 unseen instance，……

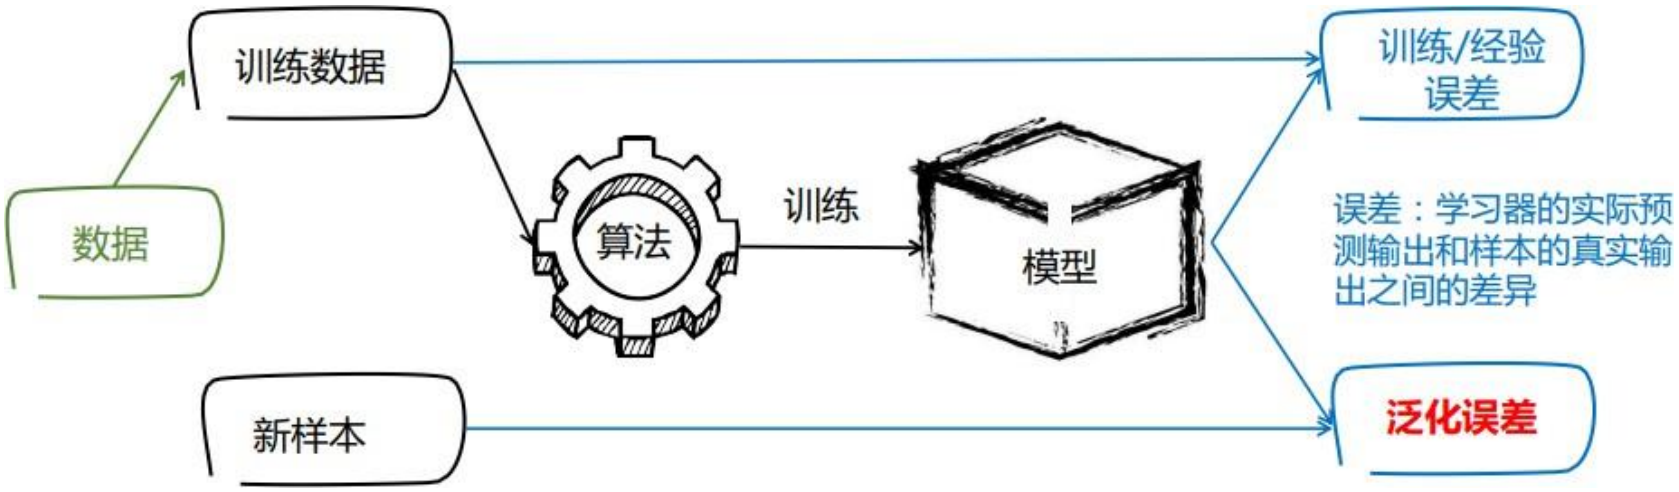
机器学习过程



机器学习过程



机器学习过程



- 训练过程中不能观察到测试样本，只能评估训练误差
- i.i.d.假设: 训练数据和测试数据来自相同分布

经验误差和泛化误差

- 泛化误差：在“未来”样本上的误差
- 经验误差：在训练集上的误差，亦称“训练误差”

- 理想情况：选择泛化误差小的模型

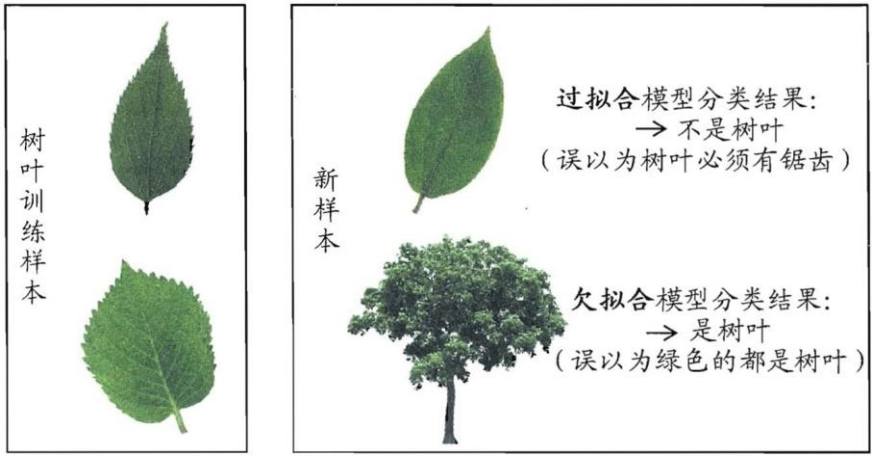
- 现实：事先不知道新样本，无法直接获知泛化误差

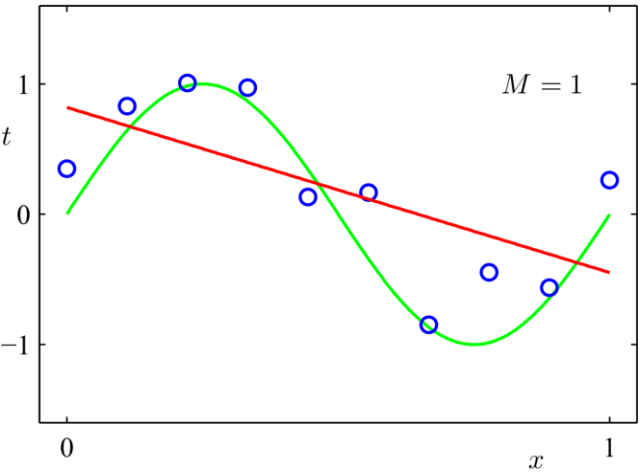
- Q: 可以用经验误差作为选择标准吗？
- A: No!

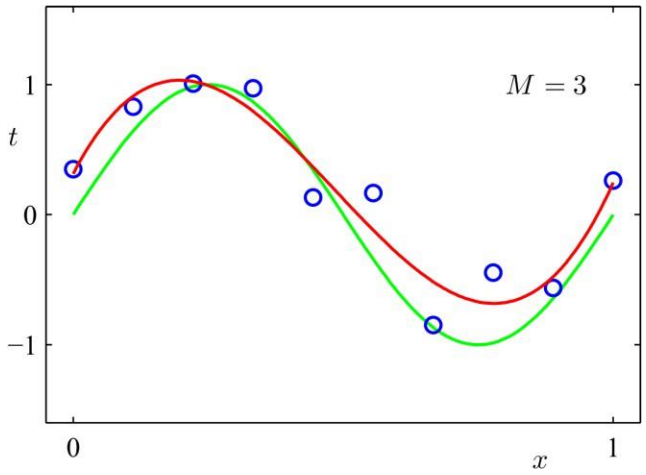
经验误差和泛化误差

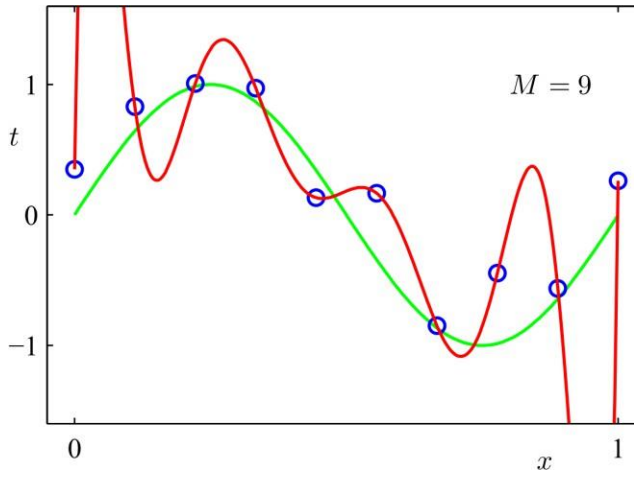
- 过拟合(overfitting)：
  - 学习器把训练样本学习的“太好”，将训练样本本身的特点当做所有样本的一般性质，导致泛化性能下降
  - 训练误差和泛化误差的差距大
  - 模型容量大，学习能力过于强大
- 欠拟合(underfitting)：
  - 对训练样本的一般性质尚未学好
  - 训练误差大
  - 模型容量小，学习能力低下

欠拟合 vs 过拟合


树叶训练样本
新样本
过拟合模型分类结果:
→ 不是树叶
(误以为树叶必须有锯齿)
欠拟合模型分类结果:
→ 是树叶
(误以为绿色的都是树叶)

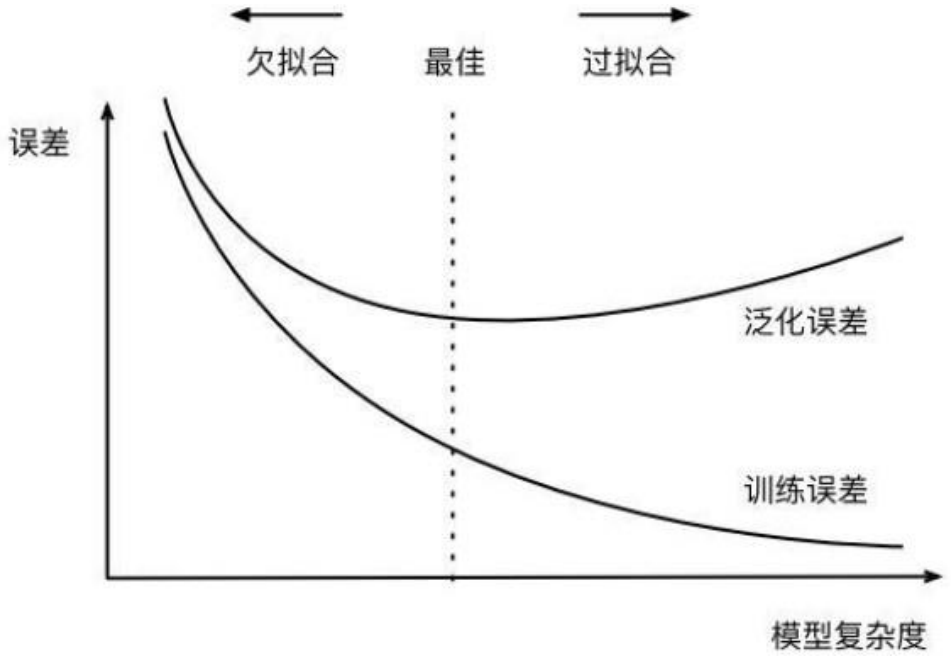

M = 1
t
x
1
0
−1
0
1


M = 3
t
x
1
0
−1
0
1


M = 9
t
x
1
0
−1
0
1

经验误差和泛化误差

- 模型复杂度和经验误差、泛化误差之间的关系



经验误差和泛化误差

- 过拟合解决方法
  - 优化目标加正则项
  - early stopping
  - 过拟合难以避免
- 欠拟合解决方法
  - 决策树：拓展分支
  - 神经网络：增加训练轮数

正则化(Regularization)

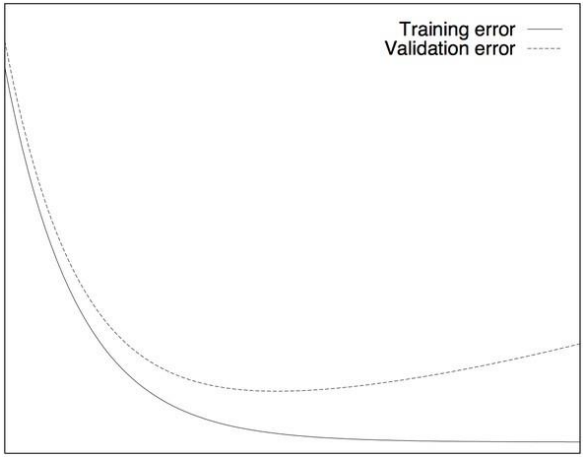
- 岭回归（Ridge)：L2正则化项

$$\mathcal{L}_{\hat{w}}=\sum_{i=1}^{m}\left(y_i-\boldsymbol{w}^T\boldsymbol{x}_i-b\right)^2+\lambda\sum_{j=1}^{d}w_j^2$$

- LASSO(least absolute shrinkage and selection operator)：L1正则化项
- 弹性网络(Elastic Net)：L1,L2正则化项的结合。r=0，岭回归； r=1，LASSO

早停法Early Stopping

- 当网络在训练集上表现越来越好，错误率越来越低的时候，实际上在某一刻，它在测试集的表现已经开始变差。



- https://www.datalearner.com/blog/1051537860479157
- https://blog.csdn.net/zwqjoy/article/details/86677030
- http://page.mi.fu-berlin.de/prechelt/Biblio/stop_tricks1997.pdf

“误差”包含了哪些因素 ？

换言之，从机器学习的角度看，

“误差”从何而来?

偏差-方差分解 (bias-variance decomposition)

$$E(f;D) = bias^2(\boldsymbol{x}) + var(\boldsymbol{x}) + \varepsilon^2$$

期望输出与真实输出的差别

$$bias^2(\boldsymbol{x}) = \left(\bar{f}(\boldsymbol{x}) - y\right)^2$$

同样大小的训练集的变动，所导致的性能变化

$$var(\boldsymbol{x}) = \mathbb{E}_D\left[\left(f(\boldsymbol{x};D) - \bar{f}(\boldsymbol{x})\right)^2\right]$$

训练样本的标记与真实标记有区别

表达了当前任务上任何学习算法所能达到的期望泛化误差下界

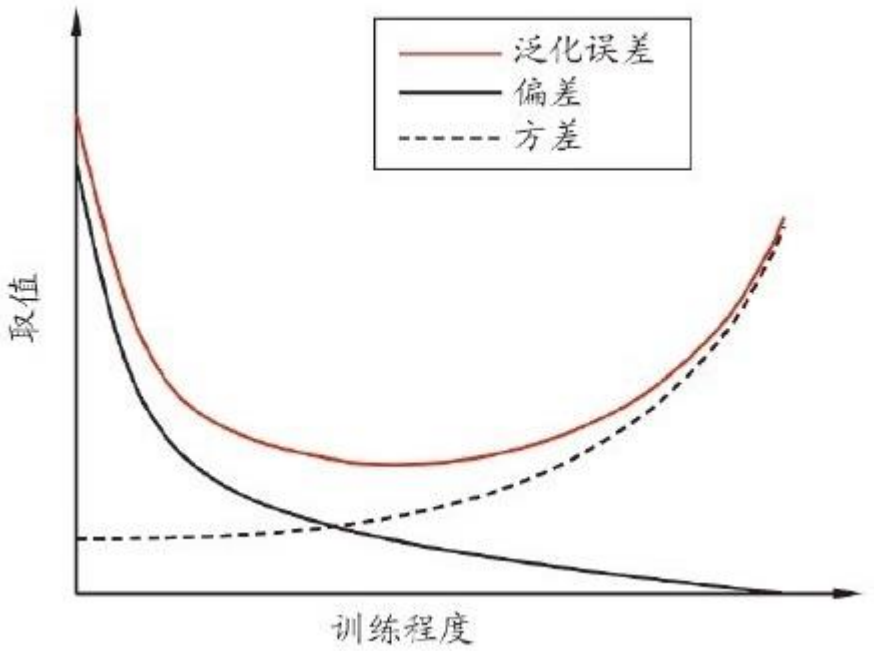
$$\varepsilon^2 = \mathbb{E}_D\left[(y_D - y)^2\right]$$

泛化性能是由学习算法的能力、数据的充分性以及学习任务本身的难度共同决定

偏差-方差窘境 (bias-variance dillema)

一般而言，偏差与方差存在冲突：

- 训练不足时，学习器拟合能力不强，偏差主导
- 随着训练程度加深，学习器拟合能力逐渐增强，方差逐渐主导
- 训练充足后，学习器的拟合能力很强，方差主导



模型选择 (model selection)

三个关键问题:

- 如何获得测试结果？ → 评估方法
- 如何评估性能优劣？ → 性能度量
- 如何判断实质差别？ → 比较检验

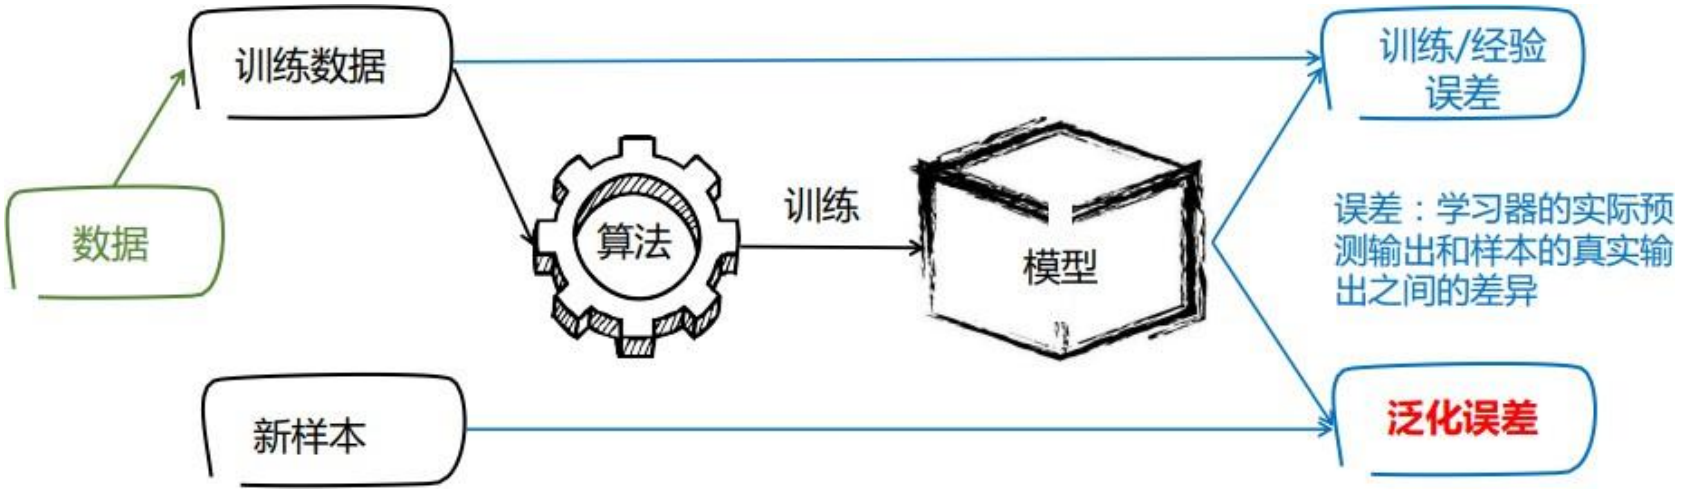
2. 评估方法

模型选择 (model selection)

三个关键问题:

- 如何获得测试结果? → 评估方法
- 如何评估性能优劣? → 性能度量
- 如何判断实质差别? → 比较检验

评估方法



- 将数据划分成训练集和测试集，利用测试误差作为泛化误差的近似实现模型选择
- 测试样本不在训练集中出现

评估方法

关键：怎么获得“测试集”(test set)？

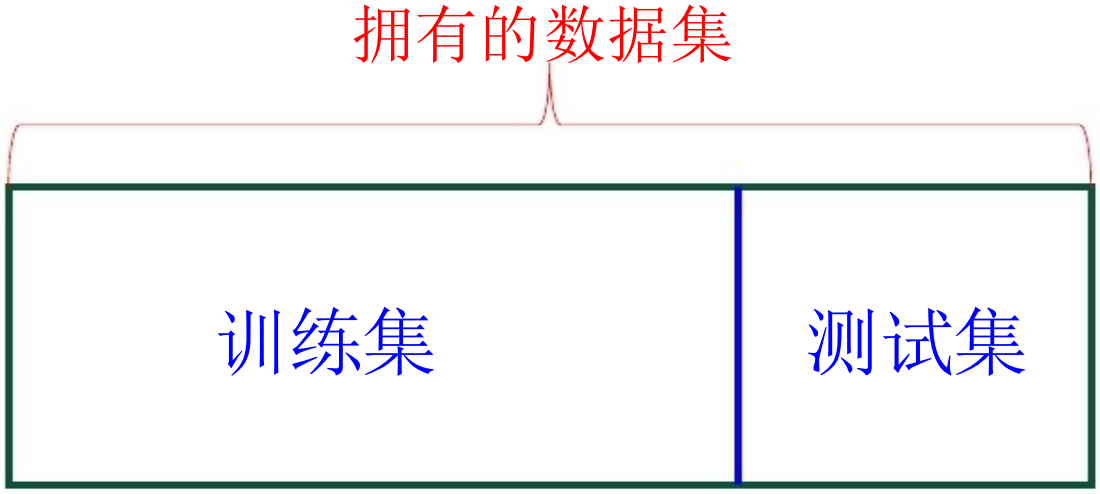
测试集应该与训练集“互斥”

常见方法：

- 留出法 (hold-out)
- 交叉验证法 (cross validation)
- 自助法 (bootstrap)

评估方法-**留出法**(hold-out)

- 直接将数据集划分为两个互斥集合—训练和测试集



注意：

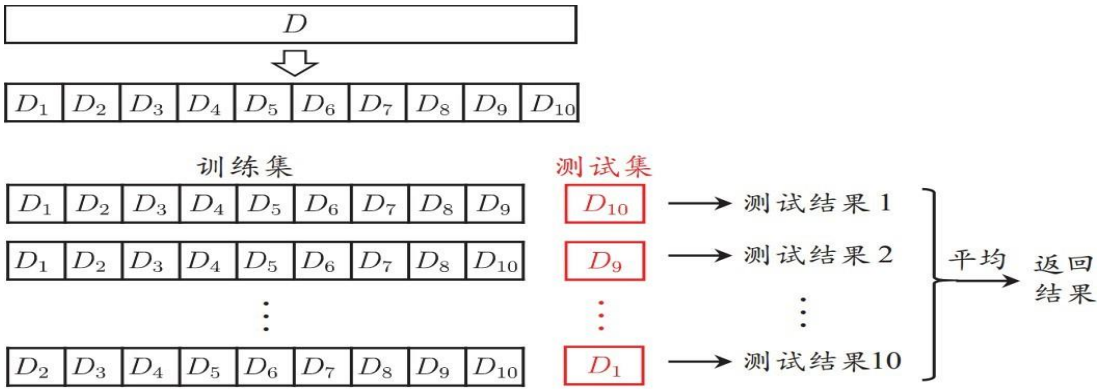
- 保持数据分布一致性 （例如: 分层采样)
- 多次重复划分 (例如: 100次随机划分)
- 测试集不能太大、不能太小 (例如：1/5~1/3)

评估方法-**留出法**(hold-out)

- 直接将数据集划分为两个互斥集合—训练和测试集
- 训练/测试集划分要尽可能保持数据分布的一致性
  - 分层采样（stratified sampling）：保持类别比例一致
- 不同的划分方式，导致结果会有差别
  - 一般若干次随机划分、重复实验取平均值
- 评估结果得准确性和保真性
  - 训练/测试样本比例通常为2:1~4:1
- 大规模问题中训练集样本数量远大于测试集

评估方法-**交叉**验证法(cross validation)

- k折交叉验证：将数据集(分层采样)划分为k个大小相似的互斥子集，每次用k-1个子集的并集作为训练集，余下的子集作为测试集，最终返回k个测试结果的均值
- k的取值影响评估结果的稳定性和保真性，最常用的取值是10.



10 折交叉验证示意图

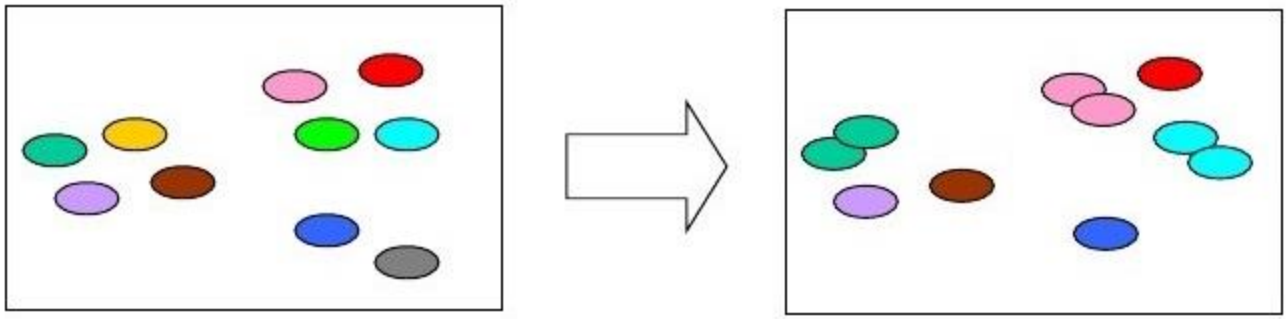
评估方法-**交叉**验证法(cross validation)

- p次k折交叉验证（为了减小因样本划分不同而引入的差别）：k折交叉验证随机使用不同的划分重复p次，p的常用取值是10
- 假设数据集D包含m个样本，若令k=m，则得到留一法(LOO)：
  - 不受随机样本划分方式的影响
  - 结果往往比较准确
  - 当数据集比较大时，计算开销难以忍受，实际中不常用

评估方法-**自助法**(bootstrapping)

亦称“有放回采样”、“可重复采样”

- 在留出法和交叉验证法中，由于只采用了一部分样本用于训练，因此会引入一些因为样本规模不足而引入的偏差。自助法可以解决这个问题。
- 假将样本集记为D，D中共有m个样本。对D进行有放回抽样m次，得到包含m个样本的训练集D'。而未被采样到的样本集合（D-D'）作为测试集。



评估方法-**自助法**(bootstrapping)

- 样本在m次采样中始终不被采样的概率为：

$$\lim_{m \mapsto \infty} (1 - \frac{1}{m})^m \mapsto \frac{1}{e} \approx 0.368$$

- 通过自助采样，初始数据集中约有36.8%的样本未出现在采样数据集D’中
- 包外估计(out-of-bag estimate)
- 适用范围
  - 产生多种不同的训练集，可用于集成学习
  - 数据集小，难以划分训练/测试集很有用
  - 改变了数据分布，因此数据量足够时，一般采用留出法和交叉验证

评估方法-调参(parameter tuning)

算法的参数：一般由人工设定，亦称“超参数”

模型的参数：一般由学习确定

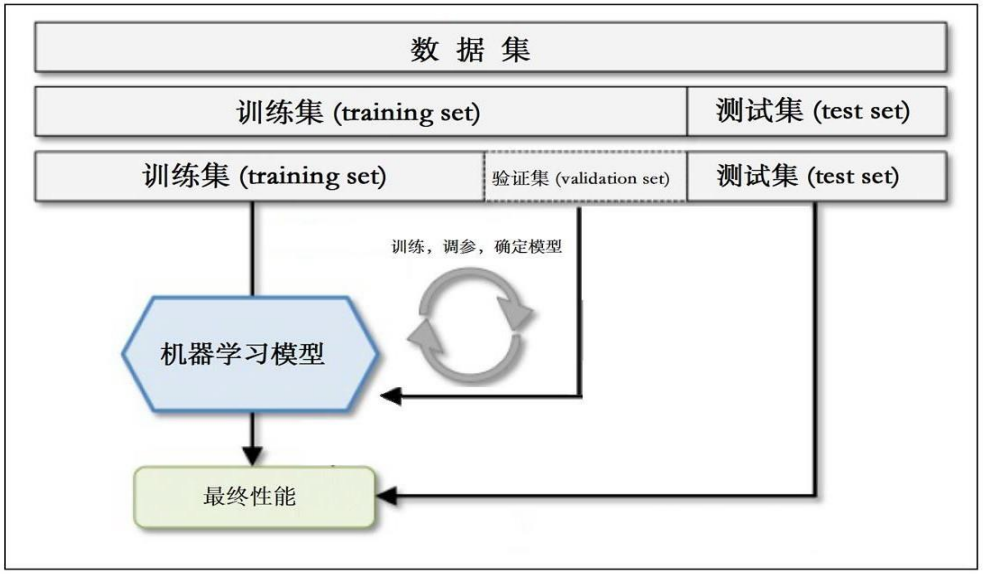
调参过程相似：先产生若干模型，然后基于某种评估方法进行选择

网格搜索：对参数选定变化范围和变化步长，选择最好模型对应的参数

参数调得好不好对性能往往对最终性能有关键影响

评估方法

- 验证集(validation set), 也叫开发集(development set)：进行模型选择和调参
- 测试集：实际应用中新样本的集合，评估实际应用中的泛化性能



算法参数选定后，要用“训练集+验证集”重新训练最终模型

3. 性能度量

模型选择 (model selection)

三个关键问题:

- 如何获得测试结果? → 评估方法
- 如何评估性能优劣? → 性能度量
- 如何判断实质差别? → 比较检验

性能度量

性能度量(performance measure)是衡量模型泛化能力的评价标准，反映了任务需求

使用不同的性能度量往往会导致不同的评判结果

什么样的模型是“好”的，不仅取决于算法和数据，还取决于任务需求

性能度量-回归任务

- 均方误差 (mean squared error)
- 样例集 $D = \{(\boldsymbol{x}_1, y_1), (\boldsymbol{x}_2, y_2), \ldots, (\boldsymbol{x}_m, y_m)\}$
- 预测模型 f

$$E(f; D) = \frac{1}{m}\sum_{i=1}^{m} (f(\boldsymbol{x}_i) - y_i)^2$$

性能度量-分类任务

- 错误率(error rate)：分错样本占样本总数的比例

$$E(f;D)=\frac{1}{m}\sum_{i=1}^{m}\mathbb{I}\left(f\left(\boldsymbol{x}_i\right)\neq y_i\right)$$

- 精度(accuracy)：分对样本占样本总数的比率

$$\begin{aligned}\mathrm{acc}(f;D) &= \frac{1}{m}\sum_{i=1}^{m}\mathbb{I}\left(f\left(\boldsymbol{x}_i\right)=y_i\right)\\ &= 1-E(f;D)\ .\end{aligned}$$

性能度量-分类任务

- 混淆矩阵

真实情况	预测结果	
	正例	反例
正例	TP(真正例)	FN (假反例)
反例	FP (假正例)	TN(真反例)

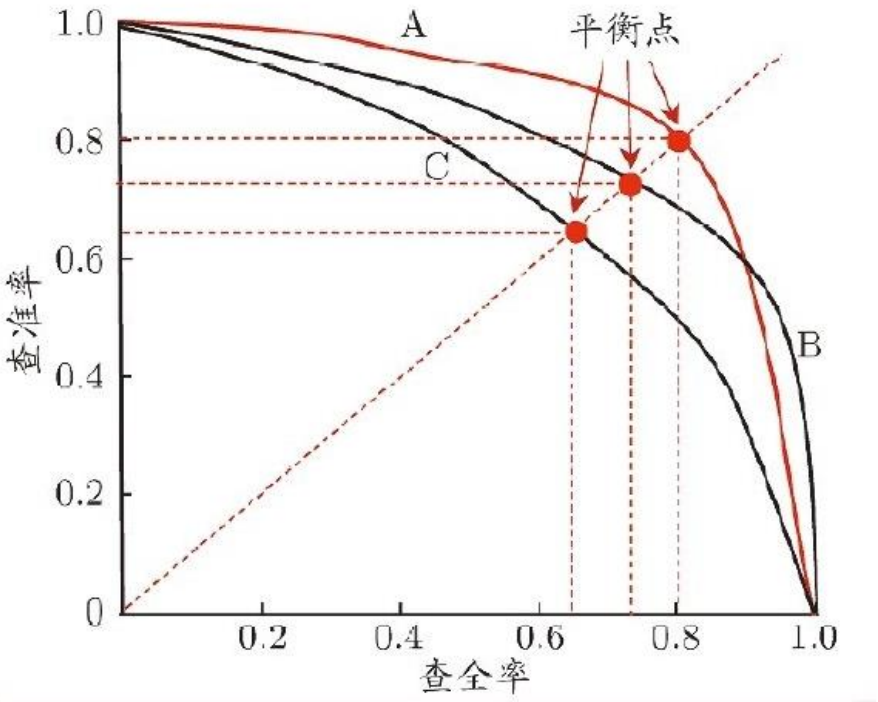
- 查准率/准确率P(precision)，查全率/召回率R(recall)

$$P = \frac{TP}{TP + FP} \quad R = \frac{TP}{TP + FN}$$

- “挑出的西瓜有多少比例是好瓜” “所有好瓜中有多少比例被挑出来了”
- 查准率和查全率通常是一对矛盾的指标

性能度量-分类任务

- PR曲线（完全“包住”）
- 平衡点(Break-Even Point, BEP)是曲线上“查准率=查全率”时的取值，可用来用于度量P-R曲线有交叉的分类器性能高低



PR图：

- 学习器 A 优于 学习器 C
- 学习器 B 优于 学习器 C
- 学习器 A ?? 学习器 B

BEP：

- 学习器 A 优于 学习器 B
- 学习器 A 优于 学习器 C
- 学习器 B 优于 学习器 C

F1

- 比 BEP 更常用的 F1 度量：
- $F1 = \frac{2 \times P \times R}{P + R} = \frac{2 \times TP}{\text{样例总数} + TP - TN}$
- 若对查准率/查全率有不同偏好：
- $F_\beta = \frac{(1 + \beta^2) \times P \times R}{(\beta^2 \times P) + R}$
- $\beta > 1$时查全率有更大影响； $\beta < 1$时查准率有更大影响

宏xx vs. 微xx

若能得到多个混淆矩阵:

(例如多次训练/测试的结果，多分类的两两混淆矩阵)

宏(macro-)查准率、查全率、F1

$$\text{macro-}P = \frac{1}{n}\sum_{i=1}^{n} P_i \ ,$$

$$\text{macro-}R = \frac{1}{n}\sum_{i=1}^{n} R_i \ ,$$

$$\text{macro-}F1 = \frac{2 \times \text{macro-}P \times \text{macro-}R}{\text{macro-}P + \text{macro-}R} \ .$$

微(micro-)查准率、查全率、F1

$$\text{micro-}P = \frac{\overline{TP}}{\overline{TP} + \overline{FP}} \ ,$$

$$\text{micro-}R = \frac{\overline{TP}}{\overline{TP} + \overline{FN}} \ ,$$

$$\text{micro-}F1 = \frac{2 \times \text{micro-}P \times \text{micro-}R}{\text{micro-}P + \text{micro-}R} \ .$$

性能度量-多分类任务

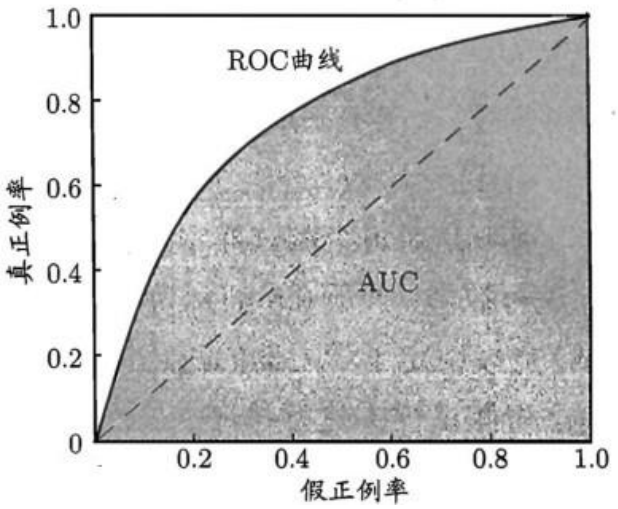
两两类别的组合 1 ⟶ 混淆矩阵 1 ⟶ (P_1, R_1)
两两类别的组合 2 ⟶ 混淆矩阵 2 ⟶ (P_2, R_2)
... ...
两两类别的组合 n ⟶ 混淆矩阵 n ⟶ (P_n, R_n)

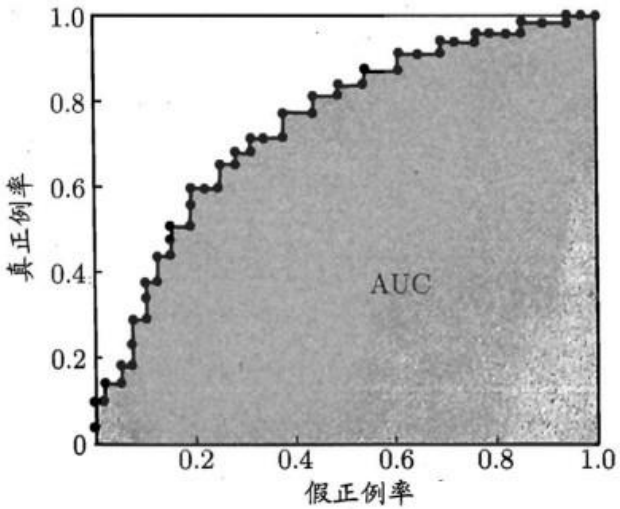
$$\text{macro}-P = \frac{1}{n}\sum_{i=1}^{n} P_i$$

$$\text{macro}-R = \frac{1}{n}\sum_{i=1}^{n} R_i$$

性能度量-分类任务

- ROC 与 AUC





真实情况	预测结果	
	正例	反例
正例	TP(真正例)	FN (假反例)
反例	FP (假正例)	TN(真反例)

真正例率 TPR

$$\mathrm{TPR} = \frac{TP}{TP + FN} \quad m^+$$

真实的正例里有多少被预测成正例

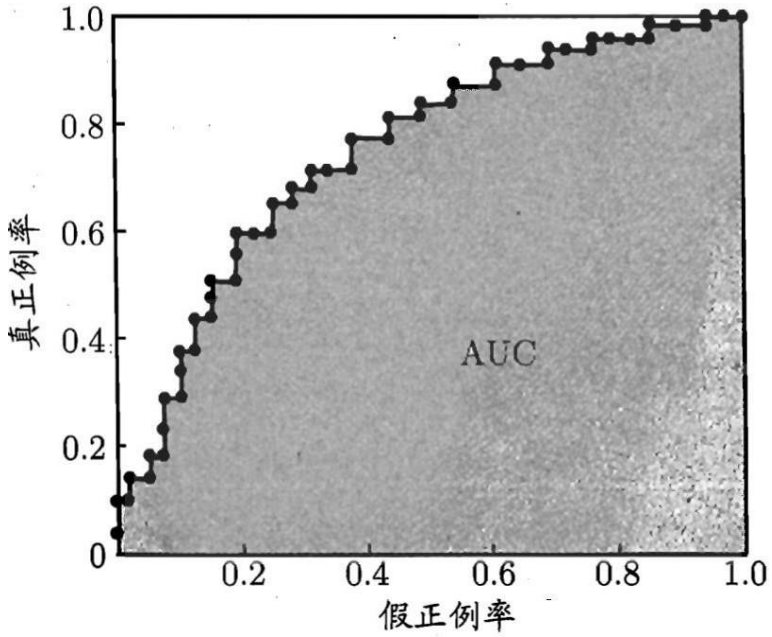
假正例率FPR

$$\mathrm{FPR} = \frac{FP}{TN + FP} \quad m^-$$

真实的反例里有多少被预测成正例

性能度量-分类任务

- ROC 与 AUC

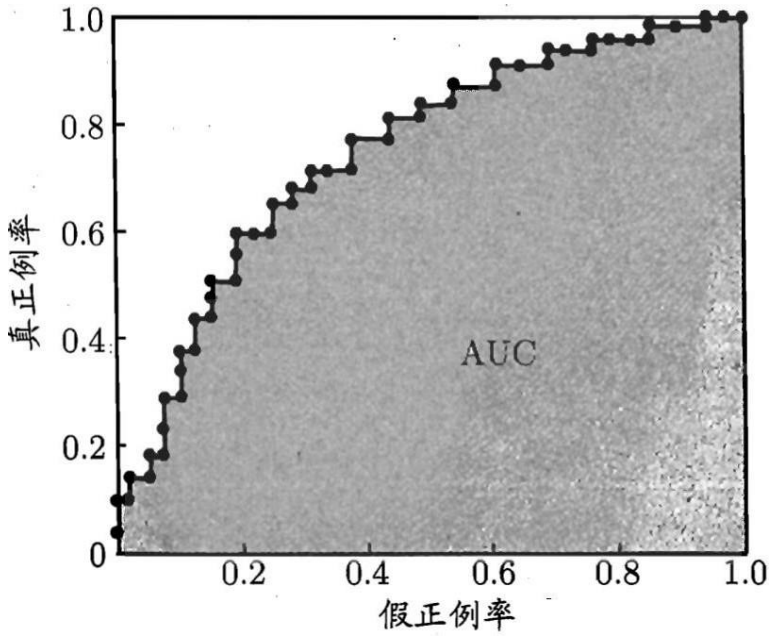


- 将模型预测结果从高到低排序，将每次概率值依次作为阈值，那么就可以得到多个混淆矩阵。
- 对于每个混淆矩阵，我们计算两个指标TPR和FPR，以FPR为x轴，TPR为y轴画图，就得到了ROC曲线 (receiver operating characteristic curve)。

AUC = “ROC 曲线之下的面积”
= 1-“ROC 曲线之上的面积”

性能度量-分类任务

- ROC 与 AUC



从AUC判断分类器（预测模型）优劣的标准：

- AUC = 1，是完美分类器，采用这个预测模型时，存在至少一个阈值能得出完美预测。绝大多数预测的场合，不存在完美分类器。
- 0.5 < AUC < 1，优于随机猜测。这个分类器（模型）妥善设定阈值的话，能有预测价值。
- AUC = 0.5，跟随机猜测一样（例：丢铜板），模型没有预测价值。
- AUC < 0.5，比随机猜测还差；但只要总是反预测而行，就优于随机猜测。

性能度量-分类任务

- ROC 与 AUC

真实情况	预测结果	
	正例	反例
正例	TP(真正例)	FN (假反例)
反例	FP (假正例)	TN(真反例)

真正例率 TPR

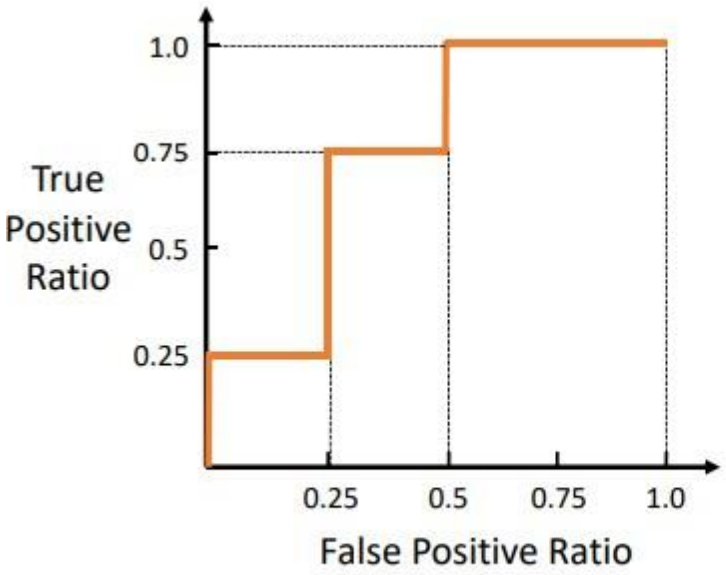
$$\mathrm{TPR} = \frac{TP}{TP + FN} \quad m^+$$

真实的正例里有多少被预测成正例

假正例率FPR

$$\mathrm{FPR} = \frac{FP}{TN + FP} \quad m^-$$

真实的反例里有多少被预测成正例



AUC = 0.75

Prediction	Label
0.91	1
0.85	0
0.77	1
0.72	1
0.61	0
0.48	1
0.42	0
0.33	0

性能度量-分类任务

- 代价敏感场景
  - 代价矩阵(cost matrix)

真实类别	预测类别	
	第 0 类	第 1 类
第 0 类	0	$cost_{10}$
第 1 类	$cost_{01}$	0

  - “代价敏感”(cost-sensitive)错误率（正例：第0类，反例：第1类）

$$E(f;D;cost)=\frac{1}{m}\left(\sum_{\boldsymbol{x}_i\in D^+}\mathbb{I}\left(f(\boldsymbol{x}_i)\neq y_i\right)\times cost_{01}+\sum_{\boldsymbol{x}_i\in D^-}\mathbb{I}\left(f(\boldsymbol{x}_i)\neq y_i\right)\times cost_{10}\right)$$

4. 比较检验

模型选择 (model selection)

三个关键问题:

- 如何获得测试结果？ → 评估方法
- 如何评估性能优劣？ → 性能度量
- 如何判断实质差别？ → 比较检验

比较检验

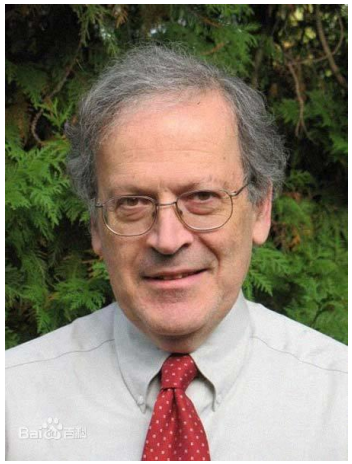
- 在某种度量下取得评估结果后，是否可以直接比较以评判优劣？

- NO ！ 因为：
  - 测试性能不等于泛化性能
  - 测试性能随着测试集的变化而变化
  - 很多机器学习算法本身有一定的随机性

机器学习  “概率近似正确”

计算学习理论

Computational learning theory



Leslie Valiant
(莱斯利 维利昂特)
(1949-)
2010年图灵奖

PAC (Probably Approximately Correct)

learning model
学习模型

[Valiant, 1984]

$$P(|f(x) - y| \leq \epsilon) \geq 1 - \delta$$

比较检验

- 假设检验(hypothesis test)：若在测试集上观察到模型A比模型B好，那么A的泛化性能是否在统计意义上优于B，以及这个结论的把握有多大
- 直觉: 给定泛化错误率的一个假设，测试错误率的某个统计量有的概率落在某个范围内。如果我们观察到的该统计量落在这个范围外，那么我们有理由相信假设不成立。

比较检验-t检验(t-test)

- 多次重复留出法或者交叉验证法进行多次训练/测试
- 记泛化错误率为 ϵ
- k个测试错误率为 $\hat{\epsilon}_1, \hat{\epsilon}_2, \ldots, \hat{\epsilon}_k$
- 待检验的假设为 $\epsilon = \epsilon_0$
- 显著度为 α

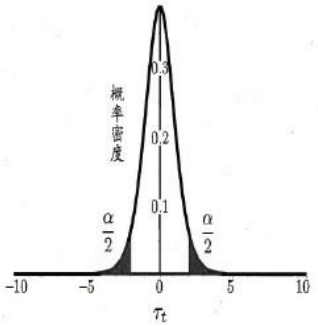
比较检验-t检验(t-test)

$$\tau_t = \frac{\sqrt{k}(\mu - \epsilon_0)}{\sigma}$$

$\hat{\epsilon}$ 的均值

$\hat{\epsilon}$的方差平方根

服从自由度为*k-1*的*t*分布



查表得到临界值$\tau_{\alpha/2,k-1}$

尾部累积概率为$\alpha/2$的临界值

α	k				
	2	5	10	20	30
0.05	12.706	2.776	2.262	2.093	2.045
0.10	6.314	2.132	1.833	1.729	1.699

判定上述变量的绝对值值是否小于临界值$\tau_{\alpha/2,k-1}$

$|\tau_t| < \tau_{\alpha/2,k-1}$

在α的显著度下，不能拒绝原假设$\epsilon = \epsilon_0$

$|\tau_t| \geq \tau_{\alpha/2,k-1}$

在α的显著度下，原假设被拒绝，即在α的显著度下模型的泛化错误率与ϵ_0有显著不同

比较检验-t检验(t-test)

- 某学习器在11折交叉验证中得到了11个测试错误率，分别是

1	2	3	4	5	6	7	8	9	10	11
0.2	0.3	0.2	0.2	0.4	0.3	0.4	0.1	0.2	0.3	0.3

- 对假设泛化错误率为0.2，显著度为0.05进行检验
- 查表，临界值是2.262
- 求测试错误率的平均值和方差，得到

$$\mu = 0.264 \qquad \sigma^2 = 0.00855$$

α	k				
	2	5	10	20	30
0.05	12.706	2.776	2.262	2.093	2.045
0.10	6.314	2.132	1.833	1.729	1.699

- 根据 $\tau_t = \dfrac{\sqrt{k}(\mu - \epsilon_0)}{\sigma}$ ，计算得到2.30

- 由于2.30>2.262, 所以在0.05的显著度下，拒绝原假设

比较检验-交叉验证t检验

成对t检验

- 待检验的假设：“学习器A和B性能相同”
- 对两个学习器A和B，若k折交叉验证得到的测试错误率分别为$\hat{\epsilon}_1^A, ..., \hat{\epsilon}_k^A$和$\hat{\epsilon}_1^B, ..., \hat{\epsilon}_k^B$，检验假设学习器A和B的泛化错误率满足$\epsilon^A = \epsilon^B$
- 定义$\hat{\Delta}_i = \hat{\epsilon}_i^A - \hat{\epsilon}_i^B$，等价于给定学习器测试错误率之差$\hat{\Delta}_1, ..., \hat{\Delta}_k$，对泛化错误率之差$\Delta = \epsilon^A - \epsilon^B$进行假设检验，假设为$\Delta = 0$
- 可使用前面学习到的t检验方法

$$\tau_t = \frac{\sqrt{k}\mu}{\sigma}$$

比较检验-交叉验证t检验

- 学习器A和B在11折交叉验证中得到了11个测试错误率，分别是

	1	2	3	4	5	6	7	8	9	10	11
学习器A	0.2	0.3	0.2	0.2	0.4	0.3	0.4	0.1	0.2	0.3	0.3
学习器B	0.3	0.3	0.3	0.2	0.3	0.4	0.5	0.2	0.2	0.3	0.3
测试错误率之差（B-A)	0.1	0	0.1	0	-0.1	0.1	0.1	0.1	0	0	0

- 假设学习器A和B的泛化错误率相同，对此进行显著度为0.05的检验
- 查表，临界值是2.262
- 求测试错误率的平均值和方差，得到

$$\mu = 0.0364 \qquad \sigma^2 = 0.00413$$

- 根据 $\tau_t = \frac{\sqrt{k}\mu}{\sigma}$,计算得到1.88
- 由于1.88<2.262, 所以在0.05的显著度下，无法拒绝原假设，即学习器A和B没有显著差别

α	k				
	2	5	10	20	30
0.05	12.706	2.776	2.262	2.093	2.045
0.10	6.314	2.132	1.833	1.729	1.699

常用方法

统计假设检验 (hypothesis test) 为学习器性能比较提供了重要依据

- 两学习器比较
  - 交叉验证 t 检验 (基于成对 t 检验)

    k 折交叉验证； 5x2交叉验证
  - McNemar 检验 (基于列联表，卡方检验)
- 多学习器比较
  - Friedman + Nemenyi
    - Friedman检验 (基于序值，F检验; 判断”是否都相同”)
    - Nemenyi 后续检验 (基于序值，进一步判断两两差别)

总结

- 经验误差与泛化误差
  - 过拟合，欠拟合
- 评估方法
  - 留出法，交叉验证，自助法，调参
- 性能度量
  - 均方误差，精度，查准率/查全率/F1，AUC，Cost敏感
- 比较检验
  - t检验，交叉验证t检验