机器学习

Chapter 4：决策树

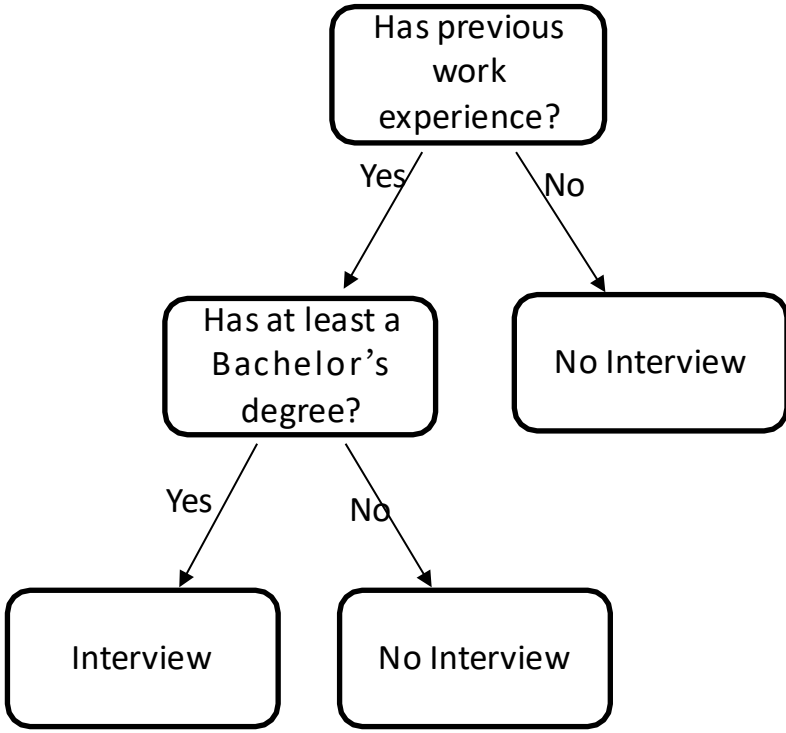
丁婧颖
信息管理与工程学院

大纲

- **基本概念与流程**
- 划分选择
- 剪枝处理
- 连续值与缺失值处理

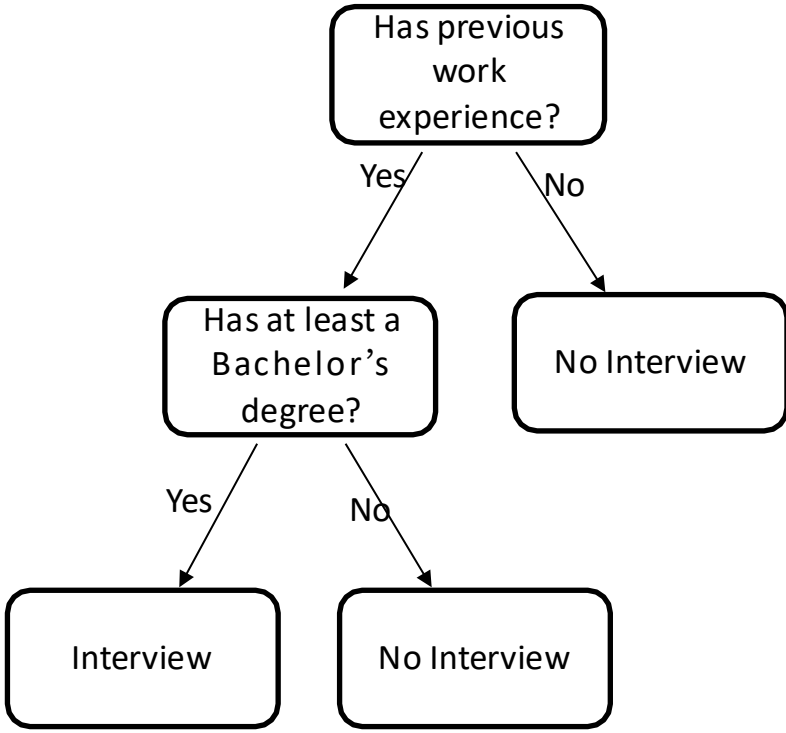
基本概念

- 决策树（decision tree）是一种常见的机器学习方法，它基于树形结构来对样本进行决策，恰似人类面临决策问题时大脑的相当自然的一种处理机制
- 决策过程的最终结论将会对应我们的判断结果，而决策过程中的每一次判定都是对某个属性的“测试”
- 每个测试的结果要么导出最终结果，要么导出下一个判定问题，并且每一次判定都会在上一次决策所划分好的范围内进行判定



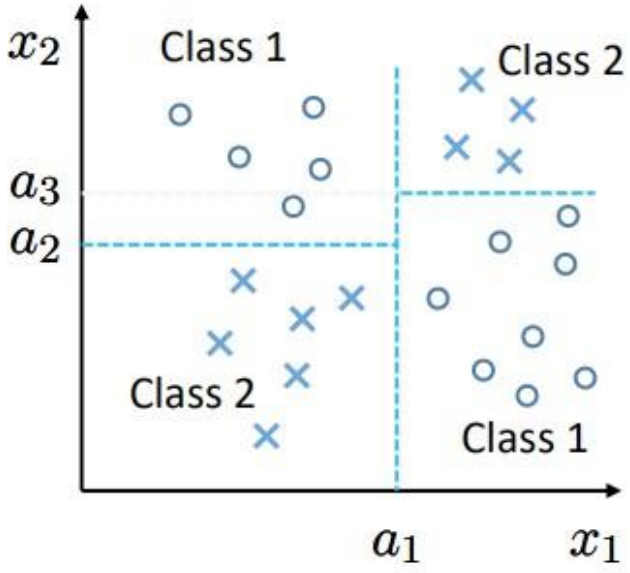
基本概念

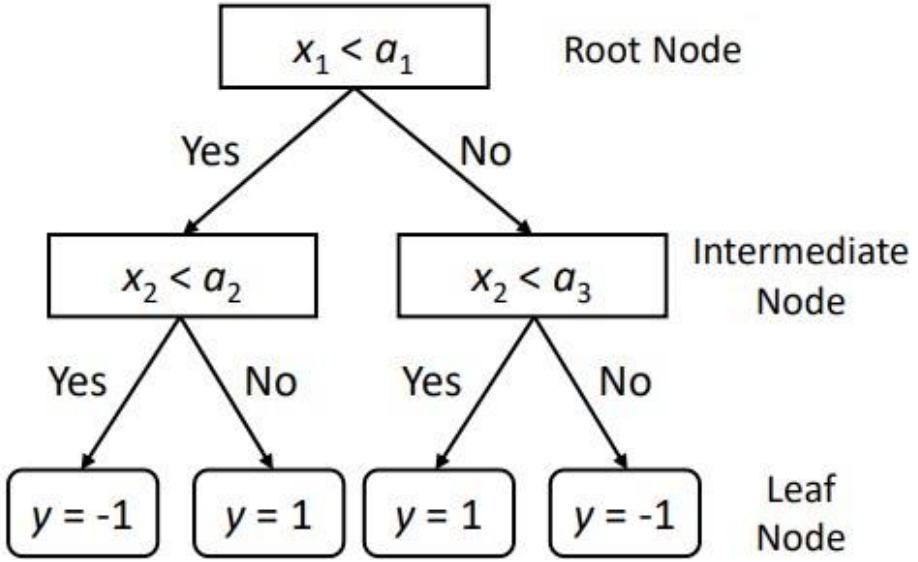
- 一般来说，一棵决策树包含一个根节点，若干个内部节点和若干个叶节点。
- 叶节点对应于决策结果，其它每个节点则对应于一个属性测试
- 每个节点包含的样本集合根据属性测试的结果被划分到子节点中
- 根节点包含样本全集
- 从根节点到每个叶节点的路径对应了一个判定测试序列
- 决策树学习的目的是为了产生一棵泛化能力强，即能够处理未知示例能力强的决策树。
  - *和训练数据集尽可能矛盾较小*
  - *模型的复杂度不能太高*



决策树的决策空间

- 连续值

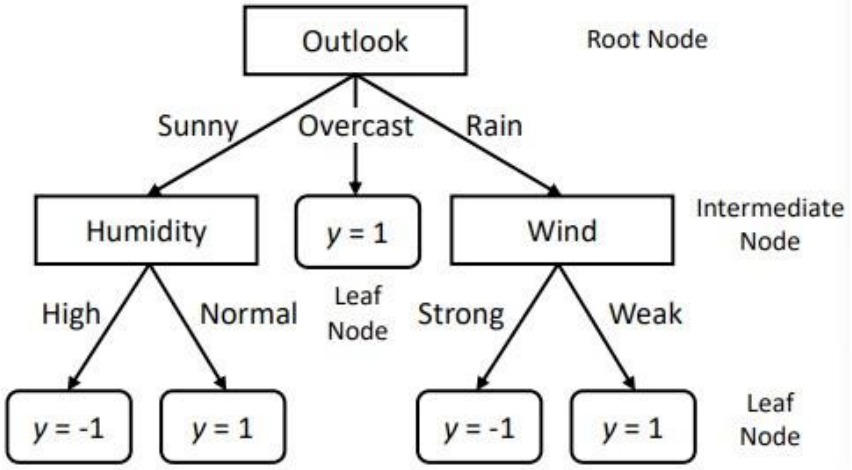




决策树的决策空间

- 离散值

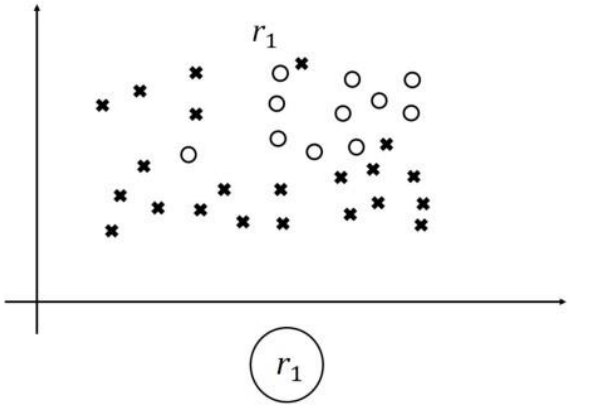
Predictors				Response
Outlook	**Temperature**	**Humidity**	**Wind**	**Class** **Play=Yes** **Play=No**
Sunny	Hot	High	Weak	No
Sunny	Hot	High	Strong	No
Overcast	Hot	High	Weak	Yes
Rain	Mild	High	Weak	Yes
Rain	Cool	Normal	Weak	Yes
Rain	Cool	Normal	Strong	No
Overcast	Cool	Normal	Strong	Yes
Sunny	Mild	High	Weak	No
Sunny	Cool	Normal	Weak	Yes
Rain	Mild	Normal	Weak	Yes
Sunny	Mild	Normal	Strong	Yes
Overcast	Mild	High	Strong	Yes
Overcast	Hot	Normal	Weak	Yes
Rain	Mild	High	Strong	No

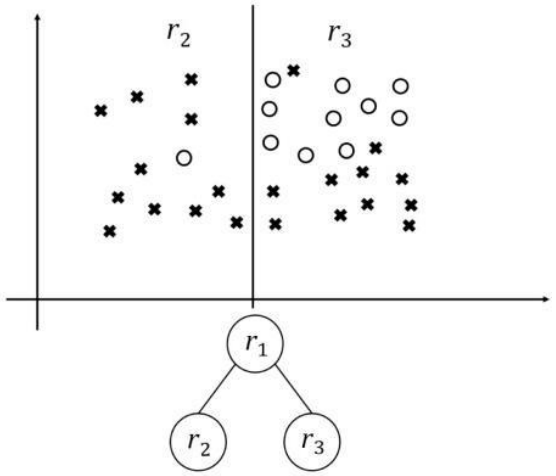


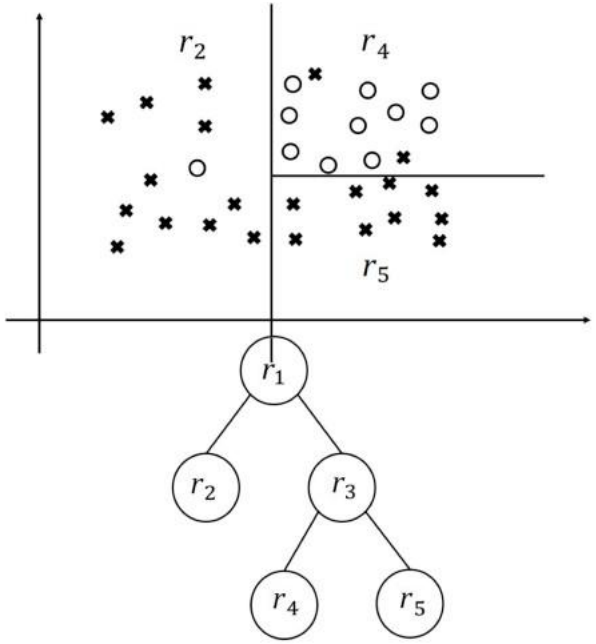
基本流程

- 决策树的基本流程遵循简单且直观的“分而治之”（divide-and-conquer）策略
- 递归地进行以下步骤：
  - 选择一个划分数据的特征作为当前节点
  - 将划分的分支刻画出来
  - 对划分的分支进行停止条件的检查：
    - 如果停止条件满足，则生成叶子节点
    - 否则继续选择特征继续划分

基本流程



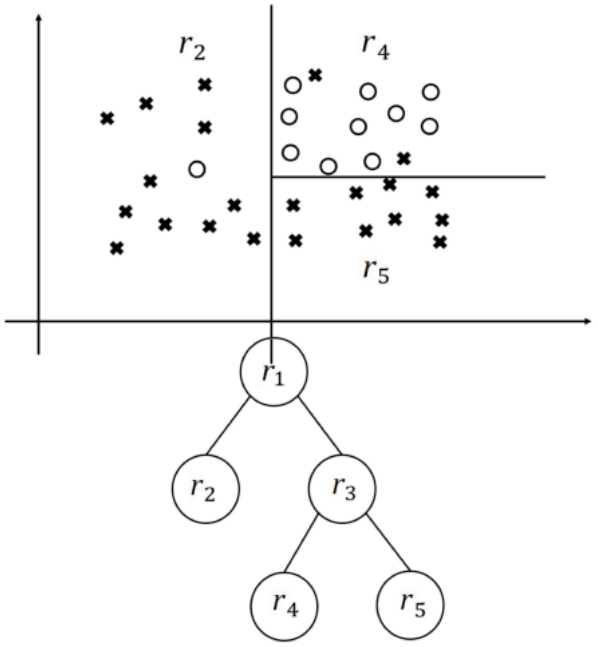




基本流程

停止划分条件

- 最小节点数
  - *数据量较少时，再做分裂容易强化噪声数据的作用；降低树生长的复杂性*
  - *提前结束分裂一定程度上有利于降低过拟合的影响。*
- 熵或者基尼值小于阈值
  - *熵和基尼值的大小表示数据的复杂程度，当熵或者基尼值过小时，表示数据的纯度比较大，如果熵或者基尼值小于一定程度数，节点停止分裂。*
- 决策树的深度达到指定的条件
  - *节点的深度可以理解为节点与决策树跟节点的距离*
  - *当深度到达指定的上限大小时，停止分裂。*
- 所有特征已经使用完毕，不能继续进行分裂。



基本流程

输入： 训练集 $D = \{(\boldsymbol{x}_1, y_1), (\boldsymbol{x}_2, y_2), \ldots, (\boldsymbol{x}_m, y_m)\}$;
属性集 $A = \{a_1, a_2, \ldots, a_d\}$.

过程： 函数 TreeGenerate(D, A)

```
1: 生成结点 node;
2: if D 中样本全属于同一类别 C then
3:     将 node 标记为 C 类叶结点; return
4: end if
5: if A = ∅ OR D 中样本在 A 上取值相同 then
6:     将 node 标记为叶结点, 其类别标记为 D 中样本数最多的类; return
7: end if
8: 从 A 中选择最优划分属性 a_*;
9: for a_* 的每一个值 a_*^v do
10:    为 node 生成一个分支; 令 D_v 表示 D 中在 a_* 上取值为 a_*^v 的样本子集;
11:    if D_v 为空 then
12:        将分支结点标记为叶结点, 其类别标记为 D 中样本最多的类; return
13:    else
14:        以 TreeGenerate(D_v, A \ {a_*})为分支结点
15:    end if
16: end for
```

输出： 以 node 为根结点的一棵决策树

基本算法

输入: 训练集 $D = \{(x_1, y_1), (x_2, y_2), \ldots, (x_m, y_m)\}$;
属性集 $A = \{a_1, a_2, \ldots, a_d\}$.

过程: 函数 TreeGenerate(D, A)

1: 生成结点 node;
2: **if** D 中样本全属于同一类别 C **then**
3: 将 node 标记为 C 类叶结点; **return**
4: **end if**
5: **if** $A = \varnothing$ **OR** D 中样本在 A 上取值相同 **then**
6: 将 node 标记为叶结点, 其类别标记为 D 中样本数最多的类; **return**
7: **end if**
8: 从 A 中选择最优划分属性 a_*;
9: **for** a_* 的每一个值 a_*^v **do**
10: 为 node 生成一个分支; 令 D_v 表示 D 中在 a_* 上取值为 a_*^v 的样本子集;
11: **if** D_v 为空 **then**
12: 将分支结点标记为叶结点, 其类别标记为 D 中样本最多的类; **return**
13: **else**
14: 以 TreeGenerate(D_v, $A \setminus \{a_*\}$)为分支结点
15: **end if**
16: **end for**

输出: 以 node 为根结点的一棵决策树

递归返回，情形(1)

递归返回，情形(2)

利用当前结点的后验分布

递归返回，情形(3)

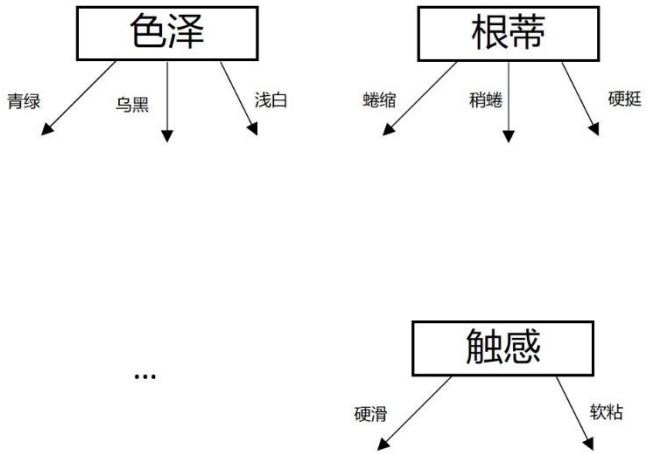
将父结点的样本分布作为当前结点的先验分布

决策树算法的核心

基本流程

- 如何选择属性测试条件？

编号	色泽	根蒂	敲声	纹理	脐部	触感	好瓜
1	青绿	蜷缩	浊响	清晰	凹陷	硬滑	是
2	乌黑	蜷缩	沉闷	清晰	凹陷	硬滑	是
3	乌黑	蜷缩	浊响	清晰	凹陷	硬滑	是
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	是
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	是
6	青绿	稍蜷	浊响	清晰	稍凹	软粘	是
7	乌黑	稍蜷	浊响	稍糊	稍凹	软粘	是
8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	是
9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	否
10	青绿	硬挺	清脆	清晰	平坦	软粘	否
11	浅白	硬挺	清脆	模糊	平坦	硬滑	否
12	浅白	蜷缩	浊响	模糊	平坦	软粘	否
13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	否
14	浅白	稍蜷	沉闷	稍糊	凹陷	硬滑	否
15	乌黑	稍蜷	浊响	清晰	稍凹	软粘	否
16	浅白	蜷缩	浊响	模糊	平坦	硬滑	否
17	青绿	蜷缩	沉闷	稍糊	稍凹	硬滑	否



如何选择？

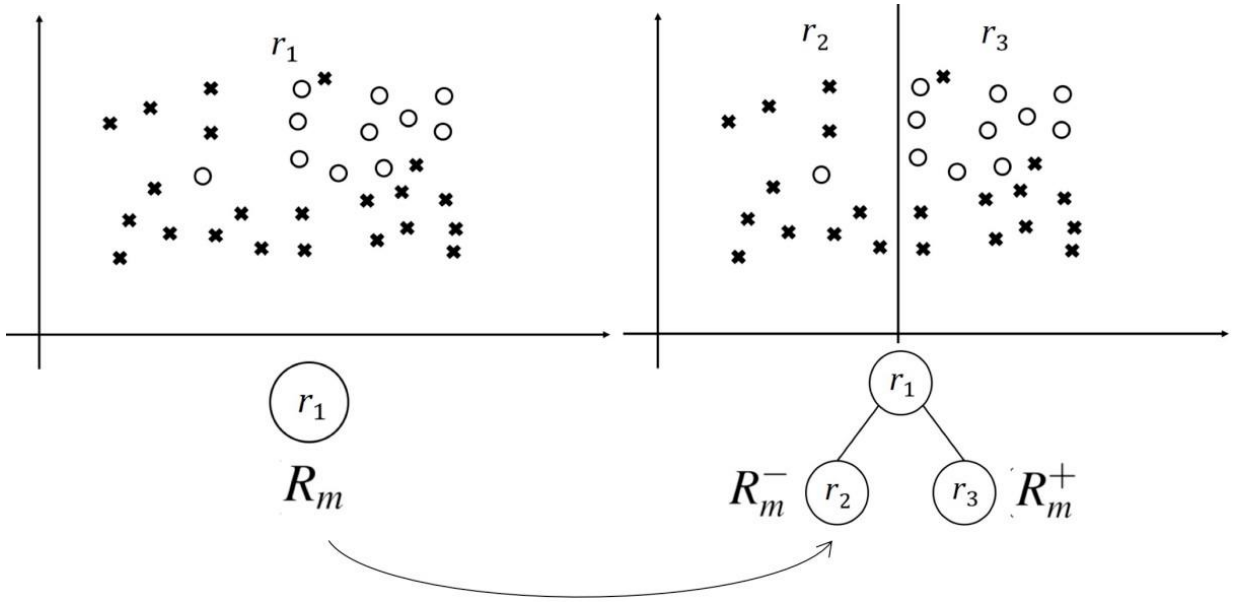
- 对训练数据具有分类能力的特征
- 节点纯度的提升：子节点包含的样本尽可能属于同一类别

大纲

- 基本概念与流程
- **划分选择**
- 剪枝处理
- 连续值与缺失值处理

划分选择

- 如何选择最优划分属性
- 目标：随着划分的进行，节点的“纯度”(purity)越来越高



划分选择

- 经典的属性划分方法
  - 信息增益：ID3决策树
  - 增益率：C4.5决策树
  - 基尼指数：CART决策树

划分选择：信息增益

- 假设当前样本集合D中第k类样本所占的比例为 $p_k(k=1,2,\ldots,|\mathcal{Y}|)$
- 信息熵：随机变量的不确定性

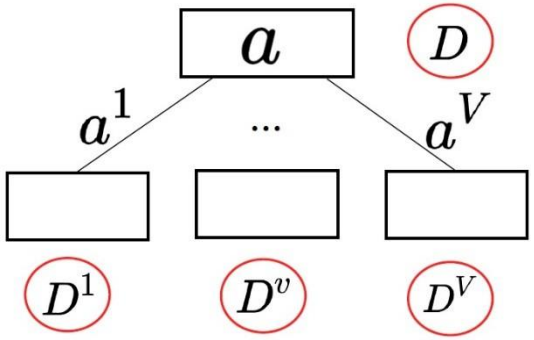
$$\mathrm{Ent}(D)=-\sum_{k=1}^{|\mathcal{Y}|}p_k\log_2 p_k$$

- 值越小，不确定性越小，纯度越高
- 对于二分类的场景，设正例的比例为p，则

$$\mathrm{Ent}(D)=-p\log_2 p-(1-p)\log_2(1-p)$$

划分选择：信息增益

- 信息增益



$$\mathrm{Gain}(D,a)=\mathrm{Ent}(D)-\sum_{v=1}^{V}\frac{|D^v|}{|D|}\mathrm{Ent}(D^v)$$

划分选择：信息增益

- 例子

编号	色泽	根蒂	敲声	纹理	脐部	触感	好瓜
1	青绿	蜷缩	浊响	清晰	凹陷	硬滑	是
2	乌黑	蜷缩	沉闷	清晰	凹陷	硬滑	是
3	乌黑	蜷缩	浊响	清晰	凹陷	硬滑	是
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	是
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	是
6	青绿	稍蜷	浊响	清晰	稍凹	软粘	是
7	乌黑	稍蜷	浊响	稍糊	稍凹	软粘	是
8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	是
9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	否
10	青绿	硬挺	清脆	清晰	平坦	软粘	否
11	浅白	硬挺	清脆	模糊	平坦	硬滑	否
12	浅白	蜷缩	浊响	模糊	平坦	软粘	否
13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	否
14	浅白	稍蜷	沉闷	稍糊	凹陷	硬滑	否
15	乌黑	稍蜷	浊响	清晰	稍凹	软粘	否
16	浅白	蜷缩	浊响	模糊	平坦	硬滑	否
17	青绿	蜷缩	沉闷	稍糊	稍凹	硬滑	否

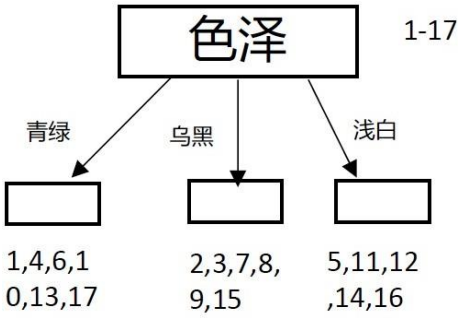
正例 $p_1 = \frac{8}{17}$

反例 $p_2 = \frac{9}{17}$

$$\mathrm{Ent}(D) = -\sum_{k=1}^{2} p_k \log_2 p_k = -\left(\frac{8}{17}\log_2\frac{8}{17} + \frac{9}{17}\log_2\frac{9}{17}\right) = 0.998$$

划分选择：信息增益

- 属性“色泽”
  - D^1 色泽=青绿 $p_1 = \frac{3}{6}, p_2 = \frac{3}{6}$
  - D^2 色泽=乌黑 $p_1 = \frac{4}{6}, p_2 = \frac{2}{6}$
  - D^3 色泽=浅白 $p_1 = \frac{1}{5}, p_2 = \frac{4}{5}$



- 对应的信息增益为

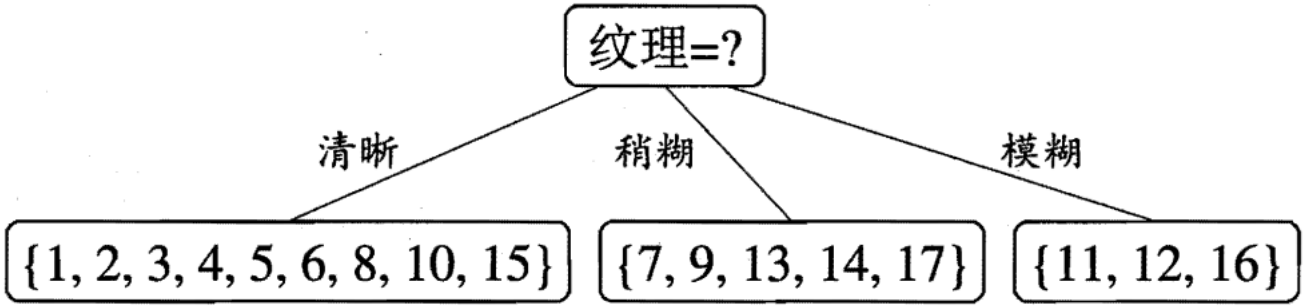
$$\begin{aligned}\text{Gain}(D, \text{色泽}) &= \text{Ent}(D) - \sum_{v=1}^{3} \frac{|D^v|}{|D|}\text{Ent}(D^v) \\ &= 0.998 - \left(\tfrac{6}{17} \times 1.000 + \tfrac{6}{17} \times 0.918 + \tfrac{5}{17} \times 0.722\right) \\ &= 0.109\end{aligned}$$

划分选择：信息增益

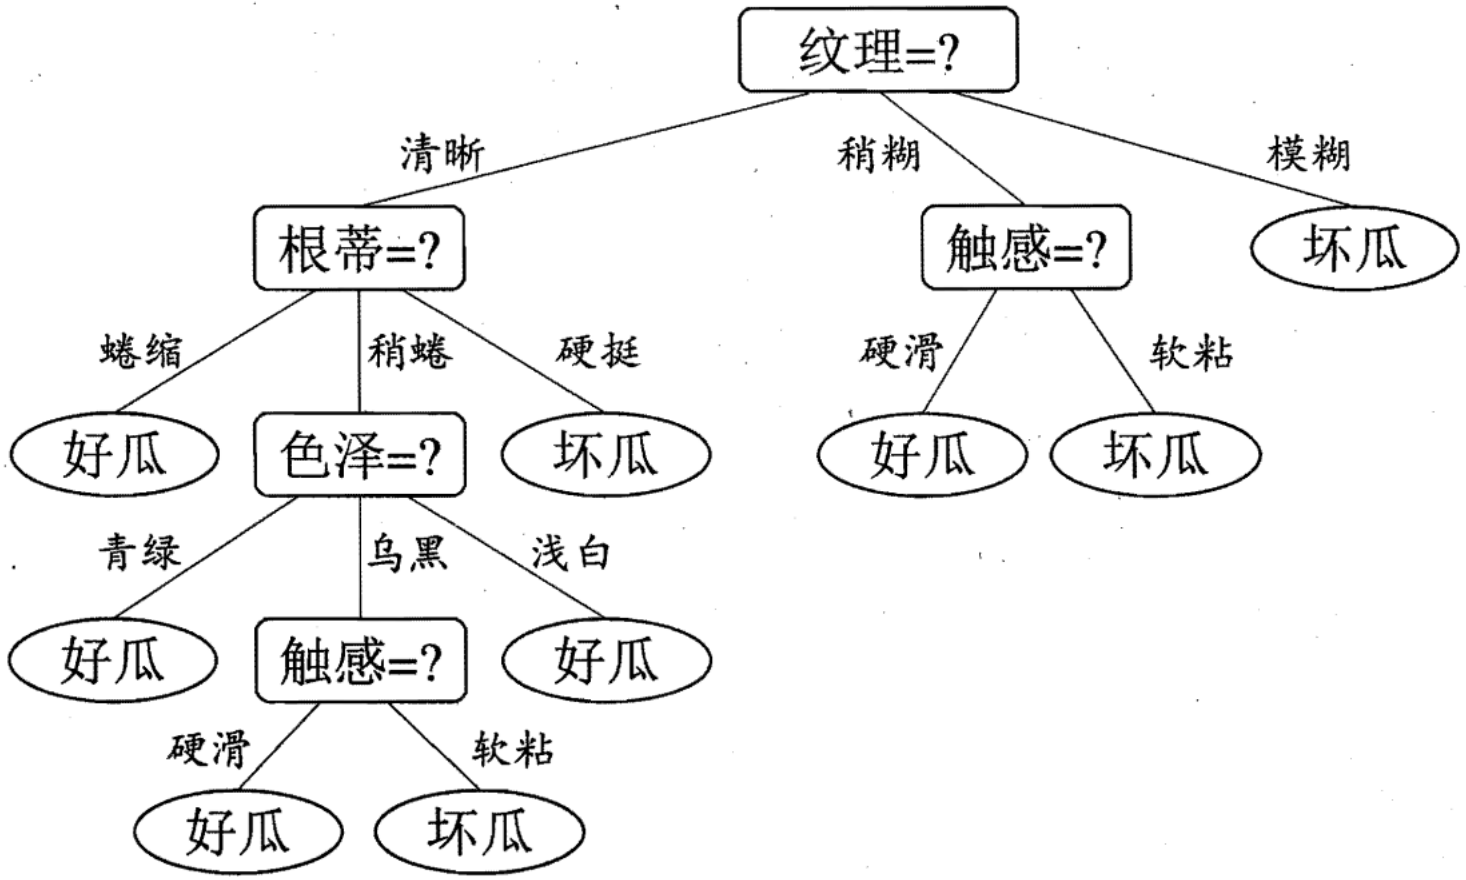
- 类似的，其他属性的信息增益为

$$\text{Gain}(D, \text{根蒂}) = 0.143 \quad \text{Gain}(D, \text{敲声}) = 0.141$$
$$\text{Gain}(D, \text{纹理}) = 0.381 \quad \text{Gain}(D, \text{脐部}) = 0.289$$
$$\text{Gain}(D, \text{触感}) = 0.006$$

- 显然，属性“纹理”的信息增益最大，其被选为划分属性



划分选择：信息增益


纹理=?
清晰
稍糊
模糊
根蒂=?
触感=?
坏瓜
蜷缩
稍蜷
硬挺
硬滑
软粘
好瓜
色泽=?
坏瓜
好瓜
坏瓜
青绿
乌黑
浅白
好瓜
触感=?
好瓜
硬滑
软粘
好瓜
坏瓜

划分选择：基尼系数

- 基尼值 $$\mathrm{Gini}(D)=\sum_{k=1}^{|\mathcal{Y}|}\sum_{k'\neq k}p_k p_{k'}=1-\sum_{k=1}^{|\mathcal{Y}|}p_k^2$$
  - 反映了从数据集中随机抽取两个样本，其类别标记不一致的概率
  - 基尼值越小，说明越纯
- 对于二分类的场景，设正例的比例为*p*，则

$$\mathrm{Gini}(D)=1-p^2-(1-p)^2=2p(1-p)$$

- 属性*a*的基尼指数

$$\mathrm{Gini_index}(D,a)=\sum_{v=1}^{V}\frac{|D^v|}{|D|}\mathrm{Gini}(D^v)$$

- CART决策树(Classification And Regression Tree)

划分选择：增益率

- 信息增益和基尼指数偏好取值数目较多的属性
- 解决方案：增益率
  - 相当于给信息增益做了一个规范化
  - 属性的可能取值数目越多，固有值越大

$$\text{Gain_ratio}(D,a) = \frac{\text{Gain}(D,a)}{\text{IV}(a)}$$

属性的固有值

$$\text{IV}(a) = -\sum_{v=1}^{V} \frac{|D^v|}{|D|} \log_2 \frac{|D^v|}{|D|}$$

- C4.5
  - 先找出信息增益高于平均水平的属性
  - 从中选增益率最高的属性

划分选择 vs. 剪枝

研究表明: 划分选择的各种准则虽然对决策树的尺寸有较大影响，但对泛化性能的影响很有限

例如信息增益与基尼指数产生的结果，仅在约 2% 的情况下不同

剪枝方法和程度对决策树泛化性能的影响更为显著

在数据带噪时甚至可能将泛化性能提升 25%

剪枝 (pruning) 是决策树对付“过拟合”的主要手段!

大纲

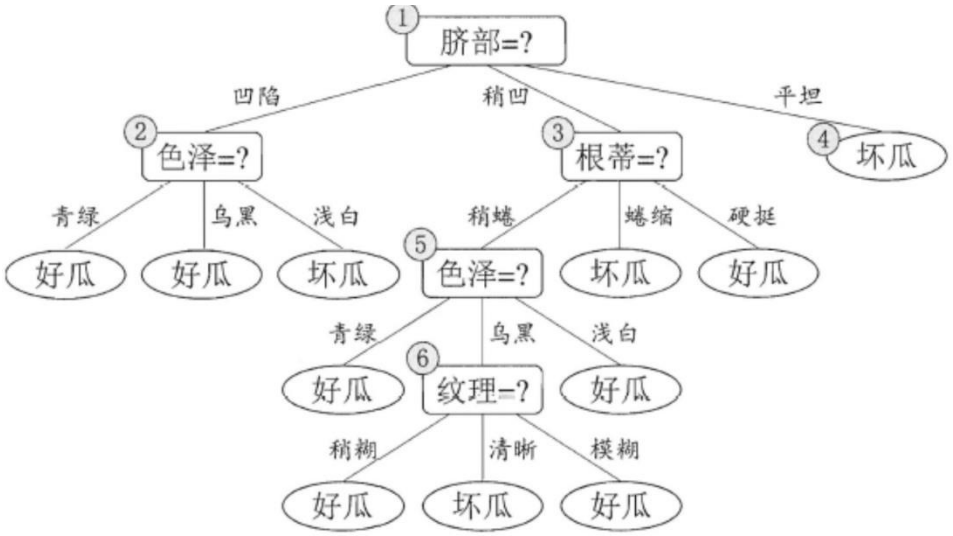
- 基本概念与流程
- 划分选择
- **剪枝处理**
- 连续值与缺失值处理

剪枝处理

- 决策树容易过拟合
  - 决策树决策分支过多，以致于把训练集自身的一些特点当做所有数据都具有的一般性质而导致的过拟合
  - 留出法：“验证集”进行剪枝的性能评估

基本策略：

- 预剪枝 (pre-pruning): 提前终止某些分支的生长
- 后剪枝 (post-pruning): 生成一棵完全树，再“回头”剪枝



训练集

编号	色泽	根蒂	敲声	纹理	脐部	触感	好瓜
1	青绿	蜷缩	浊响	清晰	凹陷	硬滑	是
2	乌黑	蜷缩	沉闷	清晰	凹陷	硬滑	是
3	乌黑	蜷缩	浊响	清晰	凹陷	硬滑	是
6	青绿	稍蜷	浊响	清晰	稍凹	软粘	是
7	乌黑	稍蜷	浊响	稍糊	稍凹	软粘	是
10	青绿	硬挺	清脆	清晰	平坦	软粘	否
14	浅白	稍蜷	沉闷	稍糊	凹陷	硬滑	否
15	乌黑	稍蜷	浊响	清晰	稍凹	软粘	否
16	浅白	蜷缩	浊响	模糊	平坦	硬滑	否
17	青绿	蜷缩	沉闷	稍糊	稍凹	硬滑	否

验证集

编号	色泽	根蒂	敲声	纹理	脐部	触感	好瓜
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	是
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	是
8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	是
9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	否
11	浅白	硬挺	清脆	模糊	平坦	硬滑	否
12	浅白	蜷缩	浊响	模糊	平坦	软粘	否
13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	否

剪枝处理-预剪枝

- 边建树，边剪枝
- 思路：当前节点的划分不能带来决策树泛化性能的提升
  - 根据信息增益的指标选择最优划分属性
  - 分别计算划分前及划分后验证集精度，判断是否需要划分
  - 若精度上升，则划分。对划分后的属性执行同样判断；否则停止划分，将当前节点记替换为叶节点，类别为训练样例最多的类别

剪枝处理-预剪枝

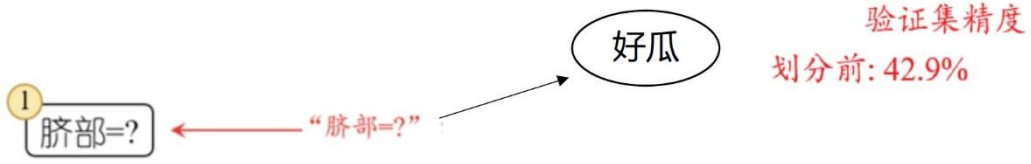
训练集

编号	色泽	根蒂	敲声	纹理	脐部	触感	好瓜
1	青绿	蜷缩	浊响	清晰	凹陷	硬滑	是
2	乌黑	蜷缩	沉闷	清晰	凹陷	硬滑	是
3	乌黑	蜷缩	浊响	清晰	凹陷	硬滑	是
6	青绿	稍蜷	浊响	清晰	稍凹	软粘	是
7	乌黑	稍蜷	浊响	稍糊	稍凹	软粘	是
10	青绿	硬挺	清脆	清晰	平坦	软粘	否
14	浅白	稍蜷	沉闷	稍糊	凹陷	硬滑	否
15	乌黑	稍蜷	浊响	清晰	稍凹	软粘	否
16	浅白	蜷缩	浊响	模糊	平坦	硬滑	否
17	青绿	蜷缩	沉闷	稍糊	稍凹	硬滑	否

验证集

编号	色泽	根蒂	敲声	纹理	脐部	触感	好瓜
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	是
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	是
8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	是
9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	否
11	浅白	硬挺	清脆	模糊	平坦	硬滑	否
12	浅白	蜷缩	浊响	模糊	平坦	软粘	否
13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	否

结点1：若不划分，则将其标记为叶结点，类别标记为训练样例中最多的类别，即好瓜。验证集中，$\{4,5,8\}$被分类正确，得到验证集精度为$\frac{3}{7} \times 100\% = 42.9\%$



验证集精度
划分前: 42.9%

剪枝处理-预剪枝

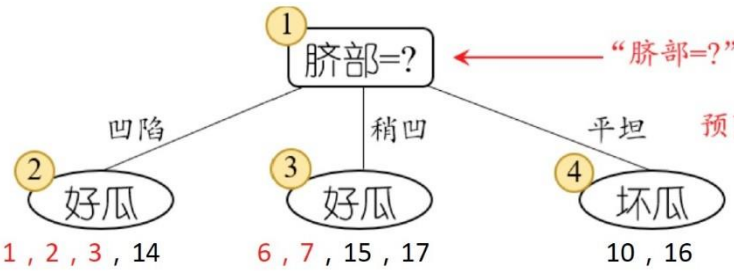
训练集

编号	色泽	根蒂	敲声	纹理	脐部	触感	好瓜
1	青绿	蜷缩	浊响	清晰	凹陷	硬滑	是
2	乌黑	蜷缩	沉闷	清晰	凹陷	硬滑	是
3	乌黑	蜷缩	浊响	清晰	凹陷	硬滑	是
6	青绿	稍蜷	浊响	清晰	稍凹	软粘	是
7	乌黑	稍蜷	浊响	稍糊	稍凹	软粘	是
10	青绿	硬挺	清脆	清晰	平坦	软粘	否
14	浅白	稍蜷	沉闷	稍糊	凹陷	硬滑	否
15	乌黑	稍蜷	浊响	清晰	稍凹	软粘	否
16	浅白	蜷缩	浊响	模糊	平坦	硬滑	否
17	青绿	蜷缩	沉闷	稍糊	稍凹	硬滑	否

验证集

编号	色泽	根蒂	敲声	纹理	脐部	触感	好瓜
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	是
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	是
8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	是
9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	否
11	浅白	硬挺	清脆	模糊	平坦	硬滑	否
12	浅白	蜷缩	浊响	模糊	平坦	软粘	否
13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	否

结点1：若划分，根据结点②，③，④的训练样例，将这3个结点分别标记为“好瓜”、“好瓜”、“坏瓜”。此时，验证集中编号为$\{4,5,8,11,12\}$的样例被划分正确，验证集精度为$\frac{5}{7}\times 100\% = 71.4\%$

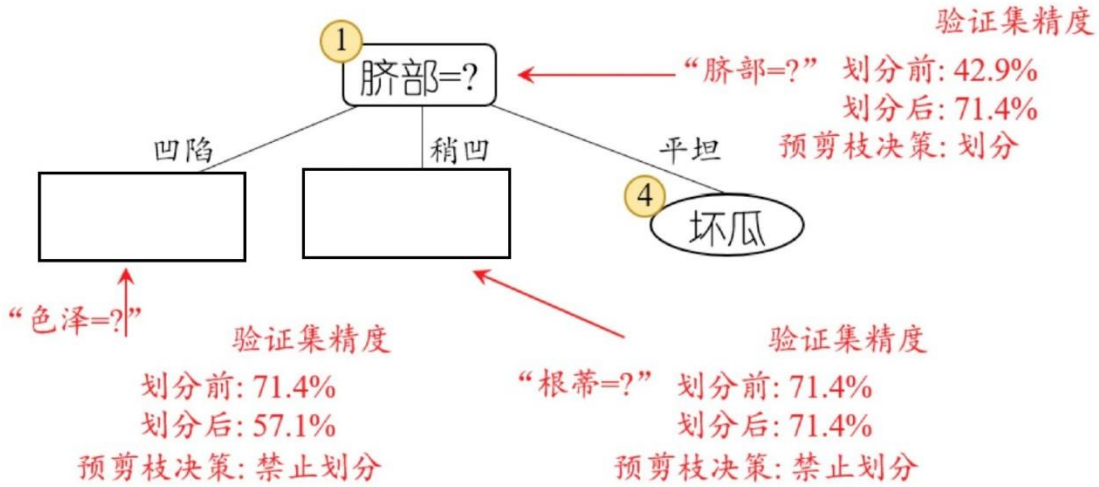


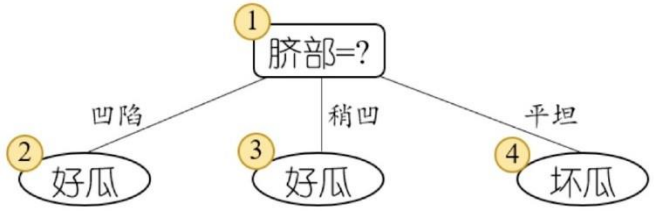
验证集精度
“脐部=?” 划分前: 42.9%
划分后: 71.4%
预剪枝决策: 划分

验证集：4，5，8，11，12正确，9，13错误

剪枝处理-预剪枝

对结点②，③，④ 分别进行剪枝判断，结点②，③都禁止划分，结点④本身为叶子结点。最终得到仅有一层划分的决策树，称为**“决策树桩”**



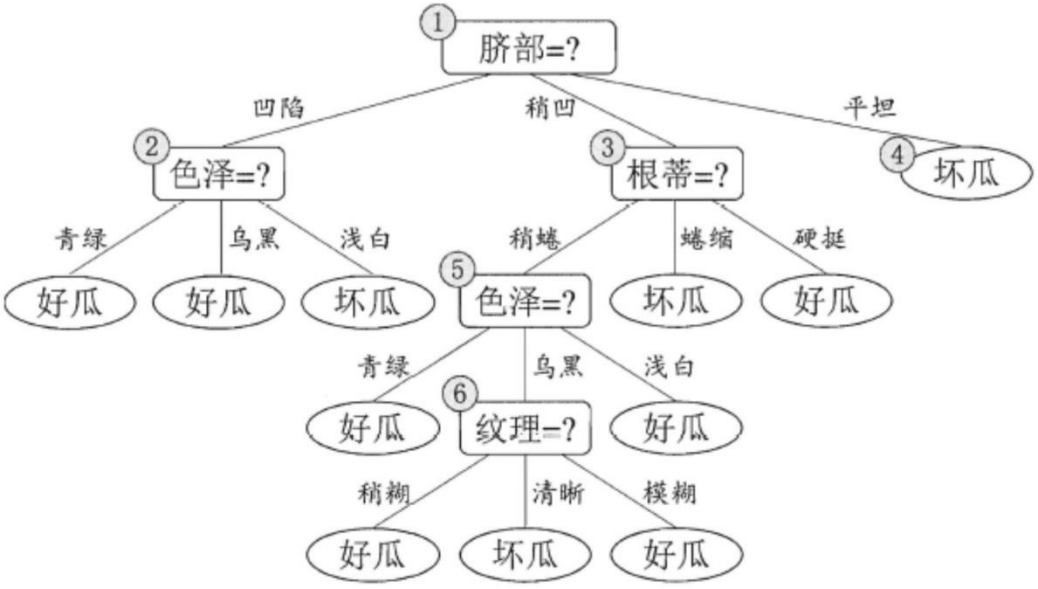


剪枝处理-预剪枝

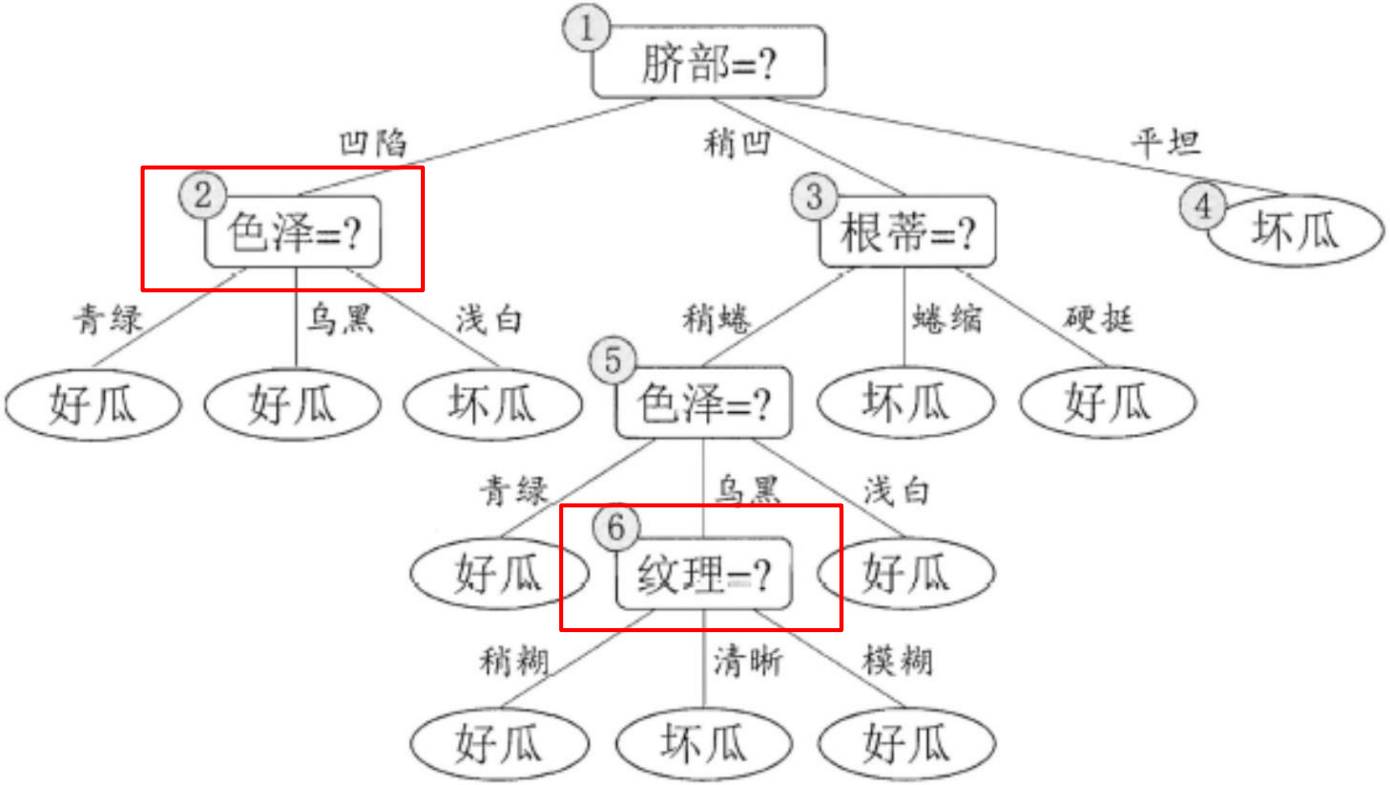
- 优点
  - 降低过拟合风险
  - 由于很多分支没有展开，减少训练时间和测试时间开销
- **缺点**
  - 欠拟合风险：预剪枝的“贪心”本质

剪枝处理-后剪枝

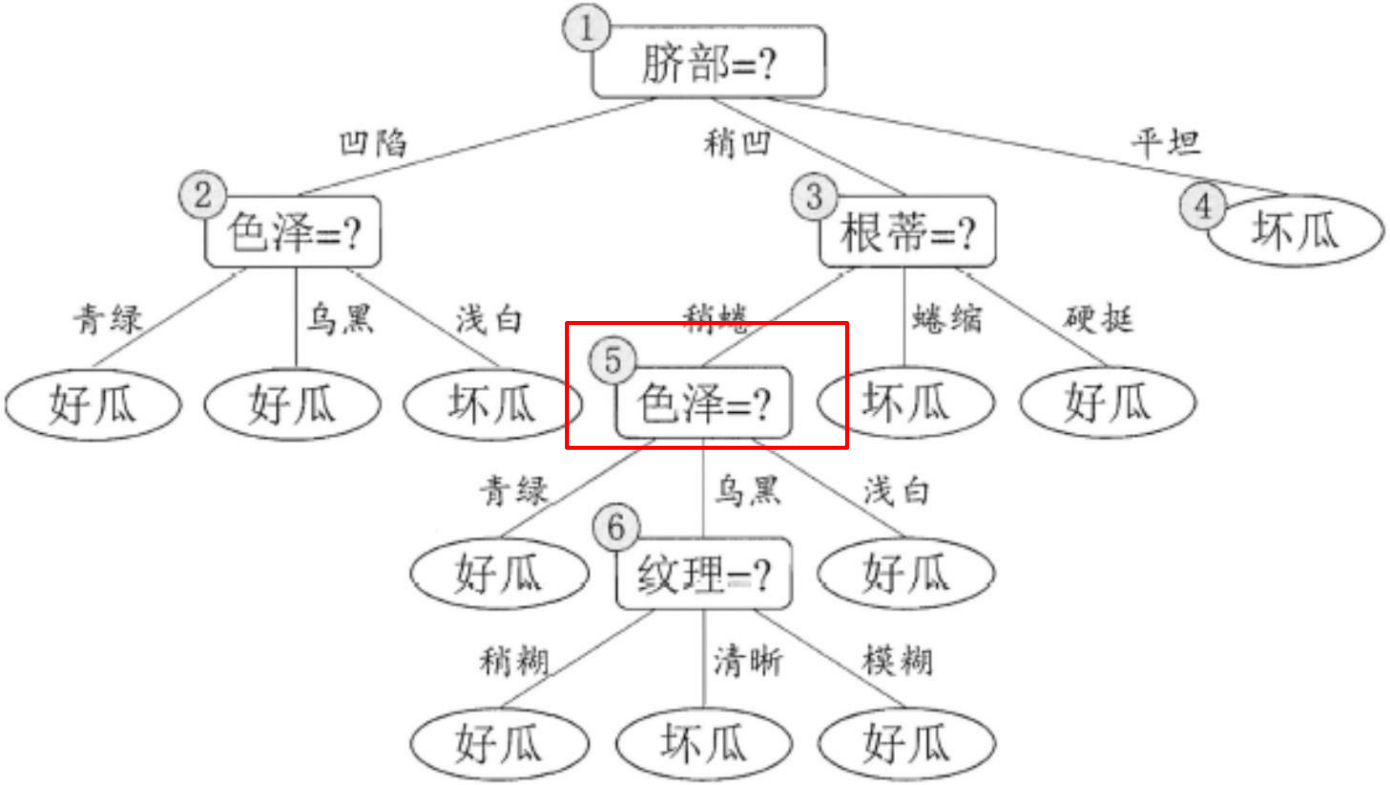
- 先建树，后剪枝
- 生成完整的决策树后，自底向上对所有非叶结点根据验证集上精度的变化决定是否剪枝
- 首先生成一棵完整的决策树，该决策树的验证集精度为42.9%



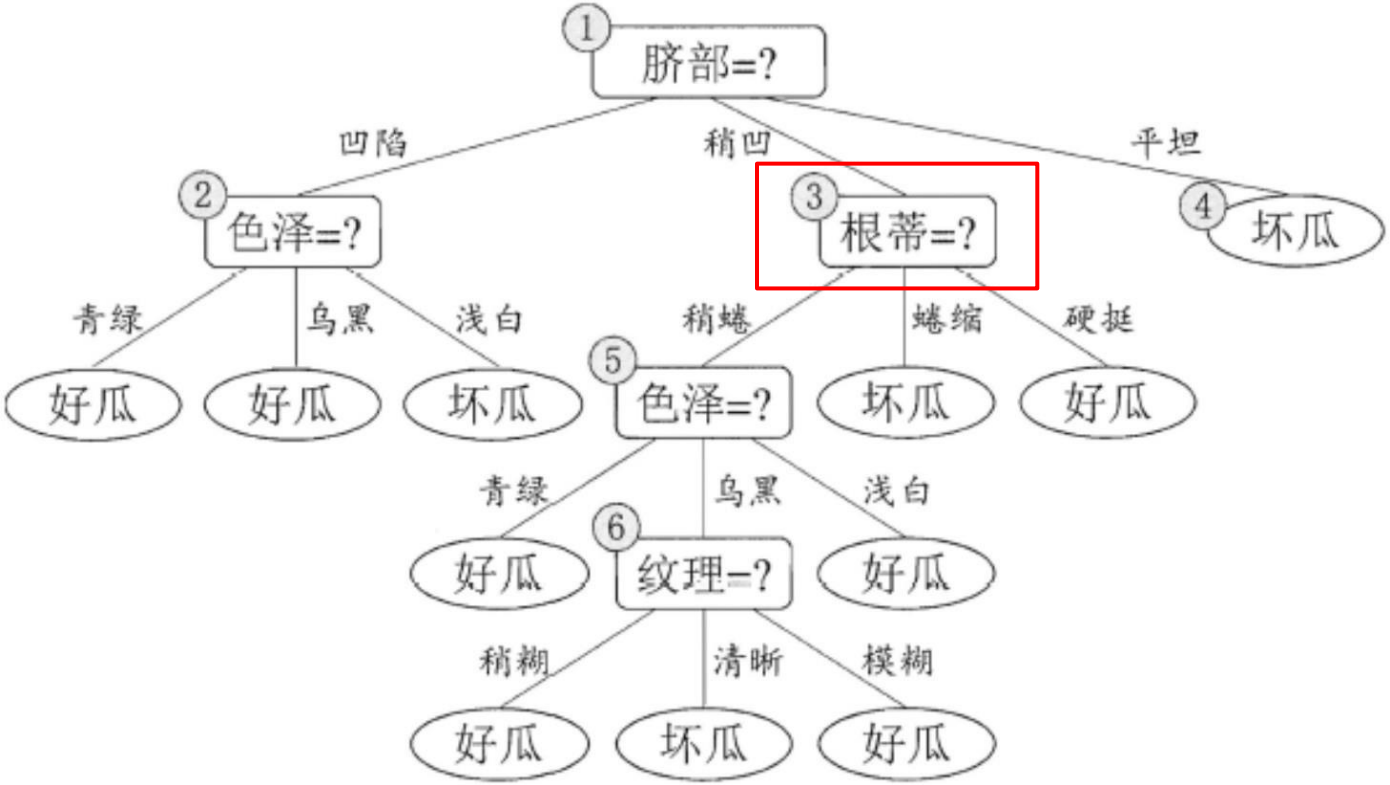
剪枝处理-后剪枝


1
脐部=?
凹陷
稍凹
平坦
2
色泽=?
3
根蒂=?
4
坏瓜
青绿
乌黑
浅白
稍蜷
蜷缩
硬挺
好瓜
好瓜
坏瓜
5
色泽=?
坏瓜
好瓜
青绿
乌黑
浅白
6
纹理=?
好瓜
好瓜
稍糊
清晰
模糊
好瓜
坏瓜
好瓜

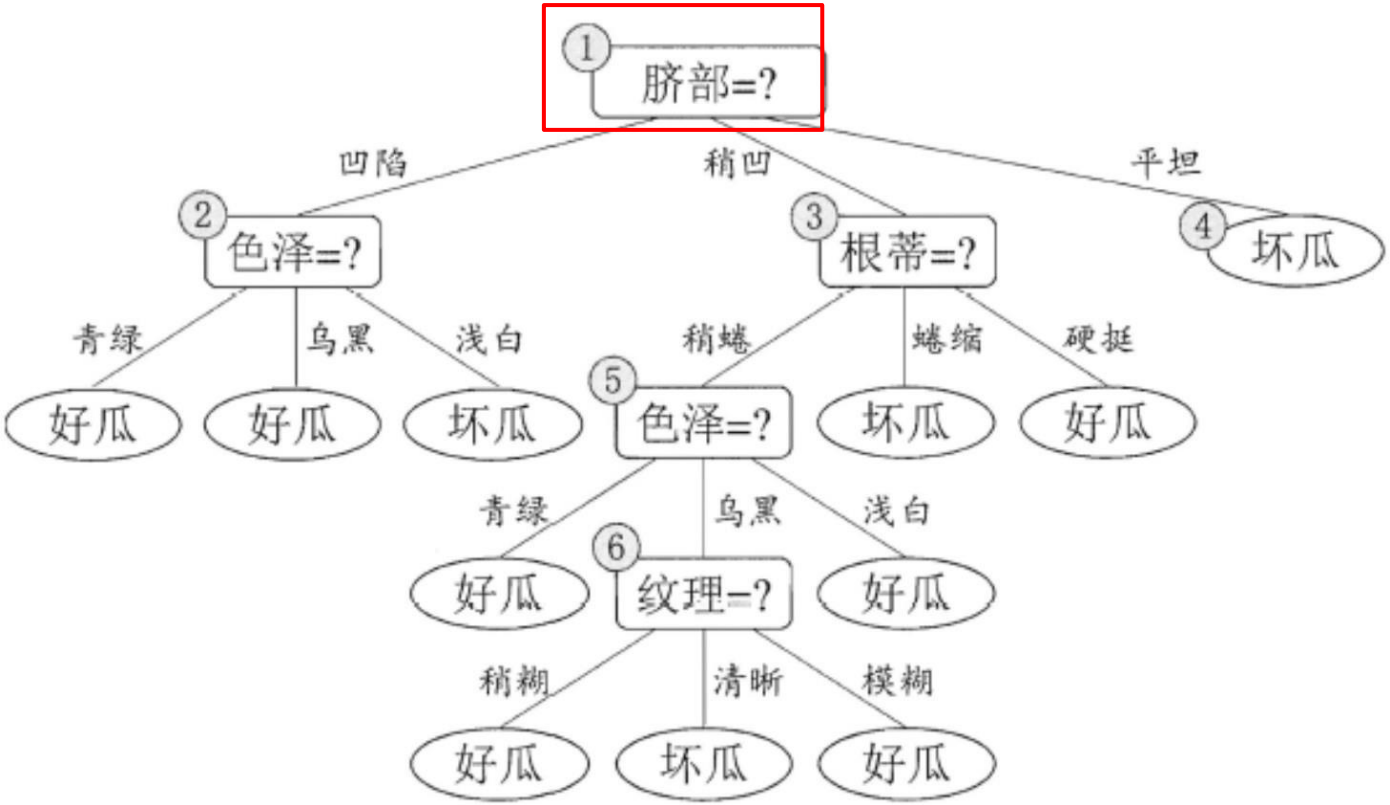
剪枝处理-后剪枝


1
脐部=?
凹陷
稍凹
平坦
2
色泽=?
3
根蒂=?
4
坏瓜
青绿
乌黑
浅白
稍蜷
蜷缩
硬挺
好瓜
好瓜
坏瓜
5
色泽=?
坏瓜
好瓜
青绿
乌黑
浅白
6
纹理=?
好瓜
好瓜
稍糊
清晰
模糊
好瓜
坏瓜
好瓜

剪枝处理-后剪枝


1
脐部=?
凹陷
稍凹
平坦
2
色泽=?
3
根蒂=?
4
坏瓜
青绿
乌黑
浅白
稍蜷
蜷缩
硬挺
好瓜
好瓜
坏瓜
5
色泽=?
坏瓜
好瓜
青绿
乌黑
浅白
6
纹理=?
好瓜
好瓜
稍糊
清晰
模糊
好瓜
坏瓜
好瓜

剪枝处理-后剪枝


1
脐部=?
凹陷
稍凹
平坦
2
色泽=?
3
根蒂=?
4
坏瓜
青绿
乌黑
浅白
稍蜷
蜷缩
硬挺
好瓜
好瓜
坏瓜
5
色泽=?
坏瓜
好瓜
青绿
乌黑
浅白
6
纹理=?
好瓜
好瓜
稍糊
清晰
模糊
好瓜
坏瓜
好瓜

剪枝处理-后剪枝

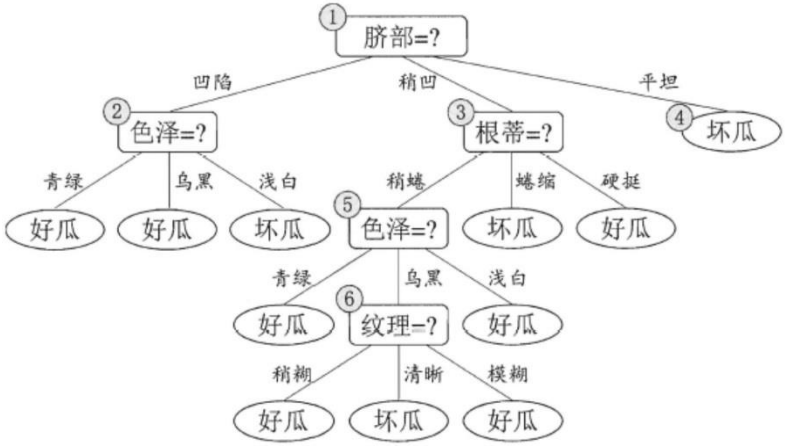
- 自底向上，首先考察结点⑥，将⑥替换为叶结点。⑥包含编号为{7，15}的训练样本，于是叶结点类别标记为“好瓜”。此时验证集上精度提高为57.1%，因此后剪枝策略决定剪枝。

训练集

编号	色泽	根蒂	敲声	纹理	脐部	触感	好瓜
1	青绿	蜷缩	浊响	清晰	凹陷	硬滑	是
2	乌黑	蜷缩	沉闷	清晰	凹陷	硬滑	是
3	乌黑	蜷缩	浊响	清晰	凹陷	硬滑	是
6	青绿	稍蜷	浊响	清晰	稍凹	软粘	是
7	乌黑	稍蜷	浊响	稍糊	稍凹	软粘	是
10	青绿	硬挺	清脆	清晰	平坦	软粘	否
14	浅白	稍蜷	沉闷	稍糊	凹陷	硬滑	否
15	乌黑	稍蜷	浊响	清晰	稍凹	软粘	否
16	浅白	蜷缩	浊响	模糊	平坦	硬滑	否
17	青绿	蜷缩	沉闷	稍糊	稍凹	硬滑	否

验证集

编号	色泽	根蒂	敲声	纹理	脐部	触感	好瓜
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	是
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	是
8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	是
9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	否
11	浅白	硬挺	清脆	模糊	平坦	硬滑	否
12	浅白	蜷缩	浊响	模糊	平坦	软粘	否
13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	否



剪枝前：验证集上8，9都分类错误

剪枝处理-后剪枝

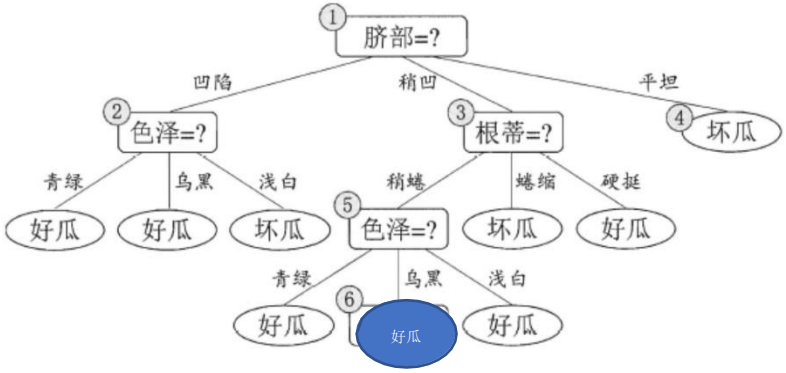
- 自底向上，首先考察结点⑥，将⑥替换为叶结点。⑥包含编号为{7，15}的训练样本，于是叶结点类别标记为“好瓜”。此时验证集上精度提高为57.1%，因此后剪枝策略决定剪枝。

训练集

编号	色泽	根蒂	敲声	纹理	脐部	触感	好瓜
1	青绿	蜷缩	浊响	清晰	凹陷	硬滑	是
2	乌黑	蜷缩	沉闷	清晰	凹陷	硬滑	是
3	乌黑	蜷缩	浊响	清晰	凹陷	硬滑	是
6	青绿	稍蜷	浊响	清晰	稍凹	软粘	是
7	乌黑	稍蜷	浊响	稍糊	稍凹	软粘	是
10	青绿	硬挺	清脆	清晰	平坦	软粘	否
14	浅白	稍蜷	沉闷	稍糊	凹陷	硬滑	否
15	乌黑	稍蜷	浊响	清晰	稍凹	软粘	否
16	浅白	蜷缩	浊响	模糊	平坦	硬滑	否
17	青绿	蜷缩	沉闷	稍糊	稍凹	硬滑	否

验证集

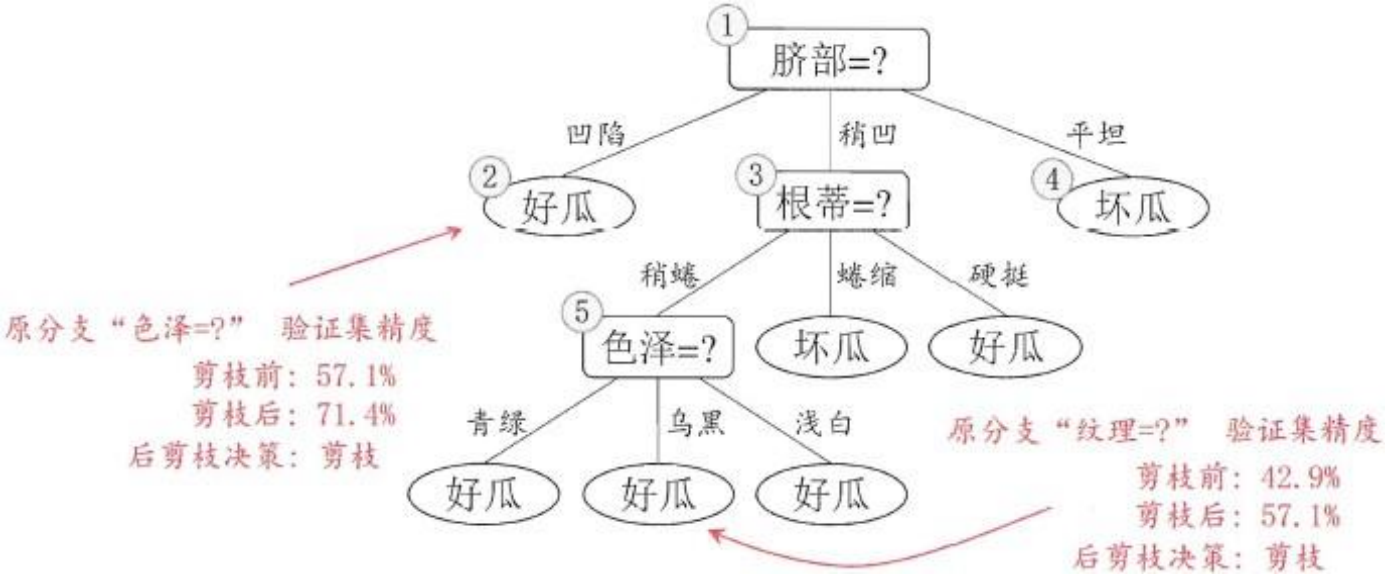
编号	色泽	根蒂	敲声	纹理	脐部	触感	好瓜
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	是
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	是
8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	是
9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	否
11	浅白	硬挺	清脆	模糊	平坦	硬滑	否
12	浅白	蜷缩	浊响	模糊	平坦	软粘	否
13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	否



剪枝后：验证集上8分类正确，9分类错误，精度提升！

剪枝处理-后剪枝

- 依次考察结点⑤②③①，得到最终的决策树



剪枝处理-后剪枝

- 优点
  - 后剪枝比预剪枝保留了更多的分支，欠拟合风险小，泛化性能往往优于预剪枝决策树
- **缺点**
  - 训练时间开销大：后剪枝过程是在生成完全决策树之后进行的，需要自底向上对所有非叶结点逐一考察；其训练时间要远大于预剪枝决策树

预剪枝 vs. 后剪枝

- 时间开销：
  - 预剪枝：训练时间开销降低，测试时间开销降低
  - 后剪枝：训练时间开销增加，测试时间开销降低

- 过/欠拟合风险：
  - 预剪枝：过拟合风险降低，欠拟合风险增加
  - 后剪枝：过拟合风险降低，欠拟合风险基本不变

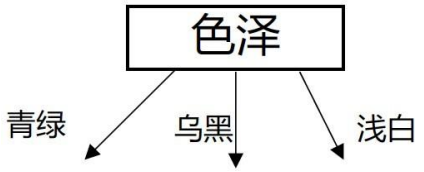
- 泛化性能：后剪枝 通常优于 预剪枝

大纲

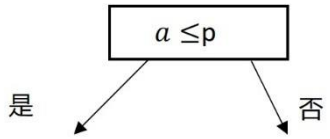
- 基本概念与流程
- 划分选择
- 剪枝处理
- **连续值与缺失值处理**

连续值处理

- 对离散属性，可直接得到属性测试条件



- 对于连续属性，如何得到属性测试条件？
  - 连续属性离散化(二分法）

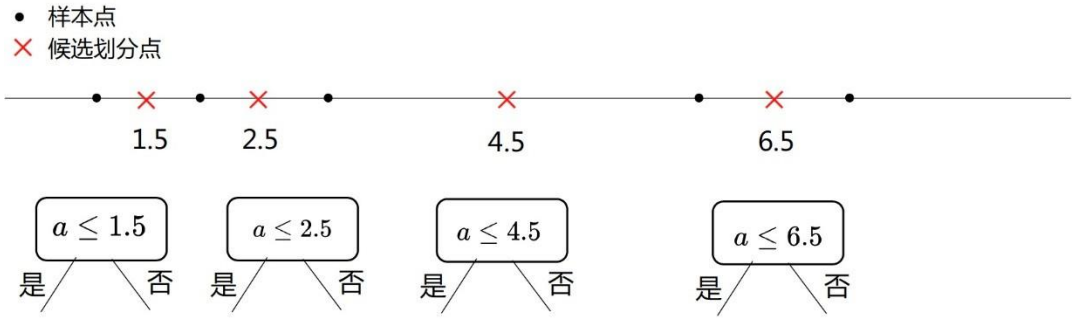


  - 如何选择划分点p?

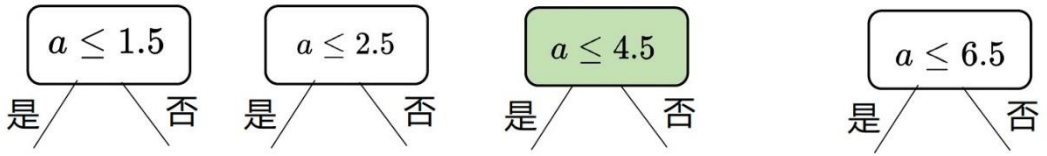
编号	色泽	根蒂	敲声	纹理	脐部	触感	密度	含糖率	好瓜
1	青绿	蜷缩	浊响	清晰	凹陷	硬滑	0.697	0.460	是
2	乌黑	蜷缩	沉闷	清晰	凹陷	硬滑	0.774	0.376	是
3	乌黑	蜷缩	浊响	清晰	凹陷	硬滑	0.634	0.264	是
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	0.608	0.318	是
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	0.556	0.215	是
6	青绿	稍蜷	浊响	清晰	稍凹	软粘	0.403	0.237	是
7	乌黑	稍蜷	浊响	稍糊	稍凹	软粘	0.481	0.149	是
8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	0.437	0.211	是
9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	0.666	0.091	否
10	青绿	硬挺	清脆	清晰	平坦	软粘	0.243	0.267	否
11	浅白	硬挺	清脆	模糊	平坦	硬滑	0.245	0.057	否
12	浅白	蜷缩	浊响	模糊	平坦	软粘	0.343	0.099	否
13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	0.639	0.161	否
14	浅白	稍蜷	沉闷	稍糊	凹陷	硬滑	0.657	0.198	否
15	乌黑	稍蜷	浊响	清晰	稍凹	软粘	0.360	0.370	否
16	浅白	蜷缩	浊响	模糊	平坦	硬滑	0.593	0.042	否
17	青绿	蜷缩	沉闷	稍糊	稍凹	硬滑	0.719	0.103	否

连续值处理

- 对样本集合该属性的属性值排序，得到候选划分点；每个候选划分点对应一种候选属性测试



- 对所有候选的属性测试，计算其信息增益，选择信息增益最大的候选属性测试作为该属性对应的属性测试



连续值处理

- 第一步：假定连续属性a在样本集D上出现n个不同的取值，从小到大排列，记为 $a^1, a^2, ...a^n$，基于划分点t，可将D分为子集D_t^-和D_t^+，其中D_t^-包含那些在属性a上取值不大于t的样本，D_t^+包含那些在属性a上取值大于t的样本。考虑包含$n-1$个元素的候选划分点集合

$$T_a = \left\{ \frac{a^i + a^{i+1}}{2} \mid 1 \leq i \leq n-1 \right\}$$

即把区间$[a^i, a^{i-1})$的中位点$\frac{a^i + a^{i+1}}{2}$作为候选划分点

连续值处理

- 第二步：采用离散属性值方法，考察这些划分点，选取最优的划分点进行样本集合的划分

$$\begin{aligned}\mathrm{Gain}(D,a) &= \max_{t\in T_a} \mathrm{Gain}(D,a,t) \\ &= \max_{t\in T_a} \mathrm{Ent}(D) - \sum_{\lambda\in\{-,+\}} \frac{|D_t^\lambda|}{|D|}\mathrm{Ent}(D_t^\lambda)\end{aligned}$$

其中 $\mathrm{Gain}(D,a,t)$ 是样本集D基于划分点t二分后的信息增益，于是，就可选择使 $\mathrm{Gain}(D,a,t)$ 最大化的划分点

连续值处理

编号	色泽	根蒂	敲声	纹理	脐部	触感	密度	含糖率	好瓜
1	青绿	蜷缩	浊响	清晰	凹陷	硬滑	0.697	0.460	是
2	乌黑	蜷缩	沉闷	清晰	凹陷	硬滑	0.774	0.376	是
3	乌黑	蜷缩	浊响	清晰	凹陷	硬滑	0.634	0.264	是
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	0.608	0.318	是
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	0.556	0.215	是
6	青绿	稍蜷	浊响	清晰	稍凹	软粘	0.403	0.237	是
7	乌黑	稍蜷	浊响	稍糊	稍凹	软粘	0.481	0.149	是
8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	0.437	0.211	是
9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	0.666	0.091	否
10	青绿	硬挺	清脆	清晰	平坦	软粘	0.243	0.267	否
11	浅白	硬挺	清脆	模糊	平坦	硬滑	0.245	0.057	否
12	浅白	蜷缩	浊响	模糊	平坦	软粘	0.343	0.099	否
13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	0.639	0.161	否
14	浅白	稍蜷	沉闷	稍糊	凹陷	硬滑	0.657	0.198	否
15	乌黑	稍蜷	浊响	清晰	稍凹	软粘	0.360	0.370	否
16	浅白	蜷缩	浊响	模糊	平坦	硬滑	0.593	0.042	否
17	青绿	蜷缩	沉闷	稍糊	稍凹	硬滑	0.719	0.103	否

对属性“密度”，其候选划分点集合包含16 个候选值：

$$T_{\text{密度}} = \{0.244, 0.294, 0.351, 0.381, 0.420, 0.459, 0.518, 0.574, 0.600, 0.621, 0.636, 0.648, 0.661, 0.681, 0.708, 0.746\}$$

可计算其信息增益为0.262，对应划分点为0.381

对属性“含糖量”进行同样处理

决策树的一些特性

- 一种构建分类模型的非参数方法。换句话说，它不要求任何先验假设，不假定类和其它属性服从一定的概率分布
- 找到最佳决策树是NP难问题，我们采用自顶向下的递归、贪心策略建立决策树
- 决策树具有很好的可解释性，但对数据扰动敏感。
- 决策树能很好地处理冗余属性。对于强相关的两个属性，若一个属性已经被选择作为划分属性，那么另一个属性通常会被忽略
- 数据碎片问题：叶结点对应的样本可能太少，不能做出具有统计意义的分类判决。解决方法：设置终止分裂的阈值

缺失值处理

```
data
```

	A	B	C	D	E	F	G
0	NaN	2.0	2.0	0	2	1	0
1	3.0	4.0	NaN	1	3	1	0
2	NaN	NaN	3.0	5	4	2	1
3	4.0	3.0	NaN	4	3	3	1
4	5.0	3.0	NaN	2	3	5	1

缺失值处理

- **造成缺失**值的原因
  - 信息暂时无法获取。如某种产品的收益等具有滞后效应。
  - 数据因人为因素没有被记录、遗漏或丢失，这个是数据缺失的主要原因。
  - 数据采集设备的故障、存储介质、传输媒体故障而造成数据丢失。
  - 获取这些信息的代价太大。
  - 有些对象的某个或某些属性是不可用的；如：未婚者的配偶姓名、儿童的固定收入状况等。

缺失值处理

- 数据集中不含缺失值的变量称为完全变量，数据集中含有缺失值的变量称为不完全变量。
- 缺失数据的类型
  - 完全随机缺失（missing completely at random, MCAR）指的是数据的缺失是随机的，数据的缺失不依赖于任何不完全变量或完全变量，如系统中断等。
  - 随机缺失(missing at random, MAR)指的是数据的缺失不是完全随机的，即该类数据的缺失依赖于其他完全变量，如高峰期数据更容易缺失。
  - 完全非随机缺失(missing not at random,MNAR)指的是数据的缺失依赖于不完全变量自身，如玩游戏多的同学倾向于不公布自己每周玩游戏的时间。

缺失值处理

- 方法一：**删除**（适用于MCAR）
- 将存在遗漏信息属性值的样本（行）或特征（列）删除，从而得到一个完整的数据表。
- **优点**：简单易行，在对象有多个属性缺失值、被删除的含缺失值的对象与初始数据集的数据量相比较小的情况下非常有效。
- **缺点**：当缺失数据所占比例较大，特别当遗漏数据非随机分布时，这种方法可能导致数据发生偏离，从而引出错误的结论。

缺失值处理

- 方法二：**插补法**
  - 平均值填充
    - 如果空值是数值型的，就根据该属性在其他所有对象的取值的平均值来填充该缺失的属性值；
    - 如果空值是非数值型的，用该属性在其他所有对象的取值次数最多的值(即出现频率最高的值，众数)来补齐该缺失的属性值
  - 条件平均值填充
    - 用于求平均的值并不是从数据集的所有对象中取，而是从与该对象具有相同决策属性值的对象中取得。
  - 这两种数据的补齐方法，其基本的出发点都是用现存数据的多数信息来推测缺失值。

缺失值处理

- 方法二：**插补法**
  - 多重插补（Multiple Imputation，MI）
  - 多值插补的思想来源于贝叶斯估计，认为待插补的值是随机的，它的值来自于已观测到的值。具体实践上通常是估计出待插补的值，然后再加上不同的噪声，形成多组可选插补值。根据某种选择依据，选取最合适的插补值。

    1　　插补：将不完整数据集缺失的观测行估算填充m次，填充值是从某种分布中提取的。这一步骤将生成m个完整的数据集。
    2　　分析：分别对（m个）每一个完整数据集进行分析。
    3　　合并：对来自各个填补数据集的结果进行综合

https://towardsdatascience.com/multiple-imputation-with-random-forests-in-python-dec83c0ac55b

缺失值处理

- 方法三：**不处理**
  - 将未知值补以我们的主观估计值，不一定完全符合客观事实，在对不完备信息进行补齐处理的同时，改变了原始的信息系统。
  - 对缺失值不正确的填充往往将新的噪声引入数据中，产生错误的结果。
  - 在许多情况下，我们希望在保持原始信息不发生变化的前提下对信息系统进行处理。
  - 在实际应用中，一些模型无法应对具有缺失值的数据，因此要对缺失值进行处理。然而还有一些模型本身就可以应对具有缺失值的数据，此时无需对数据进行处理，比如Xgboost等高级模型。

缺失值

现实应用中，经常会遇到属性值“缺失”(missing)现象

仅使用无缺失的样例？→ 对数据的极大浪费

使用带缺失值的样例，需解决：

Q1：如何进行划分属性选择？

Q2：给定划分属性，若样本在该属性上的值缺失，如何进行划分？

基本思路：样本赋权，权重划分

一个例子

仅通过无缺失值的样例来判断划分属性的优劣

学习开始时，根结点包含样例集 D 中全部17个样例，权重均为 1

表 4.4 西瓜数据集 2.0α

编号	色泽	根蒂	敲声	纹理	脐部	触感	好瓜
1	–	蜷缩	浊响	清晰	凹陷	硬滑	是
2	乌黑	蜷缩	沉闷	清晰	凹陷	–	是
3	乌黑	蜷缩	–	清晰	凹陷	硬滑	是
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	是
5	–	蜷缩	浊响	清晰	凹陷	硬滑	是
6	青绿	稍蜷	浊响	清晰	–	软粘	是
7	乌黑	稍蜷	浊响	稍糊	稍凹	软粘	是
8	乌黑	稍蜷	浊响	–	稍凹	硬滑	是
9	乌黑	–	沉闷	稍糊	稍凹	硬滑	否
10	青绿	硬挺	清脆	–	平坦	软粘	否
11	浅白	硬挺	清脆	模糊	平坦	–	否
12	浅白	蜷缩	–	模糊	平坦	软粘	否
13	–	稍蜷	浊响	稍糊	凹陷	硬滑	否
14	浅白	稍蜷	沉闷	稍糊	凹陷	硬滑	否
15	乌黑	稍蜷	浊响	清晰	–	软粘	否
16	浅白	蜷缩	浊响	模糊	平坦	硬滑	否
17	青绿	–	沉闷	稍糊	稍凹	硬滑	否

以属性“色泽”为例，该属性上无缺失值的样例子集 $\tilde{D}$ 包含 14 个样例，信息熵为

$$\mathrm{Ent}(\tilde{D}) = -\sum_{k=1}^{2} \tilde{p}_k \log_2 \tilde{p}_k = -\left(\frac{6}{14}\log_2\frac{6}{14} + \frac{8}{14}\log_2\frac{8}{14}\right) = 0.985$$

一个例子

令 $\tilde{D}^1$，$\tilde{D}^2$，$\tilde{D}^3$ 分别表示在属性“色泽”上取值为“青绿”“乌黑”以及“浅白”的样本子集，有

$$\mathrm{Ent}(\tilde{D}^1) = -\left(\frac{2}{4}\log_2\frac{2}{4} + \frac{2}{4}\log_2\frac{2}{4}\right) = 1.000 \quad \mathrm{Ent}(\tilde{D}^2) = -\left(\frac{4}{6}\log_2\frac{4}{6} + \frac{2}{6}\log_2\frac{2}{6}\right) = 0.918$$

$$\mathrm{Ent}(\tilde{D}^3) = -\left(\frac{0}{4}\log_2\frac{0}{4} + \frac{4}{4}\log_2\frac{4}{4}\right) = 0.000$$

因此，样本子集 $\tilde{D}$ 上属性“色泽”的信息增益为

$$\begin{aligned}\mathrm{Gain}(\tilde{D}, \text{色泽}) &= \mathrm{Ent}(\tilde{D}) - \sum_{v=1}^{3} \tilde{r}_v \mathrm{Ent}(\tilde{D}^v) \\ &= 0.985 - \left(\frac{4}{14} \times 1.000 + \frac{6}{14} \times 0.918 + \frac{4}{14} \times 0.000\right) \\ &= 0.306\end{aligned}$$

无缺失值样例中属性 a 取值为 v 的占比

于是，样本集 D 上属性“色泽”的信息增益为

$$\mathrm{Gain}(D, \text{色泽}) = \rho \times \mathrm{Gain}(\tilde{D}, \text{色泽}) = \frac{14}{17} \times 0.306 = 0.252$$

区别：无缺失值样例占比

类似地可计算出所有属性在 D 上的信息增益:

$$\text{Gain}(D, \text{色泽}) = 0.252; \quad \text{Gain}(D, \text{根蒂}) = 0.171;$$

$$\text{Gain}(D, \text{敲声}) = 0.145; \quad \text{Gain}(D, \text{纹理}) = 0.424;$$

$$\text{Gain}(D, \text{脐部}) = 0.289; \quad \text{Gain}(D, \text{触感}) = 0.006.$$

进入“纹理=清晰”分支

进入“纹理=稍糊”分支

进入“纹理=模糊”分支

样本权重在各子结点仍为1

在“纹理”上出现缺失值，样本 8, 10 同时进入三个分支，三分支上的权重分别为 7/15，5/15，3/15

编号	色泽	根蒂	敲声	纹理	脐部	触感	好瓜
1	–	蜷缩	浊响	清晰	凹陷	硬滑	是
2	乌黑	蜷缩	沉闷	清晰	凹陷	–	是
3	乌黑	蜷缩	–	清晰	凹陷	硬滑	是
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	是
5	–	蜷缩	浊响	清晰	凹陷	硬滑	是
6	青绿	稍蜷	浊响	清晰	–	软粘	是
7	乌黑	稍蜷	浊响	稍糊	稍凹	软粘	是
8	乌黑	稍蜷	浊响	–	稍凹	硬滑	是
9	乌黑	–	沉闷	稍糊	稍凹	硬滑	否
10	青绿	硬挺	清脆	–	平坦	软粘	否
11	浅白	硬挺	清脆	模糊	平坦	–	否
12	浅白	蜷缩	–	模糊	平坦	软粘	否
13	–	稍蜷	浊响	稍糊	凹陷	硬滑	否
14	浅白	稍蜷	沉闷	稍糊	凹陷	硬滑	否
15	乌黑	稍蜷	浊响	清晰	–	软粘	否
16	浅白	蜷缩	浊响	模糊	平坦	硬滑	否
17	青绿	–	沉闷	稍糊	稍凹	硬滑	否

权重划分

小结

- 基本概念与流程
- 划分选择
- 剪枝处理
- 连续值与缺失值处理