机器学习

Chapter 5：支持向量机

丁婧颖
信息管理与工程学院

支持向量机概述

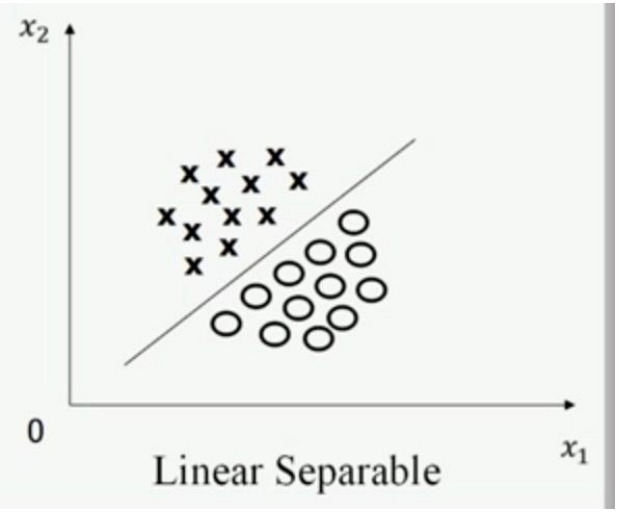
- **支持向量机**（Support Vector Machine, SVM）是一类按监督学习方式对数据进行二元分类的广义线性分类器（generalized linear classifier）。
- 与逻辑回归相比，支持向量机在学习复杂的非线性方程时提供了一种更为清晰，更加强大的方式。

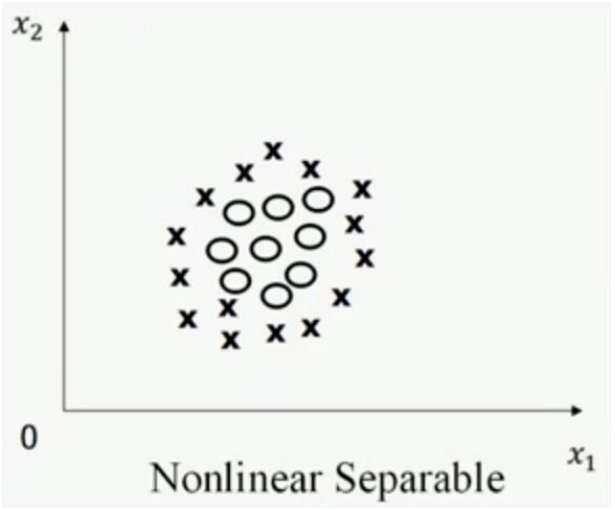
大纲

- 引言
- 线性可分支持向量机
- 软间隔支持向量机
- 核支持向量机
- 支持向量回归

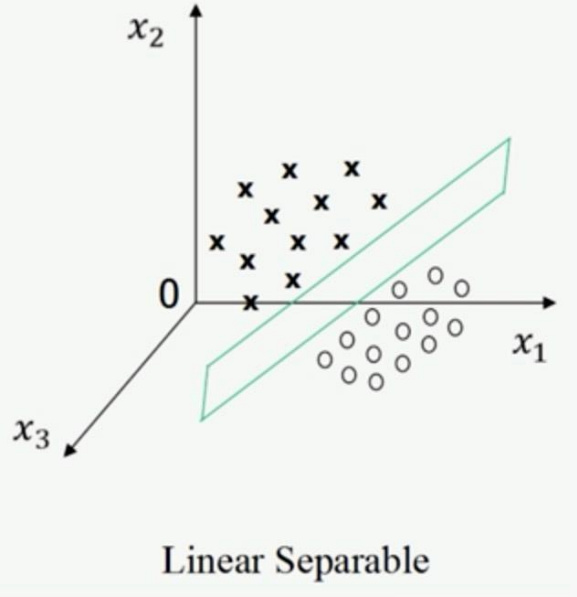
引言

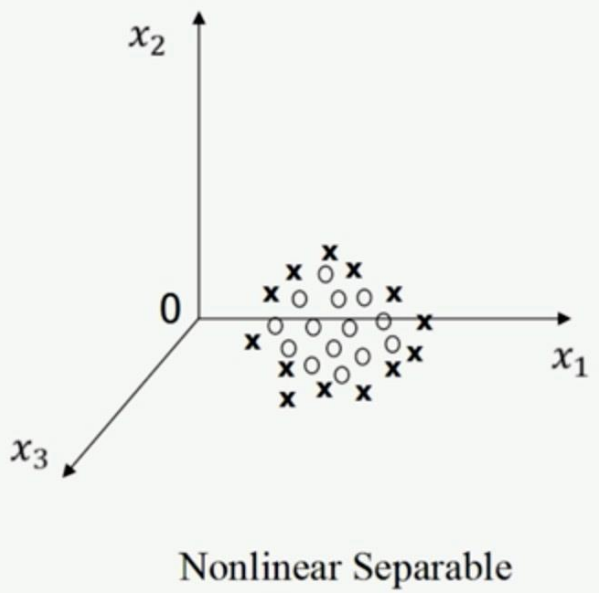
- 线性可分(Linear Separable)
- 线性不可分(Nonlinear Separable)





引言

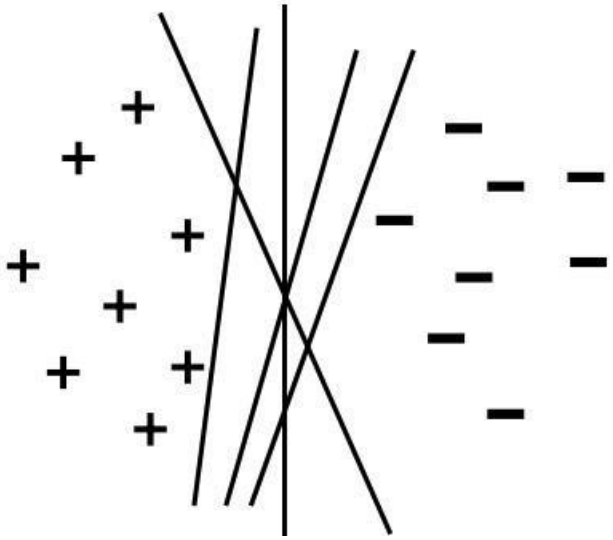




- 特征空间维度>三维时，超平面(Hyperplane)

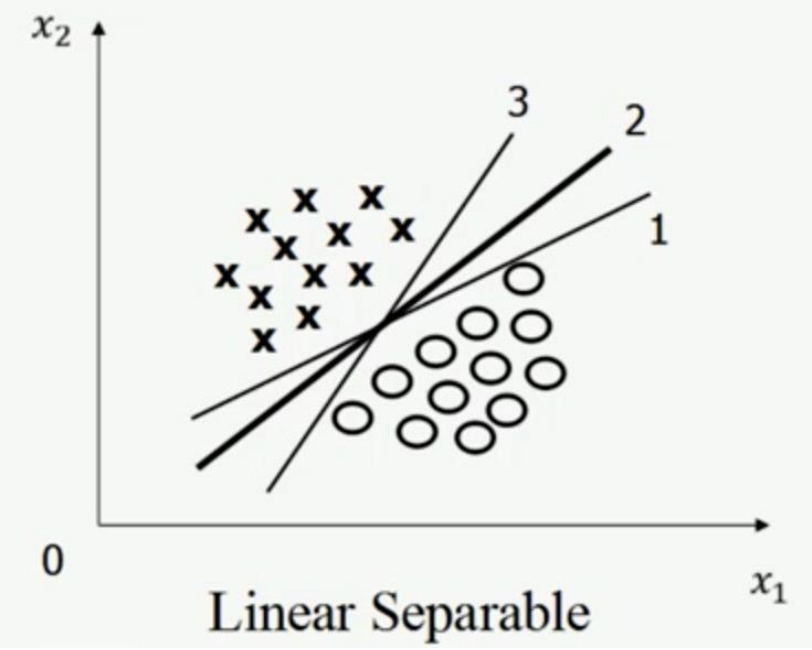
引言

- 在二分类情况下，如果一个数据集是线性可分的，即存在一个超平面将两个类别完全分开，那么一定存在无数多个超平面将这两个类别完全分开。



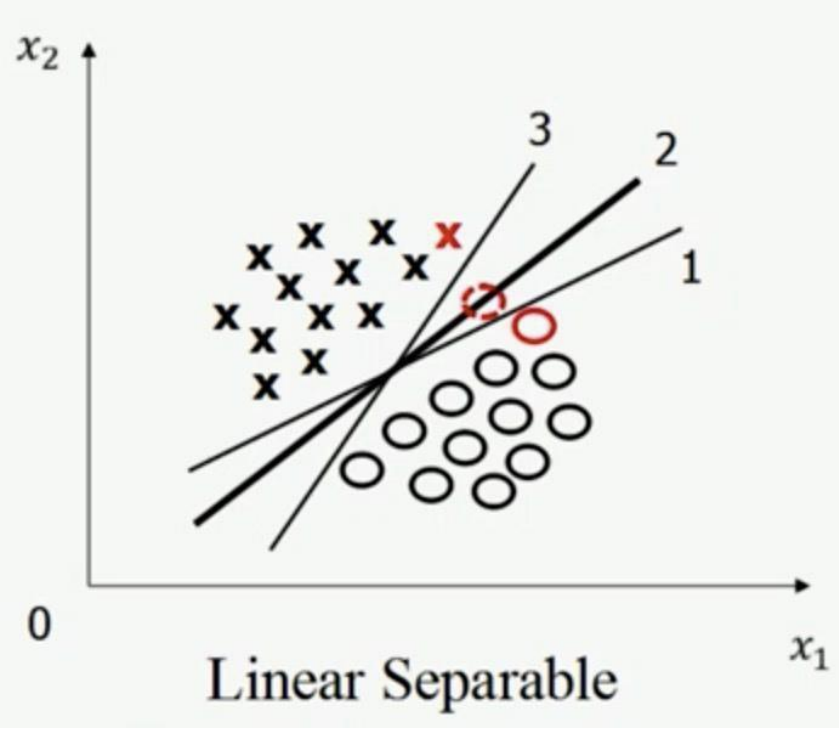
引言

- 在这无数多个分开各个类别的超平面中，到底哪一个最好呢？



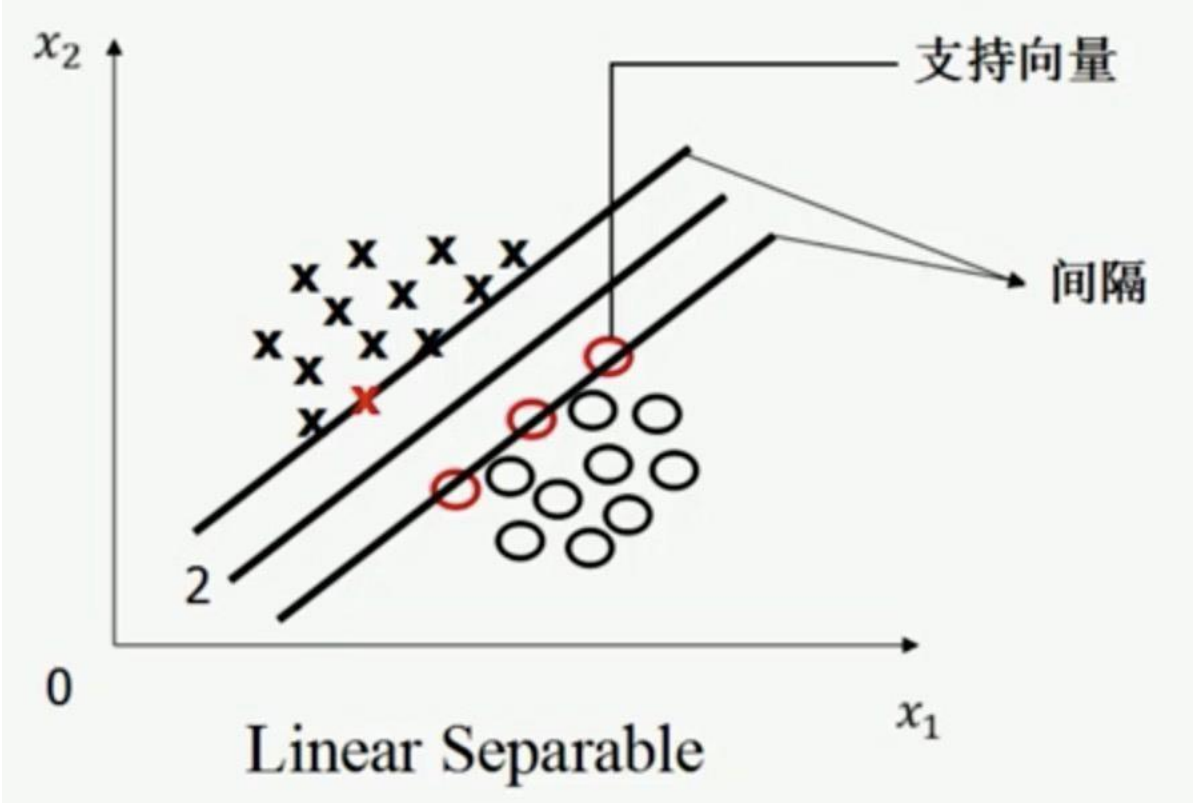
引言

- 训练集的局限性&噪声
- 直观上看，2对于训练样本局部扰动的“容忍性”最好

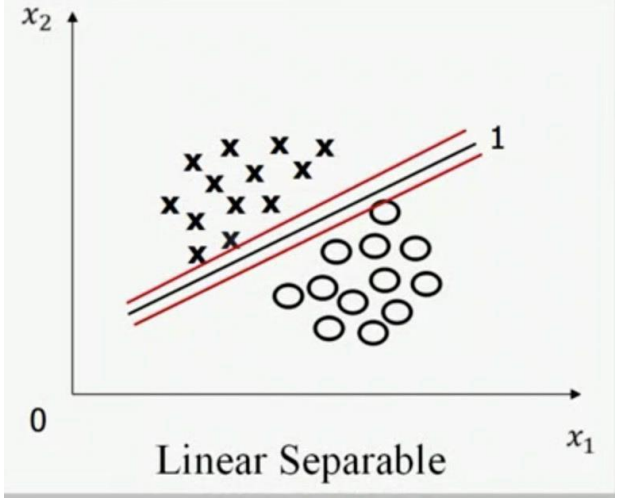


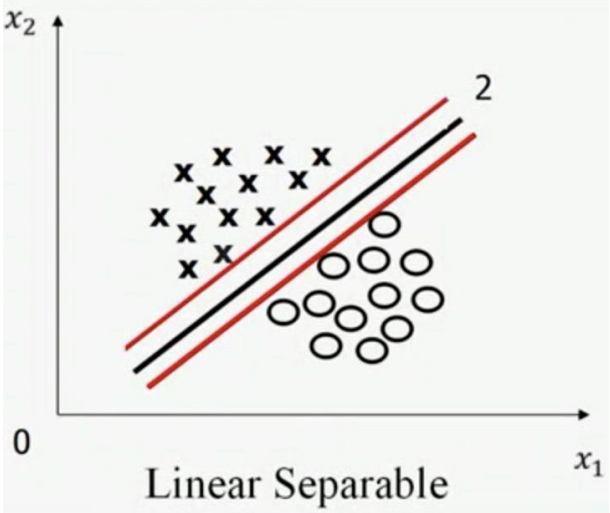
引言

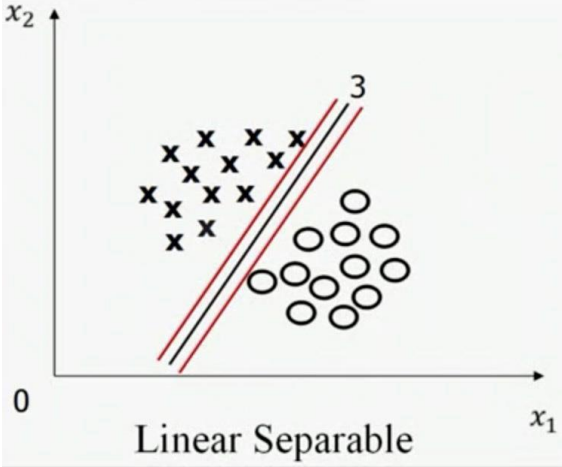
- 间隔(Margin)最大的是2号线



引言

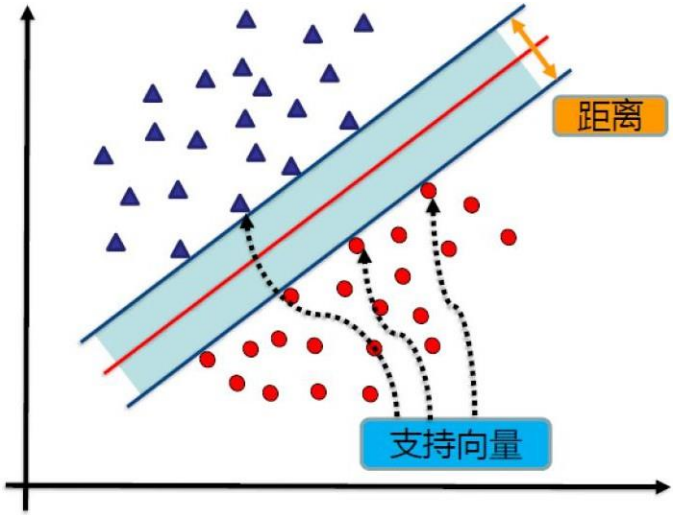

x_2
1
0
x_1
Linear Separable


x_2
2
0
x_1
Linear Separable


x_2
3
0
x_1
Linear Separable

引言

- 支持向量机的算法思路：找到集合边缘上的若干数据（称为支持向量Support Vector），用这些点找出一个平面（称为决策面），使得支持向量到该平面的距离最大。



引言

- 假如数据是完全线性可分的，那么学习到的模型可以称为硬间隔支持向量机
- 硬间隔指的就是完全分类准确，不能存在分类错误的情况
- 软间隔允许一定量的样本分类错误

大纲

- 引言
- **线性可分支持向量机**
- 软间隔支持向量机
- 核支持向量机
- 支持向量回归

线性可分支持向量机

任意超平面可以用下面这个线性方程来描述：

$$w^{\mathrm{T}}x + b = 0$$

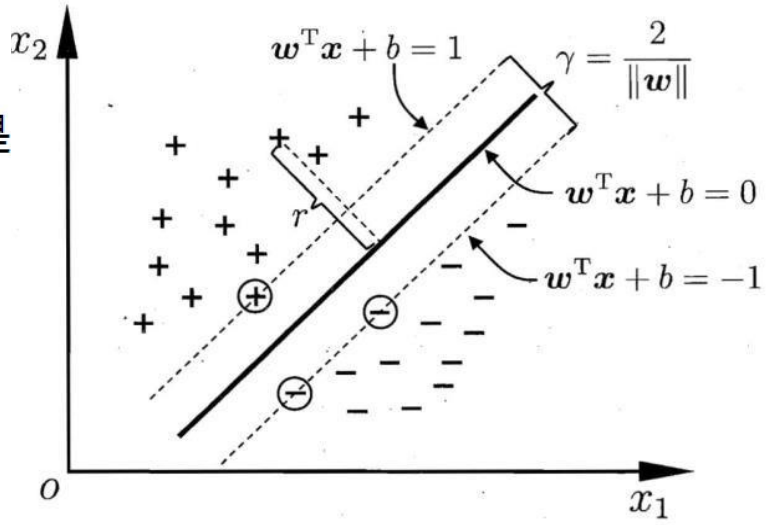
二维空间点 (x, y)到直线 $Ax + By + C = 0$的距离公式是

$$\frac{|Ax + By + C|}{\sqrt{A^2 + B^2}}$$

扩展到 n 维空间后，点 $x = (x_1, x_2 \ldots x_n)$ 到超平面

$w^{\mathrm{T}}x + b = 0$ 的距离为：$\frac{|w^{\mathrm{T}}x+b|}{||w||}$

其中 $||w|| = \sqrt{w_1^2 + \cdots w_n^2}$



线性可分支持向量机

分类全分对：$\begin{cases} \boldsymbol{w}^{\mathrm{T}}\boldsymbol{x}_i + b \geqslant +1, & y_i = +1 \\ \boldsymbol{w}^{\mathrm{T}}\boldsymbol{x}_i + b \leqslant -1, & y_i = -1 \end{cases}$

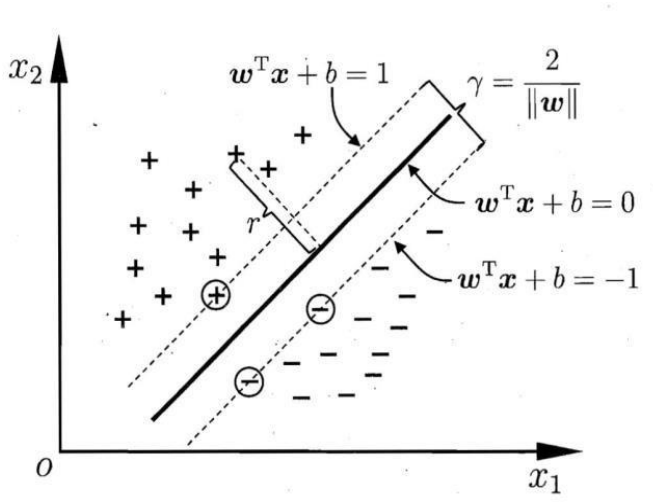
$$y_i(\boldsymbol{w}^{\mathrm{T}}\boldsymbol{x}_i + b) \geqslant 1$$

$$|\boldsymbol{w}^{\mathrm{T}}\boldsymbol{x} + b| = y(\boldsymbol{w}^{\mathrm{T}}\boldsymbol{x} + b)$$

约束 $\boldsymbol{w}$ 刚好满足：

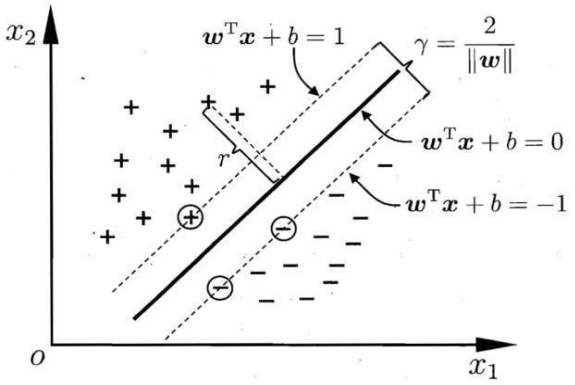
$$y_s(\boldsymbol{w}^{\mathrm{T}}\boldsymbol{x}_s + b) = 1$$

↖ 离分类超平面最近的点



支持向量机基本型

- **最大**间隔: 寻找参数 $\boldsymbol{w}$和 b，使得γ **最大**.



$$\arg\max_{\boldsymbol{w},b} \ \frac{2}{\|\boldsymbol{w}\|}$$

$$\text{s.t.} \ \ y_i(\boldsymbol{w}^{\top}\boldsymbol{x}_i+b)\geq 1, \ \ i=1,2,\ldots,m.$$

$$\arg\min_{\boldsymbol{w},b} \ \frac{1}{2}\|\boldsymbol{w}\|^2$$

$$\text{s.t.} \ \ y_i(\boldsymbol{w}^{\top}\boldsymbol{x}_i+b)\geq 1, \ \ i=1,2,\ldots,m.$$

对偶问题

$$\frac{1}{2}w^Tw+\sum_{i=1}^{m}\alpha_i-w^T\sum_{i=1}^{m}\alpha_i y_i x_i-\left(\sum_{i=1}^{m}\alpha_i y_i\right)b$$

拉格朗日乘子法

- 第一步：引入拉格朗日乘子 $\alpha_i \geq 0$ 得到拉格朗日函数

$$L(\boldsymbol{w}, b, \boldsymbol{\alpha}) = \frac{1}{2}\|\boldsymbol{w}\|^2 + \sum_{i=1}^{m}\alpha_i\left(1 - y_i(\boldsymbol{w}^{\mathrm{T}}\boldsymbol{x}_i + b)\right)$$

- 第二步：令 $L(\boldsymbol{w}, b, \boldsymbol{\alpha})$ 对 $\boldsymbol{w}$ 和 b 的偏导为零可得

$$\boldsymbol{w} = \sum_{i=1}^{m}\alpha_i y_i \boldsymbol{x}_i, \quad 0 = \sum_{i=1}^{m}\alpha_i y_i \longrightarrow -\frac{1}{2}w^Tw+\sum_{i=1}^{m}\alpha_i$$

- 第三步：回代可得

$$\max_{\boldsymbol{\alpha}} \sum_{i=1}^{m}\alpha_i - \frac{1}{2}\sum_{i=1}^{m}\sum_{j=1}^{m}\alpha_i\alpha_j y_i y_j \boldsymbol{x}_i^{\mathrm{T}}\boldsymbol{x}_j$$

$$\text{s.t.} \quad \sum_{i=1}^{m}\alpha_i y_i = 0, \quad \alpha_i \geqslant 0, \quad i = 1, 2, \ldots, m$$

解的稀疏性

- 最终模型：$f(\boldsymbol{x}) = \boldsymbol{w}^{\top}\boldsymbol{x} + b = \sum_{i=1}^{m} \alpha_i y_i \boldsymbol{x}_i^{\top}\boldsymbol{x} + b$

- KKT条件：

$$\begin{cases} \alpha_i \geq 0, \\ y_i f(\boldsymbol{x}_i) \geq 1, \\ \alpha_i (y_i f(\boldsymbol{x}_i) - 1) = 0. \end{cases} \Rightarrow \text{必有 } \alpha_i = 0 \text{ 或 } y_i f(\boldsymbol{x}_i) = 1$$

$$y_i f(\boldsymbol{x}_i) > 1 \Rightarrow \alpha_i = 0$$

支持向量机解的稀疏性：训练完成后，大部分的训练样本都不需保留，最终模型仅与支持向量有关.
重要性质：模型训练完后，大部分的训练样本都不需要保留，最终模型仅仅与支持向量有关

大纲

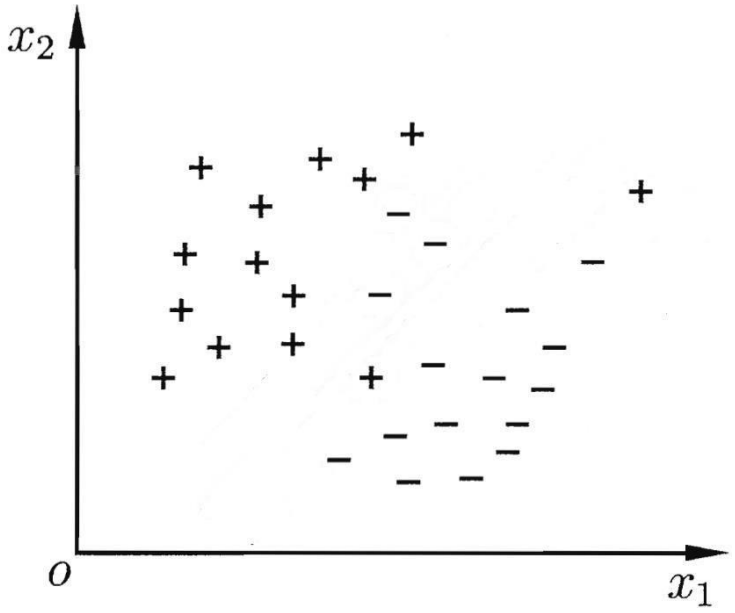
- 引言
- 线性可分支持向量机
- **软间隔支持向量机**
- 核支持向量机
- 支持向量回归

软间隔支持向量机

$$\min_{w,b} \frac{1}{2} \| \boldsymbol{w} \|^2$$

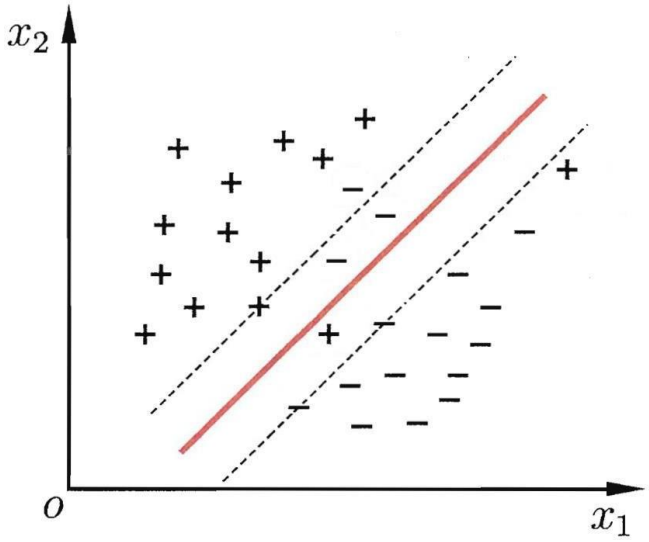
$$\text{s.t. } y_i(\boldsymbol{w}^{\mathrm{T}}\boldsymbol{x}_i + b) \geqslant 1, i = 1,2, \ldots, m$$

- 无解
- 即不存在(w, b)满足上面所有限制条件
- 适当放松限制条件



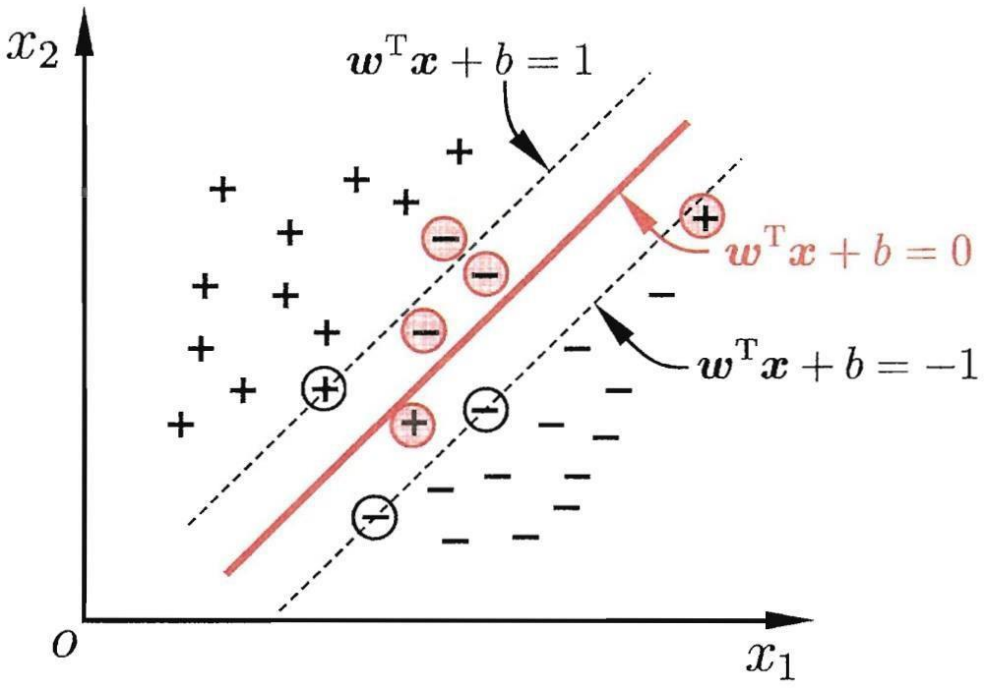
软间隔支持向量机

- 软间隔soft margin
- 基础支持向量机假定训练样本在样本空间或特征空间中是线性可分的
- 一些离群点或噪音点可能会造成训练样本仅仅是“接近线性可分的”



软间隔支持向量机

- 软间隔允许一些样本不满足 $y_i(\boldsymbol{w}^{\mathrm{T}}\boldsymbol{x}_i + b) \geqslant 1$



软间隔支持向量机

- 软间隔 *soft margin*

- 硬间隔约束

$$y_i(\boldsymbol{w}^{\mathrm{T}}\boldsymbol{x}_i + b) \geqslant 1$$

- 破坏硬间隔的0-1损失

$$\ell_{0/1}\left(y_i\left(\boldsymbol{w}^{\mathrm{T}}\boldsymbol{x}_i + b\right) - 1\right),\ \ell_{0/1}(z) = \begin{cases} 1, \text{if } z < 0 \\ 0, \text{otherwise} \end{cases}$$

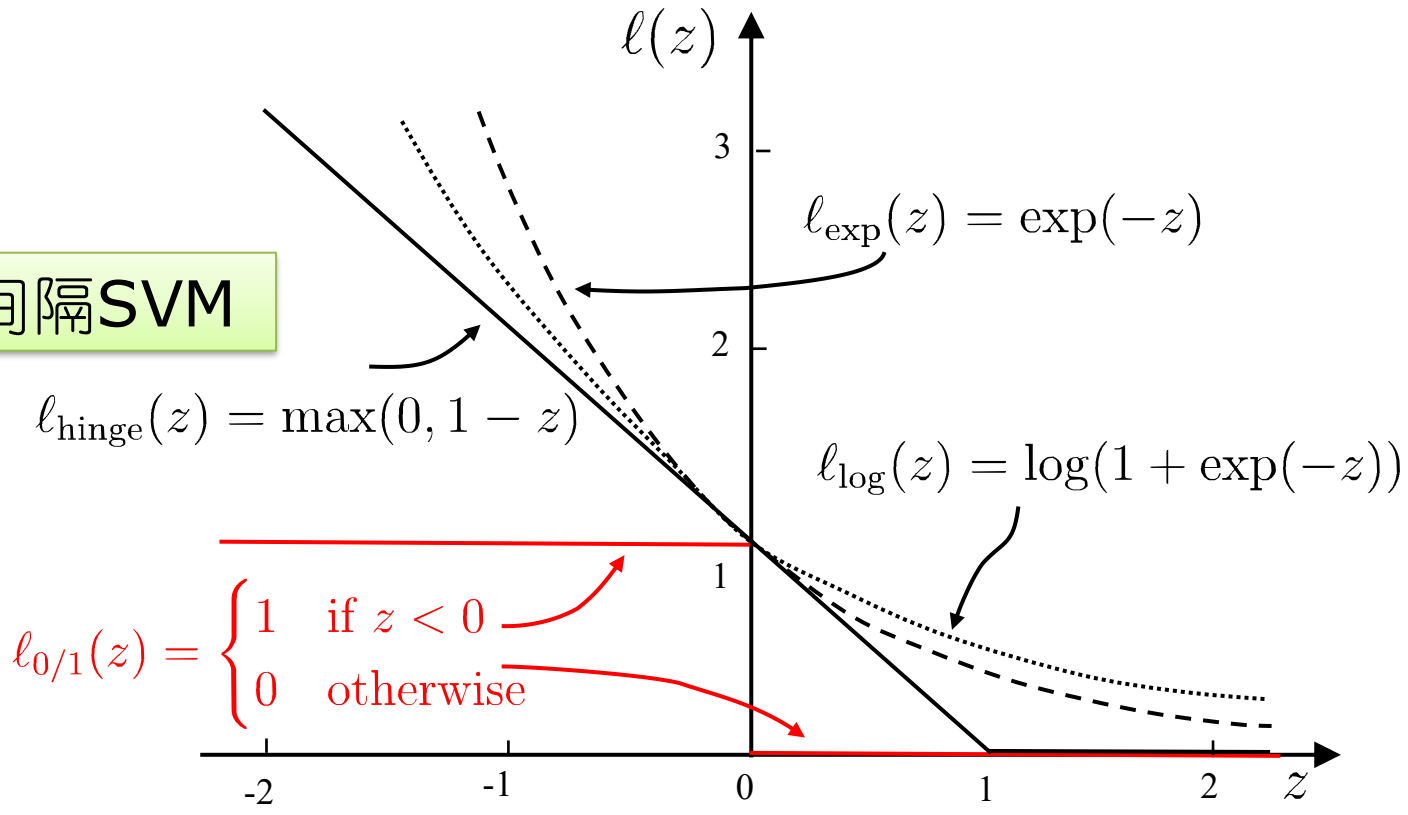
- hinge损失

$$\ell_{hinge}(z) = max(0, 1 - z)$$

$$\min_{\boldsymbol{w},b} \frac{1}{2} \| \boldsymbol{w} \|^2 + C \sum_{i=1}^{m} max(0, 1 - y_i(\boldsymbol{w}^{\mathrm{T}}\boldsymbol{x}_i + b))$$

替代损失

软间隔SVM



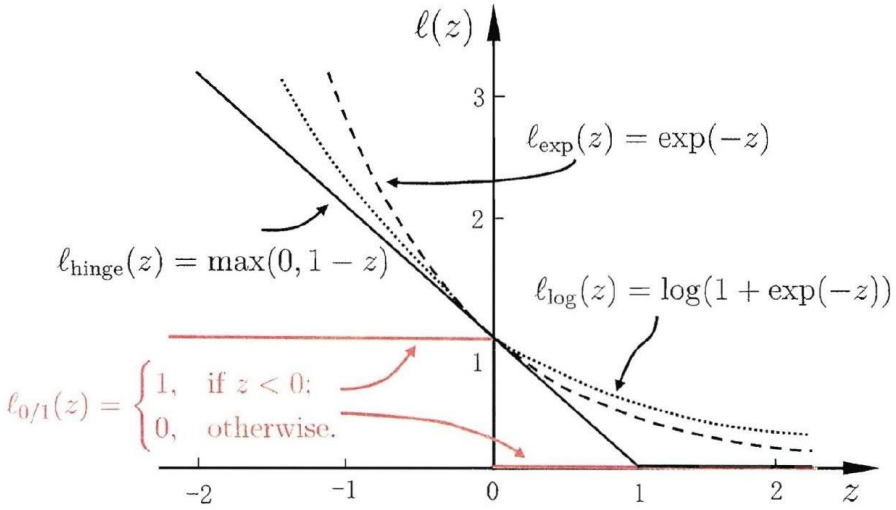
替代损失函数数学性质较好，一般是0/1损失函数的上界

软间隔支持向量机

- 常用的分类损失

- 函数间隔为关注对象 $z = y_i(\boldsymbol{w}^{\mathrm{T}}\boldsymbol{x}_i + b)$

hinge 损失: $\ell_{\text{hinge}}(z) = \max(0, 1 - z)$
指数损失(**exponential loss**): $\ell_{\exp}(z) = \exp(-z)$
对率损失(**logistic loss**): $\ell_{\log}(z) = \log(1 + \exp(-z))$



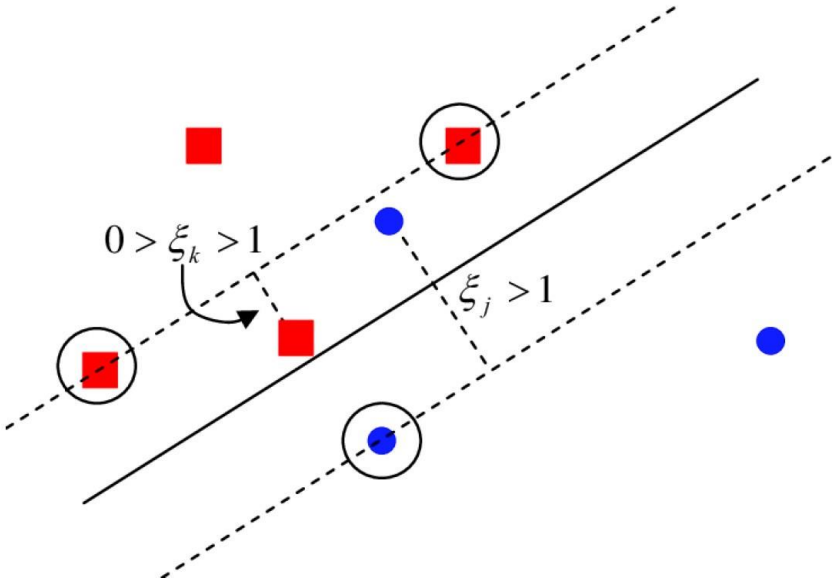
软间隔支持向量机

- 软间隔 *soft margin*

- hinge损失与松弛变量

$$\min_{w,b} \frac{1}{2} \| \boldsymbol{w} \|^2 + C \sum_{i=1}^{m} max(0, 1 - y_i(\boldsymbol{w}^{\mathrm{T}} \boldsymbol{x}_i + b))$$

$$\begin{aligned} \min_{w,b,\xi_i} \quad & \frac{1}{2} \| \boldsymbol{w} \|^2 + C \sum_{i=1}^{m} \xi_i \\ \text{s.t.} \quad & y_i(\boldsymbol{w}^{\mathrm{T}} \boldsymbol{x}_i + b) \geqslant 1 - \xi_i \\ & \xi_i \geqslant 0, i = 1,2,\ldots,m \end{aligned}$$

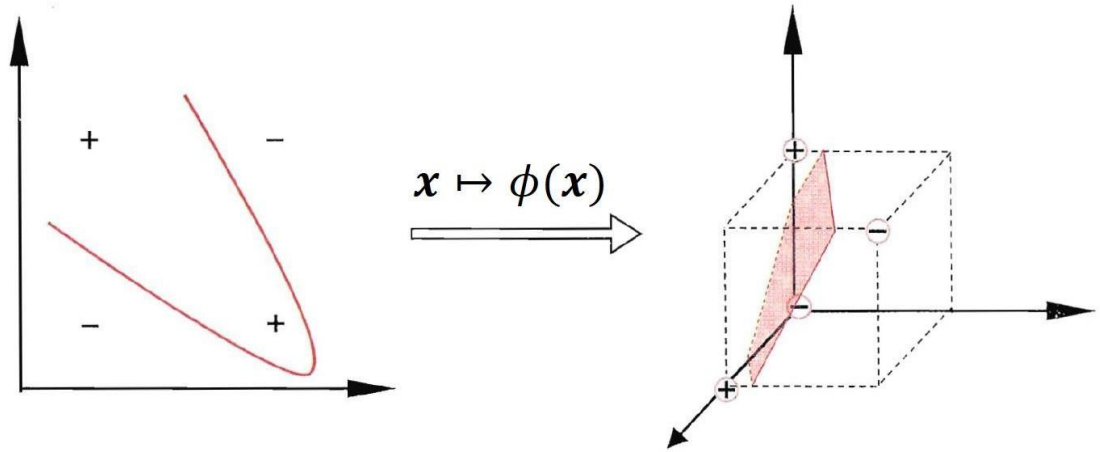


大纲

- 引言
- 线性可分支持向量机
- 软间隔支持向量机
- **核支持向量机**
- 支持向量回归

核支持向量机

- 空间变换的力量



如果原始空间是有限维，即属性数有限，那么一定存在一个高维特征空间使样本可分.

核支持向量机

- 我们需要引入一个新的概念：核函数。它可以将样本从原始空间映射到一个更高维的特征空间中，使得样本在新的空间中线性可分。
- 这样我们就可以使用原来的推导来进行计算，只是所有的推导是在新的空间，而不是在原来的空间中进行，即用核函数来替换当中的内积。

核支持向量机

- 空间变换下的支持向量机

$$f(x) = w^{\mathrm{T}}\phi(x) + b$$

$$\min_{w,b} \frac{1}{2} \| w \|^2$$
$$\text{s.t. } y_i(w^T\phi(x_i) + b) \geqslant 1, i = 1,2,\dots,m$$

$$\max_{\alpha} \sum_{i=1}^{m} \alpha_i - \frac{1}{2}\sum_{i=1}^{m}\sum_{j=1}^{m} \alpha_i\alpha_j y_i y_j \phi(\boldsymbol{x}_i)^{\mathrm{T}}\phi(\boldsymbol{x}_j)$$

$$\text{s.t. } \sum_{i=1}^{m} \alpha_i y_i = 0, \alpha_i \geqslant 0, i = 1,2,\dots,m$$

整个过程的求解式总是涉及到$\phi(\boldsymbol{x}_i)^{\mathrm{T}}\phi(\boldsymbol{x}_j)$，而直接计算高维空间下的样本内积可能是代价高昂的

核支持向量机

- 核函数

$$\kappa(\boldsymbol{x}_i, \boldsymbol{x}_j) = \langle \phi(\boldsymbol{x}_i), \phi(\boldsymbol{x}_j) \rangle = \phi(\boldsymbol{x}_i)^{\mathrm{T}} \phi(\boldsymbol{x}_j)$$

- 示例

$$\begin{aligned} \mathbf{K}(\mathbf{x}, \mathbf{y}) &= (\mathbf{x}^T \mathbf{y})^2 \\ &= x_1^2 y_1^2 + 2x_1 x_2 y_1 y_2 + x_2^2 y_2^2 \\ &= (x_1^2, \sqrt{2} x_1 x_2, x_2^2)(y_1^2, \sqrt{2} y_1 y_2, y_2^2) \\ &= \Phi(\mathbf{x})^T \Phi(\mathbf{y}) \end{aligned}$$

核支持向量机

- 核函数

$$\kappa(\boldsymbol{x}_i, \boldsymbol{x}_j) = \langle \phi(\boldsymbol{x}_i), \phi(\boldsymbol{x}_j) \rangle = \phi(\boldsymbol{x}_i)^{\mathrm{T}} \phi(\boldsymbol{x}_j)$$

- 成为核函数的条件

$$\mathbf{K} = \begin{bmatrix} \kappa(\boldsymbol{x}_1, \boldsymbol{x}_1) & \cdots & \kappa(\boldsymbol{x}_1, \boldsymbol{x}_j) & \cdots & \kappa(\boldsymbol{x}_1, \boldsymbol{x}_m) \\ \vdots & \ddots & \vdots & \ddots & \vdots \\ \kappa(\boldsymbol{x}_i, \boldsymbol{x}_1) & \cdots & \kappa(\boldsymbol{x}_i, \boldsymbol{x}_j) & \cdots & \kappa(\boldsymbol{x}_i, \boldsymbol{x}_m) \\ \vdots & \ddots & \vdots & \ddots & \vdots \\ \kappa(\boldsymbol{x}_m, \boldsymbol{x}_1) & \cdots & \kappa(\boldsymbol{x}_m, \boldsymbol{x}_j) & \cdots & \kappa(\boldsymbol{x}_m, \boldsymbol{x}_m) \end{bmatrix}$$

只要一个对称函数所对应的核矩阵半正定，它就能作为核函数使用.

- 再生核希尔伯特空间" *Reproducing Kernel Hilbert Space* (RKHS)

对于一个半正定核矩阵，总能找到一个与之对应的映射函数。

任何一个半正定核矩阵都隐式地定义了一个空间，称为"再生核希尔伯特空间"。

核支持向量机

- 核函数的选择

名称	表达式	参数
线性核	$\kappa(\boldsymbol{x}_i, \boldsymbol{x}_j) = \boldsymbol{x}_i^{\mathrm{T}} \boldsymbol{x}_j$	
多项式核	$\kappa(\boldsymbol{x}_i, \boldsymbol{x}_j) = \left(\boldsymbol{x}_i^{\mathrm{T}} \boldsymbol{x}_j\right)^d$	$d \geqslant 1$ 为多项式的次数
高斯核	$\kappa(\boldsymbol{x}_i, \boldsymbol{x}_j) = \exp\left(-\frac{\|\boldsymbol{x}_i - \boldsymbol{x}_j\|^2}{2\sigma^2}\right)$	$\sigma > 0$ 为高斯核的带宽(width)
拉普拉斯核	$\kappa(\boldsymbol{x}_i, \boldsymbol{x}_j) = \exp\left(-\frac{\|\boldsymbol{x}_i - \boldsymbol{x}_j\|}{\sigma}\right)$	$\sigma > 0$
Sigmoid 核	$\kappa(\boldsymbol{x}_i, \boldsymbol{x}_j) = \tanh\left(\beta \boldsymbol{x}_i^{\mathrm{T}} \boldsymbol{x}_j + \theta\right)$	tanh 为双曲正切函数, $\beta > 0, \theta < 0$

核函数的注意事项

- 核函数选择成为svm的最大变数
- 经验：文本数据使用线性核，情况不明使用高斯核
- 核函数的性质：
- 1 核函数的线性组合仍为核函数
- 2 核函数的直积仍为核函数

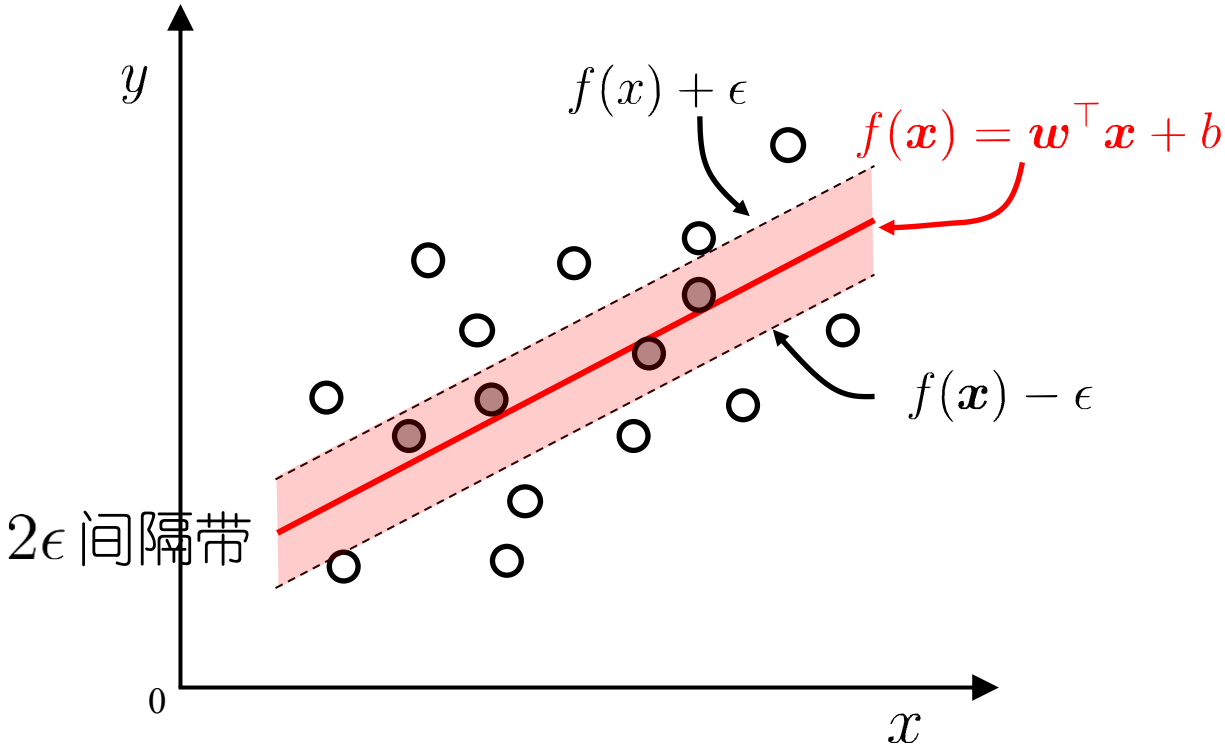
$$\kappa_1 \otimes \kappa_2 \left(x_1, x_1 \right) = \kappa_1 \left(x_1, x_2 \right) \kappa_2 \left(x_1, x_2 \right)$$

大纲

- 引言
- 线性可分支持向量机
- 软间隔支持向量机
- 核支持向量机
- **支持向量回归**

支持向量回归

特点: 允许模型输出和实际输出间存在2ϵ的偏差.



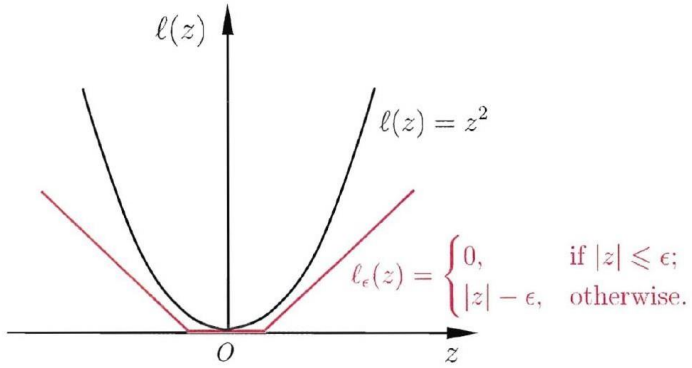
红色显示出 ϵ-间隔带, 落入其中的样本不计算损失

支持向量回归 Support Vector Regression

- ε不敏感损失

$$\min_{w,b} \frac{1}{2}\|w\|^2 + C\sum_{i=1}^{m} \ell_\epsilon(f(x_i) - y_i)$$

$$\ell_\epsilon(z) = \begin{cases} 0, & \text{if } |z| \leqslant \epsilon \\ |z| - \epsilon, & \text{otherwise} \end{cases}$$



$$\min_{w,b,\hat{\xi}_i,\xi_i} \frac{1}{2}\|w\|^2 + C\sum_{i=1}^{m} (\hat{\xi}_i + \xi_i)$$

$$\text{s.t. } f(x_i) - y_i \leqslant \epsilon + \hat{\xi}_i$$

$$y_i - f(x_i) \leqslant \epsilon + \xi_i$$

$$\hat{\xi}_i \geqslant 0, \xi_i \geqslant 0, i = 1,2,\ldots,m$$

