

矩阵微积分 (Matrix Calculus)

虽然前面几节中的主题通常都会在线性代数的标准课程中讲到，但有一个主题似乎不太常被系统介绍（而且我们后面会频繁用到），那就是将微积分推广到向量与矩阵的情形。尽管我们实际用到的微积分内容本身都相对简单，但其记号往往会让问题看起来比实际困难得多。本节将给出矩阵微积分的一些基本定义，并提供若干例子。

4.1 梯度 (The Gradient)

设 $f: \mathbb{R}^{m \times n} \rightarrow \mathbb{R}$ 是一个函数，它以一个大小为 $m \times n$ 的矩阵 A 为输入，并输出一个实数。那么， f 关于 $A \in \mathbb{R}^{m \times n}$ 的梯度 (gradient) 定义为由偏数组成的矩阵：

$$\nabla_A f(A) \in \mathbb{R}^{m \times n} = \begin{bmatrix} \frac{\partial f(A)}{\partial A_{11}} & \frac{\partial f(A)}{\partial A_{12}} & \cdots & \frac{\partial f(A)}{\partial A_{1n}} \\ \frac{\partial f(A)}{\partial A_{21}} & \frac{\partial f(A)}{\partial A_{22}} & \cdots & \frac{\partial f(A)}{\partial A_{2n}} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial f(A)}{\partial A_{m1}} & \frac{\partial f(A)}{\partial A_{m2}} & \cdots & \frac{\partial f(A)}{\partial A_{mn}} \end{bmatrix}.$$

也就是说，它是一个 $m \times n$ 的矩阵，并且其第 (i, j) 个元素满足

$$(\nabla_A f(A))_{ij} = \frac{\partial f(A)}{\partial A_{ij}}.$$

注意， $\nabla_A f(A)$ 的大小总是与 A 的大小相同。特别地，如果 A 只是一个向量 $x \in \mathbb{R}^n$ ，那么

$$\nabla_x f(x) = \begin{bmatrix} \frac{\partial f(x)}{\partial x_1} \\ \frac{\partial f(x)}{\partial x_2} \\ \vdots \\ \frac{\partial f(x)}{\partial x_n} \end{bmatrix}.$$

必须非常重要地记住：只有当函数是实值函数 (real-valued function)，也就是输出是一个标量时，梯度才有定义。比如，我们不能对 Ax （其中 $A \in \mathbb{R}^{n \times n}$ ）关于 x 求梯度，因为这个量是向量值而不是标量值。

由偏导数的基本性质可直接得到：

- $\nabla_x (f(x) + g(x)) = \nabla_x f(x) + \nabla_x g(x)$ 。
- 对任意 $t \in \mathbb{R}$ ，有 $\nabla_x (tf(x)) = t \nabla_x f(x)$ 。

原则上，梯度就是偏导数在多变量情形下的自然推广。但在实际操作中，由于记号问题，梯度有时会显得有些棘手。

例如，设 $A \in \mathbb{R}^{m \times n}$ 是一个固定系数矩阵， $b \in \mathbb{R}^m$ 是一个固定系数向量。令 $f: \mathbb{R}^m \rightarrow \mathbb{R}$ 定义为

$$f(z) = z^T z,$$

那么

$$\nabla_z f(z) = 2z.$$

现在考虑表达式

$$\nabla f(Ax).$$

这个表达式应该如何理解？至少有两种可能：

1. 第一种理解中，我们记得 $\nabla_z f(z) = 2z$ 。这里把 $\nabla f(Ax)$ 理解为：先对 f 关于变量 z 求梯度，再在点 Ax 处取值。因此，

$$\nabla f(Ax) = 2(Ax) = 2Ax \in \mathbb{R}^m.$$

2. 第二种理解中，我们把 $f(Ax)$ 看成输入变量 x 的函数。更正式地，定义

$$g(x) = f(Ax).$$

那么在这种理解下，

$$\nabla f(Ax) = \nabla_x g(x) \in \mathbb{R}^n.$$

可以看到，这两种理解确实不同：第一种得到的是一个 m 维向量，第二种得到的是一个 n 维向量。那么该如何消除这种歧义？

关键在于：必须明确指出我们是对哪个变量求导。

在第一种情况下，我们是先对函数 f 关于其自变量 z 求导，然后把 $z = Ax$ 代入；在第二种情况下，我们是直接对复合函数 $g(x) = f(Ax)$ 关于 x 求导。

因此，我们把第一种情况记作

$$\nabla_z f(Ax),$$

把第二种情况记作

$$\nabla_x f(Ax).$$

清楚地区分记号是极其重要的¹。

4.2 Hessian 矩阵 (The Hessian)

设 $f: \mathbb{R}^n \rightarrow \mathbb{R}$ 是一个函数，它以 $\mathbb{R}^n$ 中的向量为输入，并返回一个实数。那么，关于 x 的 Hessian 矩阵记作 $\nabla_x^2 f(x)$ ，或者简记为 H ，它是一个 $n \times n$ 的二阶偏导矩阵：

$$\nabla_x^2 f(x) \in \mathbb{R}^{n \times n} = \begin{bmatrix} \frac{\partial^2 f(x)}{\partial x_1^2} & \frac{\partial^2 f(x)}{\partial x_1 \partial x_2} & \cdots & \frac{\partial^2 f(x)}{\partial x_1 \partial x_n} \\ \frac{\partial^2 f(x)}{\partial x_2 \partial x_1} & \frac{\partial^2 f(x)}{\partial x_2^2} & \cdots & \frac{\partial^2 f(x)}{\partial x_2 \partial x_n} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial^2 f(x)}{\partial x_n \partial x_1} & \frac{\partial^2 f(x)}{\partial x_n \partial x_2} & \cdots & \frac{\partial^2 f(x)}{\partial x_n^2} \end{bmatrix}.$$

换句话说，

$$(\nabla_x^2 f(x))_{ij} = \frac{\partial^2 f(x)}{\partial x_i \partial x_j}.$$

注意，Hessian 总是对称矩阵，因为

$$\frac{\partial^2 f(x)}{\partial x_i \partial x_j} = \frac{\partial^2 f(x)}{\partial x_j \partial x_i}.$$

与梯度类似，只有当 $f(x)$ 是实值函数时，Hessian 才有定义。

我们很自然地会把梯度看成是一元函数中一阶导数的对应物，把 Hessian 看成是二阶导数的对应物（我们所用的记号本身也暗示了这种关系）。这种直觉大体上是对的，但仍有几点需要注意。

对于一元实值函数 $f: \mathbb{R} \rightarrow \mathbb{R}$ ，二阶导数被定义为一阶导数的导数，即

$$\frac{\partial^2 f(x)}{\partial x^2} = \frac{\partial}{\partial x} \left(\frac{\partial}{\partial x} f(x) \right).$$

¹这种记号也有一个不太方便的地方：在第一种写法 $\nabla_z f(Ax)$ 中，看起来像是在对一个根本没有出现在表达式里的变量 z 求导。正因如此，第一种情形常常简写成 $\nabla f(Ax)$ ，默认理解为“对 f 的输入变量求导”；而第二种情形则总是明确写成 $\nabla_x f(Ax)$ 。

然而，对于向量函数，自变量是向量时，函数的梯度本身是一个向量，而不能对一个向量整体再取梯度。也就是说，

$$\nabla_x \nabla_x f(x) = \nabla_x \begin{bmatrix} \frac{\partial f(x)}{\partial x_1} \\ \frac{\partial f(x)}{\partial x_2} \\ \vdots \\ \frac{\partial f(x)}{\partial x_n} \end{bmatrix}$$

这个表达式本身并没有定义。

因此，Hessian 不能简单地理解为“梯度的梯度”。不过，这种说法在某种意义上“几乎正确”。

事实上，如果我们取梯度的第 i 个分量

$$(\nabla_x f(x))_i = \frac{\partial f(x)}{\partial x_i},$$

然后再对这个标量函数关于 x 求梯度，就得到

$$\nabla_x \left(\frac{\partial f(x)}{\partial x_i} \right) = \begin{bmatrix} \frac{\partial^2 f(x)}{\partial x_i \partial x_1} \\ \frac{\partial^2 f(x)}{\partial x_i \partial x_2} \\ \vdots \\ \frac{\partial^2 f(x)}{\partial x_i \partial x_n} \end{bmatrix},$$

这正是 Hessian 的第 i 列（或由于对称性，也可看作第 i 行）。

因此，

$$\nabla_x^2 f(x) = [\nabla_x(\nabla_x f(x))_1 \quad \nabla_x(\nabla_x f(x))_2 \quad \cdots \quad \nabla_x(\nabla_x f(x))_n].$$

如果我们愿意在记号上稍微“马虎”一点，也可以写成

$$\nabla_x^2 f(x) \approx \nabla_x(\nabla_x f(x))^T,$$

但这里必须明白，这实际上表示的是：对 $(\nabla_x f(x))^T$ 的每一个分量分别求梯度，而不是把整个向量当成一个整体去求梯度。

最后，注意虽然我们可以对矩阵 A 求梯度，但在本课程中，我们只考虑对向量 $x \in \mathbb{R}^n$ 求 Hessian。这纯粹是为了方便（而且我们后续的计算也不需要矩阵求 Hessian），因为如果对矩阵求 Hessian，就必须表示所有形如

$$\frac{\partial^2 f(A)}{\partial A_{ij} \partial A_{k\ell}}$$

的二阶偏导，这样的对象用矩阵来表示会变得相当繁琐。

4.3 二次函数与线性函数的梯度和 Hessian

下面我们来求几个简单函数的梯度和 Hessian 矩阵。需要说明的是，这里给出的所有梯度公式，都是 CS229 讲义中更一般梯度公式的特殊情形。

对于 $x \in \mathbb{R}^n$ ，设

$$f(x) = b^T x,$$

其中 $b \in \mathbb{R}^n$ 是一个已知向量。则

$$f(x) = \sum_{i=1}^n b_i x_i,$$

所以

$$\frac{\partial f(x)}{\partial x_k} = \frac{\partial}{\partial x_k} \sum_{i=1}^n b_i x_i = b_k.$$

由此容易看出

$$\nabla_x(b^T x) = b.$$

这和一元微积分中的对应事实类似：

$$\frac{\partial}{\partial x}(ax) = a.$$

现在考虑二次函数

$$f(x) = x^T A x,$$

其中 $A \in S^n$ (即 A 是对称矩阵)。注意

$$f(x) = \sum_{i=1}^n \sum_{j=1}^n A_{ij} x_i x_j.$$

为了求偏导数，我们把包含 x_k 和 x_k^2 的项分开：

$$\begin{aligned} \frac{\partial f(x)}{\partial x_k} &= \frac{\partial}{\partial x_k} \sum_{i=1}^n \sum_{j=1}^n A_{ij} x_i x_j \\ &= \frac{\partial}{\partial x_k} \left[\sum_{i \neq k} \sum_{j \neq k} A_{ij} x_i x_j + \sum_{i \neq k} A_{ik} x_i x_k + \sum_{j \neq k} A_{kj} x_k x_j + A_{kk} x_k^2 \right] \\ &= \sum_{i \neq k} A_{ik} x_i + \sum_{j \neq k} A_{kj} x_j + 2A_{kk} x_k \\ &= \sum_{i=1}^n A_{ik} x_i + \sum_{j=1}^n A_{kj} x_j = 2 \sum_{i=1}^n A_{ki} x_i, \end{aligned}$$

最后一步用到了 A 的对称性。注意， $\nabla_x f(x)$ 的第 k 个分量就是 A 的第 k 行与 x 的内积。因此，

$$\nabla_x(x^T A x) = 2Ax \quad (\text{当 } A \text{ 对称时}).$$

这也对应于一元微积分中的事实：

$$\frac{\partial}{\partial x}(ax^2) = 2ax.$$

接下来求二次函数 $f(x) = x^T A x$ 的 Hessian (线性函数 $b^T x$ 的 Hessian 显然为零矩阵)。此时

$$\frac{\partial^2 f(x)}{\partial x_k \partial x_\ell} = \frac{\partial}{\partial x_k} \left(\frac{\partial f(x)}{\partial x_\ell} \right) = \frac{\partial}{\partial x_k} \left(2 \sum_{i=1}^n A_{\ell i} x_i \right) = 2A_{\ell k} = 2A_{k\ell}.$$

因此很明显，

$$\nabla_x^2(x^T A x) = 2A \quad (\text{当 } A \text{ 对称时}).$$

这同样完全符合我们的预期，并且与一元情形

$$\frac{\partial^2}{\partial x^2}(ax^2) = 2a$$

相对应。

综上所述：

- $\nabla_x(b^T x) = b$;
- $\nabla_x(x^T A x) = 2Ax$ (当 A 对称时);
- $\nabla_x^2(x^T A x) = 2A$ (当 A 对称时)。

4.4 最小二乘 (Least Squares)

现在利用上一节得到的公式来推导最小二乘方程。

设给定矩阵 $A \in \mathbb{R}^{m \times n}$ (为简单起见, 假设 A 满秩) 和向量 $b \in \mathbb{R}^m$, 并且假设

$$b \notin R(A),$$

即 b 不属于 A 的列空间。因此我们找不到 $x \in \mathbb{R}^n$ 使得

$$Ax = b.$$

于是, 我们转而希望找到一个向量 x , 使得 Ax 与 b 尽可能接近, 而这种接近程度用欧几里得范数的平方

$$\|Ax - b\|_2^2$$

来衡量。

由 $\|x\|_2^2 = x^T x$ 可知,

$$\|Ax - b\|_2^2 = (Ax - b)^T (Ax - b) = x^T A^T Ax - 2b^T Ax + b^T b.$$

对 x 求梯度, 并利用上一节的结论, 有

$$\begin{aligned} \nabla_x (x^T A^T Ax - 2b^T Ax + b^T b) &= \nabla_x (x^T A^T Ax) - \nabla_x (2b^T Ax) + \nabla_x (b^T b) \\ &= 2A^T Ax - 2A^T b. \end{aligned}$$

令这个梯度等于零, 并解出 x , 得到正规方程 (normal equations):

$$2A^T Ax - 2A^T b = 0$$

即

$$A^T Ax = A^T b.$$

若 $A^T A$ 可逆, 则

$$x = (A^T A)^{-1} A^T b.$$

这与我们在课堂上推导出的结果一致。

4.5 行列式的梯度 (Gradients of the Determinant)

下面考虑一个关于矩阵求梯度的例子。对于 $A \in \mathbb{R}^{n \times n}$, 我们希望求

$$\nabla_A |A|.$$

回忆行列式的展开式, 对于任意固定的 $j \in \{1, \dots, n\}$,

$$|A| = \sum_{i=1}^n (-1)^{i+j} A_{ij} |A_{\setminus i, \setminus j}|,$$

因此

$$\frac{\partial |A|}{\partial A_{k\ell}} = \frac{\partial}{\partial A_{k\ell}} \sum_{i=1}^n (-1)^{i+j} A_{ij} |A_{\setminus i, \setminus j}| = (-1)^{k+\ell} |A_{\setminus k, \setminus \ell}| = (\text{adj}(A))_{\ell k}.$$

由伴随矩阵 (adjoint) 的性质立刻得到

$$\nabla_A |A| = (\text{adj}(A))^T = |A| A^{-T}.$$

接着考虑函数

$$f: S_{++}^n \rightarrow \mathbb{R}, \quad f(A) = \log |A|.$$

注意, 这里必须把定义域限制在正定矩阵 (positive definite matrices) 上, 因为这样才能保证

$$|A| > 0,$$

从而 $\log |A|$ 是实数。

此时可使用链式法则 (chain rule):

$$\frac{\partial \log |A|}{\partial A_{ij}} = \frac{\partial \log |A|}{\partial |A|} \cdot \frac{\partial |A|}{\partial A_{ij}} = \frac{1}{|A|} \frac{\partial |A|}{\partial A_{ij}}.$$

因此,

$$\nabla_A \log |A| = \frac{1}{|A|} \nabla_A |A| = A^{-1},$$

最后一步中, 由于 A 是对称矩阵, 我们可以把转置略去。

这和一元情形非常相似:

$$\frac{\partial}{\partial x} \log x = \frac{1}{x}.$$

4.6 把特征值看成优化问题 (Eigenvalues as Optimization)

最后, 我们用矩阵微积分来求解一个优化问题, 而这个过程会直接导向特征值与特征向量分析。

考虑下面这个带等式约束的优化问题:

$$\max_{x \in \mathbb{R}^n} x^T A x \quad \text{subject to } \|x\|_2^2 = 1,$$

其中 $A \in S^n$ 是一个对称矩阵。

求解带等式约束优化问题的标准方法之一, 是构造拉格朗日函数 (Lagrangian), 即把等式约束并入目标函数中²。在这里, 拉格朗日函数可以写成

$$L(x, \lambda) = x^T A x - \lambda(x^T x - 1),$$

其中 λ 称为与该等式约束对应的拉格朗日乘子 (Lagrange multiplier)。

可以证明: 若 x^* 是该问题的一个最优点, 那么拉格朗日函数在 x^* 处关于 x 的梯度必须为零 (这并不是最优性的唯一条件, 但它是必要条件)。也就是说,

$$\nabla_x L(x, \lambda) = \nabla_x (x^T A x - \lambda x^T x) = 2A^T x - 2\lambda x = 0.$$

注意, 由于 A 对称, $A^T = A$, 于是这恰好就是线性方程

$$Ax = \lambda x.$$

这说明: 在约束 $x^T x = 1$ 下, 能够使 $x^T A x$ 取得极大值或极小值的点, 只可能是矩阵 A 的特征向量 (eigenvectors)。

²如果你此前没有接触过拉格朗日函数, 也不用担心; 我们会在 CS229 后面的内容中更详细地介绍它。