

凸优化问题算法整理

凸优化问题中，我们介绍了非常多的算法，但其实他们都以梯度为基础，从梯度下降法出发，为解决不通过的缺点和痛点，衍生出了很多不同的算法。

优化算法的核心要素有三个，向什么方向走（**下降方向**）、走多远（**步长**）、保留什么样的结构（**比如特定的约束、可行域等**）。迭代的核心公式就是：

$$x^{k+1} = x^k + \alpha_k d^k$$


不同的算法能够带来不同的效果，有的能够带来**精度**的提高（比如利用二阶梯度的算法，牛顿/拟牛顿法），有的是**效率高，收敛速度快**（动量加速/Nesterov加速），也有的算法能够减少**计算代价**（随机梯度、Minibatch等）。

了解一个算法，首先就要知道它的原理，比如公式，明白是基于什么思想、过程进行计算的；同时了解算法的效率，明白在不同问题情景下，算法可以达到怎样的收敛速度。

我们在衡量收敛速度的时候，也有多个不同的衡量维度，**梯度范数**是否下降、**函数值距离最优值**是否下降、**函数点离最优点的距离**是否下降。

其实我们不难发现，每次讲一个新算法的时候，我们总是先讲他的**公式、公式是怎么推的、能达到怎样的效果**，然后就进入了此恨绵绵无绝期的**收敛性分析**。所以这份整理差不多也会从这样的视角和过程切入。

手写思维导图，但貌似**有点太发散了**。



算法专题整理:

串起来一遍：

- GD 的收敛分析从 L -光滑的二次上界开始。代入 $x_{k+1} = x_k - \alpha \nabla f(x_k)$ 后，会出现一个一阶下降项和一个二阶误差项，步长条件 $0 < \alpha < 2/L$ 的本质就是保证下降项压过误差项。
- 在此基础上，如果只假设凸性，可以通过凸性和望远镜求和得到 $O(1/k)$ 的函数值收敛；如果进一步假设强凸，则梯度大小能反映距离最优的程度，从而得到每步误差乘固定比例的线性收敛。
- Nesterov 和 FISTA 在一阶方法上加入历史外推，不再单纯证明函数值单调下降，而是构造势能函数，最终把 $O(1/k)$ 提升到 $O(1/k^2)$ 。
- SGD 把全梯度换成随机梯度，下降项仍然存在，但多出噪声方差项，因此需要递减步长在后期压制噪声。
- Newton 和 BFGS 则改变搜索方向：Newton 使用真实 Hessian，BFGS 用历史梯度变化近似 Hessian；它们在远离最优点时依靠线搜索保证稳定，在靠近最优点时依靠曲率信息获得比 GD 更快的局部收敛。

先从梯度下降法出发：

沿负梯度方向下降。这是**函数值下降最快**的方向， $d^k = -\nabla f(x^k)$ ，于是有梯度下降的迭代公式就是： $x^{k+1} = x^k - \alpha_k \nabla f(x^k)$ 。

梯度下降法的收敛性很依赖**函数的具体性质**。

- 函数非凸，但是有下界时，梯度范数次线性收敛，并且意思是至少在前 k 步里，有某一步的梯度已经比较小了。
- 函数凸且具有 L -光滑性质时，次线性收敛。利用了 L -光滑函数的充分下降引理来证明， L -光滑性保证函数不会弯得过快，因此只要步长不超过 $1/L$ ，沿负梯度方向走一步一定有足够下降。
- 函数强凸，且具有 L -光滑性质时，取梯度下降步长为 $1/L$ ，线性收敛， $f(x^k) - f(x^*) \leq (1 - \frac{m}{M})^k (f(x^0) - f(x^*))$ 。

假设	衡量量	典型速度
L -光滑 + 下有界	$\min_{i \leq k} \ \nabla f(x^i)\ ^2$	$O(1/k)$ （次线性）
L -光滑 + 凸	$f(x^k) - f^*$	$O(1/k)$ （次线性）
L -光滑 + μ -强凸	$f(x^k) - f^*$ 或 $\ x^k - x^*\ ^2$	线性（指数）

速度上的优化：进入动量加速与Nesterov加速

梯度下降毕竟只看某一点的一阶最有方向，在病态图形里会zig-zag，所以我们引入两种记忆历史信息的算法，来加速寻找最优解的过程。

动量法：

这一步不只按照当前负梯度走，还顺着上一轮的位移方向再推一把。

$$x_{k+1} = x_k - \alpha \nabla f(x_k) + \beta(x_k - x_{k-1})$$

步长太小推进慢，步长太大可能振荡甚至发散；动量太小加速不明显，太大可能惯性过强越过谷底。在二次强凸问题中，动量加速的优势是二阶递推，收敛因子可以达到 $\rho_{HB} = \frac{\sqrt{L}-\sqrt{\mu}}{\sqrt{L}+\sqrt{\mu}}$ 。

Nesterov 加速：

先不急着想算梯度，而是**根据上一轮的运动方向**，预测一下**如果继续保持惯性**，会到达哪个位置。第二步才是**真正的梯度下降**。

$$x_{k+1}^{NAG} = \underbrace{x_k + \beta_k(x_k - x_{k-1})}_{\text{动量前推}} - \underbrace{\alpha \nabla f(x_k + \beta_k(x_k - x_{k-1}))}_{\text{在前瞻点算梯度}}$$

在光滑且凸的函数中，Nesterov 的收敛速度可以加速到 $O(1/k^2)$ 。

精度上的优化：进入牛顿法与拟牛顿法

牛顿法：

梯度下降的核心思想是沿着负梯度方向走，但是病态函数里这样会导致无头乱撞，其实还是zig-zag的问题，为了走得更精确，我们利用更详细的信息，也就是二阶信息，在向量世界里，就是海森矩阵。标准牛顿方向为：

$$d_k = -G_k^{-1} g_k$$

牛顿法的原理就是，用一个二次凸函数来近似原函数，是一种局部近似。知道了原理后我们就能发现特殊情况了，如果原函数本身就是个二次凸函数，那么牛顿法其实就直接把本身复现出来了，所以标准牛顿法在严格凸二次函数上一步就可以走到最优解。

牛顿法也不一定能保证下降，当该点的海森矩阵正定时，才保证下降方向。

- 标准牛顿法的步长也很简单，直接用全步长，所以标准牛顿法的迭代公式就是： $x^{k+1} = x^k + d_k$
- 阻尼牛顿法在标准牛顿法的基础上，对步长进行调整，一般采用 Armijo 原则
- 修正牛顿法解决方向可能不下降问题，对于特征值有负的情况，直接加单位矩阵上去补到正定，舍曲率保下降
- 信赖域限定范围，只在可信半径内求解二次模型

足够靠近最优点时，能够达到**二次收敛**， $\|x^{k+1} - x^*\| \leq C \|x^k - x^*\|^2$ 。

设 $e_k = \|x^k - x^*\|$ 。常见收敛速度可用误差序列描述：

类型	典型形式
线性收敛	$e_{k+1} \leq qe_k, \quad 0 < q < 1$
超线性收敛	$\frac{e_{k+1}}{e_k} \rightarrow 0$
二次收敛	$e_{k+1} \leq Ce_k^2$

Newton 法的局部二次收敛意味着：当 e_k 已经较小时，误差会以近似“平方”的速度下降。

梯度下降法计算代价小，但是速度慢，牛顿法计算代价大，但是在离最优点比较近的时候是二次收敛，找到最优解的速度非常快！

拟牛顿法：

不直接计算 Hessian 矩阵，却尽量获得类似牛顿法的曲率信息。拟牛顿法改为构造**近似矩阵** B_k 或 H_k ，**分别近似 Hessian 和逆 Hessian**，即 $B_k \approx \nabla^2 f(x_k)$ ， $H_k \approx [\nabla^2 f(x_k)]^{-1}$ 。

从第 k 步走到第 $k + 1$ 步，定义：

$$s_k = x_{k+1} - x_k, \quad y_k = \nabla f(x_{k+1}) - \nabla f(x_k).$$

拟牛顿法其实就是在用位置变化和梯度变化来近似估计局部曲率，有 $B_{k+1}s_k = y_k$ ，更新逆近似矩阵 $H_{k+1}y_k = s_k$ 。

拟牛顿法一般会从初始矩阵 $H_0 = I$ 开始。这样简单、稳定，而且不需要额外估计初始 Hessian 信息。此时第一步搜索方向为 $d_0 = -H_0g_0 = -g_0$ ，也就是说，**拟牛顿法的第一步退化成普通负梯度方向**。

BFGS 是拟牛顿法中最常用的一种完整矩阵更新方式，

$$H_{k+1} = (I - \rho_k s_k y_k^T) H_k (I - \rho_k y_k s_k^T) + \rho_k s_k s_k^T, \text{ 其中 } \rho_k = \frac{1}{y_k^T s_k}$$

这个操作能保证正定性，确保每一步都是下降方向。它相比 Newton 降低了代价，因为不需要显式计算 Hessian，也不需要解 Newton 线性方程组；但它仍然需要保存和更新一个 $n \times n$ 的逆 Hessian 近似矩阵，因此对超大规模问题仍然偏贵。

于是我们又提出 **L-BFGS** 来优化 **BFGS**，只保留最近 m 组移动信息。L-BFGS 的全称是 **Limited-memory BFGS**，即“有限记忆 BFGS”。**BFGS 需要完整保存 H_k ，而 L-BFGS 不保存 H_k** 。它只保存最近 m 组历史信息：

$$(s_{k-m}, y_{k-m}), \dots, (s_{k-1}, y_{k-1})$$

第一轮按时间倒序撤销最近几次曲率影响，第二轮按时间正序把曲率信息加回来，整个过程只用向量内积和向量加减，不需要形成 $n \times n$ 矩阵。

结构不良上的优化：约束优化 + 投影梯度法 + 近端梯度法 + FISTA

约束优化&投影梯度法：

无约束问题中的普通梯度下降，我们只需要找到最速下降路径，让函数值变小就行了。然而这种方法，默认 x^{k+1} 可以落在任意位置，一旦有了约束，那么就有可能出现**跑出可行域**的情况。迭代公式为： $x^{k+1} = \Pi_C(x^k - \alpha \nabla f(x^k))$ 。

所以我们使用投影梯度法，把迭代后跑出可行域的点投影回可行域，并尽量少地改动。先做**无约束梯度步**，找到**临时点** z^{k+1} ，再用**临时点投影**得到 x^{k+1} ，投影操作如下：

$$\Pi_C(z) = \arg \min_{x \in C} \frac{1}{2} |x - z|^2$$

• 盒约束投影：

情况	投影结果
$z_i < l_i$	拉到下界： $[\Pi_C(z)]_i = l_i$
$l_i \leq z_i \leq u_i$	本来合法，不变： $[\Pi_C(z)]_i = z_i$
$z_i > u_i$	拉到上界： $[\Pi_C(z)]_i = u_i$

• 球约束投影：

情况	投影结果	含义
$ z \leq R$	$\Pi_C(z) = z$	点已经在球内，不用动
$ z > R$	$\Pi_C(z) = R \frac{z}{ z }$	点在球外，沿原方向缩短到半径 R

- **单纯性约束投影：** $\Pi_{\Delta_n}(z) = \arg \min_{x_i \geq 0, \sum_i x_i = 1} \frac{1}{2} \|x - z\|^2$ ，具有解 $x_i = \max\{z_i - \tau, 0\}$ ，先把所有 z_i 整体减去同一个数 τ ，然后把变成负数的分量截成 0，最后保证所有分量加起来刚好等于 1。

投影梯度里**最优性条件**为 $x^* = \Pi_C(x^* - \alpha \nabla f(x^*))$ ，即如果某个点 x^* 已经是稳定点，那么从它出发，先沿负梯度方向走一步，再投影回来，应该还是它自己。

无约束时的停止准则，我们利用 $G_\alpha(x) = \frac{1}{\alpha} (x - \Pi_C(x - \alpha \nabla f(x)))$ ，在 $\|G_\alpha(x^k)\| \leq \varepsilon$ 时停下。无约束时，就退化回了 $\nabla f(x) \leq \varepsilon$ ，即无约束梯度下降的停止准则，说明**投影梯度映射其实是无约束梯度的推广**。

投影梯度法是带有可行性修正的梯度下降法，真正推动收敛的是每一步的梯度迭代，投影只是可行性修正，所以**投影梯度法的收敛速度与梯度下降法保持同一量级**。（回忆不同情景， L —光滑 + 凸、 L —光滑 + 有下届、 L —光滑 + 强凸...

近端梯度法 + FISTA:

近端梯度法解决的是式子中有不可导项时遇到的问题，我们将式子拆为两个部分，一部分是可求导的，另一份是不便求导的结构项，利用可求导部分做梯度下降步，再用结构项做近端修正，近端算子的公式就是：

$$\text{prox}_{\alpha g}(z) = \arg \min_x \left\{ g(x) + \frac{1}{2\alpha} \|x - z\|^2 \right\}$$

整个近端梯度法的流程是 $x^k \rightarrow z^k = x^k - \alpha \nabla f(x) \rightarrow x^{k+1} = \text{prox}_{\alpha g}(z^k)$ 。利用 $G_\alpha(x) = \frac{1}{\alpha} [x - \text{prox}_{\alpha g}(x - \alpha \nabla f(x))]$ 作为停止准则。一般取步长 $\alpha \leq \frac{1}{L}$ ，收敛速度与梯度下降法保持同一量级。

近端梯度法有三种比较典型的情景：

- 软阈值：结构项为不可导的 ℓ_1 正则项时，小的系数直接压为0，大的系数向 x 轴收缩，带来变量的稀疏性。公式为 $S_\tau(z) = \text{sign}(z) \max\{|z| - \tau, 0\}$ ，记 $\tau = \alpha\lambda$

- 平方缩放：结构项是二范数平方项，也就是说近端算子为这个公式：

$$\text{prox}_{\alpha g}(z) = \arg \min_x \left\{ \frac{\lambda}{2} \|x\|_2^2 + \frac{1}{2\alpha} \|x - z\|^2 \right\}$$

近端算子此时是可导的，所以我们直接求导，最后整理为 $(1 + \alpha\lambda)x = z$ ，所以 $x^* = \frac{1}{1 + \alpha\lambda} z$ ，整个向量按同一个比例缩小。

- 约束指示函数（投影）：比如非负约束、盒约束、球约束等，这些我们在投影梯度法的时候详细说过了，投影梯度法本质上是近端梯度法的一种特殊情形。此时近端算子是 $\text{prox}_{\alpha \delta_C}(z) = \Pi_C(z)$

$g(x)$ 类型	prox 做什么	结构效果
$\lambda x _1$	逐坐标软阈值	稀疏性
$\frac{\lambda}{2} x _2^2$	整体按比例缩小	系数变小，不清零
$\delta_{\{x \geq 0\}}(x)$	负数截成 0	非负约束
$\delta_{[l,u]}(x)$	截断到区间 $[l, u]$	盒约束
$\lambda x _2$	向量整体软阈值	整体收缩/组选择
$\lambda \sum_G x_G _2$	每组整体软阈值	Group Lasso
$\delta_C(x)$	投影到 C	一般约束
$\lambda X _*$	对奇异值软阈值	低秩矩阵

FISTA 是近端梯度版的 Nesterov，在近端梯度法的基础上利用历史信息对其进行加速。具体操作就是先利用历史信息生成一个外推点，在这个外推点的基础上再进行梯度下降步和近端修正。现有 $y^k = x^k +$

$\beta_k(x^k - x^{k-1})$, 再有 $x^{k+1} = \text{prox}_{\alpha g}(y^k - \alpha \nabla f(y^k))$, FISTA 理论上收敛速度能够达到 $O(1/k^2)$, 更快, 但也更容易会振荡。

计算效率上的优化: SGD与Mini-batch

随机梯度法 SGD:

普通梯度下降法, 每一次要计算全量样本的梯度找平均梯度, 虽然从准确性上很理想, 但是计算量非常大, 所以我们使用 SGD 改善这个问题。SGD 就是随机抽取一个样本, 用该样本的梯度近似完整梯度, 作为下降方向:

$$w^{k+1} = w^k - \alpha_k \nabla f_{i_k}(w^k)$$

优点是单步代价极低, 因为每次只需要计算一个样本的梯度; 缺点是方向噪声很大, 因为一个样本并不能完全代表整体数据分布。可能会产生振荡。但是随机梯度是真是梯度的无偏估计, 同时产生的噪声的期望是 0, 这就是随机梯度法尽管在局部上有振荡, 但在总体上能下降的原因。

在凸、光滑、随机梯度方差有界并且使用递减步长的情况下, SGD 收敛速率可以达到 $O\left(\frac{1}{\sqrt{k}}\right)$, 因为噪声项会以 α_k^2 的形式出现, 递减步长可以压住噪声。

Mini-batch:

每次取一批样本, 利用这一批样本的平均梯度近似完整梯度, 作为下降方向, 是SGD和完整GD的折中方法:

$$g_{B_k}(w) = \frac{1}{|B_k|} \sum_{i \in B_k} \nabla f_i(w)$$

$$w^{k+1} = w^k - \alpha_k \left(\frac{1}{|B_k|} \sum_{i \in B_k} \nabla f_i(w^k) \right)$$

其他修正方法:

动量加速和 Nesterov 加速能够减少振荡, 减少 zig-zag, 让训练轨迹更加平滑, 动量能够把多次梯度做平滑平均, 来回摆动的噪声方向会被部分抵消; Nesterov 发挥提前纠偏的思想, 先按惯性预判会到哪里, 再在那个点做梯度步。

除了振荡, 不同坐标梯度尺度相差过大也是优化算法的一大难题, 利用下面三种方法处理尺度差异, 首先他们有自适应步长的共同模板:

$$w_j^{k+1} := w_j^k - \alpha_k \frac{q_{k,j}}{s_{k,j} + \epsilon}, \quad j = 1, \dots, p.$$

$q_{k,j}$ 表示当前或平滑后的第 j 个梯度分量, $s_{k,j}$ 表示该坐标的梯度尺度估计; 这是一条坐标公式, 不是“向量整体相除”。

- **AdaGrad**: 用全部历史平方梯度估计尺度; 按坐标缩放步长, 记录每个坐标的历史梯度平方和, 但是由于 r_k 单调递增, 所以训练很久后步长可能变得很小。(PPT的69页)
- **RMSProp**: 只用近期平方梯度估计尺度; $r_k = \rho r_{k-1} + (1 - \rho)(g_k \odot g_k), 0 < \rho < 1$, r_k 是近期梯度平方的指数移动平均。
- **Adam**: 方向也平滑, 尺度也自适应; 同时利用一阶矩和二阶矩, 相当于动量 + 自适应步长, 把 Momentum 和 RMSProp 合在一起: 一条线负责“方向”, 一条线负责“尺度”。

$$m_k = \beta_1 m_{k-1} + (1 - \beta_1) g_k, \quad v_k = \beta_2 v_{k-1} + (1 - \beta_2)(g_k \odot g_k).$$

偏差修正: $\hat{m}_k = \frac{m_k}{1 - \beta_1^k}$, $\hat{v}_k = \frac{v_k}{1 - \beta_2^k}$. 第 j 个坐标更新为:

$$w_j^{k+1} = w_j^k - \alpha_k \frac{\hat{m}_{k,j}}{\sqrt{\hat{v}_{k,j} + \epsilon}}, \quad j = 1, \dots, p.$$

其中, $\hat{m}_k$ 控制更新方向, $\sqrt{\hat{v}_k} + \epsilon$ 控制每个坐标的自适应尺度; 平方根、加 ϵ 和除法均为逐坐标计算。分子给出平滑方向, 分母给出自适应尺度。

不同场景下不同算法的选择:

场景	常见选择	选择理由
小规模、光滑、要求高精度	Newton、BFGS、L-BFGS	可利用曲率或近似曲率
大规模凸问题或线性模型	SGD、Mini-batch、AdaGrad	单步便宜, 适合样本很多
深度网络初期训练	Adam、AdamW、RMSProp	启动快, 对尺度较鲁棒
追求最终泛化	SGD + momentum	常配合学习率衰减精细训练
稀疏特征、embedding	AdaGrad、Adam、AdamW	坐标级步长更友好

步长与收敛性分析专题:

收敛性分析就是证明每一步的“下降收益”足够大, 而步长的作用就是控制“曲率误差、外推风险、随机噪声、模型失真和曲率更新风险”, 使这些坏项不至于压过下降收益。

分支	进展量	核心假设	步长的作用	典型结论
GD	$f(x_k)$	L -光滑	让一阶压过二阶误差	函数值下降
凸 GD	$f(x_k) - f^*$	L -光滑 + 凸	保证可累积下降	$O(1/k)$
强凸 GD	$f(x_k) - f^*$	L -光滑 + μ -强凸	控制收敛因子	线性收敛
Nesterov	势能函数	光滑凸	控制外推稳定性	$O(1/k^2)$
FISTA	复合目标误差	f 光滑凸, g 可 prox	控制梯度步和 prox 稳定	$O(1/k^2)$
SGD	期望误差 / 平均梯度范数	随机梯度无偏、方差受控	控制噪声项	期望意义收
Newton	函数值 / 点误差	Hessian 正定、局部光滑	远处保下降, 近处取全步	局部二次收
BFGS	函数值 / 曲率近似	光滑、曲率条件	保下降与正定更新	实践快, 局部陡

1. 母版：GD 的一步下降不等式

- L -光滑二次上界

若 f 是 L -光滑函数, 则有: $f(y) \leq f(x) + \nabla f(x)^T(y - x) + \frac{L}{2}\|y - x\|^2$

理解: 真实函数值 $\leq$ 一阶线性预测 + 二阶曲率误差

- 步长条件 $0 < \alpha < 2/L$

代入 L -光滑下降引理: $f(x_{k+1}) \leq f(x_k) + \nabla f(x_k)^T(x_{k+1} - x_k) + \frac{L}{2}\|x_{k+1} - x_k\|^2$, 分别计算两项:

$$\nabla f(x_k)^T(x_{k+1} - x_k) = -\alpha\|\nabla f(x_k)\|^2$$

$$\frac{L}{2}\|x_{k+1} - x_k\|^2 = \frac{L\alpha^2}{2}\|\nabla f(x_k)\|^2$$

所以: $f(x_{k+1}) \leq f(x_k) - \left(\alpha - \frac{L\alpha^2}{2}\right)\|\nabla f(x_k)\|^2$, 为了保证下降就要有 $0 < \alpha < 2/L$

2. 凸 GD: 为什么是 $O(1/k)$

- 加入凸性

凸性的关键不等式是: $f(x_k) - f(x^*) \leq \nabla f(x_k)^T(x_k - x^*)$ 含义: 对凸函数来说, 当前梯度方向能反映当前点离最优值还差多少。

- 函数值误差作为衡量量

GD 更新: $x_{k+1} = x_k - \alpha \nabla f(x_k)$, 分析点到最优解的距离:

$$\|x_{k+1} - x^*\|^2 = \|x_k - \alpha \nabla f(x_k) - x^*\|^2$$

展开: $\|x_{k+1} - x^*\|^2 = \|x_k - x^*\|^2 - 2\alpha \nabla f(x_k)^T (x_k - x^*) + \alpha^2 \|\nabla f(x_k)\|^2$

由凸性: $\nabla f(x_k)^T (x_k - x^*) \geq f(x_k) - f^*$, 所以可以把“梯度方向项”转化成“函数值误差”。再结合 L -光滑带来的下降控制, 最终得到典型结论:

$$f(x_k) - f^* \leq \frac{\|x_0 - x^*\|^2}{2\alpha k}$$

当 $\alpha = 1/L$ 时: $f(x_k) - f^* \leq \frac{L\|x_0 - x^*\|^2}{2k}$ 。因此:

$$f(x_k) - f^* = O\left(\frac{1}{k}\right)$$

3. 强凸 GD: 为什么是线性收敛

- 加入 μ -强凸

建立: $\|\nabla f(x_k)\|^2 \geq 2\mu(f(x_k) - f^*)$, 含义: 如果当前函数值离最优值还很远, 那么梯度不可能太小。

- 梯度范数控制函数值误差

取固定步长: $\alpha = \frac{1}{L}$, 由 GD 一步下降不等式:

$$f(x_{k+1}) \leq f(x_k) - \frac{1}{2L} \|\nabla f(x_k)\|^2$$

再用强凸给出的梯度下界: $\|\nabla f(x_k)\|^2 \geq 2\mu(f(x_k) - f^*)$, 代入得:

$$f(x_{k+1}) \leq f(x_k) - \frac{\mu}{L} (f(x_k) - f^*)$$

两边减去 f^* , 记: $\Delta_k = f(x_k) - f^*$, 得到:

$$\Delta_{k+1} \leq \left(1 - \frac{\mu}{L}\right) \Delta_k$$

递推可得: $f(x_k) - f^* \leq (1 - \frac{\mu}{L})^k (f(x_0) - f^*)$

1. 加速法: Nesterov / FISTA 的 $O(1/k^2)$

- 外推点

先构造前瞻点: $y_k = x_k + \beta_k(x_k - x_{k-1})$, 再从 y_k 做梯度下降: $x_{k+1} = y_k - \alpha \nabla f(y_k)$

- 不保证每步函数值单调

Nesterov 的证明和 GD 不一样。GD 通常证明: $f(x_{k+1}) \leq f(x_k)$, 即函数值单调下降。但 Nesterov/FISTA 有外推项, 函数值不一定每步单调下降, 所以不能只盯着 $f(x_k)$ 。它的证明思路是构造一个“势能函数”:

势能函数 = 函数值误差 + 距离项 / 动量项

然后证明: 势能_{k+1} ≤ 势能_k, 最终推出: $f(x_k) - f^* = O(\frac{1}{k^2})$

- 用势能函数证明加速

我发现证明太复杂了我看不懂...要不把结论记住就行了

2. 随机法: SGD 的噪声与递减步长

- 随机梯度无偏

$$\mathbb{E}[g_k] = \nabla f(w_k)$$

- 多出方差项

若 f 是 L -光滑函数, 则: $f(y) \leq f(x) + \nabla f(x)^T(y - x) + \frac{L}{2}\|y - x\|^2$, 令: $y = x_{k+1} = x_k - \alpha_k g_k$, 代入得:

$$f(x_{k+1}) \leq f(x_k) + \nabla f(x_k)^T(x_{k+1} - x_k) + \frac{L}{2}\|x_{k+1} - x_k\|^2$$

又因为: $x_{k+1} - x_k = -\alpha_k g_k$, 所以:

$$f(x_{k+1}) \leq f(x_k) - \alpha_k \nabla f(x_k)^T g_k + \frac{L\alpha_k^2}{2}\|g_k\|^2$$

对上式在给定 x_k 的条件下取期望:

$$\mathbb{E}[f(x_{k+1}) | x_k] \leq f(x_k) - \alpha_k \mathbb{E}[\nabla f(x_k)^T g_k | x_k] + \frac{L\alpha_k^2}{2} \mathbb{E}[\|g_k\|^2 | x_k]$$

第一项: $\mathbb{E}[\nabla f(x_k)^T g_k | x_k] = \nabla f(x_k)^T \mathbb{E}[g_k | x_k]$, 由无偏性: $\mathbb{E}[g_k | x_k] = \nabla f(x_k)$, 所以:
 $\mathbb{E}[\nabla f(x_k)^T g_k | x_k] = \|\nabla f(x_k)\|^2$, 因此:

$$\mathbb{E}[f(x_{k+1}) | x_k] \leq f(x_k) - \alpha_k \|\nabla f(x_k)\|^2 + \frac{L\alpha_k^2}{2} \mathbb{E}[\|g_k\|^2 | x_k]$$

$$\mathbb{E}[\|g_k\|^2 | x_k] \leq \|\nabla f(x_k)\|^2 + \sigma^2$$

$$\text{代回去: } \mathbb{E}[f(x_{k+1}) | x_k] \leq f(x_k) - \alpha_k \|\nabla f(x_k)\|^2 + \frac{L\alpha_k^2}{2} (\|\nabla f(x_k)\|^2 + \sigma^2)$$

$$\text{整理可得: } \mathbb{E}[f(x_{k+1}) | x_k] \leq f(x_k) - \alpha_k \left(1 - \frac{L\alpha_k}{2}\right) \|\nabla f(x_k)\|^2 + \frac{L\alpha_k^2 \sigma^2}{2}$$

- **递减步长压制后期噪声**

递减步长让一阶发散, 二阶收敛, 所以保证下降, 若 f 是 L -光滑、下有界, 随机梯度无偏且方差有界, 则 SGD 常见结论是:

$$\min_{0 \leq k \leq T-1} \mathbb{E} \|\nabla f(x_k)\|^2 = O\left(\frac{1}{\sqrt{T}}\right)$$

所以要让: $\mathbb{E} \|\nabla f(x_k)\|^2 \leq \varepsilon$, 大约需要: $T = O\left(\frac{1}{\varepsilon^2}\right)$, 如果函数进一步, 还是强凸的, 那么可以达到 $O(1/T)$, 但是还是无法像梯度下降那样能达到线性收敛。固定步长的SGD只能收敛到噪声邻域。

3. 二阶法: Newton / BFGS 的线搜索与局部收敛

- **Newton 方向来自二阶模型**

明确说: Newton 利用 Hessian 曲率信息, 标准牛顿法在最优点附近很快, 但远离最优点时不一定稳定。Newton 问“当前局部二次模型的最低点在哪里”。

- **远处用线搜索/Armijo保下降**

标准 Newton 用全步长: $x_{k+1} = x_k + d_k$, 也就是: $\alpha_k = 1$ 。但二阶模型只在当前点附近可靠。远离最优点时, 直接走完整 Newton 步可能导致函数值上升。所以阻尼 Newton 改成: $x_{k+1} = x_k + \alpha_k d_k, 0 < \alpha_k \leq 1$ 。尝试用精确线搜索或Armijo规则选择步长。

- **近处 Newton 二次收敛**

若满足： $\nabla f(x^*) = 0, \nabla^2 f(x^*) \succ 0$ ，且 Hessian 在 x^* 附近 Lipschitz 连续，并且 x_0 足够接近 x^* ，则标准 Newton 法满足：

$$\|x_{k+1} - x^*\| \leq C \|x_k - x^*\|^2$$

Newton 快，是因为在最优点附近，函数越来越像二次函数，而 Newton 对二次函数可以一步到最优。

- **BFGS 用线搜索保证曲率条件和正定性**

在适当光滑性条件、强凸邻域条件和合适线搜索下，BFGS 可以达到**局部超线性收敛**：

$$\frac{\|x_{k+1} - x^*\|}{\|x_k - x^*\|} \rightarrow 0$$

它比线性收敛快，但通常不写成 Newton 那种严格二次形式。

步长选择方法总结：

四类步长策略分别为：**常数步长**、**精确线搜索**、**Armijo 回溯线搜索**、**递减步长**。这四种方法分别服务于不同场景：理论分析、单步最优、稳健下降、随机噪声控制。

梯度类算法通常写成 $x_{k+1} = x_k + \alpha_k d_k$ ，其中 d_k 是搜索方向， α_k 是步长。步长选择本质上是在回答：**方向已经确定后，这一步到底走多远？**

1. 常数步长

常数步长指每一步都取同一个步长： $\alpha_k \equiv \alpha$ 。若 f 是 L -光滑函数，**理论上常取 $\alpha \leq 1/L$ ，尤其常用 $\alpha = 1/L$ 。**

常数步长的优点是实现最简单、理论分析清楚，适合课堂证明和标准收敛性分析；缺点是需要知道或估计 L ，若 α 太小则下降慢，若 α 太大则可能振荡甚至发散。重点是**知道 L ，就取 $\alpha \leq 1/L$ 。**

2. 精确线搜索

精确线搜索是在给定方向 d_k 后，沿这条直线找最优步长： $\alpha_k \in \arg \min_{\alpha \geq 0} f(x_k + \alpha d_k)$ 。若 $d_k = -\nabla f(x_k)$ ，则为 $\alpha_k \in \arg \min_{\alpha \geq 0} f(x_k - \alpha \nabla f(x_k))$ 。

它的思想是：方向已定，只在这条线上寻找函数值最小的位置。优点是当前方向上单步效果最好，在二次函数中常能推出闭式解；缺点是每一步都要解一维优化问题，一般函数中计算代价较高，而且单步最优不

等于整体最快。

记忆句：精确线搜索追求“这一条线上的最优步长”，但每步求得太过精细，实际成本可能高。

3. Armijo 回溯线搜索

Armijo 只要求“足够下降”。一般形式为：

$$f(x_k + \alpha d_k) \leq f(x_k) + c\alpha \nabla f(x_k)^T d_k, \quad 0 < c < 1.$$

若 $d_k = -\nabla f(x_k)$ ，则变为：

$$f(x_k - \alpha \nabla f(x_k)) \leq f(x_k) - c\alpha \|\nabla f(x_k)\|^2.$$

操作流程：先取较大的初始步长，如 $\alpha = 1$ ；检查 Armijo 条件；若不满足，则令 $\alpha \leftarrow \beta\alpha$ ，其中 $0 < \beta < 1$ ；**重复回溯，直到满足充分下降。**

Armijo 的直觉是：这一步下降得要配得上当前步长，不能走了很远却几乎没降。它的优点是不需要提前知道 L ，能自动避免步长过大，常用于 Newton、BFGS 等**方向复杂的方法**；缺点是每一步可能多次计算函数值，并且需要设置参数 c, β 。

记忆句：Armijo 是稳健型步长：不求最优，只求足够下降；不够下降就缩步。

4. 递减步长

递减步长指步长随迭代逐渐变小，常见形式为 $\alpha_k = \alpha_0 / (k + 1)^p$ ， $0 < p \leq 1$ ，例如 $\alpha_k = \alpha_0 / (k + 1)$ 或 $\alpha_k = \alpha_0 / \sqrt{k + 1}$ 。

它的直觉是：**前期步长大，快速下降；后期步长小，减少振荡和噪声**。递减步长常用于 SGD、Mini-batch SGD、随机优化、非光滑优化和噪声较大的问题。

在 SGD 中，常见理论条件是 $\sum_{k=0}^{\infty} \alpha_k = \infty$ 且 $\sum_{k=0}^{\infty} \alpha_k^2 < \infty$ 。前者保证总步长足够大，不会太早停住；后者保证噪声平方项累计有限。

递减步长的优点是适合有噪声的随机梯度，后期更稳定，理论上能压制随机扰动；缺点是后期可能太小，几乎学不动，并且 α_0, p 需要调参。

记忆句：递减步长是为噪声场景服务的：**前期敢走，后期收敛时逐渐刹车。**

5. 横向比较

方法	核心理念	典型场景
常数步长	每步固定 α	GD 理论分析
精确线搜索	当前方向上找最优 α_k	二次函数、理论演示
Armijo 回溯	不求最优，只求足够下降	Newton、BFGS、一般优化
递减步长	步长逐渐变小	SGD、Mini-batch

算法与步长选择映射表：

算法	常见步长选择	核心理解
梯度下降 GD	常数步长 $\alpha \leq 1/L$ ；也可 Armijo	GD 的步长直接决定降、振或散；理论分析最常用常数步长。
最速下降法 Steepest Descent	精确线搜索较常见	“方向取负梯度，步长沿该方向最优”
Momentum / Heavy-ball	常数步长 + 固定动量系数 β	调 α, β ： α 控制当前梯度步， β 控制历史惯性。
Nesterov 加速 NAG	常数步长，常取 $\alpha = 1/L$ ；外推参数按理论设定	Nesterov 理论加速依赖特定外推参数，步长通常由 L -光滑控制。
投影梯度 PGD	常数步长 $\alpha \leq 1/L$ ；也可回溯	步长控制投影前临时点走多远。
近端梯度 Prox-GD / ISTA	常数步长 $\alpha \leq 1/L$ ；也可回溯	步长既控制光滑项梯度步，也影响结构修正强度。
FISTA	常数步长 $\alpha \leq 1/L$ ；外推参数按理论设定	Prox-GD + Nesterov 外推；步长主要由光滑项 f 的 L 控制。
SGD	递减步长；或固定学习率 + 调度	有噪声，递减步长压制噪声；固定步长只能到噪声邻域。
Mini-batch SGD	固定学习率 + 学习率调度；或递减步长	batch 降低噪声，步长控制随机波动；
Momentum SGD	固定学习率 / 调度 + 动量系数	本质是 SGD 加动量，既控制噪声，又控制惯性 overshoot。
Adam / RMSProp	自适应学习率 + 全局 learning rate；常配合调度	Adam 按坐标缩放梯度，仍需要全局学习率控制整体步幅。
标准 Newton	默认全步长 $\alpha = 1$	近最优全步长很好，发挥局部二次收敛；远离最优点不稳定。
阻尼 Newton	Armijo 回溯线搜索	步长远离最优点保稳定；近最优点后接受 $\alpha = 1$ 。
修正 Newton	Armijo 回溯线搜索	先修 Hessian 保证下降，再用线搜索保证函数值充分下降。
BFGS	Wolfe / Armijo 类非精确线搜索	步长不仅要保证下降，还保曲率条件 $y_k^T s_k > 0$ ，保近似正定。
L-BFGS	Wolfe / Armijo 类非精确线搜索	方向由有限历史曲率信息给出，步长仍靠线搜索稳住。