

凸问题对偶理论

[第六章_凸问题对偶理论.pdf](#)

对偶理论即：给一个原优化问题，另外配一个“对偶问题”；这个对偶问题不一定更容易直接看懂，但它特别擅长给原问题提供下界、判断最优、分析约束变化的影响。

本章主线：

原问题↓

→ 构造拉格朗日函数

→ 对 x 取下确界，得到对偶函数

→ 最大化这个对偶函数，得到对偶问题

→ 研究原问题和对偶问题的关系：弱对偶、强对偶、互补松弛

→ 再看一些典型例子和问题重构技巧。

拉格朗日函数：

学习线性对偶的时候，也用到了这个方法，现在我们先回忆一下，一般问题是：

$$\begin{aligned} \min & f_0(x) \\ \text{s.t. } & f_i(x) \leq 0, \quad i = 1, \dots, m \\ & h_i(x) = 0, \quad i = 1, \dots, p \end{aligned}$$

然后我们定义拉格朗日函数：

$$L(x, \lambda, \nu) = f_0(x) + \sum_{i=1}^m \lambda_i f_i(x) + \sum_{i=1}^p \nu_i h_i(x)$$

这里：

- λ_i 是不等式约束的乘子
- ν_i 是等式约束的乘子。

相当于：**原目标+约束违规的“加权惩罚”**。若某个不等式约束 $f_i(x) \leq 0$ 被违反了，那 $f_i(x)$ 会变正；再乘上乘子 $\lambda_i \geq 0$ ，它就会把 L 往上抬；那么违反约束的点，在拉格朗日函数里通常会变得“不划算”。所以拉格朗日函数的本质就是**用乘子把约束信息塞进目标函数里**。

拉格朗日对偶函数：

定义：

$$g(\lambda, \nu) = \inf_{x \in D} L(x, \lambda, \nu)$$

固定一组乘子 (λ, ν) 以后，把拉格朗日函数对 x 尽量往下压，得到的最小下边界，就是对偶函数。

下界性质：

对偶函数给原问题最优值提供了一个下界。也就是说，不管我们选哪组合法的乘子，只要 $\lambda \geq 0$ ，最终算出来的 $g(\lambda, \nu)$ ，都不可能超过原问题真正的最优值。

设 $\tilde{x}$ 是一个可行解。因为它可行，所以： $f_i(\tilde{x}) \leq 0$ 、 $h_i(\tilde{x}) = 0$ 。如果再有 $\lambda_i \geq 0$ ，那么：

$$\sum_i \lambda_i f_i(\tilde{x}) \leq 0$$

$$\text{等式部分有 } \sum_i \nu_i h_i(\tilde{x}) = 0$$

所以：

$$L(\tilde{x}, \lambda, \nu) \leq f_0(\tilde{x})$$

又因为：

$$g(\lambda, \nu) = \inf_x L(x, \lambda, \nu) \leq L(\tilde{x}, \lambda, \nu)$$

所以最后得到：

$$g(\lambda, \nu) \leq f_0(\tilde{x})$$

而 $\tilde{x}$ 是任意可行解，所以当然也有：

$$g(\lambda, \nu) \leq p^*$$

如何从实际问题写出对偶函数？

“写出 $L \rightarrow$ 对 x 取 $\inf \rightarrow$ 得到 $g \rightarrow$ 写出 $dual$ ” 整条流程。

1. 线性方程组最小范数解：

原问题是：

$$\begin{aligned} \min x^T x \\ \text{s.t. } Ax = b \end{aligned}$$

第一步：写拉格朗日函数

因为这里只有等式约束，没有不等式约束，所以只需要乘子 ν ：

$$L(x, \nu) = x^T x + \nu^T (Ax - b)$$

第二步：对 x 最小化

对 x 求梯度并令它为 0：

$$\nabla_x L(x, \nu) = 2x + A^T \nu = 0$$

所以：

$$x = -\frac{1}{2} A^T \nu$$

第三步：代回 L ，得到对偶函数

代回后得到：

$$g(\nu) = -\frac{1}{4} \nu^T A A^T \nu - b^T \nu$$

这就是对偶函数。

2. 标准形式线性规划：

$$\begin{aligned} \min c^T x \\ \text{s.t. } Ax = b, \quad x \succeq 0 \end{aligned}$$

这里：

- $Ax = b$ ：线性等式约束
- $x \succeq 0$ ：每个分量都非负。

这里我们要注意：非负约束也可以放进拉格朗日函数的哦，因为 $x \succeq 0$ 等价于 $-x \preceq 0$ ，所以它本质上也是**不等式约束**，因此也要配一个乘子 $\lambda \succeq 0$ 。

第一步：写拉格朗日函数

$$L(x, \lambda, \nu) = c^T x + \nu^T (Ax - b) - \lambda^T x$$

第二步：把式子整理一下

把和 x 有关的项合并：

$$L(x, \lambda, \nu) = -b^T \nu + (c + A^T \nu - \lambda)^T x$$

现在 L 对 x 是仿射函数也就是“常数项 + 一个线性项”。

第三步：对 x 取 $\inf$

现在我们要要求：

$$g(\lambda, \nu) = \inf_x L(x, \lambda, \nu)$$

因为：

$$L(x, \lambda, \nu) = -b^T \nu + (c + A^T \nu - \lambda)^T x$$

如果向量 $c + A^T \nu - \lambda$ 不等于 0，那么总可以选一个方向，让这个线性项一路往 $-\infty$ 掉下去。所以这时：

$$g(\lambda, \nu) = -\infty$$

反过来，只有当 $c + A^T \nu - \lambda = 0$ 时，和 x 有关的项整个消失，此时 L 就只剩一个常数：

$$L(x, \lambda, \nu) = -b^T \nu$$

于是：

$$g(\lambda, \nu) = \begin{cases} -b^T \nu, & A^T \nu - \lambda + c = 0 \\ -\infty, & \text{否则} \end{cases}$$

因为要**最大化** $g(\lambda, \nu)$ ，所以对偶问题就是：

$$\begin{aligned} & \max -b^T \nu \\ \text{s.t. } & A^T \nu - \lambda + c = 0, \quad \lambda \succeq 0 \end{aligned}$$

3.二次规划：

原问题：

$$\begin{aligned} & \min x^T P x \\ \text{s.t. } & A x \succeq b \end{aligned}$$

其中 $P \in S_{++}^n$ 。

第一步，写拉格朗日函数：

$$L(x, \lambda) = x^T P x + \lambda^T (A x - b), \quad \lambda \succeq 0$$

第二步，对 x 最小化，令梯度为 0：

$$\nabla_x L(x, \lambda) = 2P x + A^T \lambda = 0$$

$$x = -\frac{1}{2} P^{-1} A^T \lambda$$

第三步，代回得对偶函数：

$$g(\lambda) = -\frac{1}{4} \lambda^T A P^{-1} A^T \lambda - b^T \lambda$$

因此对偶问题为：

$$\begin{aligned} \max \quad & -\frac{1}{4} \lambda^T A P^{-1} A^T \lambda - b^T \lambda \\ \text{s.t.} \quad & \lambda \succeq 0 \end{aligned}$$

强对偶与弱对偶：

设：

- 原问题最优值为 p^*
- 对偶问题最优值为 d^*

1. 弱对偶

$$d^* \leq p^*$$

含义：对偶问题最优值永远不超过原问题最优值。

原因：对偶函数 $g(\lambda, \nu)$ 对所有可行对偶变量都给出原问题的下界，因此其最大值 d^* 仍然是下界。

结论：弱对偶总成立，不论原问题是否凸。

2. 强对偶

$$d^* = p^*$$

含义：对偶问题不仅给出下界，而且恰好达到原问题最优值。

3. 对偶间隙

若 $d^* < p^*$ ，则称存在对偶间隙。

4. 强对偶何时成立

强对偶一般不总成立；对于凸优化问题，在满足一定约束资格条件时通常成立。**强对偶只说明原问题与对偶问题的最优值相等，不说明最优解一定唯一或一定存在。**可能出现的情况包括：

- 强对偶成立且对偶最优解唯一；
- 强对偶成立但对偶最优解不唯一；
- 强对偶成立但对偶最优解不存在。

► 唯一的对偶最优解 (Unique Dual Optimal):

$$\begin{aligned} \min \quad & x_1 - x_2 \\ \text{s.t.} \quad & x_1 + x_2 \leq 1, \quad x_1 \geq 0, \quad x_2 \geq 0 \end{aligned}$$

► 多个对偶最优解 (Multiple Dual Optimal):

$$\min \quad |x_1| - x_2 \quad \text{s.t.} \quad x_1 \leq 0, \quad x_2 = 0$$

► 无对偶最优解 (No Dual Optimal):

$$\min \quad x \quad \text{s.t.} \quad x^2 \leq 0$$

几何角度理解凸问题对偶:

原问题:

$$\min f(x) \quad \text{s.t.} \quad f_1(x) \leq 0$$

可以几何化为:

- 构造集合

$$V = \{(u, w) \mid \exists x, f_1(x) \leq u, f(x) \leq w\}$$

u 表示: 约束被放松到什么程度、 w 表示: 目标值被压到什么程度、 V 收集了所有“可以通过某个 x 实现出来的 (u, w) 组合”。

- 原问题等价于在 $u = 0$ 上找最小的 w

$$p^* = \inf_{(0, w) \in V} w$$

所以原问题最优值 = 集合 V 与 w 轴的最小截距。

而对偶函数则可以写成:

$$q(\lambda) = \inf_{(u, w) \in V} (w + \lambda u), \quad \lambda \geq 0$$





表示当斜率 $-\lambda$ 固定时, 从下方支撑集合 V 的那条直线所对应的截距。

- 记 H 为 $\mathbb{R}^m \times \mathbb{R}$ 中的一个非垂直超平面，定义为：

$$H = \{(u, w) \mid \lambda u + w = q(\lambda)\}$$

其中： $q(\lambda) = \inf_{(u, w) \in V} \{w + \lambda u\}$, $\lambda \geq 0$

- 超平面 H 是集合 V 的一个支撑超平面，与 w 轴的交点为 $(0, q(\lambda))$



每一个对偶可行的 λ ，都对应一条从下方支撑集合 V 的斜线；这条斜线在 w -轴上的截距，就是对偶值 $q(\lambda)$ 。

何时强对偶一定成立呢？

Slater 条件

即：存在一个“严格可行点”。那什么叫严格可行点嘞？对于下面凸优化问题：

$$\begin{aligned} & \min f_0(x) \\ & \text{s.t. } f_i(x) \leq 0, i = 1, \dots, m \\ & \quad Ax = b \end{aligned}$$

如果存在某个点 x ，满足：

- 每个不等式都不是“刚好卡边界”，而是严格成立 $f_i(x) < 0$
- 等式照常满足 $Ax = b$

那我们就说这个问题满足 Slater 条件。

如果问题是凸优化问题，并且满足 Slater 条件，那么强对偶成立，也就是：

$$d^* = p^*$$

进一步，而且如果原问题最优值不是 $-\infty$ ，那么对偶最优解也存在。

Slater 条件在不同情境下的体现：



不等式形式的线性规划 (Inequality Form LP)

原始问题 (Primal Problem)：

$$\begin{aligned} \min \quad & c^T x \\ \text{s.t.} \quad & Ax \succeq b \end{aligned}$$

对偶函数 (Dual Function)：

$$g(\lambda) = \inf_x \left((c + A^T \lambda)^T x - b^T \lambda \right) = \begin{cases} -b^T \lambda, & \text{若 } A^T \lambda + c = 0 \\ -\infty, & \text{否则} \end{cases}$$

对偶问题 (Dual Problem)：

$$\begin{aligned} \max \quad & -b^T \lambda \\ \text{s.t.} \quad & A^T \lambda + c = 0, \quad \lambda \succeq 0 \end{aligned}$$

- ▶ 根据 Slater 条件：若存在 $\bar{x}$ 使得 $A\bar{x} \prec b$ ，则 $p^* = d^*$
- ▶ 实际上，除非原始问题与对偶问题都不可行，一般都有 $p^* = d^*$

二次规划 (Quadratic Program)

原始问题 (Primal Problem) (假设 $P \in \mathbb{S}_{++}^n$):

$$\begin{aligned} \min \quad & x^T P x \\ \text{s.t.} \quad & Ax \succeq b \end{aligned}$$

对偶函数 (Dual Function):

$$g(\lambda) = \inf_x (x^T P x + \lambda^T (Ax - b)) = -\frac{1}{4} \lambda^T A P^{-1} A^T \lambda - b^T \lambda$$

对偶问题 (Dual Problem):

$$\begin{aligned} \max \quad & -\frac{1}{4} \lambda^T A P^{-1} A^T \lambda - b^T \lambda \\ \text{s.t.} \quad & \lambda \succeq 0 \end{aligned}$$

- ▶ 根据 Slater 条件: 若存在 $\bar{x}$ 满足 $A\bar{x} \prec b$, 则 $p^* = d^*$
- ▶ 实际上, 对于该问题, 总有 $p^* = d^*$

17 / 22

互补松弛性:

与单纯形中的对偶同样的道理, 某个不等式约束如果没有“绷紧”, 那它对应的乘子就必须是 0; 反过来, 如果某个乘子大于 0, 那对应约束一定是“绷紧”的。(上面说的绷紧指的是约束取到等号)

设:

- x^* 是原问题最优解;
- (λ^*, ν^*) 是对偶问题最优解;
- 并且强对偶成立。

$$f_0(x^*) = g(\lambda^*, \nu^*) = \inf_x \left(f_0(x) + \sum_{i=1}^m \lambda_i^* f_i(x) + \sum_{i=1}^p \nu_i^* h_i(x) \right)$$

结论 1

x^* 使拉格朗日函数 $L(x, \lambda^*, \nu^*)$ 取得最小值。

结论 2

对每个不等式约束 i , 都有: $\lambda_i^* f_i(x^*) = 0$, 即为互补松弛性。

$$\lambda_i^* > 0 \Rightarrow f_i(x^*) = 0$$

$$f_i(x^*) < 0 \Rightarrow \lambda_i^* = 0$$

对偶与问题重构：

- 一个问题的等价形式，可能导出**非常不同**的对偶问题；
- 如果原来的对偶难推、或者推出来没启发，那就应该考虑**先重构原问题**。

1. 引入新变量或等式约束：

对于这样的原问题：

$$\min f_0(Ax + b)$$

如果我们**直接**对这个问题推对偶，那么对偶函数就是常数：

$$g = \inf_x f_0(Ax + b) = p^*$$

虽然这在形式上也算“**强对偶**”，但这个对偶几乎没用。因为它根本没有暴露出什么结构，也没有帮我们得到一个漂亮的对偶问题。

我们可以把它改写成：

$$\begin{aligned} \min f_0(y) \\ \text{s.t. } Ax + b - y = 0 \end{aligned}$$

也就是引入一个**新变量 y** ，**专门表示复杂表达式 $Ax + b$** 。原问题就被拆成了两部分：

- $f_0(y)$ ：只管函数本身；
- $Ax + b - y = 0$ ：只管线性关系。

这时候推对偶时，拉格朗日函数就会自然拆开：

$$L(x, y, \nu) = f_0(y) + \nu^T (Ax + b - y)$$

接着分别对 x 和 y 取 $\inf$, 就会得到一个非常漂亮的对偶:

$$\begin{aligned} \max & b^T \nu - f_0^*(\nu) \\ \text{s.t.} & A^T \nu = 0 \end{aligned}$$

这里出现了 f_0^* , 也就是**共轭函数**。

如果目标或约束里有一个“整体很复杂”的块, 比如:

$$Ax + b, \quad \|Ax - b\|, \quad \text{某个非线性表达式}$$

1. 先设一个**新变量**去承接它;
 2. 再用一个等式把**新变量和原变量绑起来**;
 3. 然后推对偶时, 结构往往会更清楚。
-

2. 范数逼近问题的对偶问题

这其实就是刚刚我们说的变形方法论的一个具体实操:

$$\min \|Ax - b\|_2$$

这个问题直接看, 目标里有 $Ax - b$ 这么一坨, 不太适合直接推。所以先重写成:

$$\begin{aligned} \min & \|y\|_2 \\ \text{s.t.} & y = Ax - b \end{aligned}$$

也就是: 设 y 表示残差, “残差”简单说, 就是 Ax 和 b 之间差了多少。

拉格朗日函数就可以写成:

$$L(x, y, \nu) = \|y\|^2 + \nu^T y - \nu^T Ax + b^T \nu$$

现在分两部分看:

①**对 x 取 $\inf$** , 只有一项和 x 有关:

$$-\nu^T Ax$$

要使它不跑到 $-\infty$, 必须满足: $A^T \nu = 0$

②对 y 取 $\inf$ (用配方法做)

$$\inf_y (\|y\|_2^2 + \nu^T y)$$

最后给出的结果是:

$$b^T \nu - \frac{\|\nu\|_2^2}{4}$$

于是对偶问题变成:

$$\begin{aligned} \max \quad & b^T \nu - \frac{\|\nu\|_2^2}{4} \\ \text{s.t.} \quad & A^T \nu = 0 \end{aligned}$$

这就是范数逼近问题的对偶。

3. 隐式约束



隐式约束

带有盒约束 (box constraints) 的线性规划: 原始问题与对偶问题

$$\begin{aligned} \text{minimize} \quad & c^T x & \text{maximize} \quad & -b^T \nu - 1^T \lambda_1 - 1^T \lambda_2 \\ \text{subject to} \quad & Ax = b & \text{subject to} \quad & c + A^T \nu + \lambda_1 - \lambda_2 = 0 \\ & -1 \preceq x \preceq 1 & & \lambda_1 \succeq 0, \lambda_2 \succeq 0 \end{aligned}$$

将盒约束隐式化后的重构问题:

$$\begin{aligned} \text{minimize} \quad & f_0(x) = \begin{cases} c^T x & -1 \preceq x \preceq 1 \\ \infty & \text{其他情况} \end{cases} \\ \text{subject to} \quad & Ax = b \end{aligned}$$

对偶函数:

$$g(\nu) = \inf_{-1 \preceq x \preceq 1} (c^T x + \nu^T (Ax - b)) = -b^T \nu - \|A^T \nu + c\|_1$$

对偶问题: maximize $-b^T \nu - \|A^T \nu + c\|_1$

我们把盒约束塞进目标函数，定义一个新的目标：

$$f_0(x) = \begin{cases} c^T x, & -1 \preceq x \preceq 1 \\ \infty, & \text{其他情况} \end{cases}$$

然后问题就改写成：

$$\begin{aligned} & \min f_0(x) \\ & \text{s.t. } Ax = b \end{aligned}$$

这样以后，盒约束不再显式出现，而是变成了目标函数定义域的一部分。这样的改动就叫做隐式约束，不把约束单独写出来，而是用“出了范围就记成 $+\infty$ ”的方式隐含进去。