

凸集、函数、问题

[Slide3.pdf](#)

这篇笔记一不小心写的有点太长了....**有点乱(orz)**....大概逻辑是这样的：

一、凸集：先研究“区域”是否规整

介绍集合的基本概念，以及什么样的集合叫凸集。核心是在几何层面建立基础：以后看优化问题，先看可行域是不是凸的。

二、凸函数：再研究“函数”是否规整

介绍凸函数、严格凸函数及常用判凸方法。核心是在函数层面建立基础：以后看目标函数和约束函数，先看它们是不是凸的。

三、凸问题：把凸集和凸函数结合起来

先说明一般优化问题的标准形式，再给出凸优化问题的定义与性质。核心结论是：凸优化中局部最优就是全局最优，并可进一步写出最优性条件。

四、等价变形与标准模型：把理论落到具体问题上

介绍常见的等价变形方法，以及 LP、QP、QCQP、SOCP、SDP 等标准模型。核心是把前面的理论转化为实际建模语言。

什么是凸？：“没有坑、没有断裂、没有凹进去”的几何对象

内部、闭包、边界：

- **内部点**：点 x_0 周围存在一个小球，**整个小球都落在集合 X 里面。**
- **闭包**：所有能被 X 中点列逼近到的点组成的集合。
- **边界**：闭包减去内部。

内部点：

- 如果站在房间里某个位置，**以 x 为中心画一个很小很小的圆**，这个圆完全不碰墙，还全在房间里，那它就是**内部点**。
- 如果它太靠墙了，无论圆画得多小，总会碰到墙外，那 x 就不是内部点。

数学上就是：

$$\exists r > 0, \quad B(x_0, r) \subseteq X$$

这里的 $B(x_0, r)$ 就是“以 x_0 为中心的小球”。

极限点：

如果存在一个序列 $\{x_n\} \subseteq X$, 使得 $x_n \rightarrow x_0$, 那么 x_0 被称为 X 的极限点。极限点就是“可以被集合里的点无限逼近到的点”。

比如在实数轴上：

$$x_n = \frac{1}{n}$$

那么

$$\frac{1}{1}, \frac{1}{2}, \frac{1}{3}, \dots \rightarrow 0$$

所以如果 $X = (0, 1)$, 那么虽然 $0 \notin X$, 但因为 $\frac{1}{n} \in X$ 且 $\frac{1}{n} \rightarrow 0$, 所以 **0 是 X 的极限点**。同理, 1 也是, 因为：

$$x_n = 1 - \frac{1}{n} \in (0, 1), \quad x_n \rightarrow 1$$

- 极限点不一定属于集合
 - 集合里的点也可能是极限点
 - 内部点强调**周围的一块区域也都在集合里**, 而极限点强调集合中**有一连串的点能逼近这个点**
-

$$X = [0, 1] \cap \{\text{无理数}\}$$

也就是 $[0, 1]$ 里的所有无理数。这个集合：

- **没有内部点**
 - 但它的**极限点却是整个 $[0, 1]$**
-

所以我们有这样的定义：

- 内部: $\text{int}(X) =$ 所有内部点的集合
- 闭包: $\text{cl}(X) =$ 所有极限点的集合。
- 边界: $\partial(X) = \text{cl}(X) \setminus \text{int}(X)$
- 开集: 是开集当且仅当 $\text{int}(X) = X$
- 闭集: X 是闭集当且仅当 $\text{cl}(X) = X$

同时，我们有这样的性质：

- $\text{int}(X) \subseteq X \subseteq \text{cl}(X)$
- X 是闭集当且仅当 X 的补集是开集
- 任意多个闭集的交集是闭集
- 有限个闭集的并集是闭集

因为无限并可能翻车。比如：

$$\bigcup_{n=1}^{\infty} \left[\frac{1}{n}, 1 \right] = (0, 1]$$

一定要注意闭集和开集并不是对立的！集合可以不闭不开！也可以只开不闭！也可以只闭不开！也可以又闭又开！（实数集 $\mathbb{R}$ 和空集就是又闭又开的）

凸集：

集合 C 是凸集，当且仅当对任意 $x_1, x_2 \in C$ 和任意 $\theta \in [0, 1]$ ，都有：

$$\theta x_1 + (1 - \theta)x_2 \in C$$

也就是两点之间整条线段都留在集合里。

凸集的重要性：

- 第 k 步有当前点 $x^{(k)}$
- 找一个好方向 $d^{(k)}$
- 更新为

$$x^{(k+1)} = x^{(k)} + t^{(k)} d^{(k)}$$

- 重复直到收敛

凸集合保证线搜索成立。

-
1. 内部、闭包、边界：先学会描述集合长什么样
 2. 开集、闭集：再学会按拓扑性质分类

3. 凸集：挑出几何上最规整的一类集合

超平面与半空间：

超平面 $\{x \in \mathbb{R}^n : a^\top x = b\}$ ：

在高维中，可以看作是空间切开的一张切片。因为它是“比所在空间低一维”的东西：

- 在二维空间里，它是一维直线
- 在三维空间里，它是二维平面
- 在 n 维空间里，它是 $n - 1$ 维对象

半空间 $\{x \in \mathbb{R}^n : a^\top x \leq b\}$ ：

超平面一刀切下去后，其中一边连同边界一起留下来的那一半空间。

半空间一定是凸集，假设 x, y 都满足 $a^\top x \leq b$ 和 $a^\top y \leq b$ 。看它们的凸组合：

$$z = \theta x + (1 - \theta)y, \quad \theta \in [0, 1]$$

那么

$$a^\top z = a^\top (\theta x + (1 - \theta)y) = \theta a^\top x + (1 - \theta)a^\top y \leq \theta b + (1 - \theta)b = b$$

所以 z 也还在这个半空间里。

仿射空间 $\{x \in \mathbb{R}^n : Ax = b\}$ ：

仿射空间 = **线性子空间平移了一下**。它保留了“直线、平行、平直”这些性质，但**不要求经过原点**。
“线性”要求很严：必须含 0、对加法封闭、对任意实数倍封闭。

“仿射”放松了一点：不一定含 0、不一定对数乘封闭、但它仍然像“平移过的线性结构”。

多面体 $\{x \in \mathbb{R}^n : Ax \leq b\}$ ：

也就是**若干半空间的交集**。二维里我们熟悉的：

- 三角形、矩形、多边形一些无界区域

都可以看成多面体。三维里对应的是多面体、多棱柱之类。我们单纯形法也是在多面体空间中实施的，这是我们最熟悉的。

欧几里得球与椭球体：

欧几里得球：

$$B(x_c, r) = \{x \in \mathbb{R}^n : \|x - x_c\|_2 \leq r\} = \{x_c + ru : \|u\|_2 \leq 1\}$$

欧几里得球其实就是“普通距离意义下的球”。在不同维度里：

- 在 $\mathbb{R}$ 中，它是一个区间；
- 在 $\mathbb{R}^2$ 中，它是一个圆盘；
- 在 $\mathbb{R}^3$ 中，它是一个实心球；
- 在更高维中，虽然画不出来，但定义完全一样。

球不是三维专属名词，而是“距离不超过某个半径”的统一说法。对于第二种写法：

1. 先从单位球 $\{u : \|u\|_2 \leq 1\}$ 出发；
2. 把它放大 r 倍；
3. 再平移到 x_c 。

因此，任意欧几里得球都可以看成单位球经过“缩放 + 平移”得到。

椭球体：

$$\{x \in \mathbb{R}^n : (x - x_c)^T P^{-1} (x - x_c) \leq 1\}, \quad P \in S_{++}^n$$

- x_c 是中心；
- P 是对称正定矩阵；
- P^{-1} 决定椭球在各个方向上的“伸缩程度”。

另一种表示：

$$\{x_c + Au : \|u\|_2 \leq 1\}, \quad P = AA^T$$

椭球体本质上是**旋转、变形后的球体**。

范数球与范数锥：

范数 $\|\cdot\|$ 是满足以下三条性质的函数：

$$1. \|x\| \geq 0, \quad \|x\| = 0 \iff x = 0$$

$$2. \|tx\| = |t| \|x\|, \quad \forall t \in \mathbb{R}$$

$$3. \|x + y\| \leq \|x\| + \|y\|$$

这三条分别表示：

1. **非负性**：长度不能为负；
2. **齐次性**：放大几倍，长度也放大几倍；
3. **三角不等式**：绕路不会比直走更短。

范数就是“**长度**”的抽象定义。常见例子有：

- 欧几里得范数 $\|x\|_2$ ：普通长度；
- l_1 范数 $\|x\|_1 = \sum |x_i|$ ；
- l_∞ 范数 $\|x\|_\infty = \max_i |x_i|$ 。

范数是凸函数。由于不同范数给出的“距离”不同，所以球的形状也不同。在二维里：

- $\|\cdot\|_2$ 的球是圆盘；
- $\|\cdot\|_1$ 的球是菱形；
- $\|\cdot\|_\infty$ 的球是正方形。

因此，“球”这个词不是指外形像圆，而是指：某种距离规则下，离中心不超过某个上界的点集。

范数锥：

几何上就是：第 t 层的**截面**是半径为 t 的范数球，把这些截面从 $t = 0$ 往上堆起来，就得到一个锥。

正定矩阵：

- 对称矩阵 (Symmetric matrices) : S
- 半正定矩阵 (Positive semidefinite matrices) : S_+
- 正定矩阵 (Positive definite matrices) : S_{++}

都是凸的集合，**凸集**。

凸组合与凸包

给定点 $x_1, \dots, x_k$ ，若


$$x = \theta_1 x_1 + \theta_2 x_2 + \cdots + \theta_k x_k$$

满足

$$\theta_i \geq 0, \quad \theta_1 + \cdots + \theta_k = 1,$$

则称 x 是这些点的**凸组合**。凸组合就是“**用非负权重做加权平均**”。所以它不会“跑到这些点围成的区域外面去”。

集合 S 的**凸包**记作 $\text{conv}(S)$ ，表示：**集合 S 中所有点的凸组合所构成的集合**。**凸包**就是把一个原来可能凹进去、可能离散、可能有空洞的集合，做成一个“最小的凸外壳”。可以想成：**用橡皮筋把一堆点一勒，橡皮筋围出来的区域就是凸包**。



凸、锥、放射、线性组合：

$$\theta_1 x_1 + \cdots + \theta_k x_k$$

可以分成四类：

凸组合：

$$\text{条件: } \theta_i \geq 0, \quad \sum \theta_i = 1$$

特点：只能待在“**包起来的内部**”。

锥组合：

$$\text{条件: } \theta_i \geq 0$$

特点：**不要求和为 1，所以可以不断放大**。几何上像“从原点向外张开的区域”。


仿射组合：

$$\text{条件: } \sum \theta_i = 1$$

特点：**允许系数有负数**，所以不再局限于“内部”，可以**沿直线、平面继续延伸**。例如两个点 x_1, x_2

:

- 凸组合给出线段
- 仿射组合给出穿过这两点的整条直线



线性组合:

条件: $\theta_i \in \mathbb{R}$

特点: 最自由, **没有任何限制**。甚至连非负都不需要。

保持凸性的运算:

详见PPT P16~17, 燃尽了

[第五章.pdf](#)


分离、支撑超平面定理:

若 C, D 是两个**非空、不相交的凸集**, 则存在 $a \neq 0$ 和 b , 使得


$$a^T x \leq b, \quad \forall x \in C$$

$$a^T x \geq b, \quad \forall x \in D$$

于是超平面 $\{x : a^T x = b\}$ 把 C 和 D 分开:



对凸集 C 的边界点 x_0 , 若存在超平面 $\{x : a^T x = a^T x_0\}$ 满足: $a^T x \leq a^T x_0, \forall x \in C$, 则称其为 C 在 x_0 处的**支撑超平面**。(其实可以联想切线去记):



凸函数:

函数 f 是凸函数, 当且仅当满足两条:

1. $\text{dom}(f)$ 是一个**凸集**
2. 对任意 $x_1, x_2 \in \text{dom}(f)$ 和任意 $\theta \in [0, 1]$, 有

$$f(\theta x_1 + (1 - \theta)x_2) \leq \theta f(x_1) + (1 - \theta)f(x_2)$$



严or不严格凸函数也很好理解:

- **凸函数**: 碗底可能有一段是平的
- **严格凸函数**: 不会有平底, 真的往下弯



实数域 $\mathbb{R}$ 上的例子 (Examples on $\mathbb{R}$)

凸函数 (Convex):

- ▶ 仿射函数 (Affine): $ax + b$, 定义在 $\mathbb{R}$, 其中 $a, b \in \mathbb{R}$
- ▶ 指数函数 (Exponential): e^{ax} , 定义在 $\mathbb{R}$, 其中 $a \in \mathbb{R}$
- ▶ 幂函数 (Power): x^p , 定义在 $(0, +\infty)$, 当 $p \geq 1$ 或 $p \leq 0$
- ▶ 绝对值幂函数: $|x|^p$, 定义在 $\mathbb{R}$, 当 $p \geq 1$
- ▶ 负熵函数 (Negative entropy): $x \ln x$, 定义在 $(0, +\infty)$

凹函数 (Concave):

- ▶ 仿射函数 (Affine): $ax + b$, 定义在 $\mathbb{R}$, 其中 $a, b \in \mathbb{R}$
- ▶ 幂函数 (Power): x^p , 定义在 $(0, +\infty)$, 当 $0 \leq p \leq 1$
- ▶ 对数函数 (Logarithm): $\ln x$, 定义在 $(0, +\infty)$

注意: 仿射函数既是凸的也是凹的。

注意: 范数是凸函数 (“长度”这个东西具有天然凸性)

验证函数凸性:

定义、特殊判据、一阶条件、二阶条件、归约为标量函数、上图法、保持凸性的运算。都可以用来验证凸函数

这一段也看PPT P27~? : 简单说一下,

- **一阶检验**其实就是检验**切平面总是在图像下方**; (这和优化里的找全局下界的思想非常吻合)

一阶检验里的这个“倒三角”是 ∇ , 读作 **nabla (纳布拉)**, 在这里表示 **梯度**。梯度本质上就是：**多元函数的“一阶导数向量”**。

- **二级检验**就是检验**如果函数在每一点、每个方向都不往下弯**, 那它整体一定是凸的。用到海森矩阵, 要求矩阵半正定 (≥ 0)

I. 二次函数 (Quadratic function) :

$$f(x) = \frac{1}{2}x^T Px + q^T x + r,$$

其中 P 是对称的 $n \times n$ 矩阵


$$\nabla f(x) = Px + q, \quad \nabla^2 f(x) = P$$

当 $P \succeq 0$ 时函数是凸的。

II. 用矩阵二次验证

$$f(x_1, x_2) = x_1^2 - 3x_1x_2 + x_2^2$$

写出矩阵 A 后发现不正定。或者用 $u + v, u - v$ 代替，算出来是个马鞍状函数：



III. 利用海森矩阵

线性分母下的二次函数 (Quadratic-over-linear) :

$$f(x, y) = \frac{x^2}{y}$$

海森矩阵的值是恒为 0 的。

- **划归为标量函数：**

想判断多元函数 f 是否凸，可以先把它“切到任意一条直线”上，变成一元函数 $g(t)$ ，再检查这个一元函数是不是凸。

在 $\mathbb{R}^n$ 里任取：

- 一个起点 x
- 一个方向 v

则这条直线可写成 $x + tv$ ，把原函数 f 限制到这条直线上，就得到一元函数：

$$g(t) = f(x + tv)$$

如果对任意 x, v ，这个 $g(t)$ 都是一元凸函数，那么原来的多元函数 f 就是凸函数。

- **上图法：**

α -下水平集：

$$C_\alpha = \{x \mid f(x) \leq \alpha\}$$


这里的元素是 x ，不是 (x, t) 。所以它表示的是：所有“函数值不超过某个高度 α ”的自变量点。凸函数的下水平集是凸集（反过来不可以哦）

上图集：


$$\text{epi } f = \{(x, t) \mid f(x) \leq t\}$$

这里的元素是 (x, t) 。所以它表示的是：所有“高度 t 至少压住函数值 $f(x)$ ”的点。也可以理解为图像上方（含边界）的所有点。

逐点最大值：其实很好理解，凸集的交集肯定是凸集



逐点上确界：



- 与标量、向量函数的复合：

设 $g: \mathbb{R}^n \rightarrow \mathbb{R}$, $h: \mathbb{R} \rightarrow \mathbb{R}$, 定义复合函数:

$$f(x) = h(g(x))$$

则 f 是凸函数, 当满足以下条件之一:

- ▶ g 是凸函数, h 是非减且凸函数;
- ▶ g 是凹函数, h 是非增且凸函数。

例子 (Examples):

- ▶ $e^{g(x)}$ 是凸函数, 若 g 是凸函数;
- ▶ $\frac{1}{g(x)}$ 是凸函数, 若 g 是凹函数且为正。

设 $g: \mathbb{R}^n \rightarrow \mathbb{R}^k$, $h: \mathbb{R}^k \rightarrow \mathbb{R}$, 定义复合函数:

$$f(x) = h(g(x)) = h(g_1(x), g_2(x), \dots, g_k(x))$$

则 f 是凸函数, 当满足以下条件之一:

- ▶ g_i 是凸函数, h 在每个变量上都是凸且非减的;
- ▶ g_i 是凹函数, h 在每个变量上都是凸且非增的。

例子 (Examples):

- ▶ $\log\left(\sum_{i=1}^k e^{g_i(x)}\right)$ 是凸函数, 如果每个 g_i 是凸函数。

总的来说是这样的思想:

- 如果里面每个 g_i 都是凸的, 外面 h 对每个变量都要递增
- 如果里面每个 g_i 都是凹的, 外面 h 对每个变量都要递减

• 最小化:

如果 $f(x, y)$ 对 (x, y) 联合凸, 而且 y 只能在一个凸集 C 里选, 那么把 y “最小化掉”以后得到的

$$g(x) = \inf_{y \in C} f(x, y)$$

仍然是关于 x 的凸函数。

这件事叫做: **最小化保凸**。对于每一个给定的 x , 我们找令 $f(x, y)$ 值最小的 y

- **拟凸函数:**

第一种定义: $f: \mathbb{R}^n \rightarrow \mathbb{R}$ 是拟凸函数, 当且仅当 $\text{dom} f$ 是凸集, 并且对所有 α , 下水平集

$$S_\alpha = \{x \in \text{dom} f : f(x) \leq \alpha\}$$

都是凸集。


第二种定义: 当 $\text{dom} f$ 是凸的, 且对任意 $x, y \in \text{dom} f$ 、 $\theta \in [0, 1]$, 有

$$f(\theta x + (1 - \theta)y) \leq \max\{f(x), f(y)\},$$

则 f 是拟凸函数。

凸函数要求更强→中间点的函数值, 必须不超过“两端函数值的加权平均”。

拟凸函数要求更弱→中间点的函数值, 只要不超过“两端里较大的那个”就行。





- **共轭函数:** 给定函数 $f(x)$, 它的**共轭函数**定义为

$$f^*(y) = \sup_{x \in \text{dom} f} (y^T x - f(x)).$$

对一个**固定的** y , 表达式 $y^T x - f(x)$ 是一个关于 x 的量。共轭函数 $f^*(y)$ 就是在所有 x 中, 把这个量取得尽可能大。也就是说:

$f^*(y)$ = “斜率为 y 时, 线性函数 $y^T x$ 相对 $f(x)$ 最多能高出多少”。



- 原函数 f : 告诉你每个 x 处的高度;
- 共轭函数 $f^*(y)$: 告诉你每个斜率 y 对应的“最优支撑直线”要下移多少。

凸问题:

优化问题的标准形式:

$$\begin{aligned} \min \quad & f_0(x) \\ \text{s.t.} \quad & f_i(x) \leq 0, \quad i = 1, \dots, m \\ & h_i(x) = 0, \quad i = 1, \dots, p \end{aligned}$$

- ▶ $x \in \mathbb{R}^n$ 是优化变量
- ▶ $f_0: \mathbb{R}^n \rightarrow \mathbb{R}$ 是目标函数
- ▶ $f_i: \mathbb{R}^n \rightarrow \mathbb{R}$ 是不等式约束函数
- ▶ $h_i: \mathbb{R}^n \rightarrow \mathbb{R}$ 是等式约束函数
- ▶ $p^* = \inf \{f_0(x) \mid f_i(x) \leq 0, h_i(x) = 0\}$
- ▶ 若问题不可行: $p^* = \infty$
- ▶ 若问题在可行域内无下界: $p^* = -\infty$

$\inf$ 是下确界, 不是一定能取到的最小值。它表示:

在所有可行点的目标函数值里, 能压到的最小下边界是多少。

注意它和 $\min$ 不完全一样。

- $\min$: 要求真的有某个点取到最小值
- $\inf$: 只要求这些值可以无限接近某个下界, 不要求一定取到

因为有些问题“最好的值”存在, 但“最佳点”不存在。例如: $\min_{x>0} \frac{1}{x}$ 。这里:

- x 必须大于 0
- $\frac{1}{x}$ 随 $x \rightarrow +\infty$ 越来越接近 0

所以: $p^* = 0$,但是,很显然,我们是**取不到** x 使得 $p^* = 0$ 的。

最优解与局部最优解:

全局最优解:

在整个可行域里,它都是最好的。

也就是说,对**所有可行点** z , 都有

$$f_0(x) \leq f_0(z)$$

这叫全局最优,也就是我们平时说的“最优解”。

局部最优解:

若存在 $R > 0$, 使得 x 在下面这个问题中为最优解,则称其为局部最优解:

$$\begin{aligned} \min \quad & f_0(z) \\ \text{s.t.} \quad & f_i(z) \leq 0, \quad i = 1, \dots, m \\ & h_i(z) = 0, \quad i = 1, \dots, p \\ & \|z - x\|_2 \leq R \end{aligned}$$

也就是说此时,我们不要求在整个定义域里这个点都是最优的了,只要求在**某个邻域里这个解是最优的**就可以了。

隐式约束:

$$x \in \mathcal{D} = \bigcap_{i=0}^m \text{dom } f_i \cap \bigcap_{i=1}^p \text{dom } h_i$$

这句话的意思是:

即使你没有把某些约束显式写成 $f_i(x) \leq 0$ 或 $h_i(x) = 0$, 只要**函数本身在某些地方没定义**, 那么那些地方自动就不能取。

可行性问题:

可行性问题 (Feasibility Problem) 只关心:

Find x

s.t.

$$\begin{aligned} f_i(x) &\leq 0, & i = 1, \dots, m \\ h_i(x) &= 0, & i = 1, \dots, p \end{aligned}$$

它的核心不是“让目标函数最小”，而是：

判断是否存在满足全部约束的解，并找出一个。

我们发现这里的目标函数变成 0 了，其实就是不再有目标了，只要满足所有约束，就是一个可行解，并且由于所有可行解的结果值都是 0，所以每一个可行解都是最优解。

可行性问题就是判断：

$$\bigcap_{i=1}^m \{x \mid f_i(x) \leq 0\} \cap \bigcap_{i=1}^p \{x \mid h_i(x) = 0\}$$

是否非空，看所有约束对应集合的交集是否为空。

那什么样的问题我们可以看成凸优化问题呢？接下来就进入这一块：

标准形式：

$$\begin{aligned} \min \quad & f_0(x) \\ \text{s.t.} \quad & f_i(x) \leq 0, \quad i = 1, \dots, m \\ & a_i^T x = b_i, \quad i = 1, \dots, p \end{aligned}$$

也常写成：

$$\begin{aligned} \min \quad & f_0(x) \\ \text{s.t.} \quad & f_i(x) \leq 0, \quad i = 1, \dots, m \\ & Ax = b \end{aligned}$$

要想这是一个**凸优化问题**，需要：

- f_0 是**凸函数**
- 每个 f_i 也是**凸函数**
- **等式约束必须是仿射的**，也就是 $a_i^T x = b_i$ 或 $Ax = b$

这三点缺一不可。

因为我们希望**可行域是凸集**。而不等式约束

$$f_i(x) \leq 0$$

在 f_i 是凸函数时，它的可行集合是**下水平集**，一定是凸集。但等式约束就不一样了。如果我们写成：

$$h(x) = 0$$

即使 h 是凸函数，集合 $\{x \mid h(x) = 0\}$ 也**未必是凸集**。例如：

$$h(x) = x^2$$

那么 $h(x) = 1$ 的解集是 $\{-1, 1\}$ ，这显然不是凸集。所以为了保证可行域一定凸，等式约束不能随便写，只能写成**仿射形式**：

$$a^T x = b$$

因为这种集合本身就是一个仿射集，而**仿射集一定是凸集**。

- 每个约束 $f_i(x) \leq 0$ 给出一个凸集；
- 每个约束 $a_i^T x = b_i$ 给出一个仿射集，而仿射集也是凸集；

而**凸集的交集仍然是凸集**，所以整个**可行域是凸集**。

一些**非凸约束也是可以转化为凸约束**的，就比如这个例子（这也告诉我们要善于观察！）：

$$\begin{aligned} \min \quad & f_0(x) = x_1^2 + x_2^2 \\ \text{s.t.} \quad & f_1(x) = \frac{x_1}{1+x_2^2} \leq 0 \\ & h_1(x) = (x_1 + x_2)^2 = 0 \end{aligned}$$

- ▶ f_0 是凸函数；可行域 $\{(x_1, x_2) \mid x_1 = -x_2 \leq 0\}$ 是凸集
- ▶ 不是凸优化问题： f_1 非凸， h_1 非仿射
- ▶ 它等价（但不完全相同）于下列凸优化问题：

$$\begin{aligned} \min \quad & x_1^2 + x_2^2 \\ \text{s.t.} \quad & x_1 \leq 0 \\ & x_1 + x_2 = 0 \end{aligned}$$

- 我们**不是**要把所有约束都改写成仿射；
- 在凸优化定义中：
 - **不等式约束本来就允许非线性，只要它是凸的；**
 - 等式约束这一类，要求它**必须是仿射**；
- 有些题虽然表面上**不是标准形式**，但可以**等价变形**后进入凸优化框架。

同时，任意的凸优化问题，局部最优点也一定是全局最优点！

可微函数的最优性判据：

设目标函数 f_0 可微，可行域为 X 。在凸优化背景下，点 x 是最优解，当且仅当：

$$x \in X, \quad \nabla f_0(x)^T(y - x) \geq 0, \quad \forall y \in X$$

这句话的含义是：


- $y - x$ ：从当前点 x 指向任意可行点 y 的方向；
- $\nabla f_0(x)^T(y - x)$ ：函数在 x 处沿这个方向的一阶变化趋势。

因此，上式表示：

从 x 出发，沿任何可行方向走，目标函数都不会在一阶上继续下降。

二、几何意义

若 $\nabla f_0(x) \neq 0$ ，则它在点 x 处定义了可行域 X 的一个**支撑超平面**。



简单理解，“支撑超平面”就是：刚好贴住可行域边界、并且整个可行域都位于它一侧的超平面。

因此最优点的几何图像是：梯度把可行域“顶住了”，在可行域内部已经找不到继续下降的方向。

三、统一的一阶最优性条件

下面几种常见约束结构，都是从统一条件

$$\nabla f_0(x)^T(y - x) \geq 0, \quad \forall y \in X$$

推出来的特例。

1. 无约束问题：

$$\min f_0(x)$$

一阶最优条件

$$\nabla f_0(x) = 0$$

原因：此时 $X = \mathbb{R}^n$ ，任意方向都可走。若梯度不为 0，总能找到一个下降方向，所以最优必须满足梯度为 0。

无约束最优点：梯度必须为零。

2. 等式约束问题

$$\min f_0(x) \quad \text{s.t. } Ax = b$$

一阶最优条件：存在向量 ν ，使得

$$x \in \text{dom } f_0, \quad Ax = b, \quad \nabla f_0(x) + A^T \nu = 0$$

理解：满足 $Ax = b$ 的点只能沿着满足

$$Ad = 0$$

的方向移动，这些方向叫**可行方向**。

在最优点，**沿所有可行方向都不能下降**，因此梯度必须与所有可行方向**正交**。而所有这样的“**法向方向**”正好由 A 的行向量张成，即属于 $R(A^T)$ ，所以可写成：

$$\nabla f_0(x) = -A^T \nu$$

等式约束最优点：梯度必须落在约束面的法向空间里。梯度 = 若干约束法向量的线性组合。

3. 非负约束问题

$$\min f_0(x) \quad \text{s.t. } x \geq 0$$

一阶最优条件：

$$x \in \text{dom } f_0, \quad x \geq 0,$$

并且对每个分量 i ，有：

$$\begin{cases} \nabla f_0(x)_i = 0, & x_i > 0 \\ \nabla f_0(x)_i \geq 0, & x_i = 0 \end{cases}$$

- 若 $x_i > 0$ ，说明这个**分量不在边界上**，正反两个方向都能动，所以必须有：

$$\nabla f_0(x)_i = 0$$

- 若 $x_i = 0$ ，说明**卡在边界上**，只能往正方向动，不能往负方向动，所以必须有：

$$\nabla f_0(x)_i \geq 0$$

内部点：梯度分量为 0；边界点：梯度分量非负。

这三种情形，本质上都在表达同一个思想：

最优点 = 沿所有允许的可行方向，都没有下降的一阶趋势。

不同约束，区别只在于“允许走的方向”不同：

- **无约束**：所有方向都允许
| $\Rightarrow \nabla f_0(x) = 0$
- **等式约束**：只能沿约束面切着走
| $\Rightarrow \nabla f_0(x) + A^T \nu = 0$
- **非负约束**：有的方向能双向走，有的只能单向走
| $\Rightarrow$ 分量条件成立

同一个凸问题，能不能改写成更方便求解的样子呢？等价凸优化就来解决这个问题：

在不改变原问题本质的前提下，把凸优化问题改写成另一种更好分析、更好求解、更适合算法实现的形式。首先明白几个要点：

- **等价**：两个问题的最优解、最优值能互相对应，本质上是在解同一件事。
- **保持凸性不变**：改写以后，问题还是凸的，不会把“好问题”改坏。
- **仿射变换**：形如 $Ax + b$ 的变换，就是“线性变换再平移”。
- **松弛变量**：把“不等式差多少”单独记成一个新变量。
- **上图形式 (epigraph form)**：给目标函数加一个高度变量 t ，把“最小化函数值”改写成“找最低的合法高度”。

消除等式约束：

$$\min f_0(x) \quad \text{s.t. } f_i(x) \leq 0, i = 1, \dots, m, \quad Ax = b$$

等价于：

$$\min f_0(Fz + x_0) \quad \text{s.t. } f_i(Fz + x_0) \leq 0, i = 1, \dots, m$$

其中 F, x_0 满足：

$$Ax = b \iff x = Fz + x_0 \\ \text{for some } z$$

我们不再直接拿 x 当变量，而是改用 z 当变量，然后规定：

$$x = Fz + x_0$$

这样一来，我们随便取一个 z ，得到的 x 就自动满足 $Ax = b$ 。所以等式约束就不用再写出来了。（这和我们学对偶的时候的拉格朗日乘子法的思想非常像，约束罚入等式里）。

因为满足 $Ax = b$ 的所有点，本身就是一个**仿射集合**。简单说，就是“**某个特解 + 所有零空间方向**”，设：

- x_0 是一个特解，满足 $Ax_0 = b$
- F 的列向量张成 A 的零空间，也就是 $AF = 0$

那么所有满足 $Ax = b$ 的解都可以写成：

$$x = x_0 + Fz$$

这与线性代数里学的“齐次解 + 特解”是一个道理。

引入等式约束：

$$\min f_0(A_0x + b_0) \quad \text{s.t.} \quad f_i(A_ix + b_i) \leq 0, \quad i = 1, \dots, m$$

等价于引入变量：

$$y_i = A_ix + b_i$$

$$\text{得到 } \min_{x, y_i} f_0(y_0)$$

$$\text{s.t.} \quad f_i(y_i) \leq 0, \quad i = 1, \dots, m$$

$$y_i = A_ix + b_i, \quad i = 0, \dots, m$$

把“非线性部分”和“线性耦合部分”拆开。

引入松弛变量：

$$\min f_0(x) \quad \text{s.t. } a_i^T x \leq b_i, \quad i = 1, \dots, m$$

等价于：

$$\min_{x,s} f_0(x)$$

$$\text{s.t. } a_i^T x + s_i = b_i, \quad i = 1, \dots, m$$

$$s_i \geq 0, \quad i = 1, \dots, m$$

和线性优化里加松弛变量的思路一样，没什么好说的

改写为上图形式：

$$\min f_0(x) \quad \text{s.t. } f_i(x) \leq 0, \quad Ax = b$$

等价于引入变量 t ：

$$\begin{aligned} & \min_{x,t} \\ & \text{s.t. } f_0(x) - t \leq 0 \\ & \quad f_i(x) \leq 0 \\ & \quad Ax = b \end{aligned}$$

首先来直观地理解：

$$f_0(x) - t \leq 0 \iff t \geq f_0(x)$$

所以 (x, t) 必须落在函数图像的“上方”，这就是所谓“上图”。二维时，如果函数图像是一条曲线 $t = f_0(x)$ ，那么“上图”就是曲线以上的整块区域：

$$\{(x, t) \mid t \geq f_0(x)\}$$

现在我们在这块区域里找最小的 t ，当然就会压到函数图像最低点上。所以这 and 原问题完全等价。

这样以后：

- 目标函数变成了线性的: $\min t$
- 原来的目标函数被搬进约束里: $f_0(x) - t \leq 0$

先对部分变量最小化:

$$\min_{x_1, x_2} f_0(x_1, x_2) \quad \text{s.t. } f_i(x_1) \leq 0$$

等价于定义:

$$\tilde{f}_0(x_1) = \min_{x_2} f_0(x_1, x_2)$$

然后变成

$$\min_{x_1} \tilde{f}_0(x_1) \quad \text{s.t. } f_i(x_1) \leq 0$$

如果约束只和 x_1 有关, 而 x_2 不受约束直接限制, 那么可以先固定 x_1 , 把 x_2 这部分先优化掉。

于是原来的两层变量问题, 就变成只对 x_1 优化的问题。既然如此, 就定义:

$$\tilde{f}_0(x_1) = \min_{x_2} f_0(x_1, x_2)$$

那原问题自然就等价成:

- 先把 x_2 的最优值算出来
- 再只在 x_1 上做外层优化

这本质上是“先做内层最优化, 再做外层最优化”。

• 1. 消约束 / 降维

消除等式约束: $x = Fz + x_0$

对部分变量先最小化: $\tilde{f}_0(x_1) = \min_{x_2} f_0(x_1, x_2)$

• 2. 拆结构

引入等式: $y_i = A_i x + b_i$

引入松弛变量: $a_i^T x + s_i = b_i, s_i \geq 0$

- 3. 标准化

目标改成上图形式: $\min t, f_0(x) \leq t$

如果一个问题只是拟凸的，那又该怎么办呢？→拟凸优化问题相关求解：

问题形式：

$$\begin{aligned} & \min f_0(x) \\ \text{s.t. } & f_i(x) \leq 0, i = 1, \dots, m \\ & Ax = b \end{aligned}$$

其中：

- f_0 是拟凸函数
- $f_1, \dots, f_m$ 是凸函数
- $Ax = b$ 是仿射约束

我们先回忆一下拟凸，它不要求函数图像本身是“碗形”的；它只要求每个下水平集都是凸集。所以我们是有可能把他转化为凸优化来求解的。↓

如果 $f_0(x)$ 是拟凸函数，那么存在一族函数 $\phi_t(x)$ ，满足：

1. 对每个固定的 t ， $\phi_t(x)$ 是凸函数；
2. 并且

$$f_0(x) \leq t \iff \phi_t(x) \leq 0$$

（虽然 f_0 本身不一定是凸函数，但“ $f_0(x) \leq t$ ”这个条件，可以改写成某个凸不等式 $\phi_t(x) \leq 0$ 。拟凸目标的“目标值不超过 t ”这件事，其实能写成一个凸约束。）

（因为拟凸的定义本来就是： $\{x \mid f_0(x) \leq t\}$ ，是凸集。而凸集通常可以由凸不等式来描述。所以对每一个 t ，我们都可以试图找到一个凸函数 ϕ_t ，使得 $f_0(x) \leq t$ 和 $\phi_t(x) \leq 0$ 表示的是同一个集合。）

示例：设 $f_0(x) = \frac{p(x)}{q(x)}$ ，其中：

► $p(x)$ 是凸函数， $p(x) \geq 0$

► $q(x)$ 是凹函数， $q(x) > 0$

令：

$$\phi_t(x) = p(x) - tq(x)$$

则当 $t \geq 0$ 时， ϕ_t 是凸函数，且有：

$$f_0(x) \leq t \iff \phi_t(x) \leq 0$$

这就是一个很经典的用某族凸函数替换拟凸函数的例子。用到了凸函数相加依然是凸函数的性质。

t 不是原问题里的决策变量，而是对最优值 p^* 的一个**试探值 / 阈值 / 猜测值**。

- 固定 t 后，我们思考：是否存在某个可行点 x ，使得 $f_0(x) \leq t$ ？
- 也就是问：目标值能不能被压到 t 以下？

先找一个区间

$$l \leq p^* \leq u$$

第 2 步，取中点：

$$t = \frac{l + u}{2}$$

第 3 步，判断固定 t 时的凸可行性问题有没有解

第 4 步：

- 可行：说明 $p^* \leq t$ ，令 $u = t$
- 不可行：说明 $p^* > t$ ，令 $l = t$

迭代重复即可。

Chebyshev 中心：

给定一个多面体：

$$\mathcal{P} = \{x \mid a_i^T x \leq b_i, i = 1, \dots, m\}$$

这表示：

- 每个不等式 $a_i^T x \leq b_i$ 给出一个半空间
- 所有这些半空间交在一起，形成一个多面体 $\mathcal{P}$

现在我们想在这个多面体里面塞一个球，而且希望这个球尽可能大。也就是找最大内切球。

设这个球写成：

$$\mathcal{B} = \{x_c + u \mid \|u\|_2 \leq r\}$$

这里：

- x_c 是球心
- r 是半径
- $\|u\|_2 \leq r$ 表示所有离球心不超过 r 的点

球里任一点都能写成：

$$x = x_c + u, \quad \|u\|_2 \leq r$$

所以要让整个球都在第 i 个半空间里，就要保证：

$$a_i^T (x_c + u) \leq b_i, \quad \forall \|u\|_2 \leq r$$

因为必须对所有 u 都成立，所以只需要看“最容易违反约束”的那个点，也就是让

$$a_i^T (x_c + u)$$

最大的那个 u 。于是看上确界：

$$\sup_{\|u\|_2 \leq r} a_i^T (x_c + u) = a_i^T x_c + \sup_{\|u\|_2 \leq r} a_i^T u$$

由柯西不等式得到：

$$a_i^T u \leq \|a_i\|_2 \|u\|_2 \leq \|a_i\|_2 r$$

而且这个上界是能取到的：只要让 u 和 a_i 同方向即可。所以最大值就是：

$$r \|a_i\|_2$$


因此约束变成：

$$a_i^T x_c + r \|a_i\|_2 \leq b_i, \quad i = 1, \dots, m$$

最后写成（这其实是一个线性规划LP）：

$$\begin{aligned} & \max r \\ \text{s.t. } & a_i^T x_c + r \|a_i\|_2 \leq b_i, \quad i = 1, \dots, m \end{aligned}$$

二次规划：



$$\begin{aligned} \min \quad & \frac{1}{2} x^T P x + q^T x + r \\ \text{s.t. } \quad & Gx \leq h \\ & Ax = b \end{aligned}$$

这表示：

- 目标函数是一个二次函数
- 约束是线性不等式 + 线性等式 (这意味着可行域是一个多面体，或一般地讲，多面体集合)

我们要求： $P \in S_+^n$

先简单解释：

- S^n ： $n \times n$ 对称矩阵
- S_+^n ： 对称半正定矩阵

半正定的意思是：

$$z^T P z \geq 0, \quad \forall z$$

这保证目标函数是凸二次函数。

因为二次函数的 Hessian 就是 P (更准确说是对称部分; 若 P 取对称则就是它本身)。而“二阶导矩阵半正定”正是凸函数的判据。所以:

- 若 $P \succeq 0$, 则**目标函数凸**
 - 若 $P \succ 0$, 则**目标函数严格凸**, 通常最优解更容易唯一
-

最小二乘与随即成本线性规划:

把目标展开:

$$\|Ax - b\|_2^2 = (Ax - b)^T(Ax - b)$$

展开得:

$$x^T A^T A x - 2b^T A x + b^T b$$

这正是“二次项 + 一次项 + 常数项”的形式。也就是:

$$\frac{1}{2} x^T P x + q^T x + r$$

其中可以取:

$$P = 2A^T A, \quad q = -2A^T b, \quad r = b^T b$$

所以它是一个**二次规划 QP**。

- 如果 A 不一定是方阵, 或者不可逆
- 那就不能直接写 $x = A^{-1}b$
- 这时最小二乘解可以写成

$$x^* = A^\dagger b$$

这表示“使 Ax 最接近 b 的那个解”。

如果 A 满列秩, 那么它会退化成熟悉的公式:

$$x^* = (A^T A)^{-1} A^T b$$

随机成本线性规划：

$$\begin{aligned} \min & \bar{c}^T x + \gamma x^T \Sigma x \\ \text{s.t. } & Gx \leq h, \quad Ax = b \end{aligned}$$

并且写成：

$$\mathbb{E}[c^T x] + \gamma \text{Var}(c^T x)$$

因为我们既希望期望成本小，又希望风险小。

- c 是随机向量
- 均值是 $\bar{c}$
- 协方差矩阵是 Σ
- $c^T x$ 是线性项
- $x^T \Sigma x$ 是二次项
- 约束 $Gx \leq h, Ax = b$ 是线性的

只要 $\Sigma \succeq 0$ （协方差矩阵本来就半正定），那么目标函数就是凸二次函数。所以这仍然是一个 QP。

哪些问题天然落在凸优化框架中呢？

LP $\rightarrow$ QP $\rightarrow$ QCQP $\rightarrow$ SOCP $\rightarrow$ SDP

1. LP

$$\min c^T x + d$$

$$\text{s.t. } Gx \leq h, \quad Ax = b$$

课件对 LP 的描述非常直接：**目标函数是仿射的，约束也是仿射的**，所以这是最基础的一类凸优化问题；它的可行域是一个**多面体**。

饮食问题、Chebyshev 中心都是 LP 问题

2、QP：二次规划 (Quadratic Program)

标准形式：

$$\min \frac{1}{2}x^T Px + q^T x + r$$

$$\text{s.t. } Gx \leq h, \quad Ax = b$$

这里要求：

$$P \in S_+^n$$

也就是 P 是对称半正定矩阵。这样目标函数才是**凸二次函数**。可行域仍然是线性约束给出的多面体。

最小二乘、随机成本线性规划属于此类问题

3、QCQP：带二次约束的二次规划

$$\min \frac{1}{2}x^T P_0 x + q_0^T x + r_0$$

$$\text{s.t. } \frac{1}{2}x^T P_i x + q_i^T x + r_i \leq 0, \quad i = 1, \dots, m$$

$$Ax = b$$

目标和约束里的这些二次型都要是凸的，也就是相应**矩阵要半正定**。QCQP = 在“弯的约束区域”里，最小化一个凸二次函数。

4、SOCP：二阶锥规划 (Second-order Cone Program)

二阶锥就是“范数锥”，也就是形如 $\|x\|_2 \leq t$ 这样的集合。前面已经给过：欧几里得范数锥也叫二阶锥。

$$\min f^T x$$

$$\text{s.t. } \|A_i x + b_i\|_2 \leq c_i^T x + d_i, \quad i = 1, \dots, m$$

$$F x = g$$

这些不等式就是 SOC 约束，也可以写成：

$$(A_i x + b_i, c_i^T x + d_i)$$

属于某个维度的二阶锥。

SOCP 的核心不是“二次”，而是“范数 $\leq$ 线性函数”。特别适合描述：距离、长度、欧几里得球/椭圆、鲁棒约束、各种“平方和开根号”型约束。

- 若 $n_i = 0$ ，SOCP 退化为 LP (n_i 指的是范数向量的维数，空范数就是 0)
- 若 $c_i = 0$ ，SOCP 退化为 QCQP(也就是右侧不再有含 x 的线性项了，约束就变成了“一个范数 $\leq$ 常数”，两边平方就变成二次约束了)

鲁棒线性规划就属于这类问题。这类问题目标通常线性、约束是范数 $\leq$ 线性、比 LP、QCQP 更一般。

5、SDP：半正定规划 (Semidefinite Program)

半正定矩阵就是满足：

$$z^T X z \geq 0, \quad \forall z$$

的对称矩阵。可以先把它理解成：这个矩阵对应的二次型永远不会把函数值往“负的方向”拉下去。我们前面也已把 S_+ , S_{++} 作为重要凸集介绍过。

$$\min c^T x$$

$$\text{s.t. } x_1 F_1 + x_2 F_2 + \dots + x_n F_n + G \succeq 0$$

$$A x = b$$

这里，约束：

$$x_1 F_1 + \cdots + x_n F_n + G \succeq 0$$

叫做**线性矩阵不等式**，简称 *LMI*。

LP 和 SOCP 都能写成 SDP。典型应用：特征值优化。

- LP 是最基础的；
- QP 是在**线性约束**下优化凸二次目标；
- QCQP 进一步**允许二次约束**；
- SOCP 用**二阶锥约束**统一处理许多范数型与鲁棒型问题；
- SDP 用**线性矩阵不等式**描述更一般的凸约束，**表达能力最强**。
- LP 和 SOCP 都可以改写为 SDP。

关于这五种问题的目标函数：

- LP：线性目标
- QP：二次目标
- QCQP：二次目标
- SOCP：线性目标
- SDP：线性目标

