

凸问题最优性条件

[最优性条件.pdf](#)

本章主线：一个点到底什么时候算最优？我怎么判断？



先讲**无约束优化**的一阶、二阶条件；

再讲**等式约束**下的拉格朗日乘子法；

再讲**等式 + 不等式约束**下的 KKT 条件；

最后讲**约束资格条件**，解释为什么有时乘子条件能成立、有时不行。

1. 无约束优化



考虑无约束优化问题：

$$\min_{x \in \mathbb{R}^n} f(x)$$

1. 一阶必要条件（费马法则）

若 x^* 是局部最优解，且 f 在 x^* 可微，则有：

$$\nabla f(x^*) = 0$$

即：**局部最优点一定是驻点**。但这只是**必要条件**，不是充分条件。若 f 进一步是**凸函数**，则：

$$\nabla f(x^*) = 0$$

也是 x^* 为**全局最优解**的充要条件。

2. 为什么一阶条件不够

$$\nabla f(x^*) = 0$$

只能说明 x^* 是一个**驻点**，但不能保证它一定是局部极小值点。例如：

$$f(x) = x^3$$

在 $x = 0$ 处有： $f'(0) = 0$ ，但 $x = 0$ 并不是局部极小值点。这说明：**一阶条件只能筛选候选点，不能单独判定最优性。**

3. 二阶必要条件

若 x^* 是局部极小值点，且 f 二阶可微，则必须满足：

$$\nabla f(x^*) = 0, \quad \nabla^2 f(x^*) \succeq 0$$

即：在局部极小值点处，*Hessian* 矩阵必须是**半正定**的。

4. 二阶充分条件

若：

$$\nabla f(x^*) = 0, \quad \nabla^2 f(x^*) \succ 0$$

则 x^* 是一个**严格局部极小值点**。即：若某个驻点处的 *Hessian* 矩阵是**正定**的，那么该点附近函数沿所有非零方向都向上弯，因此该点一定是真正的严格局部最小点。

无约束优化中，最优性判断从：

$$\nabla f(x^*) = 0$$

开始；但一阶条件只能找到**驻点**，不能保证该点一定最优。要进一步区分局部极小值点、极大值点或鞍点，还需要借助**二阶曲率信息**，即 *Hessian* 矩阵。（看上面那两个图感受一下）

2. 有约束条件时

在上面那个没有约束条件的情况里，最优点附近，可以朝**任何方向**动，所以最优点必须满足 $\nabla f(x^*) = 0$ ；但在有约束时，我们**不能朝任何方向乱动**，只能沿着“**还留在可行域里的方向**”

动。所以条件不再是“梯度等于 0”，而是：**沿所有可行方向，都不能继续下降。**

1. 带集合约束的几何一阶条件

对问题：

$$\min_{x \in S} f(x)$$

若 S 为闭凸集、 f 可微，且 x^* 为**局部最优解**，则有：

$$\nabla f(x^*)^T (y - x^*) \geq 0, \quad \forall y \in S$$

即：**最优点处沿任何可行方向都不能继续下降**。若 f 进一步为凸函数，则该条件也是全局最优的充要条件。（这里 y 是可行域中的某个可行点，所以 $y - x^*$ 就代表了某个可行方向，梯度 $\times$ 任意方向都不能使函数值下降）

2. 等式约束下的可行方向

对问题：

$$\min f(x) \quad \text{s.t. } h_i(x) = 0, \quad i = 1, \dots, m$$

在最优点 x^* 附近，**可行方向** d 的一阶近似满足：

$$\nabla h_i(x^*)^T d = 0, \quad i = 1, \dots, m$$

$$\nabla f(x^*)^T d = 0 \quad \text{对所有满足 } \nabla h_i(x^*)^T d = 0 \text{ 的方向 } d$$

即：**只能沿约束曲面的切向方向移动。并且该处目标函数的梯度与所有切方向正交。**

一个向量如果和所有切向方向都正交，它就只能落在哪儿？显然它必须落在约束面的法向空间里，而约束面的法向空间，正是由这些约束梯度张成的：

$$\nabla h_1(x^*), \dots, \nabla h_m(x^*)$$

所以就必然存在一组系数 $\lambda_1, \dots, \lambda_m$ ，使得：

$$\nabla f(x^*) + \sum_{i=1}^m \lambda_i \nabla h_i(x^*) = 0$$

这就是拉格朗日乘子条件。

- 最优点处，目标梯度不能有切向分量
- 所以目标梯度必须由约束梯度线性组合出来
- 这些组合系数，就是乘子

①为什么最优点处 $\nabla f(x^*)$ 不能有切向分量？

因为等式约束下，**局部最优点只能沿约束面的切线方向移动**。若 $\nabla f(x^*)$ 在切线方向上有非零投影，则沿切线某一侧或反侧走一小步，目标函数就会下降，这与局部最优矛盾。因此， **$\nabla f(x^*)$ 必须与切线方向正交。**

②为什么约束的法向是 $\nabla h(x^*)$ ？

因为在约束曲线 $h(x) = 0$ 上移动时， h 保持不变，所以在最优点处，任意切向量 t 都满足：

$$\nabla h(x^*)^T t = 0$$

这说明最优点处 $\nabla h(x^*)$ 与所有切向量正交，因此它正是约束面的法向量。

③所以为什么会得到拉格朗日乘子条件？

因为 $\nabla f(x^*)$ 和 $\nabla h(x^*)$ 都沿**法向**，所以二者平行，从而存在 λ 使得：

$$\nabla f(x^*) + \lambda \nabla h(x^*) = 0$$

3. 为什么需要正则性条件

若约束梯度线性相关，则约束可能退化，局部几何不能被一阶近似可靠刻画，乘子条件也会变得不稳定。因此通常要求：

$$\nabla h_1(x^*), \dots, \nabla h_m(x^*)$$

线性无关。也就是约束在最优点处不可以退化，不可以假装有很多约束其实在说同一件事。

► 例子：重复约束会导致退化

$$h_1(x, y) = x = 0, \quad h_2(x, y) = 2x = 0.$$

这两个约束看似有两个，其实只是在说同一件事。它们的梯度为

$$\nabla h_1 = (1, 0)^T, \quad \nabla h_2 = (2, 0)^T,$$

线性相关。

4. 拉格朗日定理（一阶、二阶必要条件）

在正则性条件下，若 x^* 是局部最优解，则存在乘子 λ_i 使得：

$$\nabla f(x^*) + \sum_{i=1}^m \lambda_i \nabla h_i(x^*) = 0$$

这表明：在最优点，目标函数梯度必须能由约束梯度的线性组合抵消。

进一步，在二阶条件上，对所有满足：

$$H(x^*)^T y = 0$$

的向量 y ，都必须有：

$$y^T \left[\nabla^2 f(x^*) + \sum_{i=1}^m \lambda_i \nabla^2 h_i(x^*) \right] y \geq 0$$

这就是二阶必要条件。（一阶条件告诉我们这一点是平的，而二阶条件帮我们保证了这一点不会“向下弯”）。

二阶是在看：

$$f(x^* + d) \approx f(x^*) + \underbrace{\nabla f(x^*)^T d}_{\text{一阶}} + \frac{1}{2} d^T \nabla^2 f(x^*) d$$

如果在驻点处 $\nabla f(x^*) = 0$ ，那一阶项没了，主导局部形状的就是二阶项：

$$\frac{1}{2} d^T \nabla^2 f(x^*) d$$

所以这时决定函数值是谷底还是山顶的，主要就是二阶。

具体例子：

$$\begin{aligned} \min \quad & -(x_1x_2 + x_2x_3 + x_3x_1) \\ \text{s.t.} \quad & x_1 + x_2 + x_3 = 3 \end{aligned}$$

我们把约束乘上乘子 λ 加到目标函数里：

$$L(x, \lambda) = -(x_1x_2 + x_2x_3 + x_3x_1) + \lambda(x_1 + x_2 + x_3 - 3)$$

这一步的意思是：

- 原目标：想让 $-(\dots)$ 最小
- 但又不能忘记 $x_1 + x_2 + x_3 = 3$

所以一阶条件就是：

$$\begin{cases} -(x_2 + x_3) + \lambda = 0 \\ -(x_1 + x_3) + \lambda = 0 \\ -(x_1 + x_2) + \lambda = 0 \\ x_1 + x_2 + x_3 = 3 \end{cases}$$

所以利用一阶条件，我们能找到一个最优解： $x^* = (1, 1, 1)$ ， $\lambda = 2$ 。接下来检验**二阶条件**：

约束函数为 $h(x) = x_1 + x_2 + x_3 - 3$ ，故 $\nabla h(x^*) = (1, 1, 1)^T$ 。所以切空间满足 $y_1 + y_2 + y_3 = 0$ 。

拉格朗日函数是：

$$L(x, \lambda) = -(x_1x_2 + x_2x_3 + x_3x_1) + \lambda(x_1 + x_2 + x_3 - 3)$$

- 后面那一项 $\lambda(x_1 + x_2 + x_3 - 3)$ 对 x 来说是**线性的**
- 线性函数的二阶导数等于 0

所以 Hessian 只来自 $-(x_1x_2 + x_2x_3 + x_3x_1)$ ，算出来是：

$$\nabla_{xx}^2 L = \begin{pmatrix} 0 & -1 & -1 \\ -1 & 0 & -1 \\ -1 & -1 & 0 \end{pmatrix}$$

在切空间里, $y^\top \nabla_{xx}^2 L y = \|y\|^2$ 。

拉格朗日的一些证明思路:

1. 为什么要引入罚函数

原问题是带等式约束的局部最优问题, 不能直接使用无约束条件 $\nabla f(x^*) = 0$ 。因此引入罚函数, 把约束违反程度加入目标函数, 构造一系列无约束问题:

$$F_{\mu_k}(x) = f(x) + \mu_k^2 \sum_{i=1}^m h_i^2(x) + \nu \|x - x^*\|^2$$

其中, 随着 $\mu_k \rightarrow \infty$, 违反约束的点会被越来越强地惩罚, 因此无约束问题的局部最优点 x_k 会逼近原约束问题的最优点 x^* 。

2. 对无约束罚函数使用一阶条件

因为 x_k 是无约束问题 F_{μ_k} 的局部最优解, 所以有 $\nabla F_{\mu_k}(x_k) = 0$ 展开可得:

$$0 = \nabla f(x_k) + \mu_k \sum_{i=1}^m h_i(x_k) \nabla h_i(x_k) + \nu(x_k - x^*)$$

将约束梯度记作矩阵 $H(x)$, 约束值记作向量 $h(x)$, 可写成:

$$H(x_k) \mu_k h(x_k) = -(\nabla f(x_k) + \nu(x_k - x^*))$$

这里的 $\mu_k h(x_k)$ 正是拉格朗日乘子的近似形式。

通过“罚函数 + 无约束一阶条件”的方法, 可以把约束问题逼近为一系列无约束问题, 并从中看出拉格朗日乘子的来源。乘子本质上来自“罚系数与约束违反量的乘积”的极限。

3. 乘子的近似形式 (第 18 页)

由罚函数无约束一阶条件可得:

$$H(x_k)\mu_k h(x_k) = -(\nabla f(x_k) + \nu(x_k - x^*))$$

在正则性条件下, $H(x_k)^\top H(x_k)$ 可逆, 从而:

$$\mu_k h(x_k) = -(H(x_k)^\top H(x_k))^{-1} H(x_k)^\top (\nabla f(x_k) + \nu(x_k - x^*))$$

因此, $\mu_k h(x_k)$ 可看作拉格朗日乘子的近似形式。

2. 取极限得到一阶条件 (第 19 页)

定义:

$$\lambda = \lim_{k \rightarrow \infty} \mu_k h(x_k)$$

并利用 $x_k \rightarrow x^*$ 得到:

$$\lambda = -(H(x^*)^\top H(x^*))^{-1} H(x^*)^\top \nabla f(x^*)$$

代回极限形式, 得到

$$\nabla f(x^*) + H(x^*)\lambda = 0$$

$$\text{即 } \nabla f(x^*) + \sum_{i=1}^m \lambda_i \nabla h_i(x^*) = 0$$

这就是拉格朗日一阶必要条件。

3. 取极限得到二阶条件 (第 20 页)

由于 x_k 是无约束罚函数问题的局部最优解, 因此:

$$\nabla^2 F_{\mu_k}(x_k) \succeq 0$$

对满足切空间条件 $H(x^*)^\top y = 0$ 的方向 y 取二次型并令 $k \rightarrow \infty$, 可得

$$y^\top \left[\nabla^2 f(x^*) + \sum_{i=1}^m \lambda_i \nabla^2 h_i(x^*) \right] y \geq 0$$

即拉格朗日函数形式的二阶必要条件。

KKT条件:

当优化问题里同时有等式约束和不等式约束时，用来刻画最优点的一组条件。

- 无约束时：看

$$\nabla f(x^*) = 0$$

- 只有等式约束时：看拉格朗日乘子条件

$$\nabla f(x^*) + \sum_i \lambda_i \nabla h_i(x^*) = 0$$

那如果现在既有等式约束，又有不等式约束呢？比如：

$$\begin{aligned} & \min f(x) \\ \text{s.t. } & h_i(x) = 0, \quad i = 1, \dots, m \\ & g_j(x) \leq 0, \quad j = 1, \dots, r \end{aligned}$$

这时候，最优点的刻画就不是单靠拉格朗日等式乘子能搞定的了，于是就要上 **KKT 条件**。

KKT条件的一阶必要条件

1. 原始可行性 (primal feasibility)

先得满足原问题约束：

$$\begin{aligned} h_i(x^*) &= 0, & i &= 1, \dots, m \\ g_j(x^*) &\leq 0, & j &= 1, \dots, r \end{aligned}$$

2. 驻点条件 (stationarity)

存在乘子：

- $\lambda_i \in \mathbb{R}$ (等式约束乘子)
- $\mu_j \geq 0$ (不等式约束乘子)

使得：

$$\nabla f(x^*) + \sum_{i=1}^m \lambda_i \nabla h_i(x^*) + \sum_{j=1}^r \mu_j \nabla g_j(x^*) = 0$$

这就是“**有不等式约束版**”的拉格朗日条件。在最优点，目标函数的下降趋势，必须被所有真正起作用的约束法向量一起抵消掉。

3. 对偶可行性 (dual feasibility)

$$\mu_j \geq 0, \quad j = 1, \dots, r$$

不等式约束的乘子必须非负。 因为不等式约束是 $g_j(x) \leq 0$ ，它们像“墙”一样顶住最优点，所以乘子的方向不能乱来，必须是非负的。课件第 22 页直接把这一条列出来，第 27 页也从 *Hessian* 推论里解释了这条非负性的来源。

4. 互补松弛 (complementary slackness)

$$\mu_j g_j(x^*) = 0, \quad j = 1, \dots, r$$

- 如果 $\mu_j > 0$ ，那么必须有 $g_j(x^*) = 0$
- 如果 $g_j(x^*) < 0$ ，说明这个约束还有余量，那就必须有 $\mu_j = 0$

KKT二阶充分条件：

对所有非零临界方向 y ，都有

$$y^\top \left[\nabla^2 f(x^*) + \sum_{i=1}^m \lambda_i \nabla^2 h_i(x^*) + \sum_{j \in A(x^*)} \mu_j \nabla^2 g_j(x^*) \right] y > 0$$

那么 x^* 就是**严格局部极小值点**。这个中括号里的东西，其实就是：

$$\nabla_{xx}^2 L(x^*, \lambda, \mu)$$

也就是拉格朗日函数对 x 的 *Hessian*。所以也可以把它记成: $y^\top \nabla_{xx}^2 L(x^*, \lambda, \mu) y > 0$ 。

在所有真正可能影响最优性的可行方向上, 函数都必须“往上弯”。

什么是临界方向?

临界方向 y 满足:

$$\begin{aligned} \nabla h_i(x^*)^T y &= 0 \\ \nabla g_j(x^*)^T y &\leq 0, \quad j \in A(x^*) \end{aligned}$$

并且:

$$\nabla f(x^*)^T y = 0$$

1. $\nabla h_i(x^*)^T y = 0$

表示: 沿 y 走, 在一阶上**不破坏等式约束**。也就是还贴着等式约束面在动。

2. $\nabla g_j(x^*)^T y \leq 0$ (对活跃约束)

表示: 沿 y 走, 在一阶上**不会冲出活跃不等式约束的可行域**。也就是你没有往“墙外”走。

什么是活跃集? $\rightarrow A(x^*) = \{j \mid g_j(x^*) = 0\}$, 也就是“刚好顶在边界上的不等式约束”;

3. $\nabla f(x^*)^T y = 0$

表示: 沿 y 走, 目标函数在一阶上**既不升也不降**。

前面学的**纯等式约束**二阶充分条件是:

- 在切空间方向上,
- 拉格朗日函数的 Hessian 二次型严格大于 0。

现在 KKT 只是把它推广到“**等式 + 不等式**”情形:

- 切空间变成了**临界方向集**
- Hessian 里多了活跃不等式约束对应的二阶项

约束资格条件:

为什么有时 KKT 条件能成立，有时却不一定能直接用？

KKT 想表达的是：

$$\nabla f(x^*) + \sum_i \lambda_i \nabla h_i(x^*) + \sum_j \mu_j \nabla g_j(x^*) = 0$$

也就是：在局部最优点，目标函数的下降趋势可以被活跃约束的法向量抵消。但这句话有个前提：

约束在 x^* 附近的一阶近似，必须能正确反映局部可行集！

如果约束退化了，这个“梯度抵消”的说法就可能失效。Fritz John 条件，它允许目标函数前面的乘子 $\mu_0 = 0$ 。一旦出现 $\mu_0 = 0$ ，就意味着目标函数梯度甚至可能完全不出现在必要条件里，这就不是我们熟悉的 KKT 了。

所以：约束资格条件的任务就是保证 Fritz John 条件里不会出现 $\mu_0 = 0$ ，从而能退化成普通 KKT 条件。

集合角度：一阶近似在近似什么？

- ▶ 真实可行集为

$$S = \{x \mid h_i(x) = 0, g_j(x) \leq 0\}.$$

- ▶ 在 x^* 附近，把 x 写成 $x^* + d$ 。一阶泰勒展开给出

$$h_i(x^* + d) \approx h_i(x^*) + \nabla h_i(x^*)^\top d,$$

$$g_j(x^* + d) \approx g_j(x^*) + \nabla g_j(x^*)^\top d.$$

- ▶ 因此，活跃约束给出的线性化可行方向集合是

$$L(x^*) = \left\{ d \mid \nabla h_i(x^*)^\top d = 0, \nabla g_j(x^*)^\top d \leq 0, j \in A(x^*) \right\}.$$

- ▶ 正则条件要保证的是：这个线性化集合能可靠反映真实可行集在 x^* 附近的局部几何。

一阶近似什么时候会失真？

- ▶ 考虑简单约束

$$x^2 \leq 0.$$

它对应的真实可行集只有一个点：

$$S = \{0\}.$$

- ▶ 但在 $x^* = 0$ 处，约束函数 $g(x) = x^2$ 的梯度为

$$\nabla g(0) = 0.$$

- ▶ 线性化约束变成

$$0 \cdot d \leq 0,$$

这对所有方向 d 都成立。

- ▶ 于是线性化模型误以为“所有方向都可行”，但真实可行集实际上根本不能移动。这就是约束退化导致的一阶近似失真。

32 / 42

各个约束条件间的关系：

- 局部最优解 $\Rightarrow$ Fritz John 条件
- 再加约束资格条件 $\Rightarrow$ KKT 条件
- LICQ $\Rightarrow$ MFCQ $\Rightarrow$ KKT 乘子存在
- Slater 条件 $\Rightarrow$ MFCQ (在凸问题中常用，且等式梯度需独立)

Fritz John 是“兜底必要条件”，不管退不退化，它都成立，它允许 $\mu = 0$ 。而 KKT 是“更强、更好用的必要条件”，但要加正则性 / 约束资格条件，才能从 Fritz John 升级到 KKT。

1. LICQ: 活跃约束梯度线性无关

在 x^* 处，

$$\nabla h_1(x^*), \dots, \nabla h_m(x^*), \nabla g_j(x^*), j \in A(x^*)$$

线性无关。每个活跃约束都应该提供一个独立的限制：

- 没有重复约束
- 没有互相抵消的约束

- 没有“看似很多，其实在说同一件事”的约束

若局部最优点满足 LICQ，则 KKT 乘子存在；但缺点也很明显，这个条件比较强，不是很容易满足，而且一旦活跃约束数量超过变量维数，这个根本不可能成立了。

2.MFCQ：存在共同往内部走的方向

存在一个方向，能同时把所有活跃不等式往“更可行”的一侧推。

- 等式约束梯度线性无关；
- 存在方向 d ，使得 $\nabla h_i(x^*)^T d = 0$ 对所有等式成立；
- 并且对所有活跃不等式约束， $\nabla g_j(x^*)^T d < 0$ ， $j \in A(x^*)$

MFCQ 比 LICQ 弱。LICQ 要求所有活跃约束梯度线性无关；MFCQ 允许它们相关，但要求至少还能找到一个共同往内走的方向。

MFCQ 能保证 Fritz John 条件里的 $\mu_0 > 0$ ，于是可以推出 KKT 条件。

3.Slater：凸问题中存在严格可行点

- h_i 是线性的，且其梯度线性无关；
- g_j 是凸函数；
- 存在一个严格可行点 $\hat{x}$ ，满足

$$h_i(\hat{x}) = 0, \quad g_j(\hat{x}) < 0$$


Slater 条件 = 可行域里真的有“内部点”。不是只贴在边界上，而是有一个点，所有不等式都严格满足。

没有任何正则性条件的例子

考虑如下例子：

$$\begin{aligned} \text{最小化} \quad & x_1^2 + x_2^2 \\ \text{满足约束} \quad & (x_1 - 1)^2 + (x_2 - 1)^2 \leq 1, \\ & (x_1 - 1)^2 + (x_2 + 1)^2 \leq 1. \end{aligned}$$

- ▶ 两个约束分别对应两个圆盘；
- ▶ 两个圆盘只在 $x^* = (1, 0)$ 处相切；
- ▶ 可行集在该点退化为一个尖点；
- ▶ 图中显示了约束区域和目标函数等高线。



39 / 42

第 40 页：反例分析

通过两个圆盘相切的例子说明，当可行域在最优点附近退化成尖点时，活跃约束梯度可能线性相关，从而 LICQ 失败；同时也可能不存在一个共同方向将所有活跃约束都推向可行域内部，因此 MFCQ 也失败。这说明约束资格条件并非总自动成立，普通 KKT 条件有时会失效。

第 41 页：如何选择约束资格条件

教学入门和手算题优先检查 LICQ；若 LICQ 太强，则尝试 MFCQ；若问题是凸优化，则优先使用 Slater 条件；若没有任何正则性条件可用，则退回 Fritz John 条件。

第 42 页：全章总结

最优性条件的主线是：**无约束问题**从 $\nabla f(x^*) = 0$ 开始；**等式约束引入拉格朗日函数**；**不等式约束进一步发展为 KKT 条件**；而约束资格条件则作为 Fritz John 条件与 KKT 条件之间的桥梁，用来**排除退化情形并保证普通 KKT 乘子存在**。