

约束优化与投影梯度法

从“无约束梯度下降”过渡到“有约束优化”，核心是解决“走一步以后不合法怎么办”这个问题。

目标函数告诉我们“往哪里下降”，可行域告诉我们“哪些地方能去”，投影梯度法就是“**先按梯度下降走一步，再投影回合法区域**”。

[约束优化与投影梯度法.pdf](#)

约束优化中的可行域：

无约束问题中的普通梯度下降，我们只需要找到最速下降路径，让函数值变小就行了。然而这种方法，默认 x^{k+1} 可以落在任意位置，一旦有了约束，那么就有可能出现**跑出可行域**的情况。

约束优化还进一步，要求我们每一次迭代出的解还要合法，也就是还得在可行域中。也就是我们**既要下降目标函数，又要保持可行性**。一个很简单的例子：

$$\min_{0 \leq x \leq 2} f(x) = (x - 3)^2.$$

无约束最优	约束最优
$x_{\text{un}} = 3, \quad f(3) = 0.$ 这个点最好，但不合法。	$x^* = 2, \quad f(2) = 1.$ 在所有合法点里，2 已经最靠近 3。

在约束优化问题：

$$\min_{x \in C} f(x)$$

中， C 表示**可行域**，也就是变量 x 必须满足的“合法范围”。不同问题会产生不同类型的约束集合。

约束类型	数学形式	含义	常见例子
盒约束	$l_i \leq x_i \leq u_i$	每个变量都有 上下界	价格范围、库存容量、参数取值范围
非负约束	$x_i \geq 0$	变量 不能为负	流量、概率、资源数量、产量
球约束	$ x _2 \leq R$	向量整体大小 不能超过某个半径	控制模型复杂度、能量限制、参数规模限制
单纯形约束	$x_i \geq 0, \sum_i x_i = 1$	每个分量 非负 ，并且 总和为 1	概率分布、投资组合权重
线性等式约束	$Ax = b$	多个变量之间满足 线性平衡关系	预算平衡、供需平衡、流量守恒

投影算子与几何意义：


给定一个闭凸集合 C ，点 z 到集合 C 的投影定义为：

$$\Pi_C(z) = \arg \min_{x \in C} \frac{1}{2} \|x - z\|^2.$$

其中， $\Pi_C(z)$ 表示 z 在集合 C 上的投影点。这里要注意两个符号：

- $\arg \min$ ：表示“使目标函数取得最小值的那个 x ”
- $\|x - z\|^2$ ：表示点 x 和点 z 之间距离的平方。

也就是，在所有满足 $x \in C$ 的可行点中，我们找一个离 z 最近的点。



直觉

投影不是让目标函数最小，而是先保证“合法”，并且改动尽量小。

投影梯度法算法框架：

从两步走的角度来看，每一次迭代，从 x^k 出发，投影梯度法的步骤都是：

- 先做无约束梯度步找到临时点 z^{k+1}
- 再用临时点投影得到 x^{k+1}

即下降方向+可行性修正，如果写成算法框架就是：

Projected Gradient Descent

1. 选初始点 $x^0 \in C$, 步长 $\alpha_k > 0$;
2. 计算梯度 $g^k = \nabla f(x^k)$;
3. 先走一步: $z^k = x^k - \alpha_k g^k$;
4. 再投影: $x^{k+1} = \Pi_C(z^k)$;
5. 若变化很小或达到最大迭代次数, 则停止。

投影梯度法实例:

一维区间投影:

看课件 P12 这个很简单。

盒约束投影:

$$C = \{x \in \mathbb{R}^n : l_i \leq x_i \leq u_i\}.$$

也就是每个变量都有自己的下界 l_i 和上界 u_i 。投影公式为:

$$[\Pi_C(z)]_i = \min\{u_i, \max\{l_i, z_i\}\}.$$

这个公式可以理解为:

情况	投影结果
$z_i < l_i$	拉到下界: $[\Pi_C(z)]_i = l_i$
$l_i \leq z_i \leq u_i$	本来合法, 不变: $[\Pi_C(z)]_i = z_i$
$z_i > u_i$	拉到上界: $[\Pi_C(z)]_i = u_i$

盒约束的投影本质是: 每个坐标单独判断, 超下界就拉到下界, 超上界就拉到上界, 合法就不动。在二维中, 我们逐个坐标修正就好。

球约束投影:

$$C = \{x : \|x\|_2 \leq R\}.$$

它限制的是向量整体长度，而不是单个坐标。投影规则分两种情况：

情况	投影结果	含义
$ z \leq R$	$\Pi_C(z) = z$	点已经在球内，不用动
$ z > R$	$\Pi_C(z) = R \frac{z}{ z }$	点在球外，沿原方向缩短到半径 R

直觉是：球约束只管“长度不能超过 R ”，所以如果 z 太长，就保持方向不变，把长度缩到 R 。P16 有一个手算的例子可以看一下。

单纯形投影：

$$\Delta_n = \left\{ x \in \mathbb{R}^n : x_i \geq 0, \sum_{i=1}^n x_i = 1 \right\}.$$

它常用来表示概率分布或投资权重。单纯形投影问题是：

$$\Pi_{\Delta_n}(z) = \arg \min_{x_i \geq 0, \sum_i x_i = 1} \frac{1}{2} \|x - z\|^2.$$

它的解具有形式：

$$x_i = \max\{z_i - \tau, 0\}.$$

这里的 τ 不是随便给的，而是由条件 $\sum_i x_i = 1$ 决定。我们可以这样理解：

先把所有 z_i 整体减去同一个数 τ ，然后把变成负数的分量截成 0，最后保证所有分量加起来刚好等于 1。

所以单纯形投影比盒约束投影复杂，因为它不仅要求每个分量非负，还要求总和等于 1。

课堂口径

单纯形投影可以理解为：整体平移 z ，再把负数截成 0，最后总和刚好为 1。

单纯形典例——三种资产权重的例子：

投资权重要求 $x_1 + x_2 + x_3 = 1$, $x_i \geq 0$, 即所有资产权重非负, 且总和为 1。某次梯度步得到 $z = (0.6, 0.3, -0.4)$, 该点不可行：

- 一方面 $z_3 < 0$
- 另一方面 $\sum_i z_i = 0.5 \neq 1$ 。

单纯形投影的一般形式为 $x_i = \max\{z_i - \tau, 0\}$, 其中 τ 由 $\sum_i x_i = 1$ 决定。假设第三个分量被截为 0, 前两个分量保留, 则有 $x_1 = 0.6 - \tau$, $x_2 = 0.3 - \tau$, $x_3 = 0$ 。

由总和约束得 $(0.6 - \tau) + (0.3 - \tau) = 1$, 解得 $\tau = -0.05$ 。因此投影结果为：

$$\Pi_{\Delta_3}(z) = (0.65, 0.35, 0).$$

核心理解： 单纯形投影不是简单地把负数改成 0, 而是“**整体平移 + 截断**”, 同时保证非负性和总和为 1。

完整迭代例子：

考虑问题 $\min_{x \in [0,1]^2} f(x) = \frac{1}{2} \|x - a\|^2$, $a = (1.5, -0.5)$, 初始点 $x^0 = (0.2, 0.2)$, 步长 $\alpha = 1$ 。

由于 $f(x) = \frac{1}{2} \|x - a\|^2$, 所以 $\nabla f(x) = x - a$ 。

第一次无约束梯度步为：

$$z^0 = x^0 - \nabla f(x^0) = x^0 - (x^0 - a) = a = (1.5, -0.5)$$

但 $z^0 \notin [0, 1]^2$, 因为第一个坐标大于 1, 第二个坐标小于 0。因此需要**投影回盒约束**：

$$x^1 = \Pi_{[0,1]^2}(1.5, -0.5) = (1, 0).$$

核心理解： 这一例子完整体现了投影梯度法的两步：**先做梯度步** $z^k = x^k - \alpha \nabla f(x^k)$, **再做投影步** $x^{k+1} = \Pi_C(z^k)$ 。

梯度步负责靠近目标函数想要的方向, 投影步负责保证结果仍在可行域内。

投影梯度的最优性条件 & 停止准则：

最有条件：

投影梯度法的迭代是：

$$x^{k+1} = \Pi_C(x^k - \alpha \nabla f(x^k)).$$

如果某个点 x^* 已经是**稳定点**，那么从它出发，先沿**负梯度方向**走一步，再**投影**回来，应该还是**它自己(又回到最初的起点~)**。所以有固定点条件：

$$x^* = \Pi_C(x^* - \alpha \nabla f(x^*)).$$

即投影梯度法中的一阶稳定条件。

梯度映射

常定义投影梯度映射

$$G_\alpha(x) = \frac{1}{\alpha} (x - \Pi_C(x - \alpha \nabla f(x))).$$

若 $G_\alpha(x) = 0$ ，说明满足一阶稳定性。

无约束情形下 $G_\alpha(x) = 0$ 就退化成 $\nabla f(x) = 0$ ，这说明**投影梯度映射其实是无约束梯度的推广**。

停止准则：

无约束 GD 常用：

$$\|\nabla f(x^k)\| \leq \varepsilon$$

作为停止准则。但约束优化里，这个不合适。因为边界最优点处梯度可能不为零。所以投影梯度法更常用：

$$\|G_\alpha(x^k)\| \leq \varepsilon$$

$$G_\alpha(x) = \frac{1}{\alpha} (x - \Pi_C(x - \alpha \nabla f(x)))$$

步长与收敛速度：

步长选择：

步长 α_k 仍然很重要。

选择方式	课堂理解
固定步长	若已知 L -光滑，可常取 $\alpha \leq 1/L$
递减步长	早期走得大，后期走得稳，例如 $\alpha_k \downarrow 0$
回溯线搜索	如果一步走得太激进，就自动缩小步长

直觉

步长太大可能来回撞边界；步长太小则每次进步很慢。

收敛速度：

投影梯度法本质上是“带可行性修正的 GD ”，所以它的理论速度也和 GD 同一量级。我们也学过，梯度下降算法中，如果函数具有凸且 L 光滑这样逆天的性质时，有 $O\left(\frac{1}{k}\right)$ ，进一步若再是强凸的，梯度下降就有线性收敛速度。

在投影梯度法里也一样，如果函数具有凸且 L 光滑的性质，那么有结论是：

$$f(x^k) - f(x^*) = O\left(\frac{1}{k}\right)$$

总结：

不要混淆

投影本身不负责找原问题最优解；它只负责把某个候选点修正为可行点。真正推动目标函数下降的是梯度步。

适用场景

投影梯度法最适合：目标函数光滑，约束集合简单且投影容易计算的问题。