

线性规划的对偶

[优化理论与算法第四章 11.pdf](#)

什么是对偶？

先用一个小小的现实中的例子来理解：

在线性规划里，一个问题除了“原问题”之外，往往还能对应出另一个问题，叫“对偶问题”。讲义用一个很经典的例子来说明：

原问题是“生产问题”：企业决定生产多少 I 型、II 型产品，**使利润最大化**。

对偶问题是“收购问题”：另一家公司给三种原料分别定价，**希望以最小代价收购企业全部原料**，而且这个收购价不能比企业自己拿这些原料去生产所能赚到的利润更低。

具体地，原问题写成：

$$\begin{aligned} & \max 13x_1 + 23x_2 \\ & \text{s.t.} \begin{cases} 5x_1 + 15x_2 \leq 480 \\ 4x_1 + 4x_2 \leq 160 \\ 35x_1 + 20x_2 \leq 1190 \\ x_1, x_2 \geq 0 \end{cases} \end{aligned}$$

对应的对偶问题是：

$$\begin{aligned} & \min 480y_1 + 160y_2 + 1190y_3 \\ & \text{s.t.} \begin{cases} 5y_1 + 4y_2 + 35y_3 \geq 13 \\ 15y_1 + 4y_2 + 20y_3 \geq 23 \\ y_1, y_2, y_3 \geq 0 \end{cases} \end{aligned}$$

这里的 y_1, y_2, y_3 就是三种原料的“单位定价”，**它们也叫对偶变量**；在经济意义上，它们的最优值叫**影子价格**，代表资源的隐含价值。

上界与下界问题：

我们不会平白无故地想到对偶，接下来探究到底为什么，我们会想要引出这个概念：

对于最大化问题，只要我们找到任意一个原问题的可行解，那么这个可行解对应的目标函数值就是最优值的一个下界，**因为最大化这个前提就注定了我们选的是所有值里最大的那一个，一定大于等于任意可行值。**

同理，**最小化问题里，原问题可行解可以给出上界。**

如何来寻找上界呢？当然可以用行变换来凑巧，凑出目标函数的样子，找到上界，但很显然这样很看运气，我们接下来来说寻找上界（对最大化型问题）的一般方法：

$$\begin{aligned} \text{maximize} \quad & z = 13x_1 + 23x_2 \\ \text{s.t.} \quad & 5x_1 + 15x_2 \leq 480 \quad (1) \\ & 4x_1 + 4x_2 \leq 160 \quad (2) \\ & 35x_1 + 20x_2 \leq 1190 \quad (3) \\ & x_1 \geq 0, x_2 \geq 0 \end{aligned}$$

利用约束做变换的一般情况

► 考虑 $y_1 \times (1) + y_2 \times (2) + y_3 \times (3)$

► $(5x_1 + 15x_2)y_1 + (4x_1 + 4x_2)y_2 + (35x_1 + 20x_2)y_3 \leq 480y_1 + 160y_2 + 1190y_3$

为保持 $\leq$ ，要求： $y_1, y_2, y_3 \geq 0$

我们利用行变换，把 y_1 、 y_2 、 y_3 当作三个约束的行变换系数，然后再整理式子，把 x 提出来， y_i 的线性组合做目标函数中的系数，然后 y_i 的线性组合匹配原问题的目标函数系数，同时原问题的约束右侧加起来就成为了新的上界目标函数。

不等式变换

$$\begin{aligned} (5x_1 + 15x_2)y_1 + (4x_1 + 4x_2)y_2 + (35x_1 + 20x_2)y_3 &\leq 480y_1 + 160y_2 + 1190y_3 \\ (5y_1 + 4y_2 + 35y_3)x_1 + (15y_1 + 4y_2 + 20y_3)x_2 &\leq 480y_1 + 160y_2 + 1190y_3 \end{aligned}$$

$$\begin{aligned} \min \quad & 480y_1 + 160y_2 + 1190y_3 \\ \text{s.t.} \quad & 5y_1 + 4y_2 + 35y_3 \geq 13 \\ & 15y_1 + 4y_2 + 20y_3 \geq 23 \\ & y_1 \geq 0, y_2 \geq 0, y_3 \geq 0 \end{aligned}$$

- 在所有上界中找最小的
- 匹配 $13x_1$ ，保持上界
- 匹配 $23x_2$ ，保持上界

于是我们惊人的发现，这个问题和原问题的形式非常相似，构成这样的关系：

原问题

$$\text{maximize} \quad c^T x$$

$$\text{s.t. } Ax \leq b$$

$$x \geq 0$$

对偶问题

$$\min \quad b^T y$$

$$\text{s.t. } A^T y \geq c$$

$$y \geq 0$$

- 这两个线性规划互为对偶
- 如果将一个问题看作原问题，另一个问题为该问题的对偶问题
- 将 y 记做对偶变量（对于左侧问题），其最优解又称为影子价格（shadow price），它代表了这些原材料的估计价值

刚刚我们的这个例子，约束全部为不等式约束，因此也要求 $y_1, y_2, y_3 \geq 0$ ；如果是等式约束，则没有这样的要求，实数即可，就比如下的形式（将原问题的第一个约束改为 $=$ ）：

$$(5x_1 + 15x_2)y_1 + (4x_1 + 4x_2)y_2 + (35x_1 + 20x_2)y_3 \leq 480y_1 + 160y_2 + 1190y_3$$

$$(5y_1 + 4y_2 + 35y_3)x_1 + (15y_1 + 4y_2 + 20y_3)x_2 \leq 480y_1 + 160y_2 + 1190y_3$$

$$\min \quad 480y_1 + 160y_2 + 1190y_3$$

$$\text{s.t. } 5y_1 + 4y_2 + 35y_3 \geq 13$$

$$15y_1 + 4y_2 + 20y_3 \geq 23$$

$$y_1 \in \mathbb{R}, y_2 \geq 0, y_3 \geq 0$$

► y_1 无约束

真正的对偶的理解：

本质可以把对偶看作是原问题最优值的界的证明（可以是上界，也可以是下届）。也就是说，原问题在找最优值，对偶在帮你证明这个最优值“不可能更好了”。在线性规划里，更妙的是：这个“证明器”最后不仅能给界，而且这个界常常正好等于原问题最优值。（后面会写：线性规划中原问题和对偶问题的最优值相等，这就是强对偶。）

原问题: $\max c^T x, \quad Ax \leq b, \quad x \geq 0$

对偶问题: $\min b^T y, \quad A^T y \geq c, \quad y \geq 0$

或者标准型:

原问题: $\min c^T x, \quad Ax = b, \quad x \geq 0$

对偶问题: $\max b^T y, \quad A^T y \leq c$ (变量无约束了, 因为原问题是等式约束)

原问题	对偶问题
$\min \quad c^T x$	$\text{maximize} \quad b^T y$
s.t. $a_i^T x \geq b_i, \quad i \in M_1,$	s.t. $y_i \geq 0, \quad i \in M_1$
$a_i^T x \leq b_i, \quad i \in M_2,$	$y_i \leq 0, \quad i \in M_2$
$a_i^T x = b_i, \quad i \in M_3,$	$y_i \text{ 无约束}, \quad i \in M_3$
$x_j \geq 0, \quad j \in N_1,$	$A_j^T y \leq c_j, \quad j \in N_1$
$x_j \leq 0, \quad j \in N_2,$	$A_j^T y \geq c_j, \quad j \in N_2$
$x_j \text{ 无约束}, \quad j \in N_3,$	$A_j^T y = c_j, \quad j \in N_3$

- ▶ a_i^T 为 A 矩阵第 i 行, A_j 为 A 矩阵第 j 列
- ▶ 每个原问题约束对应一个对偶问题变量
- ▶ 每个原问题变量对应一个对偶问题约束
- ▶ 等式约束对应无约束变量, 反之亦然

拉格朗日法乘子法的推导:

原问题有等式约束 $Ax = b$ 。我们给这组约束配上乘子 $p \in \mathbb{R}^m$, 得到拉格朗日函数:

$$L(x, p) = c^T x + p^T (b - Ax)$$

这里 p 叫**拉格朗日乘子**, 或者说写成“引入等式约束 $Ax = b$ 的对偶乘子 $p \in \mathbb{R}^m$ ”。本质上是在把“约束”搬进“目标函数”。原来必须硬性满足 $Ax = b$ 。

现在先把它写成一个残差 $b - Ax$, 再乘上一个向量 p , 加到目标函数里。

所以:

- $c^T x$ 是原目标函数
- $p^T (b - Ax)$ 是“约束违反程度”对应的修正项

固定一个 p 以后, 只对 $x \geq 0$ 做最小化:

$$g(p) = \min_{x \geq 0} (c^T x + p^T (b - Ax))$$

首先, $g(p)$ 的确是原问题最优值的下届:

设原问题最优解是 x^* 。因为 x^* 可行, 所以

$$Ax^* = b$$

$$b - Ax^* = 0$$

$$c^T x^* + p^T (b - Ax^*) = c^T x^*$$

而 $g(p)$ 是在所有 $x \geq 0$ 中取最小值, 所以当然有

$$g(p) \leq c^T x^* + p^T (b - Ax^*) = c^T x^*$$

最大化下届:

既然每一个 p 我们都能得出一个下界, 我们希望这个下界收的越紧越好, 也就是最大化这个下界:

$$\max_{p \in \mathbb{R}^m} g(p)$$

化简到理想形式:

从定义出发:

$$g(p) = \min_{x \geq 0} (c^T x + p^T (b - Ax))$$

$$g(p) = \min_{x \geq 0} (c^T x + p^T b - p^T Ax)$$

把与 x 无关的项 $p^T b$ 提出来:

$$g(p) = b^T p + \min_{x \geq 0} (c - A^T p)^T x$$

$$\min_{x \geq 0} (c - A^T p)^T x = \begin{cases} 0, & c - A^T p \geq 0 \\ -\infty, & \text{否则} \end{cases}$$

由于负无穷时没有意义，所以上面那个式子只能为 0！因此，最终我们的问题形式就变成了刚刚直接写出来的对偶式标准型：

$$\begin{aligned} & \max b^T p \\ & \text{s.t. } A^T p \leq c \end{aligned}$$

拉格朗日乘子法的思想就是把原问题的约束吸收到目标函数里，造出一个下界函数 $g(p)$ ；再在所有这样的下界里找最大的那个，这个“最大下界问题”就是对偶。

最小最大化思想——另一种视角

先把标准型原问题写成

$$\min c^T x \quad \text{s.t. } Ax = b, x \geq 0$$

然后给出等价表示：

$$\min_x \left(c^T x + \max_{y \in \mathbb{R}^m} y^T (b - Ax) \right) \quad \text{s.t. } x \geq 0,$$

接着再讨论交换 min 与 max 的顺序。

$$\max_y y^T (b - Ax)$$

能“逼出”约束 $Ax = b$ ，这里可以参考上节课的大 M 思想，这个最大化式子在公式里就像一个惩罚项，将 $Ax - b$ 压缩到 0。（不为 0 的话又变成了一个无穷问题，无意义了）

假设可以交换 max 和 min，那么问题变成：

$$\max_y \left(b^T y + \min_{x \geq 0} x^T (c - A^T y) \right).$$

y 就从“罚约束的乘子”变成了“外层要优化的变量”，这时候它就自然成了**对偶变量**。交换后我们先看式子的内层：

$$\min_{x \geq 0} x^T (c - A^T y) = \begin{cases} 0, & A^T y \leq c, \\ -\infty, & A^T y \not\leq c. \end{cases}$$

道理和上面一样，不能无意义。所以真正能留下的 y 必须满足：

$$A^T y \leq c,$$

而这时内层最小值正好是 0，于是整个问题就变成：

$$\max_y b^T y \quad \text{s.t. } A^T y \leq c,$$

拉格朗日推导是“先固定 y ，看它给出的下界”；最小最大化推导是“把整个问题看成一个 saddle point（鞍点）结构，再交换顺序得到对偶”。

$$\min_{x \geq 0} c^T x \quad \text{s.t. } Ax = b$$

既可以看成“带等式约束的最小化”，也可以看成：

$$\min_{x \geq 0} \max_y (c^T x + y^T (b - Ax))$$

这里的 y 是专门用来“检查并惩罚是否违反约束”的。一旦交换顺序， y 就变成外层变量，于是它不再只是一个惩罚参数，而变成了**对偶问题里的决策变量**。

记忆技巧

原问题	min	maximize	对偶问题
约束	$\geq b_i$	≥ 0	变量
	$\leq b_i$	≤ 0	
	$= b_i$	无约束	
变量	≥ 0	$\leq c_j$	约束
	≤ 0	$\geq c_j$	
	无约束	$= c_j$	

- ▶ 等式约束对应无约束变量，反之亦然
- ▶ 最小化问题变量的 $\geq$ 或者 $\leq$ 与最大化问题约束的 $\geq$ 或者 $\leq$ **相反**。
- ▶ 最小化问题约束的 $\geq$ 或者 $\leq$ 与最大化问题变量的 $\geq$ 或者 $\leq$ **相同**。

现在，我们先思考一下为什么会有这样的变形与对应：

首先，为什么对偶变量的正负与原问题的约束对应？

对偶的本质是为了给原问题找一个界，既然我们一直在 $\min$ 最小化问题里讨论，那么对偶的本质就是给最小化问题找一个下届，也就是对于这个最小化问题，在保持约束里面变量 $\geq$ 某个数的前提下，再把这个右侧的某个数尽可能地扩大。

所以我们 y 值根据原问题的约束符号选正负，就是因为要根据这个约束符号的方向，看 y 应该选关于 0 的什么方向把所有约束转化为大于等于。

其次，为什么对偶问题的约束与原问题的变量对应？

这个其实比上面那个要好理解一下，因为对偶变量组成的线性组合对应的是原问题的目标函数系数，对于那些 ≥ 0 的变量，如果我们在系数上不加以 $\leq$ 的上限，原问题无意义，能无限的大起来，同样对于那些 ≤ 0 的变量，系数上不加以 $\geq$ 的约束，会无限的小起来，所以这就解释了为什么对偶问题的约束符合和原问题变量符号是相反的。

弱对偶定理：

如果 x 是原问题的任意一个可行解， y 是对偶问题的任意一个可行解，那么一定有：

$$b^T y \leq c^T x$$

这就叫做**弱对偶定理**。同样，从弱对偶定理我们有这样的推论：

x 和 y 分别为原问题和对偶问题的可行解。：若 $c^T x = b^T y$, 则 x 和 y 为原问题和对偶问题最优解。

线性规划最优性条件：

- x 是原问题可行解
- y 是对偶问题可行解
- 原问题和对偶问题目标值相同

于是线性规划问题求解又转化成了这种形式：

- $Ax = b, x \geq 0$
- $A^T y \leq c$
- $b^T y = c^T x$

强对偶定理：

线性规划的原问题有最优解，则其对偶问题也有最优解，且原问题和对偶问题的最优值相等。

有时原问题不好解，但对偶问题更简单。因为强对偶成立，所以只要求出对偶最优值，就等于求出了原问题最优值。

如果找到了一个原可行解 x^* 和一个对偶可行解 y^* ，并且满足

$$c^T x^* = b^T y^*$$

那么由弱对偶和强对偶可知，它们一定分别是原问题和对偶问题的最优解。

互补松弛条件：

原问题		对偶问题	
min	$c^T x$	maximize	$b^T y$
s.t.	$Ax = b, x \geq 0$	s.t.	$A^T y \leq c$

设 x, y 分别是 (P) 和 (D) 的最优解，那么根据强对偶定理， $c^T x = y^T b$ 。此时我们回忆一下弱对偶定理证明中的不等式：

$$y^T b = y^T (Ax) = (y^T A)x \geq c^T x$$

$$\begin{cases} (y^T A - c^T)x = 0 \\ y^T (Ax - b) = 0 \end{cases}$$

(标准型情况下只用上面的式子就行，一般型两个式子都要用。因为标准型把一部分松弛变量提前消掉了，已经转化为了必然满足 $Ax = b$)

这两个式子都来源于上面的这个等式，一个是用 x 乘，一个是用 y 乘。我们称这两个等式为互补松弛条件 (complementary slackness)。若存在原始可行的 x 与对偶可行的 y 满足上面的两个等式，则称 x 和 y 满足 **互补松弛条件**。

设 x 和 y 为原问题和对偶问题的可行解，则 x 和 y 为最优解的充要条件是

$$(y^T A - c^T)x = 0$$

若某个对偶变量大于零，则对应的原约束必须紧；**若某个原约束有松弛量，则对应的对偶变量必须为零。反过来，若某个原变量大于零，则对应的对偶约束必须紧；若某个对偶约束有松弛量，则对应的原变量必须为零。**

互补松弛条件既可以作为最优性判别工具，也能帮助我们由原问题最优解推出对偶问题最优解，或反过来由对偶解推出原问题最优解。

所以，现在线性约束最优化条件我们又得到了一种新的等价形式：

- x 为原问题可行解
- y 为原问题可行解
- 满足所有互补松弛条件

所以我们现在判断一个解是否是最优就可以用这样的方法：

1. 验证 x 是否满足原问题的可行性
2. 若满足，列出对偶性与互补松弛约束
3. 然后求解，如果能接触解 y ，则 x 确实是原问题的最优解，否则 x 并不是原问题的最优解

举个栗子：

原问题：

$$\begin{aligned} \min \quad & x_1 - x_2 \\ \text{s.t.} \quad & -2x_1 + x_2 \leq 2 \\ & x_1 - 2x_2 \leq 2 \\ & x_1 + x_2 = 5 \\ & x_1, x_2 \geq 0 \end{aligned}$$

对偶问题：

$$\begin{aligned} \text{maximize} \quad & 2y_1 + 2y_2 + 5y_3 \\ \text{s.t.} \quad & -2y_1 + y_2 + y_3 \leq 1 \\ & y_1 - 2y_2 + y_3 \leq -1 \\ & y_1 \leq 0, \quad y_2 \leq 0, \quad y_3 \text{ 无约束} \end{aligned}$$

这组原—对偶问题的互补松弛条件为：

$$\begin{aligned} y_1(-2x_1 + x_2 - 2) &= 0 \\ y_2(x_1 - 2x_2 - 2) &= 0 \\ y_3(x_1 + x_2 - 5) &= 0 \\ x_1(-2y_1 + y_2 + y_3 - 1) &= 0 \\ x_2(y_1 - 2y_2 + y_3 + 1) &= 0 \end{aligned}$$

锥相关理论：

复习一下：凸集、凸函数、多面体、超平面与半空间、闭集

凸集合：一个集合 $S \subseteq R_n$ 若为凸集合，当且仅当对于任意的 $x, y \in S$ ，及任意 $\lambda \in [0, 1]$ ，满足 $\lambda x + (1 - \lambda)y \in S$ 。


直观理解：任取两个集合内的点，这两个点的连线线段全部在集合里

凸函数：一个函数 $f: R_n \rightarrow R$ 是凸函数如果满足：对任意 $x, y \in R_n$ 和任意 $\lambda \in [0, 1]$ ，成立：

$$f(\lambda x + (1 - \lambda)y) \leq \lambda f(x) + (1 - \lambda)f(y)$$

直观理解：函数上两点的连线线段也被包裹在函数里

多面体：一个集合若是多面体，则其可以表述为如下形式： $\{x \in R_n | Ax \geq b\}$ ，其中， $A \in R_{m \times n}$ 、 $b \in R_m$ 。当 $b = 0$ 时，多面体 P 更特殊地变成了一个凸多面锥。（因为 $b = 0$ 时，从原点“发射”出）




(我们依旧用这个当时学单纯形法的图来理解)

超平面&半空间: $a \in R_n$ 为非零向量, b 是一个标量,

- ▣ 称集合 $\{x \in R_n | ax = b\}$ 为一个超平面;
- ▣ 称集合 $\{x \in R_n | ax \geq b\}$ 为一个半空间。

超平面 $a^T x = \beta$ 的图示




直线 $a^T x = \beta$ 与向量 a 垂直.

沿 a 的方向是 $a^T x > \beta$, 反方向是 $a^T x < \beta$.

因为 $\langle a, x \rangle = a^T x = \beta$ (前面那个 $\langle \rangle$ 里的是在做内积, 也就是投影在 a 上都是 β 的集合, 那么就是垂直于 a 的一条线)

闭集: 一个集合 $S \in R_n$ 如果满足下列性质则被称为闭集: 对于任意序列 $x_1, x_2, \dots \in S$, 且收敛到 $x \in R_n$, 则有 $x \in S$ 成立

定理: 多面体是一个闭集 (毕竟是 $\geq$ 号)



(这个集合就不是一个闭集，因为在虚线那里，极限值不在集合里)

接下来进入锥理论！

锥其实可以看作是向量的非负组合！


锥：如果一个集合 $C \in R_n$ 被称为锥如果满足：

对于任意 $x \in C$ 和 $\lambda \geq 0$, 有 $\lambda x \in C$ 成立。


凸锥：如果一个集合 $C \in R_n$ 被称为凸锥如果它满足：

对于任意 $x_1, x_2 \in C$ 和 $\theta_1, \theta_2 \geq 0$, 有 $\theta_1 x_1 + \theta_2 x_2 \in C$ 成立。

凸锥在是一个锥的同时，还满足了是一个凸集。



(a) 多面体锥



(b) 非多面体锥

Remark: 多面体锥是凸锥。

Minkowski-Weyl 定理：

一个凸锥 C 是多面体，当且仅当它“能被有限地生成”，即这个凸锥被有限个向量 $b_1, \dots, b_m$ 生成：

$$C = \text{cone}(\mathbf{b}^1, \dots, \mathbf{b}^m) = \left\{ \sum_{i=1}^m \mathbf{b}^i y_i : y_i \geq 0, i = 1, \dots, m \right\}$$

直观理解：有限个向量生成代表他在几何上，有棱有角的，不是平滑的，那自然就是一个多面体锥


Carathéodory 定理:

一个多面体锥可以由一些基方向向量生成 (兜兜转转又回到了单纯形法)

举个栗子好理解一些:

凸多面体锥 C 可以看作:


1. 由基方向向量 $\begin{pmatrix} 1 \\ 2 \end{pmatrix}$ 和 $\begin{pmatrix} 2 \\ 1 \end{pmatrix}$ 生成
2. $\begin{pmatrix} -2 & 1 \\ 1 & -2 \end{pmatrix} x \leq 0$ 确定的区域



第一种表示方法就是基向量表示法, 第二个就是传统多面体锥表示法。

尖锥: 不包含直线的锥就是尖锥

超平面分离定理:



定理 0.5: 超平面分离定理 (点-集合分离)

果集合 $C \in \mathbb{R}^n$ 是一个非空、闭的、凸集 (nonempty, closed, convex), 且 $b \notin S$ (S 的外点), 那么存在向量 $a \in \mathbb{R}^n$ 使得

$$a^T b > \max_{x \in C} a^T x.$$

这种分离同样可以体现在分离两个集合上:

定理 0.6: 超平面分离定理 (集合-集合分离)

果集合 $S_1, S_2 \in \mathbb{R}^n$ 是非空、闭的、凸集 (nonempty, closed, convex), $S_1 \cap S_2 = \emptyset$, 且 S_2 有界 (bounded), 那么存在向量 $y \in \mathbb{R}^n$ 使得

$$\sup_{z \in S_1} y^T z < \min_{z \in S_2} y^T z.$$

Farka's Lemma:

首先对于一个线性问题, 只要我们能找到一个可行解, 那至少说明这个问题是可解的, 然而想要证明无解, 往往很复杂。

因此构造出一个对应的替代系统, 这个替代系统和原问题的是否有解情况刚好相反, 这样, 如果替代系统能找出一个解, 我们就可以马上得出 $\rightarrow$ 原问题无解。

定理 0.1: Farkas' Lemma

$A \in \mathbb{R}^{m \times n}, b \in \mathbb{R}^m$, 则下列说法有且只有一个成立

- ▶ 存在 $x \geq 0$ 使得 $Ax = b$ 成立。
- ▶ 存在 y 使得 $A^T y \leq 0$ 和 $b^T y > 0$ 成立。

也就是说要么原问题有解, 要么替代系统有解, 两个必须要二选一。

代数角度的理解:

原问题 $Ax = b, x \geq 0$ 的意义是, A 能够通过做非负的线性组合拼出 b , 接着我们来看替代问题, 把 y 看成一个“打分器”。对于任意向量 z , 它给出的分数是:

$$y^T z.$$

先看 $A^T y \leq 0$, 它展开后是:

$$A_1^T y \leq 0, A_2^T y \leq 0, \dots, A_n^T y \leq 0.$$

在评分器 y 看来, 所有基础向量 $A_1, \dots, A_n$ 的分数都不大于 0。

于是任何非负组合

$$Ax = x_1 A_1 + \cdots + x_n A_n, \quad x \geq 0$$

的分数也都不大于 0，因为

$$y^T(Ax) = x^T(A^T y) \leq 0.$$

所以**所有可由 A 的列向量非负拼出来的向量，分数都 ≤ 0** 。

再看 $b^T y > 0$ 这表示：目标向量 b 的分数却是正的。于是就矛盾了：

- 所有能拼出来的东西分数都 ≤ 0
- 但 b 的分数 > 0

因此 b 不可能是任何一个 Ax （其中 $x \geq 0$ ）。所以第二个替代问题的意义是：**它是一个“拼不出来”的证书。**

简单地从一个方向证明一下两个问题不能同时有解：

假设同时有

$$Ax = b, \quad x \geq 0$$

和

$$A^T y \leq 0, \quad b^T y > 0.$$

那么

$$b^T y = (Ax)^T y = x^T A^T y \leq 0$$

因为 $x \geq 0$ 、 $A^T y \leq 0$ 。但另一方面又要求

$$b^T y > 0,$$

矛盾。

线性系统 $Ax = b, \quad x \geq 0$ 若无解，则一定存在一个向量 y 作为“不可行证书”，使 $A^T y \leq 0$ 但 $b^T y > 0$ 。

几何角度的理解：

很容易看出, 如果原问题有解, 那么 b 落在 A 列向量组成的锥里, 然而如果替代问题有解, 那么意味着:

如果存在 y 使

$$A^T y \leq 0, \quad b^T y > 0,$$

- 对任意 $z = Ax \in K$, 都有

$$y^T z = y^T Ax = x^T A^T y \leq 0$$

- 但对 b , 有

$$y^T b > 0$$



于是超平面

$$y^T z = 0$$

就把 b 和整个锥 K 分到了两边:

- 锥 K 在 $y^T z \leq 0$ 一侧
- 点 b 在 $y^T z > 0$ 一侧

点 b 要么在锥 $K = \{Ax : x \geq 0\}$ 里, 要么能被一个超平面与这个锥严格分开。



资产定价与市场模型(Farkas的应用):

- $p = (p_1, \dots, p_n)^T$: 今天每种资产的价格
- $x = (x_1, \dots, x_n)^T$: 你买了多少份每种资产
- 初始成本: $p^T x$
- 未来有 m 种可能场景, 收益矩阵 $R \in \mathbb{R}^{m \times n}$
- 在场景 i 下, 组合 x 的总价值是 $w_i = r_i^T x$
- 所以所有场景下的回报向量是

$$W = Rx$$

第 i 行 r_i^T 代表: 如果未来发生的是**场景 i** , 那每个资产分别会给你多少钱。你买了组合 x 以后, 在每个未来场景下各自能拿到多少钱, 把这些钱排成一个向量, 就是 Rx 。

“存在套利”是:

$$Rx \geq 0, \quad p^T x < 0$$

(这个式子其实就可以看成, 向量 x 把 $R^T y : y \geq 0$ 和 P 分开了, **也就是锥外**)

我们可以解释成: 初始投入为负, 也就是不仅没花钱还拿了钱; 并且在所有未来场景下收益都非负。

显然这种白嫖行为还是挺流氓的 (bushi, 现在我们要确保金融市场是无套利的, 不然长此以往下去市场会崩溃的。结合刚刚学习的 Farkas 定理, 我们加以一定的限制:

$$\text{定价系统: } p = R^T y, y \geq 0$$

这里 y 常被称为状态价格向量 (State Price Vector)。这和 Farkas 定理高度相似, 如果定价可以写成这样, **那么一定在一个锥里**, 也就是价格 p 能够被表示为收益矩阵列向量的非负线性组合, 这刚好和原问题是互斥的情况

(因为只有两种情况, 要么锥里要么锥外, 要么价格向量 p 落在锥 $\{R^T y : y \geq 0\}$ 中; 要么存在某个组合 x 将点 p 与该锥分离, 此时该 x 正对应一个套利策略。)

对偶单纯形法 (死脑子快记啊) :

普通单纯形法可以理解成:

“我们已经站在原问题可行域里了, **最小比值法 + 沿着边走**, 让目标越来越好, 走向最优值。”

对偶单纯形法则是:

现在还没站进原问题可行域，但已经有对偶问题可行。我们要做的是：**在不丢掉对偶可行的情况下，一步一步把修正进原问题可行域。**

一旦右端项全非负，我们就同时满足原问题可行 + 对偶可行，于是直接最优。

对偶单纯形法的操作步骤：

一、找到一个“坏行”：

如果当前

$$x_B = A_B^{-1}b$$

里存在负分量，就任选一个负的，比如第 ℓ 个满足

$$x_B(\ell) < 0.$$

这就是**转轴行**。我们这一步的目的就是找出负的基变量，并进行修复。

以这个为栗子：

	x_1	x_2	x_3	x_4	x_5	
B	2	6	10	0	0	0
x_4	-2	4	1	1	0	2
x_5	4	-2	-3	0	1	-1

二、只选负系数列入基

因为现在是对偶单纯形法嘛，一切和传统的单纯形法总是呈现出“对偶性”，传统单纯形法选择检验数为负，所以这里就选解为负的，传统单纯形法利用解的值采取最小比值法，这里利用检验数进行最小比值法。

► 由于 $x_{B(2)} < 0$ ，选择第 2 行作为转轴行，其中 x_2 与 x_3 所在列的元素为负，通过计算知，选择 x_2 作为入基变量。

► 进行基变换后得：

考虑如下单纯形表，进行基变换

	x_1	x_2	x_3	x_4	x_5	
B	14	0	1	0	3	-3
x_4	6	0	-5	1	2	0
x_2	-2	1	3/2	0	-1/2	1/2

► 由于所有变量均非负，因此我们找到了原问题最优解

三、用最小比值规则选入基列

此处的规则是：

$$\frac{\bar{c}_j}{|v_j|} = \min_{i:v_i < 0} \left\{ \frac{\bar{c}_i}{|v_i|} \right\}.$$

选到的这列就是入基列，当前行对应的基变量出基。这个规则的作用是：

在修坏的右端项时，**仍然保证检验数继续非负。**

四、迭代

前三步完成后，会得到新的单纯形表，不断迭代计算，直到进入原问题的可行域。