

上海财经大学

信息管理与工程学院

牛顿法

优化理论与算法 第八章

王震

2026

本讲主线

前面已经学习了梯度下降法、线搜索、光滑凸优化的收敛速度，以及动量法如何利用历史信息改进一阶方法。

本讲进入二阶方法，回答一个自然问题：

如果能看到函数的局部曲率，能否更快地到达最优点？

模型

用二阶 Taylor 展开构造局部二次模型。

方向

通过解线性方程组得到 Newton 方向。

收敛

在最优点附近具有局部二次收敛。

本章目录

从一阶方法到二阶方法

二阶 **Taylor** 近似与 **Newton** 方向

牛顿法与阻尼牛顿法

收敛性质与计算代价

小结与下一讲

目录

从一阶方法到二阶方法

二阶 **Taylor** 近似与 **Newton** 方向

牛顿法与阻尼牛顿法

收敛性质与计算代价

小结与下一讲

回顾：梯度下降只使用一阶信息

对无约束优化问题

$$\min_{x \in \mathbb{R}^n} f(x),$$

梯度下降法采用

$$x^{k+1} = x^k - \alpha_k \nabla f(x^k).$$

- ▶ $\nabla f(x^k)$ 给出当前位置函数上升最快的方向。
- ▶ 负梯度方向是局部一阶近似下的下降方向。
- ▶ 但它没有区分不同坐标方向上的曲率尺度。

核心瓶颈

当目标函数的水平集非常狭长时，负梯度方向可能频繁横穿谷底，导致 zig-zag 和慢收敛。

曲率信息为什么重要


考虑二次函数

$$f(x) = \frac{1}{2}x^T Qx - b^T x, \quad Q \succ 0.$$

梯度与 Hessian 分别为

$$\nabla f(x) = Qx - b, \quad \nabla^2 f(x) = Q.$$

- ▶ Q 的特征值刻画不同方向上的曲率；
- ▶ 条件数大时，GD 需要兼顾陡峭方向与平坦方向；
- ▶ 如果能利用 Q ，可以自动校正不同方向的尺度。



目录

从一阶方法到二阶方法

二阶 **Taylor** 近似与 **Newton** 方向

牛顿法与阻尼牛顿法

收敛性质与计算代价

小结与下一讲

二阶 Taylor 展开

在 x^k 附近, 用二阶 Taylor 展开近似目标函数:

$$f(x^k + d) \approx f(x^k) + \nabla f(x^k)^T d + \frac{1}{2} d^T \nabla^2 f(x^k) d.$$

定义 2.1: 局部二次模型

记 $g_k = \nabla f(x^k)$, $G_k = \nabla^2 f(x^k)$, 定义

$$m_k(d) = f(x^k) + g_k^T d + \frac{1}{2} d^T G_k d.$$

牛顿法的思想是: 用 $m_k(d)$ 近似原问题在 x^k 附近的行为。

当 $G_k \succ 0$ 时, $m_k(d)$ 是关于 d 的严格凸二次函数。

从二次模型推出 **Newton** 方向

若 $G_k \succ 0$, 则 Newton 方向定义为二次模型的极小点:

$$d^k = \arg \min_d m_k(d).$$

对 d 求导并令其为零:

$$\nabla_d m_k(d) = g_k + G_k d = 0.$$

因此 Newton 方向满足

$$G_k d^k = -g_k.$$

若 G_k 可逆, 则

$$d^k = -G_k^{-1} g_k = -[\nabla^2 f(x^k)]^{-1} \nabla f(x^k).$$

计算提醒

实际实现中通常解线性方程组 $G_k d^k = -g_k$, 而不是显式计算 G_k^{-1} 。

一维视角：从驻点方程看 **Newton**

在一维情形中，找极小点常常先看一阶必要条件：

$$f'(x) = 0.$$

也就是说，我们可以把“找极小点”暂时改写成“找导数函数的零点”。

令 $\phi(x) = f'(x)$ 。对方程 $\phi(x) = 0$ 使用求根的 Newton 法：

$$x^{k+1} = x^k - \frac{\phi(x^k)}{\phi'(x^k)} = x^k - \frac{f'(x^k)}{f''(x^k)}.$$

求根视角

在 x^k 处画 f' 的切线，切线与横轴的交点就是 x^{k+1} 。

优化视角

在 x^k 附近用一个抛物线近似 f ，抛物线最低点就是 x^{k+1} 。

多维 Newton 法可以看作对方程组 $\nabla f(x) = 0$ 的 Newton 求根法。

Newton 方向何时是下降方向

线搜索能发挥作用的前提是 d^k 是下降方向，即

$$g_k^T d^k < 0.$$

若 $G_k = \nabla^2 f(x^k) \succ 0$, Newton 方向满足

$$G_k d^k = -g_k, \quad d^k = -G_k^{-1} g_k.$$

于是

$$g_k^T d^k = -g_k^T G_k^{-1} g_k < 0, \quad g_k \neq 0.$$

关键结论

当 Hessian 正定时，Newton 方向一定是下降方向；若 Hessian 不正定，这个结论可能失效。

Newton 减量：局部模型预测的下降量

对二次模型

$$m_k(d) = f(x^k) + g_k^T d + \frac{1}{2} d^T G_k d,$$

Newton 方向 $d^k = -G_k^{-1} g_k$ 给出的模型下降量为

$$m_k(0) - m_k(d^k) = \frac{1}{2} g_k^T G_k^{-1} g_k.$$

定义 2.2: Newton 减量

当 $G_k \succ 0$ 时，定义

$$\lambda_k^2 = g_k^T G_k^{-1} g_k = -g_k^T d^k.$$

它刻画当前点在局部二次模型下距离最优的程度。

在凸优化中常用 $\lambda_k^2/2 \leq \varepsilon$ 作为停止准则之一。

Newton 方向的几何解释

Newton 方向可以看作经过曲率校正的一阶方向：


$$d^k = -G_k^{-1} g_k.$$

矩阵 G_k^{-1} 会根据不同方向上的曲率缩放梯度。

- ▶ 曲率大的方向：步子自动缩小；
- ▶ 曲率小的方向：步子相对放大；
- ▶ 对二次函数而言，这种校正恰好指向最优解。

直觉

GD 问“往哪里下降最快”；Newton 问“局部二次模型的最低点在哪里”。



具体例子：梯度方向与 **Newton** 方向

考虑二次函数

$$f(x_1, x_2) = 5x_1^2 + \frac{1}{2}x_2^2, \quad x^k = (1, 1)^T.$$

它在 x_1 方向很陡，在 x_2 方向较平缓。

$$g_k = \begin{bmatrix} 10 \\ 1 \end{bmatrix}, \quad G_k = \begin{bmatrix} 10 & 0 \\ 0 & 1 \end{bmatrix}.$$

$$\text{负梯度方向: } -g_k = \begin{bmatrix} -10 \\ -1 \end{bmatrix}.$$

$$d_N^k = -G_k^{-1}g_k = -\begin{bmatrix} 1/10 & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} 10 \\ 1 \end{bmatrix} = \begin{bmatrix} -1 \\ -1 \end{bmatrix}.$$

Newton 步直接给出

$$x^k + d_N^k = (0, 0)^T = x^*.$$

它主要朝 x_1 方向走，容易受“大曲率方向”支配。

课堂口径

负梯度只看“哪里下降最快”；Newton 方向还会问“这个方向有多弯”，所以会自动缩放各坐标方向。

目录

从一阶方法到二阶方法

二阶 **Taylor** 近似与 **Newton** 方向

牛顿法与阻尼牛顿法

收敛性质与计算代价

小结与下一讲

标准牛顿法

标准牛顿法使用全步长更新：

$$x^{k+1} = x^k + d^k, \quad \nabla^2 f(x^k) d^k = -\nabla f(x^k).$$

算法：标准牛顿法

给定初始点 x^0 。对 $k = 0, 1, 2, \dots$ ：

1. 计算 $g_k = \nabla f(x^k)$, $G_k = \nabla^2 f(x^k)$;
2. 解线性方程组 $G_k d^k = -g_k$;
3. 更新 $x^{k+1} = x^k + d^k$;
4. 若 $\|g_k\|$ 足够小, 则停止。

标准牛顿法在最优点附近非常快，但远离最优点时不一定稳定。

应用案例一：非线性曲线拟合

很多实验数据不是直线关系。例如药物浓度衰减、设备老化曲线、市场增长曲线，常用模型

$$y_i \approx ae^{bt_i}.$$

目标是选择参数 a, b ，使预测值和观测值尽量接近：

$$\min_{a,b} f(a, b) = \frac{1}{2} \sum_{i=1}^m (ae^{bt_i} - y_i)^2.$$

为什么有 **Newton** 特色

这是非线性最小二乘问题。GD 只看当前梯度；**Newton** 类方法会利用残差对参数的局部曲率信息，因此常常用更少迭代找到好参数。

Gauss-Newton: Newton 思想的实际版本

把残差记为

$$r_i(a, b) = ae^{bt_i} - y_i, \quad f(a, b) = \frac{1}{2} \|r(a, b)\|^2.$$

令 J 为残差向量 r 对参数 (a, b) 的 Jacobian 矩阵，也就是一阶导数组成的矩阵。

Gauss-Newton 不直接形成完整 Hessian，而是解

$$J^T J d = -J^T r.$$

名字解释

可以理解为：针对最小二乘问题，把 Newton 方程近似成一个更容易求解的线性最小二乘方程。

实际用途

曲线拟合、传感器标定、相机标定、SLAM、工程参数估计中都常见。

应用案例二：内点法中的 **Newton** 步

带约束优化在实际中很常见，例如投资组合、资源分配、生产计划：

$$\min_x \frac{1}{2}x^T Qx - c^T x, \quad x_i > 0, \quad \sum_i x_i = 1.$$

约束 $x_i > 0$ 不能简单忽略。内点法把它放进 barrier 目标：

$$\min_x \frac{1}{2}x^T Qx - c^T x - \mu \sum_i \log x_i, \quad \sum_i x_i = 1.$$

为什么有 **Newton** 特色

barrier 项 $-\log x_i$ 在边界附近曲率很大。Newton 法能利用 Hessian 自动感知这些曲率，避免步子冲出可行区域。

内点法：Newton 步解的不是普通方程

由于还有等式约束 $\sum_i x_i = 1$ ，每一步通常要求解 KKT 线性系统：

$$\begin{bmatrix} H_k & A^T \\ A & 0 \end{bmatrix} \begin{bmatrix} d^k \\ \Delta\lambda \end{bmatrix} = - \begin{bmatrix} \nabla f_\mu(x^k) + A^T \lambda^k \\ Ax^k - b \end{bmatrix}.$$

这里 $H_k = \nabla^2 f_\mu(x^k)$ ， A 表示等式约束。

课堂口径

现代优化求解器里，Newton 法常常不是单独出现，而是作为内点法、SQP 等高级算法中的“核心线性代数步骤”。

二次函数上的一步收敛

对严格凸二次函数

$$f(x) = \frac{1}{2}x^T Qx - b^T x, \quad Q \succ 0,$$

有

$$g_k = Qx^k - b, \quad G_k = Q.$$

Newton 方程为

$$Qd^k = -(Qx^k - b).$$

因此

$$x^{k+1} = x^k + d^k = x^k - Q^{-1}(Qx^k - b) = Q^{-1}b = x^*.$$

推论 3.1: 严格凸二次函数

对任意初始点 x^0 , 标准牛顿法在严格凸二次函数上一步达到全局最优解。

标准 Newton 可能失败：一维例子

Newton 法依赖局部二次模型。若初始点远离极小点，模型可能给出很差的预测。

考虑

$$f(x) = x^4 - 3x^2, \quad f'(x) = 4x^3 - 6x, \quad f''(x) = 12x^2 - 6.$$

Newton 更新为

$$x^{k+1} = x^k - \frac{4(x^k)^3 - 6x^k}{12(x^k)^2 - 6}.$$

- ▶ 当 $f''(x^k) > 0$ 时，局部二次模型是凸的；
- ▶ 当 $f''(x^k) < 0$ 时，局部二次模型是凹的；
- ▶ 此时 Newton 步可能不是下降步，函数值可能上升。

图像解释：为什么这一步会变差

对

$$f(x) = x^4 - 3x^2$$

有两个局部极小点 $x = \pm\sqrt{3/2}$ ，中间 $x = 0$ 是局部极大点。

取 $x^k = 0.5$ ，则

$$f'(0.5) = -2.5, \quad f''(0.5) = -3.$$


Newton 方向为

$$d^k = -\frac{f'(0.5)}{f''(0.5)} = -\frac{-2.5}{-3} \approx -0.833.$$

判断是否下降要看

$$f'(x^k)d^k \approx (-2.5)(-0.833) > 0.$$

所以这一步不是下降方向，并且



非凸问题中的鞍点风险

对非凸函数，满足 $\nabla f(x) = 0$ 的点不一定是极小点，也可能是极大点或鞍点。

以二维函数

$$f(x_1, x_2) = x_1^2 - x_2^2$$

为例：

$$\nabla f(x) = \begin{bmatrix} 2x_1 \\ -2x_2 \end{bmatrix}, \quad \nabla^2 f(x) = \begin{bmatrix} 2 & 0 \\ 0 & -2 \end{bmatrix}.$$

Hessian 不正定，Newton 方程仍可解，但方向不一定对应下降。

例如取 $x^k = (1, 2)^T$ ，则

$$g_k = \begin{bmatrix} 2 \\ -4 \end{bmatrix}, \quad d^k = -G_k^{-1} g_k = \begin{bmatrix} -1 \\ -2 \end{bmatrix}.$$

此时

$$g_k^T d^k = 2(-1) + (-4)(-2) = 6 > 0,$$

非凸问题中的鞍点风险

所以 d^k 不是下降方向。标准 Newton 全步还会直接到达

$$x^k + d^k = (0, 0)^T,$$

而 $(0, 0)$ 正是鞍点。

教学要点

Newton 法本质上是在求解 $\nabla f(x) = 0$ ，因此它会快速逼近驻点；但在非凸问题中，驻点不必是局部极小点。

为什么需要阻尼 Newton

如果 x^k 远离最优点，二阶 Taylor 模型只在局部有效。全步长

$$x^{k+1} = x^k + d^k$$

可能导致函数值不降反升。

可能问题

- ▶ 二次模型只在局部准确；
- ▶ Hessian 可能不是正定；
- ▶ Newton 方向可能不是下降方向。

常用修正

- ▶ 使用线搜索选择步长；
- ▶ 必要时修正 Hessian；
- ▶ 或使用信赖域方法。

本讲重点介绍最常见的线搜索版本：阻尼牛顿法。

阻尼牛顿法与 Armijo 线搜索

阻尼牛顿法采用

$$x^{k+1} = x^k + \alpha_k d^k, \quad \alpha_k \in (0, 1].$$

其中 d^k 仍由 Newton 方程给出:

$$\nabla^2 f(x^k) d^k = -\nabla f(x^k).$$

Armijo 条件

选择 α_k 使

$$f(x^k + \alpha_k d^k) \leq f(x^k) + c \alpha_k \nabla f(x^k)^T d^k, \quad c \in (0, 1).$$

- ▶ 远离最优点时，线搜索保证充分下降；
- ▶ 靠近最优点时，通常会接受 $\alpha_k = 1$ ；
- ▶ 因而阻尼 Newton 常呈现“先稳健、后快速”的行为。

修正牛顿法：让方向重新可用

当 G_k 不正定或接近奇异时，可以用修正后的 Hessian 计算方向：

$$(G_k + \mu_k I)d^k = -g_k, \quad \mu_k \geq 0.$$

作用

- ▶ 提高矩阵正定性；
- ▶ 避免过大或不稳定步长；
- ▶ 使方向更接近下降方向。

直觉

μ_k 大时更像梯度下降； μ_k 小时更像标准 Newton。

这类思想与 Levenberg-Marquardt 方法、信赖域方法有密切关系。

信赖域 **Newton**: 控制模型可信范围

线搜索先确定方向，再沿方向找步长；信赖域方法则直接限制二次模型的适用范围：

$$\min_d \quad g_k^T d + \frac{1}{2} d^T G_k d, \quad \|d\| \leq \Delta_k.$$

- ▶ Δ_k 是当前信赖域半径；
- ▶ 若模型预测与真实下降一致，就增大 Δ_k ；
- ▶ 若模型预测不可靠，就缩小 Δ_k 。

对比

阻尼 Newton 通过步长 α_k 控制更新幅度；信赖域 Newton 通过约束 $\|d\| \leq \Delta_k$ 控制二次模型的使用范围。

两种全局化策略的比较

策略	基本思想	适用特点
线搜索	先给出方向，再选择步长 α_k	实现简单，常与下降方向配合使用
信赖域	在可信半径内求解二次模型	对不定 Hessian 和非凸情形更稳健

共同目标

二者都是为了把局部二次模型转化为具有全局稳定性的迭代算法。

目录

从一阶方法到二阶方法

二阶 **Taylor** 近似与 **Newton** 方向

牛顿法与阻尼牛顿法

收敛性质与计算代价

小结与下一讲

局部二次收敛

Newton 法最重要的性质是局部二次收敛。

定理 4.1: 局部二次收敛（非正式表述）

设 f 二阶连续可微, x^* 满足

$$\nabla f(x^*) = 0, \quad \nabla^2 f(x^*) \succ 0.$$

若 Hessian 在 x^* 附近 Lipschitz 连续, 并且初始点足够接近 x^* , 则标准牛顿法产生的序列满足

$$\|x^{k+1} - x^*\| \leq C \|x^k - x^*\|^2.$$

这意味着当误差已经较小时, 下一步误差大约与当前误差的平方同阶, 收敛速度非常快。

收敛速度：线性、超线性与二次

设 $e_k = \|x^k - x^*\|$ 。常见收敛速度可用误差序列描述：

类型	典型形式
线性收敛	$e_{k+1} \leq qe_k, \quad 0 < q < 1$
超线性收敛	$\frac{e_{k+1}}{e_k} \rightarrow 0$
二次收敛	$e_{k+1} \leq Ce_k^2$

Newton 法的局部二次收敛意味着：当 e_k 已经较小时，误差会以近似“平方”的速度下降。

与梯度下降的理论速度对比

对 L -光滑、 μ -强凸函数，固定步长梯度下降满足典型线性收敛界：

$$f(x^k) - f(x^*) \leq \left(1 - \frac{\mu}{L}\right)^k (f(x^0) - f(x^*)).$$

记条件数 $\kappa = L/\mu$ ，则收敛因子约为 $1 - 1/\kappa$ 。

病态问题的影响

κ 越大，水平集越狭长，GD 收敛越慢；Newton 法通过 Hessian 对不同曲率方向进行尺度校正，在局部可显著减弱这种影响。

代价是：Newton 每步需要更昂贵的二阶信息和线性代数计算。

二次收敛: Taylor 展开怎么用

设 x^* 为严格局部极小点, 令

$$e_k = x^k - x^*, \quad g_k = \nabla f(x^k), \quad G_k = \nabla^2 f(x^k).$$

由于

$$\nabla f(x^*) = 0,$$

对梯度函数 ∇f 在 x^k 处作一阶 Taylor 展开:

$$0 = \nabla f(x^*) = \nabla f(x^k) + \nabla^2 f(x^k)(x^* - x^k) + r_k.$$

这里 r_k 是 Taylor 余项。若 Hessian 在最优点附近 Lipschitz 连续, 则

$$\|r_k\| \leq C_1 \left\| x^* - x^k \right\|^2 = C_1 \|e_k\|^2.$$

因为 $x^* - x^k = -e_k$, 上式等价于

$$g_k = G_k e_k - r_k.$$

这一步的含义

梯度 g_k 的主要部分是 $G_k e_k$, 误差只剩二阶小量 r_k 。

二次收敛：误差为什么会平方变小

Newton 更新给出

$$G_k d^k = -g_k, \quad x^{k+1} = x^k + d^k.$$

因此误差满足

$$e_{k+1} = x^{k+1} - x^* = e_k - G_k^{-1} g_k.$$

代入 $g_k = G_k e_k - r_k$:

$$e_{k+1} = e_k - G_k^{-1} (G_k e_k - r_k) = G_k^{-1} r_k.$$

若 x^k 足够接近 x^* , 则 G_k 可逆且 $\|G_k^{-1}\| \leq C_2$ 。于是

$$\|e_{k+1}\| \leq \|G_k^{-1}\| \|r_k\| \leq C \|e_k\|^2.$$

直观理解

Newton 步把主要的一阶误差 $G_k e_k$ 抵消掉, 下一步误差只来自 Taylor 余项, 所以是二阶小量。

每步计算代价

Newton 法的快收敛来自丰富的二阶信息，但每步代价较高。

步骤	典型代价	说明
计算梯度 g_k	依问题而定	一阶信息
计算 Hessian G_k	约 $\mathcal{O}(n^2)$	存储也需 $\mathcal{O}(n^2)$
解 $G_k d^k = -g_k$	约 $\mathcal{O}(n^3)$	稠密 Cholesky 或 LU
线搜索	多次函数值计算	提高全局稳定性

适用场景

Newton 法适合中小规模、高精度、Hessian 容易计算且正定性较好的光滑优化问题。

如何求解 **Newton** 方程

Newton 步的核心是线性方程组

$$G_k d^k = -g_k.$$

不同问题结构对应不同求解方式。

情形	常见方法
$G_k \succ 0$ 且中小规模	Cholesky 分解
G_k 不定	LDL ^T 分解或 Hessian 修正
大规模稀疏问题	迭代法，如共轭梯度及其变体
Hessian 不便显式形成	使用 Hessian-vector product

实际算法通常关注“解线性系统”，而不是显式求逆。

Cholesky 分解：正定情形的常用做法

当 $G_k \succ 0$ 时，可以把 Hessian 分解为

$$G_k = LL^T,$$

其中 L 是下三角矩阵，且对角线元素为正。

Newton 方程

$$G_k d^k = -g_k$$

就变成

$$LL^T d^k = -g_k.$$

求解顺序

不需要计算 G_k^{-1} 。先解一个下三角系统，再解一个上三角系统：

$$Ly = -g_k, \quad L^T d^k = y.$$

Cholesky 求 Newton 步：二维小例子

设

$$G_k = \begin{bmatrix} 4 & 2 \\ 2 & 3 \end{bmatrix}, \quad g_k = \begin{bmatrix} 6 \\ 5 \end{bmatrix}.$$

因为 $G_k \succ 0$, 可作 Cholesky 分解:

$$G_k = LL^T, \quad L = \begin{bmatrix} 2 & 0 \\ 1 & \sqrt{2} \end{bmatrix}.$$

第一步: 解 $Ly = -g_k$

第二步: 解 $L^T d^k = y$

$$\begin{bmatrix} 2 & 0 \\ 1 & \sqrt{2} \end{bmatrix} \begin{bmatrix} y_1 \\ y_2 \end{bmatrix} = \begin{bmatrix} -6 \\ -5 \end{bmatrix}, \quad y = \begin{bmatrix} -3 \\ -\sqrt{2} \end{bmatrix}.$$

$$\begin{bmatrix} 2 & 1 \\ 0 & \sqrt{2} \end{bmatrix} \begin{bmatrix} d_1 \\ d_2 \end{bmatrix} = \begin{bmatrix} -3 \\ -\sqrt{2} \end{bmatrix}, \quad d^k = \begin{bmatrix} -1 \\ -1 \end{bmatrix}.$$

所以本步更新为 $x^{k+1} = x^k + (-1, -1)^T$ 。

Inexact Newton: 为什么可以“不精确”

Newton 步来自线性方程组

$$G_k d^k = -g_k.$$

在大规模问题中, 把这个方程精确解到机器精度可能很贵, 而且远离最优点时也没必要。

Inexact Newton 只要求残差足够小:

$$\|G_k d^k + g_k\| \leq \eta_k \|g_k\|, \quad 0 \leq \eta_k < 1.$$

怎么理解残差

$G_k d^k + g_k$ 衡量“这个 d^k 离真正 Newton 方程的解还差多少”。 η_k 越小, 说明线性系统解得越精确。

Inexact Newton: 精度可以逐步提高

一个常见策略是:

- ▶ 远离最优点时, η_k 取大一些, 方向大致正确即可;
- ▶ 接近最优点时, η_k 逐渐变小, 把 Newton 方程解得更准;
- ▶ 这样能节省早期计算, 同时保留后期快速收敛。

阶段	计算想法
----	------

早期	目标函数还很粗糙, 线性系统不必求太准
----	---------------------

后期	已接近最优点, 精确 Newton 步更有价值
----	-------------------------

CG 是什么：共轭梯度法

CG 是 Conjugate Gradient，中文常译为“共轭梯度法”。它是解正定线性方程组

$$Gd = -g, \quad G \succ 0$$

的一种迭代方法。

它在做什么

CG 不直接分解矩阵，而是不断改进 d ，让残差 $Gd + g$ 逐步变小。

为什么有用

它主要需要矩阵-向量乘法 Gv ，适合大规模稀疏问题，甚至不必显式存下完整 Hessian。

等价地，CG 在逐步最小化二次函数

$$q(d) = \frac{1}{2}d^T Gd + g^T d.$$

Newton-CG: 用 CG 近似求 Newton 方向

Newton-CG 的基本流程是:

1. 计算 $g_k = \nabla f(x^k)$;
2. 用 CG 近似求解 $G_k d^k = -g_k$;
3. 结合线搜索或信赖域, 更新 $x^{k+1} = x^k + \alpha_k d^k$ 。

大规模问题中的关键点

很多时候不显式形成 G_k , 只提供 Hessian-vector product: 给定向量 v , 能算 $G_k v$ 即可运行 CG。

若 Hessian 不正定, CG 过程中还可能发现负曲率方向, 这也是非凸优化中需要修正或信赖域方法的原因。

GD 与 Newton 的对比

方法	优点	局限
梯度下降	每步便宜，只需梯度；实现简单；适合大规模问题。	对病态问题敏感，收敛速度依赖条件数。
牛顿法	利用二阶曲率；局部二次收敛；对二次函数一步收敛。	需要 Hessian；每步代价高；远离最优点时需阻尼或修正。

一句话总结

GD 是便宜但可能慢的一阶方法；Newton 是昂贵但局部非常快的二阶方法。

目录

从一阶方法到二阶方法

二阶 **Taylor** 近似与 **Newton** 方向

牛顿法与阻尼牛顿法

收敛性质与计算代价

小结与下一讲

本讲小结

- ▶ 牛顿法从二阶 Taylor 近似出发，将原问题局部替换为二次模型。

- ▶ Newton 方向由线性方程组

$$\nabla^2 f(x^k) d^k = -\nabla f(x^k)$$

给出，本质上是经过曲率校正的下降方向。

- ▶ 在严格凸二次函数上，标准牛顿法一步到达最优点。
- ▶ 在一般非线性问题上，阻尼 Newton 结合线搜索可提高全局稳定性。
- ▶ Newton 法局部二次收敛，但 Hessian 计算、存储和求解代价较高。

自然问题：能否少用 **Hessian**？

Newton 法的方向为

$$d^k = -[\nabla^2 f(x^k)]^{-1} \nabla f(x^k).$$

它的主要瓶颈是 **Hessian**：

计算贵、存储贵、求解贵。

下一讲关注一个折中思想：

不直接计算 **Hessian**，而是用迭代中的梯度变化逐步近似曲率。

下一讲

拟牛顿法：割线条件、BFGS 更新与 L-BFGS。