

上海财经大学

信息管理与工程学院

约束优化与投影梯度法

优化理论与算法 后续专题 第 1 讲：从可行域到算法

王震

2026

本讲主线

前面主要讨论无约束优化：

$$\min_{x \in \mathbb{R}^n} f(x).$$

从这一讲开始，我们考虑更实际的情形：

$$\min_{x \in C} f(x),$$

其中 C 是可行域，例如预算、非负性、容量、概率分布等约束。

核心问题

普通梯度下降只想着让 $f(x)$ 变小，但约束优化还要求每一步都要合法：

$$x^k \in C, \quad x^{k+1} \in C.$$

本讲聚焦最直接的一阶处理方法：

$$x^{k+1} = \Pi_C(x^k - \alpha_k \nabla f(x^k)).$$

本讲学习目标

- ▶ 理解约束优化中“可行域”的含义；
- ▶ 知道普通 GD 为什么会走出可行域；
- ▶ 掌握投影算子 Π_C 的定义和几何直觉；
- ▶ 会计算几类简单集合上的投影；
- ▶ 理解投影梯度法的算法步骤、停止准则和适用场景。

课堂口径

把 C 想成“规则集合”：目标函数告诉我们想往哪里走，约束集合告诉我们哪些位置是允许的。

为什么普通 GD 可能失效

普通梯度下降为

$$x^{k+1} = x^k - \alpha_k \nabla f(x^k).$$

它默认 x^{k+1} 可以落在任意位置。

若要求

$$x \in C,$$

则一步 GD 后可能出现

$$x^k - \alpha_k \nabla f(x^k) \notin C.$$

例子

投资组合：

$$x_i \geq 0, \quad \sum_i x_i = 1.$$

普通 GD 可能产生负权重或总和不为

需要新工具

既要下降目标函数，又要保持可行性。

$$x^k \in C, \quad x^{k+1} \in C.$$

一个一维例子：最优点可以在边界

考虑

$$\min_{0 \leq x \leq 2} f(x) = (x - 3)^2.$$

如果没有约束，最优点是 $x = 3$ ，但它不满足 $x \leq 2$ 。

无约束最优

$$x_{\text{un}} = 3, \quad f(3) = 0.$$

这个点最好，但不合法。

约束最优

$$x^* = 2, \quad f(2) = 1.$$

在所有合法点里，2 已经最靠近 3。

注意： $f'(2) = 2(2 - 3) = -2 \neq 0$ 。边界最优点不一定满足梯度为零。

常见约束集合

约束集合	含义与例子
盒约束	$l_i \leq x_i \leq u_i$, 例如价格、库存、参数上下界
非负约束	$x_i \geq 0$, 例如流量、概率、资源数量
球约束	$\ x\ _2 \leq R$, 控制模型复杂度或能量
单纯形约束	$x_i \geq 0, \sum_i x_i = 1$, 概率分布、投资权重
线性等式约束	$Ax = b$, 预算平衡、供需平衡

约束越简单，越容易设计高效的一阶方法。


投影算子：回到可行域

给定闭凸集合 C ，点 z 到 C 的投影定义为

$$\Pi_C(z) = \arg \min_{x \in C} \frac{1}{2} \|x - z\|^2.$$

它的含义是：在所有可行点中，找离 z 最近的点。

- ▶ 若 $z \in C$ ，则 $\Pi_C(z) = z$;
- ▶ 若 $z \notin C$ ，投影把它拉回边界或内部;
- ▶ 投影只关心“离 z 最近”，不是重新解原问题。



投影的最简单手算

设可行域是区间

$$C = [0, 2].$$

则投影就是把点拉回区间：

$$\Pi_C(z) = \begin{cases} 0, & z < 0, \\ z, & 0 \leq z \leq 2, \\ 2, & z > 2. \end{cases}$$

z	-1	1.3	4
$\Pi_C(z)$	0	1.3	2

直觉

投影不是让目标函数最小，而是先保证“合法”，并且改动尽量小。

投影梯度法的两步解释

给定 $x^k \in C$ ，先做无约束梯度步：

$$z^k = x^k - \alpha_k \nabla f(x^k).$$

然后投影：

$$x^{k+1} = \Pi_C(z^k).$$

下降意图

$$z^k = x^k - \alpha_k \nabla f(x^k)$$

希望降低目标函数。

可行性修正

$$x^{k+1} = \Pi_C(z^k)$$

保证新的点仍在 C 中。

算法框架

投影梯度法可以写成非常直接的循环。

Projected Gradient Descent

1. 选初始点 $x^0 \in C$, 步长 $\alpha_k > 0$;
2. 计算梯度 $g^k = \nabla f(x^k)$;
3. 先走一步: $z^k = x^k - \alpha_k g^k$;
4. 再投影: $x^{k+1} = \Pi_C(z^k)$;
5. 若变化很小或达到最大迭代次数, 则停止。

它可以理解为:

下降方向 + 可行性修正.

投影不是随便截断

投影定义为

$$\Pi_C(z) = \arg \min_{x \in C} \frac{1}{2} \|x - z\|^2.$$

它是一个优化问题：找离 z 最近的可行点。

重要区别

对盒约束，投影确实是逐坐标截断；但对单纯形约束、球约束、线性约束，投影需要按集合结构计算。

投影梯度法的实用性很大程度取决于： Π_C 是否容易计算。

课堂案例：带上下限的库存决策

某商品的补货量 x 有容量限制：

$$0 \leq x \leq 100.$$

如果根据需求预测做一次梯度步后得到

$$z = 116,$$

这个决策超过仓库容量，因此不可行。

错误做法

直接采用 $x = 116$ ，目标函数也许更小，但违反容量约束。

投影修正

$$\Pi_{[0,100]}(116) = 100.$$

在合法范围内选离 116 最近的补货量。

这就是投影梯度法在很多管理、工程问题中的基本逻辑。

例子一：盒约束投影

盒约束为

$$C = \{x \in \mathbb{R}^n : l_i \leq x_i \leq u_i\}.$$

投影可以逐坐标计算：

$$[\Pi_C(z)]_i := \min\{u_i, \max\{l_i, z_i\}\}.$$

$$z_i < l_i \quad \Rightarrow \quad [\Pi_C(z)]_i = l_i.$$

$$l_i \leq z_i \leq u_i \quad \Rightarrow \quad [\Pi_C(z)]_i = z_i.$$

$$z_i > u_i \quad \Rightarrow \quad [\Pi_C(z)]_i = u_i.$$

应用

参数上下界、库存范围、控制变量限制、价格区间。

二维盒约束：逐坐标修正

设

$$C = [0, 1]^2, \quad z = (1.4, -0.2).$$

投影逐坐标进行：

$$\Pi_C(z) = (\min\{1, \max\{0, 1.4\}\}, \min\{1, \max\{0, -0.2\}\}).$$

因此

$$\Pi_C(1.4, -0.2) = (1, 0).$$

给学生的提醒

盒约束的投影很像“把每个变量限制在允许范围内”，但这只是盒约束的特殊简单性。

例子二：球约束投影

球约束为

$$C = \{x : \|x\|_2 \leq R\}.$$

若 z 已在球内，则不变：

$$\|z\| \leq R \quad \Rightarrow \quad \Pi_C(z) = z.$$

若 z 在球外，则沿径向缩放：

$$\|z\| > R \quad \Rightarrow \quad \Pi_C(z) = R \frac{z}{\|z\|}.$$

直觉

球约束只限制向量长度。投影到球上，就是保持方向不变，把长度缩到 R 。

球约束手算例子

设

$$C = \{x \in \mathbb{R}^2 : \|x\|_2 \leq 5\}, \quad z = (6, 8).$$

因为

$$\|z\|_2 = \sqrt{6^2 + 8^2} = 10 > 5,$$

所以 z 在球外，需要沿方向缩短：

$$\Pi_C(z) = 5 \frac{(6, 8)}{10} = (3, 4).$$

直觉

$(6, 8)$ 和 $(3, 4)$ 方向相同，只是长度从 10 缩成了 5。

例子三：单纯形投影

单纯形约束为

$$\Delta_n = \left\{ x \in \mathbb{R}^n : x_i \geq 0, \sum_{i=1}^n x_i = 1 \right\}.$$

它常用于概率分布或投资权重。

投影问题为

$$\Pi_{\Delta_n}(z) = \arg \min_{x \geq 0, \sum_i x_i = 1} \frac{1}{2} \|x - z\|^2.$$

其解具有形式

$$x_i = \max\{z_i - \tau, 0\},$$

其中 τ 由 $\sum_i x_i = 1$ 决定。

课堂口径

单纯形投影可以理解为：整体平移 z ，再把负数截成 0，最后总和刚好为 1。

单纯形投影：三种资产的权重

投资权重常要求

$$x_1 + x_2 + x_3 = 1, \quad x_i \geq 0.$$

假设某次梯度步给出

$$z = (0.6, 0.3, -0.4).$$

它的第三个分量为负，并且总和不是 1，所以不是合法权重。

用单纯形投影的形式

$$x_i = \max\{z_i - \tau, 0\}.$$

若前两个分量保留，第三个截成 0，由

$$(0.6 - \tau) + (0.3 - \tau) = 1$$

得到 $\tau = -0.05$ ，因此

$$\Pi_{\Delta_3}(z) = (0.65, 0.35, 0).$$

完整迭代小例子

考虑一个二维约束问题：

$$\min_{x \in [0,1]^2} f(x) = \frac{1}{2} \|x - a\|^2, \quad a = (1.5, -0.5).$$

从

$$x^0 = (0.2, 0.2), \quad \alpha = 1$$

开始。由于

$$\nabla f(x) = x - a,$$

第一次无约束梯度步为

$$z^0 = x^0 - \nabla f(x^0) = a = (1.5, -0.5).$$

投影到盒约束：

$$x^1 = \Pi_{[0,1]^2}(1.5, -0.5) = (1, 0).$$

这说明算法想靠近 a ，但最终只能停在合法区域内最靠近 a 的点。

投影梯度的最优性条件

投影梯度法的固定点满足

$$x^* = \Pi_C(x^* - \alpha \nabla f(x^*)).$$

这等价于约束优化的一阶稳定性。

直观上，如果从 x^* 沿负梯度方向走再投影，仍回到 x^* ，说明可行域内没有可下降的方向。

梯度映射

常定义投影梯度映射

$$G_\alpha(x) = \frac{1}{\alpha} (x - \Pi_C(x - \alpha \nabla f(x))).$$

若 $G_\alpha(x) = 0$ ，说明满足一阶稳定性。

停止准则：什么时候可以停

无约束 GD 常用 $\|\nabla f(x^k)\|$ 判断是否接近稳定点。投影梯度法中更常用

$$\|G_\alpha(x^k)\| = \frac{1}{\alpha} \|x^k - \Pi_C(x^k - \alpha \nabla f(x^k))\|.$$

如果很大

说明“走一步再投影”会明显改变当前位置，还没有稳定。

如果接近 0

说明沿负梯度方向尝试下降后，投影又回到附近，可以停止。

步长怎么选

步长 α_k 仍然很重要。

选择方式	课堂理解
固定步长	若已知 L -光滑, 可常取 $\alpha \leq 1/L$
递减步长	早期走得大, 后期走得稳, 例如 $\alpha_k \downarrow 0$
回溯线搜索	如果一步走得太激进, 就自动缩小步长

直觉

步长太大可能来回撞边界; 步长太小则每次进步很慢。

收敛速度：和 GD 类似

若 f 是凸且 L -光滑，固定步长

$$\alpha \leq \frac{1}{L}$$

时，投影梯度法具有典型一阶方法速度：

$$f(\mathbf{x}^k) - f(\mathbf{x}^*) = \mathcal{O}\left(\frac{1}{k}\right).$$

若进一步强凸，可以得到线性收敛。

记忆方式

投影梯度法本质上是“带可行性修正的 GD”，所以它的理论速度也和 GD 同一量级。

适合大二学生记住的三句话

1. 约束优化不是想去哪就去哪，而是只能在 C 里面走；
2. 投影 $\Pi_C(z)$ 是把不合法的点拉回最近的合法点；
3. 投影梯度法就是“先按梯度下降，再投影修正”。

不要混淆

投影本身不负责找原问题最优解；它只负责把某个候选点修正为可行点。真正推动目标函数下降的是梯度步。

投影梯度法的局限

- ▶ 若投影很难算，每步代价可能很高；
- ▶ 若约束集合复杂， Π_C 本身可能就是一个难问题；
- ▶ 只利用一阶信息，在病态问题上仍可能慢；
- ▶ 对非凸集合，投影可能不唯一，理论会复杂很多。

适用场景

投影梯度法最适合：目标函数光滑，约束集合简单且投影容易计算的问题。

常见误区

误区	正确理解
投影就是把负数改成 0	只对非负约束或某些简单盒约束成立
梯度为零才是约束最优	边界最优点的梯度可以不为零
投影一定很便宜	单纯形、线性约束、多面体投影都可能需要额外计算
投影后目标一定下降	需要合适步长和凸性条件，不能只靠投影保证

本讲小结

- ▶ 约束优化要求迭代点保持在可行域内。
- ▶ 普通 GD 可能走出可行域，因此需要投影来修正可行性。
- ▶ 投影算子 $\Pi_C(z)$ 表示离 z 最近的可行点。
- ▶ 投影梯度法每一步先走梯度步，再投影回可行域。
- ▶ 盒约束、球约束、单纯形约束是最常见、最适合课堂手算的例子。
- ▶ 投影梯度映射 $G_\alpha(x)$ 可作为停止准则，步长会影响实际效果。

下一讲

近端梯度法：当目标函数中出现不可导正则项时，如何继续使用一阶思想。