



Table of Contents

凸集

凸函数

凸问题

内部、闭包、边界

定义：设 X 是 $\mathbb{R}^n$ 中的一个非空集合

- ▶ 一个点 x_0 被称为内部点，如果存在 $r > 0$ ，使得

$$B(x_0, r) := \{x : \|x - x_0\|_2 \leq r\} \subseteq X$$

- ▶ 一个点 x_0 被称为极限点，如果存在 $\{x_n\} \subseteq X$ ，使得 $x_n \rightarrow x_0$ 当 $n \rightarrow \infty$ 。

定义：

- ▶ 内部： $\text{int}(X)$ = 所有内部点的集合。
- ▶ 闭包： $\text{cl}(X)$ = 所有极限点的集合。
- ▶ 边界： $\partial(X) = \text{cl}(X) \setminus \text{int}(X)$ 。

问题：设 $X = [0,1]$ 中的无理数。求 $\text{int}(X)$ 和 $\text{cl}(X)$ 。

开集与闭集 (Open and Closed Sets)

定义

- ▶ X 是**开集**当且仅当 $\text{int}(X) = X$
- ▶ X 是**闭集**当且仅当 $\text{cl}(X) = X$

性质

- ▶ $\text{int}(X) \subseteq X \subseteq \text{cl}(X)$
- ▶ X 是闭集当且仅当 X 的补集是开集
- ▶ 任意多个闭集的交集是闭集
- ▶ 有限个闭集的并集是闭集



凸集 (Convex Set)


点 x_1 与 x_2 之间的线段：所有点 $x = \theta x_1 + (1 - \theta)x_2$ ，其中 $0 \leq \theta \leq 1$

凸集：一个集合中任意两点之间的线段也包含在该集合中

$$\forall x_1, x_2 \in C, \quad 0 \leq \theta \leq 1 \implies \theta x_1 + (1 - \theta)x_2 \in C$$

问题：如果集合是闭集，若上述性质仅在 $\theta = 1/2$ 成立，该集合是否为凸集？

举例：（一个凸集，两个非凸集）




凸集的重要性 (The Importance of Convex Set)

在优化中设计算法的关键：局部搜索配合线搜索

- ▶ 在第 k 次迭代中，得到当前点 $x^{(k)}$ 和一个良好方向 $d^{(k)}$
- ▶ 移动到下一点 $x^{(k+1)} = x^{(k)} + t^{(k)}d^{(k)}$ ，其中 $t^{(k)}$ 是步长
- ▶ 重复直到收敛


凸集合保证线搜索的成立



超平面与半空间 (Hyperplanes and Halfspaces)


► 超平面 (Hyperplane):

$$\{x \in \mathbb{R}^n : a^\top x = b\} \quad (a \neq 0, a \in \mathbb{R}^n, b \in \mathbb{R})$$



► 半空间 (Half space):

$$\{x \in \mathbb{R}^n : a^\top x \leq b\} \quad (a \neq 0, a \in \mathbb{R}^n, b \in \mathbb{R})$$



► 仿射空间 (Affine space):

$$\{x \in \mathbb{R}^n : Ax = b\} \quad (A \in \mathbb{R}^{m \times n}, b \in \mathbb{R}^m)$$

► 多面体 (Polyhedra):

$$\{x \in \mathbb{R}^n : Ax \leq b\} \quad (A \in \mathbb{R}^{m \times n}, b \in \mathbb{R}^m)$$



欧几里得球与椭球体 (Euclidean Balls and Ellipsoids)

(欧几里得) 球体, 中心为 x_c , 半径为 r :


$$B(x_c, r) = \{x \in \mathbb{R}^n : \|x - x_c\|_2 \leq r\} = \{x_c + ru : \|u\|_2 \leq 1\}$$

椭球体 (Ellipsoid):

$$\left\{x \in \mathbb{R}^n : (x - x_c)^T P^{-1} (x - x_c) \leq 1\right\} \quad \text{其中 } P \in \mathbb{S}_+^n$$

另一种表示:

$$\{x_c + Au : \|u\|_2 \leq 1\} \quad \text{其中 } A \text{ 是方阵且非奇异满足 } P = AA^T$$





范数球与范数锥 (Norm Balls and Norm Cones)

范数 (Norm): 一个函数 $\|\cdot\|$ 满足:

1. $\|x\| \geq 0$; $\|x\| = 0$ 当且仅当 $x = 0$
2. $\|tx\| = |t| \|x\|$ 对所有 $t \in \mathbb{R}$
3. $\|x + y\| \leq \|x\| + \|y\|$

范数球, 中心为 x_c , 半径为 r : $\{x \in \mathbb{R}^n : \|x - x_c\| \leq r\}$

范数锥 (Norm Cone): $\{(x, t) : \|x\| \leq t\}$

欧几里得范数锥也被称为**二阶锥 (second-order cone)**。

正定矩阵 (Positive Definite Matrices)


- ▶ 对称矩阵 (Symmetric matrices): $\mathbb{S}$
- ▶ 半正定矩阵 (Positive semidefinite matrices): $\mathbb{S}_+$
- ▶ 正定矩阵 (Positive definite matrices): $\mathbb{S}_{++}$

2×2 Positive Definite Matrices

任意对称矩阵:

$$X = \begin{pmatrix} a & b \\ b & c \end{pmatrix} \implies a > 0, \quad ac - b^2 > 0$$

固定 $a = 1$ 的截面: $c > b^2$






凸组合与凸包 (Convex Combination and Convex Hull)

凸组合 (Convex combination) $x_1, \dots, x_k$: 任何满足如下形式的点 x

$$x = \theta_1 x_1 + \theta_2 x_2 + \dots + \theta_k x_k \quad \text{满足} \theta_1 + \theta_2 + \dots + \theta_k = 1, \theta_i \geq 0$$

凸包 (Convex hull) $\text{conv}(S)$: 集合 S 中所有点的凸组合构成的集合



将非凸可行域凸化作为一种松弛方法



凸、锥、仿射与线性组合 (Convex, Conic, Affine, and Linear Combinations)


定义 (Definition) . 给定任意元素 $x_1, \dots, x_k$, 组合

$$\theta_1 x_1 + \dots + \theta_k x_k$$

被称为:

- ▶ 凸组合 (Convex): 若 $\theta_i \geq 0, i = 1, \dots, k$ 且 $\theta_1 + \dots + \theta_k = 1$
- ▶ 锥组合 (Conic): 若 $\theta_i \geq 0, i = 1, \dots, k$
- ▶ 仿射组合 (Affine): 若 $\theta_1 + \dots + \theta_k = 1$
- ▶ 线性组合 (Linear): 若 $\theta_i \in \mathbb{R}, i = 1, \dots, k$

Affine hull vs. convex hull





凸集、锥、仿射与线性子空间 (Convex sets, Conic, Affine, and Linear Subspace)

定义 (Definition)

- ▶ **凸包 (Convex hull)**: 给定集合中所有点的凸组合构成的集合
- ▶ **凸锥 (Convex cone)**: 给定集合中所有点的锥组合构成的集合
- ▶ **仿射子空间 (Affine subspace)**: 给定集合中所有点的仿射组合构成的集合
- ▶ **线性子空间 (Linear subspace)**: 给定集合中所有点的线性组合构成的集合

很明显，线性子空间一定是凸锥；而凸锥一定是凸集。



凸集的性质 (Properties of Convex Sets)

命题 (Proposition)

- ▶ 凸包总是一个凸集。
- ▶ 如果 X 是凸集，则 $\text{Conv}(X) = X$ 。
- ▶ 对于任意集合 X ， $\text{Conv}(X)$ 是包含 X 的最小凸集。



保持凸性的运算 (Operations Preserving Convexity)

设 $C \subseteq \mathbb{R}^n$, $C_1 \subseteq \mathbb{R}^n$, $C_2 \subseteq \mathbb{R}^n$ 是凸集, 则以下集合也为凸集:

- 交集 (Intersection):

$$C_1 \cap C_2 = \{x \in \mathbb{R}^n : x \in C_1 \text{ 且 } x \in C_2\}$$

- 和 (Sum):

$$C_1 + C_2 = \{x + y \in \mathbb{R}^n : x \in C_1, y \in C_2\} \quad (\text{两个凸集的 Minkowski 和})$$

- 平移 (Translated set):

$$C + a = \{x + a \in \mathbb{R}^n : x \in C\}$$

- 缩放 (Scaled set):

$$tC = \{tx \in \mathbb{R}^n : x \in C\} \quad \text{对任意 } t \in \mathbb{R}$$

保持凸性的运算 (Operations Preserving Convexity)

设 $C \subseteq \mathbb{R}^n$, $C_1 \subseteq \mathbb{R}^n$, $C_2 \subseteq \mathbb{R}^n$, $K \subseteq \mathbb{R}^m$ 是凸集, 则下列集合也为凸集:

- ▶ 笛卡尔积 (Cartesian product)

$$C_1 \times C_2 = \{(x_1, x_2) \mid x_1 \in C_1, x_2 \in C_2\}$$

- ▶ 坐标投影 (Coordinate projection)

$$\{x_1 \mid (x_1, x_2) \in C \text{ for some } x_2\}$$

- ▶ 像集 (Image), 在线性变换 $A: \mathbb{R}^n \mapsto \mathbb{R}^m$ 下:


$$AC = \{y \in \mathbb{R}^m \mid y = Ax \text{ for some } x \in C\}$$

- ▶ 原像 (Inverse image), 在线性变换 $A: \mathbb{R}^n \mapsto \mathbb{R}^m$ 下:

$$A^{-1}K = \{x \in \mathbb{R}^n \mid Ax \in K\}$$



变换




图源:《计算机视觉:算法与应用》 x



分离超平面定理 (Separating Hyperplane Theorem)

如果 C 和 D 是非空不相交的凸集, 则存在 $a \neq 0, b$ 使得:

$$a^T x \leq b \quad \text{对所有 } x \in C, \quad a^T x \geq b \quad \text{对所有 } x \in D$$




超平面 $\{x \mid a^T x = b\}$ 将 C 和 D 分离。

支撑超平面定理 (Supporting Hyperplane Theorem)

支撑超平面 (Supporting hyperplane): 对于集合 C 在边界点 x_0 的支撑超平面为:

$$\{x \mid a^\top x = a^\top x_0\} \quad \text{其中 } a \neq 0, \text{ 且 } a^\top x \leq a^\top x_0 \text{ 对所有 } x \in C$$



支撑超平面定理 (Supporting hyperplane theorem): 如果 C 是凸集, 则在 C 的每一个边界点都存在一个支撑超平面。



Table of Contents

凸集

凸函数

凸问题



凸函数 (Convex Function)

定义 (Def.) 函数 f 是凸函数当且仅当:

1. $\text{dom}(f)$ 是一个凸集
2. 对任意 $x_1, x_2 \in \text{dom}(f)$ 且 $\theta \in [0, 1]$, 有:

$$f(\theta x_1 + (1 - \theta)x_2) \leq \theta f(x_1) + (1 - \theta)f(x_2)$$



问题 (Question): 若上述不等式仅在 $\theta = 1/2$ 成立, 函数是否为凸函数?



关于凸函数的进一步讨论 (More on Convex Function)

定义 (Def.) 如果 $\text{dom}(f)$ 是凸集, 且

$$f(\theta x_1 + (1 - \theta)x_2) < \theta f(x_1) + (1 - \theta)f(x_2)$$

对所有 $x_1, x_2 \in \text{dom}(f)$ 且 $\theta \in [0, 1]$ 成立, 则称 f 是严格凸函数 (strictly convex)。

定义 (Def.) 若 $-f$ 是凸函数, 则 f 是凹函数 (concave)。

定义 (Def.) 若 $-f$ 是严格凸函数, 则 f 是严格凹函数 (strictly concave)。

实数域 $\mathbb{R}$ 上的例子 (Examples on $\mathbb{R}$)

凸函数 (Convex):

- ▶ 仿射函数 (Affine): $ax + b$, 定义在 $\mathbb{R}$, 其中 $a, b \in \mathbb{R}$
- ▶ 指数函数 (Exponential): e^{ax} , 定义在 $\mathbb{R}$, 其中 $a \in \mathbb{R}$
- ▶ 幂函数 (Power): x^p , 定义在 $(0, +\infty)$, 当 $p \geq 1$ 或 $p \leq 0$
- ▶ 绝对值幂函数: $|x|^p$, 定义在 $\mathbb{R}$, 当 $p \geq 1$
- ▶ 负熵函数 (Negative entropy): $x \ln x$, 定义在 $(0, +\infty)$

凹函数 (Concave):

- ▶ 仿射函数 (Affine): $ax + b$, 定义在 $\mathbb{R}$, 其中 $a, b \in \mathbb{R}$
- ▶ 幂函数 (Power): x^p , 定义在 $(0, +\infty)$, 当 $0 \leq p \leq 1$
- ▶ 对数函数 (Logarithm): $\ln x$, 定义在 $(0, +\infty)$



例子：仿射函数与范数 (Examples: Affine Functions and Norms)

仿射函数既是凸的也是凹的。

例子 (Example):

- ▶ $f(x) = a^\top x + b$, 其中 $a \in \mathbb{R}^n$, $b \in \mathbb{R}$
- ▶ $f(X) = \text{tr}(A^\top X) + b = \sum_{i=1}^m \sum_{j=1}^n a_{ij} x_{ij} + b$

范数是凸函数 (Norms are convex):

- ▶ 一般的 l_p 范数: $\|x\|_p = (\sum_{i=1}^n |x_i|^p)^{1/p}$
- ▶ 谱范数 (最大奇异值范数):

$$f(X) = \|X\|_2 = \sigma_{\max}(A) = \sqrt{\lambda_{\max}(A^\top A)}$$



验证函数的凸性 (Verifying Convexity of a Function)


我们可以通过以下方式验证一个给定函数 f 是否为凸函数:

- ▶ 定义 (Definition)
- ▶ 应用一些特殊判据 (**Applying some special criteria**)
 - ▶ 一阶条件 (**First-order conditions**)
 - ▶ 二阶条件 (Second-order conditions)
 - ▶ 归约为标量函数 (Reduction to a scalar function)
 - ▶ 上图函数法 (Epigraph)
- ▶ 证明 f 是通过保持凸性的运算构造得到的

一阶条件 (First-Order Condition)

一阶条件 (1st-order condition): 可微函数 f 是凸的, 当且仅当它的定义域是凸的, 且满足:

$$f(x) + \nabla f(x)^T (y - x) \leq f(y) \quad \text{对所有 } x, y \in \text{dom}(f)$$



一阶近似是 f 的一个全局下界 (**underestimate**)

对于无约束优化问题, 有最优解 $x^* \in \{x : \nabla f(x) = 0\}$

一阶条件的证明 (Proof of First-Order Condition)

微积分回顾 (Review of Calculus)

导数: $f'(x) = \lim_{\epsilon \rightarrow 0} \frac{f(x + \epsilon) - f(x)}{\epsilon}$

梯度: $\nabla f = \left[\frac{\partial f(x)}{\partial x_1}, \dots, \frac{\partial f(x)}{\partial x_n} \right]^\top$ 其中 $\frac{\partial f(x)}{\partial x_i} = \lim_{\epsilon \rightarrow 0} \frac{f(x + \epsilon e_i) - f(x)}{\epsilon}$

方向导数: $f'(x; d) = \lim_{\epsilon \rightarrow 0} \frac{f(x + \epsilon d) - f(x)}{\epsilon} = \sum_{i=1}^n \frac{\partial f(x)}{\partial x_i} d_i = \nabla f(x)^\top d$

证明: 假设 $f(x)$ 是凸函数。对任意 $x, y \in \text{dom} f$, 以及 $\theta \in [0, 1]$, 有:

$$f(x + \theta(y - x)) = f((1 - \theta)x + \theta y) \leq (1 - \theta)f(x) + \theta f(y)$$

等价于

$$f(y) \geq \frac{1}{\theta} [f(x + \theta(y - x)) - (1 - \theta)f(x)] = f(x) + \frac{f(x + \theta(y - x)) - f(x)}{\theta}$$

$$= f(x) + \nabla f(x)^\top (y - x) \quad \text{当 } \theta \rightarrow 0$$



一阶条件的证明 (Proof of First-Order Condition)

证明：假设一阶条件成立。

对任意 $x, y \in \text{dom } f$ 且 $\theta \in [0, 1]$, 令 $z = \theta x + (1 - \theta)y$, 我们有:

$$f(x) \geq f(z) + \nabla f(z)^\top (x - z),$$

$$f(y) \geq f(z) + \nabla f(z)^\top (y - z).$$

现在考虑 (Now consider):

$$\theta f(x) + (1 - \theta)f(y) \geq f(z) + \nabla f(z)^\top [\theta(x - z) + (1 - \theta)(y - z)]$$

$$= f(z) + \nabla f(z)^\top [\theta x + (1 - \theta)y - z] = f(z)$$

验证函数的凸性 (Verifying Convexity of a Function)

我们可以通过以下方式验证一个函数 f 是否为凸函数:

- ▶ 定义 (Definition)
- ▶ 应用一些特殊判据 (**Applying some special criteria**)
 - ▶ 一阶条件 (First-order conditions)
 - ▶ 二阶条件 (**Second-order conditions**)
 - ▶ 归约为标量函数 (Reduction to a scalar function)
 - ▶ 上图法 (Epigraph)
- ▶ 证明 f 是通过保持凸性的操作构造得到的 (Showing that f is obtained through operations preserving convexity)

二阶条件 (Second-Order Condition)

函数 f 是二阶可微 (twice differentiable), 当 $\text{dom}(f)$ 是开集, 且 Hessian 矩阵 $\nabla^2 f(x) \in \mathbb{S}^n$, 即

$$[\nabla^2 f(x)]_{ij} = \frac{\partial^2 f(x)}{\partial x_i \partial x_j} \quad \text{对于 } i, j = 1, \dots, n$$

在每个 $x \in \text{dom}(f)$ 上都存在。

二阶条件 (2nd-order condition): 对于定义域为凸集的二阶可微函数 f , 有:

► f 是凸函数当且仅当:

$$\nabla^2 f(x) \succeq 0 \quad \text{对所有 } x \in \text{dom}(f)$$

► 若 $\nabla^2 f(x) \succ 0$, 则 f 是严格凸函数。

二阶条件的证明 (Proof of Second-Order Condition)

微积分回顾 (Review of Calculus)

泰勒展开 (单变量):

$$f(x + a) = f(x) + f'(x)a + \frac{1}{2}f''(x)a^2 + \cdots = \sum_{k=0}^{\infty} \frac{f^{(k)}(x)}{k!} a^k$$

双变量的线性近似:

$$f(x_1 + a, x_2 + b) \approx f(x_1, x_2) + \frac{\partial f}{\partial x_1} a + \frac{\partial f}{\partial x_2} b = f(x_1, x_2) + \nabla f(x)^\top [a; b]$$

多变量泰勒展开:

$$f(x + a) = f(x) + \nabla f(x)^\top a + \frac{1}{2} a^\top \nabla^2 f(x) a + \cdots$$

证明: 假设二阶条件成立。对任意 $x, y \in \text{dom} f$, 有:

$$f(y) = f(x) + \nabla f(x)^\top (y - x) + \frac{1}{2} (y - x)^\top \nabla^2 f(x) (y - x) + \cdots \geq f(x) + \nabla f(x)^\top (y - x)$$



二阶条件的证明 (Proof of Second-Order Condition)

证明：假设 $f(x)$ 是凸函数。对任意 $x, y \in \text{dom} f$ ，一阶条件给出：

$$f(y) \geq f(x) + \nabla f(x)^\top (y - x),$$

$$f(x) \geq f(y) + \nabla f(y)^\top (x - y)$$

将这两个不等式相加，得到：

$$(\nabla f(x) - \nabla f(y))^\top (x - y) \geq 0$$

由广义中值定理 (generalized mean-value theorem)，存在 $\theta \in (0, 1)$ ，使得：

$$\nabla f(x) - \nabla f(y) = \nabla^2 f(\theta x + (1 - \theta)y)(x - y)$$

因此，有：

$$(\nabla f(x) - \nabla f(y))^\top (x - y) = (x - y)^\top \nabla^2 f(\theta x + (1 - \theta)y)(x - y) \geq 0$$

说明当 $y \rightarrow x$ 时， $\nabla^2 f(x) \succeq 0$

例子 (Examples)

二次函数 (Quadratic function): $f(x) = \frac{1}{2}x^\top Px + q^\top x + r$, 其中 P 是对称的 $n \times n$ 矩阵

$$\nabla f(x) = Px + q, \quad \nabla^2 f(x) = P$$

当 $P \succeq 0$ 时函数是凸的。

问题: $f(x_1, x_2) = x_1^2 - 3x_1x_2 + x_2^2$ 是凸函数吗? 令 $x_1 = u + v$, $x_2 = u - v$

最小二乘目标函数 (Least-squares objective): $f(x) = \|Ax - b\|^2$, 其中 A 是 $m \times n$ 矩阵

$$\nabla f(x) = 2A^\top(Ax - b), \quad \nabla^2 f(x) = 2A^\top A$$

对任意 A , f 是凸的。

线性分母下的二次函数 (Quadratic-over-linear): $f(x, y) = \frac{x^2}{y}$ (当 $y > 0$ 时是凸的)



验证函数的凸性 (Verifying Convexity of a Function)

我们可以通过以下方式验证函数 f 是否为凸函数:

- ▶ 定义 (Definition)
- ▶ 应用一些特殊判据 (**Applying some special criteria**)
 - ▶ 一阶条件 (First-order conditions)
 - ▶ 二阶条件 (Second-order conditions)
 - ▶ 化归为标量函数 (**Reduction to a scalar function**)
 - ▶ 上图法 (Epigraph)
- ▶ 证明 f 是通过保持凸性的操作构造得到的 (Showing that f is obtained through operations preserving convexity)

将凸函数限制在一条直线上的方法

限制在直线上的函数 (Restriction to a line): 若 $f: \mathbb{R}^n \rightarrow \mathbb{R}$ 是凸函数, 当且仅当 $\text{dom } f$ 是凸集, 且如下定义的函数 $g: \mathbb{R} \rightarrow \mathbb{R}$ 是凸函数:

$$g(t) = f(x + tv), \quad \text{dom } g = \{t \mid x + tv \in \text{dom } f\}$$

对于任意 $x \in \text{dom } f$, $v \in \mathbb{R}^n$, $g(t)$ 是 t 上的凸函数。

通过一元函数的凸性验证多变量函数的凸性 (Check the convexity of one variable instead of multivariables)

例子: $f: \mathbb{S}^n \rightarrow \mathbb{R}$, $f(X) = -\ln \det X$, $\text{dom } f = \mathbb{S}_{++}^n$

$$\begin{aligned} g(t) &= -\ln \det(X + tV) = -\ln \det X - \ln \det(I + tX^{-1/2}VX^{-1/2}) \\ &= -\ln \det X - \sum_{i=1}^n \ln(1 + t\lambda_i) \end{aligned}$$

其中 λ_i 是 $X^{-1/2}VX^{-1/2}$ 的特征值。由于 $g(t)$ 是凸的 (对任意 V 且 $X \succ 0$), 因此 f 是凸函数。



验证函数的凸性 (Verifying Convexity of a Function)

我们可以通过以下方式验证一个函数 f 是否为凸函数:

- ▶ 定义 (Definition)
- ▶ 应用一些特殊判据 (**Applying some special criteria**)
 - ▶ 一阶条件 (First-order conditions)
 - ▶ 二阶条件 (Second-order conditions)
 - ▶ 化归为标量函数 (Reduction to a scalar function)
 - ▶ 上图法 (**Epigraph**)
- ▶ 证明 f 是通过保持凸性的运算构造得到的 (Showing that f is obtained through operations preserving convexity)

上图集与下水平集 (Epigraph and Sublevel Set)

α -下水平集 (sublevel set) 对于函数 $f : \mathbb{R}^n \rightarrow \mathbb{R}$ 定义为:

$$C_\alpha = \{x \in \text{dom } f \mid f(x) \leq \alpha\}$$


凸函数的下水平集是凸集 (反过来不成立)。

上图集 (Epigraph) 对于函数 $f : \mathbb{R}^n \rightarrow \mathbb{R}$

定义为:

$$\text{epi } f = \{(x, t) \in \mathbb{R}^{n+1} \mid x \in \text{dom } f, f(x) \leq t\}$$

函数 f 是凸的, 当且仅当 $\text{epi } f$ 是凸集。





保持凸性的运算 (Operations Preserving Convexity)

- ▶ 正数缩放 (Positive Scaling)
- ▶ 求和 (Sum)
- ▶ 与仿射函数的复合 (Composition with affine function)
- ▶ 逐点最大值与上确界 (Pointwise maximum and supremum)
- ▶ 函数复合 (Composition)
- ▶ 最小化 (Minimization)

缩放、求和、与仿射函数的复合

求和 (Sum): 对于凸函数 f_1 和 f_2 , 它们的和 $f_1 + f_2$ 是凸的。该结论可扩展至积分形式: 例如非负函数的卷积:

$$(f * g)(x) = \int_y f(y)g(x-y)dy \quad \text{其中 } g(x) \geq 0$$

非负倍数 (Nonnegative multiple): 若 f 是凸函数, $\lambda \geq 0$, 则 λf 是凸函数。

与仿射函数的复合 (Composition with affine function): 若 f 是凸函数, 则 $f(Ax + b)$ 是凸函数。

例子 (Examples):

- ▶ 线性不等式的对数障碍函数 (Log-barrier for linear inequalities):

$$f(x) = -\sum_{i=1}^m \ln(b_i - a_i^\top x), \quad \text{dom } f = \{x \mid a_i^\top x < b_i, i = 1, \dots, m\}$$

- ▶ 仿射函数的范数 (Norm of affine function):

$$f(x) = \|Ax + b\|$$

逐点最大值 (Pointwise Maximum)

若 $f_1, \dots, f_m$ 是凸函数, 则逐点最大值函数 $f(x)$ 为凸函数:

$$f(x) = \max\{f_1(x), \dots, f_m(x)\}$$

证明提示 (Proof hints): 使用定义或上图法 (epigraph)

例子 (Example):

- ▶ 分段线性函数: $f(x) = \max_{i=1, \dots, m}(a_i^\top x + b_i)$ 是凸函数。
- ▶ 向量 $x \in \mathbb{R}^n$ 中最大的 r 个分量之和:

$$f(x) = x_{[1]} + x_{[2]} + \dots + x_{[r]}$$

是凸的, 其中 $x_{[i]}$ 表示 x 的第 i 大分量。

证明提示: $f(x) = \max\{x_{i_1} + x_{i_2} + \dots + x_{i_r} \mid 1 \leq i_1 < \dots < i_r \leq n\}$

逐点上确界 (Pointwise Supremum)

设 $f(x, y)$ 对于每个 $y \in \mathcal{A}$ 是关于 x 的凸函数。则定义:

$$g(x) = \sup_{y \in \mathcal{A}} f(x, y)$$

是凸函数。

例子 (Examples):

- ▶ 集合 $\mathcal{A}$ 的支撑函数 (Support function):

$$S_{\mathcal{C}}(x) = \sup_{z \in \mathcal{A}} z^{\top} x$$

- ▶ 到集合 $\mathcal{A}$ 中最远点的距离:

$$f(x) = \sup_{z \in \mathcal{A}} \|x - z\|$$



与标量函数的复合 (Composition with Scalar Functions)

设 $g: \mathbb{R}^n \rightarrow \mathbb{R}$, $h: \mathbb{R} \rightarrow \mathbb{R}$, 定义复合函数:

$$f(x) = h(g(x))$$

则 f 是凸函数, 当满足以下条件之一:

- ▶ g 是凸函数, h 是非减且凸函数;
- ▶ g 是凹函数, h 是非增且凸函数。

例子 (Examples):

- ▶ $e^{g(x)}$ 是凸函数, 若 g 是凸函数;
- ▶ $\frac{1}{g(x)}$ 是凸函数, 若 g 是凹函数且为正。



与向量函数的复合 (Composition with Vector Functions)

设 $g: \mathbb{R}^n \rightarrow \mathbb{R}^k$, $h: \mathbb{R}^k \rightarrow \mathbb{R}$, 定义复合函数:

$$f(x) = h(g(x)) = h(g_1(x), g_2(x), \dots, g_k(x))$$

则 f 是凸函数, 当满足以下条件之一:

- ▶ g_i 是凸函数, h 在每个变量上都是凸且非减的;
- ▶ g_i 是凹函数, h 在每个变量上都是凸且非增的。

例子 (Examples):

- ▶ $\log\left(\sum_{i=1}^k e^{g_i(x)}\right)$ 是凸函数, 如果每个 g_i 是凸函数。

最小化 (Minimization)

若 $f(x, y)$ 关于 (x, y) 是凸函数, 且 C 是一个凸集合, 则

$$g(x) = \inf_{y \in C} f(x, y)$$

是关于 x 的凸函数。定义域为:

$$\text{dom } g = \{x \mid (x, y) \in \text{dom } f \text{ for some } y \in C\}$$

证明提示 (Proof hints): 设 $\varepsilon > 0$ 是任意小的正数。对任意 $x_1, x_2 \in \mathbb{R}^n$ 和 $\theta \in (0, 1)$, 存在 $y_1, y_2 \in C$, 使得:

$$f(x_1, y_1) \leq g(x_1) + \varepsilon, \quad f(x_2, y_2) \leq g(x_2) + \varepsilon$$

考虑: $(\theta x_1 + (1 - \theta)x_2, \theta y_1 + (1 - \theta)y_2)$

利用 f 和 C 的凸性完成证明。

另一种观点 (Another view): 将 g 的上图集写作:


$$\text{epi } g = \{(x, t) : (x, y, t) \in \text{epi } f \text{ for some } y\}$$

拟凸性 (Quasi-Convexity)

函数 $f : \mathbb{R}^n \rightarrow \mathbb{R}$ 是拟凸函数 (quasi-convex), 当且仅当 $\text{dom } f$ 是凸集, 且如下的下水平集:

$$S_\alpha = \{x \in \text{dom } f : f(x) \leq \alpha\}$$

对所有 α 都是凸集。



另一种拟凸函数定义: 当 $\text{dom } f$ 是凸的, 且对于任意 $x, y \in \text{dom } f$ 与 $\theta \in [0, 1]$, 有:

$$f(\theta x + (1 - \theta)y) \leq \max\{f(x), f(y)\}$$



例子 (Examples)

- ▶ $\sqrt{|x|}$ 在 $\mathbb{R}$ 上是拟凸的 (quasi-convex)
- ▶ $\log(x)$ 在 $\mathbb{R}_+$ 上是拟凸的
- ▶ $f(x_1, x_2) = -x_1 x_2$ 在 $\mathbb{R}_{++}^2$ 上是拟凸的
- ▶ 距离比 (Distance ratio) 函数:

$$f(x) = \frac{\|x - a\|_2}{\|x - b\|_2}$$

在定义域 $\text{dom } f = \{x : \|x - a\|_2 \leq \|x - b\|_2\}$ 上是拟凸的

因此, 即使 $f(x)$ 不是凸函数, 集合 $\{x : f(x) \leq 0\}$ 也可能是一个凸集。

共轭函数 (The Conjugate Function)

函数 f 的共轭函数 (conjugate) 定义为:

$$f^*(y) = \sup_{x \in \text{dom } f} (y^T x - f(x))$$


- ▶ f^* 是凸函数 (即使 f 不是凸的)
- ▶ Fenchel 不等式 (Fenchel's inequality):

$$f(x) + f^*(y) \geq y^T x, \quad \forall x, y$$

- ▶ 如果 f 是凸函数且其上图集 (epigraph) 是闭集, 则

$$f^{**} = f$$

- ▶ 共轭函数在拉格朗日对偶问题 (Lagrange dual) 中非常有用



例子 (Examples)

- 仿射函数 (Affine function): $f(x) = a^T x + b$

$$f^*(y) = \sup_x (y^T x - a^T x - b) = \begin{cases} -b & \text{若 } y = a \\ \infty & \text{否则} \end{cases}$$

- 负对数函数 (Negative logarithm): $f(x) = -\log x$

$$f^*(y) = \sup_{x>0} (yx + \log x) = \begin{cases} -1 - \log(-y) & \text{若 } y < 0 \\ \infty & \text{否则} \end{cases}$$

- 严格凸二次函数 (Strictly convex quadratic): $f(x) = \frac{1}{2}x^T Qx$, 其中 $Q \in \mathbb{S}_{++}^n$

$$f^*(y) = \sup_x \left(y^T x - \frac{1}{2}x^T Qx \right) = \frac{1}{2}y^T Q^{-1}y$$



Table of Contents

凸集

凸函数

凸问题



优化问题的标准形式

优化问题的标准形式:

$$\begin{aligned} \min \quad & f_0(x) \\ \text{s.t.} \quad & f_i(x) \leq 0, \quad i = 1, \dots, m \\ & h_i(x) = 0, \quad i = 1, \dots, p \end{aligned}$$

- ▶ $x \in \mathbb{R}^n$ 是优化变量
- ▶ $f_0 : \mathbb{R}^n \rightarrow \mathbb{R}$ 是目标函数
- ▶ $f_i : \mathbb{R}^n \rightarrow \mathbb{R}$ 是不等式约束函数
- ▶ $h_i : \mathbb{R}^n \rightarrow \mathbb{R}$ 是等式约束函数
- ▶ $p^* = \inf \{f_0(x) \mid f_i(x) \leq 0, h_i(x) = 0\}$
- ▶ 若问题不可行: $p^* = \infty$
- ▶ 若问题在可行域内无下界: $p^* = -\infty$

最优解与局部最优解

- ▶ 若 $x \in \text{dom } f_0$ 且满足约束, 则 x 为**可行解**
- ▶ 若可行解 x 满足 $f_0(x) = p^*$, 则为**最优解**, 最优解集合记为 X_{opt}
- ▶ 若存在 $R > 0$, 使 x 在以下问题中为最优解, 则称其为**局部最优解**:

$$\begin{aligned} \min_z \quad & f_0(z) \\ \text{s.t.} \quad & f_i(z) \leq 0, \quad i = 1, \dots, m \\ & h_i(z) = 0, \quad i = 1, \dots, p \\ & \|z - x\|_2 \leq R \end{aligned}$$

- | | |
|---|--|
| ▶ $f_0(x) = 1/x$, $\text{dom } f_0 = \mathbb{R}_{++}$:
$p^* = 0$, 无最优解 | ▶ $f_0(x) = x \log x$, $\text{dom } f_0 = \mathbb{R}_{++}$:
$p^* = -1/e$, $x = 1/e$ 是最优解 |
| ▶ $f_0(x) = -\log x$, $\text{dom } f_0 = \mathbb{R}_{++}$:
$p^* = -\infty$ | ▶ $f_0(x) = x^3 - 3x$: $p^* = -\infty$,
但 $x = 1$ 是局部最优解 |

隐式约束 (Implicit Constraints)

标准形式的优化问题包含隐式约束：

$$x \in \mathcal{D} = \bigcap_{i=0}^m \text{dom } f_i \cap \bigcap_{i=1}^p \text{dom } h_i$$

- ▶ $\mathcal{D}$ 被称为问题的定义域 (domain)
- ▶ $f_i(x) \leq 0$, $h_i(x) = 0$ 是显式约束
- ▶ 若 $m = p = 0$, 即无显式约束, 则问题为无约束问题 (unconstrained)

例子：

$$\min f_0(x) = - \sum_{i=1}^k \log(b_i - a_i^\top x)$$

这是一个无约束问题, 但其隐式约束为 $a_i^\top x < b_i$

可行性问题 (Feasibility Problem)

Find x

$$\text{s.t. } f_i(x) \leq 0, \quad i = 1, \dots, m$$

$$h_i(x) = 0, \quad i = 1, \dots, p$$

可行性问题是目标函数为常数 $f_0(x) = 0$ 的一般优化问题特例:

min 0

$$\text{s.t. } f_i(x) \leq 0, \quad i = 1, \dots, m$$

$$h_i(x) = 0, \quad i = 1, \dots, p$$

- ▶ 若约束可行, 则 $p^* = 0$, 任意可行 x 为最优
- ▶ 若约束不可行, 则 $p^* = \infty$



凸优化问题 (Convex Optimization Problem)

标准形式:

$$\begin{aligned} \min \quad & f_0(x) \\ \text{s.t.} \quad & f_i(x) \leq 0, \quad i = 1, \dots, m \\ & a_i^\top x = b_i, \quad i = 1, \dots, p \end{aligned}$$

- ▶ $f_0, f_1, \dots, f_m$ 是凸函数, 等式约束是仿射的
- ▶ 若 f_0 为拟凸函数, $f_1, \dots, f_m$ 为凸函数, 则问题为拟凸优化问题

常写作:

$$\begin{aligned} \min \quad & f_0(x) \\ \text{s.t.} \quad & f_i(x) \leq 0, \quad i = 1, \dots, m \\ & Ax = b \end{aligned}$$

重要性质: 凸优化问题的可行解集是凸集



非凸约束示例

$$\begin{array}{ll}\min & f_0(x) = x_1^2 + x_2^2 \\ \text{s.t.} & f_1(x) = \frac{x_1}{1 + x_2^2} \leq 0\end{array}$$

$$h_1(x) = (x_1 + x_2)^2 = 0$$

- ▶ f_0 是凸函数；可行域 $\{(x_1, x_2) \mid x_1 = -x_2 \leq 0\}$ 是凸集
- ▶ 不是凸优化问题： f_1 非凸， h_1 非仿射
- ▶ 它等价（但不完全相同）于下列凸优化问题：

$$\begin{array}{ll}\min & x_1^2 + x_2^2 \\ \text{s.t.} & x_1 \leq 0 \\ & x_1 + x_2 = 0\end{array}$$



局部最优与全局最优

任意凸优化问题的局部最优点也是全局最优点。

证明：假设 x 是局部最优，但存在可行 y 使得 $f_0(y) < f_0(x)$ 。

局部最优意味着存在 $R > 0$ ，使得

$$z \text{ 可行}, \|z - x\|_2 \leq R \Rightarrow f_0(z) \geq f_0(x)$$

令 $z = \theta y + (1 - \theta)x$ ，不妨设 $\theta = R/(2\|y - x\|_2)$ ，那么可以验证：

$$\|y - x\|_2 > R \Rightarrow 0 < \theta < 1/2 \in (0, 1), \text{ 且 } \|z - x\|_2 = R/2.$$

由目标函数凸性可得： $f_0(z) \leq \theta f_0(y) + (1 - \theta)f_0(x) < f_0(x)$

这与 x 是局部最优点矛盾，故 x 必为全局最优点。

可微函数的最优性判据


若目标函数 f_0 可微，点 x 是最优的当且仅当：

- ▶ x 是可行解；
- ▶ 对所有可行点 y ，有：

$$\nabla f_0(x)^T (y - x) \geq 0$$

图示说明：

- ▶ 若 $\nabla f_0(x) \neq 0$ ，则其定义了一个在点 x 处支撑可行域 X 的超平面 (supporting hyperplane)



常见结构下的最优性条件

1. 无约束问题: $\min f_0(x)$, 则最优的充要条件为:

$$\nabla f_0(x) = 0$$

2. 等式约束问题: $\min f_0(x)$ s.t. $Ax = b$ 。最优性充要条件为存在 ν 使得:

$$x \in \text{dom } f_0, \quad Ax = b, \quad \nabla f_0(x) + A^T \nu = 0$$

3. 非负正交域上的最优化: $\min f_0(x)$ s.t. $x \succeq 0$ 。最优性充要条件为:

$$x \in \text{dom } f_0, \quad x \succeq 0, \quad \begin{cases} \nabla f_0(x)_i \geq 0 & \text{若 } x_i = 0 \\ \nabla f_0(x)_i = 0 & \text{若 } x_i > 0 \end{cases}$$

等价凸优化问题：消除等式约束

若两个问题的解可相互转换，我们称它们等价。

目标：消除等式约束 $Ax = b$ ，保持凸性不变。

原问题：

$$\begin{aligned} \min \quad & f_0(x) \\ \text{s.t.} \quad & f_i(x) \leq 0, \quad i = 1, \dots, m \\ & Ax = b \end{aligned}$$

等价于如下问题（变量变为 z ）：

$$\begin{aligned} \min \quad & f_0(Fz + x_0) \\ \text{s.t.} \quad & f_i(Fz + x_0) \leq 0, \quad i = 1, \dots, m \end{aligned}$$

其中 F 和 x_0 满足： $Ax = b \iff x = Fz + x_0$, for some z



等价凸问题：引入等式

引入等式约束：

$$\begin{aligned} \min \quad & f_0(A_0x + b_0) \\ \text{s.t.} \quad & f_i(A_ix + b_i) \leq 0, \quad i = 1, \dots, m \end{aligned}$$

等价于引入变量 $y_i = A_ix + b_i$ ：

$$\begin{aligned} \min_{x, y_i} \quad & f_0(y_0) \\ \text{s.t.} \quad & f_i(y_i) \leq 0, \quad i = 1, \dots, m \\ & y_i = A_ix + b_i, \quad i = 0, \dots, m \end{aligned}$$



等价凸问题：引入松弛变量

引入松弛变量：

$$\min \quad f_0(x) \quad \text{s.t.} \quad a_i^T x \leq b_i, \quad i = 1, \dots, m$$

等价于：

$$\begin{aligned} \min_{x,s} \quad & f_0(x) \\ \text{s.t.} \quad & a_i^T x + s_i = b_i, \quad i = 1, \dots, m \\ & s_i \geq 0, \quad i = 1, \dots, m \end{aligned}$$

等价凸优化形式：改写成上图形式

凸问题标准形式问题：

$$\min f_0(x) \quad \text{s.t.} \quad f_i(x) \leq 0, \quad Ax = b$$

等价于引入变量 t 的形式：

$$\begin{aligned} \min_{x,t} \quad & t \\ \text{s.t.} \quad & f_0(x) - t \leq 0 \\ & f_i(x) \leq 0 \\ & Ax = b \end{aligned}$$

等价凸优化形式：对部分变量先进行最小化

原问题

$$\min_{x_1, x_2} f_0(x_1, x_2) \quad \text{s.t.} \quad f_i(x_1) \leq 0$$

等价于令 $\tilde{f}_0(x_1) = \min_{x_2} f_0(x_1, x_2)$

$$\min_{x_1} \tilde{f}_0(x_1) \quad \text{s.t.} \quad f_i(x_1) \leq 0,$$

含义：先优化掉 x_2 ，之后仅对 x_1 优化。


- **降维**：减少优化变量数量；
- **结构优化**：保留部分变量结构，有利于分布式算法（如 ADMM）实现。

拟凸优化问题 (Quasiconvex Optimization)

$$\begin{aligned} \min \quad & f_0(x) \\ \text{s.t.} \quad & f_i(x) \leq 0, \quad i = 1, \dots, m \\ & Ax = b \end{aligned}$$

其中:

- ▶ $f_0 : \mathbb{R}^n \rightarrow \mathbb{R}$ 是拟凸函数;
- ▶ $f_1, \dots, f_m$ 是凸函数;
- ▶ $Ax = b$ 是仿射约束。



图示：拟凸函数可能出现“鞍点式”的局部最优，见右图。

拟凸函数的下水平集的凸表示

若 $f_0(x)$ 是拟凸函数, 则存在一族函数 $\phi_t(x)$ 满足:

- ▶ 对每个固定的 t , $\phi_t(x)$ 是凸函数; 同时, $f_0(x) \leq t \iff \phi_t(x) \leq 0$

示例: 设 $f_0(x) = \frac{p(x)}{q(x)}$, 其中:

- ▶ $p(x)$ 是凸函数, $p(x) \geq 0$
- ▶ $q(x)$ 是凹函数, $q(x) > 0$

令:

$$\phi_t(x) = p(x) - tq(x)$$

则当 $t \geq 0$ 时, ϕ_t 是凸函数, 且有:

$$f_0(x) \leq t \iff \phi_t(x) \leq 0$$

拟凸优化：通过凸可行性问题 + 二分法求解

将拟凸优化转化为可行性问题：固定参数 t ，考虑以下凸可行性问题

$$\phi_t(x) \leq 0, \quad f_i(x) \leq 0, \quad Ax = b \quad (1)$$

► 若 (1) 可行，则 $t \geq p^*$

► 若 (1) 不可行，则 $t < p^*$

二分法 (bisection method):

► 输入: $l \leq p^*, u \geq p^*, \epsilon > 0$

► 重复直到 $u - l \leq \epsilon$:

1. $t := (l + u)/2$

2. 解可行性问题 (1)


3. 若可行，设 $u := t$ ；否则 $l := t$

收敛次数:

$$\left\lceil \log_2 \left(\frac{u - l}{\epsilon} \right) \right\rceil$$

线性规划 (Linear Program, LP)

$$\begin{array}{ll}\min & c^T x + d \\ \text{s.t.} & Gx \leq h \\ & Ax = b\end{array}$$



- ▶ 具有仿射目标函数与仿射约束函数的凸优化问题
- ▶ 可行解集合是一个多面体 (polyhedron)



示例 (Examples)

饮食问题 (diet problem): 选择 $x_1, \dots, x_n$ 种食物的数量

- ▶ 每单位食物 j 的价格为 c_j , 含有 a_{ij} 单位的营养素 i
- ▶ 健康饮食要求营养素 i 的摄入量至少为 b_i

为找到最便宜的健康饮食方案, 求解如下问题:

$$\begin{aligned} \min \quad & c^T x \\ \text{s.t.} \quad & Ax \leq b \\ & x \geq 0 \end{aligned}$$



Chebyshev 中心 (Chebyshev center of a polyhedron)

Chebyshev 中心定义于:

$$\mathcal{P} = \{x \mid a_i^T x \leq b_i, \quad i = 1, \dots, m\}$$

是其最大内切球的中心, 记为: $\mathcal{B} = \{x_c + u \mid \|u\|_2 \leq r\}$

► $a_i^T x \leq b_i$ 对所有 $x \in \mathcal{B}$ 成立, 当且仅当:


$$\sup\{a_i^T (x_c + u) \mid \|u\|_2 \leq r\} = a_i^T x_c + r\|a_i\|_2 \leq b_i$$

► 因此, 可以通过求解以下线性规划来确定 x_c, r :

$$\begin{aligned} \max \quad & r \\ \text{s.t.} \quad & a_i^T x_c + r\|a_i\|_2 \leq b_i, \quad i = 1, \dots, m \end{aligned}$$

二次规划 (Quadratic Program, QP)

$$\begin{aligned} \min \quad & \frac{1}{2}x^T Px + q^T x + r \\ \text{s.t.} \quad & Gx \leq h \\ & Ax = b \end{aligned}$$



- ▶ 要求 $P \in \mathbb{S}_+^n$, 所以目标函数是凸二次函数
- ▶ 目标是在多面体可行域上最小化一个凸二次函数

示例：最小二乘与随机成本线性规划

最小二乘 (least-squares) $\min \|Ax - b\|_2^2$

- ▶ 解析解 $x^* = A^\dagger b$, 其中 $A^\dagger$ 是广义逆
- ▶ 可添加线性约束, 例如 $l \leq x \leq u$

具有随机成本的线性规划 (linear program with random cost)

$$\begin{aligned} \min \quad & \bar{c}^T x + \gamma x^T \Sigma x = \mathbb{E}[c^T x] + \gamma \text{Var}(c^T x) \\ \text{s.t.} \quad & Gx \leq h, \quad Ax = b \end{aligned}$$

- ▶ 向量 c 是具有均值 $\bar{c}$ 、协方差为 Σ 的随机向量
- ▶ 因此 $c^T x$ 是具有均值 $\bar{c}^T x$ 、方差 $x^T \Sigma x$ 的随机变量
- ▶ $\gamma > 0$ 是风险规避参数, 调节期望成本与方差 (风险) 之间的权衡

带二次约束的二次规划 (QCQP)

$$\begin{aligned} \min \quad & \frac{1}{2}x^T P_0 x + q_0^T x + r_0 \\ \text{s.t.} \quad & \frac{1}{2}x^T P_i x + q_i^T x + r_i \leq 0, \quad i = 1, \dots, m \\ & Ax = b \end{aligned}$$

- ▶ 要求 $P_i \in \mathbb{S}_+^n$, 所以目标函数与约束均为凸二次函数
- ▶ 要求 $P_1, \dots, P_m \in \mathbb{S}_{++}^n$, 所以可行域是 m 个椭球与一个仿射集的交集



二阶锥规划 (Second-order Cone Programming)

$$\begin{aligned} \min \quad & f^T x \\ \text{s.t.} \quad & \|A_i x + b_i\|_2 \leq c_i^T x + d_i, \quad i = 1, \dots, m \\ & Fx = g \end{aligned}$$

其中 $A_i \in \mathbb{R}^{n_i \times n}$, $F \in \mathbb{R}^{p \times n}$

- ▶ 不等式为二阶锥 (second-order cone, SOC) 约束, 也可以表示为:

$$(A_i x + b_i, c_i^T x + d_i) \in n_i + 1 \text{ 维的二阶锥}$$

- ▶ 若 $n_i = 0$, 则退化为线性规划; 若 $c_i = 0$, 则退化为 QCQP
- ▶ 比 QCQP 和 LP 更一般

鲁棒线性规划 (Robust Linear Programming)

优化问题中的参数常常具有不确定性，例如在线性规划中：

$$\begin{aligned} \min \quad & c^T x \\ \text{s.t.} \quad & a_i^T x \leq b_i, \quad i = 1, \dots, m \end{aligned}$$

其中 c , a_i , b_i 都可能具有不确定性。

我们以 a_i 为例，常见的两种建模方式：

- **确定性模型：** 约束对所有可能的 $a_i \in \mathcal{E}_i$ 都必须成立

$$\min \quad c^T x \quad \text{s.t.} \quad a_i^T x \leq b_i \quad \forall a_i \in \mathcal{E}_i, \quad i = 1, \dots, m$$

- **随机模型：** a_i 是随机变量，约束以概率 η 成立

$$\min \quad c^T x \quad \text{s.t.} \quad \text{prob}(a_i^T x \leq b_i) \geq \eta, \quad i = 1, \dots, m$$

确定性鲁棒优化中的 SOCP 表达

- ▶ 对于不确定集 $\mathcal{E}_i$, 选用椭球形式:

$$\mathcal{E}_i = \{\bar{a}_i + P_i u \mid \|u\|_2 \leq 1\}, \quad \bar{a}_i \in \mathbb{R}^n, \quad P_i \in \mathbb{R}^{n \times n}$$

中心为 $\bar{a}_i$, 半轴由 P_i 的奇异值与奇异向量决定

- ▶ 鲁棒线性规划问题:

$$\min c^T x \quad \text{s.t.} \quad a_i^T x \leq b_i, \quad \forall a_i \in \mathcal{E}_i, \quad i = 1, \dots, m$$

可等价转化为二阶锥规划:

$$\min c^T x \quad \text{s.t.} \quad \bar{a}_i^T x + \|P_i^T x\|_2 \leq b_i, \quad i = 1, \dots, m$$

(推导基于: $\sup_{\|u\|_2 \leq 1} (\bar{a}_i + P_i u)^T x = \bar{a}_i^T x + \|P_i^T x\|_2$)

随机鲁棒优化中的 SOCP 表达

- ▶ 假设 $a_i \sim \mathcal{N}(\bar{a}_i, \Sigma_i)$, 均值为 $\bar{a}_i$, 协方差为 Σ_i
- ▶ 则 $a_i^T x$ 是正态分布随机变量, 均值为 $\bar{a}_i^T x$, 方差为 $x^T \Sigma_i x$
- ▶ 因此概率约束可写为: $\text{prob}(a_i^T x \leq b_i) = \Phi\left(\frac{b_i - \bar{a}_i^T x}{\|\Sigma_i^{1/2} x\|_2}\right)$

其中 $\Phi(x) = (1/\sqrt{2\pi}) \int_{-\infty}^x e^{-t^2/2} dt$ 为标准正态分布的累积分布函数

- ▶ 鲁棒线性规划问题:

$$\min c^T x \quad \text{s.t.} \quad \text{prob}(a_i^T x \leq b_i) \geq \eta, \quad i = 1, \dots, m$$

当 $\eta \geq 1/2$ 时, 可转化为 SOCP:

$$\min c^T x \quad \text{s.t.} \quad \bar{a}_i^T x + \Phi^{-1}(\eta) \|\Sigma_i^{1/2} x\|_2 \leq b_i, \quad i = 1, \dots, m$$



半正定规划 (Semidefinite Program, SDP)

$$\begin{aligned} \min \quad & c^T x \\ \text{s.t.} \quad & x_1 F_1 + x_2 F_2 + \cdots + x_n F_n + G \preceq 0 \\ & Ax = b \end{aligned}$$

其中给定参数为: c, A, b 以及 $F_i, G \in \mathbb{S}^k$; 决策变量: $x \in \mathbb{R}^n$

- ▶ 不等式约束被称为线性矩阵不等式
- ▶ 多个不等式, 如: $x_1 \hat{F}_1 + \cdots + x_n \hat{F}_n + \hat{G} \preceq 0, \quad x_1 \tilde{F}_1 + \cdots + x_n \tilde{F}_n + \tilde{G} \preceq 0$

等价于单个:
$$x_1 \begin{bmatrix} \hat{F}_1 & 0 \\ 0 & \tilde{F}_1 \end{bmatrix} + x_2 \begin{bmatrix} \hat{F}_2 & 0 \\ 0 & \tilde{F}_2 \end{bmatrix} + \cdots + x_n \begin{bmatrix} \hat{F}_n & 0 \\ 0 & \tilde{F}_n \end{bmatrix} + \begin{bmatrix} \hat{G} & 0 \\ 0 & \tilde{G} \end{bmatrix} \preceq 0$$



LP 与 SOCP 的 SDP 表达

LP 与等价 SDP

- ▶ LP: $\min c^T x \quad \text{s.t.} \quad Ax \leq b$
- ▶ SDP: $\min c^T x \quad \text{s.t.} \quad \text{diag}(Ax - b) \preceq 0$

SOCP 与等价 SDP

- ▶ SOCP: $\min f^T x \quad \text{s.t.} \quad \|A_i x + b_i\|_2 \leq c_i^T x + d_i, \quad i = 1, \dots, m$
- ▶ SDP:

$$\min f^T x \quad \text{s.t.} \quad \begin{bmatrix} (c_i^T x + d_i)I & A_i x + b_i \\ (A_i x + b_i)^T & c_i^T x + d_i \end{bmatrix} \succeq 0, \quad i = 1, \dots, m$$



特征值最小化问题 (Eigenvalue Minimization)

$$\begin{aligned} \min \quad & \lambda_{\max}(A(x)) \\ \text{s.t.} \quad & A(x) = A_0 + x_1 A_1 + \cdots + x_n A_n, \quad A_i \in \mathbb{S}^k \end{aligned}$$

等价的 SDP 形式:

$$\min t \quad \text{s.t.} \quad A(x) \preceq tI$$

- ▶ 决策变量为 $x \in \mathbb{R}^n, t \in \mathbb{R}$
- ▶ 推理基于:

$$\lambda_{\max}(A) \leq t \iff A \preceq tI$$