

上海财经大学

信息管理与工程学院

梯度下降法

优化理论与算法 第七章

王震



本章目录

基本思想与梯度下降算法

步长选择与线搜索

光滑性与收敛性分析

条件数、应用实验与小结



目录

基本思想与梯度下降算法

步长选择与线搜索

光滑性与收敛性分析

条件数、应用实验与小结



无约束优化问题

本章研究的是无约束优化问题

$$\min_{x \in \mathbb{R}^n} f(x),$$

其中 $f : \mathbb{R}^n \rightarrow \mathbb{R}$ 连续可微。

- ▶ 直接求解 $\nabla f(x) = 0$ 通常不可行：方程组高度非线性，且解未必唯一。
- ▶ 实际中常用迭代算法：从初始点 x^0 出发，构造点列 $\{x^k\}$ 逐步逼近极小点。
- ▶ 一个好的迭代格式应当满足两点：每一步实质性地改进目标，并且每一步代价可控。

大雾下山的类比

将 $f(x)$ 想象成地表的海拔高度（越低越好）。在大雾中我们无法看见全局，只能感受脚下最陡的下坡方向——这正是「梯度下降」的本质：仅利用局部一阶信息 $\nabla f(x)$ 来决定走向。





方向导数与梯度

设 f 在 x 处可微，单位向量 $d \in \mathbb{R}^n$ (即 $\|d\| = 1$)。沿方向 d 走 $\delta > 0$ 步：

$$f(x + \delta d) = f(x) + \delta \nabla f(x)^\top d + o(\delta).$$

当 $\delta \rightarrow 0^+$ 时，单位降幅近似为 $\nabla f(x)^\top d$ 。

- ▶ 若 $\nabla f(x)^\top d < 0$ ，则 d 称为下降方向 (descent direction)；
- ▶ 若 $\nabla f(x) = 0$ ，则 x 是驻点，无任何方向能产生一阶下降。



最速下降方向

定理 1.1: 最速下降方向

设 $\nabla f(x) \neq 0$, 则在所有满足 $\|d\| = 1$ 的方向中,

$$d^* = -\frac{\nabla f(x)}{\|\nabla f(x)\|}$$

是使一阶降幅 $\nabla f(x)^\top d$ 最小的方向, 对应降幅为 $-\|\nabla f(x)\|$ 。

证明: 由 Cauchy-Schwarz 不等式,

$$\nabla f(x)^\top d \geq -\|\nabla f(x)\| \|d\| = -\|\nabla f(x)\|,$$

且当且仅当 d 与 $-\nabla f(x)$ 同向 (即 $d = -\nabla f(x)/\|\nabla f(x)\|$) 时取等号。 □

梯度下降迭代

取负梯度方向作为搜索方向，得到梯度下降法（Gradient Descent, GD）：

$$x^{k+1} = x^k - \alpha_k \nabla f(x^k), \quad k = 0, 1, 2, \dots$$

其中 $\alpha_k > 0$ 是步长， $-\nabla f(x^k)$ 是最速下降方向。

对 f 在 x^k 处作一阶 Taylor 展开。令

$$s^k := x^{k+1} - x^k = -\alpha_k \nabla f(x^k),$$

则

$$f(x^k + s^k) = f(x^k) + \nabla f(x^k)^\top s^k + o(\|s^k\|).$$

代入 $s^k = -\alpha_k \nabla f(x^k)$ ，得

$$f(x^{k+1}) = f(x^k) - \alpha_k \|\nabla f(x^k)\|^2 + o(\alpha_k \|\nabla f(x^k)\|).$$

含义：若 $\nabla f(x^k) \neq 0$ 且 α_k 足够小，主项为负，函数值会下降；若 α_k 太大，高阶项可能破坏下降。



算法 1 梯度下降法

输入： 初始点 x^0 ，容差 $\varepsilon > 0$ ，最大迭代 K

- 1: **for** $k = 0, 1, 2, \dots, K - 1$ **do**
- 2: 计算梯度 $g^k = \nabla f(x^k)$
- 3: **if** $\|g^k\| \leq \varepsilon$ **then**
- 4: 输出 x^k ，停止
- 5: **end if**
- 6: 选取步长 $\alpha_k > 0$
- 7: 更新 $x^{k+1} = x^k - \alpha_k g^k$
- 8: **end for**

核心问题：如何选取步长 α_k ，使每一步既能下降，又不会因步子太大而振荡或发散？



实验一：一维函数上的步长影响



实验目标：用最简单的函数观察步长如何影响收敛、振荡与发散。

$$f(x) = x^2, \quad \nabla f(x) = 2x, \quad x^{k+1} = (1 - 2\alpha)x^k.$$

- ▶ 初始点： $x^0 = 5$;
- ▶ 步长： $\alpha = 0.05, 0.2, 0.5, 0.9, 1.1$;
- ▶ 观察： x^k 与 $f(x^k)$ 随迭代次数的变化。

关键判断： $|1 - 2\alpha| < 1$ 时收敛； $1 - 2\alpha < 0$ 时会振荡； $|1 - 2\alpha| > 1$ 时发散。

实验结果：一维梯度下降



解读： $\alpha = 0.5$ 时一步到达最优点； $\alpha = 0.9$ 振荡但收敛； $\alpha = 1.1$ 发散。



目录

基本思想与梯度下降算法

步长选择与线搜索

光滑性与收敛性分析

条件数、应用实验与小结

为什么步长如此关键

前面的一维实验已经说明：步长决定了收敛、振荡还是发散。这里固定一个二维函数，只讨论步长本身的影响：

$$f(x_1, x_2) = \frac{1}{2}(x_1^2 + 10x_2^2), \quad L = 10.$$

梯度下降为

$$x_1^{k+1} = (1 - \alpha)x_1^k, \quad x_2^{k+1} = (1 - 10\alpha)x_2^k.$$

步长过小

步长过大若 $\alpha > 2/L = 0.2$ ，则

$$|1 - \alpha| \approx 1, \quad |1 - 10\alpha| \approx 1.$$

$$|1 - 10\alpha| > 1,$$

两个坐标每次只缩小一点点，因此下降稳定但慢。

第二个坐标会被放大，出现振荡甚至发散。

结论：本页只解释步长大小。条件数为何让问题更难，将放到后面的“条件数”部分统一说明。



四类步长策略：具体做法

1. 常数步长：

$$\alpha_k \equiv \alpha.$$

若已知 f 为 L -光滑，理论上常取 $\alpha \leq 1/L$ ，例如 $\alpha = 1/L$ 。

2. 精确线搜索：

$$\alpha_k \in \arg \min_{\alpha \geq 0} f(x^k - \alpha \nabla f(x^k)).$$

对二次函数 $f(x) = \frac{1}{2}x^\top Qx$ ，有闭式

$$\alpha_k = \frac{\nabla f(x^k)^\top \nabla f(x^k)}{\nabla f(x^k)^\top Q \nabla f(x^k)}.$$



四类步长策略：具体做法（续）

3. 非精确线搜索（**Armijo**）：不要求一步最优，只要求函数值有“足够下降”：

$$f(x^k - \alpha \nabla f(x^k)) \leq f(x^k) - c_1 \alpha \|\nabla f(x^k)\|^2.$$

若不满足，就令 $\alpha \leftarrow \beta \alpha$ 回溯。

4. 递减步长：

$$\alpha_k = \frac{\alpha_0}{(k+1)^p}, \quad 0 < p \leq 1.$$

例如 $\alpha_k = 0.5/\sqrt{k+1}$ 。这类方法常见于随机梯度或非光滑问题。

小结：常数步长看重简单与理论，精确线搜索看重单步效果，Armijo 看重稳健，递减步长看重大规模与噪声场景。



常见步长策略：优劣对比

方法	优势	局限
常数步长	实现最简单；理论分析清楚；适合课堂证明。	需要估计 L ；取小慢，取大发散。
精确线搜索	沿当前方向单步最优；适合二次函数演示。	每步要解一维优化，一般问题代价高。
Armijo	不需提前知道 L ；自动避免过大步长；函数值单调下降。	每步可能多次计算函数值；参数需要设置。
递减步长	适合随机梯度、噪声和大规模场景。	后期可能太小；理论条件和调参较细。



实验二：四类步长策略对比

固定同一个二次函数

$$f(x) = \frac{1}{2}(x_1^2 + 10x_2^2), \quad x^0 = (5, 5),$$





比较四种步长策略：

- ▶ 常数步长： $\alpha = 1/L = 0.1$;
- ▶ 精确线搜索：每步求 $\arg \min_{\alpha} f(x^k - \alpha \nabla f(x^k))$;
- ▶ Armijo 回溯：从 $\hat{\alpha} = 1$ 开始，不满足充分下降就缩小；
- ▶ 递减步长： $\alpha_k = 0.5/\sqrt{k+1}$ 。


目的：让学生看到“步长策略”不只是一个参数，而是一类算法设计选择。

实验结果：四类步长策略的轨迹

Four step-size strategies on the same quadratic problem




实验结果：四类步长策略的函数值



解读：常数步长稳定且适合理论；精确线搜索单步贪心；Armijo 自动避开过大步长；递减步长后期变小，常更保守。

补充实验：步长过小、合适与过大

若只看常数步长，固定 $L = 10$ ，稳定条件约为 $0 < \alpha < 2/L = 0.2$ 。



作用：这张图作为“步长大小”的补充说明，不再承担“四种方法比较”的角色。



Armijo 充分下降条件

取参数 $c_1 \in (0, 1)$ (常用 $c_1 = 10^{-4}$)。称步长 α 满足 **Armijo** 条件, 若


$$f(x^k - \alpha \nabla f(x^k)) \leq f(x^k) - c_1 \alpha \|\nabla f(x^k)\|^2.$$

解释: 函数值不仅要降, 还要至少降到与 α 成比例的" 梯度能量" 那么多。

- ▶ 右端是一条允许的下降上界线;
- ▶ 实际函数值落到这条线下方时, 接受该步长;
- ▶ 若不满足, 就通过回溯把步长缩小。

c_1 的作用: 它控制“要求下降多少”。 c_1 越大, 要求越严格, 回溯可能越多; c_1 很小时, 比较容易接受当前步长。

Armijo 条件的几何图示





回溯线搜索（Armijo 回溯）

算法 2 Armijo 回溯线搜索

输入： 当前点 x^k ，初值 $\hat{\alpha} > 0$ ，参数 $c_1 \in (0, 1)$ ， $\beta \in (0, 1)$

1: 令 $\alpha \leftarrow \hat{\alpha}$

2: **while** $f(x^k - \alpha \nabla f(x^k)) > f(x^k) - c_1 \alpha \|\nabla f(x^k)\|^2$ **do**

3: $\alpha \leftarrow \beta \alpha$

4: **end while**

5: 输出 $\alpha_k = \alpha$

常用参数： $\hat{\alpha} = 1$ ， $\beta = 1/2$ ， $c_1 = 10^{-4}$ 。优势：无需知道 L ，仅需函数值与梯度即可执行。





实验三：Armijo 自动选步长

实验目标：比较固定步长与回溯线搜索的不同，观察 Armijo 如何自动调整 α_k 。

$$f(x_1, x_2) = \frac{1}{2}(x_1^2 + 10x_2^2), \quad x^0 = (5, 5).$$


- ▶ 初始试探步长： $\hat{\alpha} = 1$;
- ▶ 回溯比例： $\beta = 1/2$;
- ▶ Armijo 参数： $c_1 = 10^{-4}$;
- ▶ 每步记录： α_k 、 $f(x^k)$ 、 $\|\nabla f(x^k)\|$ 、回溯次数。

实验结果: Armijo 的轨迹与函数值






实验结果：Armijo 的步长变化



解读：Armijo 从较大步长开始试探，下降不足时缩小步长；最终保证函数值单调下降。

实验结果: Armijo 参数的影响



解读: β 越小, 每次回溯缩得越猛; c_1 越大, 对下降量要求越严格, 可能接受更小步长。课堂中可用 notebook 修改 $\hat{\alpha}, \beta, c_1$ 观察差异。



目录

基本思想与梯度下降算法

步长选择与线搜索

光滑性与收敛性分析

条件数、应用实验与小结



梯度 Lipschitz 与 L -光滑

定义 3.1: 梯度 Lipschitz 连续

设 $f: \mathbb{R}^n \rightarrow \mathbb{R}$ 连续可微。若存在常数 $L > 0$ 使得

$$\|\nabla f(x) - \nabla f(y)\| \leq L\|x - y\|, \quad \forall x, y \in \mathbb{R}^n,$$

则称 ∇f 是 L -Lipschitz 连续的, 也称 f 为 L -光滑的。

等价刻画 (不证): f 为 L -光滑 $\iff$ 对所有 x, y 有

$$f(y) \leq f(x) + \nabla f(x)^\top (y - x) + \frac{L}{2} \|y - x\|^2 \quad (\text{二次上界}).$$

若 f 二阶可微, 等价于 $\nabla^2 f(x) \preceq LI$ 。



充分下降引理（核心证明 1）

引理 3.1: 充分下降引理

设 f 为 L -光滑。对任意 $x \in \mathbb{R}^n$ 与任意步长 $\alpha > 0$, 令 $x^+ = x - \alpha \nabla f(x)$ 。则

$$f(x^+) \leq f(x) - \alpha \left(1 - \frac{L\alpha}{2}\right) \|\nabla f(x)\|^2.$$

特别地, 当 $0 < \alpha < \frac{2}{L}$ 时, 记 $M = \alpha \left(1 - \frac{L\alpha}{2}\right) > 0$, 有

$$f(x^+) \leq f(x) - M \|\nabla f(x)\|^2.$$



充分下降引理：证明

由 L -光滑的二次上界，取 $y = x^+ = x - \alpha \nabla f(x)$ ：

$$f(x^+) \leq f(x) + \nabla f(x)^\top (x^+ - x) + \frac{L}{2} \|x^+ - x\|^2.$$

代入 $x^+ - x = -\alpha \nabla f(x)$ ：

$$\begin{aligned}\nabla f(x)^\top (x^+ - x) &= -\alpha \|\nabla f(x)\|^2, \\ \|x^+ - x\|^2 &= \alpha^2 \|\nabla f(x)\|^2.\end{aligned}$$

代回整理：

$$f(x^+) \leq f(x) - \alpha \|\nabla f(x)\|^2 + \frac{L\alpha^2}{2} \|\nabla f(x)\|^2 = f(x) - \alpha \left(1 - \frac{L\alpha}{2}\right) \|\nabla f(x)\|^2.$$

当 $\alpha < 2/L$ 时 $1 - L\alpha/2 > 0$ ，得 $M > 0$ 。

□

评注：步长取 $\alpha = 1/L$ 时 $M = 1/(2L)$ 最大化下降量。



收敛性分析的"三份合同"

对常数步长梯度下降 $x^{k+1} = x^k - \alpha \nabla f(x^k)$, 在不同假设下我们关心不同的衡量:

假设	衡量量	典型速度
L -光滑 + 下有界	$\min_{i \leq k} \ \nabla f(x^i)\ ^2$	$O(1/k)$ (次线性)
L -光滑 + 凸	$f(x^k) - f^*$	$O(1/k)$ (次线性)
L -光滑 + μ -强凸	$f(x^k) - f^*$ 或 $\ x^k - x^*\ ^2$	线性 (指数)

本节重点证明凸光滑情形下的 $O(1/k)$ 收敛速度 (核心证明 2), 其他两类只给定理结论。



非凸但有下界：定理结论

定理 3.1: 非凸情形下的次线性梯度收敛

设 f 为 L -光滑且 $f^* = \inf_x f(x) > -\infty$ 。取常数步长 $0 < \alpha < 2/L$ ，则

$$\min_{0 \leq i \leq k} \|\nabla f(x^i)\|^2 \leq \frac{f(x^0) - f^*}{(k+1)M},$$

其中 $M = \alpha(1 - L\alpha/2)$ 。

思路（不展开）：对充分下降引理累加，左侧得到梯度范数平方之和的"望远镜"形式；用"最小值不超过平均值"即得。

结论：至多 $O(1/\varepsilon^2)$ 步可使 $\min_i \|\nabla f(x^i)\| \leq \varepsilon$ ，即近似驻点。

凸 + L -光滑（核心证明 2：定理）

定理 3.2: 凸光滑情形下的 $O(1/k)$ 收敛

设 f 凸且 L -光滑，存在极小点 x^* 。取常数步长 $0 < \alpha \leq 1/L$ ，则

$$f(x^k) - f(x^*) \leq \frac{\|x^0 - x^*\|^2}{2\alpha k}, \quad k \geq 1.$$

特别地， $\alpha = 1/L$ 时上界为 $L\|x^0 - x^*\|^2/(2k)$ 。

结论：至多 $O(1/\varepsilon)$ 步可使 $f(x^k) - f(x^*) \leq \varepsilon$ 。

核心证明 2: 第 1 步 (充分下降的简化)

记 $\mathbf{g}^k = \nabla f(\mathbf{x}^k)$ 。由充分下降引理, 当 $\alpha \leq 1/L$ 时

$$1 - \frac{L\alpha}{2} \geq \frac{1}{2} \implies f(\mathbf{x}^{k+1}) \leq f(\mathbf{x}^k) - \frac{\alpha}{2} \|\mathbf{g}^k\|^2. \quad (1)$$

另由梯度步 $\mathbf{x}^{k+1} = \mathbf{x}^k - \alpha \mathbf{g}^k$ 展开:

$$\begin{aligned} \|\mathbf{x}^{k+1} - \mathbf{x}^*\|^2 &= \|(\mathbf{x}^k - \mathbf{x}^*) - \alpha \mathbf{g}^k\|^2 \\ &= \|\mathbf{x}^k - \mathbf{x}^*\|^2 - 2\alpha(\mathbf{g}^k)^\top (\mathbf{x}^k - \mathbf{x}^*) + \alpha^2 \|\mathbf{g}^k\|^2. \end{aligned}$$

即

$$2\alpha(\mathbf{g}^k)^\top (\mathbf{x}^k - \mathbf{x}^*) = \|\mathbf{x}^k - \mathbf{x}^*\|^2 - \|\mathbf{x}^{k+1} - \mathbf{x}^*\|^2 + \alpha^2 \|\mathbf{g}^k\|^2. \quad (2)$$

核心证明 2：第 2 步（用凸性把内积换成函数差）

由凸性（一阶下界）：

$$f(x^*) \geq f(x^k) + (g^k)^\top (x^* - x^k),$$

等价地

$$(g^k)^\top (x^k - x^*) \geq f(x^k) - f(x^*). \quad (3)$$

将 (3) 代入 (2) 左侧（放缩）：

$$2\alpha(f(x^k) - f(x^*)) \leq \|x^k - x^*\|^2 - \|x^{k+1} - x^*\|^2 + \alpha^2 \|g^k\|^2. \quad (4)$$

再用 (1)： $\alpha^2 \|g^k\|^2 \leq 2\alpha(f(x^k) - f(x^{k+1}))$ ，代入 (4)：

$$2\alpha(f(x^{k+1}) - f(x^*)) \leq \|x^k - x^*\|^2 - \|x^{k+1} - x^*\|^2. \quad (5)$$

核心证明 2: 第 3 步 (望远镜求和 + 单调性)

对 $i = 0, 1, \dots, k-1$ 把 (5) 累加 (左侧求和、右侧望远镜消去):

$$2\alpha \sum_{i=0}^{k-1} (f(x^{i+1}) - f(x^*)) \leq \|x^0 - x^*\|^2 - \|x^k - x^*\|^2 \leq \|x^0 - x^*\|^2. \quad (6)$$

由 (1) 知 $\{f(x^k)\}$ 单调不增, 故对 $i = 0, \dots, k-1$ 都有 $f(x^{i+1}) \geq f(x^k)$, 从而

$$k(f(x^k) - f(x^*)) \leq \sum_{i=0}^{k-1} (f(x^{i+1}) - f(x^*)). \quad (7)$$

合并 (6)(7):

$$2\alpha k(f(x^k) - f(x^*)) \leq \|x^0 - x^*\|^2,$$

$$\text{即 } f(x^k) - f(x^*) \leq \frac{\|x^0 - x^*\|^2}{2\alpha k}.$$

□

实验四：两个例子理解 $O(1/k)$

实验目标：区分“定理上界有效”和“实际曲线看起来像 $1/k$ ”这两件事。

$$f(x^k) - f(x^*) \leq \frac{\|x^0 - x^*\|^2}{2\alpha k}.$$

例 1：强凸二次函数

$$f(x) = \frac{1}{2}x^\top Qx, \quad Q = \begin{pmatrix} 1 & 0 \\ 0 & 10 \end{pmatrix}.$$

- ▶ 它不仅凸光滑，而且强凸，因此实际收敛是线性的；
- ▶ 所以 $O(1/k)$ 上界正确，但会显得很松。


例 2：非强凸光滑凸函数

$$f(x) = \log(1 + \exp(x)), \quad \inf_x f(x) = 0.$$

- ▶ 该函数凸且光滑，但没有强凸曲率；
- ▶ 在数值上更容易看到接近 $1/k$ 的下降趋势。




实验结果：强凸二次函数更快



解读：实际函数差下降远快于 $1/k$ 。这不是定理失效，而是因为强凸给出了更强的线性收敛。

实验结果：非强凸光滑凸函数



函数:

$$f(x) = \log(1 + \exp(x)).$$

设置:

$$L = \frac{1}{4}, \quad \alpha = \frac{1}{L} = 4.$$

现象:

- ▶ 后期函数值与 C/k 参考线接近;
- ▶ 这更适合作为 $O(1/k)$ 速度的直观演示;
- ▶ 注意该例最小值 0 在 $-\infty$ 处达到极限, 主要用于演示速度形态。

强凸函数：从“平底碗”到“尖底碗”

定义 3.2: 强凸函数

f 称为 μ -强凸 ($\mu > 0$), 若对任意 x, y 都有

$$f(y) \geq f(x) + \nabla f(x)^\top (y - x) + \frac{\mu}{2} \|y - x\|^2.$$

和普通凸性的区别:

- ▶ 普通凸性只要求函数图像在切平面之上;
- ▶ 强凸性要求函数图像至少在一个二次下界之上;
- ▶ μ 越大, 底部越“尖”, 离最优点越远时函数值惩罚越明显。

若 f 二阶可微, 则可以理解为

$$\nabla^2 f(x) \succeq \mu I,$$

即每个方向上都有至少 μ 的曲率。

强凸与光滑：上下两个二次模型

若 f 同时 μ -强凸且 L -光滑，则对任意 x, y 有

$$\underbrace{f(x) + \nabla f(x)^\top (y - x) + \frac{\mu}{2} \|y - x\|^2}_{\text{强凸给出的二次下界}} \leq f(y) \\ \leq \underbrace{f(x) + \nabla f(x)^\top (y - x) + \frac{L}{2} \|y - x\|^2}_{\text{L-光滑给出的二次上界}}.$$

这两个不等式各自负责一件事：

- ▶ L -光滑：控制函数不要弯得太厉害，保证合适步长会下降；
- ▶ μ -强凸：控制函数不要太平，保证梯度不可能“很小但还离最优很远”；
- ▶ 二者合在一起，就能把“每步下降”变成“按固定比例下降”。



强凸的直接后果：最优点唯一且函数差可控

设 x^* 为最优点。由强凸性，取 $x = x^*$ ，并利用 $\nabla f(x^*) = 0$ ，得

$$f(x) \geq f(x^*) + \frac{\mu}{2} \|x - x^*\|^2.$$

因此

$$f(x) - f^* \geq \frac{\mu}{2} \|x - x^*\|^2.$$

含义：

- ▶ 函数值越接近最优，点也越接近最优；
- ▶ 若存在两个不同最优点，上式会给出矛盾，因此最优点唯一；
- ▶ 但要证明梯度下降线性收敛，还需要一个更关键的不等式：用梯度范数控制函数值差。

关键引理：梯度范数控制函数值差

引理 3.2: 强凸给出的梯度下界

若 f 为 μ -强凸且可微, 记 $f^* = \min_x f(x)$, 则

$$\|\nabla f(x)\|^2 \geq 2\mu(f(x) - f^*).$$

证明思路: 强凸性说明 $f(y)$ 总在一个二次函数之上。把这个二次下界关于 y 最小化, 可以得到一个对 f^* 的下界。

$$f(y) \geq f(x) + \nabla f(x)^\top (y - x) + \frac{\mu}{2} \|y - x\|^2. \quad (1)$$

右侧是关于 y 的强凸二次函数。



关键引理：详细推导

令

$$q_x(y) = f(x) + \nabla f(x)^\top (y - x) + \frac{\mu}{2} \|y - x\|^2.$$

对 y 求导：

$$\nabla_y q_x(y) = \nabla f(x) + \mu(y - x).$$

令其为零，得右侧二次模型的最小点

$$y = x - \frac{1}{\mu} \nabla f(x).$$

代入 $q_x(y)$ ：

$$\min_y q_x(y) = f(x) - \frac{1}{\mu} \|\nabla f(x)\|^2 + \frac{1}{2\mu} \|\nabla f(x)\|^2 = f(x) - \frac{1}{2\mu} \|\nabla f(x)\|^2.$$

因为 $f(y) \geq q_x(y)$ ，所以

$$f^* = \min_y f(y) \geq \min_y q_x(y) = f(x) - \frac{1}{2\mu} \|\nabla f(x)\|^2.$$

整理即得引理。□



强凸 + L -光滑：线性收敛定理

定理 3.3: 强凸光滑下的线性收敛

设 f 为 μ -强凸且 L -光滑，取梯度下降步长 $\alpha = 1/L$ 。则

$$f(x^k) - f^* \leq \left(1 - \frac{\mu}{L}\right)^k (f(x^0) - f^*).$$

为什么叫线性收敛？

- ▶ 误差不是每次减去一个固定数，而是每次乘以固定比例；
- ▶ 比例因子为 $1 - \mu/L$ ，严格小于 1；
- ▶ 在半对数图上，函数值差近似表现为一条直线。

线性收敛证明：把两个不等式接起来

第一步：由 L -光滑得到充分下降。取 $\alpha = 1/L$ ，梯度下降 $x^{k+1} = x^k - \frac{1}{L}\nabla f(x^k)$ 满足

$$f(x^{k+1}) \leq f(x^k) - \frac{1}{2L} \|\nabla f(x^k)\|^2. \quad (2)$$

第二步：由强凸关键引理得到梯度下界。

$$\|\nabla f(x^k)\|^2 \geq 2\mu(f(x^k) - f^*). \quad (3)$$

第三步：把 **(3)** 代入 **(2)**。

$$f(x^{k+1}) \leq f(x^k) - \frac{\mu}{L}(f(x^k) - f^*).$$

两边减去 f^* ，得

$$f(x^{k+1}) - f^* \leq \left(1 - \frac{\mu}{L}\right)(f(x^k) - f^*). \quad (4)$$

线性收敛证明：递推得到全局结论

令

$$\Delta_k = f(x^k) - f^*, \quad \rho = 1 - \frac{\mu}{L}.$$

由上一页 (4) 可写成

$$\Delta_{k+1} \leq \rho \Delta_k, \quad 0 < \rho < 1.$$

连续使用该递推：

$$\Delta_1 \leq \rho \Delta_0, \quad \Delta_2 \leq \rho \Delta_1 \leq \rho^2 \Delta_0, \quad \dots$$

因此

$$\Delta_k \leq \rho^k \Delta_0 = \left(1 - \frac{\mu}{L}\right)^k (f(x^0) - f^*).$$

达到精度 ε ：

$$f(x^k) - f^* \leq \varepsilon \iff k = O\left(\frac{L}{\mu} \log \frac{1}{\varepsilon}\right).$$



线性收敛与条件数

强凸光滑下的收敛因子为

$$1 - \frac{\mu}{L} = 1 - \frac{1}{\kappa}, \quad \kappa = \frac{L}{\mu}.$$

- ▶ L 表示最大曲率，控制步长不能太大；
- ▶ μ 表示最小曲率，控制函数底部不能太平；
- ▶ $\kappa = L/\mu$ 越大，说明不同方向曲率差异越大。

两个典型情况：

- ▶ κ 小： $1 - 1/\kappa$ 远离 1，下降快；
- ▶ κ 大： $1 - 1/\kappa$ 接近 1，下降慢，轨迹常出现“之”字形。



目录

基本思想与梯度下降算法

步长选择与线搜索

光滑性与收敛性分析

条件数、应用实验与小结

条件数：梯度下降为何怕“病态”

对二次型 $f(x) = \frac{1}{2}x^\top Qx$ ($Q \succ 0$)，定义条件数

$$\kappa := \frac{\lambda_{\max}(Q)}{\lambda_{\min}(Q)} = \frac{L}{\mu} \geq 1.$$

- ▶ 强凸光滑下，几何因子 $1 - \mu/L = 1 - 1/\kappa$ ： κ 越大，每步缩减越接近 1；
- ▶ 等高线越扁平（轴长比 $= \sqrt{\kappa}$ ），梯度方向越偏离指向最优点，出现之字形轨迹；
- ▶ 病态问题（ κ 很大）正是梯度下降法的主要劣势所在。

加速思路：动量法 / Nesterov 加速可将凸光滑情形改进至 $O(1/k^2)$ ，强凸情形改进至 $O(\sqrt{\kappa} \log(1/\varepsilon))$ 。




实验五：条件数与梯度下降轨迹

实验目标：观察条件数变大时，等高线如何变狭长，梯度下降轨迹为何变慢。

$$f(x_1, x_2) = \frac{1}{2}(x_1^2 + \gamma x_2^2), \quad \nabla f(x) = (x_1, \gamma x_2)^\top.$$

- ▶ 比较 $\gamma = 1, 10, 100$;
- ▶ 条件数可理解为 $\kappa = \gamma$;
- ▶ 每个 γ 下取稳定步长 $\alpha = 0.9/\gamma$ ，避免把“发散”误认为“条件数影响”。

实验结果：条件数对轨迹的影响



解读： γ 越大，等高线越狭长，负梯度方向越容易与通向最优点的方向偏离；即使步长稳定，下降也会更慢。

实验六：线性回归中的梯度下降

最小二乘问题



$$\min_w \frac{1}{2m} \|Xw - y\|^2$$

是机器学习中最常见的二次优化问题之一，其梯度为

$$\nabla f(w) = \frac{1}{m} X^\top (Xw - y).$$

- ▶ 比较不同学习率 $\alpha = 0.01, 0.05, 0.2$;
- ▶ 观察 loss 曲线和参数 w 的收敛轨迹;
- ▶ 说明抽象的梯度下降理论如何进入机器学习训练。

实验结果：线性回归的 **loss** 与参数轨迹





本章小结

核心算法 $x^{k+1} = x^k - \alpha_k \nabla f(x^k)$: 方向 = 负梯度, 步长 = 关键。

关键工具

- ▶ L -光滑的二次上界 $\Rightarrow$ 充分下降引理 (核心证明 1);
- ▶ 凸性 + 充分下降 + 望远镜求和 $\Rightarrow$ 凸光滑下 $O(1/k)$ (核心证明 2)。

速度对照

- ▶ 非凸光滑: $\min_i \|\nabla f(x^i)\|^2 = O(1/k)$;
- ▶ 凸光滑: $f(x^k) - f^* = O(1/k)$;
- ▶ 强凸光滑: $f(x^k) - f^*$ 与 $\|x^k - x^*\|^2$ 均线性收敛。

下一步 投影梯度 (约束)、次梯度 (非光滑)、加速方法、随机梯度、二阶法等。