



对偶理论

- ▶ 对优化理论至关重要
- ▶ 其理论与实践中的影响深远
- ▶ 一种强大的工具，提供：
 - ▶ 优化算法丰富类别发展的基础
 - ▶ 一种系统的泛化方法，用于构建上下界策略（适用于连续与离散优化）
 - ▶ 敏感性分析的基础



对偶理论的基本思想与核心问题

- ▶ 将一个“等价的对偶问题”与给定的（原始）问题关联起来
- ▶ 该方法适用于一般约束优化问题
- ▶ 研究的问题包括：
 - ▶ 原始问题与其对偶问题之间是否存在一般性的关系？
 - ▶ 在什么条件下，原始问题与对偶问题具有相同的最优值？
 - ▶ 在什么条件下，原始与对偶问题的最优解存在？
 - ▶ 原始与对偶问题的最优解之间有何关系？
 - ▶ 对偶最优解可以提供关于原始问题哪些方面的信息？

拉格朗日函数 (Lagrangian)

标准形式问题 (不要求是凸的):

$$\begin{aligned} \min \quad & f_0(x) \\ \text{s.t.} \quad & f_i(x) \leq 0, \quad i = 1, \dots, m \\ & h_i(x) = 0, \quad i = 1, \dots, p \end{aligned}$$

变量 $x \in \mathbb{R}^n$, 定义域 $\mathcal{D}$, 最优值为 p^*

拉格朗日函数: $L: \mathbb{R}^n \times \mathbb{R}^m \times \mathbb{R}^p \rightarrow \mathbb{R}$, 定义域为 $\text{dom } L = \mathcal{D} \times \mathbb{R}^m \times \mathbb{R}^p$, 其形式为:

$$L(x, \lambda, \nu) = f_0(x) + \sum_{i=1}^m \lambda_i f_i(x) + \sum_{i=1}^p \nu_i h_i(x)$$

- ▶ 目标函数与约束函数的加权和
- ▶ λ_i 是与不等式约束 $f_i(x) \leq 0$ 对应的拉格朗日乘子
- ▶ ν_i 是与等式约束 $h_i(x) = 0$ 对应的拉格朗日乘子

拉格朗日对偶函数 (Lagrange Dual Function)

拉格朗日对偶函数: $g: \mathbb{R}^m \times \mathbb{R}^p \rightarrow \mathbb{R}$, 定义为:

$$\begin{aligned} g(\lambda, \nu) &= \inf_{x \in \mathcal{D}} L(x, \lambda, \nu) \\ &= \inf_{x \in \mathcal{D}} \left(f_0(x) + \sum_{i=1}^m \lambda_i f_i(x) + \sum_{i=1}^p \nu_i h_i(x) \right) \end{aligned}$$

- ▶ 函数 g 是凹函数, 但在某些 λ, ν 情况下可能为 $-\infty$
- ▶ 下界性质 (Lower bound property): 若 $\lambda \succeq 0$, 则 $g(\lambda, \nu) \leq p^*$

证明: 若 $\tilde{x}$ 是可行解, 且 $\lambda \succeq 0$, 则有

$$f_0(\tilde{x}) \geq L(\tilde{x}, \lambda, \nu) \geq \inf_{x \in \mathcal{D}} L(x, \lambda, \nu) = g(\lambda, \nu)$$

对所有可行的 $\tilde{x}$ 取最小值, 可得:

$$p^* \geq g(\lambda, \nu)$$

线性方程组的最小范数解 (Least-norm Solution)

$$\min \quad x^T x$$

$$\text{s.t.} \quad Ax = b$$

对偶函数 (dual function):

► 拉格朗日函数为: $L(x, \nu) = x^T x + \nu^T (Ax - b)$

► 对 x 最小化 L , 令梯度为零:

$$\nabla_x L(x, \nu) = 2x + A^T \nu = 0 \quad \Rightarrow \quad x = -\frac{1}{2} A^T \nu$$

► 将 x 代入 L 得到 g :

$$g(\nu) = L\left(-\frac{1}{2} A^T \nu, \nu\right) = -\frac{1}{4} \nu^T A A^T \nu - b^T \nu$$

► $g(\nu)$ 是 ν 的一个凹函数

下界性质 (lower bound property):

$$p^* \geq -\frac{1}{4} \nu^T A A^T \nu - b^T \nu, \quad \text{对所有 } \nu \text{ 成立}$$

标准形式线性规划 (Standard Form LP)

$$\min \quad c^T x$$

$$\text{s.t.} \quad Ax = b, \quad x \succeq 0$$

对偶函数 (dual function):

► 拉格朗日函数为:

$$\begin{aligned} L(x, \lambda, \nu) &= c^T x + \nu^T (Ax - b) - \lambda^T x \\ &= -b^T \nu + (c + A^T \nu - \lambda)^T x \end{aligned}$$

► L 是关于 x 的仿射函数, 因此:

$$g(\lambda, \nu) = \inf_x L(x, \lambda, \nu) = \begin{cases} -b^T \nu, & A^T \nu - \lambda + c = 0 \\ -\infty, & \text{否则} \end{cases}$$

► g 是定义在 $\{(\lambda, \nu) \mid A^T \nu - \lambda + c = 0\}$ 上的线性函数, 因此是凹函数

下界性质 (lower bound property):

$$p^* \geq -b^T \nu \quad \text{若 } A^T \nu + c \succeq 0$$

二次规划 (Quadratic Program)

原始问题 (Primal Problem) (假设 $P \in \mathbb{S}_{++}^n$):

$$\begin{aligned} \min \quad & x^T P x \\ \text{s.t.} \quad & Ax \succeq b \end{aligned}$$

对偶函数 (Dual Function):

$$g(\lambda) = \inf_x \left(x^T P x + \lambda^T (Ax - b) \right) = -\frac{1}{4} \lambda^T A P^{-1} A^T \lambda - b^T \lambda$$

对偶问题 (Dual Problem):

$$\begin{aligned} \max \quad & -\frac{1}{4} \lambda^T A P^{-1} A^T \lambda - b^T \lambda \\ \text{s.t.} \quad & \lambda \succeq 0 \end{aligned}$$

弱对偶与强对偶 (Weak and Strong Duality)

弱对偶 (weak duality): $d^* \leq p^*$

- ▶ 总是成立 (无论问题是凸的还是非凸的)
- ▶ 可用于为困难问题提供非平凡的下界
- ▶ 例如, 求解如下 SDP 问题:

$$\begin{aligned} \max \quad & -\mathbf{1}^T \nu \\ \text{s.t.} \quad & W + \text{diag}(\nu) \succeq 0 \end{aligned}$$

- ▶ 该问题为“两分划分问题”的下界 (见第 5–7 页)

强对偶 (strong duality): $d^* = p^*$

- ▶ 一般不成立
- ▶ 对于凸优化问题通常成立
- ▶ 保证强对偶成立的条件被称为: 约束资格条件 (constraint qualifications)

强对偶的示例 (Examples with Strong Duality)

- 唯一的对偶最优解 (Unique Dual Optimal):

$$\begin{aligned} \min \quad & x_1 - x_2 \\ \text{s.t.} \quad & x_1 + x_2 \leq 1, \ x_1 \geq 0, \ x_2 \geq 0 \end{aligned}$$

- 多个对偶最优解 (Multiple Dual Optimal):

$$\min \quad |x_1| - x_2 \quad \text{s.t.} \quad x_1 \leq 0, \ x_2 = 0$$

- 无对偶最优解 (No Dual Optimal):

$$\min \quad x \quad \text{s.t.} \quad x^2 \leq 0$$

类似地，我们可以构造一些例子使得 $d^* = p^*$ ，但原始问题最优解是否存在却无法确定。



几何意义

原始问题 (**Primal Problem**) (不一定是凸的):

$$\begin{aligned} \min \quad & f(x) \\ \text{s.t.} \quad & f_1(x) \leq 0, \quad x \in D \end{aligned}$$

变量 $x \in \mathbb{R}^n$, 可行, 最优值记为 $p^* > -\infty$

几何框架 (**Geometric Framework**):

► 定义集合 V 如下:

$$V = \{(u, w) \mid \exists x \in X \text{ 使得 } f_1(x) \leq u, f(x) \leq w\}$$

几何原始问题 (**Geometric Primal Problem**): 确定集合 V 与 w 轴的最小截距:

$$\begin{aligned} \min \quad & w \\ \text{s.t.} \quad & (0, w) \in V \end{aligned}$$

最小截距值记为 p^* , 即:

$$p^* = \inf_{(0, w) \in V} w$$



几何意义

原始问题 (Primal Problem) (不一定是凸的):

$$\begin{aligned} \min \quad & f(x) \\ \text{s.t.} \quad & f_1(x) \leq 0, \quad x \in D \end{aligned}$$

几何框架 (Geometric Framework):

- ▶ 定义集合 V 如下:

$$V = \{(u, w) \mid \exists x \in X, f_1(x) \leq u, f(x) \leq w\}$$

- ▶ 对偶函数 (Dual Function) 定义为:

$$q(\lambda) = \inf_{x \in D} \{f(x) + \lambda f_1(x)\} = \inf_{(u, w) \in V} \{w + \lambda u\}, \quad \lambda \succeq 0$$

对偶问题 (Dual Problem):

$$\begin{aligned} \max \quad & q(\lambda) \\ \text{s.t.} \quad & \lambda \succeq 0 \end{aligned}$$


非垂直超平面 (Nonvertical Hyperplanes)


- 记 H 为 $\mathbb{R}^m \times \mathbb{R}$ 中的一个非垂直超平面，定义为：

$$H = \{(u, w) \mid \lambda u + w = q(\lambda)\}$$

其中： $q(\lambda) = \inf_{(u, w) \in V} \{w + \lambda u\}$, $\lambda \geq 0$

- 超平面 H 是集合 V 的一个支撑超平面，与 w 轴的交点为 $(0, q(\lambda))$





原始问题 (Primal) :

$$\min \quad w$$

$$\text{s.t. } (0, w) \in V$$

对偶问题 (Dual) :



$$\max \quad q(\mu)$$

$$\text{s.t. } \mu \succeq 0$$

- ▶ 对偶值 $q(\mu)$ 总是小于或等于任意满足 $(0, w) \in V$ 的 w , 也即不超过 f^*
- ▶ 对偶最优值 q^* 永远不超过原始最优值 f^* : $q^* \leq f^*$ (弱对偶)
- ▶ 弱对偶可能是严格的, 即 $q^* < f^*$, 此时存在对偶间隙 (Duality Gap)



对偶间隙示意图 (Duality Gap Illustrations)



Slater 约束资格条件 (Slater's Constraint Qualification)

若问题为凸优化问题，且满足 Slater 条件，则强对偶成立：

$$\begin{aligned} \min \quad & f_0(x) \\ \text{s.t.} \quad & f_i(x) \leq 0, \quad i = 1, \dots, m \\ & Ax = b \end{aligned}$$

若该问题是严格可行的，即：

$$\exists x \in \text{int } \mathcal{D} \text{ 使得 } f_i(x) < 0, \forall i = 1, \dots, m, \text{ 且 } Ax = b$$

则：

- ▶ 保证强对偶成立，并且对偶最优解存在（若 $p^* > -\infty$ ）
- ▶ 可进一步强化（例如，将 $\text{int } \mathcal{D}$ 替换为 $\text{relint } \mathcal{D}$ ，即相对内点）
- ▶ 线性不等式可不必严格满足
- ▶ 还有很多其他类型的约束资格条件也可保证强对偶



不等式形式的线性规划 (Inequality Form LP)

原始问题 (Primal Problem):

$$\begin{aligned} \min \quad & c^T x \\ \text{s.t.} \quad & Ax \succeq b \end{aligned}$$

对偶函数 (Dual Function):

$$g(\lambda) = \inf_x \left((c + A^T \lambda)^T x - b^T \lambda \right) = \begin{cases} -b^T \lambda, & \text{若 } A^T \lambda + c = 0 \\ -\infty, & \text{否则} \end{cases}$$

对偶问题 (Dual Problem):

$$\begin{aligned} \max \quad & -b^T \lambda \\ \text{s.t.} \quad & A^T \lambda + c = 0, \quad \lambda \succeq 0 \end{aligned}$$

- ▶ 根据 Slater 条件: 若存在 $\tilde{x}$ 使得 $A\tilde{x} \prec b$, 则 $p^* = d^*$
- ▶ 实际上, 除非原始问题与对偶问题都不可行, 一般都有 $p^* = d^*$

二次规划 (Quadratic Program)

原始问题 (Primal Problem) (假设 $P \in \mathbb{S}_{++}^n$):

$$\begin{aligned} \min \quad & x^T P x \\ \text{s.t.} \quad & Ax \succeq b \end{aligned}$$

对偶函数 (Dual Function):

$$g(\lambda) = \inf_x \left(x^T P x + \lambda^T (Ax - b) \right) = -\frac{1}{4} \lambda^T A P^{-1} A^T \lambda - b^T \lambda$$

对偶问题 (Dual Problem):

$$\begin{aligned} \max \quad & -\frac{1}{4} \lambda^T A P^{-1} A^T \lambda - b^T \lambda \\ \text{s.t.} \quad & \lambda \succeq 0 \end{aligned}$$

- ▶ 根据 Slater 条件: 若存在 $\tilde{x}$ 满足 $A\tilde{x} \prec b$, 则 $p^* = d^*$
- ▶ 实际上, 对于该问题, 总有 $p^* = d^*$



互补松弛性 (Complementary Slackness)

假设强对偶成立, x^* 为原始问题最优解, (λ^*, ν^*) 为对偶问题最优解:

$$\begin{aligned} f_0(x^*) = g(\lambda^*, \nu^*) &= \inf_x \left(f_0(x) + \sum_{i=1}^m \lambda_i^* f_i(x) + \sum_{i=1}^p \nu_i^* h_i(x) \right) \\ &\leq f_0(x^*) + \sum_{i=1}^m \lambda_i^* f_i(x^*) + \sum_{i=1}^p \nu_i^* h_i(x^*) \\ &\leq f_0(x^*) \end{aligned}$$

因此, 两个不等式必须同时取等:

- ▶ x^* 使拉格朗日函数 $L(x, \lambda^*, \nu^*)$ 取最小值;
- ▶ 对于所有 $i = 1, \dots, m$, 有: $\lambda_i^* f_i(x^*) = 0$, 称为**互补松弛性**。

$$\lambda_i^* > 0 \Rightarrow f_i(x^*) = 0, \quad f_i(x^*) < 0 \Rightarrow \lambda_i^* = 0$$



对偶与问题重构

- ▶ 一个问题的等价形式可能会导出非常不同的对偶问题；
- ▶ 当对偶问题难以推导或不具启发性时，重构原始问题可能会非常有用；

常见的重构方式

- ▶ 引入新变量和等式约束；
- ▶ 将显式约束转为隐式，或反之；
- ▶ 变换目标函数或约束函数，

例如：将 $f_0(x)$ 替换为 $\phi(f_0(x))$ ，其中 ϕ 是凸且单调递增的函数。



引入新变量与等式约束

$$\text{minimize } f_0(Ax + b)$$

- ▶ 对偶函数是常数: $g = \inf_x L(x) = \inf_x f_0(Ax + b) = p^*$
- ▶ 虽然满足强对偶性, 但此时对偶问题几乎无用

重写后的问题及其对偶问题:

$$\text{minimize } f_0(y)$$

$$\text{subject to } Ax + b - y = 0$$

$$\text{maximize } b^T \nu - f_0^*(\nu)$$

$$\text{subject to } A^T \nu = 0$$

对偶函数推导如下:

$$\begin{aligned} g(\nu) &= \inf_{x,y} \left(f_0(y) - \nu^T y + \nu^T Ax + b^T \nu \right) \\ &= \begin{cases} -f_0^*(\nu) + b^T \nu & \text{若 } A^T \nu = 0 \\ -\infty & \text{否则} \end{cases} \end{aligned}$$

范数逼近问题的对偶问题

范数逼近问题：最小化 $\|Ax - b\|^2$

$$\begin{aligned} & \text{minimize} \quad \|y\|^2 \\ & \text{subject to} \quad y = Ax - b \end{aligned}$$

直接推导对偶函数：

$$\begin{aligned} g(\nu) &= \inf_{x,y} \left(\|y\|^2 + \nu^T y - \nu^T Ax + b^T \nu \right) \\ &= \begin{cases} b^T \nu + \inf_y (\|y\|^2 + \nu^T y) & A^T \nu = 0 \\ -\infty & \text{否则} \end{cases} = \begin{cases} b^T \nu - \frac{\|\nu\|^2}{4} & A^T \nu = 0 \\ -\infty & \text{否则} \end{cases} \end{aligned}$$

范数逼近问题的对偶问题：

$$\begin{aligned} & \text{maximize} \quad b^T \nu - \frac{\|\nu\|^2}{4} \\ & \text{subject to} \quad A^T \nu = 0. \end{aligned}$$

隐式约束

带有盒约束 (box constraints) 的线性规划：原始问题与对偶问题

$$\begin{array}{ll} \text{minimize} & c^T x \\ \text{subject to} & Ax = b \\ & -1 \preceq x \preceq 1 \end{array} \qquad \begin{array}{ll} \text{maximize} & -b^T \nu - \mathbf{1}^T \lambda_1 - \mathbf{1}^T \lambda_2 \\ \text{subject to} & c + A^T \nu + \lambda_1 - \lambda_2 = 0 \\ & \lambda_1 \succeq 0, \lambda_2 \succeq 0 \end{array}$$

将盒约束隐式化后的重构问题：

$$\begin{array}{ll} \text{minimize} & f_0(x) = \begin{cases} c^T x & -1 \preceq x \preceq 1 \\ \infty & \text{其他情况} \end{cases} \\ \text{subject to} & Ax = b \end{array}$$

对偶函数：

$$g(\nu) = \inf_{-1 \preceq x \preceq 1} \left(c^T x + \nu^T (Ax - b) \right) = -b^T \nu - \|A^T \nu + c\|_1$$

对偶问题：maximize $-b^T \nu - \|A^T \nu + c\|_1$