

上海财经大学

信息管理与工程学院

最优性条件

优化理论与算法第六章

王震

2026.4.27

今天的课程主线

- ▶ 无约束优化：从最简单的问题出发，理解一阶必要条件、二阶必要条件与二阶充分条件。
- ▶ 等式约束优化：引入拉格朗日乘子法，说明约束如何改变一阶和二阶最优性条件。
- ▶ 等式与不等式约束优化：进一步引入 KKT 条件，用活跃约束、非负乘子和互补松弛刻画不等式约束。
- ▶ 约束资格条件：解释为什么需要正则性、MFCQ、Slater 等条件，保证乘子条件能够成立。



非线性规划的最优性条件

- ▶ 考虑如下带有显式等式和不等式约束的非线性规划问题：

$$\begin{aligned} & \text{minimize} && f(x) \\ & \text{subject to} && h_i(x) = 0, \quad i = 1, \dots, m \\ & && g_j(x) \leq 0, \quad j = 1, \dots, r \end{aligned}$$

- ▶ 最优性条件的提出是一个重要的里程碑，由 Kuhn 和 Tucker 于 1951 年提出
 - ▶ （后来的学者发现该条件最早由 Karush 提出）
- ▶ 我们的目标是刻画上述问题最优解的性质

一个简单的情形：无约束优化问题

$$\min_{x \in \mathbb{R}^n} f(x)$$

- ▶ 费马法则 (**Fermat's Rule**): 若 x^* 是局部最优解, 且 f 在 x^* 可微, 则


$$\nabla f(x^*) = \left[\frac{\partial f(x^*)}{\partial x_1}, \dots, \frac{\partial f(x^*)}{\partial x_n} \right]^\top = 0$$

- ▶ 一般情形下, 这是局部最优解的必要条件, 不是充分条件。
- ▶ 若进一步假设 f 是凸函数, 则 $\nabla f(x^*) = 0$ 是全局最优解的充要条件。




例子

► $f(x) = (x-1)(x-2)(x-4)$



► $f(x) = x^3$



- 这两个例子说明： $\nabla f(x^*) = 0$ 只能筛选驻点，不能保证局部最优。
- $f(x) = x^3$ 在 $x = 0$ 处还有 $f''(0) = 0$ ，也提示二阶必要条件仍然不充分。



二阶最优性条件 (Second Order Condition)

- ▶ 二阶必要条件 (**Necessary Condition**): 若 x^* 是局部极小值点, 且 f 二阶可微, 则

$$\nabla f(x^*) = 0, \quad \nabla^2 f(x^*) \succeq 0.$$

- ▶ 这仍然不是充分条件。例如 $f(x) = x^3$ 在 $x = 0$ 处满足

$$f'(0) = 0, \quad f''(0) = 0,$$

但 $x = 0$ 不是局部极小值点。

- ▶ 二阶充分条件 (**Sufficient Condition**): 若

$$\nabla f(x^*) = 0, \quad \nabla^2 f(x^*) \succ 0,$$

则 x^* 是严格局部极小值点。

带约束问题的几何视角：凸集约束

- ▶ 在进入具体的等式/不等式约束前，先看一个更抽象的写法：把所有可行解放在集合 S 中。
- ▶ 考虑如下优化问题：

$$\min_{x \in S} f(x)$$

其中 S 是一个闭凸集， f 可微。

- ▶ 这一页的目的不是替代拉格朗日或 KKT 条件，而是给出一个几何直觉：最优点处不能沿着任何可行方向继续下降。
- ▶ 若 x^* 是局部最优解，则必要的一阶最优性条件是：

$$\nabla f(x^*)^\top (y - x^*) \geq 0, \quad \forall y \in S.$$

- ▶ 若进一步假设 f 是凸函数，则该条件也是 x^* 为全局最优解的充要条件。



等式约束问题：从几何到乘子

- ▶ 接下来考虑更具体、也更常见的一类约束优化问题：

$$\begin{array}{ll}\min & f(x) \\ \text{s.t.} & h_i(x) = 0, \quad i = 1, \dots, m.\end{array}$$

- ▶ 这时可行集由若干等式方程刻画，最优点附近的可行方向由这些约束的一阶近似决定。
- ▶ 拉格朗日乘子法的作用是：把“目标函数的梯度”和“约束函数的梯度”联系起来，给出可检验的最优性条件。
- ▶ 因此，在给出拉格朗日定理前，需要先说明什么时候这些约束的一阶近似是可靠的，这就是正则性条件。

为什么需要正则性条件？

- ▶ 拉格朗日乘子的核心想法是：在最优点 x^* ，目标函数梯度可以由约束梯度的线性组合来抵消。
- ▶ 对于等式约束 $h_i(x) = 0$ ，可行方向 d 的一阶近似应满足

$$\nabla h_i(x^*)^\top d = 0, \quad i = 1, \dots, m.$$

- ▶ 若约束梯度 $\nabla h_1(x^*), \dots, \nabla h_m(x^*)$ 线性无关，则每个约束都提供一个独立限制，切空间才由这些一阶方程正确刻画。
- ▶ 例子：重复约束会导致退化

$$h_1(x, y) = x = 0, \quad h_2(x, y) = 2x = 0.$$

这两个约束看似有两个，其实只是在说同一件事。它们的梯度为

$$\nabla h_1 = (1, 0)^\top, \quad \nabla h_2 = (2, 0)^\top,$$

线性相关。

- ▶ 如果把相关约束也当成独立约束，乘子会变得不唯一，约束的一阶近似也不能稳定地刻画局部几何。因此正则性条件的作用是排除这种约束退化。



拉格朗日定理

- 问题形式：仅包含等式约束

$$\begin{aligned} \min \quad & f(x) \\ \text{s.t.} \quad & h_i(x) = 0, \quad i = 1, \dots, m. \end{aligned}$$

- 正则性假设：约束梯度线性无关，即

$$\text{rank}([\nabla h_1(x^*), \dots, \nabla h_m(x^*)]) = m.$$

- 一阶必要条件：若 x^* 是局部最优解，则存在拉格朗日乘子 λ_i , $i = 1, \dots, m$, 使得

$$\nabla f(x^*) + \sum_{i=1}^m \lambda_i \nabla h_i(x^*) = 0.$$



拉格朗日定理（续）

- 切空间记号：令

$$H(x) = [\nabla h_1(x), \dots, \nabla h_m(x)].$$

- 可行方向的一阶近似：只考虑满足

$$H(x^*)^\top y = 0$$

的方向 y 。

- 二阶必要条件：对所有满足 $H(x^*)^\top y = 0$ 的向量 y ，有

$$y^\top \left[\nabla^2 f(x^*) + \sum_{i=1}^m \lambda_i \nabla^2 h_i(x^*) \right] y \geq 0.$$



解释

回顾拉格朗日函数：

$$L(x, \lambda) = f(x) + \sum_{i=1}^m \lambda_i h_i(x)$$

拉格朗日定理可以表述为：存在某个 λ ，使得

$$\nabla_x L(x^*, \lambda) = 0$$

并且

$$y^\top \nabla_{xx}^2 L(x^*, \lambda) y \geq 0$$

对所有满足 $H(x^*)^\top y = 0$ 的向量 y



充分条件

就像无约束情形一样，如果进一步地， x^* 满足

$$y^\top \left[\nabla^2 f(x^*) + \sum_{i=1}^m \lambda_i \nabla^2 h_i(x^*) \right] y > 0$$

对于任意满足 $y \neq 0$ 且 $H(x^*)^\top y = 0$ 的向量 y ，那么 x^* 是一个局部极小值点。

换句话说，这是最优性的一个充分条件。我们也可以将其用拉格朗日函数形式表达为：

$$y^\top \nabla_{xx}^2 L(x^*, \lambda) y > 0$$

对于所有满足 $y \neq 0$ 且 $H(x^*)^\top y = 0$ 的向量 y 。



例子

应用上面的最优性条件来求解以下问题：

$$\begin{array}{ll}\text{minimize} & -(x_1x_2 + x_2x_3 + x_3x_1) \\ \text{s.t.} & x_1 + x_2 + x_3 = 3.\end{array}$$

例子：具体分析过程

- ▶ 写出拉格朗日函数：

$$L(x, \lambda) = -(x_1 x_2 + x_2 x_3 + x_3 x_1) + \lambda(x_1 + x_2 + x_3 - 3).$$

- ▶ 一阶条件为

$$\begin{cases} -(x_2 + x_3) + \lambda = 0, \\ -(x_1 + x_3) + \lambda = 0, \\ -(x_1 + x_2) + \lambda = 0, \\ x_1 + x_2 + x_3 = 3. \end{cases}$$

- ▶ 前三式相减可得 $x_1 = x_2 = x_3$ ，结合约束得到

$$x^* = (1, 1, 1), \quad \lambda = 2.$$

- ▶ 切空间为 $y_1 + y_2 + y_3 = 0$ 。在该方向上，

$$y^\top \nabla_{xx}^2 L(x^*, \lambda) y = -2(y_1 y_2 + y_2 y_3 + y_3 y_1) = \|y\|^2 > 0.$$

因此 x^* 是严格局部极小值点。



证明思路：为什么引入罚函数？

- ▶ 证明的困难在于： x^* 是约束问题的局部最优解，不能直接套用无约束的一阶条件 $\nabla f(x^*) = 0$ 。
- ▶ 想法：把等式约束的违反程度作为惩罚项加入目标函数，构造一系列无约束问题。
- ▶ 对每个 $\mu_k \rightarrow \infty$ ，考虑

$$F_{\mu_k}(x) = f(x) + \frac{\mu_k}{2} \sum_{i=1}^m h_i^2(x) + \frac{\nu}{2} \|x - x^*\|^2.$$

- ▶ 令 x^k 是该无约束问题的局部最优解。罚系数越来越大时，违反约束的点会被强烈惩罚，因此 $x^k \rightarrow x^*$ 。



证明步骤一：无约束一阶条件

- ▶ 对无约束问题 F_{μ_k} ，可以使用前面学过的一阶必要条件：

$$\nabla F_{\mu_k}(x^k) = 0.$$

- ▶ 逐项求导可得

$$0 = \nabla f(x^k) + \mu_k \sum_{i=1}^m h_i(x^k) \nabla h_i(x^k) + \nu(x^k - x^*).$$

- ▶ 记

$$H(x) = [\nabla h_1(x), \dots, \nabla h_m(x)], \quad h(x) = [h_1(x), \dots, h_m(x)]^\top.$$

则上式可以写成

$$H(x^k) \mu_k h(x^k) = -(\nabla f(x^k) + \nu(x^k - x^*)).$$

证明步骤二：乘子的来源

► 正则性条件保证 $H(x^*)$ 的列线性无关；当 k 足够大时， $H(x^k)^\top H(x^k)$ 可逆。

► 对

$$H(x^k) \mu_k h(x^k) = -(\nabla f(x^k) + \nu(x^k - x^*))$$

两边左乘 $H(x^k)^\top$ ，得到

$$H(x^k)^\top H(x^k) \mu_k h(x^k) = -H(x^k)^\top (\nabla f(x^k) + \nu(x^k - x^*)).$$

► 因此

$$\mu_k h(x^k) = -\left(H(x^k)^\top H(x^k)\right)^{-1} H(x^k)^\top (\nabla f(x^k) + \nu(x^k - x^*)).$$

► 这就是拉格朗日乘子的近似形式：惩罚系数 μ_k 乘以约束违反量 $h(x^k)$ 。

证明步骤三：取极限得到一阶条件

► 令

$$\lambda = \lim_{k \rightarrow \infty} \mu_k h(x^k).$$

► 由于 $x^k \rightarrow x^*$, 且 $\nu(x^k - x^*) \rightarrow 0$, 由上一页公式得到

$$\lambda = - \left(H(x^*)^\top H(x^*) \right)^{-1} H(x^*)^\top \nabla f(x^*).$$

► 把 λ 代回无约束一阶条件的极限形式:

$$\nabla f(x^*) + H(x^*)\lambda = 0.$$

► 展开矩阵记号即得到

$$\nabla f(x^*) + \sum_{i=1}^m \lambda_i \nabla h_i(x^*) = 0.$$



证明步骤四：二阶条件

- ▶ 因为 x^k 是无约束问题 F_{μ_k} 的局部最优解，所以

$$0 \preceq \nabla^2 F_{\mu_k}(x^k).$$

- ▶ 展开 Hessian:

$$\nabla^2 F_{\mu_k}(x^k) = \nabla^2 f(x^k) + \mu_k \sum_{i=1}^m \left[\nabla h_i(x^k) \nabla h_i(x^k)^\top + h_i(x^k) \nabla^2 h_i(x^k) \right] + \nu I.$$

- ▶ 对满足 $H(x^*)^\top y = 0$ 的切向方向 y 取二次型并令 $k \rightarrow \infty$ ，可得

$$y^\top \left[\nabla^2 f(x^*) + \sum_{i=1}^m \lambda_i \nabla^2 h_i(x^*) + \nu I \right] y \geq 0.$$

- ▶ 由于 $\nu > 0$ 可任意小，得到拉格朗日函数形式的二阶必要条件。



KKT 条件：问题形式

- ▶ KKT 条件处理同时含有等式约束和不等式约束的问题：

$$\begin{aligned} \min \quad & f(x) \\ \text{s.t.} \quad & h_i(x) = 0, \quad i = 1, \dots, m, \\ & g_j(x) \leq 0, \quad j = 1, \dots, r. \end{aligned}$$

- ▶ 活跃集表示在当前点“真正顶住”的不等式约束：

$$A(x) = \{j \mid g_j(x) = 0\}.$$

若 $g_j(x) < 0$ ，则该约束在当前点没有起作用。

- ▶ LICQ 约束资格条件：在 x^* 处，

$$\nabla h_1(x^*), \dots, \nabla h_m(x^*), \nabla g_j(x^*), j \in A(x^*)$$

线性无关。



KKT 条件：一阶必要条件

- ▶ 若 x^* 是局部最优解，并且满足上述 LICQ 条件，则存在乘子

$$\lambda_i \in \mathbb{R}, \quad \mu_j \geq 0,$$

使得以下条件成立。

- ▶ 原始可行性：

$$h_i(x^*) = 0, \quad g_j(x^*) \leq 0.$$

- ▶ 驻点条件：

$$\nabla f(x^*) + \sum_{i=1}^m \lambda_i \nabla h_i(x^*) + \sum_{j=1}^r \mu_j \nabla g_j(x^*) = 0.$$

- ▶ 对偶可行性与互补松弛：

$$\mu_j \geq 0, \quad \mu_j g_j(x^*) = 0, \quad j = 1, \dots, r.$$

因而若 $j \notin A(x^*)$ ，即 $g_j(x^*) < 0$ ，则必有 $\mu_j = 0$ 。



KKT 二阶充分条件

- ▶ 一阶 KKT 条件通常只是必要条件；若再加上临界方向上的二阶正定性，就可以得到局部最优的充分条件。
- ▶ 临界方向 y 满足

$$\nabla h_i(x^*)^\top y = 0, \quad \nabla g_j(x^*)^\top y \leq 0, \quad j \in A(x^*),$$

且在一阶上不改变目标函数：

$$\nabla f(x^*)^\top y = 0.$$

- ▶ 若对所有非零临界方向 y ，都有

$$y^\top \left[\nabla^2 f(x^*) + \sum_{i=1}^m \lambda_i \nabla^2 h_i(x^*) + \sum_{j \in A(x^*)} \mu_j \nabla^2 g_j(x^*) \right] y > 0,$$

则 x^* 是严格局部极小值点。

- ▶ 直观上：在所有真正可能影响最优性的临界方向上，拉格朗日函数的二阶变化都是正的。

KKT 证明思路：把不等式变成等式

- ▶ 证明 KKT 条件的一个思路：为每个不等式约束引入松弛变量 z_j 。
- ▶ 不等式 $g_j(x) \leq 0$ 等价于存在 z_j 使得

$$g_j(x) + z_j^2 = 0.$$

因为 $z_j^2 \geq 0$ ，所以该等式自动保证 $g_j(x) \leq 0$ 。

- ▶ 于是原问题可写成只含等式约束的问题：

$$\begin{aligned} \min \quad & f(x) \\ \text{s.t.} \quad & h_i(x) = 0, \quad i = 1, \dots, m, \\ & g_j(x) + z_j^2 = 0, \quad j = 1, \dots, r. \end{aligned}$$

- ▶ 现在就可以套用前面讲过的等式约束拉格朗日定理。

KKT 证明思路：构造拉格朗日函数

- ▶ 对等式约束 $h_i(x) = 0$ 的乘子记为 λ_i ；对 $g_j(x) + z_j^2 = 0$ 的乘子记为 μ_j 。
- ▶ 拉格朗日函数为

$$L(x, z, \lambda, \mu) = f(x) + \sum_{i=1}^m \lambda_i h_i(x) + \sum_{j=1}^r \mu_j (g_j(x) + z_j^2).$$

- ▶ 对 x 和 z 分别求导：

$$\nabla L(x, z, \lambda, \mu) = \begin{bmatrix} \nabla f(x) + \sum_{i=1}^m \lambda_i \nabla h_i(x) + \sum_{j=1}^r \mu_j \nabla g_j(x) \\ 2\mu_1 z_1 \\ \vdots \\ 2\mu_r z_r \end{bmatrix}$$

KKT 证明思路：推出互补松弛

- ▶ 在最优点 (x^*, z^*) 处得到

$$\begin{cases} \nabla f(x^*) + \sum_{i=1}^m \lambda_i \nabla h_i(x^*) + \sum_{j=1}^r \mu_j \nabla g_j(x^*) = 0 \\ 2\mu_j z_j^* = 0, \quad j = 1, \dots, r \end{cases}$$

- ▶ 由等式约束

$$g_j(x^*) + (z_j^*)^2 = 0$$

可知：若 $g_j(x^*) < 0$ ，则 $z_j^* \neq 0$ 。

- ▶ 再由 $2\mu_j z_j^* = 0$ 可得 $\mu_j = 0$ 。因此非活跃约束不影响驻点条件。
- ▶ 这正是互补松弛条件

$$\mu_j g_j(x^*) = 0$$

的来源。

Hessian 矩阵与推论

- 其 Hessian 矩阵为:

$$\nabla_{x,z}^2 L(x, z, \lambda, \mu) = \begin{bmatrix} \nabla^2 f(x) + \sum_{i=1}^m \lambda_i \nabla^2 h_i(x) + \sum_{j=1}^r \mu_j \nabla^2 g_j(x) & 0 \\ 0 & 2\text{diag}(\mu) \end{bmatrix}$$

其中 $\text{diag}(\mu)$ 是一个以 μ 为对角元素的对角矩阵。

- 因此, 有:

$$\begin{bmatrix} y \\ w \end{bmatrix}^\top \nabla_{x,z}^2 L(x, z, \lambda, \mu) \begin{bmatrix} y \\ w \end{bmatrix} = y^\top \left[\nabla^2 f(x) + \sum_{i=1}^m \lambda_i \nabla^2 h_i(x) + \sum_{j=1}^r \mu_j \nabla^2 g_j(x) \right] y + 2 \sum_{j=1}^r \mu_j w_j^2$$

- 对活跃不等式约束有 $z_j = 0$ 。若取 $y = 0$ 且只改变对应的 w_j , 二阶必要条件会推出 $\mu_j \geq 0$, 这正是 KKT 中对偶可行性的来源。

二阶最优性条件（续）

- 二阶最优性条件指出：

$$\begin{bmatrix} y \\ w \end{bmatrix}^\top \nabla_{x,z}^2 L(x, z, \lambda, \mu) \begin{bmatrix} y \\ w \end{bmatrix} \geq 0$$

对于所有满足条件

$$(\nabla_{x,z} h_i(x, z))^\top \begin{bmatrix} y \\ w \end{bmatrix} = 0 \quad \text{和} \quad (\nabla_{x,z} g_j(x, z))^\top \begin{bmatrix} y \\ w \end{bmatrix} = 0$$

- 现在我们有：

$$\nabla_{x,z} h_i(x, z) = \begin{bmatrix} \nabla h_i(x) \\ 0 \end{bmatrix} \quad \text{和} \quad \nabla_{x,z} g_j(x, z) = \begin{bmatrix} \nabla g_j(x) \\ 2z_j \end{bmatrix}$$

- 因此有：

$$(\nabla_{x,z} g_j(x, z))^\top \begin{bmatrix} y \\ w \end{bmatrix} = (\nabla g_j(x))^\top y + 2z_j w_j$$



二阶最优性条件

- 更准确地说，KKT 二阶必要条件应在临界方向上表述。临界方向 y 满足

$$\nabla h_i(x^*)^\top y = 0, \quad \nabla g_j(x^*)^\top y \leq 0, \quad j \in A(x^*),$$

且

$$\nabla f(x^*)^\top y = 0.$$

- 在这些方向上，拉格朗日函数的二阶项不能为负：

$$y^\top \left[\nabla^2 f(x^*) + \sum_{i=1}^m \lambda_i \nabla^2 h_i(x^*) + \sum_{j \in A(x^*)} \mu_j \nabla^2 g_j(x^*) \right] y \geq 0$$

对所有临界方向 y 成立。



为什么还需要约束资格条件？

- ▶ KKT 条件想表达的是：在局部最优点，目标函数的下降趋势可以被活跃约束的法向量抵消。

$$\nabla f(x^*) + \sum_{i=1}^m \lambda_i \nabla h_i(x^*) + \sum_{j=1}^r \mu_j \nabla g_j(x^*) = 0.$$

- ▶ 但是这个表达需要一个前提：约束在 x^* 附近的一阶近似能够正确描述局部可行集。
- ▶ 若约束退化，仍然可以得到更弱的 Fritz John 条件；它允许目标函数前面的乘子 $\mu_0 = 0$ ，这时目标函数梯度可能完全没有出现在必要条件中。
- ▶ 约束资格条件的作用：排除这种异常情况，使 Fritz John 条件退化为普通 KKT 条件，即保证 $\mu_0 > 0$ 。

集合角度：一阶近似在近似什么？

- ▶ 真实可行集为

$$S = \{x \mid h_i(x) = 0, g_j(x) \leq 0\}.$$

- ▶ 在 x^* 附近，把 x 写成 $x^* + d$ 。一阶泰勒展开给出

$$h_i(x^* + d) \approx h_i(x^*) + \nabla h_i(x^*)^\top d,$$

$$g_j(x^* + d) \approx g_j(x^*) + \nabla g_j(x^*)^\top d.$$

- ▶ 因此，活跃约束给出的线性化可行方向集合是

$$L(x^*) = \left\{ d \mid \nabla h_i(x^*)^\top d = 0, \nabla g_j(x^*)^\top d \leq 0, j \in A(x^*) \right\}.$$

- ▶ 正则条件要保证的是：这个线性化集合能可靠反映真实可行集在 x^* 附近的局部几何。

一阶近似什么时候会失真？

- ▶ 考虑简单约束

$$x^2 \leq 0.$$

它对应的真实可行集只有一个点：

$$S = \{0\}.$$

- ▶ 但在 $x^* = 0$ 处，约束函数 $g(x) = x^2$ 的梯度为

$$\nabla g(0) = 0.$$

- ▶ 线性化约束变成

$$0 \cdot d \leq 0,$$

这对所有方向 d 都成立。

- ▶ 于是线性化模型误以为“所有方向都可行”，但真实可行集实际上根本不能移动。这就是约束退化导致的一阶近似失真。



约束资格条件的关系图

局部最优解 $\implies$ Fritz John 条件 $\xRightarrow{\text{约束资格条件}}$ KKT 条件

LICQ $\implies$ MFCQ $\implies$ KKT 乘子存在

Slater 条件 $\implies$ MFCQ (凸问题中常用, 等式梯度需独立)

- ▶ Fritz John 条件是没有正则性时的兜底必要条件。
- ▶ LICQ、MFCQ、Slater 都是常见的约束资格条件, 但适用范围和强弱不同。
- ▶ 讲解时可以把它理解为: 不同方式地保证约束没有在最优点附近发生退化。

Fritz John 条件：无正则性时的兜底

- ▶ 不管是否满足约束资格条件，若 x^* 是局部最优解，则存在乘子

$$\lambda_i, \quad i = 1, \dots, m, \quad \mu_j \geq 0, \quad j = 0, 1, \dots, r,$$

且这些乘子不全为零，使得

$$\mu_0 \nabla f(x^*) + \sum_{i=1}^m \lambda_i \nabla h_i(x^*) + \sum_{j=1}^r \mu_j \nabla g_j(x^*) = 0.$$

- ▶ 同时满足互补条件

$$\mu_j g_j(x^*) = 0, \quad j = 1, \dots, r.$$

- ▶ 与 KKT 的关键差别在于：Fritz John 允许 $\mu_0 = 0$ 。若能证明 $\mu_0 > 0$ ，两边同除以 μ_0 ，就得到普通 KKT 条件。



LICQ: 活跃约束梯度线性无关

- ▶ 定义：在 x^* 处，等式约束梯度和活跃不等式约束梯度线性无关：

$$\nabla h_1(x^*), \dots, \nabla h_m(x^*), \nabla g_j(x^*), j \in A(x^*)$$

线性无关。

- ▶ 直观：每个活跃约束都提供一个独立的限制，没有重复约束，也没有互相抵消的约束。
- ▶ 作用：LICQ 是较强但最直观的约束资格条件；若局部最优点满足 LICQ，则 KKT 乘子存在，并且乘子通常具有较好的唯一性。
- ▶ 局限：LICQ 要求所有活跃约束梯度线性无关，条件较强；一旦活跃约束数量超过变量维数，就不可能成立。



MFCQ: 存在严格可行下降方向

- ▶ 定义：等式约束梯度 $\nabla h_i(x^*)$, $i = 1, \dots, m$ 线性无关，且存在方向 d ，使得

$$\nabla h_i(x^*)^\top d = 0, \quad i = 1, \dots, m,$$

并且对所有活跃不等式约束

$$\nabla g_j(x^*)^\top d < 0, \quad j \in A(x^*).$$

- ▶ 直观：方向 d 在一阶意义下不破坏等式约束，同时能把所有顶住的不等式约束往内部推。
- ▶ 作用：MFCQ 保证 Fritz John 条件中的 $\mu_0 > 0$ ，因此可以推出 KKT 条件。
- ▶ 局限：MFCQ 比 LICQ 弱，但仍要求所有活跃不等式能够被同一个方向同时严格放松。

Slater 条件：凸问题中的常用条件

- ▶ 定义：若 h_i 是线性函数且其梯度线性无关、 g_j 是凸函数，并且存在严格可行点 $\hat{x}$ 满足

$$h_i(\hat{x}) = 0, \quad i = 1, \dots, m, \quad g_j(\hat{x}) < 0, \quad j = 1, \dots, r,$$

则称 Slater 条件成立。

- ▶ 直观：可行域不只是贴在边界上，而是有一个真正落在所有不等式约束内部的点。
- ▶ 作用：在凸优化中，Slater 条件容易验证；它不仅可以作为 KKT 的约束资格条件，也常用于推出强对偶。
- ▶ 局限：Slater 条件主要服务于凸问题；对一般非凸问题，不能简单把它当作通用正则条件。



Slater 条件为什么推出 MFCQ?

- ▶ 设 x^* 是可行点, $\hat{x}$ 是 Slater 点。对任意活跃约束 $j \in A(x^*)$, 有 $g_j(x^*) = 0$ 且 $g_j(\hat{x}) < 0$ 。
- ▶ 由凸函数的一阶不等式,

$$g_j(\hat{x}) \geq g_j(x^*) + \nabla g_j(x^*)^\top (\hat{x} - x^*) = \nabla g_j(x^*)^\top (\hat{x} - x^*).$$

- ▶ 因此令 $d = \hat{x} - x^*$, 可得

$$\nabla g_j(x^*)^\top d < 0, \quad j \in A(x^*).$$

- ▶ 若等式约束是线性的且其梯度线性无关, 则

$$\nabla h_i(x^*)^\top d = 0, \quad i = 1, \dots, m.$$

所以在凸问题中, Slater 条件自然给出了 MFCQ 所需的方向。

没有任何正则性条件的例子


考虑如下例子：

$$\text{最小化 } x_1^2 + x_2^2$$

$$\text{满足约束 } (x_1 - 1)^2 + (x_2 - 1)^2 \leq 1,$$

$$(x_1 - 1)^2 + (x_2 + 1)^2 \leq 1.$$

- ▶ 两个约束分别对应两个圆盘；
- ▶ 两个圆盘只在 $x^* = (1, 0)$ 处相切；
- ▶ 可行集在该点退化为一个尖点；
- ▶ 图中显示了约束区域和目标函数等高线。



反例分析：正则条件如何失败？

► 令

$$g_1(x) = (x_1 - 1)^2 + (x_2 - 1)^2 - 1,$$

$$g_2(x) = (x_1 - 1)^2 + (x_2 + 1)^2 - 1.$$

在 $x^* = (1, 0)$ 处，两个约束都活跃。

► 两个活跃约束梯度为

$$\nabla g_1(x^*) = (0, -2)^\top, \quad \nabla g_2(x^*) = (0, 2)^\top.$$

► **LICQ** 失败：两个活跃约束梯度方向相反，线性相关，不可能构成独立限制。

► **MFCQ** 失败：若存在方向 $d = (d_1, d_2)$ 使两个活跃约束同时严格下降，则需

$$-2d_2 < 0, \quad 2d_2 < 0,$$

即 $d_2 > 0$ 且 $d_2 < 0$ ，矛盾。

► 因此普通 KKT 可能失效；此时只能依靠 Fritz John 条件作为更弱的必要条件。



如何选择约束资格条件？

- ▶ 教学入门或手算例题：优先检查 LICQ。它最直观，就是看活跃约束梯度是否线性无关。
- ▶ LICQ 太强时：尝试使用 MFCQ。它允许活跃不等式梯度相关，但要求存在一个共同的严格可行方向。
- ▶ 凸优化问题：优先使用 Slater 条件。它通常容易验证，并且能自然连接 KKT 条件和强对偶理论。
- ▶ 没有任何正则性时：仍可使用 Fritz John 条件，但它比 KKT 弱，因为目标函数前的乘子可能为零。

本章总结：最优性条件的主线

- ▶ 无约束问题中，最优性条件从 $\nabla f(x^*) = 0$ 开始；它通常只是局部最优的必要条件。
- ▶ 等式约束问题中，拉格朗日定理把约束的影响写入拉格朗日函数：

$$L(x, \lambda) = f(x) + \sum_{i=1}^m \lambda_i h_i(x).$$

在正则性条件下，局部最优解必须满足 $\nabla_x L(x^*, \lambda) = 0$ 。

- ▶ KKT 条件进一步处理不等式约束：

$$L(x, \lambda, \mu) = f(x) + \sum_i \lambda_i h_i(x) + \sum_j \mu_j g_j(x), \quad \mu_j \geq 0.$$

- ▶ 二者的本质区别：拉格朗日定理主要处理等式约束；KKT 条件通过非负乘子和互补松弛

$$\mu_j g_j(x^*) = 0$$

刻画哪些不等式约束在最优点真正起作用。

- ▶ 约束资格条件是 Fritz John 条件与 KKT 条件之间的桥梁：它排除异常乘子 $\mu_0 = 0$ ，从而保证普通 KKT 乘子存在。