

HW3 2024111279 范心宇

2.1 归纳法证明有限个点的凸组合仍在凸集内 对 k 使用数学归纳法。当 $k = 2$ 时，由凸集定义可知，若 $x_1, x_2 \in C$ ，且 $\theta_1, \theta_2 \geq 0$ ， $\theta_1 + \theta_2 = 1$ ，则：

$$\theta_1 x_1 + \theta_2 x_2 \in C$$

因此命题在 $k = 2$ 时成立。我们假设命题对 $k = m$ 时成立，即对任意 $x_1, \dots, x_m \in C$ ，以及任意非负系数 $\theta_1, \dots, \theta_m$ ，若满足 $\sum_{i=1}^m \theta_i = 1$ ，则有：

$$\sum_{i=1}^m \theta_i x_i \in C.$$

下面我们来证明命题对 $k = m + 1$ 时也成立，任取 $x_1, \dots, x_m, x_{m+1} \in C$ ，并取非负系数 $\theta_1, \dots, \theta_m, \theta_{m+1}$ ，使其满足：

$$\sum_{i=1}^{m+1} \theta_i = 1.$$

若 $\sum_{i=1}^m \theta_i = 0$ ，由于每个 $\theta_i \geq 0$ ，可知 $\theta_1 = \dots = \theta_m = 0$ ，从而 $\theta_{m+1} = 1$ 。因此

$$\sum_{i=1}^{m+1} \theta_i x_i = x_{m+1} \in C.$$

若 $\sum_{i=1}^m \theta_i > 0$ ，我们令 $\lambda = \sum_{i=1}^m \theta_i$ ，由 $\sum_{i=1}^{m+1} \theta_i = 1$ 可知 $\lambda = 1 - \theta_{m+1}$ ，因此 $0 < \lambda \leq 1$ 。对 $i = 1, \dots, m$ ，令 $\mu_i = \frac{\theta_i}{\lambda}$ ，则 $\mu_i \geq 0$ ，且：

$$\sum_{i=1}^m \mu_i = \sum_{i=1}^m \frac{\theta_i}{\lambda} = \frac{1}{\lambda} \sum_{i=1}^m \theta_i = 1$$

由归纳假设可知 $y = \sum_{i=1}^m \mu_i x_i \in C$ ，于是有：

$$\sum_{i=1}^{m+1} \theta_i x_i = \sum_{i=1}^m \theta_i x_i + \theta_{m+1} x_{m+1} = \lambda \sum_{i=1}^m \mu_i x_i + \theta_{m+1} x_{m+1} = \lambda y + \theta_{m+1} x_{m+1}.$$

由于 $y \in C$ ， $x_{m+1} \in C$ ，并且 $\lambda \geq 0$ ， $\theta_{m+1} \geq 0$ ， $\lambda + \theta_{m+1} = 1$ ，所以由凸集定义可得：

$$\lambda y + \theta_{m+1} x_{m+1} \in C.$$

因此

$$\sum_{i=1}^{m+1} \theta_i x_i \in C.$$

综上，若命题对 $k = m$ 成立，则命题对 $k = m + 1$ 也成立。又因为命题在 $k = 2$ 时成立，所以由数学归纳法可知，对任意 $k \geq 2$ ，都有 $\sum_{i=1}^k \theta_i x_i \in C$ 。

证毕

2.2 判断集合凸性

(a) C 是凸集，证明如下： 注意到，题中集合 C 中 $x^T x = \|x\|_2^2$ ，所以集合也可以写为：

$$C = \{x \in \mathbb{R}^n : \|x\|_2 \leq 1\}.$$

我们任取 $x, y \in C$ ，以及任意的 $\theta \in [0, 1]$ 。由于 $x, y \in C$ ，所以 $\|x\|_2 \leq 1$ ， $\|y\|_2 \leq 1$ 。由范数的三角不等式以及齐次性，有：

$$\|\theta x + (1 - \theta)y\|_2 \leq \theta \|x\|_2 + (1 - \theta)\|y\|_2 \leq \theta + (1 - \theta) = 1.$$


因此 $\theta x + (1 - \theta)y \in C$ 。所以 C 是凸集。

(b) C 不是凸集，反例如下： 取两个点 $p = (-1, -1), q = (-3, -\frac{1}{3})$ 。对点 p ，我们有 $p_1 = -1 < 0$ ，且 $p_1 p_2 = (-1)(-1) = 1 \leq 1$ ，所以 $p \in C$ 。对点 q ，我们有 $q_1 = -3 < 0$ ，且 $q_1 q_2 = (-3)(-\frac{1}{3}) = 1 \leq 1$ ，所以 $q \in C$ 。

但 p, q 二者的中点为：

$$\frac{p+q}{2} = \left(-2, -\frac{2}{3}\right)$$

此时第一坐标满足 $-2 < 0$ ，但 $(-2)(-\frac{2}{3}) = \frac{4}{3} > 1$ ，所以 $\frac{p+q}{2} \notin C$ ，它们的中点并不在集合中。也就是说，存在 $p, q \in C$ ，但它们的中点不属于 C 。因此 C 不是凸集。



(c) C 不是凸集, 反例如下: 很显然, 我们只需要构造一个反例, 其中两个矩阵 A, B 的秩均 ≤ 2 , 而它们各自拥有单位矩阵的一部分, 那么它们的中点将会成为一个秩更大的对角矩阵。具体如下:

我们取:

$$A = \begin{pmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \end{pmatrix}, \quad B = \begin{pmatrix} 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \end{pmatrix}.$$

很显然, $\text{rank}(A) = 2$, $\text{rank}(B) = 2$, 所以 $A, B \in C$ 。但是二者的中点为

$$\frac{A+B}{2} = \begin{pmatrix} \frac{1}{2} & 0 & 0 & 0 \\ 0 & \frac{1}{2} & 0 & 0 \\ 0 & 0 & \frac{1}{2} & 0 \\ 0 & 0 & 0 & \frac{1}{2} \end{pmatrix}.$$

这是一个 4×4 对角矩阵, 并且对角线上的元素全部为 $1/2$, 对角线外元素全部为 0 , 因此我们有:

$$\text{rank}\left(\frac{A+B}{2}\right) = 4 > 2.$$

所以 $\frac{A+B}{2} \notin C$ 。于是存在 $A, B \in C$ ，但其中点不在 C 中。因此 C 不是凸集。

2.4 判断集合是否为凸集

(a) C 是凸集，证明如下：任取 $x, y \in C$ ，以及任意 $\theta \in [0, 1]$ 。由于 $x, y \in C$ ，所以：

$$\alpha \leq a^T x \leq \beta, \quad \alpha \leq a^T y \leq \beta.$$

于是：

$$a^T(\theta x + (1 - \theta)y) = \theta a^T x + (1 - \theta)a^T y.$$

因为 $a^T x$ 和 $a^T y$ 都位于区间 $[\alpha, \beta]$ 中，且区间 $[\alpha, \beta]$ 是一维上的凸区间，所以它们的凸组合仍然位于 $[\alpha, \beta]$ 中，即：

$$\alpha \leq a^T(\theta x + (1 - \theta)y) \leq \beta.$$

因此 $\theta x + (1 - \theta)y \in C$ ，所以 C 是凸集。同时，也可以从另一个视角来理解，该集合可以写成两个半空间的交集，也就是：

$$C = \{x \in \mathbb{R}^n \mid a^T x \geq \alpha\} \cap \{x \in \mathbb{R}^n \mid a^T x \leq \beta\}.$$

半空间是我们已证明的典型的凸集，而凸集的交集仍是凸集，所以自然 C 也是凸集。

(b) C 是凸集，证明如下：我们任取 $x, y \in C$ ，以及任意 $\theta \in [0, 1]$ 。由于 $x, y \in C$ ，所以对每个 $i = 1, \dots, n$ ，根据题意都有：

$$\alpha_i \leq x_i \leq \beta_i, \quad \alpha_i \leq y_i \leq \beta_i.$$

接着我们来考察凸组合 $z = \theta x + (1 - \theta)y$ 。其第 i 个分量为 $z_i = \theta x_i + (1 - \theta)y_i$ 。因为 $x_i, y_i \in [\alpha_i, \beta_i]$ ， $[\alpha_i, \beta_i]$ 是一维上的凸区间，所以它们的凸组合仍然属于 $[\alpha_i, \beta_i]$ ，即：

$$\alpha_i \leq z_i \leq \beta_i.$$

这对所有 $i = 1, \dots, n$ 都成立，因此 $z \in C$ 。所以 C 是凸集。

(c) C 是凸集, 证明如下: 任取 $x, y \in C$, 以及任意 $\theta \in [0, 1]$ 。由于 $x, y \in C$, 所以 x, y 有 $a_1^T x \leq b_1, a_1^T y \leq b_1$, 并且 $a_2^T x \geq b_2, a_2^T y \geq b_2$ 。我们令 $z = \theta x + (1 - \theta)y$, 则:

$$a_1^T z = \theta a_1^T x + (1 - \theta)a_1^T y \leq \theta b_1 + (1 - \theta)b_1 = b_1,$$

同时有:

$$a_2^T z = \theta a_2^T x + (1 - \theta)a_2^T y \geq \theta b_2 + (1 - \theta)b_2 = b_2.$$

因此 $z \in C$, 所以 C 是凸集。这道题同样可以从另一个角度看, 这里 C 也是两个半空间的交集, 凸集的交集依然是凸集。

(d) C 是凸集, 证明如下: 首先看, 对任意的固定的 $y \in S$, 我们看不等式:

$$\|x - x_0\|_2 \leq \|x - y\|_2.$$

由于两边均非负, 因此可以同时进行平方, 就得到:

$$\|x - x_0\|_2^2 \leq \|x - y\|_2^2.$$

展开两边:

$$x^T x - 2x_0^T x + x_0^T x_0 \leq x^T x - 2y^T x + y^T y.$$

两边同时消去 $x^T x$, 可得 $2(y - x_0)^T x \leq y^T y - x_0^T x_0$ 。这说明, 对于每一个固定的 $y \in S$, 集合: $\{x \mid \|x - x_0\|_2 \leq \|x - y\|_2\}$ 都是一个半空间。因此原集合 C , 其实就是这些半空间对所有 $y \in S$ 的交集:

$$C = \bigcap_{y \in S} \{x \mid 2(y - x_0)^T x \leq y^T y - x_0^T x_0\}.$$

由于半空间是凸集, 而任意多个凸集的交集仍然是凸集, 所以 C 是凸集。

(e) C 不一定是凸集, 反例如下: 我们可以构造一个很直观的反例, 两个集合 S 的点在左右两边, 而 T 在中间。左右两个点显然 “离 S 更近”, 但它们的中点正好落入 T , 所以 “离 T 更近”, 这就直接破坏了凸性。

我们令 $n = 2$, 取

$$S = \{(-1, 0), (1, 0)\}, \quad T = \{(0, 0)\}.$$

记 $p = (-1, 0)$, $q = (1, 0)$ 。由于 $p \in S$, 所以 $\text{dist}(p, S) = 0$;

同时 T 中只有点 $(0, 0)$, 因此 $\text{dist}(p, T) = \|(-1, 0) - (0, 0)\|_2 = 1$ 。于是 $\text{dist}(p, S) \leq \text{dist}(p, T)$, 从而 $p \in C$ 。

同理, 对 $q = (1, 0)$, 有 $\text{dist}(q, S) = 0$, 且 $\text{dist}(q, T) = \|(1, 0) - (0, 0)\|_2 = 1$, 所以 $q \in C$ 。


但是, p 与 q 的中点为:

$$\frac{p+q}{2} = (0, 0).$$

对于该中点, 由于它本身就落入集合 T 中, 所以 $\text{dist}((0, 0), T) = 0$; 而它到集合 S 中两个点 $(-1, 0)$ 和 $(1, 0)$ 的距离都等于 1, 所以 $\text{dist}((0, 0), S) = 1$ 。因此:

$$\text{dist}((0, 0), S) > \text{dist}((0, 0), T),$$

从而 $(0, 0) \notin C$ 。这说明存在 $p, q \in C$, 它们的中点 $(p+q)/2 \notin C$, 所以集合 C 就不一定是凸集。



2.5 二次不等式的解集

(a) 证明如下: 我们令函数 $f(x) = x^T A x + b^T x + c$ 。由于 $A \in S^n$, 所以我们可以写出函数 f 的 Hessian 矩阵为:

$$\nabla^2 f(x) = 2A.$$

若 $A \succeq 0$, 则也有 $2A \succeq 0$, 因此 $f(x)$ 是凸函数。又因为凸函数的下水平集也是凸集, 而 C 正是 f 的 0-下水平集:

$$C = \{x \in \mathbb{R}^n \mid f(x) \leq 0\},$$

所以 C 是凸集。证毕。

(b) 证明如下： 由于在超平面 H 上恒有 $g^T x + h = 0$ ，所以对任意的 $x \in H$ ，都有 $\lambda(g^T x + h)^2 = 0$ 。因此，在超平面 H 上，原来的二次不等式 $f(x) \leq 0$ 就能够等价于：

$$x^T A x + b^T x + c + \lambda(g^T x + h)^2 \leq 0.$$

我们将左边展开，可得：

$$x^T A x + b^T x + c + \lambda(g^T x + h)^2 = x^T (A + \lambda g g^T) x + (b + 2\lambda h g)^T x + c + \lambda h^2.$$

设超平面为：

$$H = \{x \in \mathbb{R}^n \mid g^T x + h = 0\},$$

并定义原二次函数 $f(x) = x^T A x + b^T x + c$ ，我们需要证明：

$$C \cap H = \{x \in H \mid f(x) \leq 0\}$$

是凸集。由于在超平面 H 上恒有 $g^T x + h = 0$ ，所以对任意 $x \in H$ ，都有 $\lambda(g^T x + h)^2 = 0$ 。因此，在 H 上，原不等式 $f(x) \leq 0$ 等价于

$$f(x) + \lambda(g^T x + h)^2 \leq 0.$$

记 $\tilde{f}(x) = f(x) + \lambda(g^T x + h)^2$ ，展开可得：

$$\tilde{f}(x) = x^T (A + \lambda g g^T) x + (b + 2\lambda h g)^T x + c + \lambda h^2.$$

由于 $A + \lambda g g^T \succeq 0$ ，所以 $\tilde{f}(x)$ 是凸函数。因此 $\{x \mid \tilde{f}(x) \leq 0\}$ 是凸函数的下水平集，从而是凸集。同时， H 是超平面，也是凸集。又因为在 H 上有 $f(x) = \tilde{f}(x)$ ，所以

$$C \cap H = \{x \in H \mid f(x) \leq 0\} = \{x \in H \mid \tilde{f}(x) \leq 0\} = H \cap \{x \mid \tilde{f}(x) \leq 0\}.$$

右端是两个凸集的交集，因此 $C \cap H$ 是凸集。

接下来我们来看两问的逆命题是否成立：首先看 a 的逆命题：我们取 $n = 1$ ，令：

$$A = -1, \quad b = 0, \quad c = 0.$$

此时 $C = \{x \in \mathbb{R} \mid -x^2 \leq 0\}$ 由于对任意 $x \in \mathbb{R}$ ，都有 $-x^2 \leq 0$ ，所以 $C = \mathbb{R}$ ，显然 C 是凸集。但是 $A = -1 < 0$ ，并不满足 $A \succeq 0$ 。所以逆命题 C 是凸集并不能推出 $A \succeq 0$ ，逆命题不成立。

接下来看 b 的逆命题：我们构造一个比较简单的超平面，取：

$$g = \begin{pmatrix} 1 \\ 0 \end{pmatrix}, \quad h = 0$$

那么超平面就是 $H = \{x \in \mathbb{R}^2 \mid x_1 = 0\}$ ，同时，我们希望构造一个二次型，只要 $x_1 = 0$ 就等于 0。构造如下： $x^T A x = 2x_1 x_2$ ，那么对应的矩阵就是：

$$A = \begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix}.$$

于是我们令 $b = 0, c = 0$ ，则 $C = \{(x_1, x_2) \in \mathbb{R}^2 \mid 2x_1 x_2 \leq 0\}$ ，在超平面 $H = \{x_1 = 0\}$ 上，恒有 $2x_1 x_2 = 0$ ，所以：

$$C \cap H = H.$$

因为 $g = \begin{pmatrix} 1 \\ 0 \end{pmatrix}$ ，所以 $gg^T = \begin{pmatrix} 1 & 0 \\ 0 & 0 \end{pmatrix}$ ，于是就有：

$$A + \lambda gg^T = \begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix} + \lambda \begin{pmatrix} 1 & 0 \\ 0 & 0 \end{pmatrix} = \begin{pmatrix} \lambda & 1 \\ 1 & 0 \end{pmatrix}$$

若该矩阵半正定，则其行列式必须非负。然而其行列式恒为 $-1 < 0$ ，因此对任意 $\lambda \in \mathbb{R}$ ，矩阵 $A + \lambda gg^T$ 都不可能半正定，故逆命题不成立。

综上， a 、 b 的逆命题都不成立。

2.6 判断函数是否为凸函数

(1) 不是凸函数, 反例如下: 我们取 $x = (1, 3)$, $y = (3, 1)$, 显然 $x, y \in \mathbb{R}_{++}^2$ 。二者中点为:

$$\frac{x+y}{2} = (2, 2)$$

于是有 $f\left(\frac{x+y}{2}\right) = f(2, 2) = 4$, 而 $\frac{f(x)+f(y)}{2} = \frac{f(1,3)+f(3,1)}{2} = \frac{3+3}{2} = 3$ 。而我们知道凸函数的定义为:

$$f\left(\frac{x+y}{2}\right) \leq \frac{f(x)+f(y)}{2}$$

但这里 $4 > 3$, 与凸函数定义矛盾了。所以 $f(x_1, x_2) = x_1 x_2$ 在 $\mathbb{R}_{++}^2$ 上并不是凸函数。

(2) 是凸函数, 证明如下: 我们可以将函数写为:

$$f(x_1, x_2) = x_1^{-1} x_2^{-1}.$$

故计算出一阶偏导数:

$$\frac{\partial f}{\partial x_1} = -x_1^{-2} x_2^{-1}, \quad \frac{\partial f}{\partial x_2} = -x_1^{-1} x_2^{-2}.$$

进一步计算出二阶偏导数:

$$\frac{\partial^2 f}{\partial x_1^2} = 2x_1^{-3} x_2^{-1}, \quad \frac{\partial^2 f}{\partial x_2^2} = 2x_1^{-1} x_2^{-3}, \quad \frac{\partial^2 f}{\partial x_1 \partial x_2} = x_1^{-2} x_2^{-2}.$$

因此该函数的 Hessian 矩阵就是:

$$\nabla^2 f(x_1, x_2) = \begin{pmatrix} \frac{2}{x_1^3 x_2} & \frac{1}{x_1^2 x_2^2} \\ \frac{1}{x_1^2 x_2^2} & \frac{2}{x_1 x_2^3} \end{pmatrix}.$$

由于 $x_1 > 0$, $x_2 > 0$, 所以 Hessian 的第一个顺序主子式 $\frac{2}{x_1^3 x_2} > 0$, 同时, 其行列式为:

$$\det(\nabla^2 f) = \frac{4}{x_1^4 x_2^4} - \frac{1}{x_1^4 x_2^4} = \frac{3}{x_1^4 x_2^4} > 0$$

因此 $\nabla^2 f(x_1, x_2)$ 在 $\mathbb{R}_{++}^2$ 上处处正定, 当然也半正定, 所以 f 是凸函数。证毕。

(3) 是凸函数, 证明如下: 首先, 当 $\alpha = 0$, 或 $\alpha = 1$ 时, $f(x_1, x_2) = -x_2$, 是仿射函数, $f(x_1, x_2) = -x_1$, 同样是仿射函数, 因此这两种情况下, 函数都是凸函数。接下来我们考虑 $0 < \alpha < 1$ 的情况。

我们计算二阶偏导数可得:

$$\frac{\partial^2 f}{\partial x_1^2} = \alpha(1-\alpha)x_1^{\alpha-2}x_2^{1-\alpha}, \frac{\partial^2 f}{\partial x_2^2} = \alpha(1-\alpha)x_1^\alpha x_2^{-\alpha-1}, \frac{\partial^2 f}{\partial x_1 \partial x_2} = -\alpha(1-\alpha)x_1^{\alpha-1}x_2^{-\alpha}.$$

所以函数的 *Hessian* 矩阵就是:

$$\nabla^2 f(x_1, x_2) = \alpha(1-\alpha)x_1^\alpha x_2^{1-\alpha} \begin{pmatrix} \frac{1}{x_1^2} & -\frac{1}{x_1 x_2} \\ -\frac{1}{x_1 x_2} & \frac{1}{x_2^2} \end{pmatrix}$$


注意到:

$$\begin{pmatrix} \frac{1}{x_1^2} & -\frac{1}{x_1 x_2} \\ -\frac{1}{x_1 x_2} & \frac{1}{x_2^2} \end{pmatrix} = \begin{pmatrix} \frac{1}{x_1} \\ -\frac{1}{x_2} \end{pmatrix} \begin{pmatrix} \frac{1}{x_1} & -\frac{1}{x_2} \end{pmatrix}.$$

右侧是向量与自身转置的乘积, 因此是半正定的。又因为 $0 < \alpha < 1$, 且 $x_1 > 0, x_2 > 0$, 所以系数 $\alpha(1-\alpha)x_1^\alpha x_2^{1-\alpha} > 0$, 因此 $\nabla^2 f(x_1, x_2) \succeq 0$ 。所以 f 在 $\mathbb{R}_{++}^2$ 上是凸函数。

2.7 判断是否为凸函数

(a) 是凸函数, 不是凹函数; 也是拟凸函数, 也是拟凹函数, 证明如下: 由于 $f''(x) = e^x > 0$, 所以 f 在 $\mathbb{R}$ 上是凸函数。如果 f 是凹函数, 则应有 $f''(x) \leq 0$, 但这里 $f''(x) = e^x > 0$, 因此 f 不是凹函数。



下面判断拟凸性与拟凹性。对任意 $t \in \mathbb{R}$ ，其下水平集为：

$$\{x \in \mathbb{R} \mid e^x - 1 \leq t\}$$

当 $t \leq -1$ 时，由于 $e^x > 0$ ，不可能有 $e^x \leq t + 1 \leq 0$ ，所以该集合为空集；当 $t > -1$ 时，该集合为：

$$\{x \mid x \leq \ln(t + 1)\} = (-\infty, \ln(t + 1)]$$

空集和区间都是凸集，所以 f 是拟凸函数。类似地，其上水平集为：

$$\{x \in \mathbb{R} \mid e^x - 1 \geq t\}.$$

当 $t \leq -1$ 时，该集合为 $\mathbb{R}$ ；当 $t > -1$ 时，该集合为

$$\{x \mid x \geq \ln(t + 1)\} = [\ln(t + 1), +\infty)$$

这些集合也都是凸集，所以 f 是拟凹函数。

(b) 不是凸函数，也不是凹函数；是拟凸函数，也是拟凹函数，证明如下： 首先，先判断凸性和凹性。计算 *Hessian* 矩阵有：

$$\nabla^2 f(x_1, x_2) = \begin{pmatrix} 0 & -\frac{1}{x_2^2} \\ -\frac{1}{x_2^2} & \frac{2x_1}{x_2^3} \end{pmatrix}.$$

其行列式为 $\det(\nabla^2 f) = 0 \cdot \frac{2x_1}{x_2^3} - \left(-\frac{1}{x_2^2}\right)^2 = -\frac{1}{x_2^4} < 0$ 。因此 *Hessian* 的两个特征值一正一负，是不定矩阵，既不半正定，也不半负定，所以 f 既不是凸函数，也不是凹函数。

下面判断拟凸性。对任意 $t \in \mathbb{R}$ ，下水平集为 $\{(x_1, x_2) \in \mathbb{R}_{++}^2 \mid \frac{x_1}{x_2} \leq t\}$ ，由于 $x_2 > 0$ ，所以上式就等价于：

$$\{(x_1, x_2) \in \mathbb{R}_{++}^2 \mid x_1 \leq tx_2\}.$$

当 $t \leq 0$ 时，该集合为空集；当 $t > 0$ 时，是正象限与半空间 $x_1 - tx_2 \leq 0$ 的交集，因此是凸集。所以 f 是拟凸函数。

再判断拟凹性。对任意 $t \in \mathbb{R}$ ，上水平集为 $\{(x_1, x_2) \in \mathbb{R}_{++}^2 \mid \frac{x_1}{x_2} \geq t\}$ ，由于 $x_2 > 0$ ，它就等价于：

$$\{(x_1, x_2) \in \mathbb{R}_{++}^2 \mid x_1 \geq tx_2\}.$$

当 $t \leq 0$ 时，该集合为整个 $\mathbb{R}_{++}^2$ ；当 $t > 0$ 时，它是正象限与半空间 $x_1 - tx_2 \geq 0$ 的交集，因此仍然是凸集。所以 f 是拟凹函数。

(c) 是凸函数，不是凹函数；是拟凸函数，但不是拟凹函数。证明如下： 我们先判断凸性。计算 *Hessian* 矩阵：

$$\nabla^2 f(x_1, x_2) = \begin{pmatrix} \frac{2}{x_2} & -\frac{2x_1}{x_2^2} \\ \frac{2x_1}{x_2^2} & \frac{2x_1^2}{x_2^3} \end{pmatrix}.$$

对任意 $z = (z_1, z_2)^T$ ，有 $z^T \nabla^2 f(x_1, x_2) z = \frac{2}{x_2} \left(z_1 - \frac{x_1}{x_2} z_2\right)^2 \geq 0$ 。由于 $x_2 > 0$ ，所以 $\nabla^2 f(x_1, x_2) \succeq 0$ ，因此 f 是凸函数。凸函数一定是拟凸函数，所以 f 也是拟凸函数。

下面说明 f 不是凹函数。首先取两个点 $p = (-1, 1)$ ， $q = (1, 1)$ ，它们都在定义域内，且中点为 $(0, 1)$ 。此时：

$$f(p) = 1, \quad f(q) = 1, \quad f\left(\frac{p+q}{2}\right) = f(0, 1) = 0.$$

如果 f 是凹函数，则应有 $f\left(\frac{p+q}{2}\right) \geq \frac{f(p)+f(q)}{2} = 1$ ，但这里 $0 < 1$ ，矛盾。因此 f 不是凹函数。

最后， f 不是拟凹函数。取水平值 $t = 1$ ，其上水平集为 $\{(x_1, x_2) \in \mathbb{R} \times \mathbb{R}_{++} \mid \frac{x_1^2}{x_2} \geq 1\}$ ，即：

$$\{(x_1, x_2) \mid x_1^2 \geq x_2, x_2 > 0\}.$$

点 $p = (-1, 1)$ 与 $q = (1, 1)$ 显然都属于该上水平集，二者都满足 $x_1^2 = x_2 = 1$ 。但是它们的中点 $(0, 1)$ ，而 $0^2 = 0 < 1$ ，所以 $(0, 1)$ 是不属于该上水平集的。因此该上水平集不是凸集， f 不是拟凹函数。

2.8 利用复合规则证明凸函数

(a) 证明如下： 令：

$$h(x) = \begin{pmatrix} a_1^T x + b_1 \\ a_2^T x + b_2 \\ \vdots \\ a_m^T x + b_m \end{pmatrix}.$$

显然 $h(x)$ 是关于 x 的仿射映射。再定义 log-sum-exp 函数：

$$\ell(z) = \log \left(\sum_{i=1}^m e^{z_i} \right), \quad z \in \mathbb{R}^m.$$

所以原函数内层的部分可以写成 $g(x) = \log \left(\sum_{i=1}^m e^{a_i^T x + b_i} \right) = \ell(h(x))$ 。由于 $\ell(z) = \log \left(\sum_{i=1}^m e^{z_i} \right)$ 是经典的 log-sum-exp 函数，是凸函数，log-sum-exp 函数的凸性可由其 Hessian $\nabla^2 \ell(z) = \text{diag}(p) - pp^T \succeq 0$ 得到，其中 $p_i = \frac{e^{z_i}}{\sum_j e^{z_j}}$ ；

而 $h(x)$ 是仿射映射，所以由“凸函数与仿射映射复合仍为凸函数”可知， $g(x) = \ell(h(x))$ 是凸函数。

根据定义域 $\sum_{i=1}^m e^{a_i^T x + b_i} < 1$ 可得 $g(x) = \log \left(\sum_{i=1}^m e^{a_i^T x + b_i} \right) < 0$ ，所以原函数就可以进一步写成：

$$f(x) = \phi(g(x)),$$

其中 $\phi(t) = -\log(-t), t < 0$ 。接下来我们来考察外层函数 ϕ 的性质。对任意 $t < 0$ ，有：

$$\phi'(t) = -\frac{1}{t} > 0, \quad \phi''(t) = \frac{1}{t^2} > 0.$$

因此 $\phi(t)$ 在 $t < 0$ 上是凸函数，并且是单调递增函数。前面已经证明 $g(x)$ 是凸函数，且在定义域内有 $g(x) < 0$ ，此外，定义域可以写成

$$\text{dom } f = \{x \mid g(x) < 0\}.$$

由于 $g(x)$ 是凸函数，所以 $\{x \mid g(x) < 0\}$ 是凸函数的严格下水平集，因此定义域是凸集。

所以 $f(x) = \phi(g(x))$ 是“凸且非减函数”与“凸函数”的复合。由凸函数复合规则可知， $f(x)$ 是凸函数。

(b)证明如下： 记 $g(x, u, v) = \sqrt{uv - x^T x}$ ，若能证明 $g(x, u, v)$ 是凹函数，则 $f(x, u, v) = -g(x, u, v)$ 就是凸函数。下面我们来证明 g 是凹函数。

首先，由于定义域中 $u > 0$ ，所以我们可以将根号内部改写为：

$$uv - x^T x = u \left(v - \frac{x^T x}{u} \right).$$

因此就有 $g(x, u, v) = \sqrt{u \left(v - \frac{x^T x}{u} \right)}$ 。分层看这个复合关系。首先，先定义 $q(x, u) = \frac{x^T x}{u}$ ， $u > 0$ 。函数 $q(x, u)$ 是 quadratic-over-linear 函数，即二次函数除以正的一次变量，该函数在 $u > 0$ 上是凸函数。于是有：

$$r(x, u, v) = v - \frac{x^T x}{u} = v - q(x, u)$$

是凹函数，因为它是仿射函数 v 减去凸函数 $q(x, u)$ 。同时，由定义域条件 $uv > x^T x$ ， $u > 0$ ，可知 $v - \frac{x^T x}{u} > 0$ ，即 $r(x, u, v) > 0$ 。再定义二元几何平均函数：

$$\psi(s, t) = \sqrt{st}, \quad s > 0, t > 0.$$

该函数在 $\mathbb{R}_{++}^2$ 上是凹函数，并且关于 s, t 都是单调递增的。于是 g 可以写成如下复合形式：

$$g(x, u, v) = \psi(u, r(x, u, v)).$$

其中，外层函数 $\psi(s, t) = \sqrt{st}$ 是凹且非减函数；内层函数 u 是仿射函数，因此既凸又凹；内层函数 $r(x, u, v) = v - \frac{x^T x}{u}$ 是凹函数。由凹函数的复合规则可知， $g(x, u, v)$ 是凹函数。因此：

$$f(x, u, v) = -g(x, u, v) = -\sqrt{uv - x^T x}$$

是凸函数。

2.9 迭代复杂度与收敛速率

(a) $O(\log \frac{1}{\varepsilon})$, **线性收敛** 由于 $\lfloor k/2 \rfloor$ 大约等于 $k/2$, 所以 $4^{-\lfloor k/2 \rfloor} = O(2^{-k})$, 若要求 $e(x^k) \leq \varepsilon$, 则需要 $4^{-\lfloor k/2 \rfloor} \leq \varepsilon$, 即:

$$\lfloor k/2 \rfloor \geq \log_4 \frac{1}{\varepsilon}.$$

因此迭代复杂度为 $k = O(\log \frac{1}{\varepsilon})$, 该误差按几何速度下降, 因此属于**线性收敛**。但更严格地说, 因为 e_{k+1}/e_k 会在 1 和 1/4 之间交替, 所以它不是最标准的 Q-线性收敛, 但满足:

$$e(x^k) = O\left(\left(\frac{1}{2}\right)^k\right),$$

因此通常也可称为 **R-线性收敛**, 收敛因子可看作 1/2。

(b) $O(\log \log \frac{1}{\varepsilon})$, **二次收敛** 对于 $e(x^k) = \frac{\sqrt{5}}{2^{2^k}}$, 若要求 $e(x^k) \leq \varepsilon$, 则有 $\frac{\sqrt{5}}{2^{2^k}} \leq \varepsilon$, 等价于:

$$2^{2^k} \geq \frac{\sqrt{5}}{\varepsilon}$$

两边取以 2 为底的对数, 得到 $2^k \geq \log_2 \left(\frac{\sqrt{5}}{\varepsilon}\right)$, 再次取以 2 为底的对数, 可得:

$$k \geq \log_2 \left[\log_2 \left(\frac{\sqrt{5}}{\varepsilon} \right) \right]$$

因此迭代复杂度为 $k = O(\log \log \frac{1}{\varepsilon})$, 进一步地, 由于:

$$e(x^{k+1}) = \frac{\sqrt{5}}{2^{2^{k+1}}} = \frac{\sqrt{5}}{2^{2 \cdot 2^k}} = \frac{1}{\sqrt{5}} \left(\frac{\sqrt{5}}{2^{2^k}} \right)^2 = \frac{1}{\sqrt{5}} e(x^k)^2,$$

所以该误差序列满足

$$e(x^{k+1}) = \frac{1}{\sqrt{5}} e(x^k)^2$$

因此它是二次收敛，也就是 Q-二次收敛，收敛阶为 2，渐近常数为 $\frac{1}{\sqrt{5}}$ 。

(c) 迭代复杂度为 $O\left(\frac{1}{\varepsilon}\right)$ ，收敛速率为 $O\left(\frac{1}{k}\right)$ ，次线性收敛 若要求 $e(x^k) \leq \varepsilon$ ，则 $\frac{100}{k} \leq \varepsilon$ ，因此 $k \geq \frac{100}{\varepsilon}$ 。所以迭代复杂度为：

$$k = O\left(\frac{1}{\varepsilon}\right)$$

该误差按 $1/k$ 的速度下降，不是几何下降，因此属于次线性收敛，收敛速率为 $O\left(\frac{1}{k}\right)$ 。

(d) 分类别讨论 若要求 $e(x^k) \leq \varepsilon$ ，需要分两种情况讨论。首先，当精度要求不高，即可以在 $k \leq 50$ 阶段达到误差要求时，误差满足 $e(x^k) = \frac{1}{k^2}$ ，此时由 $\frac{1}{k^2} \leq \varepsilon$ 可得：

$$k \geq \frac{1}{\sqrt{\varepsilon}}$$

但这一段只在 $k \leq 50$ 时有效，因此它要求 $\frac{1}{\sqrt{\varepsilon}} \leq 50$ ，即 $\varepsilon \geq \frac{1}{2500}$ 。所以当 $\varepsilon \geq \frac{1}{2500}$ 时，迭代复杂度为：

$$k = O\left(\frac{1}{\sqrt{\varepsilon}}\right).$$

其次，当精度要求较高，即 $\varepsilon < \frac{1}{2500}$ 时，前 50 次迭代无法达到该精度要求，需要进入 $k > 50$ 的阶段。此时误差满足：

$$e(x^k) = 0.895^k.$$



由 $0.895^k \leq \varepsilon$ ，两边取对数，因为 $\log(0.895) < 0$ ，所以得到：


$$k \geq \frac{\log \varepsilon}{\log(0.895)} = \frac{\log(1/\varepsilon)}{-\log(0.895)}.$$

因此在高精度情形下，迭代复杂度为 $k = O(\log \frac{1}{\varepsilon})$ ，综上，该误差序列的复杂度可以分段写为：

$$k = \begin{cases} O\left(\frac{1}{\sqrt{\varepsilon}}\right), & \varepsilon \geq \frac{1}{2500}, \\ O\left(\log \frac{1}{\varepsilon}\right), & \varepsilon < \frac{1}{2500}. \end{cases}$$

从渐近意义上看，当 $\varepsilon \rightarrow 0$ 时，最终一定进入 $k > 50$ 的阶段，因此该误差序列的渐近收敛速率为线性收敛，收敛因子为 0.895。





(对 semilogy 图纵坐标范围进行了一定的调整, 便于观察结果)

2.10 二维二次函数优化问题

$$f(x) = \frac{1}{2}(x_1^2 + \gamma x_2^2), \quad \gamma \geq 1$$

我们可以将其写成矩阵形式:

$$f(x) = \frac{1}{2}x^T Q x, \quad Q = \begin{pmatrix} 1 & 0 \\ 0 & \gamma \end{pmatrix}$$

由于 $Q \succeq 0$, 因此目标函数在 $x_1 = 0, x_2 = 0$ 时取得最小值, 所以最优解就为 $x^* = (0, 0)^T$ 。同时, 目标函数的梯度为 $\nabla f(x) = Qx = \begin{pmatrix} x_1 \\ \gamma x_2 \end{pmatrix}$ 。

采用最速下降法并配合精确线搜索时, 迭代格式为

$$x^{k+1} = x^k - \alpha_k \nabla f(x^k),$$

其中 α_k 是沿负梯度方向使函数值最小的步长。记 $g_k = \nabla f(x^k)$, 则

$$\alpha_k = \arg \min_{\alpha \geq 0} f(x^k - \alpha g_k)$$

对二次函数 $f(x) = \frac{1}{2}x^T Qx$, 令 $\varphi(\alpha) = f(x^k - \alpha g_k)$, 则

$$\varphi(\alpha) = \frac{1}{2}(x^k - \alpha g_k)^T Q(x^k - \alpha g_k).$$

对 α 求导并令导数为 0, 可得 $\varphi'(\alpha) = -g_k^T Qx^k + \alpha g_k^T Qg_k = 0$, 又因为 $g_k = Qx^k$, 所以 $g_k^T Qx^k = g_k^T g_k$, 因此精确线搜索步长为:

$$\alpha_k = \frac{g_k^T g_k}{g_k^T Qg_k}$$

当 $\gamma = 1$ 时, 目标函数变为

$$f(x) = \frac{1}{2}\|x\|_2^2$$

此时 $\nabla f(x) = x$ 。采用精确线搜索时, 沿方向 $-x^k$ 的迭代点为 $(1 - \alpha)x^k$, 对应函数值为:

$$f((1 - \alpha)x^k) = \frac{1}{2}(1 - \alpha)^2 \|x^k\|_2^2$$

显然当 $\alpha = 1$ 时取得最小值, 因此算法一步到达最优解 $x^* = 0$ 。当 $k = 0$ 时, 题中等式两边均为 1; 当 $k \geq 1$ 时, $\|x^k - x^*\|_2 = 0$, 且 $(\frac{\gamma-1}{\gamma+1})^k = 0$, 因此题中结论成立。下面只需考虑 $\gamma > 1$ 的情形。

令 $\rho = \frac{\gamma-1}{\gamma+1}$, 接下来, 我们先用数学归纳法进行证明 $x^k = \rho^k \begin{pmatrix} \gamma \\ (-1)^k \end{pmatrix}$ 。很显然, 当 $k = 0$ 时, 有:

$$\rho^0 \begin{pmatrix} \gamma \\ (-1)^0 \end{pmatrix} = \begin{pmatrix} \gamma \\ 1 \end{pmatrix} = x^0,$$

所以结论成立。假设对某个 k 有 $x^k = \rho^k \begin{pmatrix} \gamma \\ (-1)^k \end{pmatrix}$, 那么由梯度表达式可得:

$$g_k = \nabla f(x^k) = Qx^k = \rho^k \begin{pmatrix} \gamma \\ \gamma(-1)^k \end{pmatrix}$$

于是 $g_k^T g_k = 2\gamma^2 \rho^{2k}$, $g_k^T Qg_k = \gamma^2(1 + \gamma)\rho^{2k}$, 因此精确线搜索步长为:

$$\alpha_k = \frac{g_k^T g_k}{g_k^T Qg_k} = \frac{2\gamma^2 \rho^{2k}}{\gamma^2(1 + \gamma)\rho^{2k}} = \frac{2}{\gamma + 1}.$$

将该步长代入迭代公式，有：

$$x^{k+1} = x^k - \alpha_k g_k = \rho^k \begin{pmatrix} \gamma \\ (-1)^k \end{pmatrix} - \frac{2}{\gamma+1} \rho^k \begin{pmatrix} \gamma \\ \gamma(-1)^k \end{pmatrix}$$

整理得到：

$$x^{k+1} = \rho^k \begin{pmatrix} \gamma \left(1 - \frac{2}{\gamma+1}\right) \\ (-1)^k \left(1 - \frac{2\gamma}{\gamma+1}\right) \end{pmatrix}.$$

而我们发现 $1 - \frac{2}{\gamma+1} = \frac{\gamma-1}{\gamma+1} = \rho$, $1 - \frac{2\gamma}{\gamma+1} = \frac{1-\gamma}{\gamma+1} = -\rho$, 所以: $x^{k+1} = \rho^k \begin{pmatrix} \gamma\rho \\ (-1)^{k+1}\rho \end{pmatrix} = \rho^{k+1} \begin{pmatrix} \gamma \\ (-1)^{k+1} \end{pmatrix}$ 。因此，若结论对 k 成立，则对 $k+1$ 也成立。根据数学归纳法可知，该式对任何 $k \geq 0$ 均成立。

由于 $x^* = (0, 0)^T$ ，所以 $\|x^k - x^*\|_2 = \|x^k\|_2$ 。由上式可得：

$$\|x^k - x^*\|_2 = \left\| \rho^k \begin{pmatrix} \gamma \\ (-1)^k \end{pmatrix} \right\|_2 = \rho^k \sqrt{\gamma^2 + 1}$$

而初始点满足 $\|x^0 - x^*\|_2 = \left\| \begin{pmatrix} \gamma \\ 1 \end{pmatrix} \right\|_2 = \sqrt{\gamma^2 + 1}$ ，因此

$$\frac{\|x^k - x^*\|_2}{\|x^0 - x^*\|_2} = \frac{\rho^k \sqrt{\gamma^2 + 1}}{\sqrt{\gamma^2 + 1}} = \rho^k.$$

代回 $\rho = \frac{\gamma-1}{\gamma+1}$ ，得到：

$$\boxed{\frac{\|x^k - x^*\|_2}{\|x^0 - x^*\|_2} = \left(\frac{\gamma-1}{\gamma+1} \right)^k}$$

2.11 求解与绘图

1. 求出最优值与最优解 首先, 我们记 $A = e^{x_1+3x_2-0.1}$, $B = e^{x_1-3x_2-0.1}$, $C = e^{-x_1-0.1}$, 则 $f(x_1, x_2) = A + B + C$ 。对 x_1, x_2 分别求偏导, 可得:

$$\frac{\partial f}{\partial x_1} = A + B - C, \quad \frac{\partial f}{\partial x_2} = 3A - 3B. \quad \text{令梯度为零, 得到 } A + B - C = 0 \text{ 与 } A = B.$$

由 $A = B$ 可知:

$$e^{x_1+3x_2-0.1} = e^{x_1-3x_2-0.1},$$

由于指数函数单调且一一对应, 因此 $x_1 + 3x_2 - 0.1 = x_1 - 3x_2 - 0.1$, 从而 $x_2^* = 0$ 。

再由 $A + B - C = 0$ 以及 $A = B$, 可得 $C = 2A$ 。

将 $x_2^* = 0$ 代入, 有 $A = e^{x_1-0.1}$, $C = e^{-x_1-0.1}$, 因此 $e^{-x_1-0.1} = 2e^{x_1-0.1}$ 。两边同时除以 $e^{-0.1}$, 得到 $e^{-x_1} = 2e^{x_1}$, 即 $e^{-2x_1} = 2$, 所以 $x_1^* = -\frac{1}{2} \ln 2$ 。因此最优解为:

$$x^* = \begin{pmatrix} -\frac{1}{2} \ln 2 \\ 0 \end{pmatrix}$$

将 x^* 代回原函数。此时 $A = B = e^{-\frac{1}{2} \ln 2 - 0.1} = \frac{e^{-0.1}}{\sqrt{2}}$, 而 $C = e^{\frac{1}{2} \ln 2 - 0.1} = \sqrt{2}e^{-0.1}$ 。因此:

$$f^* = A + B + C = \frac{e^{-0.1}}{\sqrt{2}} + \frac{e^{-0.1}}{\sqrt{2}} + \sqrt{2}e^{-0.1} = 2\sqrt{2}e^{-0.1}.$$

所以最优值为:

$$f^* = 2\sqrt{2}e^{-0.1}$$


由于 f 是若干个指数仿射函数之和, 而指数仿射函数是凸函数, 所以 f 是凸函数。因此, 上述满足 $\nabla f(x^*) = 0$ 的点就是全局最优解。进一步地, 由于该函数中三个指数项对应的仿射方向能够张成 $\mathbb{R}^2$, 所以 f 实际上是严格凸函数, 因此该最优解也是唯一最优解。

2. 利用回溯线搜索求解 采用梯度下降格式:

$$x^{k+1} = x^k - t_k \nabla f(x^k).$$

其中回溯线搜索从 $t = 1$ 开始, 不断令 $t \leftarrow \beta t$, 直到满足 Armijo 条件

$$f(x^k - t \nabla f(x^k)) \leq f(x^k) - \alpha t \|\nabla f(x^k)\|_2^2.$$



$$x^* \approx (-0.34657359, 0)^T, f^* \approx 2.5592666967.$$

30 次迭代后得到:

$$x^{30} \approx (-0.34646271, 0)^T, f(x^{30}) - f^* \approx 1.57 \times 10^{-8}.$$

0.0.1 代码附录:

2.9 代码

```
from pathlib import Path
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt

BASE = Path.cwd().parent if Path.cwd().name == "notebooks" else Path.cwd()
PICS = BASE / "pics"
PICS.mkdir(exist_ok=True)

plt.rcParams["figure.dpi"] = 120
plt.rcParams["savefig.dpi"] = 220
plt.rcParams["axes.unicode_minus"] = False
plt.rcParams["font.sans-serif"] = ["Microsoft YaHei", "SimHei", "DejaVu Sans"]
```

```

def make_error_sequences(max_iter=100):
    k = np.arange(1, max_iter + 1, dtype=float)

    errors = {
        r"(a)$4^{\lfloor k/2 \rfloor}$": 1.0 / (4.0 ** np.floor(k /
2.0)),
        r"(b)$\sqrt{5}/2^{2^k}$": np.sqrt(5.0) * np.exp(-np.log(2.0)
* (2.0 ** k)),
        r"(c)$100/k$": 100.0 / k,
        r"(d) piecewise": np.where(k <= 50, 1.0 / (k ** 2), 0.895 **
k),
    }
    return k, errors

def summarize_error_sequences():
    rows = [
        {
            "sequence": r"$4^{\lfloor k/2 \rfloor}$",
            "iteration_complexity": r"$O(\log(1/\varepsilon))$",
            "rate": r"R-linear, about $O((1/2)^k)$",
        },
        {
            "sequence": r"$\sqrt{5}/2^{2^k}$",
            "iteration_complexity": r"$O(\log\log(1/\varepsilon))$",
            "rate": r"Q-quadratic, $e_{k+1}=e_k^2/\sqrt{5}$",
        },
        {
            "sequence": r"$100/k$",
            "iteration_complexity": r"$O(1/\varepsilon)$",
            "rate": r"sublinear, $O(1/k)$",
        },
        {
            "sequence": r"$1/k^2$ if $k \le 50$, $0.895^k$ if $k > 50$",
            "iteration_complexity": (
                r"$O(1/\sqrt{\varepsilon})$ for $\varepsilon \ge$
1/2500; "
                r"$O(\log(1/\varepsilon))$ for $\varepsilon < 1/2500$"
            ),
            "rate": r"early stage $O(1/k^2)$; asymptotically linear,
factor $0.895$",
        },
    ]

```

```
]
    return pd.DataFrame(rows)

k, errors = make_error_sequences(max_iter=100)
summary_df = summarize_error_sequences()
summary_df
```

普通比例尺作图:

```
fig, ax = plt.subplots(figsize=(8.5, 5.0))

for label, err in errors.items():
    ax.plot(k, err, linewidth=1.8, label=label)

ax.set_xlabel("iteration k")
ax.set_ylabel(r"error$(x^k)$")
ax.set_title("Problem 2.9: error sequences, normal scale")
ax.grid(True, alpha=0.3)
ax.legend(fontsize=8)

fig.tight_layout()
out = PICS / "problem_2_9_error_sequences_normal.png"
fig.savefig(out, bbox_inches="tight")
print(f"saved to {out}")
plt.show()
```

semilogy 作图:

```
fig, ax = plt.subplots(figsize=(8.5, 5.0))

for label, err in errors.items():
    mask = np.isfinite(err) & (err > 0)
    ax.semilogy(k[mask], err[mask], linewidth=1.8, label=label)

ax.set_xlabel("iteration k")
ax.set_ylabel(r"error$(x^k)$")
ax.set_title("Problem 2.9: error sequences, semilogy scale")
ax.grid(True, which="both", alpha=0.3)
ax.legend(fontsize=8)

fig.tight_layout()
out = PICS / "problem_2_9_error_sequences_semilogy.png"
fig.savefig(out, bbox_inches="tight")
```

```
print(f"saved to {out}")  
plt.show()
```

2.11 代码

```
from pathlib import Path  
import numpy as np  
import matplotlib.pyplot as plt  
  
BASE = Path.cwd().parent if Path.cwd().name == "notebooks" else Path  
    .cwd()  
PICS = BASE / "pics"  
PICS.mkdir(exist_ok=True)  
  
plt.rcParams["figure.dpi"] = 120  
plt.rcParams["savefig.dpi"] = 220  
plt.rcParams["axes.unicode_minus"] = False  
plt.rcParams["font.sans-serif"] = ["Microsoft YaHei", "SimHei", "  
    DejaVu Sans"]  
  
def f(x):  
    x1, x2 = x  
    return (  
        np.exp(x1 + 3 * x2 - 0.1)  
        + np.exp(x1 - 3 * x2 - 0.1)  
        + np.exp(-x1 - 0.1)  
    )  
  
def grad_f(x):  
    x1, x2 = x  
    e1 = np.exp(x1 + 3 * x2 - 0.1)  
    e2 = np.exp(x1 - 3 * x2 - 0.1)  
    e3 = np.exp(-x1 - 0.1)  
    return np.array([e1 + e2 - e3, 3 * e1 - 3 * e2], dtype=float)  
  
def backtracking_gradient_descent(x0, max_iter=30, alpha=0.1, beta  
    =0.7):  
    x = np.array(x0, dtype=float)
```

```
xs = [x.copy()]
f_values = [f(x)]
step_sizes = []

for _ in range(max_iter):
    g = grad_f(x)
    t = 1.0

    # Armijo condition:
    #  $f(x - t g) \leq f(x) - \alpha * t * ||g||_2^2$ 
    while f(x - t * g) > f(x) - alpha * t * np.dot(g, g):
        t *= beta

    x = x - t * g
    xs.append(x.copy())
    f_values.append(f(x))
    step_sizes.append(t)

return np.array(xs), np.array(f_values), np.array(step_sizes)

x_star = np.array([-0.5 * np.log(2.0), 0.0])
f_star = 2.0 * np.sqrt(2.0) * np.exp(-0.1)

xs, f_values, step_sizes = backtracking_gradient_descent(
    x0=np.array([0.0, 0.0]),
    max_iter=30,
    alpha=0.1,
    beta=0.7,
)

gap = np.maximum(f_values - f_star, np.finfo(float).eps)
k = np.arange(len(gap))

fig, ax = plt.subplots(figsize=(8.5, 5.0))
ax.semilogy(k, gap, marker="o", linewidth=1.5, markersize=3.5)
ax.set_xlabel("iteration k")
ax.set_ylabel(r" $f(x^k) - f^{\star}$ ")
ax.set_title("Problem 2.11: Backtracking Gradient Descent")
ax.grid(True, which="both", alpha=0.3)

fig.tight_layout()
```

```
out = PICS / "problem_2_11_backtracking_semiology.png"
fig.savefig(out, bbox_inches="tight")
print(f"saved to {out}")
plt.show()

print("x_star =", x_star)
print("f_star =", f_star)
print("x_30 =", xs[-1])
print("f(x_30)-f_star =", f_values[-1] - f_star)
```