

《优化理论与算法》第 10 次作业

- 作业截止于周日 (5/17/2026)，在 Canvas 系统中提交 PDF 或照片文件
- 作业题目的 tex 文件可以在 Canvas 中下载
- 鼓励相互讨论，但不要抄袭.

1 阅读与积累

1.1

- 复习 Boyd and Vandenberghe，也就是 Convex Optimization 教材，章节 9.1, 9.3 相关

2 迭代算法

2.1 假设 $e(x^k)$ 是算法第 k 次迭代点 x^k 的误差。下列误差的迭代复杂度（写成大 O 形式）与收敛速率分别是什么？

(a) $e(x_k) = 1/4^{\lfloor k/2 \rfloor}$

(b) $e(x_k) = \sqrt{5}/2^{2^k}$

(c) $e(x_k) = 100/k$

(d)
$$e(x_k) = \begin{cases} \frac{1}{k^2} & \text{if } k \leq 50 \\ 0.895^k & \text{if } k > 50 \end{cases}$$

利用 Python 或 Matlab 画图，类似课件 P15 页，将 4 种误差画在同一个图里面，要求一张图的坐标轴采用正常比例尺，另一张图的 y 轴采用 semilogy 的方式作图。

3 梯度下降法

3.1 如课件 (P16), 考虑 2 维 2 次函数优化问题:

$$\min_x f(x) = \frac{1}{2} (x_1^2 + \gamma x_2^2)$$

其中, $\gamma \geq 1$ 。当选取初始点 $x^0 = (\gamma, 1)$ 时, 试证明采用精准线搜索时, 有下式成立

$$\frac{\|x_k - x^*\|_2}{\|x_0 - x^*\|_2} = \left(\frac{\gamma - 1}{\gamma + 1} \right)^k$$

3.2 考虑教材 9.3.2 中的函数

$$f(x_1, x_2) = e^{x_1+3x_2-0.1} + e^{x_1-3x_2-0.1} + e^{-x_1-0.1}$$

1. 最优值 f^* 与最优解 x^* 分别是什么?
2. 利用回溯线搜索 ($\alpha = 0.1, \beta = 0.7$) 求解, 可设置初始点为 $x^0 = (0, 0)$ 。请画出 $f(x^k) - f^*$ 随着迭代次数 k 变化的图像 (semilogy 形式, 展示 30 次迭代就可以)。注意: 你可以利用 Matlab 或 Python 自行画图, 并将相关代码附在作业后面。

3.3 (附加加分题) 假设函数是 f 是凸的且 L -光滑, 试证明

$$(\nabla f(x) - \nabla f(y))^T (x - y) \geq \frac{1}{L} \|\nabla f(x) - \nabla f(y)\|_2^2$$

3.4 证明课件梯度下降法课件 P34 中的定理。提示:

a 构建 $h(x) = f(x) - \frac{\mu}{2} x^T x$ 。利用 3.3 证明如下性质:

$$(\nabla f(x) - \nabla f(y))^T (x - y) \geq \frac{\mu L}{\mu + L} \|x - y\|_2^2 + \frac{1}{\mu + L} \|\nabla f(x) - \nabla f(y)\|_2^2$$

b 开始证明定理, 可以从下式开始

$$\|x^{k+1} - x^*\|_2^2 = \|(x^k - x^*) - t \nabla f(x)\|_2^2$$

4 次梯度下降法

4.1 证明 $\partial f(x)$ 是凸集合。