

《优化理论与算法》第 8 次作业 solution

- 作业截止于**周日 (5/3/2026)**，在 Canvas 系统中提交 PDF 或照片文件
- 作业题目的 tex 文件可以在 Canvas 中下载
- 鼓励相互讨论，但不要抄袭.

1 阅读与积累

1.1

- 复习 Boyd and Vandenberghe, 也就是 Convex Optimization 教材, 章节 3.2-3.4 与 4.1-4.2 相关

2 习题

2.1 判断下列函数是否是凸函数、凹函数、拟凸函数?

- (a) $f(x) = e^x - 1$, 定义域为 $\mathbb{R}$
- (b) $f(x_1, x_2) = x_1/x_2$, 定义域为 $\mathbb{R}_{++}^2$
- (c) $f(x_1, x_2) = x_1^2/x_2$, 定义域为 $\mathbb{R} \times \mathbb{R}_{++}$

2.1 solution

- (a) 该函数为严格凸函数，因此也是拟凸函数。同时具有拟凹性，但不是凹函数。
- (b) f 的海森矩阵为

$$\nabla^2 f(x) = \begin{pmatrix} 0 & -1/x_2^2 \\ -1/x_2^2 & 2x_1/x_2^3 \end{pmatrix}$$

该矩阵既非半正定也非半负定，故 f 既非凸函数也非凹函数。然而，由于其子水平集和超水平集均为半空间， f 同时具有拟凸性和拟凹性（即为拟线性函数）。

(c) f 是凸函数。通过计算海森矩阵可验证:

$$\nabla^2 f(x) = \begin{pmatrix} 2/x_2 & -2x_1/x_2^2 \\ -2x_1/x_2^2 & 2x_1^2/x_2^3 \end{pmatrix} = (2/x_2) \begin{pmatrix} 1 & \\ & -2x_1/x_2 \end{pmatrix} \begin{pmatrix} 1 & -2x_1/x_2 \end{pmatrix} \succeq 0$$

因此, f 是凸函数及拟凸函数。但 f 既非凹函数也非拟凹函数。

2.2 复合规则。证明下列函数是凸函数:

(a) $f(x) = -\log\left(-\log\left(\sum_{i=1}^m e^{a_i^T x + b_i}\right)\right)$, $\text{dom } f = \left\{x \mid \sum_{i=1}^m e^{a_i^T x + b_i} < 1\right\}$

(b) $f(x, u, v) = -\sqrt{uv - x^T x}$, $\text{dom } f = \{(x, u, v) \mid uv > x^T x, u > 0, v > 0\}$

2.2 solution

(a) 函数为 $f(x) = -\log\left(-\log\left(\sum_{i=1}^m e^{a_i^T x + b_i}\right)\right)$, 定义域为 $\sum_{i=1}^m e^{a_i^T x + b_i} < 1$ 。

令 $g(x) = \sum_{i=1}^m e^{a_i^T x + b_i}$, 则 $f(x) = -\log(-\log(g(x)))$ 。

$g(x)$ 是指数函数的和, 每个 $e^{a_i^T x + b_i}$ 是凸函数 (指数函数为凸函数, 和保持凸性)。

内层函数 $h(y) = -\log(y)$ 在 $y > 0$ 时是凸函数 (二阶导数 $h''(y) = 1/y^2 > 0$)。由于 $g(x) < 1$, $h(g(x)) = -\log(g(x))$ 是凸函数 (凸函数复合凸且非增函数仍为凸)。

外层函数 $k(z) = -\log(z)$ 在 $z > 0$ 时是凸函数 (二阶导数 $k''(z) = 1/z^2 > 0$)。由于 $z = h(g(x))$ 是凸函数, 且 k 是凸且非增的, 复合后 $k(z) = -\log(-\log(g(x)))$ 是凸函数。

综上, $f(x)$ 是凸函数。

(b) 函数为 $f(x, u, v) = -\sqrt{uv - x^T x}$, 定义域为 $uv > x^T x$, 且 $u > 0, v > 0$ 。

令 $g(x, u, v) = uv - x^T x$, 则 $f = -\sqrt{g}$ 。

分析 g 的性质: 虽然 uv 是双线性函数 (非凸非凹), 但 $-x^T x$ 是凹函数。整体 g 的凸性需进一步验证。

通过二次锥约束的凸性: 定义域 $uv > x^T x$ 等价于 $\sqrt{x^T x} \leq \sqrt{uv}$, 这定义了一个凸集 (二次锥)。

函数 $\sqrt{g}$ 在凸集 $g > 0$ 上是凹函数 (平方根函数为凹函数且非减), 因此 $f = -\sqrt{g}$ 是凸函数 (凹函数的负数为凸函数)。

综上, $f(x, u, v)$ 是凸函数。

2.3 正式证明共轭函数为凸函数, 即使原函数是非凸函数。

2.3 solution

对任意 y ，共轭函数定义为：

$$f^*(y) = \sup_x (y^\top x - f(x)).$$

对固定的 x ，函数 $\phi_x(y) = y^\top x - f(x)$ 是关于 y 的仿射（线性）函数，因此是凸函数。共轭函数 $f^*(y)$ 是所有 $\phi_x(y)$ 的逐点上确界。根据凸函数的性质，凸函数的逐点上确界仍是凸函数。

因此，无论原函数 f 是否为凸函数，其共轭函数 f^* 恒为凸函数。

2.4 求给定负熵函数的共轭：

$$f(x) = \sum_{i=1}^n x_i \log(x_i / 1^T x), \quad \text{dom } f = \mathbb{R}_{++}^n$$

证明其共轭函数为

$$f^*(y) = \begin{cases} 0 & \text{若 } \sum_{i=1}^n e^{y_i} \leq 1 \\ +\infty & \text{其他情况} \end{cases}$$

2.4 solution

要证明负熵函数 $f(x) = \sum_{i=1}^n x_i \log\left(\frac{x_i}{1^T x}\right)$ 的共轭函数为

$$f^*(y) = \begin{cases} 0 & \text{若 } \sum_{i=1}^n e^{y_i} \leq 1 \\ +\infty & \text{其他情况} \end{cases}$$

共轭函数 $f^*(y)$ 定义为：

$$f^*(y) = \sup_{x \in \mathbb{R}_{++}^n} (y^\top x - f(x)).$$

将 $f(x)$ 代入并展开：

$$y^\top x - f(x) = \sum_{i=1}^n y_i x_i - \sum_{i=1}^n x_i \log\left(\frac{x_i}{1^T x}\right).$$

令 $s = 1^T x = \sum_{i=1}^n x_i$ 和 $p_i = x_i/s$ ，则 $x_i = sp_i$ 且 $\sum_{i=1}^n p_i = 1$ 。代入上式得：

$$\sum_{i=1}^n y_i (sp_i) - \sum_{i=1}^n sp_i \log p_i = s \left(\sum_{i=1}^n y_i p_i - \sum_{i=1}^n p_i \log p_i \right).$$

优化问题转化为：

$$f^*(y) = \sup_{s>0, p \in \Delta} s \left(\sum_{i=1}^n y_i p_i - \sum_{i=1}^n p_i \log p_i \right),$$

其中 Δ 是概率单纯形。对固定的 p ，关于 s 的优化结果为：

- 若 $\sum_{i=1}^n y_i p_i - \sum_{i=1}^n p_i \log p_i > 0$, 则上确界为 $+\infty$;
- 否则, 上确界为 0。

进一步分析 $\sum_{i=1}^n y_i p_i - \sum_{i=1}^n p_i \log p_i$ 在 $p \in \Delta$ 上的最大值。通过拉格朗日乘数法求得最优 $p_i = \frac{e^{y_i}}{\sum_{j=1}^n e^{y_j}}$, 此时最大值为:

$$\log \left(\sum_{i=1}^n e^{y_i} \right).$$

因此

- 当 $\sum_{i=1}^n e^{y_i} \leq 1$ 时, 最大值为 $\log(\sum e^{y_i}) \leq 0$, 故 $f^*(y) = 0$;
- 当 $\sum_{i=1}^n e^{y_i} > 1$ 时, 最大值 $\log(\sum e^{y_i}) > 0$, 故 $f^*(y) = +\infty$ 。

综上所述可得:

$$f^*(y) = \begin{cases} 0 & \text{若 } \sum_{i=1}^n e^{y_i} \leq 1 \\ +\infty & \text{其他情况} \end{cases}$$

2.5 《Convex Optimization》(Boyd and Vandenberghe) 教材课后题 4.1

2.5 solution

可行域是点 $(0, \infty)$, $(0, 1)$, $(\frac{2}{5}, \frac{1}{5})$, $(1, 0)$, $(\infty, 0)$ 的凸包。

(a) $\mathbf{x}^* = \left(\frac{2}{5}, \frac{1}{5}\right)$.

(b) 目标函数下方无界。

(c) 最优解集 $X_{\text{opt}} = \{(0, x_2) \mid x_2 \geq 1\}$.

(d) $\mathbf{x}^* = \left(\frac{1}{3}, \frac{1}{3}\right)$.

(e) $\mathbf{x}^* = \left(\frac{1}{2}, \frac{1}{6}\right)$. 该点为最优点, 因为它满足

$$2x_1 + x_2 = \frac{7}{6} > 1, \quad x_1 + 3x_2 = 1,$$

且梯度 $\nabla f_0(\mathbf{x}^*) = (1, 3)$ 与直线 $x_1 + 3x_2 = 1$ 垂直。

2.6 《Convex Optimization》(Boyd and Vandenberghe) 教材课后题 4.3

2.6 solution

令

$$f(x) = \frac{1}{2}x^T Px + q^T x + r$$

则

$$\nabla f(x^*) = Px^* + q = \begin{pmatrix} -1 \\ 0 \\ 2 \end{pmatrix}$$

对于任意可行解 $y \in \mathbb{R}^3$, 都有 $-1 \leq y_i \leq 1$, $i = 1, 2, 3$ 。因此,

$$\begin{aligned} \nabla f(x^*)^T(y - x^*) &= \nabla f(x^*)_1(y_1 - x_1^*) + \nabla f(x^*)_2(y_2 - x_2^*) + \nabla f(x^*)_3(y_3 - x_3^*) \\ &= -y_1 + 2y_3 + 3 \\ &\geq -1 - 2 + 3 = 0 \end{aligned}$$

由一阶最优性条件, $x^* = (1, 1/2, -1)$ 是最优解。

2.7 《Convex Optimization》(Boyd and Vandenberghe) 教材课后题 4.26 (a) (提示: 利用上图形式, 考虑目标函数形式为: $\min \sum_{i=1}^m t_i$)

2.7 solution

该问题等价于

$$\begin{aligned} &\text{minimize} \quad \mathbf{1}^T t \\ &\text{subject to} \quad t_i(a_i^T x + b_i) \geq 1, \quad i = 1, \dots, m \\ &\quad \quad \quad t \succeq 0. \end{aligned}$$

将双曲约束写成二阶锥约束会得到一个二阶锥规划 (SOCP)

$$\begin{aligned} &\text{minimize} \quad \mathbf{1}^T t \\ &\text{subject to} \quad \left\| \begin{bmatrix} 2 \\ a_i^T x + b_i - t_i \end{bmatrix} \right\|_2 \leq a_i^T x + b_i + t_i, \quad i = 1, \dots, m \\ &\quad \quad \quad t_i \geq 0, \quad a_i^T x + b_i \geq 0, \quad i = 1, \dots, m. \end{aligned}$$

2.8 《Convex Optimization》(Boyd and Vandenberghe) 教材课后题 4.28 (a) (提示: 利用上图形式, 考虑目标函数形式为: $\min t$)

2.8 solution

目标函数是凸函数的最大值, 因此是凸的。

我们可以将该问题写为

$$\begin{aligned} & \text{minimize} && t \\ & \text{subject to} && (1/2)x^T P_i x + q^T x + r \leq t, \quad i = 1, \dots, K \\ & && Ax \preceq b, \end{aligned}$$

这是以变量 x 和 t 表示的二次约束二次规划 (QCQP)。