

《优化理论与算法》第 10 次作业

- 作业截止于**周日 (5/17/2025)**，在 Canvas 系统中提交 PDF 或照片文件
- 作业题目的 tex 文件可以在 Canvas 中下载
- 鼓励相互讨论，但不要抄袭.

1 阅读与积累

1.1

- 复习 Boyd and Vandenberghe，也就是 Convex Optimization 教材，章节 9.1，9.3 相关

2 迭代算法

2.1 假设 $e(x^k)$ 是算法第 k 次迭代点 x^k 的误差。下列误差的迭代复杂度（写成大 O 形式）与收敛速率分别是什么？

(a) $e(x_k) = 1/4^{\lfloor k/2 \rfloor}$

(b) $e(x_k) = \sqrt{5}/2^{2^k}$

(c) $e(x_k) = 100/k$

(d)
$$e(x_k) = \begin{cases} \frac{1}{k^2} & \text{if } k \leq 50 \\ 0.895^k & \text{if } k > 50 \end{cases}$$

利用 Python 或 Matlab 画图，类似课件 P15 页，将 4 种误差画在同一个图里面，要求一张图的坐标轴采用正常比例尺，另一张图的 y 轴采用 semilogy 的方式作图。

2.1 solution

(a) Q-线性收敛

令 $\tilde{e}(X^k) = (\frac{1}{2})^{k-1}$ ，则 $e(X^k) \leq \tilde{e}(X^k)$

$$\lim_{k \rightarrow +\infty} \frac{\tilde{e}(X^{k+1})}{\tilde{e}(X^k)} = \lim_{k \rightarrow +\infty} \frac{\left(\frac{1}{2}\right)^k}{\left(\frac{1}{2}\right)^{k-1}} = \frac{1}{2} \in (0, 1)$$

则 $\{\tilde{e}(X^{k+1})\}$ Q-线性收敛, 从而 $\{e(X^k)\}$ R-线性收敛。

当 $e(X^k) < \varepsilon$ 时, $k \geq O(\log(\frac{1}{\varepsilon}))$

(b) 二次收敛

$$\lim_{k \rightarrow +\infty} \frac{e(X^{k+1})}{e(X^k)} = \lim_{k \rightarrow +\infty} \frac{\sqrt{5}/2^{2k}}{\sqrt{5}/2^{2k}} \cdot \frac{1}{2^{2k}} = \frac{1}{2^{2k}} = 0$$

$$\lim_{k \rightarrow +\infty} \frac{e(X^{k+1})}{e(X^k)^2} = \lim_{k \rightarrow +\infty} \frac{\sqrt{5}/2^{2k+1}}{5/2^{2k}} = \frac{\sqrt{5}}{5} > 0$$

则 $\{e(X^k)\}$ 的收敛性为二次收敛。

当 $e(X^k) \leq \varepsilon$ 时, $k \geq O(\log(\log(\frac{1}{\varepsilon})))$

(c) 亚线性收敛

$$\lim_{k \rightarrow +\infty} \frac{e(X^{k+1})}{e(X^k)} = \lim_{k \rightarrow +\infty} \frac{100/(k+1)}{100/k} = \lim_{k \rightarrow +\infty} \frac{k}{k+1} = 1$$

则 $\{e(X^k)\}$ 的收敛性为亚线性收敛。


当 $e(X^k) \leq \varepsilon$ 时, $k \geq O(\frac{1}{\varepsilon})$

(d) R-线性收敛

$$\lim_{k \rightarrow +\infty} \frac{e(X^{k+1})}{e(X^k)} = \lim_{k \rightarrow +\infty} \frac{0.895^{k+1}}{0.895^k} = 0.895 \in (0, 1)$$

则 $\{e(X^k)\}$ 的收敛性为 R-线性收敛。

当 $e(X^k) \leq \varepsilon$ 时, $k \geq O(\log(\frac{1}{\varepsilon}))$



3 梯度下降法

3.1 如课件 (P16), 考虑 2 维 2 次函数优化问题:

$$\min_x f(x) = \frac{1}{2} (x_1^2 + \gamma x_2^2)$$

其中, $\gamma \geq 1$ 。当选取初始点 $x^0 = (\gamma, 1)$ 时, 试证明采用精准线搜索时, 有下式成立

$$\frac{\|x_k - x^*\|_2}{\|x_0 - x^*\|_2} = \left(\frac{\gamma - 1}{\gamma + 1} \right)^k$$

3.1 solution

梯度 $\nabla f(x) = (x_1, \gamma x_2)^T$

则 $\nabla f(x^0) = (\gamma, \gamma)^T$

令迭代方向 $d^k = -\nabla f(x^k)$

$$\begin{aligned} t_0 &= \arg \min_{t \geq 0} f(x^0 - t \nabla f(x^0)) \\ &= \arg \min_{t \geq 0} \left\{ t^2 \left(\frac{\gamma^3}{2} + \frac{\gamma^2}{2} \right) - 2\gamma^2 t + \frac{\gamma^2}{2} + \frac{\gamma}{2} \right\} \\ &= \frac{2}{1 + \gamma} \end{aligned}$$

则 $x^1 = -\frac{\gamma-1}{1+\gamma}(\gamma, -1)^T$

$$\begin{aligned} t_1 &= \arg \min_{t \geq 0} f(x^1 - t \nabla f(x^1)) \\ &= \arg \min_{t \geq 0} \left(\frac{\gamma-1}{\gamma+1} \right)^2 \left[t^2 \left(\frac{\gamma^3}{2} + \frac{\gamma^2}{2} \right) - 2\gamma^2 t + \frac{\gamma^2}{2} + \frac{\gamma}{2} \right] \\ &= \frac{2}{1 + \gamma} \end{aligned}$$

则 $x^2 = \left(\frac{\gamma-1}{\gamma+1} \right)^2 (\gamma, 1)^T$

同理得 $x^k = \left(\frac{\gamma-1}{\gamma+1} \right)^k (\gamma, -1)^T$

当 $k \rightarrow +\infty$ 时, $x^k \rightarrow (0, 0)^T$, 即 $x^* = (0, 0)^T$

$$\therefore \frac{\|x^k - x^*\|_2}{\|x^0 - x^*\|_2} = \frac{\|x^k\|_2}{\|x^0\|_2} = \left(\frac{\gamma - 1}{\gamma + 1} \right)^k$$

3.2 考虑教材 9.3.2 中的函数

$$f(x_1, x_2) = e^{x_1+3x_2-0.1} + e^{x_1-3x_2-0.1} + e^{-x_1-0.1}$$


1. 最优值 f^* 与最优解 x^* 分别是什么?
2. 利用回溯线搜索 ($\alpha = 0.1, \beta = 0.7$) 求解, 可设置初始点为 $x^0 = (0, 0)$ 。请画出 $f(x^k) - f^*$ 随着迭代次数 k 变化的图像 (semilogy 形式, 展示 30 次迭代就可以)。注意: 你可以利用 Matlab 或 Python 自行画图, 并将相关代码附在作业后面。

3.2 solution

1. 目标函数是可导的凸函数， $\mathbf{x}^*$ 是最小值的充分必要条件是

$$\nabla f(\mathbf{x}^*) = \begin{pmatrix} e^{x_1+3x_2-0.1} + e^{x_1-3x_2-0.1} - e^{-x_1-0.1} \\ 3e^{x_1+3x_2-0.1} - 3e^{x_1-3x_2-0.1} \end{pmatrix} = 0$$

第二个等式可以得到 $x_2 = 0$ ，再带入第一个等式 $x_1 = \frac{1}{2} \ln \frac{1}{2}$
那么最优的点为 $\mathbf{x}^* = (\frac{1}{2} \ln \frac{1}{2}, 0)^T$ ，最优值 $f^* = 2\sqrt{2}e^{-0.1}$ 2.



3.3(附加加分题) 假设函数是 f 是凸的且 L -光滑，试证明

$$(\nabla f(x) - \nabla f(y))^T (x - y) \geq \frac{1}{L} \|\nabla f(x) - \nabla f(y)\|_2^2$$

3.3 solution

$$\begin{aligned} f(y) - f(x) - \nabla f(x)^T (y - x) &= \phi_x(y) - \phi_x(x) \\ &\geq \frac{1}{2L} \|\nabla f(y) - \nabla f(x)\|^2 \end{aligned}$$

(课程链接中)

交换 x 、 y 得

$$\begin{aligned} f(x) - f(y) - \nabla f(y)^T (x - y) &= \phi_y(x) - \phi_y(y) \\ &\geq \frac{1}{2L} \|\nabla f(x) - \nabla f(y)\|^2 \end{aligned}$$

两式相加得

$$(\nabla f(x) - \nabla f(y))^T (x - y) \geq \frac{1}{L} \|\nabla f(x) - \nabla f(y)\|_2^2$$

3.4 证明课件梯度下降法课件 P34 中的定理。提示：

a 构建 $h(x) = f(x) - \frac{\mu}{2}x^Tx$ 。利用 **3.3** 证明如下性质：

$$(\nabla f(x) - \nabla f(y))^T(x - y) \geq \frac{\mu L}{\mu + L}\|x - y\|_2^2 + \frac{1}{\mu + L}\|\nabla f(x) - \nabla f(y)\|_2^2$$

b 开始证明定理，可以从下式开始

$$\|x^{k+1} - x^*\|_2^2 = \|(x^k - x^*) - t\nabla f(x^k)\|_2^2$$

3.4 solution

1. 我们首先证明 $h(x) = f(x) - \frac{\mu}{2}x^Tx$ 是凸函数并且是 $(L - \mu)$ -smooth.

$f(x)$ 是 μ -convex, 那么有

$$\begin{aligned} f(y) &\geq f(x) + \nabla f(x)^T(y - x) + \frac{\mu}{2}\|y - x\|_2^2 \\ \iff f(y) - \frac{\mu}{2}y^Ty &\geq f(x) - \frac{\mu}{2}x^Tx + \nabla f(x)^T(y - x) + \frac{\mu}{2}\|y - x\|_2^2 - \frac{\mu}{2}y^Ty + \frac{\mu}{2}x^Tx \\ \iff h(y) &\geq h(x) + \nabla f(x)^T(y - x) - \mu x^T(y - x) \\ \iff h(y) &\geq h(x) + (\nabla f(x) - \mu x)^T(y - x) \\ \iff h(y) &\geq h(x) + \nabla h(x)^T(y - x) \end{aligned}$$

这就证明了 $h(x)$ 是凸函数

下面证明 $h(x)$ 是 $(L - \mu)$ -smooth.

$f(x)$ 是 L -smooth, 那么有

$$\begin{aligned} f(y) &\leq f(x) + \nabla f(x)^T(y - x) + \frac{L}{2}\|y - x\|_2^2 \\ \iff f(y) - \frac{\mu}{2}y^Ty &\leq f(x) - \frac{\mu}{2}x^Tx + \nabla f(x)^T(y - x) + \frac{L}{2}\|y - x\|_2^2 - \frac{\mu}{2}y^Ty + \frac{\mu}{2}x^Tx \\ \iff h(y) &\leq h(x) + \nabla h(x)^T(y - x) + \mu x^T(y - x) + \frac{L}{2}\|y - x\|_2^2 - \frac{\mu}{2}(y^Ty + x^Tx - 2x^Ty) \\ \iff h(y) &\leq h(x) + \nabla h(x)^T(y - x) + \frac{L - \mu}{2}\|y - x\|_2^2 \end{aligned}$$

我们证明了 $h(x)$ 是 $(L - \mu)$ -smooth.

2. 我们利用 2.2 得到的不等式有：

$$\begin{aligned} (\nabla h(x) - \nabla h(y))^T(x - y) &\geq \frac{1}{L - \mu}\|\nabla h(x) - \nabla h(y)\|_2^2 \\ \iff (\nabla f(x) - \nabla f(y) - \mu(x - y))^T(x - y) &\geq \frac{1}{L - \mu}\|\nabla f(x) - \nabla f(y) - \mu(x - y)\|_2^2 \\ \iff \left(1 + \frac{2\mu}{L - \mu}\right)(\nabla f(x) - \nabla f(y))^T(x - y) &\geq \frac{1}{L - \mu}\|\nabla f(x) - \nabla f(y)\|_2^2 + \left(\mu + \frac{\mu^2}{L - \mu}\right)\|x - y\|_2^2 \\ \iff (\nabla f(x) - \nabla f(y))^T(x - y) &\geq \frac{1}{L + \mu}\|\nabla f(x) - \nabla f(y)\|_2^2 + \frac{\mu L}{L + \mu}\|x - y\|_2^2 \end{aligned}$$

3.

$$\begin{aligned}
\|x^{k+1} - x^*\|_2^2 &= \|x^k - x^* - t\nabla f(x^k)\|_2^2 \\
&= \|x^k - x^*\|_2^2 + t^2 \|\nabla f(x^k)\|_2^2 - 2t \nabla f(x^k)^T (x^k - x^*) \\
&\stackrel{2. \text{ inequality}}{\leq} \|x^k - x^*\|_2^2 + t^2 \|\nabla f(x^k)\|_2^2 - 2t (\nabla f(x^k) - \nabla f(x^*))^T (x^k - x^*) \\
&= \|x^k - x^*\|_2^2 + t^2 \|\nabla f(x^k)\|_2^2 - \frac{2t}{L + \mu} \|\nabla f(x^k)\|_2^2 - \frac{2\mu t}{L + \mu} \|x^k - x^*\|_2^2 \\
&= \left(1 - \frac{2\mu t}{L + \mu}\right) \|x^k - x^*\|_2^2 + \left(t^2 - \frac{2t}{L + \mu}\right) \|\nabla f(x^k)\|_2^2 \\
&\stackrel{0 < t < \frac{2}{L + \mu}}{\leq} \left(1 - \frac{2\mu t}{L + \mu}\right) \|x^k - x^*\|_2^2 \leq \left(1 - \frac{2\mu t}{L + \mu}\right)^2 \|x^{k-1} - x^*\|_2^2 \\
&\leq \left(1 - \frac{2\mu t}{L + \mu}\right)^k \|x^0 - x^*\|_2^2
\end{aligned}$$

我们得到 $\|x^k - x^*\|_2^2 \leq \left(1 - \frac{2\mu t}{L + \mu}\right)^k \|x^0 - x^*\|_2^2$

4 次梯度下降法

4.1 证明 $\partial f(x)$ 是凸集合。

4.1 solution

$$\partial f(x) = \{g \mid f(y) \geq f(x) + g^T(y - x), \forall y \in \mathbf{dom} f\}$$

令 $g_1, g_2 \in \partial f(x)$, 对于 $\theta \in [0, 1]$, 我们只需要证明 $\theta g_1 + (1 - \theta)g_2 \in \partial f(x)$
我们有

$$f(y) \geq f(x) + g_1^T(y - x), \forall y \in \mathbf{dom} f$$

$$f(y) \geq f(x) + g_2^T(y - x), \forall y \in \mathbf{dom} f$$

分别乘上 θ 、 $1 - \theta$ 相加得到

$$f(y) \geq f(x) + (\theta g_1 + (1 - \theta)g_2)^T (y - x), \forall y \in \mathbf{dom} f \implies \theta g_1 + (1 - \theta)g_2 \in \partial f(x)$$

这就证明了 $\partial f(x)$ 是凸集合