

《优化理论与算法》第 13 次作业

- 作业截止于**周五（6/12/2025）**，在 Canvas 系统中提交 PDF 或照片文件
- 作业题目的 tex 文件可以在 Canvas 中下载
- 鼓励相互讨论，但不要抄袭.

1 随机梯度下降法

1.1 比较所学随机优化方法各自的优势

1.1 solution

(1) AdaGrad 自适应梯度算法

属于经典自适应学习率算法，为每个参数独立维护历史梯度平方累积和，自动为不同参数分配差异化步长。对于稀疏特征维度会自动放大学习率，适配推荐系统、自然语言处理等存在大量稀疏数据的场景；算法逻辑简洁，无需过多人工调参。缺点为梯度平方持续累加，学习率会不断衰减，训练后期参数更新易陷入停滞。

(2) RMSProp

作为 AdaGrad 的改进算法，采用梯度平方指数滑动平均替代直接累积，限制历史梯度的权重，有效解决了 AdaGrad 学习率过度衰减、后期停滞的问题。参数更新更加平缓稳定，迭代震荡小，兼顾自适应学习率的优势与持续收敛能力，广泛应用于图像训练、生成模型等深度学习场景，鲁棒性优于 AdaGrad。

(3) Adam 自适应优化器

结合自适应步长与动量机制：利用梯度一阶矩加速迭代，二阶矩为每个参数单独设置学习率。超参数鲁棒性强，大幅减少人工调参工作量，兼顾收敛速度与稳定性，是高维优化、深度学习的主流算法。初期学习效果好。

(4) 批量梯度下降（BGD）

每一轮迭代使用全部样本计算完整梯度，梯度无随机噪声，迭代方向稳定。对于梯度 Lipschitz 连续的凸函数，收敛速率为 $O(1/k)$ ；对于强凸函数可实现线性收

敛，收敛精度高。算法对学习率鲁棒，调参简单，适合小数据集、内存充足且对求解精度要求高的场景。

(5) 标准随机梯度下降 (SGD, 单样本)

每次仅随机选取单个样本计算梯度，单次迭代计算复杂度为 $O(p)$ (p 为参数维度)，计算速度快、内存开销极小，适配大数据与在线流式学习。梯度自带随机噪声，具备隐式正则作用，可抑制过拟合。

(6) 小批量随机梯度下降 (Mini-batch SGD)

融合批量梯度下降与单样本 SGD 的优点：通过样本平均降低梯度方差，迭代震荡明显减弱；可充分利用 CPU/GPU 并行计算；能够灵活调整批次大小，在计算速度与迭代稳定性之间权衡，是工业界通用基准算法。

(7) SGD + 动量 (Momentum SGD)

引入历史梯度累积项模拟惯性效应，有效削弱迭代震荡、加速收敛；缓解目标函数平坦区域迭代缓慢的问题，迭代轨迹更平滑，整体性能优于原始 SGD。

(8) SGD + 方差缩减 (SAG / SAGA)

针对 SGD 梯度方差大、强凸问题无法线性收敛的缺陷设计。通过维护历史梯度表构造修正项，大幅降低梯度方差，且方差随迭代逐步衰减。

- SAG：凸函数收敛阶 $O(1/k)$ ，强凸函数实现线性收敛，计算量与 SGD 基本持平；
- SAGA：保留 SAG 全部优势，梯度为无偏估计，支持带非光滑正则的复合优化，步长鲁棒性更强。

1.2 常见的学习率调节方法有哪些

1.2 solution

- 固定学习率：实现简单，但后期可能围绕最优点震荡；
- 衰减学习率：后期更稳定；
- 分段衰减：训练到某些 epoch 后降低学习率；
- warmup：训练初期逐渐增大学习率，避免一开始更新过猛；
- cosine decay：深度学习中常用的平滑衰减策略。

1.3 问题构建：在二维平面中，考虑以下设定：

- 已知锚点位置： $\mathbf{a}_i \in \mathbb{R}^2, i = 1, \dots, m$;
- 未知节点位置： $\mathbf{x}_j \in \mathbb{R}^2, j = 1, \dots, n$ （待估计）。

我们可以获得带噪声的**平方距离**测量值 d_{ij} ，表示锚点 i 到未知节点 j 的平方距离测量（而非直接距离）。定义如下非线性最小二乘目标函数：

$$\min_{\mathbf{x}_1, \dots, \mathbf{x}_n} F(\mathbf{x}) = \sum_{i=1}^m \sum_{j=1}^n (\|\mathbf{a}_i - \mathbf{x}_j\|_2^2 - d_{ij})^2.$$

来求解未知节点的位置。

数据生成：

1. 参数设置

- 锚点数量： $m = 100$;
- 未知节点数量： $n = 50$;
- 坐标范围： $[0, 10] \times [0, 10]$;
- 噪声标准差： $\sigma = 0.1$;
- 随机种子固定（例如 42）以保证结果可重复。

2. 生成真实位置

- 锚点坐标 $\mathbf{a}_i$ ：在 $[0, 10]^2$ 内均匀随机生成。
- 未知节点真实坐标 $\mathbf{x}_j^{\text{true}}$ ：在 $[0, 10]^2$ 内均匀随机生成。


3. 计算带噪声的平方距离测量对于每一对 $(i, j), i = 1, \dots, m, j = 1, \dots, n$:

- 真实平方距离： $d_{ij}^{\text{true}} = \|\mathbf{a}_i - \mathbf{x}_j^{\text{true}}\|^2$;
- 测量值： $d_{ij} = d_{ij}^{\text{true}} + \epsilon_{ij}$ ，其中 $\epsilon_{ij} \sim \mathcal{N}(0, \sigma^2)$ 且相互独立。

测量值 d_{ij} 可能为负值（由于噪声），这在实际数据中是允许的，仅作为优化算法的输入。

输出要求：比较随机梯度下降法、随机梯度下降法 + 动量、随机梯度下降法 + 方差缩减，Adam 优化方法在该问题的求解效果。包含代码实现，绘制相关图像，总结观察等。

1.3 solution



上图是不同随机优化方法的目标函数下降比较、不同随机优化方法的位置估计误差比较

1. SGD 的目标函数下降具有波动性。
2. Momentum 利用历史方向平滑随机梯度，通常比普通 SGD 下降更快，但步长过大时可能振荡。
3. SVRG 通过周期性计算全梯度减少随机梯度方差，后期收敛更稳定，但每个 epoch 需要额外全梯度计算。
4. Adam 对不同坐标自适应调整步长，前期下降较快，对步长较不敏感，适合作为非线性最小二乘问题的强基准。

2 内点法

2.1 线性规划（标准型）的原始对偶中心路径是什么？

2.1 solution

线性规划标准形式：

$$\begin{cases} \min \mathbf{c}^T \mathbf{x} \\ s.t. \mathbf{A}\mathbf{x} = \mathbf{b}, \mathbf{x} \geq \mathbf{0} \end{cases}$$

对偶问题：

$$\begin{cases} \max \mathbf{b}^T \mathbf{y} \\ s.t. \mathbf{A}^T \mathbf{y} + \mathbf{s} = \mathbf{c}, \mathbf{s} \geq \mathbf{0} \end{cases}$$

其中 $\mathbf{s}$ 为对偶松弛变量。

引入障碍参数 $\mu > 0$, 原始对偶中心路径是满足如下扰动 KKT 系统的全体解 $(\mathbf{x}(\mu), \mathbf{y}(\mu), \mathbf{s}(\mu))$:

$$\begin{cases} A\mathbf{x} = \mathbf{b} \\ A^T\mathbf{y} + \mathbf{s} = \mathbf{c} \\ x_i s_i = \mu, \quad \forall i \\ \mathbf{x} > \mathbf{0}, \mathbf{s} > \mathbf{0} \end{cases}$$

当 $\mu \rightarrow 0^+$ 时, 中心路径收敛到原线性规划最优解。

2.2 考虑如下线性规划

$$\begin{aligned} \max \quad & 2x \\ \text{s.t.} \quad & x \leq 3 \\ & x \leq 5 \\ & x \geq 0 \end{aligned}$$

- (a) 给定障碍参数 $\mu = 1$, 写出原始对偶中心路径的形式。
- (b) 考虑原始对偶可行解 $x = 2$ 和 $y = (1, 2)$ 。求 a) 问对应的牛顿步。
- (c) 对比初始解 $x = 2, y = (1, 2)$ 的对偶间隙与一次牛顿迭代后的对偶间隙。

2.2 solution

原线性规划:

$$\begin{aligned} \max \quad & 2x \\ \text{s.t.} \quad & x \leq 3 \\ & x \leq 5 \\ & x \geq 0 \end{aligned}$$

- (a) 添加松弛变量, 写出障碍问题, $\mu = 1$ 求中心路径解
- 对不等式约束引入松弛变量 $z_1, z_2 > 0$, 转化为等式约束:

$$\begin{cases} x + z_1 = 3 \\ x + z_2 = 5 \\ x, z_1, z_2 > 0 \end{cases}$$

对数障碍最大化问题:

$$\begin{aligned} \max \quad & 2x + \mu \log x + \mu \log z_1 + \mu \log z_2 \\ \text{s.t.} \quad & x + z_1 = 3 \\ & x + z_2 = 5 \\ & x, z_1, z_2 > 0 \end{aligned}$$

构造拉格朗日函数

$$\mathcal{L} = 2x + \mu \log x + \mu \log z_1 + \mu \log z_2 - y_1(x + z_1 - 3) - y_2(x + z_2 - 5)$$

KKT 最优条件:

$$\begin{cases} x + z_1 = 3 \\ x + z_2 = 5 \\ x, z_1, z_2 > 0 \\ y_1 + y_2 - s_1 = 2 \\ y_1 - s_2 = 0 \\ y_2 - s_3 = 0 \\ \frac{1}{x}s_1 = 1 \\ \frac{\mu}{1}z_1s_2 = 1 \\ \frac{\mu}{1}z_2s_3 = 1 \end{cases}$$

代入 $\mu = 1$ 求解中心路径点:

$$x(1) = \frac{5}{2}, \quad z_1(1) = \frac{1}{2}, \quad z_2(1) = \frac{5}{2}$$

$$y_1(1) = 2, \quad y_2(1) = \frac{2}{5}$$

$$s_1(1) = \frac{2}{5}, \quad s_2(1) = 2, \quad s_3(1) = \frac{2}{5}$$

(b) 给定可行解 $\bar{x} = 2, \bar{z} = (1, 3), \bar{y} = (1, 2), \bar{s} = (1, 1, 2)$, 求原始对偶牛顿步牛顿方程组:

$$\begin{cases} \Delta x + \Delta z_1 = 0 \\ \Delta x + \Delta z_2 = 0 \\ \Delta y_1 + \Delta y_2 - \Delta s_1 = 0 \\ \Delta y_1 - \Delta s_2 = 0 \\ \Delta y_2 - \Delta s_3 = 0 \\ \bar{s}_1 \Delta x + \bar{x} \Delta s_1 = \mu - \bar{x} \bar{s}_1 \\ \bar{s}_2 \Delta z_1 + \bar{z}_1 \Delta s_2 = \mu - \bar{z}_1 \bar{s}_2 \\ \bar{s}_3 \Delta z_2 + \bar{z}_2 \Delta s_3 = \mu - \bar{z}_2 \bar{s}_3 \end{cases}$$

取 $\mu = 1$, 解得牛顿增量:

$$\Delta x = \frac{7}{13}, \quad \Delta z_1 = -\frac{7}{13}, \quad \Delta z_2 = -\frac{7}{13}$$

$$\Delta y_1 = \frac{7}{13}, \quad \Delta y_2 = -\frac{17}{13}$$

$$\Delta s_1 = -\frac{10}{13}, \quad \Delta s_2 = \frac{7}{13}, \quad \Delta s_3 = -\frac{17}{13}$$

(c) 完整牛顿步更新后的新解与对偶间隙对比

完整牛顿步（步长取 1）更新得到新解：

$$\begin{aligned} x &= \frac{33}{13}, & z_1 &= \frac{6}{13}, & z_2 &= \frac{32}{13} \\ y_1 &= \frac{20}{13}, & y_2 &= \frac{9}{13} \\ s_1 &= \frac{3}{13}, & s_2 &= \frac{20}{13}, & s_3 &= \frac{9}{13} \end{aligned}$$

对偶间隙计算：

- 初始解对偶间隙：

$$\text{gap}_0 = \bar{x}\bar{s}_1 + \bar{z}_1\bar{s}_2 + \bar{z}_2\bar{s}_3 = 2 \cdot 1 + 1 \cdot 1 + 3 \cdot 2 = 9$$

- 牛顿迭代后对偶间隙：

$$\text{gap}_1 = x s_1 + z_1 s_2 + z_2 s_3 = \frac{33}{13} \cdot \frac{3}{13} + \frac{6}{13} \cdot \frac{20}{13} + \frac{32}{13} \cdot \frac{9}{13} = \frac{507}{169} = 3$$

初始对偶间隙为 9，一次完整牛顿步后对偶间隙降至 3，对偶间隙显著减小。

2.3 比较单纯形法与内点法各自的优势

2.3 solution

2.3.1 单纯形法优势

1. 中小规模线性规划中实际运行速度快，迭代次数少；
2. 迭代始终在可行域**顶点**上进行，每一步中间解都是可行顶点，可直接使用；
3. 算法原理直观、实现简单，传统线性规划工程问题首选；
4. 输出**低秩稀疏解**，适合投资组合、图论等需要非零分量少的场景。

缺陷：最坏情况为指数时间复杂度，超高维大规模问题效率急剧下降。

2.3.2 内点法优势

1. 理论上为**多项式时间复杂度**，运行结果稳定，不受问题结构影响；
2. 迭代全程在可行域**内部**，不受顶点数量限制，擅长大规模、高维线性规划；
3. 通用性强，可直接拓展到凸非线性规划、半定规划、锥规划等更广泛的优化问题；
4. 输出**高秩解**，靠近可行域解析中心，适合联盟分配、图像重构、选址等场景。

缺陷：中小规模问题下，实际速度通常慢于单纯形法。