

上海财经大学

信息管理与工程学院

动量法与 Nesterov 加速

优化理论与算法

郭加熠

本讲主线

前面已经学习了梯度下降法、步长选择、光滑凸函数的 $\mathcal{O}(1/k)$ 收敛，以及强凸情形下与条件数相关的线性收敛。

本讲关注一个自然问题：

如果梯度下降在病态问题上很慢，能否用历史信息加速？

瓶颈

只看当前梯度，容易在狭长谷底中 zig-zag。

动量

利用上一轮位移方向，形成惯性。

加速

在前瞻点计算梯度，获得更好理论速率。

本章目录

为什么需要加速

Heavy-ball 动量法

Nesterov 加速与方法对比

目录

为什么需要加速

Heavy-ball 动量法

Nesterov 加速与方法对比

回顾：梯度下降与条件数

对 L -光滑函数，梯度下降法为

$$x^{k+1} = x^k - \alpha \nabla f(x^k).$$

若 f 进一步为 μ -强凸，取合适步长时有线性收敛：

$$f(x^k) - f^* \leq \left(1 - \frac{\mu}{L}\right)^k (f(x^0) - f^*).$$

定义 1.1: 条件数

$$\kappa = \frac{L}{\mu}.$$

它刻画目标函数在不同方向上的曲率差异。 κ 越大，水平集越狭长，普通梯度下降越慢。

问题：能否在不计算 Hessian 的情况下，让一阶方法对病态问题更不敏感？


GD 为什么会慢：病态二次函数

考虑二维二次函数

$$f(x_1, x_2) = \frac{1}{2}(x_1^2 + \kappa x_2^2), \quad \kappa \gg 1.$$

它的水平集是狭长椭圆。负梯度方向通常不指向最优点，而是近似垂直于当前水平集。

- ▶ 在陡峭方向上，步长太大容易振荡；
- ▶ 在平坦方向上，步长太小导致推进缓慢；
- ▶ 因而轨迹常出现 zig-zag。



加速的基本想法：利用历史信息

普通 GD 的更新只依赖当前位置的梯度：

$$x^{k+1} = x^k - \alpha \nabla f(x^k).$$

如果连续几步都朝着类似方向移动，那么上一轮的位移

$$x^k - x^{k-1}$$

也携带了有用信息。

核心思想

在负梯度方向之外，加入一部分历史位移方向，使算法在稳定方向上积累速度，在振荡方向上受到抑制。

这正是动量法和加速梯度法的出发点。

目录

为什么需要加速

Heavy-ball 动量法


Nesterov 加速与方法对比

Heavy-ball 方法的物理直觉

一维直线上，过去方向和当前负梯度方向往往同向，因此“惯性”容易被误解为只是把步子变大。更有解释力的场景是二维狭长谷底：

- ▶ 谷底方向：连续几步移动方向大致一致，动量会累积速度；
- ▶ 横向方向：轨迹在谷底两侧来回摆动，动量会部分抵消震荡；
- ▶ 因而 Heavy-ball 不是简单放大梯度，而是利用历史位移区分稳定前进方向和反复震荡方向。

GD: 横向来回摆动



$$\begin{aligned}x^{k+1} &= x^k - \alpha \nabla f(x^k) \\ &\quad + \beta(x^k - x^{k-1}).\end{aligned}$$

Heavy-ball 迭代公式

定义 2.1: Heavy-ball 动量法

给定步长 $\alpha > 0$ 与动量系数 $\beta \in [0, 1)$, Heavy-ball 方法为

$$x^{k+1} = x^k - \alpha \nabla f(x^k) + \beta(x^k - x^{k-1}).$$

等价地, 引入速度变量 $v^k = x^k - x^{k-1}$, 可写成

$$v^{k+1} = \beta v^k - \alpha \nabla f(x^k), \quad x^{k+1} = x^k + v^{k+1}.$$

- ▶ α : 控制当前梯度步的大小;
- ▶ β : 控制历史方向保留多少;
- ▶ $\beta = 0$ 时退化为普通梯度下降。

速度变量与历史梯度累积

由速度递推

$$\mathbf{v}^{k+1} = \beta \mathbf{v}^k - \alpha \mathbf{g}^k, \quad \mathbf{g}^k = \nabla f(\mathbf{x}^k),$$

若取 $\mathbf{v}^0 = 0$ ，逐步展开可得

$$\begin{aligned} \mathbf{v}^{k+1} &= -\alpha \mathbf{g}^k - \alpha \beta \mathbf{g}^{k-1} - \alpha \beta^2 \mathbf{g}^{k-2} - \dots - \alpha \beta^k \mathbf{g}^0 \\ &= -\alpha \sum_{j=0}^k \beta^j \mathbf{g}^{k-j}. \end{aligned}$$

含义

Heavy-ball 并不是只看当前梯度，而是在当前梯度之外叠加过去梯度的指数衰减平均。若某些方向的梯度长期一致，这些信息会累积；若某些方向频繁变号，则会相互抵消。

动量系数 β : 记忆有多长?

展开式中的权重为

$$1, \beta, \beta^2, \beta^3, \dots$$

因此 β 可以理解为算法的记忆长度。

β	记忆长度	典型现象
0	无记忆	退化为 GD
0.5	短记忆	较稳定, 加速有限
0.9	长记忆	机器学习中常见, 加速明显
接近 1	很长记忆	惯性强, 可能 overshoot

课堂提示: 调大 β 不一定总是更好; 它提高了沿稳定方向的速度, 也提高了冲过最优点的风险。

参数 α, β 的作用

步长 α

- ▶ 太小：推进慢；
- ▶ 合适：稳定下降；
- ▶ 太大：振荡甚至发散。

动量 β

- ▶ 太小：加速不明显；
- ▶ 合适：沿稳定方向加速；
- ▶ 太大：惯性过强，越过谷底。

参数选择	典型现象	课堂理解
α 小、 β 小	稳定但慢	接近 GD
α 合适、 β 合适	快速下降	利用历史方向
α 大或 β 大	震荡/发散	惯性过强

为什么动量会加速：特征方向视角

考虑强凸二次函数

$$f(x) = \frac{1}{2}x^\top Qx, \quad 0 < \mu I \preceq Q \preceq LI.$$

若 $Q = U\Lambda U^\top$ ，在特征坐标 $z = U^\top x$ 下，每个方向可以单独分析。

普通 GD 在第 i 个特征方向上满足

$$z_i^{k+1} = (1 - \alpha\lambda_i)z_i^k.$$

Heavy-ball 则满足二阶递推

$$z_i^{k+1} = (1 - \alpha\lambda_i + \beta)z_i^k - \beta z_i^{k-1}.$$

课堂解释

动量项让算法不只看当前位置，还看“过去怎么走”。平坦方向上的连续位移会被累积，陡峭方向上的来回摆动会被二阶递推调节。

收敛因子：从 κ 到 $\sqrt{\kappa}$

在二次函数的特征方向上，GD 的误差因子为

$$\max_{\lambda \in [\mu, L]} |1 - \alpha\lambda|.$$

令两端误差平衡：

$$1 - \alpha\mu = -(1 - \alpha L),$$

得到

$$\alpha_{\text{GD}} = \frac{2}{L + \mu}, \quad \rho_{\text{GD}} = \frac{L - \mu}{L + \mu} = \frac{\kappa - 1}{\kappa + 1}.$$

Heavy-ball 的每个特征方向是二阶递推。经典参数选择让区间 $[\mu, L]$ 上的特征根模长被统一压到

$$\rho_{\text{HB}} = \frac{\sqrt{L} - \sqrt{\mu}}{\sqrt{L} + \sqrt{\mu}} = \frac{\sqrt{\kappa} - 1}{\sqrt{\kappa} + 1}.$$

关键改进：病态程度从 κ 的量级变成 $\sqrt{\kappa}$ 的量级。

二次强凸问题上的推荐参数

对于特征值落在区间 $[\mu, L]$ 的二次问题，Heavy-ball 有一组经典参数：

$$\alpha_{\text{HB}} = \frac{4}{(\sqrt{L} + \sqrt{\mu})^2}, \quad \beta_{\text{HB}} = \left(\frac{\sqrt{L} - \sqrt{\mu}}{\sqrt{L} + \sqrt{\mu}} \right)^2.$$

此时收敛因子大致为

$$\rho_{\text{HB}} = \frac{\sqrt{\kappa} - 1}{\sqrt{\kappa} + 1}, \quad \kappa = \frac{L}{\mu}.$$

方法	典型收敛因子	条件数依赖
GD 最优常数步长	$\frac{\kappa - 1}{\kappa + 1}$	κ
Heavy-ball（二次情形）	$\frac{\sqrt{\kappa} - 1}{\sqrt{\kappa} + 1}$	$\sqrt{\kappa}$

注意：这组参数主要适用于强凸二次模型；一般非二次或非凸问题中， α, β 通常需要调参。

目录

为什么需要加速


Heavy-ball 动量法

Nesterov 加速与方法对比

Nesterov 加速的核心思想

Heavy-ball 在当前位置 x^k 计算梯度，再加上惯性项。Nesterov 的想法稍有不同：

先沿动量方向走到前瞻点，再在前瞻点计算梯度。



在“预计到达的位置”观察局部斜率

NAG 算法公式

一种常见的 Nesterov Accelerated Gradient (NAG) 形式为

$$y^k = x^k + \beta_k(x^k - x^{k-1}),$$

$$x^{k+1} = y^k - \alpha \nabla f(y^k).$$

与 Heavy-ball 的区别

Heavy-ball 使用 $\nabla f(x^k)$, 而 NAG 使用 $\nabla f(y^k)$ 。这个“前瞻梯度”会在理论上带来更好的加速性质。

对 L -光滑凸函数, 常取 $\alpha = 1/L$, 并配合特定的 β_k 序列, 可得到最优的一阶复杂度量级。

前瞻点为什么有用？

Heavy-ball 的梯度在当前位置计算：

$$x^{k+1} = x^k - \alpha \nabla f(x^k) + \beta(x^k - x^{k-1}).$$

如果动量把点带得太远，当前位置的梯度可能已经滞后。

NAG 先预测一个位置

$$y^k = x^k + \beta_k(x^k - x^{k-1}),$$

再在预测点修正：

$$x^{k+1} = y^k - \alpha \nabla f(y^k).$$

直觉

NAG 的前瞻梯度像是“提前看一眼前方坡度”。如果动量方向过猛， $\nabla f(y^k)$ 会更早给出纠偏信号。

NAG 的典型参数与收敛速度

对光滑凸函数，Nesterov 加速方法可达到

$$f(x^k) - f^* = \mathcal{O}\left(\frac{1}{k^2}\right),$$

相比 GD 的 $\mathcal{O}(1/k)$ 有数量级上的改进。

对 μ -强凸且 L -光滑的问题，常见参数可写成

$$\alpha = \frac{1}{L}, \quad \beta = \frac{\sqrt{L} - \sqrt{\mu}}{\sqrt{L} + \sqrt{\mu}} = \frac{\sqrt{\kappa} - 1}{\sqrt{\kappa} + 1}.$$

此时达到精度 ε 的迭代复杂度为

$$\mathcal{O}\left(\sqrt{\kappa} \log \frac{1}{\varepsilon}\right).$$

对比：NAG 和 Heavy-ball 都利用动量，但 NAG 在一般光滑凸优化中有更系统的理论保证。

收敛速度与方法对比

方法	是否用历史信息	梯度计算位置	光滑凸速率	特点
GD	否	x^k	$\mathcal{O}(1/k)$	简单稳定, 病态问题慢
Heavy-ball	是	x^k	依赖问题与参数	实践中常加速, 但参数敏感
NAG	是	前瞻点 y^k	$\mathcal{O}(1/k^2)$	理论保证强, 是经典加速方法

强凸光滑情形下, 普通 GD 的复杂度通常依赖 $\kappa = L/\mu$, 而加速方法可改善到依赖 $\sqrt{\kappa}$ 的量级:

$$\text{GD: } \mathcal{O}\left(\kappa \log \frac{1}{\varepsilon}\right), \quad \text{加速方法: } \mathcal{O}\left(\sqrt{\kappa} \log \frac{1}{\varepsilon}\right).$$

发展历史：两条重要线索

Heavy-ball

- ▶ 由 Polyak 在 1964 年提出；
- ▶ 灵感来自带惯性的物理系统；
- ▶ 在强凸二次问题上具有清晰的加速效果；
- ▶ 后来影响了 SGD with momentum 等方法。

Nesterov 加速

- ▶ 由 Nesterov 在 1983 年提出；
- ▶ 是一阶凸优化复杂度理论中的经典结果；
- ▶ 给出光滑凸情形的 $\mathcal{O}(1/k^2)$ 速率；
- ▶ 后来发展出 FISTA 等近端加速算法。

课堂定位：Heavy-ball 更像物理直觉驱动的动量法；NAG 更像复杂度理论驱动的最优一阶方法。

应用场景：今天在哪里会用到？

Heavy-ball / Momentum

- ▶ 深度学习中的 SGD with momentum;
- ▶ 大规模经验风险最小化;
- ▶ 病态二次近似问题;
- ▶ 工程计算中的迭代求解。

NAG / 加速梯度

- ▶ 光滑凸优化的一阶基准算法;
- ▶ 稀疏学习与 Lasso 的 FISTA;
- ▶ 图像重建、压缩感知等反问题;
- ▶ 现代加速一阶方法的理论基础。

实践提醒

在真实问题中，动量常常能显著加快训练；但它也会放大不稳定性，因此通常需要学习率衰减、重启、归一化或自适应步长配合。

案例一：工程计算中的线性方程组

背景：结构力学、热传导、电路网络和有限元离散中，经常需要求解大型对称正定线性方程组

$$Ax = b, \quad A \succ 0.$$

直接分解 A 在大规模问题中可能代价很高，因此常使用迭代方法。

等价优化问题：

$$\min_x f(x) = \frac{1}{2}x^\top Ax - b^\top x.$$

因为

$$\nabla f(x) = Ax - b,$$

所以

$$\nabla f(x) = 0 \iff Ax = b.$$

课堂实验目标：比较直接解 $x_{\text{direct}} = A^{-1}b$ 与 GD / Heavy-ball / NAG 迭代所得解是否一致。

案例一：实验步骤与观察指标

实验步骤：

1. 构造病态对称正定矩阵 $A = Q^\top D Q$ ，其中 $D = \text{diag}(1, \dots, \kappa)$ ；
2. 随机生成真实解 x_{true} ，令 $b = Ax_{\text{true}}$ ；
3. 直接求解 $Ax = b$ ，得到 x_{direct} ；
4. 最小化 $f(x) = \frac{1}{2}x^\top Ax - b^\top x$ ，分别运行 GD、Heavy-ball、NAG；
5. 比较最终解与直接解的误差。

观察指标：

$$\frac{\|Ax^k - b\|}{\|b\|}, \quad f(x^k) - f(x_{\text{direct}}), \quad \|x^k - x_{\text{direct}}\|.$$

预期现象：三种迭代法收敛到同一个 x_{direct} ，但 Heavy-ball 与 NAG 通常需要更少迭代。

案例二：图像模糊、加噪与恢复

背景：图像采集过程中常出现模糊和噪声。设真实图像为 x_{true} ，观测图像为

$$y = Kx_{\text{true}} + \eta,$$

其中 K 是模糊算子（如高斯模糊）， η 是高斯噪声。目标是从退化图像 y 恢复清晰图像 x 。

优化模型：

$$\min_x \frac{1}{2} \|Kx - y\|^2 + \frac{\lambda}{2} (\|D_x x\|^2 + \|D_y x\|^2).$$

其中 D_x, D_y 是水平和垂直方向的离散差分算子。第二项不是优化变量的梯度，而是图像空间中相邻像素差的平方和：

$$\|D_x x\|^2 + \|D_y x\|^2 = \sum_{i,j} (x_{i,j} - x_{i,j-1})^2 + \sum_{i,j} (x_{i,j} - x_{i-1,j})^2.$$

目标函数梯度：

$$\nabla f(x) = K^\top (Kx - y) + \lambda (D_x^\top D_x + D_y^\top D_y)x = K^\top (Kx - y) + \lambda Lx,$$

其中 L 是离散 Laplacian 算子。

案例二：实验步骤与恢复效果

实验分两步：

1. 生成退化图像：构造合成灰度图 $\mathbf{x}_{\text{true}}$ ，先做高斯模糊 $K\mathbf{x}_{\text{true}}$ ，再加入不同强度高斯噪声 $\sigma = 0.05, 0.15, 0.30$.
2. 优化恢复图像：固定一个噪声水平，分别用 GD、Heavy-ball、NAG 求解正则化去卷积模型。

展示内容：

- ▶ 原图、模糊加噪图、三种算法恢复图；
- ▶ 目标函数下降曲线；
- ▶ 恢复误差：

$$\text{MSE} = \frac{1}{n} \|\mathbf{x} - \mathbf{x}_{\text{true}}\|^2, \quad \text{PSNR} = 10 \log_{10} \frac{1}{\text{MSE}}.$$

课堂提醒：这里的正则项会抑制噪声，但也会平滑边缘；恢复效果取决于模型和参数，而不仅是算法。

方法选择与实际注意事项

什么时候有帮助？

- ▶ 目标函数光滑；
- ▶ 条件数较大；
- ▶ 普通 GD 出现慢速 zig-zag；
- ▶ 梯度计算成本相对可控。

需要注意什么？

- ▶ 参数选择更敏感；
- ▶ 非凸问题中可能更容易震荡；
- ▶ 需要结合线搜索、重启或自适应策略。

课堂直觉：加速方法不是改变梯度本身，而是改变“如何使用梯度历史”。它在许多问题上显著加快下降，但也要求更谨慎地控制步长与动量。

本讲小结

- ▶ 普通梯度下降只利用当前梯度，在病态问题上会受到条件数影响，容易沿狭长谷底缓慢前进。
- ▶ Heavy-ball 方法加入动量项 $\beta(x^k - x^{k-1})$ ，利用历史位移方向形成惯性。
- ▶ Nesterov 加速方法在前瞻点 y^k 计算梯度，具有更好的理论收敛速度。
- ▶ 光滑凸情形下，GD 为 $\mathcal{O}(1/k)$ ，NAG 可达到 $\mathcal{O}(1/k^2)$ 。
- ▶ 强凸光滑情形下，加速方法将条件数依赖从 κ 改善到 $\sqrt{\kappa}$ 的量级。

下一讲

牛顿法：不再只用一阶梯度，而是利用 Hessian 曲率信息构造更好的搜索方向。