

优化理论与算法

第八章 次梯度下降法

郭加熠 | 助理教授



目录

次梯度的定义

次梯度方法

讲 员

郭加熠，江波，刘慧康

线性回归模型

- 考虑岭回归模型:

$$\min_{x \in \mathbb{R}^n} \|Ax - b\|_2^2 + \lambda \|x\|_2^2.$$

最优解为

$$x^* = (A^T A + \lambda I)^{-1} A^T b.$$

- 问题: LASSO 问题的最优性条件是什么?

$$\min_{x \in \mathbb{R}^n} \|Ax - b\|_2^2 + \lambda \|x\|_1.$$

次梯度


回忆凸可微函数的一阶条件:

$$f(y) \geq f(x) + \nabla f(x)^T(y - x), \forall x, y.$$

定义. 对于凸函数 f , 若满足:

$$f(y) \geq f(x) + g^T(y - x), \forall y.$$

则称 g 是 f 在 x 处的**次梯度** (subgradient)。



g_2, g_3 are subgradients at x_2 ; g_1 is a subgradient at x_1

次微分

f 在 x 处的**次微分** $\partial f(x)$ 是所有次梯度的集合:



$$\partial f(x) = \{g \mid f(y) \geq f(x) + g^T(y - x), \forall y \in \text{dom}(f)\}$$

- ▶ $\partial f(x)$ 是闭凸集 (可能为空)
- ▶ 若 f 在 x 处可微, 则 $\partial f(x) = \{\nabla f(x)\}$ (或写作 $\partial f(x) = \nabla f(x)$)
- ▶ 若 $f(x)$ 是凸函数且定义域为开集, 则 $\partial f(x)$ 在 $\text{dom}(f)$ 上非空且有界

示例

绝对值函数 $f(x) = |x|$:

$$\partial f(x) = \begin{cases} 1, & \text{若 } x > 0 \\ [-1, 1], & \text{若 } x = 0 \\ -1, & \text{若 } x < 0 \end{cases}$$



欧几里得范数 $f(x) = \|x\|_2$:

$$\partial f(x) = \begin{cases} \frac{x}{\|x\|_2}, & \text{若 } x \neq 0 \\ \{g \mid \|g\|_2 \leq 1\}, & \text{若 } x = 0. \end{cases}$$

基本规则：缩放与加法

- **缩放:** $\partial(tf) = t\partial f$ 当 $t > 0$, 例如:

$$\partial(2|x|) = 2\partial(|x|), \quad \partial(2\|x\|_1) = 2\partial(\|x\|_1)$$

- **加法:** $\partial(f_1 + f_2) = \partial f_1 + \partial f_2$, 例如:

$$\partial \left(\frac{1}{2} \|Ax - b\|_2^2 + \lambda \|x\|_1 \right) = A^T (Ax - b) + \lambda \partial \|x\|_1$$

此外可以证明:

$$g \in \partial(\|x\|_1) \text{ 当且仅当 } g_i \in \partial(|x_i|)$$

基本规则：逐点最大值

逐点最大值：若 $f = \max_{i=1,\dots,m} f_i(x)$ ，则

$$\partial f(x) = \text{Conv} \left(\bigcup \{ \partial f_i(x) \mid f_i(x) = f(x) \} \right),$$

即在 x 处激活函数的次微分集合的凸包，例如：

► $|x| = \max\{x, -x\}$ ，则

$$\partial|x| \mid_{x=0} = \text{Conv}\{-1, 1\} = [-1, 1]$$

► $\|x\|_2 = \max_{\|g\|_2=1} \{g^T x\}$ ，则

$$\partial\|x\|_2 \mid_{x=0} = \text{Conv}(\{g \mid \|g\|_2 = 1\}) = \{g \mid \|g\|_2 \leq 1\}$$

正式证明可参考 "Ruszczynski, Andrzej. *Nonlinear Optimization*. Princeton University Press, Princeton, New Jersey, 2006"


无约束问题的最优性条件

定理: 设 $f(x)$ 是凸且不可微函数, 则 x^* 是最优解当且仅当

$$0 \in \partial f(x^*).$$

证明.

- ▶ $(\Rightarrow)$: $f(x) \geq f(x^*)$ 推导出 $0 \in \partial f(x^*)$
- ▶ $(\Leftarrow)$: $f(x) \geq f(x^*) + g^T(x - x^*)$ 取 $g = 0$



应用实例

考虑 LASSO 问题:

$$\min_{x \in \mathbb{R}^n} \frac{1}{2} \|b - Ax\|_2^2 + \lambda \|x\|_1.$$

其最优性条件为

$$0 \in A^T(Ax^* - b) + \lambda \partial \|x^*\|_1$$

当 $A = I$ 时, 最优性条件简化为

$$0 \in x^* - b + \lambda \partial \|x^*\|_1$$

此时最优解为

$$x_i^* = \begin{cases} b_i - \lambda & \text{若 } b_i > \lambda \\ 0 & \text{若 } |b_i| \leq \lambda \\ b_i + \lambda & \text{若 } b_i < -\lambda. \end{cases}$$

目录

次梯度的定义

次梯度方法

讲 员

郭加熠，江波，刘慧康

次梯度方法

考虑不可微凸函数 f 的极小化问题:

$$\min_{x \in \mathbb{R}^n} f(x)$$

次梯度方法:

$$x^{k+1} = x^k - t_k g^k \quad \text{其中 } g^k \in \partial f(x^k)$$

- ▶ 固定步长: t_k 较小
- ▶ 递减步长: $t_k \rightarrow 0, \sum_{k=1}^{\infty} t_k = \infty$

示例

使用次梯度方法求解以下一维极小化问题：

$$\min_{x \in \mathbb{R}} |x|.$$

假设 $x^0 = 1$ ，若选择：

- **固定步长**：例如 $t_k = 0.7$ ，则迭代序列为

$$x^1 = x^3 = \cdots = 0.3, \quad x^2 = x^4 = \cdots = -0.4.$$

序列可能不收敛到最优解

- **递减步长**：例如 $t_k = \frac{1}{k+1} + \frac{1}{k+2}$ ，则可证明

$$x^k = \frac{(-1)^k}{k+1}.$$

序列将收敛到最优解

示例：分段线性函数极小化

极小化以下分段线性函数：

$$\min f(x) := \max_{i=1,\dots,m} a_i^T x + b_i$$

在 x^k 处的次梯度： $g^k = a_i$ (其中 $i \in I$)，这里 I 是激活集


$$I = \{j : a_j^T x + b_j = \max_{i=1,\dots,m} a_i^T x + b_i\}$$

次梯度方法：


$$x^{k+1} = x^k - t_k g^k$$

问题实例： $n = 20$ 个变量， $m = 100$ ， $f^* \approx 1.1$

图示展示了 $f_{bs}^k - f^*$ 随迭代次数变化，固定步长 $\gamma = 0.05, 0.01, 0.005$



递减步长规则



收敛性分析：固定步长

定理： 设 $f(x)$ 是凸函数且对所有 $g \in \partial f$ 有 $\|g\| \leq G$ ，则固定步长 t 的次梯度下降法满足：

$$f_{bs}^k - f^* \leq \frac{R^2 + G^2 kt^2}{2kt} = \frac{R^2}{2kt} + \frac{G^2 t}{2}$$

其中 $f_{bs}^k = \min_{i=0, \dots, k-1} f(x^i)$, $R = \|x^0 - x^*\|_2$ 。

- ▶ 右端收敛到 $G^2 t/2$
- ▶ 不保证收敛到最优解
- ▶ 若总迭代次数 K 已知，选择 $t = \frac{R}{G\sqrt{K}}$ ，复杂度为 $O(\frac{1}{\sqrt{K}})$

证明

$$\begin{aligned}\|x^{i+1} - x^*\|_2^2 &= \|x^i - t_i g^i - x^*\|_2^2 \\&= \|x^i - x^*\|_2^2 - 2t_i (g^i)^T (x^i - x^*) + t_i^2 \|g^i\|_2^2 \\&\leq \|x^i - x^*\|_2^2 - 2t_i (f(x^i) - f^*) + t_i^2 \|g^i\|_2^2\end{aligned}$$

故有 $2t_i(f(x^i) - f^*) \leq \|x^i - x^*\|_2^2 - \|x^{i+1} - x^*\|_2^2 + t_i^2 \|g^i\|_2^2$.

累加不等式 $i = 0$ 到 $k - 1$ 并错位相消, 定义 $f_{bs}^k = \min_{i=0, \dots, k-1} f(x^i)$:

$$\begin{aligned}2 \sum_{i=0}^{k-1} t_i (f_{bs} - f^*) &\leq \|x^0 - x^*\|_2^2 - \|x^k - x^*\|_2^2 + \sum_{i=0}^{k-1} t_i^2 \|g^i\|_2^2 \\&\leq \|x^0 - x^*\|_2^2 + \sum_{i=0}^{k-1} t_i^2 \|g^i\|_2^2\end{aligned}$$

收敛性分析：递减步长

定理: 设 $f(x)$ 是凸函数且对所有 $g \in \partial f$ 有 $\|g\| \leq G$, 则次梯度下降法满足:

$$f_{bs}^k - f^* \leq \frac{R^2 + G^2 \sum_{i=0}^{k-1} t_i^2}{2 \sum_{i=0}^{k-1} t_i}$$

其中 $f_{bs}^k = \min_{i=0, \dots, k-1} f(x^i)$, $R = \|x^0 - x^*\|_2$ 。

- ▶ 非可和递减步长: $t_k \rightarrow 0$, $\sum_{i=0}^{\infty} t_i = \infty$ 保证收敛到最优解
- ▶ 若取 $t_k = \frac{R}{G\sqrt{k}}$, 迭代复杂度为 $O(\frac{RG \log(k)}{\sqrt{k}})$

证明

根据 (P18) 中的推导可得如下不等式:

$$f_{bs}^k - f^* \leq \frac{R^2 + G^2 \sum_{i=0}^{k-1} t_i^2}{2 \sum_{i=0}^{k-1} t_i}$$

- ▶ 对任意 $\epsilon > 0$, 存在 N_1 使得当 $i > N_1$ 时 $t_i < \epsilon/G^2$
- ▶ 存在 N_2 使得 $\sum_{i=0}^{N_2} t_i \geq \frac{1}{\epsilon} \left(R^2 + G^2 \sum_{i=0}^{N_1} t_i^2 \right)$
- ▶ 则对 $k \geq \max\{N_1, N_2\}$, 有

$$\frac{R^2 + G^2 \sum_{i=0}^{k-1} t_i^2}{2 \sum_{i=0}^{k-1} t_i} = \frac{R^2 + G^2 \sum_{i=0}^{N_1} t_i^2}{2 \sum_{i=0}^{k-1} t_i} + \frac{G^2 \sum_{i=N_1+1}^{k-1} t_i^2}{2 \sum_{i=0}^{k-1} t_i} \leq \epsilon$$

当 f^* 已知时的最优步长（应用于可行性问题）

Polyak 步长:

$$t_k = \frac{f(x^k) - f^*}{\|g^k\|_2^2}$$

该步长的由来是最小化不等式的右端项:

$$\|x^{k+1} - x^*\|_2^2 \leq \|x^k - x^*\|_2^2 - 2t_k(f(x^k) - f^*) + t_k^2 \|g^k\|_2^2$$

代入 t_k 得:

$$\|x^{k+1} - x^*\|_2^2 \leq \|x^k - x^*\|_2^2 - \frac{(f(x^k) - f^*)^2}{\|g^k\|_2^2}$$

递归应用可得:

$$f_{bs}^k - f^* \leq GR/\sqrt{k}$$

Polyak 步长的性能

