

数值计算方法

向量范数和矩阵范数

信息管理与工程学院
冯银波

为什么要引入“范数”的概念

- 数值计算过程中，经常需要讨论：
 - ✓ “参数的扰动”对计算结果的影响（判断是否病态）
 - ✓ 由误差导致的“计算解”和“精确解”之间的差距有多大（是否数值稳定）
- “模型的参数”和“计算结果”通常为向量或矩阵。为了讨论上述问题，就必须引入一个衡量两个向量/矩阵之间差距大小的标准
 - ✓ 什么叫“计算解和精确解离得近”？
 - ✓ 什么叫“参数矩阵的微小波动”？

欧氏空间中的向量范数

范数最简单的例子是绝对值函数, 即 $|x|$ 。绝对值函数满足三条性质:

- (1) $|x| \geq 0, \forall x; |x| = 0$ 当且仅当 $x = 0$;
- (2) $|ax| = |a| \cdot |x|, a$ 为常数;
- (3) $|x + y| \leq |x| + |y|, \forall x, y$.

绝对值函数衡量的是一维实数空间中的欧氏长度。二维实数空间中向量 $x = (x_1, x_2)$ 的欧氏长度为 $\|x\| = \sqrt{x_1^2 + x_2^2}$ 。它同样满足三条性质:

- (1) $\|x\| \geq 0, \forall x; \|x\| = 0$ 当且仅当 $x = 0$;
- (2) $\|ax\| = |a| \cdot \|x\|, a$ 为常数;
- (3) $\|x + y\| \leq \|x\| + \|y\|, \forall x, y$. (三角形的两边之和大于第三边)

n 维实数空间中的欧氏长度同样满足这三条性质。

n 维复数空间中的向量的模同样满足这三条性质。

一般的向量范数

定义：一个从 $\mathbf{R}^n$ 到 $\mathbf{R}$ 的非负函数 $\|\cdot\|$ 叫做 $\mathbf{R}^n$ 上的向量范数，如果它满足：

- (1) **正定性：** $\|x\| \geq 0, \forall x; \|x\| = 0$ 当且仅当 $x = 0$;
- (2) **齐次性：** $\|ax\| = |a| \cdot \|x\|$, a 为常数;
- (3) **三角不等式：** $\|x + y\| \leq \|x\| + \|y\|, \forall x, y$.

根据范数的定义，可得一些其他性质：

- (4) $\|0\| = 0$;
- (5) $\|-x\| = \|x\|$;
- (6) $|\|x\| - \|y\|| \leq \|x - y\|, \forall x, y$.

请自行证明(6)。

由 $|\|x\| - \|y\|| \leq \|x - y\| \leq \max_{1 \leq i \leq n} \|e_i\| \cdot \sum_{i=1}^n |x_i - y_i|$ 可知， $\|\cdot\|$ 是 $\mathbf{R}^n$ 到 $\mathbf{R}$ 的连续函数。



x 和 y 的每个分量在一维欧氏距离下离得近，那么 x 和 y 在一般范数下离得也近

常用的向量范数

最常用的向量范数是 p 范数：

$$\|x\|_p = (|x_1|^p + \cdots + |x_n|^p)^{\frac{1}{p}}, p \geq 1.$$

其中， $p = 1, 2, \infty$ 三种情形是最常见的：

$$\|x\|_1 = |x_1| + \cdots + |x_n|,$$

$$\|x\|_2 = (|x_1|^2 + \cdots + |x_n|^2)^{\frac{1}{2}},$$

$$\|x\|_\infty = \max\{|x_i| : i = 1, \cdots, n\},$$

它们分别叫做1范数，2范数和 ∞ 范数。

请验证这三种范数（以及一般的 p 范数）满足范数定义中的三个条件。

下面，只证明 $\|\cdot\|_p$ 满足三角不等式，其它性质都容易验证。

一些重要的不等式

Young不等式：设 $a \geq 0, b \geq 0, p > 1, q > 1, \frac{1}{p} + \frac{1}{q} = 1$ ，则 $ab \leq \frac{a^p}{p} + \frac{b^q}{q}$ 。

证：仅考虑 $a > 0, b > 0$

此时由泰勒公式可知

$$\begin{aligned}\ln ab &= \ln a + \ln b \\&= \frac{1}{p} \ln a^p + \frac{1}{q} \ln b^q \quad \text{令 } x_0 = \frac{a^p}{p} + \frac{b^q}{q} \\&= \frac{1}{p} \left(\ln x_0 + \frac{1}{x_0} (a^p - x_0) - \frac{1}{\eta_1^2} (a^p - x_0)^2 \right) + \frac{1}{q} \left(\ln x_0 + \frac{1}{x_0} (b^q - x_0) - \frac{1}{\eta_2^2} (b^q - x_0)^2 \right) \\&\leq \left(\frac{1}{p} + \frac{1}{q} \right) \ln x_0 + \frac{1}{x_0} \left(\frac{a^p}{p} + \frac{b^q}{q} - \left(\frac{1}{p} + \frac{1}{q} \right) x_0 \right) \\&= \ln x_0 + \frac{1}{x_0} (x_0 - x_0) \\&= \ln \left(\frac{a^p}{p} + \frac{b^q}{q} \right)\end{aligned}$$

一些重要的不等式

Hölder不等式：设 $a, b \in R^n, p > 1, q > 1, \frac{1}{p} + \frac{1}{q} = 1$ ，则 $|a^T b| \leq \|a\|_p \cdot \|b\|_q$ ，

或

$$\sum_{k=1}^n |a_k b_k| \leq \left(\sum_{k=1}^n |a_k|^p \right)^{\frac{1}{p}} \cdot \left(\sum_{k=1}^n |b_k|^q \right)^{\frac{1}{q}}.$$

证明：不妨设 $a, b \neq 0$ ，由Young不等式知

$$\begin{aligned} \sum_{k=1}^n \frac{|a_k| |b_k|}{\left(\sum_{j=1}^n |a_j|^p \right)^{\frac{1}{p}} \left(\sum_{j=1}^n |b_j|^q \right)^{\frac{1}{q}}} &= \sum_{k=1}^n \frac{|a_k|}{\left(\sum_{j=1}^n |a_j|^p \right)^{\frac{1}{p}}} \cdot \frac{|b_k|}{\left(\sum_{j=1}^n |b_j|^q \right)^{\frac{1}{q}}} \\ &\leq \sum_{k=1}^n \left(\frac{1}{p} \left(\frac{|a_k|}{\left(\sum_{j=1}^n |a_j|^p \right)^{\frac{1}{p}}} \right)^p + \frac{1}{q} \left(\frac{|b_k|}{\left(\sum_{j=1}^n |b_j|^q \right)^{\frac{1}{q}}} \right)^q \right) \\ &\leq \frac{1}{p} + \frac{1}{q} = 1 \end{aligned}$$

一些重要的不等式

Minkovski不等式: 设 $a, b \in R^n, p > 1$, 则 $\|a + b\|_p \leq \|a\|_p + \|b\|_p$.

证明: 取 q 使得 $\frac{1}{p} + \frac{1}{q} = 1$, 于是 $p = (p-1)q$.

因为 $|a_k + b_k|^p = |a_k + b_k| |a_k + b_k|^{p-1} \leq |a_k| |a_k + b_k|^{p-1} + |b_k| |a_k + b_k|^{p-1}$,

所以, 由 Hölder 不等式知,

$$\begin{aligned} \sum_{k=1}^n |a_k + b_k|^p &\leq \sum_{k=1}^n (|a_k| |a_k + b_k|^{p-1} + |b_k| |a_k + b_k|^{p-1}) \\ &= \sum_{k=1}^n (|a_k| |a_k + b_k|^{p-1}) + \sum_{k=1}^n (|b_k| |a_k + b_k|^{p-1}) \\ &\leq \left(\sum_{k=1}^n |a_k|^p \right)^{\frac{1}{p}} \left(\sum_{k=1}^n |a_k + b_k|^{(p-1)q} \right)^{\frac{1}{q}} + \left(\sum_{k=1}^n |b_k|^p \right)^{\frac{1}{p}} \left(\sum_{k=1}^n |a_k + b_k|^{(p-1)q} \right)^{\frac{1}{q}} \\ &\leq \left(\left(\sum_{k=1}^n |a_k|^p \right)^{\frac{1}{p}} + \left(\sum_{k=1}^n |b_k|^p \right)^{\frac{1}{p}} \right) \left(\sum_{k=1}^n |a_k + b_k|^p \right)^{\frac{1}{q}} \end{aligned}$$

一些重要的不等式

Cauchy-Schwartz不等式：设 $a, b \in R^n$ ，则 $|a^T b| \leq \|a\|_2 \cdot \|b\|_2$ ，

请自行用Cauchy-Schwartz不等式证明 $\|a + b\|_2 \leq \|a\|_2 + \|b\|_2$ 。

向量范数之间并不一致

举例说明存在以下情形：

$$\|x\|_1 \leq \|y\|_1, \quad \|x\|_2 \geq \|y\|_2$$

向量范数的等价性

定理：在 R^n 上定义的任一向量范数 $\|\cdot\|$ 都与1范数 $\|\cdot\|_1$ 等价，即存在正数 M 与 m ($M > m$)，使得对一切 $x \in R^n$ 都有

$$m\|x\|_1 \leq \|x\| \leq M\|x\|_1.$$

证明：令 $G = \{x \in R^n: \|x\|_1 = 1\}$ 。 G 是有界闭集。因为 $\|\cdot\|$ 是连续函数，故存在正数 M 与 m ($M > m$)，使得对一切 $x \in G$ 都有

$$m \leq \|x\| \leq M.$$

因为对任意的 $x \in R^n$ ，有 $\frac{x}{\|x\|_1} \in G$ ，所以

$$m \leq \left\| \frac{x}{\|x\|_1} \right\| \leq M,$$

即

$$m\|x\|_1 \leq \|x\| \leq M\|x\|_1.$$

向量范数的等价性

推论： R^n 上定义的任意两个范数 $\|x\|_\alpha$ 与 $\|x\|_\beta$ 等价, 即存在正数 M 与 m ($M > m$), 使得对一切 $x \in R^n$ 都有

$$m\|x\|_\alpha \leq \|x\|_\beta \leq M\|x\|_\alpha.$$

对于常用范数, 容易验证下列不等式:

$$\|x\|_2 \leq \|x\|_1 \leq \sqrt{n}\|x\|_2,$$

$$\|x\|_\infty \leq \|x\|_2 \leq \sqrt{n}\|x\|_\infty,$$

$$\|x\|_\infty \leq \|x\|_1 \leq n\|x\|_\infty.$$

向量范数的收敛性

有了范数的概念，我们就可以讨论向量序列的收敛性问题。

定义： 给定 R^n 上的向量序列 $\{x^{(k)}\}$ ，若对 $i = 1, 2, \dots, n$ 都有

$$\lim_{k \rightarrow \infty} |x_i^{(k)} - x_i|,$$

则称向量序列 $\{x^{(k)}\}$ 依坐标收敛于 $x = (x_1, \dots, x_n)$ 。

定义： 给定 R^n 上的向量序列 $\{x^{(k)}\}$ 以及范数 $\|\cdot\|$ ，如果

$$\lim_{k \rightarrow \infty} \|x^{(k)} - x\| = 0,$$

则称向量序列 $\{x^{(k)}\}$ 依范数收敛于 x 。

定理： R^n 上的向量序列依范数收敛与依坐标收敛是等价的。

矩阵范数

定义：一个从 $\mathbf{R}^{n \times n}$ 到 $\mathbf{R}$ 的非负函数 $\|\cdot\|$ 叫做 $\mathbf{R}^{n \times n}$ 上的矩阵范数，如果它满足：

- (1) **正定性：** $\|A\| \geq 0, \forall A$; $\|A\| = 0$ 当且仅当 $A = 0$;
- (2) **齐次性：** $\|aA\| = |a| \cdot \|A\|$, a 为常数;
- (3) **三角不等式：** $\|A + B\| \leq \|A\| + \|B\|, \forall A, B$;
- (4) **相容性：** $\|AB\| \leq \|A\| \cdot \|B\|, \forall A, B$.

矩阵范数的前三个条件和向量范数的三个条件一样，这是因为矩阵本身就是 n^2 维的向量。由于矩阵的乘法运算不同于向量的运算，所以在矩阵范数的定义中加入了第四个条件。

由前三个条件可知，矩阵范数具有向量范数的一切性质，例如：

- (1) $\mathbf{R}^{n \times n}$ 上的任意两个矩阵范数是等价的;
- (2) $\mathbf{R}^{n \times n}$ 上的矩阵序列依范数收敛与依元素收敛等价，即

$$\lim_{k \rightarrow \infty} \|A^{(k)} - A\| = 0 \Leftrightarrow \lim_{k \rightarrow \infty} a_{ij}^{(k)} = a_{ij}, \forall i, j = 1, \dots, n.$$

矩阵范数

由于矩阵和向量之间也存在乘法运算，因此，我们通常不加规定地要求矩阵范数满足第五个条件：

(5) 矩阵范数与向量范数的相容性： $\|Ax\| \leq \|A\| \cdot \|x\|, \forall A \in R^{n \times n}, x \in R^n$.

对于任意给定的 R^n 上的向量范数，都可以构造一个 $R^{n \times n}$ 上的矩阵范数满足上述五个条件。

定理： 设 $\|\cdot\|$ 是 R^n 上的一个向量范数，由该向量范数可以诱导出 $R^{n \times n}$ 到 R 的非负函数：

$$\|A\| = \max_{\substack{x \in R^n \\ x \neq 0}} \frac{\|Ax\|}{\|x\|} = \max_{\|x\|=1} \|Ax\|, A \in R^{n \times n},$$

该函数是 $R^{n \times n}$ 上的一个矩阵范数，且满足矩阵范数与向量范数之间相容性。

该定理中定义的矩阵范数称为向量范数诱导出的算子范数。以后的学习中可能会经常用到。

矩阵范数

证明: 令 $G = \{x \in R^n: \|x\| = 1\}$ 。 G 是有界闭集。因为 $\|\cdot\|$ 是连续函数, 故 $\|\cdot\|$ 在 G 上存在最大值。因此, 对于任意的矩阵 $A \in R^{n \times n}$, 定理中所定义的都 $\|A\|$ 有意义。下面证明 $\|\cdot\|$ 满足上述的五条性质。

(1)**正定性.** 由向量范数的定义易知, 如果 $A \neq 0$, 则存在 $x \in G$, 使得 $\|Ax\| > 0$, 于是 $\|A\| = \max_{\|x\|=1} \|Ax\| > 0$. 因此, $\|A\| = 0$, 当且仅当 $A = 0$.

(2)**齐次性.** 对任意的常数 a ,

$$\|aA\| = \max_{\|x\|=1} \|aAx\| = |a| \cdot \max_{\|x\|=1} \|Ax\| = |a| \cdot \|A\|.$$

(3)**三角不等式.** 对任意的常数 a ,

$$\begin{aligned} \|A + B\| &= \max_{\|x\|=1} \|(A + B)x\| \leq \max_{\|x\|=1} (\|Ax\| + \|Bx\|) \\ &\leq \max_{\|x\|=1} \|Ax\| + \max_{\|x\|=1} \|Bx\| \leq \|A\| + \|B\|. \end{aligned}$$

(4)**矩阵范数与向量范数的相容性.** $\forall A \in R^{n \times n}, x \in R^n$,

$$\|A\| = \max_{\substack{x \in R^n \\ x \neq 0}} \frac{\|Ax\|}{\|x\|} \Rightarrow \|Ax\| \leq \|A\| \cdot \|x\|$$

矩阵p范数

(5)相容性. $\forall A, B \in R^{n \times n}, x \in R^n$, 有性质 (4) 可知:

$$\|ABx\| \leq \|A\| \cdot \|Bx\| \leq \|A\| \cdot \|B\| \cdot \|x\|.$$

所以, $\|AB\| = \max_{\|x\|=1} \|ABx\| \leq \max_{\|x\|=1} \|A\| \cdot \|B\| \cdot \|x\| = \|A\| \cdot \|B\|.$ 证毕。

向量的 p 范数可以诱导出矩阵的 p 范数:

$$\|A\|_p = \max_{\substack{x \in R^n \\ x \neq 0}} \frac{\|Ax\|_p}{\|x\|_p}.$$

容易验证, 矩阵的 p 范数与向量的 p 范数是相容的。

定理: 设 $A = (a_{ij})_{n \times n}$, 则有:

$$\|A\|_1 = \max_{1 \leq j \leq n} \sum_{i=1}^n |a_{ij}|,$$

$$\|A\|_\infty = \max_{1 \leq i \leq n} \sum_{j=1}^n |a_{ij}|,$$

$$\|A\|_2 = \sqrt{\lambda_{\max}(A^T A)},$$

其中, $\lambda_{\max}(A^T A)$ 表示 $A^T A$ 的最大特征值。

矩阵p范数

证明： $A = 0$ 时定理显然成立，下面假定 $A \neq 0$ 。

考虑1范数。 将矩阵 A 按列分块为 $A = [a_1, \dots, a_n]$ ，并记 $\delta = \|a_{j_0}\|_1 = \max_{1 \leq j \leq n} \|a_j\|_1$ ，这表示第 j_0 列之和为最大列和，该最大列和为 δ 。现只需证 $\max_{\|x\|_1=1} \|Ax\|_1 = \delta$ 。对任一满足 $\|x\|_1 = 1$ 的 x ，有

$$\|Ax\|_1 = \left\| \sum_{j=1}^n x_j a_j \right\|_1 \leq \sum_{j=1}^n |x_j| \|a_j\|_1 \leq \sum_{j=1}^n |x_j| \cdot \delta = \delta.$$

令 e_{j_0} 表示第 j_0 个元素为1，其它元素为0的列向量，

$$\|Ae_{j_0}\|_1 = \|a_{j_0}\|_1 = \delta,$$

所以， $\|A\|_1 = \max_{\|x\|=1} \|Ax\|_1 = \delta$ 。

矩阵p范数

考虑 ∞ 范数. 记 $\eta = \max_{1 \leq i \leq n} \sum_{j=1}^n |a_{ij}| = \sum_{j=1}^n |a_{kj}|$, 这表示第 k 行之和为最大行和, 该最大行和为 η 。现只需证 $\max_{\|x\|_\infty=1} \|Ax\|_\infty = \eta$. 对任一满足 $\|x\|_\infty = 1$ 的 x , 有

$$\|Ax\|_\infty = \max_{1 \leq i \leq n} \left| \sum_{j=1}^n a_{ij} x_j \right| \leq \max_{1 \leq i \leq n} \sum_{j=1}^n |a_{ij}| \cdot |x_j| \leq \max_{1 \leq i \leq n} \sum_{j=1}^n |a_{ij}| = \eta.$$

令 $\tilde{x} = (\text{sign}(a_{k1}), \dots, \text{sign}(a_{kn}))^T$, 则 $\|\tilde{x}\|_\infty = 1$ 且 $\|A\tilde{x}\|_\infty = \eta$,

所以, $\|A\|_\infty = \max_{\|x\|_\infty=1} \|Ax\|_\infty = \eta$.

矩阵p范数

考虑2范数. 已知 $A^T A$ 为半正定矩阵, 故有

$$\max_x \frac{x^T (A^T A) x}{x^T x} = \lambda_{\max}(A^T A).$$

因此,

$$\|A\|_2 = \max_x \frac{\|Ax\|_2}{\|x\|_2} = \max_x \sqrt{\frac{x^T (A^T A) x}{x^T x}} = \sqrt{\lambda_{\max}(A^T A)}.$$

设 $A^T A$ 的特征值为: $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_n \geq 0$, 存在正交矩阵 Q 使得
 $A^T A = Q D Q^T, D = \text{diag}(\lambda_1, \dots, \lambda_n)$.

令 $\tilde{x} = Q^T x$, 于是
 $\frac{x^T (A^T A) x}{x^T x} = \frac{\tilde{x}^T D \tilde{x}}{\tilde{x}^T \tilde{x}} \leq \lambda_1$.
当取 x 为 Q 的第一列时, 上不等式取等, 故得证

矩阵的1范数、 ∞ 范数、2范数通常分别被称为列和范数、行和范数、谱范数。

定理: 设 $A = (a_{ij})_{n \times n}$ 则有:

- (1) $\|A\|_2 = \max\{|y^T A x| : x, y \in R^n, \|x\|_2 = \|y\|_2 = 1\}$;
- (2) $\|A\|_2 = \|A^T\|_2 = \sqrt{\|A^T A\|_2}$;
- (3) 对任意的 n 阶正交矩阵 U 和 V , 有 $\|UA\|_2 = \|AV\|_2 = \|A\|_2$.

当矩阵只有一列时, 矩阵范数就是(列)向量范数(在p范数下自行验证)

Frobenius范数

一个常用且易于计算的矩阵范数-Frobenius范数：

$$\|A\|_F = \left(\sum_{i,j=1}^n a_{ij}^2 \right)^{1/2},$$

Frobenius范数是向量2范数的自然推广，但它不是算子范数。

思考：从直觉出发，为什么Frobenius范数不是算子范数？

矩阵范数与特征值的关系

定义： 设 $A \in \mathbf{R}^{n \times n}$ 。矩阵 A 的所有特征值的模的最大值称为谱半径，记为：

$$\rho(A) = \max\{|\lambda_1|, \dots, |\lambda_n|\}.$$

定理： 设 $A \in \mathbf{R}^{n \times n}$ ，则有

(1) 对 $\mathbf{R}^{n \times n}$ 上的任意矩阵范数 $\|\cdot\|$ ，都有

$$\rho(A) \leq \|A\|;$$

(2) 对任给的 $\varepsilon > 0$ ，存在 $\mathbf{R}^{n \times n}$ 上的算子范数 $\|\cdot\|$ ，使得

$$\|A\| \leq \rho(A) + \varepsilon.$$

矩阵范数与特征值的关系

证明：(1) 设 $A \in \mathbf{R}^n$. 设 λ 是 A 的任一特征值, x 是相应的一个特征向量。现在证 $|\lambda| \leq \|A\|$. 不妨假设 x 的第一个分量不为 0, 这样便有 $xe_1^T \neq 0$. 因为

$$|\lambda| \cdot \|xe_1^T\| = \|\lambda xe_1^T\| = \|Axe_1^T\| \leq \|A\| \cdot \|xe_1^T\|,$$

所以, $|\lambda| \leq \|A\|$. 因此, $\rho(A) \leq \|A\|$.

(2) 由 Jordan 分解定理知, 存在非奇异矩阵 X 使得

$$X^{-1}AX = \begin{pmatrix} \lambda_1 & \delta_1 & & & \\ & \lambda_2 & \delta_2 & & \\ & & \ddots & \ddots & \\ & & & \lambda_{n-1} & \delta_{n-1} \\ & & & & \lambda_n \end{pmatrix},$$

其中 $\delta_i = 1$ 或 0 . 对于任给的 $\varepsilon > 0$, 令 $D_\varepsilon = \text{diag}(1, \varepsilon, \varepsilon^2, \dots, \varepsilon^{n-1})$, 则有

矩阵范数与特征值的关系

$$D_\varepsilon^{-1}X^{-1}AXD_\varepsilon = \begin{pmatrix} \lambda_1 & \varepsilon\delta_1 & & \\ & \lambda_2 & \varepsilon\delta_2 & \\ & & \ddots & \ddots \\ & & & \lambda_{n-1} & \varepsilon\delta_{n-1} \\ & & & & \lambda_n \end{pmatrix}.$$

定义一个从 $\mathbb{R}^{n \times n}$ 到 $\mathbb{R}$ 的函数 $\|\cdot\|_\varepsilon$:

$$\|A\|_\varepsilon = \|(XD_\varepsilon)^{-1}AXD_\varepsilon\|_\infty, A \in \mathbb{R}^{n \times n}.$$

现在证明上面定义的函数 $\|\cdot\|_\varepsilon$ 是由某个向量范数诱导出的算子范数, 并且满足 $\|A\|_\varepsilon \leq \rho(A) + \varepsilon$.

定义一个从 $\mathbb{R}^n$ 到 $\mathbb{R}$ 的函数 $\|\cdot\|$:

$$\|x\| = \|(XD_\varepsilon)^{-1}x\|_\infty, x \in \mathbb{R}^n.$$

于是

$$\|Ax\| = \|(XD_\varepsilon)^{-1}Ax\|_\infty, x \in \mathbb{R}^n.$$

矩阵范数与特征值的关系

从而

$$\|A\|_\varepsilon = \|(XD_\varepsilon)^{-1}AXD_\varepsilon\|_\infty = \max_x \frac{\|(XD_\varepsilon)^{-1}AXD_\varepsilon(XD_\varepsilon)^{-1}x\|_\infty}{\|(XD_\varepsilon)^{-1}x\|_\infty} = \max_x \frac{\|Ax\|}{\|x\|}$$

因此, $\|\cdot\|_\varepsilon$ 是由向量范数诱导出的算子范数。

此外还可得到

$$\|A\|_\varepsilon = \|(XD_\varepsilon)^{-1}AXD_\varepsilon\|_\infty = \max_{1 \leq i \leq n} (|\lambda_i| + |\varepsilon\delta_i|) \leq \rho(A) + \varepsilon,$$

其中 $\delta_n = 0$.

思考：从算子范数的定义出发，为什么矩阵的范数会比所有特征值的模要大？

思考：从算子范数的定义出发，为什么矩阵范数会满足 $\|AB\| \leq \|A\|\|B\|$ ？

思考：从算子范数的定义出发，矩阵的范数和其逆矩阵的范数之间关系？

矩阵范数与特征值的关系

定理： 设 $A \in \mathbf{R}^{n \times n}$, 则有

$$\lim_{k \rightarrow \infty} A^k = 0 \Leftrightarrow \rho(A) < 1.$$

证明：必要性. 设 λ 是 A 的模最大的特征值, 即 $|\lambda| = \rho(A)$.

易知, 设 λ^k 也是 A^k 的一个特征值. 于是

$$\rho(A)^k = |\lambda|^k = \rho(A^k) \leq \|A^k\|_2.$$

因此, $\lim_{k \rightarrow \infty} A^k = 0 \Rightarrow \lim_{k \rightarrow \infty} \|A^k\|_2 = 0 \Rightarrow \rho(A) < 1$.

充分性. 已知 $\rho(A) < 1$, 必有算子范数 $\|\cdot\|$ 使得 $\|A\| < 1$. 从而

$$\lim_{k \rightarrow \infty} \|A^k\| \leq \lim_{k \rightarrow \infty} \|A\|^k = 0.$$

因此, $\lim_{k \rightarrow \infty} A^k = 0$.

矩阵范数与特征值的关系

定理： 设 $A \in \mathbf{R}^{n \times n}$, 则有

(1) $\sum_{k=0}^{\infty} A^k$ 收敛的充要条件是 $\rho(A) < 1$;

(2) 当 $\sum_{k=0}^{\infty} A^k$ 收敛时, 有

$$\sum_{k=0}^{\infty} A^k = (I - A)^{-1},$$

而且存在 $\mathbf{R}^{n \times n}$ 上的算子范数 $\|\cdot\|$, 使得对一切自然数 m 都有

$$\left\| (I - A)^{-1} - \sum_{k=0}^m A^k \right\| \leq \frac{\|A\|^{m+1}}{1 - \|A\|}.$$

自行证明。

推论： 设 $\|\cdot\|$ 是 $\mathbf{R}^{n \times n}$ 上的一个满足条件 $\|I\| = 1$ 的矩阵范数，并假定 $A \in \mathbf{R}^{n \times n}$ 满足 $\|A\| < 1$ ，则 $I - A$ 可逆，且有

$$\|(I - A)^{-1}\| \leq \frac{1}{1 - \|A\|}$$

证明： 由 $\|A\| < 1$ ，知 $I - A$ 可逆，且有 $(I - A)^{-1} = \sum_{k=0}^{\infty} A^k$ 。所以

$$\begin{aligned} \|(I - A)^{-1}\| &= \left\| \sum_{k=0}^{\infty} A^k \right\| \leq \left\| I + \sum_{k=1}^{\infty} A^k \cdot I \right\| \leq \|I\| + \|A\|\|I\| + \|A\|^2\|I\| + \dots \\ &\leq \frac{\|I\|}{1 - \|A\|}. \end{aligned}$$

自行证明： $\|(I - A)^{-1}B\| \leq \frac{\|B\|}{1 - \|A\|}$ (假设 $\|A\| < 1$)

计算范数-Matlab指令

$x = \text{norm}(A, p)$; 计算矩阵或向量 A 的 p 范数

当 A 为矩阵时, p 只可取1、2、inf、'fro'

当 A 为向量时, p 只可取任意实数以及'fro'

$x = \text{norm}(A)$; 当没有给定 p 时, 默认计算2范数

作业

1 /

证明教材定理2.1.5

提示：每一小问依赖于前面的小问。第一小问中可以考虑 $y = \frac{Ax}{\|Ax\|_2}$

2 /

教材第二章课后习题1、9

3 /

体会矩阵范数和向量范数的区别与联系。体会矩阵范数和矩阵特征值之间的联系。（不用交）

4 /

矩阵的范数和其逆矩阵的范数之间关系？（不用交）