

数值计算方法

线性方程组的敏度/误差分析

信息管理与工程学院
冯银波

什么是敏度分析？

- 线性方程组 $Ax = b$ 的系数矩阵 A 和右端向量 b ，往往是观测来的，因此它们不可避免地带有误差。这种原始数据的误差对方程组求解的影响如何，是必须探讨的，此即所谓方程组的敏感性问题，也叫做条件问题。
 - ✓ A 或者 b 的微小扰动对线性方程组的（精确）解的影响如果比较小，则成该方程组问题是良态的

病态问题-举例

例：线性方程组

$$\begin{bmatrix} 2.0002 & 1.9998 \\ 1.9998 & 2.0002 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 4 \\ 4 \end{bmatrix}$$

的（精确）解为 $x = (1, 1)^T$. 若方程的右端向量发生了扰动，从 b 变为 $b + \delta b$, $\delta b = (2 \times 10^{-4}, -2 \times 10^{-4})^T$, 则原方程组变为

$$\begin{bmatrix} 2.0002 & 1.9998 \\ 1.9998 & 2.0002 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 4.0002 \\ 3.9998 \end{bmatrix},$$

它的（精确）解为 $\tilde{x} = (1.5, 0.5)^T$. 于是，

$$\frac{\|\tilde{x} - x\|_{\infty}}{\|x\|_{\infty}} = \frac{1}{2}, \quad \frac{\|\delta b\|_{\infty}}{\|b\|_{\infty}} = \frac{1}{20000}.$$

右端向量变化了万分之0.5，但方程组的（精确）解却变化了50%。这说明该线性方程组问题不是一个良态问题。

一般线性方程组的敏感性问题

对于系数矩阵非奇异的线性方程组 $Ax = b$ ，经微小变动后变为：

$$(A + \delta A)(x + \delta x) = b + \delta b.$$

将 $b = Ax$ 代入上式并整理可得

$$(A + \delta A)\delta x = \delta b - \delta Ax.$$

δA 充分小，是指 δA 的
每一个元素都充分小，
或者说 $\|\delta A\|$ 充分小

由于 A 非奇异，故当 δA 充分小时， $A + \delta A$ 仍是非奇异的。

因此可得，

$$\delta x = (A + \delta A)^{-1}(\delta b - \delta Ax) = (I + A^{-1}\delta A)^{-1}A^{-1}(\delta b - \delta Ax)$$

两边取范数可得，

$$\begin{aligned}\|\delta x\| &\leq \|(I + A^{-1}\delta A)^{-1}A^{-1}\| \cdot (\|\delta b\| + \|\delta A\| \cdot \|x\|) \\ &\leq \frac{\|A^{-1}\|}{1 - \|A^{-1}\| \cdot \|\delta A\|} (\|\delta b\| + \|\delta A\| \cdot \|x\|),\end{aligned}$$

其中第二个不等式利用了不等式：

$$\|(I - A)^{-1}B\| \leq \frac{\|B\|}{1 - \|A\|} \quad \text{if } \|A\| < 1.$$

一般线性方程组的敏感性问题

两边除以 $\|x\|$ ，并利用 $\|b\| \leq \|A\| \|x\|$ ，可得

$$\frac{\|\delta x\|}{\|x\|} \leq \frac{\|A^{-1}\| \cdot \|A\|}{1 - \|A^{-1}\| \cdot \|\delta A\|} \left(\frac{\|\delta b\|}{\|b\|} + \frac{\|\delta A\|}{\|A\|} \right).$$

定理： 设 $\|\cdot\|$ 是 $\mathbf{R}^{n \times n}$ 上的一个满足条件 $\|I\| = 1$ 的矩阵范数，并假定 $A \in \mathbf{R}^{n \times n}$ 非奇异， $b \in \mathbf{R}^n$ 非0；再假定 $\delta A \in \mathbf{R}^{n \times n}$ 满足 $\|A^{-1}\| \cdot \|\delta A\| < 1$ 。若 x 和 $x + \delta x$ 分别是线性方程组

$$Ax = b \text{ 和 } (A + \delta A)(x + \delta x) = b + \delta b$$

的解，则

$$\frac{\|\delta x\|}{\|x\|} \leq \frac{\kappa(A)}{1 - \kappa(A) \frac{\|\delta A\|}{\|A\|}} \left(\frac{\|\delta b\|}{\|b\|} + \frac{\|\delta A\|}{\|A\|} \right)$$

其中， $\kappa(A) = \|A^{-1}\| \cdot \|A\|$

当 $\frac{\|\delta A\|}{\|A\|}$ 比较小时， $\frac{\kappa(A)}{1 - \kappa(A) \frac{\|\delta A\|}{\|A\|}} \approx \kappa(A)$ ，
$$\frac{\|\delta x\|}{\|x\|} \leq \kappa(A) \left(\frac{\|\delta b\|}{\|b\|} + \frac{\|\delta A\|}{\|A\|} \right)$$

条件数与敏度

$$\frac{\|\delta x\|}{\|x\|} \leq \kappa(A) \left(\frac{\|\delta b\|}{\|b\|} + \frac{\|\delta A\|}{\|A\|} \right).$$

定义：称 $\kappa(A) = \|A^{-1}\| \cdot \|A\|$ 为线性方程组 $Ax = b$ 的条件数。

条件数的大小依赖于系数矩阵 A ，故也称为矩阵 A 的条件数。条件数在一定程度上刻画了系数矩阵 A 和右端向量 b 的扰动对方程组解的影响程度。若 $\kappa(A)$ 很小(大)，则称该方程组的求解问题是良态的(病态的)。

由于范数之间的“等价性”，若条件数在一种范数下很小，那么其它范数下也会很小。因此，要分析线性方程组的敏感性问题，只需分析它在某一种范数下是良态或病态即可。

定理：对任意的矩阵范数有：

- (1) $\kappa(A) \geq 1$; (提示: $\|A^{-1}\| \cdot \|A\| \geq \|I\|$.)
- (2) $\kappa(aA) = \kappa(A)$, 其中 a 为任意常数。

条件数的几何意义

定理： 设 $A \in \mathbf{R}^{n \times n}$ 非奇异，则

$$\min \left\{ \frac{\|\delta A\|_2}{\|A\|_2} : A + \delta A \text{ 奇异} \right\} = \frac{1}{\|A^{-1}\|_2 \cdot \|A\|_2} = \frac{1}{\kappa_2(A)}.$$

注意： A 是非奇异矩阵，经过扰动之后变成了奇异矩阵 $A + \delta A$ 。

该定理表明： 在谱范数下，矩阵 A 的条件数的倒数等于 A 与奇异矩阵集合的相对距离 $\frac{\|A + \delta A - A\|_2}{\|A\|_2}$ 。当 A 十分病态时，说明 A 与一个奇异矩阵十分靠近或者 A 的 2 范数非常大。

对于本节一开始的例子：求解线性方程组

$$\begin{bmatrix} 2.0002 & 1.9998 \\ 1.9998 & 2.0002 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 4 \\ 4 \end{bmatrix},$$

可以验证： $\kappa_\infty(A) = \|A^{-1}\|_\infty \cdot \|A\|_\infty = 2500$ 。

病态原因：系数矩阵的两行几乎相同，十分接近于奇异矩阵

条件数的几何意义

$$A = \begin{bmatrix} 1 & 0 \\ 0 & 10^{100} \end{bmatrix}, \quad A^{-1} = \begin{bmatrix} 1 & 0 \\ 0 & 10^{-100} \end{bmatrix}$$

$$\|A\|_2 = 10^{100}, \quad \|A^{-1}\|_2 = 1$$

$$\kappa_2(A) = \kappa_2(A^{-1}) = 10^{100}$$

A 的条件数很大，要么是因为 A 与一个奇异矩阵十分靠近，要么是因为 A^{-1} 与一个奇异矩阵十分靠近。

病态问题-举例2

例：线性方程组

$$\begin{bmatrix} 1.001 & 0.25 \\ 0.25 & 0.0625 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 1.501 \\ 0.375 \end{bmatrix}$$

的（精确）解为 $x = (1, 2)^T$. 若对方程的系数矩阵和右端向量取近似数，比如：

$$\begin{bmatrix} 1 & 0.25 \\ 0.25 & 0.063 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 1.5 \\ 0.37 \end{bmatrix}$$

它的（精确）解为 $\tilde{x} = (4, -10)^T$. 可见该问题十分病态。

验证其条件数：

$$A = \begin{bmatrix} 1.001 & 0.25 \\ 0.25 & 0.0625 \end{bmatrix} \quad A^{-1} = \begin{bmatrix} 1000 & -4000 \\ -4000 & 16016 \end{bmatrix}$$

$$\|A\|_{\infty} = 1.251$$

$$\|A^{-1}\|_{\infty} = 20016$$

$$\kappa_{\infty}(A) = \|A^{-1}\|_{\infty} \cdot \|A\|_{\infty} = 25040$$

病态原因：系数矩阵的第一行几乎恰好是第二行的4倍，近似奇异矩阵

病态问题-举例3

例：某线性方程组的系数矩阵(100阶)如下：

$$A = \begin{bmatrix} 1 & -1 & -1 & \cdots & -1 & -1 \\ & 1 & -1 & \cdots & -1 & -1 \\ & & 1 & \cdots & -1 & -1 \\ & & & \ddots & \vdots & \vdots \\ & & & & 1 & -1 \\ & & & & & 1 \end{bmatrix}$$

思考：如何对A做一个微小的改变，使得A变为奇异阵？

所以，这样的A对应的线性方程组问题是病态的。

误差分析

在数值计算过程中，由于计算机的字长的限制，运算结果难以精确地被存储。超出字长的部分将会被截断或“四舍五入”（与软件和指令有关）。

比如：123x123=15129，如果计算机中只能存储4位10进制的数字，那么，这个计算结果将被存储为15120（截断）或15130（四舍五入）。这涉及到计算机中的浮点数存储机制。

定义：一个 β 进制的浮点数 f 表示为：

$$f = \pm 0.d_1d_2 \dots d_t \times \beta^J, \quad L \leq J \leq U,$$

其中， $0.d_1d_2 \dots d_t$ 是尾数， t 是字长（最多包含 t 个有效数字）， β 是机器浮点数所用的基底，通常 $\beta = 2$ ， J 是阶码。 t, β, L, U 决定了所有浮点数的取值集合。

对非零的二进制浮点数，其**规范**的表示形式中，尾数的小数点左边永远是1，如：

$$f = 1.01101 \times 2^{1001}.$$

IEEE754浮点数表示标准

标准的单精度二进制浮点数包含4个字节，每个字节含8个比特，共32个比特，如：

$$b_1 b_2 \dots b_9 b_{10} \dots b_{31} b_{32}$$

每个比特取值为0或1。

- (1) 其中第一位 b_1 表示数字的正负号，0为正，1位负；
- (2) 接下来的8个比特 $b_2 \dots b_9$ 表示阶码，取值范围在0到255，该阶码减去127后表示真正的指数，范围在-127到128之间；
- (3) 最后的23个比特 $b_{10} \dots b_{31} b_{32}$ 表示尾数，在标准的二进制浮点数的表示形式中，尾数的整数部分默认是1，所以真正的尾数为 $1.b_{10} \dots b_{31} b_{32}$ 。

例：某个比特序列



该比特序列对应的二进制数字为： $1.00011 \times 2^{10000011-1111111}$

写成10进制： $\left(1 + \frac{1}{2^4} + \frac{1}{2^5}\right) \times 2^{131-127} = 17.5$

自行学习双精度浮点数的标准格式

绝对误差与相对误差

由于字长的限制，浮点数之间的运算很难精确地进行。

用 $\text{fl}(x)$ 表示 x 的浮点数。比如：对于3位的10进制浮点数，

$$\text{fl}(5.45627) = 5.45 \times 10^0 \text{ 或 } 0.545 \times 10^1 (\text{截断})$$

$$\text{fl}(5.45627) = 5.46 \times 10^0 \text{ 或 } 0.546 \times 10^1 (\text{四舍五入}).$$

浮点数表示形式并不唯一，不同的表示形式并不影响其实际取值。

四舍五入是针对十进制而言的，在二进制中是“0舍1入”。

绝对误差： $\text{fl}(x) - x$

相对误差： $\frac{\text{fl}(x) - x}{x}$

绝对误差与相对误差

例：令 $a = 0.263 \times 10^4$, $b = 0.466 \times 10^1$ 为3位10进制浮点数， $a + b$ 的真实值为 0.263446×10^4 . 然而将这个和表示成浮点数为 0.263×10^4 , 这是计算机得出的结果。

绝对误差： $\text{fl}(a + b) - (a + b) = -4.46$

相对误差： $\frac{-4.46}{0.263446 \times 10^4} \approx -0.17 \times 10^{-2}$

ab 的真实值为 11729.8; 将这个积表示成浮点数为 0.117×10^5

绝对误差： $\text{fl}(ab) - (ab) = -29.8$

相对误差： $\frac{-29.8}{11729.8} \approx -0.25 \times 10^{-2}$

机器精度

一个实数 x 用浮数 $\text{fl}(x)$ 表示的相对误差，通常用 δ 表示，于是有

$$\text{fl}(x) = x(1 + \delta).$$

在给定 t, β, L, U 后， δ 依赖于 x ，机器精度是 $|\delta|$ 的一个上界（用浮点数表示）。**机器精度**定义为：满足 $\text{fl}(1 + \mathbf{u}) > 1$ 的最小浮点数 $\mathbf{u}$ 。

例：对于3位10进制浮点数，在四舍五入的规则下，因为

$$\text{fl}(1 + 0.499 \times 10^{-2}) = 1,$$

$$\text{fl}(1 + 0.5 \times 10^{-2}) = 1.01,$$

所以，相应的机器精度为 $\mathbf{u} = 0.500 \times 10^{-2}$ ($\mathbf{u} = 0.5 \times 10^{-(t-1)}$)

若在截断的规则下，相应的机器精度为 $\mathbf{u} = 1.00 \times 10^{-2}$ ($\mathbf{u} = 10^{-(t-1)}$)

在Matlab中， eps 表示双精度下的机器精度， $\text{eps} = 2^{-52}$ 。

单精度机器精度为 2^{-23} 。

定理：给定 t, β, L, U ，对任意浮点数 x ，有 $\left| \frac{\text{fl}(x) - x}{x} \right| \leq \mathbf{u}$ 。

机器精度

定理： 给定 t, β, L, U ，对任意浮点数 x, y ，在不发生溢出的条件下，

$$\left| \frac{\text{fl}(x \pm y) - (x \pm y)}{(x \pm y)} \right| \leq u$$

$$\left| \frac{\text{fl}(x \times y) - (x \times y)}{(x \times y)} \right| \leq u$$

$$\left| \frac{\text{fl}(x \div y) - (x \div y)}{(x \div y)} \right| \leq u.$$

对于规范的二进制浮点数，“溢出”是指阶码超出取值范围。如果发生溢出，则可能产生较大误差，上述定理不一定成立

机器精度

给定 t, β, L, U , 对任意浮点数 x, y, z , $(x + y) \times z$ 的计算结果过为:

$$\text{fl}(\text{fl}(x + y) \times z) = \text{fl}((x + y)(1 + \delta_1) \times z) = (x + y) \times z(1 + \delta_1)(1 + \delta_2).$$

思考: $x + y + z$ 和 $x + z + y$ 的计算结果一样吗? ($0.995 + 0.005 + 1$)

定理: 若 $|\delta_i| \leq \mathbf{u}$ 且 $n\mathbf{u} \leq 0.01$, 那么

$$1 - n\mathbf{u} \leq \prod_{i=1}^n (1 + \delta_i) \leq 1 + 1.01n\mathbf{u}$$

或写成

利用 $(1 - \mathbf{u})^n \leq \prod_{i=1}^n (1 + \delta_i) \leq (1 + \mathbf{u})^n \leq e^{n\mathbf{u}}$
去证, 可参考教材

$$\prod_{i=1}^n (1 + \delta_i) = 1 + \delta, \quad |\delta| \leq 1.01n\mathbf{u}.$$

机器精度

例： 估计 $|\text{fl}(\sum_{i=1}^n x_i y_i) - \sum_{i=1}^n x_i y_i|$ 的上界。其中 $\text{fl}(\text{表达式})$ 表示用浮点运算计算该表达式得到的结果，而不是先计算其精确值再化为浮点数。

$$\text{fl}(x_1 y_1) = x_1 y_1 (1 + \gamma_1)$$

$$\text{fl}(x_1 y_1 + x_2 y_2) = (x_1 y_1 (1 + \gamma_1) + x_2 y_2 (1 + \gamma_2)) (1 + \delta_2)$$

$$\begin{aligned} \text{fl}(x_1 y_1 + x_2 y_2 + x_3 y_3) &= (\text{fl}(x_1 y_1 + x_2 y_2) + x_3 y_3 (1 + \gamma_3)) (1 + \delta_3) \\ &= \dots \end{aligned}$$

$$\begin{aligned} \text{fl}(\sum_{i=1}^n x_i y_i) &= x_1 y_1 (1 + \gamma_1) \prod_{i=2}^n (1 + \delta_i) + x_2 y_2 (1 + \gamma_2) \prod_{i=2}^n (1 + \delta_i) \\ &\quad + x_3 y_3 (1 + \gamma_3) \prod_{i=3}^n (1 + \delta_i) + x_4 y_4 (1 + \gamma_4) \prod_{i=4}^n (1 + \delta_i) \\ &\quad + \dots \end{aligned}$$

$$|\text{fl}(\sum_{i=1}^n x_i y_i) - \sum_{i=1}^n x_i y_i| \leq 1.01n\mathbf{u} \sum_{i=1}^n |x_i y_i| \quad \text{利用 } |\prod_{i=1}^n (1 + \delta_i) - 1| \leq 1.01n\mathbf{u}$$

机器精度

以上结论可以推广到矩阵的运算。定义

$$|A| = [|a_{ij}|]$$

$$|A| \leq |B| \Leftrightarrow |a_{ij}| \leq |b_{ij}|, \forall i, j.$$

则有

$$\text{fl}(\alpha A) = \alpha A + E, \quad |E| \leq \mathbf{u}|\alpha A|$$

$$\text{fl}(A + B) = A + B + E, \quad |E| \leq \mathbf{u}|A + B|$$

$$\text{fl}(AB) = AB + E, \quad |E| \leq 1.01n\mathbf{u}|A||B|$$



注意：这里是 $|A||B|$ 而不是 $|AB|$ 。比如，计算 $a_1b_1 + a_2b_2$ ，误差为： $|(a_1b_1(1 + \delta_1) + a_2b_2(1 + \delta_2))(1 + \delta_3) - (a_1b_1 + a_2b_2)| \leq 1.01 \times 2\mathbf{u}(|a_1b_1| + |a_2b_2|)$

向后误差分析法

以矩阵相乘为例,

$$\text{fl}(AB) = AB + E, \quad |E| \leq 1.01n\mathbf{u}|A||B|$$

上式给出了计算结果与真实结果之间差距的上界, 这种误差分析方法称为**向前误差分析法**。在实际中, 经常采用的是**向后误差分析法**, 它是指将计算过程中产生的舍入/截断误差归结为原始数据的扰动在精确计算下带来的误差的一种分析方法。

例: 分析矩阵乘积 AB 的误差

$$A = \begin{bmatrix} a_{11} & a_{12} \\ 0 & a_{22} \end{bmatrix}, \quad B = \begin{bmatrix} b_{11} & b_{12} \\ 0 & b_{22} \end{bmatrix}$$

$$\begin{aligned} \text{fl}(AB) &= \begin{bmatrix} a_{11}b_{11}(1+\delta_1) & (a_{11}b_{12}(1+\delta_2) + a_{12}b_{22}(1+\delta_3))(1+\delta_4) \\ 0 & a_{22}b_{22}(1+\delta_5) \end{bmatrix} \\ &= AB + E \text{ (向前误差分析)} \end{aligned}$$

$$\text{令} \quad \tilde{A} = \begin{bmatrix} a_{11} & a_{12}(1+\delta_3)(1+\delta_4) \\ 0 & a_{22}(1+\delta_5) \end{bmatrix}, \quad \tilde{B} = \begin{bmatrix} b_{11}(1+\delta_1) & b_{12}(1+\delta_2)(1+\delta_4) \\ 0 & b_{22} \end{bmatrix}$$

$$\begin{aligned} \text{fl}(AB) &= \tilde{A}\tilde{B}; \quad \tilde{A} = A + E, |E| \leq 3\mathbf{u}|A|; \quad \tilde{B} = B + F, |F| \leq 3\mathbf{u}|B|; \\ &\text{(向后误差分析)} \end{aligned}$$

向后误差分析法

向后误差分析法的优点：(1)将浮点数运算的误差归结为原始数据的扰动，之后便可结合敏度分析的方法来分析误差的影响；(2)不需要知道精确解是多少；(3)在分析误差的大小时，只需考虑实数的精确运算，例如前面通过 $A, B, \text{fl}(AB)$ 去估计满足 $\text{fl}(AB) = (A + E_1)(B + E_2)$ 的 E_1, E_2 的大小。

注意，我们求得了 $\tilde{x}$ ，
但我们并不知道 x

例：对于线性方程组 $Ax = b$ ，精确解为 x ，计算解为 $\tilde{x}$ 。向后误差分析法将 $\tilde{x}$ 与 x 之间的差距看成是由 A 的扰动造成的。 $\tilde{x}$ 满足 $(A + \delta A)\tilde{x} = b$ ，从而分析 $\tilde{x}$ 与 x 之间的误差问题归结为了分析 A 的扰动问题，即分析 $\frac{\|\delta A\|}{\|A\|}$ 的上界。

用列主元Gauss消去法求线性方程组主要分两步：(1)三角分解 $PA = LU$ ；(2)用前代法和回代法求解 x 。每一步都会导致浮点数运算引起的误差。

$$PA = LU \rightarrow Ly = Pb \rightarrow Ux = y$$

下面先分析三角分解的误差。

三角分解的误差分析

对 $n \times n$ 的浮点数矩阵 A 用Gauss消去法进行三角分解, 精确结果为 $A = LU$, 计算结果为 $\tilde{L}\tilde{U}$. $\tilde{L}, \tilde{U}$ 分别与 L, U 之间的误差可以归结为是由 A 的扰动导致的, 即

$$A + E = \tilde{L}\tilde{U}.$$

分析三角分解的误差问题分析归结为了分析 $|E|$ 的上界问题。

定理: 设 $n \times n$ 的浮点数矩阵 A 存在三角分解, 且 $1.01n\mathbf{u} \leq 0.01$, 则用Gauss消去法计算得到的单位下三角阵 $\tilde{L}$ 和上三角阵 $\tilde{U}$ 满足:

$$A + E = \tilde{L}\tilde{U}, \quad |E| \leq 2.05n\mathbf{u}|\tilde{L}| \cdot |\tilde{U}|.$$

注意: $|E|$ 表示矩阵, 不是行列式

三角分解的误差分析

回顾Gauss消去法的计算过程：

$$\begin{array}{c}
 \begin{bmatrix} a_{11}^{(0)} & a_{12}^{(0)} & a_{13}^{(0)} & a_{14}^{(0)} \\ a_{21}^{(0)} & a_{22}^{(0)} & a_{23}^{(0)} & a_{24}^{(0)} \\ a_{31}^{(0)} & a_{32}^{(0)} & a_{33}^{(0)} & a_{34}^{(0)} \\ a_{41}^{(0)} & a_{42}^{(0)} & a_{43}^{(0)} & a_{44}^{(0)} \end{bmatrix} \xrightarrow{\text{第1步}} \begin{bmatrix} \tilde{u}_{11} & \tilde{u}_{12} & \tilde{u}_{13} & \tilde{u}_{14} \\ a_{21}^{(0)} & a_{22}^{(0)} & a_{23}^{(0)} & a_{24}^{(0)} \\ a_{31}^{(0)} & a_{32}^{(0)} & a_{33}^{(0)} & a_{34}^{(0)} \\ a_{41}^{(0)} & a_{42}^{(0)} & a_{43}^{(0)} & a_{44}^{(0)} \end{bmatrix} \longrightarrow \begin{bmatrix} \tilde{u}_{11} & \tilde{u}_{12} & \tilde{u}_{13} & \tilde{u}_{14} \\ \tilde{l}_{21} & a_{22}^{(1)} & a_{23}^{(1)} & a_{24}^{(1)} \\ \tilde{l}_{31} & a_{32}^{(1)} & a_{33}^{(1)} & a_{34}^{(1)} \\ \tilde{l}_{41} & a_{42}^{(1)} & a_{43}^{(1)} & a_{44}^{(1)} \end{bmatrix} \\
 \\
 \xrightarrow{\text{第2步}} \begin{bmatrix} \tilde{u}_{11} & \tilde{u}_{12} & \tilde{u}_{13} & \tilde{u}_{14} \\ \tilde{l}_{21} & \tilde{u}_{22} & \tilde{u}_{23} & \tilde{u}_{24} \\ \tilde{l}_{31} & a_{32}^{(1)} & a_{33}^{(1)} & a_{34}^{(1)} \\ \tilde{l}_{41} & a_{42}^{(1)} & a_{43}^{(1)} & a_{44}^{(1)} \end{bmatrix} \longrightarrow \begin{bmatrix} \tilde{u}_{11} & \tilde{u}_{12} & \tilde{u}_{13} & \tilde{u}_{14} \\ \tilde{l}_{21} & \tilde{u}_{22} & \tilde{u}_{23} & \tilde{u}_{24} \\ \tilde{l}_{31} & \tilde{l}_{32} & a_{33}^{(2)} & a_{34}^{(2)} \\ \tilde{l}_{41} & \tilde{l}_{42} & a_{43}^{(2)} & a_{44}^{(2)} \end{bmatrix} \\
 \\
 \xrightarrow{\text{第3步}} \dots\dots
 \end{array}$$

可以看到： $\tilde{u}_{34} = \text{fl}(a_{34} - \tilde{l}_{31}\tilde{u}_{14} - \tilde{l}_{32}\tilde{u}_{24})$, $\tilde{u}_{44} = ?$

三角分解的误差分析

证明上述定理:

由Gauss消去法的计算过程, 可知: 当 $i \leq j$,

$$\begin{aligned}\tilde{u}_{ij} &= \text{fl} \left(a_{ij} - \sum_{k=1}^{i-1} \tilde{l}_{ik} \tilde{u}_{kj} \right) \\ &= a_{ij} \prod_{k=1}^{i-1} (1 + \varepsilon_k) - \tilde{l}_{i1} \tilde{u}_{1j} (1 + \gamma_1) \prod_{k=1}^{i-1} (1 + \varepsilon_k) \\ &\quad - \tilde{l}_{i2} \tilde{u}_{2j} (1 + \gamma_2) \prod_{k=2}^{i-1} (1 + \varepsilon_k) - \cdots \\ &= a_{ij} (1 + \delta_i) - \sum_{k=1}^{i-1} \tilde{l}_{ik} \tilde{u}_{kj} (1 + \delta_k), \quad |\delta_k| \leq 1.01 n \mathbf{u}.\end{aligned}$$

于是,
$$a_{ij} = \frac{\tilde{u}_{ij}}{1 + \delta_i} + \sum_{k=1}^{i-1} \tilde{l}_{ik} \tilde{u}_{kj} \frac{1 + \delta_k}{1 + \delta_i} = \sum_{k=1}^i \tilde{l}_{ik} \tilde{u}_{kj} - e_{ij}, \quad e_{ij} = ?$$

三角分解的误差分析

$$e_{ij} = \overset{1}{\uparrow} \tilde{l}_{ii} \tilde{u}_{ij} \frac{\delta_i}{1 + \delta_i} + \sum_{k=1}^{i-1} \tilde{l}_{ik} \tilde{u}_{kj} \frac{\delta_i - \delta_k}{1 + \delta_i},$$
$$|e_{ij}| \leq \frac{2.02n\mathbf{u}}{1 - 0.01} \sum_{k=1}^i |\tilde{l}_{ik}| |\tilde{u}_{kj}| \leq 2.05n\mathbf{u} \sum_{k=1}^i |\tilde{l}_{ik}| |\tilde{u}_{kj}|.$$

证毕。

也可以根据 $\tilde{l}_{ij}$ 的计算过程去证明上述定理。

思考： $\tilde{l}_{ij} = ?$ ，如何得到 a_{ij} 与 $\tilde{l}_{ij}$, $\tilde{u}_{ij}$ 的关系？

然后利用相似的思路去证明上述定理，具体可参考教材。

三角分解的误差分析

定理： 设 $n \times n$ 的浮点数矩阵 A 非奇异 (存在列主元三角分解)，且 $1.01n\mathbf{u} \leq 0.01$ ，则用列主元Gauss消去法计算得到的单位下三角阵 $\tilde{L}$ ，上三角阵 $\tilde{U}$ 以及排列方阵 $\tilde{P}$ 满足：

$$\tilde{P}A + E = \tilde{L}\tilde{U}, \quad |E| \leq 2.05n\mathbf{u}|\tilde{L}| \cdot |\tilde{U}|.$$

证明略。

注意：列主元消去法可以减小误差，但并不意味着可以减小误差的上界。

三角形线性方程组的误差分析

当对 A 完成 LU 分解之后, 求解线性方程组 $Ax = b$ 的问题就归结为求解两个三角性方程组的问题:

$$\tilde{L}y = \tilde{P}b \quad \text{和} \quad \tilde{U}x = y.$$

同样地, 分析三角形方程组求解的误差问题可归结为分析系数矩阵的扰动的上界问题。

定理: 设 $n \times n$ 的浮点数三角(上三角或下三角)矩阵 S 非奇异(存在列主元三角分解), 且 $1.01n\mathbf{u} \leq 0.01$, 则用前代法或回代法求解 $Sx = b$ 得到的计算解 $\tilde{x}$ 满足:

$$(S + H)\tilde{x} = b, \quad |H| \leq 1.01n\mathbf{u}|S|.$$

三角形线性方程组的误差分析

证明：用数学归纳法证。不妨假设 S 为下三角矩阵。

先考虑 $n = 1$. 通过浮点数运算求解：

$$s_{11}x = b_1,$$

得
$$\tilde{x} = \frac{b_1}{s_{11}}(1 + \gamma_1), \quad |\gamma_1| \leq \mathbf{u} \leq \frac{0.01}{1.01}.$$

从而
$$\frac{s_{11}}{1 + \gamma_1} \tilde{x} = b_1.$$

因为
$$\frac{1}{1 + \gamma_1} = 1 - \gamma_1 + \gamma_1^2 - \gamma_1^3 + \cdots = 1 - \gamma_1 + \frac{\gamma_1^2}{1 + \gamma_1},$$

且
$$\left| \frac{\gamma_1}{1 + \gamma_1} \right| \leq \frac{\frac{0.01}{1.01}}{1 - \frac{0.01}{1.01}} = 0.01, \quad \text{因为 } 1.01n\mathbf{u} \leq 0.01,$$

所以,
$$\frac{s_{11}}{1 + \gamma_1} = s_{11}(1 + \delta_1), \quad |\delta_1| \leq 1.01\mathbf{u}.$$

即,
$$(s_{11} + h_{11})\tilde{x} = b_1, \quad |h_{11}| \leq 1.01\mathbf{u}|s_{11}|$$

三角形线性方程组的误差分析

假设对 $n-1$ 阶的三角方程组, 该定理成立, 即方程组

$$\begin{bmatrix} s_{11} & & \\ \vdots & \ddots & \\ s_{1,n-1} & \dots & s_{n-1,n-1} \end{bmatrix} \begin{bmatrix} x_1 \\ \vdots \\ x_{n-1} \end{bmatrix} = \begin{bmatrix} b_1 \\ \vdots \\ b_{n-1} \end{bmatrix}$$

的计算结果满足定理结论。

下面考虑下列 n 阶的三角方程组的计算结果:

$$\begin{bmatrix} s_{11} & & & \\ \vdots & \ddots & & \\ s_{1,n-1} & \dots & s_{n-1,n-1} & \\ s_{1,n} & \dots & s_{n,n-1} & s_{n,n} \end{bmatrix} \begin{bmatrix} x_1 \\ \vdots \\ x_{n-1} \\ x_n \end{bmatrix} = \begin{bmatrix} b_1 \\ \vdots \\ b_{n-1} \\ b_n \end{bmatrix}.$$

由前代法先求出 $\tilde{x}, \dots, \tilde{x}_{n-1}$ 。由归纳假设知

$$\left(\begin{bmatrix} s_{11} & & \\ \vdots & \ddots & \\ s_{1,n-1} & \dots & s_{n-1,n-1} \end{bmatrix} + \begin{bmatrix} h_{11} & & \\ \vdots & \ddots & \\ h_{1,n-1} & \dots & h_{n-1,n-1} \end{bmatrix} \right) \begin{bmatrix} \tilde{x}_1 \\ \vdots \\ \tilde{x}_{n-1} \end{bmatrix} = \begin{bmatrix} b_1 \\ \vdots \\ b_{n-1} \end{bmatrix},$$

其中 $|h_{ij}| \leq 1.01(n-1)\mathbf{u}$ 。

三角形线性方程组的误差分析

将 $\tilde{x}, \dots, \tilde{x}_{n-1}$ 代入最后一个方程, 得

$$\tilde{x}_n = \text{fl} \left(\frac{b_n - s_{n,1}\tilde{x}_1 - \dots - s_{n,n-1}\tilde{x}_{n-1}}{s_{n,n}} \right).$$

易知

$$\frac{s_{n,n}\tilde{x}_n}{1 + \gamma_n} = \text{fl}(b_n - s_{n,1}\tilde{x}_1 - \dots - s_{n,n-1}\tilde{x}_{n-1})$$

由前面的分析知

$$\begin{aligned} \text{fl}(b_n - s_{n,1}\tilde{x}_1 - \dots - s_{n,n-1}\tilde{x}_{n-1}) &= b_n(1 + \gamma_1) \cdots (1 + \gamma_{n-1}) \\ &+ \sum_{k=1}^{n-1} s_{n,k}\tilde{x}_k (1 + \delta_k)(1 + \gamma_k) \cdots (1 + \gamma_{n-1}), \end{aligned}$$

故有

$$\begin{aligned} s_{n,1}\tilde{x}_1(1 + \delta_1) + \frac{s_{n,2}\tilde{x}_2(1 + \delta_2)}{(1 + \gamma_1)} + \dots + \frac{s_{n,n-1}\tilde{x}_{n-1}(1 + \delta_{n-1})}{(1 + \gamma_1) \cdots (1 + \gamma_{n-2})} \\ + \frac{s_{n,n}\tilde{x}_n}{(1 + \gamma_1) \cdots (1 + \gamma_n)} = b_n \end{aligned}$$

三角形线性方程组的误差分析

利用前面的结论, 有

$$\frac{1}{1+\gamma} = (1+\delta), \quad |\delta| \leq 1.01\mathbf{u}.$$

因为 $1.01n\mathbf{u} \leq 0.01$,

可以证明:

$$(1 + 1.01\mathbf{u})^n \leq 1 + 1.01n\mathbf{u}.$$

和前面的定理证明类似

所以, 计算解满足

$$(s_{11} + h_{11})\tilde{x}_1 + \cdots + (s_{n,n} + h_{nn})\tilde{x}_n = b_n, \quad |h_{kk}| \leq 10.1n\mathbf{u}.$$

列主元Gauss消去法求线性方程组的误差分析

上面完成了用列主元Gauss消去法求 $Ax = b$ 的过程中每个步骤的误差分析，
下面讨论：如果计算解 $\tilde{x}$ 满足 $(A + \delta A)\tilde{x} = b$ ，那么 $\frac{\|\delta A\|}{\|A\|}$ 有多大。

向前

$$\begin{array}{c} PA = LU \rightarrow \tilde{L}, \tilde{U} \\ \downarrow \\ \tilde{L}y = Pb \rightarrow \tilde{y} \\ \downarrow \\ \tilde{U}x = \tilde{y} \rightarrow \tilde{x} \end{array}$$

向后

$$\begin{array}{c} \tilde{P}A + E_3 = (\tilde{L} + E_2)(\tilde{U} + E_1) \\ \uparrow \\ (\tilde{L} + E_2)\tilde{y} = \tilde{P}b \\ \uparrow \\ (\tilde{U} + E_1)\tilde{x} = \tilde{y} \end{array}$$

定理： 设 $n \times n$ 的浮点数矩阵 A 非奇异 (存在列主元三角分解)，且 $1.01n\mathbf{u} \leq 0.01$ ，则用列主元Gauss消去法求解 $Ax = b$ 得到的计算解 $\tilde{x}$ 满足：

$$(A + \delta A)\tilde{x} = b, \quad \frac{\|\delta A\|_{\infty}}{\|A\|_{\infty}} \leq 4.09n^3\rho\mathbf{u},$$

$$\rho = \frac{\max_{i,j} |\tilde{u}_{ij}|}{\max_{i,j} |a_{ij}|}.$$

有了对 $\frac{\|\delta A\|_{\infty}}{\|A\|_{\infty}}$ 的上界的估计，接下来便可判断列主元消去法是否数值稳定

列主元Gauss消去法求线性方程组的误差分析

最后需要指出的是，理论上可以证明 $\rho \leq 2^{n-1}$ ，而且上界可以达到。但在实际计算时，常遇到的问题 ρ 往往很小，一般不超过 n 。此外， $4.09n^3\rho\mathbf{u}$ 在理论上比 $\frac{\|\delta A\|_\infty}{\|A\|_\infty}$ 要大很多，但对于常遇到的问题，有 $\frac{\|\delta A\|_\infty}{\|A\|_\infty} \approx \mathbf{u}$ 。这说明，列主元Gauss消去法（应该）是数值稳定的。

计算解的精度估计

当我们对具体的计算问题做了敏度分析，比如：

$$\frac{\|\tilde{x} - x\|_{\infty}}{\|x\|_{\infty}} \leq \kappa_{\infty}(A) \left(\frac{\|\delta A\|_{\infty}}{\|A\|_{\infty}} + \frac{\|\delta b\|_{\infty}}{\|b\|_{\infty}} \right).$$

又对具体算法做了误差分析，比如：

$$\frac{\|\delta b\|_{\infty}}{\|b\|_{\infty}} = 0, \quad \frac{\|\delta A\|_{\infty}}{\|A\|_{\infty}} \leq 4.09n^3\rho\mathbf{u}$$

接下来就可以给出计算结果的精度估计：

$$\frac{\|\tilde{x} - x\|_{\infty}}{\|x\|_{\infty}} \leq \kappa_{\infty}(A) * 4.09n^3\rho\mathbf{u}$$

这种方法普适性强，但对于具体的参数，有时候做出的精度估计不太准确，下面介绍另一种方法。

计算解的精度估计

在得到线性方程组 $Ax = b$ 的计算解 $\tilde{x}$ 之后，下面介绍一种直接估计 $\frac{\|\tilde{x} - x\|}{\|x\|}$ 大小的方法，称为精度估计。

$$\begin{aligned}\text{令} \quad r &= b - A\tilde{x} \\ r &= Ax - A\tilde{x} = A(x - \tilde{x}).\end{aligned}$$

$$\text{于是} \quad \|x - \tilde{x}\| = \|A^{-1}r\| \leq \|A^{-1}\| \cdot \|r\|.$$

左边除以 $\|x\|$ ，右边除以 $\frac{\|b\|}{\|A\|}$ ，因为 $\|b\| \leq \|A\|\|x\|$ ，所以

$$\frac{\|\tilde{x} - x\|}{\|x\|} \leq \kappa(A) \frac{\|r\|}{\|b\|}, \kappa(A) = \|A^{-1}\| \cdot \|A\|$$

特别地，对于 ∞ 范数，有

$$\frac{\|\tilde{x} - x\|_{\infty}}{\|x\|_{\infty}} \leq \kappa_{\infty}(A) \frac{\|r\|_{\infty}}{\|b\|_{\infty}}, \kappa_{\infty}(A) = \|A^{-1}\|_{\infty} \|A\|_{\infty}$$

计算解的精度估计

从而，通过求 $\|A^{-1}\|_{\infty}$ ， $\|A\|_{\infty}$ ， $\|r\|_{\infty}$ ， $\|b\|_{\infty}$ 便可得到计算解的精度估计。

这种误差估计方法较为简单，便于理解，但不够严谨。（1）没有考虑计算 $r = b - A\tilde{x}$ 时的误差，有可能出现 $\|r\|$ 很小但 $\|x - \tilde{x}\|$ 很大的情形；（2）不好区分最终的误差多少是由问题本身的病态性导致的，多少是由方法不当导致的。这种做法实际上就是将计算解和精确解之间的误差归结为 $\|r\|$ 。

作业

1 / 计算课件第9页100阶矩阵 A (无穷范数下的)条件数。

2 / 教材第二章课后习题11、17

3 / 证明：如果 A 正定，那么 $\kappa(A) = \frac{\lambda_{max}}{\lambda_{min}}$ ，这里 λ_{max} 和 λ_{min} 分别是 A 的最大最小特征值。