

数值计算方法

线性方程组的矩阵分裂迭代法

信息管理与工程学院
冯银波

直接法 vs 迭代法

用直接法求解线性方程组在理论上能求得精确解，它的计算量都是 n^3 量级的，它的存储量为 n^2 量级。对 n 比较小的情形，直接法非常有效。对于很多实际问题，系数矩阵的阶数往往很大并且十分稀疏（含有大量0元素），这时用迭代法效果更好，理由如下：

- 1) **处理大规模稀疏矩阵更高效**：直接解法会破坏矩阵的稀疏性，导致大量不必要的计算和存储开销。而矩阵分裂迭代法，每次迭代只需要处理系数矩阵中的非零元素，且能保持矩阵的稀疏性，大大减少计算量和存储空间。
- 2) **对系数矩阵的适应性强**：直接解法通常要求系数矩阵具有某些特定的性质，如非奇异性、正定等。而迭代法对系数矩阵的要求相对较低，甚至面对病态矩阵，迭代法依然可能收敛到满意的解。
- 3) **易于并行计算**：矩阵分裂迭代法天然具有并行性，例如，每次迭代中不同元素的更新是相互独立的，可以同时进行计算。

直接法 vs 迭代法

迭代法是按照某种规则构造一个向量序列 $\{x^{(k)}\}$, 使其极限向量 x^* 是方程组 $Ax = b$ 的精确解。使用迭代法时, 往往只能经过有限次迭代得到 x^* 的近似值。迭代法面临的问题:

- (1) 如何构造迭代序列?
- (2) 构造的迭代序列是否收敛? 在什么情况下收敛?
- (3) 如果收敛, 收敛的速度如何?
- (4) 如何讨论近似解的误差?

迭代法对存储单位的需求较小, 程序设计简单, 原始系数矩阵在迭代过程中保持不变, 是求解大型系数矩阵的重要方法。

Jacobi 迭代法

考虑非奇异线性方程组：

$$\begin{cases} a_{11}x_1 + a_{12}x_2 + \cdots + a_{1n}x_n = b_1 \\ a_{21}x_1 + a_{22}x_2 + \cdots + a_{2n}x_n = b_2 \\ \dots\dots\dots \\ a_{n1}x_1 + a_{n2}x_2 + \cdots + a_{nn}x_n = b_n \end{cases}$$

假设对角元素全不为0

改写成：

$$\begin{cases} x_1 = \frac{1}{a_{11}}(b_1 - a_{12}x_2 - a_{13}x_3 - \cdots - a_{1n}x_n) \\ x_2 = \frac{1}{a_{22}}(b_2 - a_{21}x_1 - a_{23}x_3 - \cdots - a_{2n}x_n) \\ \dots\dots\dots \\ x_n = \frac{1}{a_{nn}}(b_n - a_{n1}x_1 - a_{n2}x_2 - \cdots - a_{n,n-1}x_{n-1}) \end{cases}$$

改写迭代格式：



$$\begin{cases} x_1^{(k+1)} = \frac{1}{a_{11}}(b_1 - a_{12}x_2^{(k)} - a_{13}x_3^{(k)} - \cdots - a_{1n}x_n^{(k)}) \\ x_2^{(k+1)} = \frac{1}{a_{22}}(b_2 - a_{21}x_1^{(k)} - a_{23}x_3^{(k)} - \cdots - a_{2n}x_n^{(k)}) \\ \dots\dots\dots \\ x_n^{(k+1)} = \frac{1}{a_{nn}}(b_n - a_{n1}x_1^{(k)} - a_{n2}x_2^{(k)} - \cdots - a_{n,n-1}x_{n-1}^{(k)}) \end{cases}$$

Jacobi 迭代法：

$$x_i^{(k+1)} = \frac{1}{a_{ii}} \left(b_i - \sum_{\substack{j=1 \\ j \neq i}}^n a_{ij}x_j^{(k)} \right) \quad (i = 1, 2, \dots, n)$$

Jacobi 迭代法-矩阵表示

考虑非奇异线性方程组 $Ax = b$, 假设的对角元素全不为0
令

$$A = D - L - U$$

其中

$$D = \text{diag}(a_{11}, a_{22}, \dots, a_{nn}) \quad L = \begin{pmatrix} 0 & & & \\ -a_{21} & 0 & & \\ -a_{31} & -a_{32} & & \\ \vdots & \vdots & \ddots & \\ -a_{n1} & -a_{n2} & & 0 \end{pmatrix} \quad U = \begin{pmatrix} 0 & -a_{12} & \cdots & -a_{1n} \\ & 0 & \cdots & -a_{2n} \\ & & \ddots & \\ & & & 0 \end{pmatrix}$$

原方程组可以改写成:

$$Ax = b \Leftrightarrow (D - L - U)x = b \Leftrightarrow Dx = (L + U)x + b$$

Jacobi 迭代法: $x^{(k+1)} = Mx^{(k)} + g$

其中 $M = D^{-1}(L + U)$ 称为迭代矩阵, $g = D^{-1}b$ 称为常数项。

Jacobi 迭代法

若给定初始向量 $x^{(0)} = (x_1^{(0)}, \dots, x_n^{(0)})^T$ ，便可利用迭代公式构造迭代序列 $\{x^{(k)}\}$ ：

$$x^{(1)} = Mx^{(0)} + g,$$

$$x^{(k+1)} = Mx^{(k)} + g, \quad k = 0, 1, \dots$$

终止条件：(1) 迭代够一定次数；(2) $\|x^{(k)} - x^*\|$ 或 $\frac{\|b - Ax^{(k)}\|}{\|b\|}$ 或 $\|x^{(k)} - x^{(k-1)}\|$ 小于某设定值。

问题：这样的迭代序列收敛吗？

举例

用Jacobi迭代法计算下列线性方程组，设 $x^{(0)} = (0,0)^T$. 观察收敛性与收敛速度：

$$\begin{cases} 2x_1 + x_2 = 3 \\ x_1 + 2x_2 = 3 \end{cases}$$

$$\begin{cases} x_1 + 2x_2 = 3 \\ 2x_1 + x_2 = 3 \end{cases}$$

Gauss-Seidel 迭代法

如果Jacobi迭代序列收敛，那么 $x^{(k+1)}$ 应当比 $x^{(k)}$ 更接近 x^* 。因此，对Jacobi迭代法进行如下修改，应该可以提高收敛速度。

(1) 按照Jacobi迭代公式计算 $x_1^{(k+1)}$

(2) 因 $x_1^{(k+1)}$ 已经计算出，将 $x^{(k)}$ 的第一个元素用 $x_1^{(k+1)}$ 代替，其它元素保持不变，然后按照Jacobi迭代公式计算 $x_2^{(k+1)}$

(3) 类似地，对于 $i = 3, \dots, n$ ，在计算 $x_i^{(k+1)}$ 时，因 $x_1^{(k+1)}, \dots, x_{i-1}^{(k+1)}$ 已经计算出，用它们代替 $x^{(k)}$ 的相应分量，然后按照Jacobi迭代公式计算 $x_i^{(k+1)}$ 。

具体过程：

$$\begin{cases} x_1^{(k+1)} = \frac{1}{a_{11}} (b_1 - a_{12}x_2^{(k)} - a_{13}x_3^{(k)} - \dots - a_{1n}x_n^{(k)}) \\ x_2^{(k+1)} = \frac{1}{a_{22}} (b_2 - a_{21}x_1^{(k+1)} - a_{23}x_3^{(k)} - \dots - a_{2n}x_n^{(k)}) \\ \dots\dots\dots \\ x_n^{(k+1)} = \frac{1}{a_{nn}} (b_n - a_{n1}x_1^{(k+1)} - a_{n2}x_2^{(k+1)} - \dots - a_{n,n-1}x_{n-1}^{(k+1)}) \end{cases}$$

Gauss-Seidel 迭代法

Gauss-Seidel 迭代法:

$$x_i^{(k+1)} = \frac{1}{a_{ii}} \left(b_i - \sum_{j=1}^{i-1} a_{ij} x_j^{(k+1)} - \sum_{j=i+1}^n a_{ij} x_j^{(k)} \right) \quad (i = 1, 2, \dots, n)$$

写成矩阵形式:

$$Ax = b \Leftrightarrow (D - L - U)x = b \Leftrightarrow (D - L)x = Ux + b$$

如果 $D - L$ 可逆, 则有:

$$x = (D - L)^{-1} Ux + (D - L)^{-1} b$$

Gauss-Seidel 迭代法的矩阵形式:

$$x^{(k+1)} = Mx^{(k)} + g$$

其中 $M = (D - L)^{-1} U$ 称为迭代矩阵, $g = (D - L)^{-1} b$ 称为常数项。

单步线性定常迭代法

Jacobi迭代法和Gauss-Seidel迭代法都具有如下线性形式：

$$x^{(k+1)} = Mx^{(k)} + g.$$

Jacobi迭代法： $M = D^{-1}(L + U), \quad g = D^{-1}b;$

Gauss-Seidel迭代法： $M = (D - L)^{-1}U, \quad g = (D - L)^{-1}b.$

具有以上形式的迭代法称作单步线性定常迭代法， M 称为迭代矩阵， g 称为常数项， $x^{(0)}$ 为初始向量， $\{x^{(k)}\}$ 称为迭代序列。如果对任意的 $x^{(0)}$ ，迭代法产生的迭代序列都收敛，则称该迭代法是收敛的。

单步线性定常迭代法

如果迭代法 $x^{(k+1)} = Mx^{(k)} + g$ 收敛, 记其极限为 x^* , 则有

$$x^* = Mx^* + g.$$

对于非奇异方程组 $Ax = b$, 如果存在非奇异矩阵 G 使得

$$G(I - M) = A, \quad Gg = b,$$

那么, $x = Mx + g$ 可由 $Ax = b$ 通过可逆变换而得到, 这说明这两个线性方程组是等价的, 因此, 迭代法(如果收敛)必收敛到原方程组的唯一解。此时, 称该迭代法与原线性方程组是相容的。

思考: 若要保证迭代法收敛, M 需要是可逆的吗?

思考: 已知 $M = I - G^{-1}A$, 直觉上, 如何选取 G 可以提高收敛性和收敛速度?

单步线性定常迭代法的收敛性

定义

$$y^{(k)} = x^{(k)} - x^*,$$

为 $x^{(k)}$ 的误差向量. 利用迭代公式可得

$$y^{(k+1)} = My^{(k)},$$

因此,
$$y^{(k)} = M^k y^{(0)}.$$

定理: 设 $M \in \mathbf{R}^{n \times n}$, $g \in \mathbf{R}^n$, 迭代法 $x^{(k+1)} = Mx^{(k)} + g$ ($k = 0, 1, \dots$)收敛的充要条件是 $M^k \rightarrow 0$ 。

定理: 设 $M \in \mathbf{R}^{n \times n}$, $g \in \mathbf{R}^n$, 迭代法 $x^{(k+1)} = Mx^{(k)} + g$ ($k = 0, 1, \dots$)收敛的充要条件是 $\rho(M) < 1$ 。

因此, 迭代法是否收敛以与迭代矩阵的谱半径有关, 与常数项无关。
(注意: 收敛到哪个点与常数项有关)

Jacobi迭代法 vs G-S 迭代法

对于同一个线性方程组，它所对应的Jacobi迭代矩阵和G-S迭代矩阵的谱半径可能不一样，因此两种迭代法的收敛性和收敛速度可能不一样。可能都收敛，也可能都不收敛，也可能一个收敛另一个不收敛。如果都收敛，收敛速度也可能不一样。

例：

$$A_1 = \begin{bmatrix} 1 & 2 & -2 \\ 1 & 1 & 1 \\ 2 & 2 & 1 \end{bmatrix} \quad A_2 = \begin{bmatrix} 2 & -1 & 1 \\ 1 & 1 & 1 \\ 1 & 1 & -2 \end{bmatrix},$$

通过计算 A_1 对应的两个迭代矩阵的谱半径可知，分别为0, 2。因此，对 A_1 而言，Jacobi迭代法收敛，而G-S迭代法不收敛。

对 A_2 而言，对应的两个迭代矩阵的谱半径分别为1.118, 0.5。因此，Jacobi迭代法不收敛，而G-S迭代法收敛。

Jacobi迭代法 vs G-S 迭代法

例：

$$\begin{bmatrix} 9 & -1 & -1 \\ -1 & 8 & 0 \\ -1 & 0 & 9 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} 7 \\ 7 \\ 8 \end{bmatrix}$$

可以验证两种迭代矩阵的谱半径均小于1，所以两种迭代法都收敛。

Jacobi 迭代法：

$$M = I - D^{-1}A = \begin{bmatrix} 0 & 1/9 & 1/9 \\ 1/8 & 0 & 0 \\ 1/8 & 0 & 0 \end{bmatrix} \quad g = D^{-1}b = \begin{bmatrix} 7/9 \\ 7/8 \\ 8/9 \end{bmatrix}$$

$$x^{(k+1)} = \begin{bmatrix} 0 & 1/9 & 1/9 \\ 1/8 & 0 & 0 \\ 1/8 & 0 & 0 \end{bmatrix} x^{(k)} + \begin{bmatrix} 7/9 \\ 7/8 \\ 8/9 \end{bmatrix}$$

迭代结果：

k	0	1	2	3	4	5
$x^{(k)}$	$\begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix}$	$\begin{bmatrix} 0.7778 \\ 0.8750 \\ 0.8889 \end{bmatrix}$	$\begin{bmatrix} 0.9738 \\ 0.9722 \\ 0.9753 \end{bmatrix}$	$\begin{bmatrix} 0.9942 \\ 0.9967 \\ 0.9971 \end{bmatrix}$	$\begin{bmatrix} 0.9993 \\ 0.9993 \\ 0.9994 \end{bmatrix}$	$\begin{bmatrix} 0.9998 \\ 0.9999 \\ 0.9999 \end{bmatrix}$

Jacobi迭代法 vs G-S 迭代法

G-S迭代法:

$$x^{(k+1)} = \begin{bmatrix} 0 & 1/9 & 1/9 \\ 0 & 1/72 & 1/72 \\ 0 & 1/81 & 1/81 \end{bmatrix} x^{(k)} + \begin{bmatrix} 7/9 \\ 35/36 \\ 79/81 \end{bmatrix}$$

迭代结果:

k	0	1	2	3	4
$x^{(k)}$	$\begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix}$	$\begin{bmatrix} 0.7778 \\ 0.9722 \\ 0.9753 \end{bmatrix}$	$\begin{bmatrix} 0.9942 \\ 0.9993 \\ 0.9994 \end{bmatrix}$	$\begin{bmatrix} 0.9998 \\ 1.000 \\ 1.000 \end{bmatrix}$	$\begin{bmatrix} 1.000 \\ 1.000 \\ 1.000 \end{bmatrix}$

在这个例子中G-S迭代法的速度快于Jacobi迭代法。

思考：这两种迭代法占用的存储空间有何不同？

单步线性定常迭代法的收敛性

通过计算谱半径来判断迭代法是否收敛，显然是不方便的。

定理： 设 $M \in \mathbf{R}^{n \times n}$, $g \in \mathbf{R}^n$ 。若 $\|M\| = q < 1$ ，则迭代法 $x^{(k+1)} = Mx^{(k)} + g$ ($k = 0, 1, \dots$) 产生的近似解 $x^{(k)}$ 与 x^* 的误差满足：

$$\|x^{(k)} - x^*\| \leq \frac{q^k}{1-q} \|x^{(1)} - x^{(0)}\|.$$

证明： 已知 $y^{(k)} = M^k y^{(0)}$ 。两边取范数，得

$$\|y^{(k)}\| \leq \|M\|^k \|y^{(0)}\| = q^k \|y^{(0)}\|.$$

而

$$\begin{aligned}\|y^{(0)}\| &= \|x^{(0)} - x^*\| \leq \|x^{(0)} - x^{(1)}\| + \|x^{(1)} - x^*\| \\ &= \|x^{(0)} - x^{(1)}\| + \|My^{(0)}\| \\ &\leq \|x^{(0)} - x^{(1)}\| + q\|y^{(0)}\|\end{aligned}$$

得到

$$\|y^{(0)}\| \leq \frac{1}{1-q} \|x^{(1)} - x^{(0)}\|$$

所以

$$\|y^{(k)}\| \leq \frac{q^k}{1-q} \|x^{(1)} - x^{(0)}\|$$

单步线性定常迭代法的收敛性

根据上述定理，可以计算出要得到满足精度要求的近似解需要迭代多少次。这种估计往往过于保守。

定理： 设 $M \in \mathbf{R}^{n \times n}$, $g \in \mathbf{R}^n$ 。若 $\|M\| = q < 1$ ，则迭代法 $x^{(k+1)} = Mx^{(k)} + g$ ($k = 0, 1, \dots$) 产生的近似解 $x^{(k)}$ 与 x^* 的误差满足：

$$\|x^{(k)} - x^*\| \leq \frac{q}{1 - q} \|x^{(k-1)} - x^{(k)}\|.$$

证明： 因为

$$\begin{aligned} \|x^{(k)} - x^*\| &= \|M(x^{(k-1)} - x^*)\| \leq q \|x^{(k-1)} - x^*\| \\ &\leq q \|x^{(k-1)} - x^{(k)}\| + q \|x^{(k)} - x^*\| \end{aligned}$$

所以

$$\|x^{(k)} - x^*\| \leq \frac{q}{1 - q} \|x^{(k-1)} - x^{(k)}\|.$$

该定理表明，只要迭代矩阵的范数较小，当 $x^{(k)}$ 与 $x^{(k-1)}$ 很接近时， $x^{(k)}$ 与 x^* 也很接近。所以可用 “ $\|x^{(k-1)} - x^{(k)}\|$ 是否充分小” 来作为终止条件。

单步线性定常迭代法的收敛性

已知 $\rho(M) \leq \|M\|$ ，所以 $\|M\| < 1$ 只是迭代法收敛的充分条件。但是，在实际中计算 $\|M\|_1$ 或 $\|M\|_\infty$ 比计算 $\rho(M)$ 要方便得多。因此，通常利用 $\|M\|_1$ 或 $\|M\|_\infty$ 来判断迭代法是否收敛，以及设定迭代终止条件，但这只是充分条件。

Jacobi迭代法的收敛性

之前介绍的收敛性判定条件适用于所有的单步线性定常迭代法。下面根据Jacobi迭代法的特点, 给出Jacobi迭代法的收敛性判定条件。

定理: 设线性方程组的系数矩阵 $A \in \mathbf{R}^{n \times n}$ 对称, 而且对角元素 $a_{ii} > 0 (i = 1, \dots, n)$, 则Jacobi迭代法收敛的充要条件是 A 和 $2D - A$ 都正定。

证明: 因为 $M = I - D^{-1}A$, 且 D 的对角元均大于0, 故

$$M = I - D^{-1}A = D^{-\frac{1}{2}}(I - D^{-\frac{1}{2}}AD^{-\frac{1}{2}})D^{\frac{1}{2}}$$

由 A 的对称性推出 $I - D^{-\frac{1}{2}}AD^{-\frac{1}{2}}$ 也是对称的, 且与 M 相似, 这说明 M 的特征值均为实数。此外, 根据上式可得:

$$\begin{aligned} I - M &= D^{-\frac{1}{2}}(D^{-\frac{1}{2}}AD^{-\frac{1}{2}})D^{\frac{1}{2}} \\ I + M &= D^{-\frac{1}{2}}(2I - D^{-\frac{1}{2}}AD^{-\frac{1}{2}})D^{\frac{1}{2}}. \end{aligned}$$

Jacobi迭代法收敛 $\Leftrightarrow \rho(M) < 1 \Leftrightarrow M$ 的特征值都在-1到1之间 $\Leftrightarrow I - M$ 与 $I + M$ 的特征值都为正 $\Leftrightarrow A$ 和 $2D - A$ 都正定

G-S迭代法的收敛性

定理：若线性方程组的系数矩阵 $A \in \mathbf{R}^{n \times n}$ 正定，则G-S迭代法收敛。

该定理的证明在后面给出。

可见，判断Jacobi或G-S迭代法是否收敛与判断矩阵是否正定有关。然而判断矩阵是否正定不是件容易的事。而且正定矩阵的要求过于苛刻。

对角占优与不可约矩阵

定义： 设矩阵 $A = (a_{ij}) \in \mathbf{R}^{n \times n}$ 。若对所有的 $i (1 \leq i \leq n)$ 都有

$$|a_{ii}| \geq \sum_{\substack{j=1 \\ j \neq i}}^n |a_{ij}|,$$

且至少有一个不等号成立，则称 A 为弱严格对角占优矩阵；如果所有的不等号都成立，则称 A 为严格对角占优矩阵。

定义： 设矩阵 $A \in \mathbf{R}^{n \times n}$ 。若存在 n 阶排列方阵 P 使得

$$PAP^T = \begin{bmatrix} A_{11} & 0 \\ A_{21} & A_{22} \end{bmatrix},$$

其中 A_{11} 和 A_{22} 是方阵，则称 A 是可约矩阵。否则，称为不可约矩阵。

对角占优与不可约矩阵

如果 A 是可约矩阵, 则可将方程组 $Ax = b$ 化为

$$PAP^T Px = Pb.$$

记 $Px = y, Pb = f$, 则

$$\begin{bmatrix} A_{11} & 0 \\ A_{21} & A_{22} \end{bmatrix} \begin{bmatrix} y_1 \\ y_2 \end{bmatrix} = \begin{bmatrix} f_1 \\ f_2 \end{bmatrix},$$

这样, 可以先求解 $A_{11}y_1 = f_1$, 再求解 $A_{21}y_1 + A_{22}y_2 = f_2$. 这就把一个高阶方程组转化为了两个低阶方程组。

可约矩阵的等价定义: 令

$$\mathcal{W} = \{1, \dots, n\},$$

如果存在 $\mathcal{W}$ 的两个子集 $\mathcal{S}$ 和 $\mathcal{T}$ 满足:

$$\mathcal{S} \cup \mathcal{T} = \mathcal{W}, \mathcal{S} \cap \mathcal{T} = \emptyset,$$

使得 $a_{ij} = 0, \forall i \in \mathcal{S}, j \in \mathcal{T}$, 则称 A 是可约的。

对角占优与不可约矩阵

对上述定义的通俗解释：将 $1, \dots, n$ 看作图上的 n 个点；如果 $a_{ij} \neq 0$ ，则认为从 i 到 j 有一条有向边；如果 $a_{ij} = 0$ ，则认为从 i 到 j 不存在边；如果从 i 出发，经过一条或多条有向边可到达 j ，则称从 i 到 j 是连通的；如果任意的两点之间都是连通的，则称 A 是**不可约矩阵**；否则称为**可约矩阵**。

例：判断下列矩阵是可约矩阵or不可约矩阵

$$\begin{bmatrix} * & * & & & \\ * & * & * & & \\ & * & * & \ddots & \\ & & \ddots & \ddots & * \\ & & & * & * \end{bmatrix}$$

$$\begin{bmatrix} * & * & & & \\ & * & * & & \\ & & * & \ddots & \\ & & & \ddots & * \\ & & & & * \end{bmatrix}$$

定义：设矩阵 $A \in \mathbf{R}^{n \times n}$ 。如果 A 是不可约矩阵，并且是弱严格对角占优的，则称 A 是**不可约对角占优矩阵**。

对角占优与不可约矩阵

定理：若矩阵 $A \in \mathbf{R}^{n \times n}$ 是严格对角占优的，或不可约对角占优（弱对角占优）的，则 A 非奇异。

证明：先证明 A 是严格对角占优的情形。反正法。

假设 A 奇异，则 $Ax = 0$ 存在非零解 x 。不妨设 $x_1 = \|x\|_\infty = 1$ 。考虑第一个方程：

$$a_{11} + a_{12}x_2 + \cdots + a_{1n}x_n = 0,$$

其中， $|x_2|, \dots, |x_n|$ 均 ≤ 1 。这与

$$|a_{11}| > |a_{12}| + \cdots + |a_{1n}|$$

如果 A 只是弱严格对角占优，则会发生什么？

矛盾。

下面证明 A 是不可约对角占优的情形。同样采用反正法。

假设 A 奇异，则 $Ax = 0$ 存在非零解 x 。不妨设 $\|x\|_\infty = 1$ 。因为 A 是弱严格对角占优（至少有一个严格 $>$ ），所以 x 的分量不可能全是 1。

对角占优与不可约矩阵

令

$$\mathcal{S} = \{i: |x_i| = 1\}, \quad \mathcal{T} = \{i: |x_i| < 1\},$$

显然, $\mathcal{S} \cup \mathcal{T} = \mathcal{W}, \mathcal{S} \cap \mathcal{T} = \emptyset$, 且 $\mathcal{S}$ 与 $\mathcal{T}$ 均非空。

因为 A 不可约, 必存在 i, k , 使得

$$a_{ik} \neq 0, \quad i \in \mathcal{S}, k \in \mathcal{T}.$$

于是, $|a_{ik}x_k| < |a_{ik}|$ 。考虑第 i 个方程:

$$a_{ii}x_i + \sum_{j \in \mathcal{S}, j \neq i} a_{ij}x_j + \sum_{j \in \mathcal{T}} a_{ij}x_j = 0.$$

$$\text{有 } |a_{ii}| \leq \sum_{j \in \mathcal{S}, j \neq i} |a_{ij}||x_j| + \sum_{j \in \mathcal{T}} |a_{ij}||x_j| < \sum_{j \in \mathcal{S}, j \neq i} |a_{ij}| + \sum_{j \in \mathcal{T}} |a_{ij}| = \sum_{j \neq i} |a_{ij}|,$$

这与 A 弱对角占优矛盾。

例子

考虑下列矩阵

$$A = \begin{bmatrix} 2 & 2 & 0 \\ 1 & 1 & 0 \\ 0.1 & 0.1 & 1 \end{bmatrix}$$

矩阵A是弱对角占优矩阵、可约矩阵，也是奇异矩阵。

对角占优与不可约矩阵

定理：若矩阵 $A \in \mathbf{R}^{n \times n}$ 是严格对角占优的或不可约对角占优的对称矩阵，且 A 对角元素均为正数，则 A 正定。

证明：对于任意的 $\lambda \leq 0$ ，已知 A 的对角元素全为正，故有

- (1) 如果 A 严格对角占优，则 $A - \lambda I$ 也严格对角占优；
- (2) 如果 A 弱严格对角占优，则 $A - \lambda I$ 弱严格对角占优或严格对角占优；
- (3) 如果 A 不可约，则 $A - \lambda I$ 也不可约。

因此， $A - \lambda I$ 一定非奇异，所以 A 不可能有零或负特征值。从而 A 正定。

Jacobi和G-S迭代法收敛性

定理：若矩阵 $A \in \mathbf{R}^{n \times n}$ 是严格对角占优的或不可约对角占优的，则Jacobi迭代法和G-S迭代法均收敛。 教材中定理4.2.9给出了另一种证明方法

证明：这里只考虑矩阵 A 严格对角占优的情形。另一情形留作练习。

Jacobi迭代法：

$$\left| x_i^{(k+1)} - x_i^* \right| = \left| \sum_{\substack{j=1 \\ j \neq i}}^n \frac{a_{ij}}{a_{ii}} (x_j^{(k)} - x_j^*) \right| \leq \sum_{\substack{j=1 \\ j \neq i}}^n \frac{|a_{ij}|}{|a_{ii}|} |x_j^{(k)} - x_j^*|$$

记

$$L_i = \sum_{\substack{j=1 \\ j \neq i}}^n \frac{|a_{ij}|}{|a_{ii}|}, \quad L = \max\{L_i\}$$

则有

$$\left| x_i^{(k+1)} - x_i^* \right| \leq L \max_{1 \leq j \leq n} |x_j^{(k)} - x_j^*|$$

则有

$$\|y^{(k+1)}\|_{\infty} \leq L \|y^{(k)}\|_{\infty} \leq \dots \leq L^{k+1} \|y^{(0)}\|_{\infty}$$

由于 A 严格对角占优， $L < 1$ ，所以 $\lim_{k \rightarrow \infty} \|y^{(k+1)}\|_{\infty} = 0$ 。

Jacobi和G-S迭代法收敛性

$$\begin{aligned}\text{G-S迭代法: } |x_i^{(k+1)} - x_i^*| &= \left| \sum_{j=1}^{i-1} \frac{a_{ij}}{a_{ii}} (x_j^{(k+1)} - x_j^*) + \sum_{j=i+1}^n \frac{a_{ij}}{a_{ii}} (x_j^{(k)} - x_j^*) \right| \\ &\leq \left| \sum_{j=1}^{i-1} \left| \frac{a_{ij}}{a_{ii}} \right| |x_j^{(k+1)} - x_j^*| + \sum_{j=i+1}^n \left| \frac{a_{ij}}{a_{ii}} \right| |x_j^{(k)} - x_j^*| \right|\end{aligned}$$

$$\text{令} \quad L_i = \sum_{j=1}^{i-1} \left| \frac{a_{ij}}{a_{ii}} \right|, \quad S_i = \sum_{j=i+1}^n \left| \frac{a_{ij}}{a_{ii}} \right|, \quad \frac{S}{1-L} = \max \left\{ \frac{S_i}{1-L_i} \right\}$$

$$\text{则有} \quad |x_i^{(k+1)} - x_i^*| \leq L_i \max_{1 \leq j \leq i-1} |x_j^{(k+1)} - x_j^*| + S_i \max_{i+1 \leq j \leq n} |x_j^{(k)} - x_j^*|$$

$$\text{存在} i \text{ 使得} \quad \|y^{(k+1)}\|_{\infty} \leq L_i \|y^{(k+1)}\|_{\infty} + S_i \|y^{(k)}\|_{\infty}$$

$$\text{从而} \quad \|y^{(k+1)}\|_{\infty} \leq \frac{S}{1-L} \|y^{(k)}\|_{\infty} \leq \dots \leq \left(\frac{S}{1-L} \right)^{k+1} \|y^{(0)}\|_{\infty}$$

由于 A 严格对角占优, $L + S < 1$, 所以 $\lim_{k \rightarrow \infty} \|y^{(k+1)}\|_{\infty} = 0$.

Jacobi迭代法的Matlab程序

```
1 function [x,k,err,time]=mjacobi(A,b,x,tol,max_it)
2 -
3 -     if nargin<5
4 -         max_it=1000;
5 -     end
6 -     if nargin<4
7 -         tol=1.e-5;
8 -     end
9 -     if nargin<3
10 -         x=zeros(length(b),1);
11 -     end
12 -     tic;
13 -     bnorm2=norm(b);
14 -     r=b-A*x;
15 -     err=norm(r)/bnorm2;
16 -     if (err<tol)
17 -         return;
18 -     end
19 -     D=diag(diag(A));
20 -     for k=1:max_it
21 -         x=D\((D-A)*x+b);
22 -         r=b-A*x;
23 -         err=norm(r)/bnorm2;
24 -         if (err<=tol)
25 -             break;
26 -         end
27 -     end
28 -     time=toc;
```

这里的A最好是按照稀疏格式输入的。命令sparse(A)可将A按照稀疏格式存储

如果A本身很稀疏但没有按照稀疏格式储存,那么当n不够大(如一万以内)或者迭代次数比较多(如大于一百)时,该代码计算效率可能不如在for循环之前先计算出M和g(M在Jacobi法中依然稀疏但在其它法中可能稠密)

如果A本身不是很稀疏,即使按照稀疏格式储存,该代码计算效率也可能不如在for循环之前先计算出M和g

相对残差 $\frac{\|b-Ax\|_2}{\|b\|_2}$

G-S迭代法的Matlab程序

```
1 function [x,k,err,time]=mseidel(A,b,x,tol,max_it)
2 - if nargin<5
3 -     max_it=1000;
4 - end
5 - if nargin<4
6 -     tol=1.e-5;
7 - end
8 - if nargin<3
9 -     x=zeros(length(b),1);
10 - end
11 - tic;
12 - bnorm2=norm(b);
13 - r=b-A*x;
14 - err=norm(r)/bnorm2;
15 - if (err<tol)
16 -     return;
17 - end
18 - DL=tril(A); U=-triu(A,1);
19 - for k=1:max_it
20 -     x=DL\ (U*x+b);
21 -     r=b-A*x;
22 -     err=norm(r)/bnorm2;
23 -     if (err<=tol)
24 -         break;
25 -     end
26 - end
27 - time=toc;
```

这里的 A 最好是按照稀疏格式输入的。命令`sparse(A)`可将 A 按照稀疏格式存储

该代码计算效率与 A 的规模、稀疏程度、 M 的稠密程度、是否按照稀疏格式存储、以及迭代次数有关。

单步线性定常迭代法的收敛速度

如果单步线性迭代法

$$x^{(k+1)} = Mx^{(k)} + g$$

收敛, 则误差向量满足:

$$y^{(k)} = M^k y^{(0)}.$$

$$\|y^{(k)}\| \leq \|M^k\| \|y^{(0)}\|.$$

所以通常用 $\|M^k\|$ 的大小来刻画迭代法的收敛速度。

定义

$$R_k(M) = -\frac{\ln \|M^k\|}{k},$$

为 k 次迭代的平均收敛速度。

平均收敛速度的含义:

$$\left(\frac{\|y^{(k)}\|}{\|y^{(0)}\|} \right)^{\frac{1}{k}} \leq (\|M^k\|)^{\frac{1}{k}} = e^{-R_k(M)},$$

表示误差范数在 k 次迭代中的平均(几何平均)缩减比例因子。

单步线性定常迭代法的收敛速度

如果两个迭代矩阵 G, H 满足 $R_k(G) > R_k(H) > 0$, 则对于 k 次迭代迭代而言, G 对应的迭代法比 H 对应的迭代法的收敛速度快。

如果两个迭代矩阵都是对称矩阵, 则相对容易计算并比较其收敛速度, 这是因为:

$$\|M^k\|_2 = \sqrt{\rho(M^{2k})} = \sqrt{\rho(M)^{2k}} = (\rho(M))^k.$$

$$R_k(M) = -\frac{\ln\|M^k\|_2}{k} = -\ln\rho(M).$$

一般来说, R_k 的计算很复杂。另外, 如果对于某些 k 有 $R_k(G) > R_k(H) > 0$, 而对另一些 k 有 $R_k(H) > R_k(G) > 0$, 则不方便用有限次迭代的平均收敛速度来进行比较。

此时, 可利用**渐进收敛速度**

$$R_\infty(M) = \lim_{k \rightarrow \infty} R_k(M)$$

来进行比较。

对于对称矩阵而言, 渐进收敛速度相对容易计算。

单步线性定常迭代法的收敛速度

对于非对称矩阵而言，以下定理告诉我们，其渐进收敛速度也容易计算。

定理： 设单步线性定常迭代矩阵为 M ，则有

$$R_{\infty}(M) = -\ln \rho(M).$$

证明： 只需证明 $\lim_{k \rightarrow \infty} \|M^k\|^{\frac{1}{k}} = \rho(M)$, 然后两边取负对数即可。

因为 $(\rho(M))^k = \rho(M^k) \leq \|M^k\|$,

所以 $\rho(M) \leq \|M^k\|^{\frac{1}{k}}.$

另一方面，对任给的 $\epsilon > 0$ ，考虑矩阵

$$B_{\epsilon} = \frac{1}{\rho(M) + \epsilon} M.$$

显然， $\rho(B_{\epsilon}) < 1$. 于是 $\lim_{k \rightarrow \infty} B_{\epsilon}^k = 0$. 因此存在自然数 K ，使得当 $k \geq K$

时，有 $\|B_{\epsilon}^k\| \leq 1 \Leftrightarrow \|M^k\| \leq (\rho(M) + \epsilon)^k \Leftrightarrow \|M^k\|^{\frac{1}{k}} \leq \rho(M) + \epsilon.$

单步线性定常迭代法的收敛速度

综上，对任给的 $\epsilon > 0$ ，存在自然数 K ，使得当 $k \geq K$ 时，有

$$\rho(M) \leq \|M^k\|^{\frac{1}{k}} \leq \rho(M) + \epsilon,$$

因此， $\lim_{k \rightarrow \infty} \|M^k\|^{\frac{1}{k}} = \rho(M)$.

Jacobi收敛速度 vs G-S收敛速度

根据上面定理，可通过比较迭代矩阵的谱半径大小来比较不同迭代法的渐进收敛速度。

对于 $Ax = b$ ，当 A 为严格对角占优时，G-S迭代法的收敛速度快于Jacobi迭代法的收敛速度。（可通过上级习题进行比较，这里不给出证明）

松弛迭代法

假设已经得到了 $x^{(k)}$ 以及 $x^{(k+1)}$ 的前 $i-1$ 个分量，现构造一种计算 $x_i^{(k+1)}$ 的新方法。

首先由Gauss-Seidel迭代格式得到：

$$\tilde{x}_i^{(k+1)} = \frac{1}{a_{ii}} \left(b_i - \sum_{j=1}^{i-1} a_{ij} x_j^{(k+1)} - \sum_{j=i+1}^n a_{ij} x_j^{(k)} \right)$$

松弛法是一种对G-S迭代法的线性加速方法，迭代格式为：

$$x_i^{(k+1)} = (1 - \omega) x_i^{(k)} + \omega \tilde{x}_i^{(k+1)}$$

即

$$x_i^{(k+1)} = (1 - \omega) x_i^{(k)} + \frac{\omega}{a_{ii}} \left(b_i - \sum_{j=1}^{i-1} a_{ij} x_j^{(k+1)} - \sum_{j=i+1}^n a_{ij} x_j^{(k)} \right)$$

写成矩阵形式：

$$x^{(k+1)} = (1 - \omega) x^{(k)} + \omega (D^{-1} L x^{(k+1)} + D^{-1} U x^{(k)} + D^{-1} b).$$

$$(I - \omega D^{-1} L) x^{(k+1)} = [(1 - \omega) I + \omega D^{-1} U] x^{(k)} + \omega D^{-1} b.$$

松弛迭代法

只要 D 可逆, 则 $I - \omega D^{-1}L = D^{-1}(D - \omega L)$ 可逆(为什么?). 因此有

$$D^{-1}(D - \omega L)x^{(k+1)} = D^{-1}[(1 - \omega)D + \omega U]x^{(k)} + \omega D^{-1}b.$$

$$(D - \omega L)x^{(k+1)} = [(1 - \omega)D + \omega U]x^{(k)} + \omega b$$

$$x^{(k+1)} = (D - \omega L)^{-1}[(1 - \omega)D + \omega U]x^{(k)} + \omega(D - \omega L)^{-1}b.$$

这就是松弛法的迭代公式。 ω 称为松弛因子。通过调整 ω 来加速收敛。当 $\omega = 1$ 时, 即为G-S迭代法。当 $\omega < 1$ 时, 叫做低松弛迭代法。当 $\omega > 1$ 时, 叫做超松弛迭代法, 简称SOR迭代法(Successive Over Relaxation)。

记

$$L_{\omega} = (D - \omega L)^{-1}[(1 - \omega)D + \omega U]$$

为松弛迭代法的迭代矩阵。

SOR迭代法Matlab程序

```
1 function [x,k,err,time]=msor(A,b,w,x,tol,max_it)
2 if nargin<6
3     max_it=1000;
4 end
5 if nargin<5
6     tol=1.e-5;
7 end
8 if nargin<4
9     x=zeros(length(b),1);
10 end
11 tic;
12 bnorm2=norm(b);
13 r=b-A*x;
14 err=norm(r)/bnorm2;
15 if (err<tol)
16     return;
17 end
18 D=diag(diag(A)); L=-tril(A,-1); U=-triu(A,1);
19 for k=1:max_it
20     x=(D-w*L)\(((1-w)*D+w*U)*x+w*b);
21     r=b-A*x;
22     err=norm(r)/bnorm2;
23     if (err<=tol)
24         break;
25     end
26 end
27 time=toc;
```

这里的 A 最好是按照稀疏格式输入的。命令`sparse(A)`可将 A 按照稀疏格式存储

该代码计算效率与 A 的规模、稀疏程度、 M 的稠密程度、是否按照稀疏格式存储、以及迭代次数有关。

当 $w=1$ 时，SOR法通常比GS法慢，因为会浪费大量与 w 相关的运算。因此，SOR加速效果不显著时不如直接用GS，结合作业题自行尝试

SOR迭代法的收敛性

定理： SOR迭代法收敛的充要条件是 $\rho(L_\omega) < 1$.

定理： SOR迭代法收敛的必要条件是 $0 < \omega < 2$.

证明： 因为SOR迭代法收敛，所以 $\rho(L_\omega) < 1$ 。从而

$$|\det(L_\omega)| = |\lambda_1 \lambda_2 \cdots \lambda_n| < 1,$$

其中 $\lambda_1, \lambda_2, \dots, \lambda_n$ 是 L_ω 的 n 个特征值(可能为复数)。

由于

$$L_\omega = (I - \omega D^{-1}L)^{-1}[(1 - \omega)I + \omega D^{-1}U],$$

$$\det(I - \omega D^{-1}L)^{-1} = 1,$$

$$\det[(1 - \omega)I + \omega D^{-1}U] = (1 - \omega)^n,$$

所以，

$$|\det(L_\omega)| = |(1 - \omega)^n| < 1,$$

因此必有， $0 < \omega < 2$.

SOR迭代法的收敛性

上述定理也可作为下述定理的推论。

定理：对于任意的 ω ，SOR迭代矩阵满足： $\rho(L_\omega) \geq |1 - \omega|$ 。

证明：有上面定理的证明过程知

$$|\det(L_\omega)| = |(1 - \omega)^n| = |\lambda_1 \lambda_2 \cdots \lambda_n| \leq \rho(L_\omega)^n,$$

所以， $\rho(L_\omega) \geq |1 - \omega|$ 。

定理：若系数矩阵 A 是严格对角占优的或不可约对角占优的，且松弛因子满足 $0 < \omega \leq 1$ ，则SOR迭代法收敛。

该定理的证明过程与Jacobi，G-S迭代法的收敛性证明类似，留作练习。

SOR迭代法的收敛性

定理：若系数矩阵 A 是正定矩阵，则当 $0 < \omega < 2$ 时，SOR迭代法收敛。

证明：设 λ 是 L_ω 的任一特征值， x 为对应的特征向量(可能为复数)，则有

$$(D - \omega L)^{-1}[(1 - \omega)D + \omega U]x = \lambda x,$$

$$[(1 - \omega)D + \omega L^T]x = \lambda(D - \omega L)x.$$

可得二次型：

$$x^T[(1 - \omega)D + \omega L^T]x = \lambda x^T(D - \omega L)x.$$

令

$$x^T D x = \delta, \quad x^T L x = \alpha + i\beta, \quad x^T L^T x = \alpha - i\beta, \quad x^T A x = \delta - 2\alpha.$$

由于 A 正定，易知 $\delta > 0, \delta - 2\alpha > 0$.

上述二次型变为：

$$(1 - \omega)\delta + \omega(\alpha - i\beta) = \lambda[\delta - \omega(\alpha + i\beta)]$$

两边取模得：

$$[(1 - \omega)\delta + \omega\alpha]^2 + \omega^2\beta^2 = |\lambda|^2[(\delta - \omega\alpha)^2 + \omega^2\beta^2]$$

SOR迭代法的收敛性

所以,

$$|\lambda| < 1 \Leftrightarrow [(1 - \omega)\delta + \omega\alpha]^2 + \omega^2\beta^2 - [(\delta - \omega\alpha)^2 + \omega^2\beta^2] < 0$$

$$\Leftrightarrow \omega\delta(\delta - 2\alpha)(\omega - 2) < 0$$

$$\Leftrightarrow A \text{正定且 } 0 < \omega < 2$$

证毕。

注意：取 $\omega = 1$ ，可知：如果 A 正定，那么G-S迭代法收敛。

SOR迭代法的收敛速度

松弛因子 ω 的选取对收敛速度影响极大。实际计算时，可以根据系数矩阵的性质，结合经验通过反复计算来确定松弛因子。

通过选取合适的 ω ，可以使得SOR迭代法的收敛速度比Jacobi、G-S迭代法快很多。

SSOR迭代法

SOR的迭代公式:

$$(D - \omega L)x^{(k+1)} = [(1 - \omega)D + \omega U]x^{(k)} + \omega b.$$

SOR迭代法每次迭代时是按照 $1, 2, \dots, n$ 的顺序逐个计算 $x^{(k+1)}$ 的分量。计算第 $x_i^{(k+1)}$ 时, 要利用到 $x_1^{(k+1)}, \dots, x_{i-1}^{(k+1)}$ 。

换一种思路: 按照 $n, n-1, \dots, 1$ 的顺序逐个计算 $x^{(k+1)}$ 的分量, 计算第 $x_i^{(k+1)}$ 时, 要利用到 $x_{i+1}^{(k+1)}, \dots, x_n^{(k+1)}$ 。

这时, 迭代公式变为:

$$(D - \omega U)x^{(k+1)} = [(1 - \omega)D + \omega L]x^{(k)} + \omega b.$$

与SOR迭代法相比, 相对于互换了 L, U 的位置。

SSOR迭代法

利用上述技巧可得到SSOR迭代法(Symmetric SOR)：

$$\begin{cases} (D - \omega L)x^{(k+\frac{1}{2})} = [(1 - \omega)D + \omega U]x^{(k)} + \omega b \\ (D - \omega U)x^{(k+1)} = [(1 - \omega)D + \omega L]x^{(k+\frac{1}{2})} + \omega b \end{cases}$$

这是一种两步迭代法。它相当于，每次迭代时，先按照正序计算 $x^{(k+\frac{1}{2})}$ ，再按照逆序计算 $x^{(k+1)}$ 。

SSOR迭代法的好处：

- (1) 对某些特殊问题，用SOR迭代法不收敛，但SSOR却收敛；
- (2) SOR对松弛因子非常敏感，但SSOR却不敏感。

可对SSOR方法进一步改进，比如：两步迭代采用不同的松弛因子。

练习

分别用Jacobi、G-S、SOR、SSOR求解 $Ax = b$, 其中

$$A = \begin{bmatrix} 4 & -1 & & & \\ -1 & 4 & -1 & & \\ & -1 & 4 & \ddots & \\ & & \ddots & \ddots & -1 \\ & & & -1 & 4 \end{bmatrix}_{n \times n}, \quad b = \begin{bmatrix} 3 \\ 2 \\ \vdots \\ 2 \\ 3 \end{bmatrix}$$

其精确解为 $x^* = (1, 1, \dots, 1)^T$ 。取 $n = 2^{12} - 1 = 4095$, 初始向量为零向量, 相对残差不超过 10^{-10} 。比较各种方法的迭代次数、运行时间、相对残差。(向量范数统一用2范数)

其它的松弛迭代法

Jacobi 松弛法，简称JOR迭代法。具体见课后第9题。

加速超松弛法，简称AOR迭代法。其迭代公式为：

$$x^{(k+1)} = L_{\omega,r}x^{(k)} + g_{\omega,r}$$

其中，

$$L_{\omega,r} = (D - rL)^{-1}[(1 - \omega)D + (\omega - r)L + \omega U], \quad g_{\omega,r} = \omega(D - rL)^{-1}b.$$

Jacobi、G-S、SOR、JOR都可以看作是AOR的一个特例：

- (1) 当 $r = 0, \omega = 1$ 时，AOR即为Jacobi方法；
- (2) 当 $r = 0, \omega \neq 0$ 时，AOR即为JOR方法；
- (3) 当 $r = \omega = 1$ 时，AOR即为G-S方法；
- (4) 当 $r = \omega \neq 0$ 时，AOR即为SOR方法。

类似于SSOR，AOR也可以推广到SAOR (Symmetric AOR)

作业

1 / 教材第四章习题3

2 / 课件第46页上机练习。只考虑Jacobi和G-S迭代法。(必做)

3 / 请在上例中结合G-S算法进行比较： A 是否按照系数格式存储时的差异，以及是否在for循环之前先算好 M 及 g 时的差异。通过尝试不同的 n 与迭代次数来进行比较，可以通过改变 A 的对角线元素来调整收敛所需的迭代次数。(选做)

1 / 教材第四章习题2

2 / 课件第46页上机练习。只考虑SOR和SSOR迭代法。松弛因子为 $\omega = 1.1$ 。请尝试其它的松弛因子，观察运行时间，并与之前的Jacobi，G-S方法进行比较。（必做）

另：通过改变 n 、 ω 以及 A 的对角线元素，来比较SOR相对于GS的加速效果。（选做）

3 / 请在上例中结合SOR算法进行比较： A 是否按照系数格式存储时的差异，以及是否在for循环之前先算好 M 及 g 时的差异。通过尝试不同的 n 与迭代次数来进行比较，可以通过改变 A 的对角线元素来调整收敛所需的迭代次数。（选做）