

数值计算方法

线性方程组的共轭梯度法

信息管理与工程学院
冯银波

正定线性方程组与二次规划

考虑正定线性方程组：

$$Ax = b.$$

已知有哪些求解方法？

将其转化为一个二次规划问题：

$$\min_x \varphi(x) = x^T Ax - 2b^T x$$

定理： 设 $A \in \mathbf{R}^{n \times n}$ 正定，求线性方程组 $Ax = b$ 的解等价求 $\varphi(x)$ 的极小值点。

正定线性方程组与二次规划

证明：求 $\varphi(x)$ 的梯度：

$$\text{grad } \varphi(x) = 2(Ax - b).$$

可知，若 $\varphi(x)$ 在 x^* 处达到极小，则必有 $Ax = b$.

反过来，若 $Ax^* = b$ ，则对任一向量 y 有

$$\begin{aligned}\varphi(x^* + y) &= (x^* + y)^T A(x^* + y) - 2b^T(x^* + y) \\ &= (x^*)^T Ax^* - 2b^T x^* + y^T Ay \\ &= \varphi(x^*) + y^T Ay.\end{aligned}$$

当 A 正定时，有 $y^T Ay \geq 0$ ，因此 $\varphi(x^* + y) \geq \varphi(x^*)$ ，即 x^* 使得 $\varphi(x)$ 达到极小。

盲人下山法

对于求极小值问题，通常的做法是：给定初始点 x_0 ，从 x_0 出发，寻找使得目标函数值下降的方向 p_0 ，然后在直线 $x = x_0 + \alpha p_0$ 上寻找下一个点

$$x_1 = x_0 + \alpha_0 p_0,$$

使得关于 α 的函数 $\varphi(x_0 + \alpha p_0)$ 在 α_0 处达到极小。也就是说 x_1 是 $\varphi(x)$ 在这条直线上的极小值点，但不一定是整个空间上的极小值点。

然后，从 x_1 出发，寻找使得目标函数值下降的方向 p_1 ，然后在直线 $x = x_1 + \alpha p_1$ 上寻找下一个点 $x_2 = x_1 + \alpha_1 p_1$ ，使得 $\varphi(x_1 + \alpha p_1)$ 在 α_1 处达到极小。

重复下去，便得到一串

$$p_0, p_1, \dots, p_k, \dots \text{ 和 } \alpha_0, \alpha_1, \dots, \alpha_k, \dots$$

称 p_k 为搜索方向， α_k 为步长， $\{x_k\}$ 为迭代序列。

盲人下山法

假设经过 k 步迭代得到了 x_k ，接下来需要选定下一步的搜索方向和步长，选定的方法有很多种。假设搜索方向 p_k 已选定，我们先给出一种确定步长 α_k 的方法。

$$\begin{aligned}\text{令} \quad f(\alpha) &= \varphi(x_k + \alpha p_k) \\ &= (x_k + \alpha p_k)^T A(x_k + \alpha p_k) - 2b^T(x_k + \alpha p_k) \\ &= \alpha^2 p_k^T A p_k - 2\alpha(b - Ax_k)^T p_k + \varphi(x_k) \\ &= \alpha^2 p_k^T A p_k - 2\alpha r_k^T p_k + \varphi(x_k)\end{aligned}$$

易知， $f(\alpha)$ 的极小值点为

$$\alpha_k = \frac{r_k^T p_k}{p_k^T A p_k}.$$

于是 $x_{k+1} = x_k + \alpha_k p_k$.

那么， $\varphi(x_{k+1})$ 是否比 $\varphi(x_k)$ 小？这肯定与 p_k 的选取有关。

最速下降法

因为

$$\begin{aligned}\varphi(x_{k+1}) - \varphi(x_k) &= \varphi(x_k + \alpha_k p_k) - \varphi(x_k) \\ &= \alpha_k^2 p_k^T A p_k - 2\alpha_k r_k^T p_k \\ &= -\frac{(r_k^T p_k)^2}{p_k^T A p_k}\end{aligned}$$

所以, 只要 $r_k^T p_k \neq 0$, 就一定有 $\varphi(x_{k+1}) < \varphi(x_k)$ 。

可见 p_k 的选取很重要。最简单的做法就是选取 p_k 为负梯度方向, 即

$$p_k = -r_k.$$

于是得到最速下降法:

$$p_k = -r_k = b - Ax_k, \quad \alpha_k = \frac{r_k^T r_k}{r_k^T A r_k}, \quad x_{k+1} = x_k + \alpha_k p_k.$$

最速下降法

算法：（解正定方程组：最速下降法）

$x_0 =$ 初值;

$r_0 = b - Ax_0$;

$k = 0$;

while $r_k \neq 0$ 实际编程中，当 r_k 足够小时即可停止迭代

$k = k + 1$;

$\alpha_{k-1} = r_{k-1}^T r_{k-1} / (r_{k-1}^T A r_{k-1})$;

$x_k = x_{k-1} + \alpha_{k-1} r_{k-1}$;

$r_k = b - Ax_k$;

end

所谓“最速”下降法，不代表下降速度最快，只是每一个搜索方向都是局部下降最快的方向。

最速下降法收敛定理

引理： 设正定矩阵 A 的特征值为 $0 < \lambda_1 \leq \dots \leq \lambda_n$, $P(t)$ 是一个 t 的多项式, 则

$$\|P(A)x\|_A \leq \max_{1 \leq i \leq n} |P(\lambda_i)| \cdot \|x\|_A, \quad \forall x \in \mathbf{R}^n,$$

其中 $\|x\|_A = \sqrt{x^T A x}$.

证明： 设 $y_1, \dots, y_n$ 是 A 对应于特征值 $\lambda_1, \dots, \lambda_n$ 的特征向量所构成的 $\mathbf{R}^n$ 上的一组标准正交基, 则对任意的 $x \in \mathbf{R}^n$, 有 $x = \sum_{i=1}^n \beta_i y_i$, 从而有

$$\begin{aligned} x^T P(A) A P(A) x &= \left(\sum_{i=1}^n \beta_i P(A) y_i \right)^T A \left(\sum_{i=1}^n \beta_i P(A) y_i \right) \\ &= \left(\sum_{i=1}^n \beta_i P(\lambda_i) y_i \right)^T A \left(\sum_{i=1}^n \beta_i P(\lambda_i) y_i \right) \\ &= \sum_{i=1}^n \lambda_i \beta_i^2 P^2(\lambda_i) \leq \max_{1 \leq i \leq n} P(\lambda_i)^2 \sum_{i=1}^n \lambda_i \beta_i^2 \\ &= \max_{1 \leq i \leq n} P(\lambda_i)^2 x^T A x. \end{aligned}$$

于是得证。

最速下降法收敛定理

定理： 设正定矩阵 A 的特征值为 $0 < \lambda_1 \leq \dots \leq \lambda_n$ ，则由上述算法产生的序列 $\{x_k\}$ 满足

$$\|x_k - x^*\|_A \leq \left(\frac{\lambda_n - \lambda_1}{\lambda_n + \lambda_1} \right)^k \|x_0 - x^*\|_A,$$

其中 $x^* = A^{-1}b$, $\|x\|_A = \sqrt{x^T A x}$.

证明： 已知 x_k 满足

$$\varphi(x_k) \leq \varphi(x_{k-1} + \alpha r_{k-1}), \quad \alpha \in \mathbf{R}$$

$$(x_k - x^*)^T A (x_k - x^*) = \varphi(x_k) + (x^*)^T A x^*,$$

$$\begin{aligned} \text{所以} \quad (x_k - x^*)^T A (x_k - x^*) &\leq \varphi(x_{k-1} + \alpha r_{k-1}) + (x^*)^T A x^* \\ &= (x_{k-1} + \alpha r_{k-1} - x^*)^T A (x_{k-1} + \alpha r_{k-1} - x^*) \\ &= (x_{k-1} + \alpha A(x^* - x_{k-1}) - x^*)^T A (x_{k-1} + \alpha A(x^* - x_{k-1}) - x^*) \\ &= [(I - \alpha A)(x_{k-1} - x^*)]^T A [(I - \alpha A)(x_{k-1} - x^*)]. \end{aligned}$$

注意上式对任意的 α 都成立.

最速下降法收敛定理

记 $P_\alpha(t) = 1 - \alpha t$, 由上述引理, 可得

$$\begin{aligned}\|x_k - x^*\|_A &\leq \|P_\alpha(A)(x_{k-1} - x^*)\|_A \\ &\leq \max_{1 \leq i \leq n} |P_\alpha(\lambda_i)| \cdot \|x_{k-1} - x^*\|_A\end{aligned}$$

对一切 α 都成立。再利用以下性质:

$$\min_{\alpha} \max_{\lambda_1 \leq t \leq \lambda_n} |1 - \alpha t| = \frac{\lambda_n - \lambda_1}{\lambda_n + \lambda_1}$$

参考Chebyshev多项式及其性质


便得到

$$\begin{aligned}\|x_k - x^*\|_A &\leq \frac{\lambda_n - \lambda_1}{\lambda_n + \lambda_1} \|x_{k-1} - x^*\|_A, \\ &\leq \left(\frac{\lambda_n - \lambda_1}{\lambda_n + \lambda_1} \right)^k \|x_0 - x^*\|_A.\end{aligned}$$

最速下降法收敛定理

有上述定理知，从任一初始向量出发，最速下降法总是收敛的，且极限点等于线性方程组的解。收敛速度由 $\frac{\lambda_n - \lambda_1}{\lambda_n + \lambda_1}$ 来决定。

当 $\lambda_1 \ll \lambda_n$ 时，收敛速度变得非常慢。思考这是为什么？



注意， r_k 与 p_{k-1} 正交， p_{k-1} 与 x_k 所在的等值线相切。可由迭代公式进行验证

共轭梯度法

负梯度方向虽然从局部看是最快的下降方向，但是从整体看却不一定。
共轭梯度法做出了改进。

给定初始向量 x_0 ，第一步仍选取负梯度方向作为搜索方向，即 $p_0 = r_0$ ，
步长的选取和最速下降法一样。于是有

$$\begin{aligned}\alpha_0 &= \frac{r_0^T r_0}{r_0^T A r_0} \\ x_1 &= x_0 + \alpha_0 p_0, \\ r_1 &= b - A x_1.\end{aligned}$$

从第二步开始，不再选取负梯度方向作为搜索方向。而是在经过点 x_k 由
向量 r_k 和 p_{k-1} 所张成的二维平面

$$\pi_2 = \{x = x_k + \xi r_k + \eta p_{k-1}\}$$

上寻找下降方向和下一个迭代点。

共轭梯度法

考虑 $\varphi(x)$ 在平面 π_2 上的求极小值问题：

$$\psi(\xi, \eta) = \varphi(x_k + \xi r_k + \eta p_{k-1})$$

$$= (x_k + \xi r_k + \eta p_{k-1})^T A(x_k + \xi r_k + \eta p_{k-1}) - 2b^T(x_k + \xi r_k + \eta p_{k-1}).$$

一阶条件：

$$\frac{\partial \psi(\xi, \eta)}{\partial \xi} = 2(\xi r_k^T A r_k + \eta r_k^T A p_{k-1} - r_k^T r_k) = 0$$

$$\frac{\partial \psi(\xi, \eta)}{\partial \eta} = 2(\xi r_k^T A p_{k-1} + \eta p_{k-1}^T A p_{k-1}) = 0$$

这里用到了 $r_k = b - Ax_k$ 以及 $r_k^T p_{k-1} = 0$ (思考为什么)。

易知， $\varphi(x)$ 在平面 π_2 上存在唯一极小值点。由一阶条件可得 ξ_0, η_0 ，该极小值点为

$$\tilde{x} = x_k + \xi_0 r_k + \eta_0 p_{k-1} = x_k + \xi_0 \left(r_k + \frac{\eta_0}{\xi_0} p_{k-1} \right) = x_k + \xi_0 p_k$$

共轭梯度法

令 $\beta_{k-1} = \frac{\eta_0}{\xi_0}$, 由第二个一阶条件可得

$$\beta_{k-1} = \frac{\eta_0}{\xi_0} = -\frac{r_k^T A p_{k-1}}{p_{k-1}^T A p_{k-1}}$$

选取所搜方向:

$$p_k = r_k + \beta_{k-1} p_{k-1}$$


步长的选取方法和最速下降法一样, 即

$$\alpha_k = \frac{r_k^T p_k}{p_k^T A p_k}.$$

这样便得到下一个迭代点:

$$x_{k+1} = x_k + \alpha_k p_k.$$

可以验证 $\alpha_k = \xi_0$, 即 $x_{k+1} = x_k + \xi_0 r_k + \eta_0 p_{k-1}$



知乎 @小小何先生

共轭梯度法

综上，第 $k+1$ 次迭代所需要计算的内容如下：

$$\beta_{k-1} = -\frac{r_k^T A p_{k-1}}{p_{k-1}^T A p_{k-1}}$$

$$p_k = r_k + \beta_{k-1} p_{k-1}$$

$$\alpha_k = \frac{r_k^T p_k}{p_k^T A p_k}$$

$$x_{k+1} = x_k + \alpha_k p_k$$

$$r_{k+1} = b - A x_{k+1}.$$

上述计算包含多次矩阵和向量的乘法运算，甚至是重复计算。可以进行简化。简化之前先给出以下性质。

举例

例：求解线性方程组 $Ax = b$ ，其中


$$A = \begin{bmatrix} 3 & 2 \\ 2 & 6 \end{bmatrix}, b = \begin{bmatrix} 2 \\ -8 \end{bmatrix}.$$

等价于求解下列二次函数的极小值：


$$\begin{aligned} \varphi(x) &= \frac{1}{2} x^T A x - b^T x \\ &= \frac{3}{2} x_1^2 + 2x_1 x_2 + 3x_2^2 - 2x_1 + 8x_2 \end{aligned}$$

精确解为： $x^* = (2, -2)^T$


举例



$\varphi(x)$



等值线



$\varphi'(x)$


举例

最速下降法:

$$p_k = r_k = b - Ax_k$$

$$\alpha_k = \frac{r_k^T r_k}{r_k^T A r_k}$$

$$x_{k+1} = x_k + \alpha_k p_k$$



k	0	1	2	3	4	5
x_k	$\begin{pmatrix} -2 \\ -2 \end{pmatrix}$	$\begin{pmatrix} 0.08 \\ -0.6133 \end{pmatrix}$	$\begin{pmatrix} 1.0044 \\ -2 \end{pmatrix}$	$\begin{pmatrix} 1.5221 \\ -1.6549 \end{pmatrix}$	$\begin{pmatrix} 1.7522 \\ -2 \end{pmatrix}$	$\begin{pmatrix} 1.8811 \\ -1.9141 \end{pmatrix}$

举例

共轭梯度法:


$$\beta_{k-1} = -\frac{r_k^T A p_{k-1}}{p_{k-1}^T A p_{k-1}}$$

$$p_k = r_k + \beta_{k-1} p_{k-1}$$

$$\alpha_k = \frac{r_k^T p_k}{p_k^T A p_k}$$

$$x_{k+1} = x_k + \alpha_k p_k$$

$$r_{k+1} = b - A x_{k+1}$$



k	0	1	2
x_k	$\begin{pmatrix} -2 \\ -2 \end{pmatrix}$	$\begin{pmatrix} 0.08 \\ -0.6133 \end{pmatrix}$	$\begin{pmatrix} 2 \\ -2 \end{pmatrix}$

共轭梯度法

定理：由共轭梯度法得到的向量组 $\{r_i\}$ 和 $\{p_i\}$ 具有以下性质：

$$(1) p_i^T r_j = 0, \quad 0 \leq i < j \leq k;$$

$$(2) r_i^T r_j = 0, \quad i \neq j, \quad 0 \leq i < j \leq k;$$

$$(3) p_i^T A p_j = 0, \quad i \neq j, \quad 0 \leq i < j \leq k;$$

$$(4) \text{span}\{r_0, r_1, \dots, r_k\} = \text{span}\{p_0, p_1, \dots, p_k\} = \mathcal{K}(A, r_0, k+1), \text{ 其中}$$

$$\mathcal{K}(A, r_0, k+1) = \text{span}\{r_0, A r_0, \dots, A^k r_0\}$$

称为Krylov子空间.

证明：对(1)-(4)均采用数学归纳法。当 $k=1$ 时，

$$p_0 = r_0, \quad r_1 = r_0 - \alpha_0 A p_0, \quad p_1 = r_1 + \beta_0 p_0, \quad \beta_0 = -\frac{r_1^T A p_0}{p_0^T A p_0}$$

易验证(1)-(4)均成立。假设对 k 成立，下证明对 $k+1$ 成立。

共轭梯度法

(1) 有 $r_{k+1} = b - Ax_{k+1}$ 和 $x_{k+1} = x_k + \alpha_k p_k$ 得

$$r_{k+1} = r_k - \alpha_k A p_k.$$

于是

$$p_i^T r_{k+1} = p_i^T r_k - \alpha_k p_i^T A p_k = 0, \quad 0 \leq i \leq k-1.$$

由于

$$p_k^T r_{k+1} = p_k^T r_k - \frac{r_k^T p_k}{p_k^T A p_k} p_k^T A p_k = 0,$$

故(1)对k+1成立。

(2) 由归纳假设知

$$\text{span}\{r_0, r_1, \dots, r_k\} = \text{span}\{p_0, p_1, \dots, p_k\}$$

再由(1)的结论知, r_{k+1} 与 $\text{span}\{p_0, p_1, \dots, p_k\}$ 正交, 故也与 $\text{span}\{r_0, r_1, \dots, r_k\}$ 正交。因此, (2)对k+1成立。

共轭梯度法

(3) 利用等式

$$p_{k+1} = r_{k+1} + \beta_k p_k \text{ 和 } r_{i+1} = r_i - \alpha_i A p_i,$$

并利用归纳假设和(2)的结论, 有

$$p_i^T A p_{k+1} = \frac{1}{\alpha_i} r_{k+1}^T (r_i - r_{i+1}) + \beta_k p_i^T A p_k = 0, \quad 0 \leq i \leq k-1$$

又因为

$$p_{k+1}^T A p_k = (r_{k+1} + \beta_k p_k)^T A p_k = r_{k+1}^T A p_k - \frac{r_{k+1}^T A p_k}{p_k^T A p_k} p_k^T A p_k = 0,$$

故(3)对 $k+1$ 成立。

(4) 由归纳假设以及 $p_{k+1} = r_{k+1} + \beta_k p_k$, 易知

$$\text{span}\{r_0, r_1, \dots, r_k, r_{k+1}\} = \text{span}\{p_0, p_1, \dots, p_k, p_{k+1}\}.$$

共轭梯度法

另一方面,

$$\begin{aligned}\text{span}\{r_0, Ar_0, \dots, A^k r_0\} &= \text{span}\{r_0, A * \text{span}\{r_0, \dots, A^{k-1} r_0\}\} \\ &= \text{span}\{r_0, A * \text{span}\{r_0, r_1, \dots, r_k\}\} \\ &= \text{span}\{r_0, A * \text{span}\{p_0, p_1, \dots, p_k\}\}\end{aligned}$$

因为 $Ap_i = \frac{1}{\alpha_i}(r_i - r_{i+1})$, 所以

$$\begin{aligned}\text{上式} &= \text{span}\{r_0, \text{span}\{r_0 - r_1, r_1 - r_2, \dots, r_k - r_{k+1}\}\} \\ &= \text{span}\{r_0, r_1, \dots, r_{k+1}\}\end{aligned}$$

故 (4) 对 $k+1$ 成立。

共轭梯度法

如果 $p_i^T A p_j = 0$ ，则称 p_i 与 p_j 共轭。

上述定理表明：向量组 $\{r_i\}_{i=1}^k$ 和 $\{p_i\}_{i=1}^k$ 分别是 Krylov 子空间 $\mathcal{K}(A, r_0, k+1)$ 的正交基和共轭正交基。由此(大概)可知，共轭梯度法最多 n 步就可以得到解。(有没有可能小于 n 步?)

利用上述性质，对共轭梯度的计算过程进行简化：

$$\begin{aligned} r_{k+1}^T A p_k &= \frac{1}{\alpha_k} r_{k+1}^T (r_k - r_{k+1}) = -\frac{1}{\alpha_k} r_{k+1}^T r_{k+1} \\ p_k^T A p_k &= \frac{1}{\alpha_k} p_k^T (r_k - r_{k+1}) = \frac{1}{\alpha_k} p_k^T r_k \\ &= \frac{1}{\alpha_k} r_k (r_k + \beta_{k-1} p_{k-1}) = \frac{1}{\alpha_k} r_k^T r_k. \end{aligned}$$

于是可得：

$$\beta_{k-1} = \frac{r_k^T r_k}{r_{k-1}^T r_{k-1}}, \quad \alpha_k = \frac{r_k^T r_k}{p_k^T A p_k}$$

共轭梯度法

算法：（解正定方程组：共轭梯度法）

$x_0 = \text{初值};$

$r_0 = b - Ax_0;$

$k = 0;$

while $r_k \neq 0$

$k = k + 1;$

 if $k = 1$

$p_0 = r_0;$

 else

$\beta_{k-2} = r_{k-1}^T r_{k-1} / r_{k-2}^T r_{k-2};$

$p_{k-1} = r_{k-1} + \beta_{k-2} p_{k-2};$

 end

$\alpha_{k-1} = r_{k-1}^T r_{k-1} / p_{k-1}^T A p_{k-1};$

$x_k = x_{k-1} + \alpha_{k-1} p_{k-1};$

$r_k = r_{k-1} - \alpha_{k-1} A p_{k-1};$

end

$x = x_k;$

每次迭代，只需要一次矩阵与向量的乘积运算

更深层次地理解共轭梯度法

$$x_k = x_0 + \alpha_0 p_0 + \alpha_1 p_1 + \cdots + \alpha_{k-1} p_{k-1}$$

$$x^* = x_0 + \alpha_0 p_0 + \alpha_1 p_1 + \cdots + \alpha_{k-1} p_{k-1} + \cdots$$

1. 最速下降法可以保证每一步的搜索方向 p_k 和上一步的 p_{k-1} 正交，由于该方法只关心“眼前”，所以很难保证这些 p_k 之间是线性不相关的，有可能会像第10页的例子中那样，使得 x_k 趋于 x^* 的过程“非常曲折”。
2. 共轭梯度法可以保证各步的搜索方向是共轭正交的，它们可以构成整个空间的一组基，因此 $x^* - x_0$ 一定可以写成这些 p_k 的线性组合，故从 x_0 出发最多 n 步可以得到 x^* 。
3. 理解：共轭梯度法中， $\{r_0, r_1, \dots, r_k\}$ 其实是 $\{p_0, p_1, \dots, p_k\}$ 的正交化。

提示：由递推公式 $p_k = r_k + \beta_{k-1} p_{k-1}$ 和 $p_0 = r_0$ 知， p_k 是 $\{r_0, r_1, \dots, r_k\}$ 的线性组合，而 p_{k-1} 是 $\{r_0, r_1, \dots, r_{k-1}\}$ 的线性组合。又由于 r_k 与 p_{k-1} 正交，可知 p_k 在 $\{r_0, r_1, \dots, r_{k-1}\}$ 上的投影的方向就是 p_{k-1} ， p_k 减去这些投影之后就是 r_k

更深层次地理解共轭梯度法

4. 理解：共轭梯度法中， $\{p_0, p_1, \dots, p_k\}$ 其实是 $\{r_0, r_1, \dots, r_k\}$ 的共轭正交化。

提示：
$$p_k = r_k + \beta_{k-1}p_{k-1}, \quad \beta_{k-1} = -\frac{r_k^T A p_{k-1}}{p_{k-1}^T A p_{k-1}}$$

r_k 减去它在 $\{p_0, p_1, \dots, p_{k-1}\}$ 上的共轭正交投影，即 $\frac{r_k^T A p_{k-1}}{p_{k-1}^T A p_{k-1}} p_{k-1}$ 之后，便可得到 p_k

更深层次地理解共轭梯度法

5. 定理：用共轭梯度法得到的近似解 x_k 满足：

$$\varphi(x_k) = \min\{\varphi(x) : x \in x_0 + \mathcal{K}(A, r_0, k)\},$$

$$\|x_k - x^*\|_A = \min\{\|x - x^*\|_A : x \in x_0 + \mathcal{K}(A, r_0, k)\},$$

其中 $x^* = A^{-1}b$, $\|x\|_A = \sqrt{x^T A x}$. $\mathcal{K}(A, r_0, k)$ 是 Krylov 子空间。

证明：因为

$$\|x_k - x^*\|_A^2 = (x_k - x^*)^T A (x_k - x^*) = \varphi(x_k) + (x^*)^T A x^*,$$

所以只需证

$$\|x_k - x^*\|_A = \min\{\|x - x^*\|_A : x \in x_0 + \mathcal{K}(A, r_0, k)\}.$$

假设共轭梯度法计算到第 l 步出现 $r_l = 0$. 那么有

$$x^* = x_0 + \alpha_0 p_0 + \alpha_1 p_1 + \cdots + \alpha_{l-1} p_{l-1}.$$

更深层次地理解共轭梯度法

对于中间某一步迭代结果有：

$$x_k = x_0 + \alpha_0 p_0 + \alpha_1 p_1 + \cdots + \alpha_{k-1} p_{k-1}.$$

所以有：

$$x^* - x_k = \alpha_k p_k + \cdots + \alpha_{l-1} p_{l-1}.$$

对于任意的 $x \in x_0 + \mathcal{K}(A, r_0, k)$, 有

$$x = x_0 + \gamma_0 p_0 + \gamma_1 p_1 + \cdots + \gamma_{k-1} p_{k-1}.$$

所以有：

$$\begin{aligned} x^* - x &= (\alpha_0 - \gamma_0) p_0 + (\alpha_1 - \gamma_1) p_1 + \cdots + (\alpha_{k-1} - \gamma_{k-1}) p_{k-1} \\ &\quad + \alpha_k p_k + \cdots + \alpha_{l-1} p_{l-1}. \end{aligned}$$

比较 $x^* - x_k$ 与 $x^* - x$ 可知：

$$\begin{aligned} \|x^* - x\|_A^2 &= \|(\alpha_0 - \gamma_0) p_0 + (\alpha_1 - \gamma_1) p_1 + \cdots + (\alpha_{k-1} - \gamma_{k-1}) p_{k-1}\|_A^2 \\ &\quad + \|\alpha_k p_k + \cdots + \alpha_{l-1} p_{l-1}\|_A^2 \\ &\geq \|\alpha_k p_k + \cdots + \alpha_{l-1} p_{l-1}\|_A^2 = \|x^* - x_k\|_A^2. \end{aligned}$$

实用共轭梯度法

共轭梯度法理论上 n 步可以得到精确解。当 n 很大时，耗费时间很长。另外，由于误差的影响， r_k 之间的正交性很快损失，也就是说，实际上， n 步不一定能得到精确解。所以在实际使用中，通常采用实用共轭梯度法。

实用共轭梯度法

算法：（解正定方程组：实用共轭梯度法）

$x = \text{初值};$

$r = b - Ax; \quad k = 0; \quad \rho = r^T r;$

while $(\sqrt{\rho} > \varepsilon \|b\|_2)$ **and** $(k < k_{max})$

$k = k + 1;$

if $k = 1$

$p = r;$

else

$\beta = \rho / \tilde{\rho}; \quad p = r + \beta p;$

end

$w = Ap; \quad \alpha = \rho / (p^T w); \quad x = x + \alpha p;$

$r = r - \alpha w; \quad \tilde{\rho} = \rho; \quad \rho = r^T r;$

end

共轭梯度法的收敛性

定理： 用共轭梯度法得到 x_k 的误差满足：

$$\|x_k - x^*\|_A \leq 2 \left(\frac{\sqrt{\kappa_2} - 1}{\sqrt{\kappa_2} + 1} \right)^k \|x_0 - x^*\|_A,$$

其中 $\kappa_2 = \kappa_2(A) = \|A\|_2 \|A^{-1}\|_2 = \frac{\lambda_{\max}(A^T A)}{\lambda_{\min}(A^T A)}$ 。

证明： (略，见教材)。

该定理表明：当系数矩阵十分良态时，共轭梯度法收敛很快

再结合课后第7、8题可知：当正定的系数矩阵仅有少数几个互异的特征值（每个特征值可能为重根）时，不考虑误差的情形下共轭梯度法只需要少数几次迭代便可收敛到精确解。

共轭梯度法专门用于求解大型稀疏正定线性方程组。在科学工程计算中极其常见（电磁仿真、气候模拟、地球物理反演、热传导方程等）。

预优共轭梯度法

预优共轭梯度法的思路是：寻找正定矩阵 C 使得 $C^{-1}AC^{-1}$ 具有良好的性质：条件数比较小（接近于1），谱相对集中。然后，原线性方程组等价于：

$$C^{-1}AC^{-1} * Cx = C^{-1}b.$$

注意， $C^{-1}AC^{-1}$ 与 $(C^{-1})^2A$ 相似，因此只要选取正定矩阵 M 使得 $M^{-1}A$ 具有良好的性质即可，因为正定矩阵 M 可以表示成另一个正定矩阵 C 的平方。

M 的选取方法有很多种，比如： M 可取 A 对角元所构成的矩阵，这种做法称为Jacobi预处理，它与Jacobi古典迭代法的思路相似；而Gauss-Seidel迭代法和SOR迭代法的思路却不能用在这里，因为它们所对应的 M 矩阵不是对称的。

预优共轭梯度法的具体求解过程这里不再赘述，请参考教材第5.4节。

Lanczos Method

思考：共轭梯度法为什么需要 A 正定？如果 A 只对称不正定，那应该如何求解 $Ax = b$ ？

可使用 **Lanczos Method**。其大题思路如下：

6. 共轭梯度法：

$$x^* - x_0 = \alpha_0 p_0 + \alpha_1 p_1 + \cdots + \alpha_n p_n \triangleq P\alpha$$

$$A(x^* - x_0) = AP\alpha, \quad A(x^* - x_0) = b - Ax_0 = r_0 = AP\alpha$$

$$P^T AP\alpha = P^T r_0$$

注意： $p_i^T A p_j = 0, i \neq j$ 。可知， $P^T AP$ 是个对角矩阵。因此共轭梯度法可以理解成：寻找一个矩阵 P （它是由每步的 p_k 构成的矩阵，各列共轭正交），使得 $P^T AP$ 为对角阵， A 的正定性保证了该对角矩阵满秩，再通过求解一个对角线性方程组计算出 α （它由每步的步长组成）。回忆 A 的 LDL 分解及与共轭梯度法的关系。

Lanczos Method 的大题思路是：寻找一个正交矩阵 Q 使得 $Q^T A Q$ 为三对角阵，再通过求解 $Q^T A Q \alpha = Q^T r_0$ 计算出 α 。回忆追赶法求解三对角线性方程组。

作业

1 / 教材第五章习题5、6

2 / (选做) 教材第五章习题7、8

3 / 用共轭梯度法求解线性方程组 $Ax = b$, 其中

$$A = \begin{bmatrix} 1 & 0 \\ 0 & 2 \end{bmatrix}, \quad b = \begin{bmatrix} 1 \\ 2 \end{bmatrix},$$

初始向量 $x_0 = (0, 0)^T$ 。

1 / 用实用共轭梯度法编程求解线性方程组 $Ax = b$, 其中

$$A = \begin{bmatrix} 1 & -1 & & & \\ -1 & 2 & -1 & & \\ & -1 & 3 & \ddots & \\ & & \ddots & \ddots & -1 \\ & & & -1 & n \end{bmatrix}, \quad b = \begin{bmatrix} 0 \\ 0 \\ 1 \\ 2 \\ \vdots \\ n-3 \\ n-1 \end{bmatrix}$$

$n = 1000$. 初始向量 $x_0 = (0,0)^T$. 要求相对残差不超过 10^{-10} . 给出计算解、迭代次数、运行时间。

2 / 思考：将线性方程组 $Ax = b$ 或最小二乘问题 $\min_x \|b - Ax\|_2^2$ 转化为二次规划 $\min_x x^T A^T A x - 2b^T A x + b^T b$ 是否总是划算的？（不用交）