

数值计算方法

矩阵特征值的求解方法

信息管理与工程学院
冯银波

基本概念

在科学技术的应用领域中，许多问题都归为求解一个特征系统。如动力学系统和结构系统中的振动问题，求系统的频率与振型；物理学中的某些临界值的确定等等。

设 A 为 n 阶方阵， $A \in \mathbf{R}^{n \times n}$ ，若存在非零向量 x 以及数 λ 使得

$$Ax = \lambda x,$$

其中， x 、 λ 可能为复向量或复数，这时称 λ 为 A 的**特征值**， x 为 A 的属于 λ 的**特征向量**。

矩阵的特征值问题包含两个方面：

(1) 求特征值 λ 使得

$$p_A(\lambda) = \det(\lambda I - A) = 0,$$

这里， $p_A(\lambda)$ 称为 A 的**特征多项式**。

(2) 求特征向量 x 使得

$$(\lambda I - A)x = 0.$$

基本性质

定义： 设 $A, B \in \mathbf{R}^{n \times n}$, 若存在可逆矩阵 P 使得

$$B = P^{-1}AP,$$

则称 A 与 B 相似。

若 A 与 B 相似, 则 A 与 B 有相同的特征值, 而且 x 是 B 的特征向量的充要条件是 Px 是 A 的特征向量。

定理： 设 $A \in \mathbf{R}^{n \times n}$ 为对称矩阵, 其特征值为 $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_n$, 则

(1) 对任意的 $x \in \mathbf{R}^{n \times n}$, $x \neq 0$,

$$\lambda_n \leq \frac{\langle Ax, x \rangle}{\langle x, x \rangle} \leq \lambda_1,$$

(2)
$$\lambda_n = \min_{x \neq 0} \frac{\langle Ax, x \rangle}{\langle x, x \rangle},$$

(3)
$$\lambda_1 = \max_{x \neq 0} \frac{\langle Ax, x \rangle}{\langle x, x \rangle}.$$

Jordan分解定理

定理 (Jordan分解定理): 设 $A \in \mathbf{R}^{n \times n}$ 有 r 个不同的特征值为 $\lambda_1, \dots, \lambda_r$, 其重数分别为 $n(\lambda_1), \dots, n(\lambda_r)$, 则必存在一个非奇异矩阵 $P \in \mathbf{C}^{n \times n}$ 使得

$$J = P^{-1}AP = \begin{bmatrix} J(\lambda_1) & & & \\ & J(\lambda_2) & & \\ & & \ddots & \\ & & & J(\lambda_r) \end{bmatrix},$$

其中, $J(\lambda_i) = \text{diag}(J_1(\lambda_i), J_2(\lambda_i), \dots, J_{k_i}(\lambda_i)) \in \mathbf{C}^{n(\lambda_i) \times n(\lambda_i)}$, $i = 1, 2, \dots, r$,

$$J_j(\lambda_i) = \begin{bmatrix} \lambda_i & 1 & & \\ & \lambda_i & \ddots & \\ & & \ddots & 1 \\ & & & \lambda_i \end{bmatrix} \in \mathbf{C}^{n_j(\lambda_i) \times n_j(\lambda_i)}, \quad j = 1, 2, \dots, k_i,$$

$$n_1(\lambda_i) + \dots + n_{k_i}(\lambda_i) = n(\lambda_i), \quad i = 1, 2, \dots, r,$$

除了 $J_j(\lambda_i)$ 顺序可以交换以外, J 是唯一确定的。

J 称作 A 的 **Jordan标准型**, $J_j(\lambda_i)$ 称作 **Jordan块**。

举例：Jordan标准型

$$\begin{bmatrix} \boxed{\begin{matrix} 2 & 1 \\ & 2 \end{matrix}} & & & & \\ & \boxed{\begin{matrix} 2 & 1 \\ & 2 \end{matrix}} & & & \\ & & \boxed{2} & & \\ & & & \boxed{\begin{matrix} 2 & 1 & \\ & 2 & 1 \\ & & 2 \end{matrix}} & \\ & & & & \boxed{\begin{matrix} 0 & 1 \\ & 0 \end{matrix}} \end{bmatrix}$$

举例：Jordan标准型

例：考虑旋转矩阵

$$A = \begin{bmatrix} 1 & 1 \\ -1 & 1 \end{bmatrix}$$

的Jordan标准型。

解：A的特征值为 $1 + i, 1 - i$ ，对应的特征向量为

$$\begin{pmatrix} -i \\ 1 \end{pmatrix}, \quad \begin{pmatrix} i \\ 1 \end{pmatrix}$$

因此A的Jordan分解为

$$\begin{bmatrix} 1+i & 0 \\ 0 & 1-i \end{bmatrix} = \begin{bmatrix} -i & i \\ 1 & 1 \end{bmatrix}^{-1} \begin{bmatrix} 1 & 1 \\ -1 & 1 \end{bmatrix} \begin{bmatrix} -i & i \\ 1 & 1 \end{bmatrix}$$

或

$$\begin{bmatrix} 1 & 1 \\ -1 & 1 \end{bmatrix} = \begin{bmatrix} -i & i \\ 1 & 1 \end{bmatrix} \begin{bmatrix} 1+i & 0 \\ 0 & 1-i \end{bmatrix} \begin{bmatrix} -i & i \\ 1 & 1 \end{bmatrix}^{-1}$$

Schur分解定理

在Jordan分解定理中，若限定 P 为酉矩阵，则有如下Schur分解定理。

定理 (Schur分解定理): 设 $A \in \mathbf{R}^{n \times n}$, 则必存在酉矩阵 $U \in \mathbf{C}^{n \times n}$ 使得

$$A = UTU^H,$$

其中， U^H 是 U 的共轭转置， T 为上三角阵，其对角元素为 A 的特征值，而且可以适当选取 U 使得 T 的对角元素任意排列。

证明思路: 先做Jordan分解 $A = PJP^{-1}$, 再对 P 做QR分解 $P = QR$, 于是

$$A = QRJR^{-1}Q^{-1} = QTQ^H.$$

例: 矩阵 $A = \begin{bmatrix} 1 & 1 \\ -1 & 1 \end{bmatrix}$ 的Schur分解:

$$\begin{bmatrix} 1 & 1 \\ -1 & 1 \end{bmatrix} = \begin{bmatrix} \frac{\sqrt{2}}{2}i & \frac{\sqrt{2}}{2} \\ -\frac{\sqrt{2}}{2} & \frac{\sqrt{2}}{2}i \end{bmatrix} \begin{bmatrix} 1+i & 0 \\ 0 & 1-i \end{bmatrix} \begin{bmatrix} \frac{\sqrt{2}}{2}i & \frac{\sqrt{2}}{2} \\ -\frac{\sqrt{2}}{2} & \frac{\sqrt{2}}{2}i \end{bmatrix}^H$$

Gerschgorin圆盘定理

定理 (Gerschgorin圆盘定理): 设 $A \in \mathbf{R}^{n \times n}$, 则

(1) 则 A 的每一个特征值必属于下列某个圆盘之中,

$$G_i(A) = \left\{ z \in \mathbf{C}: |z - a_{ii}| \leq \sum_{j \neq i} |a_{ij}| \right\}, \quad i = 1, \dots, n,$$

$G_i(A)$ 表示以 a_{ii} 为中心, 以 $\sum_{j \neq i} |a_{ij}|$ 为半径的复平面上的圆盘。

(2) 如果矩阵 A 的 m 个圆盘组成的并集 S (连通的) 与其余 $n - m$ 个圆盘不连接, 则 S 内恰包含 m 个 A 的特征值。

举例

例：估计矩阵 A 的特征值的取值范围

$$A = \begin{bmatrix} 4 & 1 & 0 \\ 1 & 0 & -1 \\ 1 & 1 & -4 \end{bmatrix}.$$

解：由原盘定理， A 的三个圆盘分别为：

$$G_1(A) = |z - 4| \leq 1,$$

$$G_2(A) = |z - 0| \leq 2,$$

$$G_3(A) = |z + 4| \leq 2.$$

为什么一定是实数？

$G_1(A)$ 是孤立圆盘，所以包含且仅包含一个实特征值， $3 \leq \lambda_1 \leq 5$.

$\lambda_2, \lambda_3 \in G_2(A) \cup G_3(A)$ ，若为实数，则必属于 $[-6, 2]$. A 的谱半径必然小于等于6。

可以计算， A 的真实特征值分别为4.2030、-3.7601、-0.4429，分别位于三个圆盘之中。

幂法

在实际工程应用中，如大型结构的振动系统中，往往要计算振动系统的最低频率（或前几个最低频率）及相应的振型，相应的数学问题便为求解矩阵的按模最大（或前几个按模最大）特征值（主特征值）及相应的特征向量问题。

幂法是计算一个矩阵的模最大特征值和对应的特征向量的一种迭代方法。幂法的计算公式如下：

设 $A \in \mathbf{R}^{n \times n}$ ，选取初始向量 $x^{(0)} \in \mathbf{R}^n$ ，令

$$x^{(k)} = Ax^{(k-1)}, \quad k = 1, 2, \dots$$

$$\text{或 } x^{(k)} = A^k x^{(0)}, \quad k = 1, 2, \dots$$

形成迭代序列 $\{x^{(k)}\}$ 。

那么， $\{x^{(k)}\}$ 是否收敛呢？它与 A 的特征向量是否有关系？

为了便于讨论，假设 A 可对角化，即 A 有 n 个不相关的特征向量。

幂法

设 A 的 n 个特征值满足 $|\lambda_1| \geq |\lambda_2| \geq \cdots \geq |\lambda_n|$, $v_1, \dots, v_n$ 为相应的特征向量, 构成的一组基底。

对任取的实初始向量 $x^{(0)}$, $x^{(0)}$ 可以表示为

$$x^{(0)} = \alpha_1 v_1 + \cdots + \alpha_n v_n$$

得到

$$\begin{aligned} x^{(k)} &= A^k x^{(0)} = \alpha_1 A^k v_1 + \cdots + \alpha_n A^k v_n \\ &= \alpha_1 \lambda_1^k v_1 + \cdots + \alpha_n \lambda_n^k v_n \\ &= \lambda_1^k \left[\alpha_1 v_1 + \sum_{j=2}^n \alpha_j \left(\frac{\lambda_j}{\lambda_1} \right)^k v_j \right]. \end{aligned}$$

下面分情况讨论。

(1) 如果 $|\lambda_1| > |\lambda_2| \geq \cdots \geq |\lambda_n|$, 且 $\alpha_1 \neq 0$, 当 k 充分大时, 有

$$x^{(k)} \approx \lambda_1^k \alpha_1 v_1, \quad \lim_{k \rightarrow \infty} \frac{x_i^{(k+1)}}{x_i^{(k)}} = \lambda_1, i = 1, \dots, n$$

幂法

可知, 对任意 i , $\frac{x_i^{(k)}}{x_i^{(k-1)}}$ 收敛到 λ_1 ; 由于我们只关心特征向量的方向而不关心其具体长度, 所以 $x^{(k)}$ 可作为 λ_1 的特征向量的近似值, 只不过 $x^{(k)}$ 的模可能趋于0或 ∞ , 为避免这一情形出现, 只需在每次迭代之后对 $x^{(k)}$ 再做一次规范化处理即可。

另外可知, 这种情况下, 迭代序列 $\{x^{(k)}\}$ 的收敛速度取决于 $\left|\frac{\lambda_2}{\lambda_1}\right|$ 的大小。

(2) 如果 $|\lambda_1| = |\lambda_2| > |\lambda_3| \cdots \geq |\lambda_n|$, 且 $\alpha_1, \alpha_2 \neq 0$, 则可分为三种情形:

$$\text{a) } \lambda_1 = \lambda_2, \quad \text{b) } \lambda_1 = -\lambda_2, \quad \text{c) } \lambda_1 = \overline{\lambda_2}$$

情形 a). 如果 $\lambda_1 = \lambda_2$, 当 k 充分大时, 有

$$x^{(k)} \approx \lambda_1^k (\alpha_1 v_1 + \alpha_2 v_2), \quad \lim_{k \rightarrow \infty} \frac{x_i^{(k+1)}}{x_i^{(k)}} = \lambda_1, i = 1, \dots, n$$

依然有: 对任意 i , $\frac{x_i^{(k)}}{x_i^{(k-1)}}$ 收敛到 λ_1 , $x^{(k)}$ 可作为 λ_1 的特征向量的近似值。

幂法

情形 b). 如果 $\lambda_1 = -\lambda_2$, 当 k 充分大时, 有

$$x^{(k)} \approx \lambda_1^k (\alpha_1 v_1 + (-1)^k \alpha_2 v_2), \quad \lim_{k \rightarrow \infty} \frac{x_i^{(k+2)}}{x_i^{(k)}} = \lambda_1^2, i = 1, \dots, n$$

可知, 对任意 i , $\frac{x_i^{(k+2)}}{x_i^{(k)}}$ 收敛到 λ_1^2 , 每次迭代计算出 λ_1 的近似值之后, 再利用迭代序列 $\{x^{(k+1)} + \lambda_1 x^{(k)}\}$ 和 $\{x^{(k+1)} - \lambda_1 x^{(k)}\}$ 去逼近 v_1 和 v_2 。

情形 c). 如果 $\lambda_1 = \overline{\lambda_2}$, λ_1 与 λ_2 为共轭复特征值。

因为 A 是实矩阵, 所以 $A = \overline{A}$.

由
$$Av_1 = \lambda_1 v_1, \quad \overline{Av_1} = \lambda_2 \overline{v_1}, \quad \overline{Av_1} = A\overline{v_1}, \quad A\overline{v_1} = \lambda_2 \overline{v_1},$$
 得
$$v_1 = \overline{v_2}.$$

为便于分析, 令 $\lambda_1 = \rho e^{i\theta}, \lambda_2 = \rho e^{-i\theta}$ 。另外, 如果 $x^{(0)}$ 为实数, 则必有 $\alpha_1 = \overline{\alpha_2}$ 。

$$x^{(0)} = \alpha_1 v_1 + \overline{\alpha_1} \overline{v_1} + \alpha_3 v_3 + \dots + \alpha_n v_n$$

幂法

当 k 充分大时, 有

$$x^{(k)} \approx \rho^k (\alpha_1 v_1 e^{ik\theta} + \overline{\alpha_1 v_1} e^{-ik\theta}).$$

接下来考虑怎么求 ρ, θ .

令 $(\alpha_1 v_1)_j = r_j e^{i\varphi}, \quad (\overline{\alpha_1 v_1})_j = r_j e^{-i\varphi}$

有 $x_j^{(k)} \approx \rho^k (r_j e^{i(\varphi+k\theta)} + r_j e^{-i(\varphi+k\theta)})$

于是
$$\begin{aligned} x_j^{(k)} &\approx 2\rho^k r_j \cos(\varphi + k\theta) \\ x_j^{(k+1)} &\approx 2\rho^{k+1} r_j \cos(\varphi + (k+1)\theta) \\ x_j^{(k+2)} &\approx 2\rho^{k+2} r_j \cos(\varphi + (k+2)\theta) \end{aligned}$$

利用三角函数性质, 可得

$$x_j^{(k+2)} - (\lambda_1 + \lambda_2)x_j^{(k+1)} + \lambda_1\lambda_2x_j^{(k)} \approx 0.$$

幂法

注意上式对任意的 j 都成立，可通过方程组求解 λ_1 和 λ_2 的近似值。

每次迭代计算出 λ_1 和 λ_2 的近似值之后，再利用迭代序列 $\{x^{(k+1)} - \lambda_2 x^{(k)}\}$ 和 $\{x^{(k+1)} - \lambda_1 x^{(k)}\}$ 去逼近 v_1 和 v_2 。

思考：如果误把情形(2)当作情形(1)，将会发生什么？

至此，在多种情形下，得到了计算矩阵模最大的特征值及其特征向量的方法。之后，我们主要考虑情形(1)。

注意，每次迭代后，需对迭代向量 $x^{(k)}$ 进行规范化。令 $\max(x)$ 表示向量 x 的模最大的分量。即，如果有 i_0 使得 $|x_{i_0}| = \max_i |x_i|$ ，则

$\max(x) = x_{i_0}$ 。

规范化的幂法迭代公式：

$$\begin{aligned} y^{(k)} &= \frac{x^{(k)}}{\max(x^{(k)})}, \\ x^{(k+1)} &= Ay^{(k)}, \quad k = 0, 1, 2, \dots \end{aligned}$$

幂法

如果 A 没有完全特征向量系，会发生什么？

例：假设 A 的Jordan标准型如下， A 只有 v_1 一个特征向量。

$$[v_1, v_2, v_3] \begin{bmatrix} \lambda_1 & 1 & \\ & \lambda_1 & 1 \\ & & \lambda_1 \end{bmatrix} = A[v_1, v_2, v_3]$$

$$x^{(0)} = [v_1, v_2, v_3] \begin{bmatrix} \alpha_1 \\ \alpha_2 \\ \alpha_3 \end{bmatrix}$$

$$Ax^{(0)} = [v_1, v_2, v_3] \begin{bmatrix} \lambda_1 & 1 & \\ & \lambda_1 & 1 \\ & & \lambda_1 \end{bmatrix} \begin{bmatrix} \alpha_1 \\ \alpha_2 \\ \alpha_3 \end{bmatrix}$$

$$A^k x^{(0)} = [v_1, v_2, v_3] \begin{bmatrix} \lambda_1 & 1 & \\ & \lambda_1 & 1 \\ & & \lambda_1 \end{bmatrix}^k \begin{bmatrix} \alpha_1 \\ \alpha_2 \\ \alpha_3 \end{bmatrix}$$

可见 $x^{(k)}$ 在方向上不会收敛到 v_1

幂法

例：假设 A 的Jordan标准型如下， A 有 v_1, v_2 两个特征向量。

$$[v_1, v_2, v_3] \begin{bmatrix} \lambda_1 & 0 & \\ & \lambda_2 & 1 \\ & & \lambda_2 \end{bmatrix} = A[v_1, v_2, v_3]$$

$$x^{(0)} = [v_1, v_2, v_3] \begin{bmatrix} \alpha_1 \\ \alpha_2 \\ \alpha_3 \end{bmatrix} = \alpha_1 v_1 + [v_2, v_3] \begin{bmatrix} \alpha_2 \\ \alpha_3 \end{bmatrix}$$

$$A^k x^{(0)} = \alpha_1 \lambda_1^k v_1 + [v_2, v_3] \begin{bmatrix} \lambda_2 & 1 \\ & \lambda_2 \end{bmatrix}^k \begin{bmatrix} \alpha_2 \\ \alpha_3 \end{bmatrix}$$

由于 $\frac{1}{\lambda_1} \begin{bmatrix} \lambda_2 & 1 \\ & \lambda_2 \end{bmatrix}$ 的所有特征值的模均小于1，所以 $\begin{bmatrix} \lambda_2 & 1 \\ & \lambda_2 \end{bmatrix}^k / \lambda_1^k$ 趋于0矩阵。

可见 $x^{(k)}$ 在方向上会收敛到 v_1

幂法

这意味着 λ_1 必是实数

定理： 设 $A \in \mathbf{R}^{n \times n}$ 有完全特征向量系，设 A 的 n 个特征值满足 $|\lambda_1| > |\lambda_2| \geq \dots \geq |\lambda_n|$ ，则对任初始向量 $x^{(0)}$ (但要保证 $\alpha_1 \neq 0$)，由规范化的幂法公式确定的向量序列 $\{y^{(k)}\}, \{x^{(k)}\}$ 满足：

$$(1) \lim_{k \rightarrow \infty} \max(x^{(k)}) = \lambda_1;$$

$$(2) \lim_{k \rightarrow \infty} y^{(k)} = v_1.$$

教材定理6.2.1给出了更一般的情形： A 可以没有完全特征向量系， λ_1 可以是**重特征值**但不能是**复特征值**，只要 λ_1 是半单的（即特征值的重数等于特征向量的个数）且 $|\lambda_1| >$ 其他不同于 λ_1 的特征值的模，则幂法依然有效。

相当于情形(1)和2a)

注意，如果 $x^{(0)}$ 和 A 都是实数，则幂法不可能收敛到复特征值和复特征向量。

举例

例：用规范化的幂法计算下列矩阵的模最大特征值和相应的特征向量。

$$A = \begin{bmatrix} -4 & 14 & 0 \\ -5 & 13 & 0 \\ -1 & 0 & 2 \end{bmatrix}, \quad x^{(0)} = (1, 1, 1)^T$$

解：手动计算可得 A 的特征值为(6, 3, 2)。幂法迭代过程如下：

k	$\max(x^{(k)})$	$y^{(k)} = x^{(k)}/\max(x^{(k)})$	$x^{(k+1)} = Ay^{(k)}$
0	1	(1, 1, 1)	(10, 8, 1)
1	10	(1, 0.8, 0.1)	(7.2, 5.4, -0.8)
2	7.2	(1, 0.75, -0.111111)	(6.5, 4.75, -1.222222)
3	6.57	(1, 0.730769, -0.203704)	(6.230766, 4.499997, -1.407408)
4	6.230766	(1, 0.722222, -0.225880)	(6.111108, 4.388886, -1.1451767)
5	6.111108	(1, 0.718182, -0.237561)	(6.054548, 4.336336, -1.475122)
6	6.054548	(1, 0.716216, -0.243639)	(6.027024, 4.310808, -1.487278)
7	6.027024	(1, 0.715247, -0.246768)	(6.013458, 4.298211, -1.483536)
8	6.013458	(1, 0.714765, -0.248366)	(6.00671, 4.291945, -1.496732)
9	6.00671	(1, 0.714525, -0.249177)	(6.00335, 4.28825, -1.496354)
10	6.00335	(1, 0.714405, -0.249586)	(6.00167, 4.287265, -1.499172)
11	6.00167	(1, 0.714345, -0.239792)	(6.00083, 4.286485, -1.499584)
12	6.00083	(1, 0.714315, -0.249896)	

幂法的加速

设 A 的 n 个特征值满足 $|\lambda_1| > |\lambda_2| \geq \dots \geq |\lambda_n|$ ，则幂法的收敛速度取决于 $\left|\frac{\lambda_2}{\lambda_1}\right|$ 的大小。为提高收敛速度，可以采取**原点移位**的方法，使得原矩阵 A 的特征值统一增加或减小。比如：考虑 $B = A - \lambda I$ ， B 的特征值统一比 A 减小了 λ ，选取适当的 λ 可以使得计算 B 的特征值的幂法收敛速度很快。

已知

$$\begin{aligned} x^{(k)} &= B^k x^{(0)} = \alpha_1 B^k v_1 + \dots + \alpha_n B^k v_n \\ &= (\lambda_1 - \lambda)^k \left[\alpha_1 v_1 + \sum_{j=2}^n \alpha_j \left(\frac{\lambda_j - \lambda}{\lambda_1 - \lambda} \right)^k v_j \right]. \end{aligned}$$

为加快收敛速度，可以选取 λ 使得

$$\max_{2 \leq j \leq n} \left| \frac{\lambda_j - \lambda}{\lambda_1 - \lambda} \right|$$

尽可能地小。

幂法的加速

如果所有特征值均为实数，上述公式的极小值点为

$$\lambda = \frac{\lambda_2 + \lambda_n}{2}.$$

原点移位法是一个矩阵变换过程，变换简单且不破坏原矩阵的稀疏性。但由于预先不知道特征值的分布，所以应用起来有一定困难，通常对特征值的分布有一个大略估计，设定一个参数 λ 进行试算，当所取 λ 对迭代有明显加速效应以后再进行确定计算。

举例

例：计算下列矩阵的模最大特征值和相应的特征向量。

$$A = \begin{bmatrix} 1 & 1 & 0.5 \\ 1 & 1 & 0.25 \\ 0.5 & 0.25 & 2 \end{bmatrix}, \quad x^{(0)} = (1, 1, 1)^T$$

λ_1, v_1 的精确解为： $\lambda_1 = 2.5362258, v_1 = (0.74822116, 0.64966116, 1)^T$

解：先用规范化的幂法：

k	$y^{(k)} = x^{(k)} / \max(x^{(k)})$	$\lambda_1 \approx \max(x^{(k)})$
0	(1, 1, 1)	
1	(0.9091, 0.8182, 1) ^T	2.75
19	(0.7482, 0.6497, 1) ^T	2.5365374
20	(0.7482, 0.6497, 1) ^T	2.5365323

再采用原点位移的加速法求解，取 $\lambda = 0.75$ ，矩阵 $B = A - \lambda I$ 。

$$B = \begin{bmatrix} 0.25 & 1 & 0.5 \\ 1 & 0.25 & 0.25 \\ 0.5 & 0.25 & 1.25 \end{bmatrix}, \quad x^{(0)} = (1, 1, 1)^T$$

举例

对 B 用规范化的幂法：

k	$y^{(k)} = x^{(k)} / \max(x^{(k)})$	$\lambda_1 \approx \max(x^{(k)})$
0	$(1, 1, 1)^T$	
9	$(0.7483, 0.6497, 1)^T$	1.7866587
10	$(0.7483, 0.6497, 1)^T$	1.7865914

此结果与未加速的规范化乘幂法公式计算结果相比，收敛速度要快得多。

幂法求最大特征值代码

假设模最大的特征值是单根或重根，即不为复数也不互为相反数。
下列算法可以求出该最大特征值及它的一个特征向量

```
1  function [lam,x,k]=mypower(A,x,tol,N)
2  %幂法求矩阵A的最大特征值及其特征向量
3  - if nargin<4
4  -     N=1000;
5  - end
6  - if nargin<3
7  -     tol=1e-10;
8  - end
9  - k=0;
10 - [~,t]=max(abs(x));
11 - m=x(t);
12 - while (k<N)
13 -     x=x/m;
14 -     x=A*x;
15 -     [~,t]=max(abs(x));
16 -     m1=x(t);
17 -     err=abs(m1-m);
18 -     if err<tol
19 -         break
20 -     end
21 -     m=m1;
22 -     k=k+1;
23 - end
24 - lam=m1;
```


幂法的降价

在已经求出主特征值 λ_1 及特征向量 v_1 以后,可将原矩阵进行修改,使修改后的矩阵按模最大特征值是原矩阵的按模次大特征值,再用乘幂法去求按模次大特征值及特征向量,此方法称为降阶过程。

为使问题简单,设 $A \in R^{n \times n}$ 为对称矩阵。假定已求出主特征值 λ_1 及特征向量 v_1 ,记 $A^{(1)}=A$,构造矩阵

$$A^{(2)} = A^{(1)} - \lambda_1 v_1 v_1^T / v_1^T v_1$$

因 A 对称,则具完全特征向量系,且特征向量 v_i 可两两相互正交,即满足 $v_1^T v_i = 0 (i = 2, \dots, n)$,于是

$$A^{(2)} v_1 = A^{(1)} v_1 - \lambda_1 v_1 (v_1^T v_1) / v_1^T v_1 = 0$$

$$A^{(2)} v_i = A^{(1)} v_i - \lambda_1 v_1 (v_1^T v_i) / v_1^T v_1 = A^{(1)} v_i = \lambda_i v_i \quad (i = 2, 3, \dots, n)$$

这表明矩阵 $A^{(2)}$ 除一个特征值 $\lambda_1 = 0$ 与矩阵 $A^{(1)}$ 不一样之外,其余与 $A^{(1)}$ 具相同特征值,且 $A^{(2)}$ 的按模最大特征值是 λ_2 ,用 $A^{(2)}$ 代替 $A^{(1)}$ 进行乘幂迭代即可求得 λ_2 及相应的特征向量 v_2 ,而 λ_2 又为 $A^{(1)}$ 的按模次大特征值。这种做法称为降阶法。

注意,降阶法实际上只可用少数几次,求矩阵的前几个按模最大特征值及特征向量。因为,每降阶一次,计算精度就会损失或降低一些。

反幂法

设 $A \in R^{n \times n}$ 可逆, 则无零特征值, 由

$$Ax = \lambda x \quad (x \neq 0)$$

有

$$A^{-1}x = \frac{1}{\lambda}x$$

即若 λ 为矩阵 A 的特征值, 则 $\frac{1}{\lambda}$ 必为矩阵 A^{-1} 的特征值, 且特征向量相同。

如果 A 的 n 个特征值 $\lambda_i (i = 1, 2, \dots, n)$ 为

$$|\lambda_1| \geq |\lambda_2| \geq \dots \geq |\lambda_n|$$

则 A^{-1} 的 n 个特征值更为

$$\left| \frac{1}{\lambda_n} \right| \geq \left| \frac{1}{\lambda_{n-1}} \right| \geq \dots \geq \left| \frac{1}{\lambda_1} \right|$$

反幂法

因此, 若乘幂法可求 A 的主特征值 λ_1 , 则用 A^{-1} 做乘幂矩阵, 由乘幂迭代格式

$$x^{(k+1)} = A^{-1}x^{(k)}$$

便可求出 A^{-1} 的按模最大特征值 $\frac{1}{\lambda_n}$, 取倒数, 即为矩阵 A 的按模最小特征值。因此, 对任

取初始向量 $x^{(0)} \in R^n$, 称上述公式为求矩阵 A 按模最小特征值的反幂法。

在应用上述公式计算时, 由于要计算 A 的逆矩阵 A^{-1} , 一方面计算复杂、麻烦, 另一方面, 有时会破坏 A 的稀疏性, 故改写为:

$$Ax^{(k+1)} = x^{(k)} \quad (k = 0, 1, \dots)$$

规范化乘幂法公式为

$$\begin{cases} y^{(k)} = x^{(k)} / \max(x^{(k)}) \\ Ax^{(k+1)} = y^{(k)} \end{cases} \quad (k = 0, 1, \dots)$$

反幂法

如果考虑到利用原点移位加速的反幂法, 则记 $B = A - \lambda_0 I$, 对任取初始向量 $x^{(0)} \in R^n$,

$$\begin{cases} y^{(k)} = x^{(k)} / \max(x^{(k)}) \\ Bx^{(k+1)} = y^{(k)} \end{cases} \quad (k = 0, 1, \dots)$$

由于反幂法的主要工作量是每迭代一步都要解一个线性方程组, 且系数矩阵 A (或 B) 是不变的, 故可利用矩阵的三角分解 $A = LU$ (或 $B = LU$), 则每次迭代只需解二个三角形方程组

$$\begin{cases} L\tilde{x} = y^{(k)} \\ Ux^{(k+1)} = \tilde{x} \end{cases}$$

且当 $|\lambda_1| \geq |\lambda_2| \geq \dots \geq |\lambda_{n-1}| > |\lambda_n| > 0$ 时

$$\lim_{k \rightarrow \infty} \max(x^{(k)}) = \frac{1}{\lambda_n - \lambda_0}; \quad \text{同时} \quad \lim_{k \rightarrow \infty} y^{(k)} = v_n.$$

注意: 反幂法的收敛速度同样取决于 $\left| \frac{\lambda_n}{\lambda_{n-1}} \right|$ 的大小。(考虑 $x^{(k)} = A^{-1}x^{(k-1)} = \dots = A^{-k}x^{(0)}$, 将 $x^{(0)}$ 写成 $v_1, \dots, v_n$ 的线性组合, 之后的分析和幂法一样)

反幂法

可结合反幂法和降价法去求矩阵的前几个按模最小特征值及其特征向量。例如求得 λ_n 和 v_n 之后，（当 A 对称时）可采用如下迭代公式去求 λ_{n-1} 和 v_{n-1} ：

$$y^{(k)} = \frac{x^{(k)}}{\max(x^{(k)})},$$
$$Ax^{(k+1)} = \left(I - \frac{1}{\lambda_n} A \frac{v_n v_n^T}{v_n^T v_n}\right) y^{(k)}, \quad k = 0, 1, 2, \dots$$

由于计算量较大，一般不用上述迭代法去求矩阵的前几个按模最小特征值。

反幂法的主要应用是已知矩阵的近似特征值后去求矩阵的特征向量，收敛快，精度高，是目前求特征向量最有效的方法之一。比如，已得到某特征值 λ 的近似值 μ ，可用如下方法计算该特征值的特征向量：

$$y^{(k)} = \frac{x^{(k)}}{\max(x^{(k)})},$$
$$(A - \mu I)x^{(k+1)} = y^{(k)}, \quad k = 0, 1, 2, \dots$$

这其实就是原点位移加速，当 μ 离 λ 很近时，因为这样使得 $\left|\frac{\lambda_n}{\lambda_{n-1}}\right|$ 很小，从而收敛很快。需要注意的是， $A - \mu I$ 非常接近奇异阵，条件数非常大，然而实际经验和理论分析表明：这种病态不会影响收敛速度和收敛结果，因为所引起的误差主要体现在迭代序列的长度上，而求特征向量只需关心方向。

反幂法求特征值代码

```
1  function [lam,x,k]=myinvpower(A,x,alpha,tol,N)
2      %反幂法求alpha附近的特征及其特征向量
3      if nargin<5
4          N=1000;
5      end
6      if nargin<4
7          tol=1e-10;
8      end
9      k=0;
10     A=A-alpha*eye(length(x));
11     [L,U,P]=lu(A);
12     [~,t]=max(abs(x));
13     m=x(t);
14     while (k<N)
15         x=x/m;
16         z=L\(P*x);
17         x=U\z;
18         [~,t]=max(abs(x));
19         m1=x(t);
20         %x=v/m1;
21         err=abs(m1-m);
22         if err<tol
23             break
24         end
25         m=m1;
26         k=k+1;
27     end
28     lam=alpha+1/m;
```

QR方法

幂法（或子空间迭代法）可用于求矩阵的按模最大的一个（或前几个）特征值和特征向量，而对一般实矩阵 $A \in \mathbf{R}^{n \times n}$ ，若 A 可逆，可用QR方法求解 A 的全部特征值。

QR方法的主要思路如下：

记 $A_0 = A$ ，对 A_0 做QR分解，得

$$A_0 = Q_1 R_1$$

通过逆序相乘，得

$$A_1 = R_1 Q_1$$

可知， $A_1 = Q_1^T A_0 Q_1$ ， A_1 是由 A_0 通过正交相似变换得到的。所以 A_1 与 A_0 的特征值相同。

重复上述步骤，可得QR方法的迭代公式：

$$A_{k-1} = Q_k R_k$$

$$A_k = R_k Q_k = Q_k^T A_{k-1} Q_k.$$

QR方法与幂法的关系

子空间迭代法:

选取初始线性无关组 Y_0



基于QR分解的迭代公式:

$$AY_k = Y_{k+1}R_{k+1}$$



$$A^k Y_0 = Y_k R_k R_{k-1} \cdots R_1$$

如果收敛的话, Y_k 和 R_k 分别收敛到特征向量和特征值

QR迭代法:

$$A * I = A_0 = Q_1 R_1$$

$$A^2 * I = Q_1 R_1 Q_1 R_1 = Q_1 Q_2 R_2 R_1$$

$$\begin{aligned} A^3 * I &= Q_1 R_1 Q_1 Q_2 R_2 R_1 \\ &= Q_1 Q_2 R_2 Q_2 R_2 R_1 = Q_1 Q_2 Q_3 R_3 R_2 R_1 \end{aligned}$$



$$\begin{aligned} A^k * I &= Q_1 \cdots Q_k R_k \cdots R_1 \\ &= \tilde{Q}_k R_k \cdots R_1 \end{aligned}$$

如果收敛的话, $Q_k * R_k$ 的对角线收敛到全部特征值 (见下面的定理)

QR方法收敛性

定理 (QR方法收敛性定理)： 设 $A \in \mathbf{R}^{n \times n}$,

1° A 的 n 个特征值 $\lambda_1, \dots, \lambda_n$ 满足

$$|\lambda_1| > |\lambda_2| > \dots > |\lambda_n| > 0$$

2° 有可逆矩阵 P , 将 A 相似变换为对角阵 J , 即

$$A = PJP^{-1}$$

$$J = \text{diag}(\lambda_1, \dots, \lambda_n)$$

3° 矩阵 P^{-1} 有三角分解

$$P^{-1} = LU$$

其中 L 为单位下三角阵, U 为上三角阵,

则由 $A_1 = A$ 进行的 QR 算法序列 $\{A_k\}$ 的对角线以下元素趋于 0, 对角元素趋于 A 的所有特征值, 对角线以上元素不一定收敛。

该定理的证明参考教材定理 6.4.1。可以结合 Schur 分解定理理解 QR 方法的原理。

实Schur标准型

如果实矩阵 A 有复特征值，则实数域中的QR迭代法难以保证 A_k 收敛到上三角阵，需要每一次迭代都在复数域中作QR分解，即 Q_k 是酉矩阵。

如果我们希望只涉及实数域中的QR分解，则需要引入实Schur分解定理。

定理(实Schur分解定理)： 设 $A \in \mathbf{R}^{n \times n}$ ，则必存在正交矩阵 $Q \in \mathbf{R}^{n \times n}$ 使得

$$Q^T A Q = R = \begin{bmatrix} R_{11} & R_{12} & \cdots & R_{1m} \\ & R_{22} & \cdots & R_{2m} \\ & & \ddots & \vdots \\ & & & R_{mm} \end{bmatrix}, \quad \text{实Schur标准型}$$

其中， R_{ii} 是一个实特征值或者是一个具有一对复共轭特征值的2阶方阵。可以适当选取 Q 使得 R 的对角块任意排列。

不难想象，当实矩阵 A 有复特征值时，实数域中的QR迭代序列 $\{A_k\}$ 应当收敛到 A 的实Schur标准型。

举例

例：求下列矩阵 A 的所有特征值。

$$A = \begin{bmatrix} 5 & -2 & -5 & -1 \\ 1 & 0 & -3 & 2 \\ 0 & 2 & 2 & -3 \\ 0 & 0 & 1 & -2 \end{bmatrix}$$

解 矩阵 A 的特征多项式为

$$\lambda^4 - 5\lambda^3 + 7\lambda^2 - 7\lambda - 20 = 0$$

其特征值为

$$\lambda_1 = 4, \quad \lambda_{2,3} = 1 \pm 2i, \quad \lambda_4 = -1$$

接下来用 QR 算法求 A 的特征值。

举例

令 $A = A_1$ ，进行正交 QR 分解。由斯密特征变化过程，得

$$A_1 = Q_1 R_1$$

其中

$$Q_1 = \begin{bmatrix} 0.9806 & -0.0377 & 0.1923 & -0.1038 \\ 0.1961 & 0.1887 & -0.8804 & -0.4192 \\ 0 & 0.9813 & 0.1761 & 0.0740 \\ 0 & 0 & 0.3962 & -0.8989 \end{bmatrix}$$
$$R = \begin{bmatrix} 5.0992 & -1.9612 & -5.4912 & -0.3922 \\ 0 & 2.0381 & 1.5852 & -2.5288 \\ 0 & 0 & 2.5242 & -3.2736 \\ 0 & 0 & 0 & 0.7822 \end{bmatrix}$$

将 Q_1 、 R_1 逆序相乘，得 A_2

$$A_2 = \begin{bmatrix} 4.6157 & 5.9508 & 1.5922 & 0.2390 \\ 0.3997 & 1.9401 & -2.5171 & 1.5361 \\ 0 & 2.4770 & -0.8525 & 3.1294 \\ 0 & 0 & 0.3099 & -0.7031 \end{bmatrix}$$

举例

接下来，分解 $A_2 = Q_2 R_2$ ，重复以上步骤，迭代11次得 A_{12} ：

$$A_{12} = \begin{bmatrix} 4.000 & * & * & * \\ 0 & 1.8789 & -3.5910 & * \\ 0 & 1.3290 & 0.1211 & * \\ 0 & 0 & 0 & -1.000 \end{bmatrix}$$
$$= \begin{bmatrix} \Lambda_1 & * & * \\ & \Lambda_2 & * \\ & & \Lambda_3 \end{bmatrix} \quad \text{分块上三角阵}$$

其中 Λ_1 、 Λ_3 是一阶子块， Λ_2 是二阶子块，从而 A 的特征值的近似值为：

$$\lambda_1 = 4.000, \quad \lambda_4 = -1.000$$

而 λ_2 、 λ_3 是特征方程

$$|\lambda I - A| = \begin{vmatrix} \lambda - 1.8789 & 3.5910 \\ 1.3290 & \lambda - 0.1211 \end{vmatrix}$$

的两个根。

上Hessenberg化

通常，上述的QR迭代法收敛速度是线性的，且计算工作量较大，实际应用不很方便。为了减少每次迭代的运算（并一定减少迭代次数），可以先将矩阵A上Hessenberg化，即化为以下形式的矩阵

$$\begin{bmatrix} h_{11} & h_{12} & h_{13} & \cdots & h_{1,n-1} & h_{1n} \\ h_{21} & h_{22} & h_{23} & \cdots & h_{2,n-1} & h_{2n} \\ & h_{32} & h_{33} & \cdots & h_{3,n-1} & h_{3n} \\ & & \ddots & \ddots & \vdots & \vdots \\ & & & \ddots & \ddots & \vdots \\ & & & & h_{n,n-1} & h_{nn} \end{bmatrix}$$

然后再做QR分解，这样可以大大提高计算效率。

设 $A \in \mathbf{R}^{n \times n}$ ，我们最希望通过相似变换 QAQ^T 将A化为上三角形。容易想到利用Household正交变换来实现这一目的。如果选取Household变换 H_1 使得 H_1A 的第一列下三角化，当继续计算 $H_1AH_1^T$ 时，第一列的零元素可能会被破坏掉。为了保证不出现这一现象， H_1 应当选取如下形式：

$$H_1 = \begin{bmatrix} 1 & 0 \\ 0 & \tilde{H}_1 \end{bmatrix}$$

其中 $\tilde{H}_1$ 是n-1维的Household变换。

上Hessenberg化

于是

$$H_1 A H_1^T = \begin{bmatrix} a_{11} & A(1,2:n)\tilde{H}_1 \\ \tilde{H}_1 A(2:n,1) & \tilde{H}_1 A(2:n,2:n)\tilde{H}_1 \end{bmatrix},$$

这样， $H_1 A H_1^T$ 的第一列的第3~n个元素便成了0. 即第一列实现了上Hessenberg化。

接下来，选取 H_2

$$H_1 = \begin{bmatrix} I_2 & 0 \\ 0 & \tilde{H}_2 \end{bmatrix}$$

其中 $\tilde{H}_2$ 是n-2维的Household变换。可知 $H_2 H_1 A H_1^T H_2^T$ 的前两列实现了上Hessenberg化。如此重复，经过n-2个household变换，使得

$$H_{n-2} \cdots H_1 A H_1^T \cdots H_{n-2}^T = H = \text{一个上Hessenberg矩阵}$$

上 Hessenberg 化 Matlab 代码

仅供参考

```
1  function [A,Q]=mhessen(A)
2  -      n=size(A,1);
3  -      Q=eye(n);
4  -      for k=1:(n-2)
5  -          x=A(k+1:n,k);
6  -          [v,beta]=house(x);
7  -          H=eye(length(v))-beta*(v*v');
8  -          A(k+1:n,k:n)=H*A(k+1:n,k:n);
9  -          A(1:n,k+1:n)=A(1:n,k+1:n)*H;
10 -          Q=Q*blkdiag(eye(k),H);
11 -      end
```

如无需输出 $H_1 \cdots H_{n-2}$, 则与 Q 相关的代码可以省去

上Hessenberg矩阵的QR分解

将矩阵 A 化为上Hessenberg矩阵 H 之后,需要对 H 进行QR分解。可以采用 $n-1$ 次Givens变换实现 $H = QR$ 。

注意：对上Hessenberg矩阵实现QR分解比对一般的矩阵实现QR分解要节省很多计算量。这正是先做上Hessenberg化的好处。

对 H 进行QR分解之后,需要计算 $\tilde{H} = RQ$,然后进入下一次迭代。

可以证明 $\tilde{H} = RQ$ 依然是上Hessenberg矩阵。可见上Hessenberg矩阵的性质在迭代过程中保持不变,从而大大节约了计算量。

上 Hessenberg 矩阵的 QR 分解代码

仅供参考

输入 A , $A = QR$, $A = RQ$, 再输出 A

```
1  function A=hessen_qrtran(A,m)
2  -   Q=eye(m);
3  -   for i=1:m-1
4  -       xi=A(i,i);
5  -       xk=A(i+1,i);
6  -       if xk~=0
7  -           [c,s]=givens(xi,xk);
8  -           G=[c,s;-s,c];
9  -           A(i:i+1,i:m)=G*A(i:i+1,i:m);
10 -          Q(1:m,i:i+1)=Q(1:m,i:i+1)*G';
11 -       end
12 -   end
13 -   A(1:m,1:m)=A(1:m,1:m)*Q;
```

QR迭代法代码

仅供参考

*iter*表示迭代次数，*D*用于存储全部特征值

```
1 function [iter,D] = qr_eig(A,tol,N)
2     if nargin < 3
3         N = 5000;
4     end
5     if nargin < 2
6         tol = 1e-8;
7     end
8     n = size(A,1); D = ones(n,1); iter = 0;
9     m = n; %表示次对角线上，最后一个非零元素所在行。一开始等于n
10    A = mhessen(A);
11    while iter <= N
12        iter = iter + 1;
13        l=1;%l表示从第m行沿次对角线往上寻找到的第一个0元素所在行
14        for k = m:-1:2 %从第m行沿次对角线往上寻找第一个0元素
15            if abs(A(k,k-1)) < tol
16                if m-k+1 <= 2
17                    la = eig(A(k:m,k:m));
18                    D(k:m) = la';
19                    m = k-1;
20                else
21                    l=k;%A(l:m,l:m)表示A中间的大于等于3阶的不可约子矩阵块
22                    break;
23                end
24            end
25        end
26        if m <= 2
27            la = eig(A(1:m,1:m));
28            D(1:m) = la';
29            break;
30        end
31        A(l:m,l:m) = hessen_qrtran(A(l:m,l:m),m-l+1);
32    end
```

求特征向量

由QR迭代法得到矩阵的全部特征值（近似值）之后，通常借助带原点位移的反幂法逐个求解相应的特征向量（不论特征值是实数还是复数）。

- 给定近似特征值 $\tilde{\lambda}$ ，先用反幂法求 H 的特征向量 z ，再通过 $x = Qz$ 得到 A 的特征向量，其中 $Q = H_1 \cdots H_{n-2}$ 。

思考：为什么不直接利用线性方程组 $(A - \tilde{\lambda}I)x = 0$ 求解特征向量

- 取决于 $\tilde{\lambda}$ 够不够精确，而且系数矩阵接近奇异阵，误差可能很大
- 得到近似值 $\tilde{\lambda}$ 之后，用反幂法既可以得到特征向量，也可以进一步得到更精确的特征值

作业

1 / 教材第六章习题第8题。

2 / 教材第六章上机习题第1题，两问都要做。提示：考虑多项式 $x^n + a_{n-1}x^{n-1} + a_{n-2}x^{n-2} + \cdots + a_1x + a_0$ 跟下列矩阵的关系

$$\begin{bmatrix} 0 & 0 & \cdots & 0 & -a_0 \\ 1 & 0 & \cdots & 0 & -a_1 \\ & 1 & \ddots & \vdots & -a_2 \\ & & \ddots & 0 & \vdots \\ & & & 1 & -a_{n-1} \end{bmatrix}$$

作业只需要考虑模最大根为单重实根的情形。对于其他情形，大家自行完善。

作业

- 1 / （编程）利用带原点位移的反幂法求下列矩阵在11附近的特征值及其特征向量。

$$\begin{pmatrix} 3 & 2 & 3 & 4 & 5 & 6 & 7 \\ 11 & 1 & 2 & 3 & 4 & 5 & 6 \\ 2 & 8 & 9 & 1 & 2 & 3 & 4 \\ -4 & 2 & 9 & 11 & 13 & 5 & 8 \\ -1 & -2 & -3 & -1 & -1 & -1 & -1 \\ 3 & 2 & 3 & 4 & 13 & 15 & 8 \\ -2 & -2 & -3 & -4 & -5 & -3 & -3 \end{pmatrix}$$

- 2 / （编程）利用基于上 Hessenberg 化的 QR 迭代法求解上述矩阵的全部特征值。