

第六章

参数估计

在上一章中,我们主要讲述了几个常用统计量的抽样分布及充分统计量.我们回想一下,引进统计量的目的在于对感兴趣的问题进行统计推断,而在实际中,我们感兴趣的问题多是与分布族中的未知参数有关的.从本章开始,我们将讨论参数的估计和检验问题.本章将介绍参数的估计问题.

这里参数是指如下三类未知参数:

- 分布中所含的未知参数 θ .如:二点分布 $b(1, p)$ 中的概率 p , 正态分布 $N(\mu, \sigma^2)$ 中的 μ 和 σ^2 .

- 分布中所含的未知参数 θ 的函数.如:服从正态分布 $N(\mu, \sigma^2)$ 的变量 X 不超过某给定值 a 的概率 $P(X \leq a) = \Phi\left(\frac{a-\mu}{\sigma}\right)$ 是未知参数 μ, σ 的函数;单位产品的缺陷数 X 通常服从泊松分布 $P(\lambda)$, 则单位产品合格(无缺陷)的概率 $P(X=0) = e^{-\lambda}$ 是未知参数 λ 的函数.

- 分布的各种特征数也都是未知参数.如:均值 $E(X)$, 方差 $\text{Var}(X)$, 分布中位数等.

一般场合,常用 θ 表示参数,参数 θ 所有可能取值组成的集合称为参数空间,常用 Θ 表示.参数估计问题就是根据样本构造适当的统计量对上述各种未知参数作出估计.

参数估计的形式有两种:点估计与区间估计.这里我们从点估计开始.

§ 6.1 点估计的概念与无偏性

6.1.1 点估计及无偏性

定义 6.1.1 设 $x_1, x_2, \dots, x_n$ 是来自总体的一个样本,用于估计未知参数 θ 的统计量 $\hat{\theta} = \hat{\theta}(x_1, x_2, \dots, x_n)$ 称为 θ 的估计量,或称为 θ 的点估计,简称估计.

在这里如何构造统计量 $\hat{\theta}$ 并没有明确的规定,只要它满足一定的合理性即可.最常见的合理性要求是所谓的无偏性.

定义 6.1.2 设 $\hat{\theta} = \hat{\theta}(x_1, x_2, \dots, x_n)$ 是 θ 的一个估计, θ 的参数空间为 Θ , 若对任意

的 $\theta \in \Theta$, 有

$$E_{\theta}(\hat{\theta}) = \theta, \quad (6.1.1)$$

则称 $\hat{\theta}$ 是 θ 的无偏估计, 否则称为有偏估计.

无偏性要求可以改写为 $E_{\theta}(\hat{\theta} - \theta) = 0$, 这表示无偏估计没有系统偏差. 当我们使用 $\hat{\theta}$ 估计 θ 时, 由于样本的随机性, $\hat{\theta}$ 与 θ 总是有偏差的, 这种偏差时而 (对某些样本观测值) 为正, 时而 (对另一些样本观测值) 为负, 时而大, 时而小. 无偏性表示, 把这些偏差平均起来其值为 0, 这就是无偏估计的含义. 而若估计不具有无偏性, 则无论使用多少次, 其平均也会与参数真值有一定的距离, 这个距离就是系统误差.

例 6.1.1 对任一总体而言, 样本均值是总体均值的无偏估计. 当总体 k 阶矩存在时, 样本 k 阶原点矩 a_k 是总体 k 阶原点矩 μ_k 的无偏估计. 但对 k 阶中心矩则不一样, 譬如, 样本方差 s_n^2 就不是总体方差 σ^2 的无偏估计, 因由定理 5.3.2 可得

$$E(s_n^2) = \frac{n-1}{n} \sigma^2.$$

对此, 有如下两点说明:

(1) 当样本量趋于无穷时, 有 $E(s_n^2) \rightarrow \sigma^2$, 我们称 s_n^2 为 σ^2 的渐近无偏估计, 这表明当样本量较大时, s_n^2 可近似看作 σ^2 的无偏估计.

(2) 若对 s_n^2 作如下修正:

$$s^2 = \frac{ns_n^2}{n-1} = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2, \quad (6.1.2)$$

则 s^2 是总体方差的无偏估计. 这种简单的修正方法在一些场合常被采用. (6.1.2) 式定义的 s^2 也称为样本方差, 它比 s_n^2 更常用. 这是因为在 $n \geq 2$ 时, $s_n^2 < s^2$, 因此用 s_n^2 估计 σ^2 有偏小的倾向, 特别在小样本场合要使用 s^2 估计 σ^2 .

无偏性不具有不变性. 即若 $\hat{\theta}$ 是 θ 的无偏估计, 一般而言, 其函数 $g(\hat{\theta})$ 不是 $g(\theta)$ 的无偏估计, 除非 $g(\theta)$ 是 θ 的线性函数. 譬如, s^2 是 σ^2 的无偏估计, 但 s 不是 σ 的无偏估计. 下面我们以正态分布为例加以说明.

例 6.1.2 设总体为 $N(\mu, \sigma^2)$, $x_1, x_2, \dots, x_n$ 是样本, 我们已经指出 s^2 是 σ^2 的无偏估计. 下面来考察 s 是否是 σ 的无偏估计. 由定理 5.4.1 知, $Y = \frac{(n-1)s^2}{\sigma^2} \sim \chi^2(n-1)$, 其密度函数为

$$p(y) = \frac{1}{2^{\frac{n-1}{2}} \Gamma\left(\frac{n-1}{2}\right)} y^{\frac{n-1}{2}-1} e^{-\frac{y}{2}}, \quad y > 0.$$

从而

$$E(Y^{1/2}) = \int_0^{\infty} y^{1/2} p(y) dy = \frac{1}{2^{\frac{n-1}{2}} \Gamma\left(\frac{n-1}{2}\right)} \int_0^{\infty} y^{\frac{n-1}{2}-1} e^{-\frac{y}{2}} dy$$

$$= \frac{2^{\frac{n}{2}} \Gamma\left(\frac{n}{2}\right)}{2^{\frac{n-1}{2}} \Gamma\left(\frac{n-1}{2}\right)} = \sqrt{2} \frac{\Gamma\left(\frac{n}{2}\right)}{\Gamma\left(\frac{n-1}{2}\right)}.$$

由此,我们有

$$E(s) = \frac{\sigma}{\sqrt{n-1}} E(Y^{1/2}) = \sqrt{\frac{2}{n-1}} \cdot \frac{\Gamma(n/2)}{\Gamma((n-1)/2)} \cdot \sigma \equiv \frac{\sigma}{c_n}.$$

这说明 s 不是 σ 的无偏估计,利用修正技术可得 $c_n \cdot s$ 是 σ 的无偏估计,其中 $c_n = \sqrt{\frac{n-1}{2}} \cdot \frac{\Gamma((n-1)/2)}{\Gamma(n/2)}$ 是修偏系数,表 6.1.1 给出了 c_n 的部分取值.可以证明,当 $n \rightarrow \infty$ 时有 $c_n \rightarrow 1$,这说明 s 是 σ 的渐近无偏估计,从而在样本容量较大时,不经修正的 s 也是 σ 的一个很好的估计.

表 6.1.1 正态标准差的修偏系数表

n	c_n	n	c_n	n	c_n	n	c_n	n	c_n
		7	1.042 4	13	1.021 0	19	1.014 0	25	1.010 5
2	1.253 3	8	1.036 2	14	1.019 4	20	1.013 2	26	1.010 0
3	1.128 4	9	1.031 7	15	1.018 0	21	1.012 6	27	1.009 7
4	1.085 4	10	1.028 1	16	1.016 8	22	1.012 0	28	1.009 3
5	1.063 8	11	1.025 3	17	1.015 7	23	1.011 4	29	1.009 0
6	1.050 9	12	1.023 0	18	1.014 8	24	1.010 9	30	1.008 7

大偏差通常被视为估计的一种不足,有人提出了多种缩小偏差的方法.下面的刀切法就是由 Quenouille 于 1949 年和 1956 年提出的,而正式命名则由图基(Tukey)于 1958 年给出.

例 6.1.3(刀切法, jackknife) 设 $T(x)$ 是基于样本 $x = (x_1, x_2, \cdots, x_n)$ 的关于参数 $g(\theta)$ 的估计量,且满足 $E_\theta(T(x)) = g(\theta) + O\left(\frac{1}{n}\right)$. 如以 $x_{(-i)}$ 表示从样本中删去 x_i 后的向量,则 $T(x)$ 的刀切统计量定义为

$$T_j(x) = nT(x) - \frac{n-1}{n} \sum_{i=1}^n T(x_{(-i)}). \tag{6.1.3}$$

可以证明:由(6.1.3)式定义的刀切统计量具有如下性质:

$$E_\theta(T_j(x)) = g(\theta) + O\left(\frac{1}{n^2}\right),$$

并且其方差不会增大.

譬如,设总体为 $b(1, \theta)$, $x_1, x_2, \cdots, x_n$ 是其样本,又设 $g(\theta) = \theta^2$,则 $T(x) = \bar{x}^2$ 是 $g(\theta)$ 的一个估计,且

$$E(T(x)) = \theta^2 + \frac{\theta(1-\theta)}{n} = g(\theta) + O\left(\frac{1}{n}\right).$$

下面应用刀切法,注意到

$$T(x_{(-i)}) = \left(\frac{\sum_{j=1}^n x_j - x_i}{n-1} \right)^2 = \frac{n^2 \bar{x}^2 + x_i^2 - 2nx_i \bar{x}}{(n-1)^2},$$

于是

$$T_j(x) = n \bar{x}^2 - \frac{n-1}{n} \sum_{i=1}^n \frac{n^2 \bar{x}^2 + x_i^2 - 2nx_i \bar{x}}{(n-1)^2} = \frac{n \bar{x}^2}{n-1} - \frac{\sum_{i=1}^n x_i^2}{n(n-1)}.$$

可以验证 $ET_j(x) = g(\theta)$. 关于刀切法的详细介绍,有兴趣的读者可参考 Efron 的专著 [20].

并不是所有的参数都存在无偏估计,当参数存在无偏估计时,我们称该参数是可估的,否则称它是不可估的.下面是一个参数不可估的例子.

例 6.1.4 设总体为二点分布 $b(1, p)$, $0 < p < 1$, $x_1, x_2, \dots, x_n$ 是样本,我们说明参数 $\theta = 1/p$ 是不可估的.

首先, $T = x_1 + x_2 + \dots + x_n$ 是充分统计量, $T \sim b(n, p)$. 若有一个 $\hat{\theta} = \hat{\theta}(t)$ 是 θ 的无偏估计,则有

$$E_{\theta}(\hat{\theta}) = \sum_{i=1}^n \binom{n}{i} \hat{\theta}(i) p^i (1-p)^{n-i} = \frac{1}{p}$$

或

$$\sum_{i=1}^n \binom{n}{i} \hat{\theta}(i) p^{i+1} (1-p)^{n-i} - 1 = 0, \quad 0 < p < 1.$$

这是 p 的 $n+1$ 次方程,最多有 $n+1$ 个实根,要使它对所有 $p \in (0, 1)$ 都成立是不可能的,故参数 $\theta = 1/p$ 是不可估的.

其次,若有某个 $h(x_1, x_2, \dots, x_n)$ 是 θ 的无偏估计,则令 $\tilde{\theta} = E(h(x_1, x_2, \dots, x_n)/T)$, 由重期望公式知 $E_p(\tilde{\theta}) = E_p(E(h(x_1, x_2, \dots, x_n)/T)) = E_p(h(x_1, x_2, \dots, x_n)) = \theta$, 这说明 $\tilde{\theta}(T)$ 是 θ 的无偏估计,由前述,这是不可能的.

6.1.2 有效性

当参数可估时,其无偏估计可以有很多,如何在无偏估计中进行选择? 直观的想法是希望该估计围绕参数真值的波动越小越好,波动大小可以用方差来衡量,因此人们常用无偏估计的方差的大小作为度量无偏估计优劣的标准,这就是有效性.

定义 6.1.3 设 $\hat{\theta}_1, \hat{\theta}_2$ 是 θ 的两个无偏估计,如果对任意的 $\theta \in \Theta$ 有

$$\text{Var}(\hat{\theta}_1) \leq \text{Var}(\hat{\theta}_2),$$

且至少有一个 $\theta \in \Theta$ 使得上述不等号严格成立,则称 $\hat{\theta}_1$ 比 $\hat{\theta}_2$ 有效.

例 6.1.5 设 $x_1, x_2, \dots, x_n$ 是取自某总体的样本,记总体均值为 μ , 总体方差为 σ^2 ,

则 $\hat{\mu}_1 = x_1, \hat{\mu}_2 = \bar{x}$ 都是 μ 的无偏估计, 但

$$\text{Var}(\hat{\mu}_1) = \sigma^2, \quad \text{Var}(\hat{\mu}_2) = \sigma^2/n.$$

显然, 只要 $n > 1$, $\hat{\mu}_2$ 比 $\hat{\mu}_1$ 有效. 这表明, 用全部数据的平均估计总体均值要比只使用部分数据更有效.

例 6.1.6 设 $x_1, x_2, \dots, x_n$ 是来自均匀总体 $U(0, \theta)$ 的样本, 人们常用最大观测值 $x_{(n)}$ 来估计 θ (参见例 6.3.5), 由于 $E(x_{(n)}) = \frac{n}{n+1}\theta$, 所以 $x_{(n)}$ 不是 θ 的无偏估计, 但它是 θ 的渐近无偏估计. 经过修偏后可以得到 θ 的一个无偏估计 $\hat{\theta}_1 = \frac{n+1}{n}x_{(n)}$. 且

$$\text{Var}(\hat{\theta}_1) = \left(\frac{n+1}{n}\right)^2 \text{Var}(x_{(n)}) = \left(\frac{n+1}{n}\right)^2 \frac{n}{(n+1)^2(n+2)}\theta^2 = \frac{\theta^2}{n(n+2)}.$$

另一方面, 由于总体均值为 $\theta/2$, 人们也可以使用样本均值估计总体均值 (见 6.2 节), 于是可得到 θ 的另一个无偏估计 $\hat{\theta}_2 = 2\bar{x}$, 且

$$\text{Var}(\hat{\theta}_2) = 4\text{Var}(\bar{x}) = \frac{4}{n}\text{Var}(X) = \frac{4}{n} \cdot \frac{\theta^2}{12} = \frac{\theta^2}{3n},$$

两项比较知道, 当 $n > 1$ 时, $\hat{\theta}_1$ 比 $\hat{\theta}_2$ 有效.

习 题 6.1

1. 设 x_1, x_2, x_3 是取自某总体容量为 3 的样本, 试证下列统计量都是该总体均值 μ 的无偏估计, 在方差存在时指出哪一个估计的有效性最差.

$$(1) \hat{\mu}_1 = \frac{1}{2}x_1 + \frac{1}{3}x_2 + \frac{1}{6}x_3;$$

$$(2) \hat{\mu}_2 = \frac{1}{3}x_1 + \frac{1}{3}x_2 + \frac{1}{3}x_3;$$

$$(3) \hat{\mu}_3 = \frac{1}{6}x_1 + \frac{1}{6}x_2 + \frac{2}{3}x_3.$$

2. 设 $x_1, x_2, \dots, x_n$ 是来自 $\text{Exp}(\lambda)$ 的样本, 已知 $\bar{x}$ 为 $1/\lambda$ 的无偏估计, 试说明 $1/\bar{x}$ 是否为 λ 的无偏估计.

3. 设 $\hat{\theta}$ 是参数 θ 的无偏估计, 且有 $\text{Var}(\hat{\theta}) > 0$, 试证 $(\hat{\theta})^2$ 不是 θ^2 的无偏估计.

4. 设总体 $X \sim N(\mu, \sigma^2)$, $x_1, x_2, \dots, x_n$ 是来自该总体的一个样本. 试确定常数 c 使 $c \sum_{i=1}^{n-1} (x_{i+1} - x_i)^2$ 为 σ^2 的无偏估计.

5. 设 $x_1, x_2, \dots, x_n$ 是来自下列总体的简单样本,

$$p(x, \theta) = \begin{cases} 1, & \theta - \frac{1}{2} \leq x \leq \theta + \frac{1}{2}, \\ 0, & \text{其他}, \end{cases} \quad -\infty < \theta < \infty,$$

证明样本均值 $\bar{x}$ 及 $\frac{1}{2}(x_{(1)} + x_{(n)})$ 都是 θ 的无偏估计, 问何者更有效?

6. 设 x_1, x_2, x_3 服从均匀分布 $U(0, \theta)$, 试证 $\frac{4}{3}x_{(3)}$ 及 $4x_{(1)}$ 都是 θ 的无偏估计, 哪个更有效?

7. 设从均值为 μ , 方差为 $\sigma^2 > 0$ 的总体中分别抽取容量为 n_1 和 n_2 的两独立样本, $\bar{x}_1$ 和 $\bar{x}_2$ 分别是这两个样本的均值. 试证, 对于任意常数 a, b ($a+b=1$), $Y=a\bar{x}_1+b\bar{x}_2$ 都是 μ 的无偏估计, 并确定常数 a, b 使 $\text{Var}(Y)$ 达到最小.

8. 设总体 X 的均值为 μ , 方差为 σ^2 , $x_1, x_2, \dots, x_n$ 是来自该总体的一个样本, $T(x_1, x_2, \dots, x_n)$ 为 μ 的任一线性无偏估计量. 证明: $\bar{x}$ 与 T 的相关系数为 $\sqrt{\text{Var}(\bar{x})/\text{Var}(T)}$.

9. 设有 k 台仪器, 已知用第 i 台仪器测量的标准差为 σ_i ($i=1, 2, \dots, k$). 用这些仪器独立地对某一物理量 θ 各观察一次, 分别得到 $x_1, x_2, \dots, x_k$, 设仪器都没有系统偏差. 问 $a_1, a_2, \dots, a_k$ 应取何值, 方能使 $\hat{\theta} = \sum_{i=1}^k a_i x_i$ 成为 θ 的无偏估计, 且方差达到最小?

10. 设 $x_1, x_2, \dots, x_n$ 是来自 $N(\theta, 1)$ 的样本, 证明 $g(\theta) = |\theta|$ 没有无偏估计 (提示: 利用 $g(\theta)$ 在 $\theta=0$ 处不可导).

11. 设总体 X 服从正态分布 $N(\mu, \sigma^2)$, $x_1, x_2, \dots, x_n$ 为来自总体 X 的样本, 为了得到标准差 σ 的估计量, 考虑统计量:

$$y_1 = \frac{1}{n} \sum_{i=1}^n |x_i - \bar{x}|, \quad \bar{x} = \frac{1}{n} \sum_{i=1}^n x_i, \quad n \geq 2,$$

$$y_2 = \frac{1}{n(n-1)} \sum_{i=1}^n \sum_{j=1}^n |x_i - x_j|, \quad n \geq 2,$$

求常数 C_1 与 C_2 , 使得 $C_1 y_1$ 与 $C_2 y_2$ 都是 σ 的无偏估计.

§ 6.2 矩估计及相合性

6.2.1 替换原理和矩法估计

1900 年 K. 皮尔逊提出了一个替换原理, 后来人们称此方法为矩法.

替换原理常指如下两句话:

- 用样本矩去替换总体矩, 这里的矩可以是原点矩也可以是中心矩.
- 用样本矩的函数去替换相应的总体矩的函数.

根据这个替换原理, 在总体分布形式未知场合也可对各种参数作出估计, 譬如:

- 用样本均值 $\bar{x}$ 估计总体均值 $E(X)$.
- 用样本方差 s^2 估计总体方差 $\text{Var}(X)$.
- 用事件 A 出现的频率估计事件 A 发生的概率.
- 用样本的 p 分位数估计总体的 p 分位数, 特别, 用样本中位数估计总体中位数.

例 6.2.1 对某型号的 20 辆汽车记录其每 5 L 汽油的行驶里程 (单位: km), 观测数据如下:

29.8 27.6 28.3 27.9 30.1 28.7 29.9 28.0 27.9 28.7
28.4 27.2 29.5 28.5 28.0 30.0 29.1 29.8 29.6 26.9

这是一个容量为 20 的样本观测值,对应总体是该型号汽车每 5 L 汽油的行驶里程,其分布形式尚不清楚,可用矩法估计其均值、方差和中位数等.本例中经计算有

$$\bar{x} = 28.695, \quad s^2 = 0.9668, \quad m_{0.5} = 28.6,$$

由此给出总体均值、方差和中位数的估计分别为 28.695, 0.9668 和 28.6.

矩法估计的统计思想(替换原理)十分简单明确,众人都能接受,使用场合甚广.它的实质是用经验分布函数去替换总体分布,其理论基础是格利文科定理.

6.2.2 概率函数已知时未知参数的矩估计

设总体具有已知的概率函数 $p(x; \theta_1, \theta_2, \dots, \theta_k)$, $(\theta_1, \theta_2, \dots, \theta_k) \in \Theta$ 是未知参数或参数向量, $x_1, x_2, \dots, x_n$ 是样本,假定总体的 k 阶原点矩 μ_k 存在,则对所有的 j , $0 < j < k$, μ_j 都存在,若假设 $\theta_1, \theta_2, \dots, \theta_k$ 能够表示成 $\mu_1, \mu_2, \dots, \mu_k$ 的函数 $\theta_j = \theta_j(\mu_1, \mu_2, \dots, \mu_k)$, 则可给出诸 θ_j 的矩估计:

$$\hat{\theta}_j = \theta_j(a_1, a_2, \dots, a_k), \quad j = 1, 2, \dots, k,$$

其中 $a_1, a_2, \dots, a_k$ 是前 k 阶样本原点矩 $a_j = \frac{1}{n} \sum_{i=1}^n x_i^j$. 进一步,如果我们要估计 $\theta_1, \theta_2, \dots, \theta_k$ 的函数 $\eta = g(\theta_1, \theta_2, \dots, \theta_k)$, 则可直接得到 η 的矩估计

$$\hat{\eta} = g(\hat{\theta}_1, \hat{\theta}_2, \dots, \hat{\theta}_k),$$

当 $k=1$ 时,我们通常可以由样本均值出发对未知参数进行估计;如果 $k=2$,我们可以由一阶、二阶原点矩(或二阶中心矩)出发估计未知参数.

例 6.2.2 设总体为指数分布,其密度函数为

$$p(x; \lambda) = \lambda e^{-\lambda x}, \quad x \geq 0,$$

$x_1, x_2, \dots, x_n$ 是样本,此处 $k=1$, 由于 $E(X) = 1/\lambda$, 亦即 $\lambda = 1/E(X)$, 故 λ 的矩估计为

$$\hat{\lambda} = 1/\bar{x}.$$

另外,由于 $\text{Var}(X) = 1/\lambda^2$, 其反函数为 $\lambda = 1/\sqrt{\text{Var}(X)}$, 因此,从替换原理来看, λ 的矩估计也可取为

$$\hat{\lambda}_1 = 1/s,$$

s 为样本标准差.这说明矩估计可能是不唯一的,此时通常应该尽量采用低阶矩给出未知参数的估计.

例 6.2.3 设 $x_1, x_2, \dots, x_n$ 是来自均匀分布 $U(a, b)$ 的样本, a 与 b 均是未知参数,这里 $k=2$, 由于

$$E(X) = \frac{a+b}{2}, \quad \text{Var}(X) = \frac{(b-a)^2}{12},$$

不难推出

$$a = E(X) - \sqrt{3\text{Var}(X)}, \quad b = E(X) + \sqrt{3\text{Var}(X)},$$

由此即可得到 a, b 的矩估计:

$$\hat{a} = \bar{x} - \sqrt{3}s, \quad \hat{b} = \bar{x} + \sqrt{3}s,$$

若从均匀分布总体 $U(a, b)$ 获得如下一个容量为 5 的样本:

4.5 5.0 4.7 4.0 4.2

经计算,有 $\bar{x}=4.48, s=0.3962$,于是可得 a, b 的矩估计为

$$\hat{a} = 4.48 - 0.3962\sqrt{3} = 3.7938,$$

$$\hat{b} = 4.48 + 0.3962\sqrt{3} = 5.1662.$$

6.2.3 相合性

我们知道,点估计是一个统计量,因此它是一个随机变量,在样本量一定的条件下,我们不可能要求它完全等同于参数的真实取值.但如果我们有足够的观测值,根据格利文科定理,随着样本量的不断增大,经验分布函数逼近真实分布函数,因此完全可以要求估计量随着样本量的不断增大而逼近参数真值,这就是相合性,其定义如下.

定义 6.2.1 设 $\theta \in \Theta$ 为未知参数, $\hat{\theta}_n = \hat{\theta}_n(x_1, x_2, \dots, x_n)$ 是 θ 的一个估计量, n 是样本容量,若对任何一个 $\varepsilon > 0$,有

$$\lim_{n \rightarrow \infty} P(|\hat{\theta}_n - \theta| \geq \varepsilon) = 0, \quad (6.2.1)$$

则称 $\hat{\theta}_n$ 为参数 θ 的相合估计.

相合性被认为是对估计的一个最基本要求,如果一个估计量,在样本量不断增大时,它都不能把被估参数估计到任意指定的精度,那么这个估计是很值得怀疑的.通常,不满足相合性要求的估计不予考虑.

若把依赖于样本量 n 的估计量 $\hat{\theta}_n$ 看作一个随机变量序列,相合性就是 $\hat{\theta}_n$ 依概率收敛于 θ ,所以证明估计的相合性可应用依概率收敛的性质及各种大数定律.

例 6.2.4 设 $x_1, x_2, \dots$ 是来自正态总体 $N(\mu, \sigma^2)$ 的样本序列,则由辛钦大数定律及依概率收敛的性质知:

- $\bar{x}$ 是 μ 的相合估计.
- s_n^2 是 σ^2 的相合估计.
- s^2 也是 σ^2 的相合估计.

由此可见参数的相合估计不止一个.

在判断估计的相合性时下述两个定理是很有用的.

定理 6.2.1 设 $\hat{\theta}_n = \hat{\theta}_n(x_1, x_2, \dots, x_n)$ 是 θ 的一个估计量,若

$$\lim_{n \rightarrow \infty} E(\hat{\theta}_n) = \theta, \quad \lim_{n \rightarrow \infty} \text{Var}(\hat{\theta}_n) = 0, \quad (6.2.2)$$

则 $\hat{\theta}_n$ 是 θ 的相合估计.

证明 对任意的 $\varepsilon > 0$,由切比雪夫不等式有

$$P\left(|\hat{\theta}_n - E(\hat{\theta}_n)| \geq \frac{\varepsilon}{2}\right) \leq \frac{4}{\varepsilon^2} \text{Var}(\hat{\theta}_n).$$

另一方面,由 $\lim_{n \rightarrow \infty} E(\hat{\theta}_n) = \theta$ 可知,当 n 充分大时有

$$|E(\hat{\theta}_n) - \theta| < \frac{\varepsilon}{2}.$$

注意到此时如果 $|\hat{\theta}_n - E(\hat{\theta}_n)| < \frac{\varepsilon}{2}$, 就有

$$|\hat{\theta}_n - \theta| \leq |\hat{\theta}_n - E(\hat{\theta}_n)| + |E(\hat{\theta}_n) - \theta| < \varepsilon,$$

故

$$\left\{ |\hat{\theta}_n - E(\hat{\theta}_n)| < \frac{\varepsilon}{2} \right\} \subset \{ |\hat{\theta}_n - \theta| < \varepsilon \},$$

等价地

$$\left\{ |\hat{\theta}_n - E(\hat{\theta}_n)| \geq \frac{\varepsilon}{2} \right\} \supset \{ |\hat{\theta}_n - \theta| \geq \varepsilon \}.$$

由此即有

$$P(|\hat{\theta}_n - \theta| \geq \varepsilon) \leq P\left(|\hat{\theta}_n - E(\hat{\theta}_n)| \geq \frac{\varepsilon}{2}\right) \leq \frac{4}{\varepsilon^2} \text{Var}(\hat{\theta}_n) \rightarrow 0 \quad (n \rightarrow \infty),$$

定理得证.

例 6.2.5 设 $x_1, x_2, \dots, x_n$ 是来自均匀总体 $U(0, \theta)$ 的样本, 证明 $x_{(n)}$ 是 θ 的相合估计.

证明 由次序统计量的分布, 我们知道 $\hat{\theta} = x_{(n)}$ 的分布密度函数为

$$p(y) = ny^{n-1}/\theta^n, \quad y < \theta.$$

故有

$$E(\hat{\theta}) = \int_0^\theta ny^n dy / \theta^n = \frac{n}{n+1} \theta \rightarrow \theta \quad (n \rightarrow \infty),$$

$$E(\hat{\theta}^2) = \int_0^\theta ny^{n+1} dy / \theta^n = \frac{n}{n+2} \theta^2,$$

$$\text{Var}(\hat{\theta}) = \frac{n}{n+2} \theta^2 - \left(\frac{n}{n+1} \theta \right)^2 = \frac{n}{(n+1)^2(n+2)} \theta^2 \rightarrow 0 \quad (n \rightarrow \infty).$$

由定理 6.2.1 可知, $x_{(n)}$ 是 θ 的相合估计.

定理 6.2.2 若 $\hat{\theta}_{n1}, \hat{\theta}_{n2}, \dots, \hat{\theta}_{nk}$ 分别是 $\theta_1, \theta_2, \dots, \theta_k$ 的相合估计, $\eta = g(\theta_1, \theta_2, \dots, \theta_k)$ 是 $\theta_1, \theta_2, \dots, \theta_k$ 的连续函数, 则 $\hat{\eta}_n = g(\hat{\theta}_{n1}, \hat{\theta}_{n2}, \dots, \hat{\theta}_{nk})$ 是 η 的相合估计.

证明 由函数 g 的连续性, 对任意给定的 $\varepsilon > 0$, 存在一个 $\delta > 0$, 当 $|\hat{\theta}_{nj} - \theta_j| < \delta, j=1, 2, \dots, k$ 时, 有

$$|g(\hat{\theta}_{n1}, \hat{\theta}_{n2}, \dots, \hat{\theta}_{nk}) - g(\theta_1, \theta_2, \dots, \theta_k)| < \varepsilon. \quad (6.2.3)$$

又由 $\hat{\theta}_{n1}, \hat{\theta}_{n2}, \dots, \hat{\theta}_{nk}$ 的相合性, 对给定的 $\delta > 0$, 对任意给定的 $v > 0$, 存在正整数 N , 使得 $n \geq N$ 时,

$$P(|\hat{\theta}_{nj} - \theta_j| \geq \delta) < v/k, \quad j = 1, 2, \dots, k.$$

从而有

$$P\left(\bigcap_{j=1}^k \{|\hat{\theta}_{nj} - \theta_j| < \delta\}\right) = 1 - P\left(\bigcup_{j=1}^k \{|\hat{\theta}_{nj} - \theta_j| \geq \delta\}\right)$$

$$\begin{aligned} &\geq 1 - \sum_{j=1}^k P(|\hat{\theta}_{n_j} - \theta_j| \geq \delta) \\ &> 1 - k \cdot v/k = 1 - v. \end{aligned}$$

根据(6.2.3), $\bigcap_{j=1}^k \{|\hat{\theta}_{n_j} - \theta_j| < \delta\} \subset \{|\hat{\eta}_n - \eta| < \varepsilon\}$, 故有

$$P(|\hat{\eta}_n - \eta| < \varepsilon) > 1 - v,$$

由 v 的任意性, 定理得证.

由大数定律及定理 6.2.2, 我们可以看到, 矩估计一般都具有相合性. 比如:

- 样本均值是总体均值的相合估计.
- 样本标准差是总体标准差的相合估计.
- 样本变异系数 $s/\bar{x}$ 是总体变异系数的相合估计.

例 6.2.6 设一个试验有三种可能结果, 其发生概率分别为

$$p_1 = \theta^2, \quad p_2 = 2\theta(1 - \theta), \quad p_3 = (1 - \theta)^2.$$

现做了 n 次试验, 观测到三种结果发生的次数分别为 n_1, n_2, n_3 , 可以采用频率替换方法估计 θ . 由于可以有三个不同的 θ 的表达式

$$\theta = \sqrt{p_1}, \quad \theta = 1 - \sqrt{p_3}, \quad \theta = p_1 + p_2/2.$$

从而可以给出 θ 的三种不同的频率替换估计, 它们分别是

$$\hat{\theta}_1 = \sqrt{n_1/n}, \quad \hat{\theta}_2 = 1 - \sqrt{n_3/n}, \quad \hat{\theta}_3 = (n_1 + n_2/2)/n.$$

由大数定律, $n_1/n, n_2/n, n_3/n$ 分别是 p_1, p_2, p_3 的相合估计, 由定理 6.2.2 知, 上述三个估计都是 θ 的相合估计.

习题 6.2

1. 从一批电子元件中抽取 8 个进行寿命测试, 得到如下数据 (单位: h):

1 050 1 100 1 130 1 040 1 250 1 300 1 200 1 080

试对这批元件的平均寿命以及寿命分布的标准差给出矩估计.

2. 设总体 $X \sim U(0, \theta)$, 现从该总体中抽取容量为 10 的样本, 样本值为:

0.5 1.3 0.6 1.7 2.2 1.2 0.8 1.5 2.0 1.6

试对参数 θ 给出矩估计.

3. 设总体分布列如下, $x_1, x_2, \dots, x_n$ 是样本, 试求未知参数的矩估计:

(1) $P(X=k) = \frac{1}{N}, k=0, 1, 2, \dots, N-1, N$ (正整数) 是未知参数;

(2) $P(X=k) = (k-1)\theta^2(1-\theta)^{k-2}, k=2, 3, \dots, 0 < \theta < 1.$

4. 设总体密度函数如下, $x_1, x_2, \dots, x_n$ 是样本, 试求未知参数的矩估计:

(1) $p(x; \theta) = \frac{2}{\theta^2}(\theta - x), 0 < x < \theta, \theta > 0;$

(2) $p(x; \theta) = (\theta+1)x^\theta, 0 < x < 1, \theta > 0;$

(3) $p(x; \theta) = \sqrt{\theta}x^{\theta-1}, 0 < x < 1, \theta > 0;$