

统计推断的另一个主要内容是(统计)假设检验(hypothesis test).在这一章里我们将讨论(统计)假设的建立及其各种检验.

假设检验是由 K.皮尔逊(K.Pearson)于 20 世纪初提出的,之后由费希尔进行了细化,并最终由奈曼(Neyman)和 E.皮尔逊(E.Pearson)提出了较完整的假设检验理论.

§ 7.1 假设检验的基本思想与概念

7.1.1 假设检验问题

先从一个实例来考察假设检验的基本思想.

例 7.1.1(女士品茶试验) 一种奶茶由牛奶与茶按一定比例混合而成,可以先倒茶后倒奶(记为 TM),也可以反过来(记为 MT).某女士声称她可以鉴别是 TM 还是 MT,周围品茶的人对此产生了议论,“这怎么可能呢?”“她在胡言乱语.”“不可想象.”在场的费希尔也在思索这个问题,他提议做一项试验来检验如下假设(命题)是否可以接受:

假设 H :该女士无此种鉴别能力.

他准备了 10 杯调制好的奶茶, TM 与 MT 都有.服务员一杯一杯地奉上,让该女士品尝,说出是 TM 还是 MT,结果那位女士竟然正确地分辨出 10 杯奶茶中的每一杯.这时该如何对此作出判断呢?

费希尔的想法是:假如假设 H 是正确的,即该女士无此种鉴别能力,她只能猜,每次猜对的概率为 $1/2$, 10 次都猜对的概率为 $2^{-10} < 0.001$,这是一个很小的概率,在一次试验中几乎不会发生,如今该事件竟然发生了,这只能说明原假设 H 不当,应予以拒绝,而认为该女士确有辨别奶茶中 TM 与 MT 的能力.费希尔用试验结果对假设 H 的对错进行判断的思维方式可归纳如下:

假如试验结果与假设 H 发生矛盾就拒绝原假设 H , 否则就接受原假设.

当然,实际操作远非这么简单,假如该女士说对了 9 杯(或 8 杯等),又该如何对 H 作出判断呢? 判断会发生错误吗? 发生错误的概率是多少? 能被控制吗? 这里还有很多细节需要研究,费希尔对这些细节作了周密的研究,提出一些新的概念,建立一套可行的方法,形成假设检验理论,为进一步发展假设检验理论与方法打下了牢固基础.

本章将详细讨论其中基础和实用部分,进一步结果可参阅文献[15].

下面再用一个实例引出假设检验中的一些基本概念和操作步骤.

例 7.1.2 某厂生产的合金强度服从正态分布 $N(\theta, 16)$, 其中 θ 的设计值为不低于 110 Pa. 为保证质量, 该厂每天都要对生产情况做例行检查, 以判断生产是否正常进行, 即该合金的平均强度是否不低于 110 Pa. 某天从生产的产品中随机抽取 25 块合金, 测得其强度值为 $x_1, x_2, \dots, x_{25}$, 均值为 $\bar{x} = 108.2$ Pa, 问当日生产是否正常?

对这个实际问题可作如下分析:

(1) 这不是一个参数估计问题.

(2) 这是在给定总体与样本下, 要求对命题“合金平均强度不低于 110 Pa”作出回答: “是”还是“否”? 这类问题称为统计假设检验问题, 简称假设检验问题.

(3) 命题: “合金平均强度不低于 110 Pa”仅涉及参数 θ 范围, 因此该命题是否正确将涉及如下两个参数集合:

$$\Theta_0 = \{\theta: \theta \geq 110\}, \quad \Theta_1 = \{\theta: \theta < 110\}.$$

命题成立对应于“ $\theta \in \Theta_0$ ”, 命题不成立则对应“ $\theta \in \Theta_1$ ”. 在统计学中这两个非空不相交参数集合都称作统计假设, 简称假设.

(4) 我们的任务是利用所给总体 $N(\theta, 16)$ 和样本均值 $\bar{x} = 108.2$ Pa 判断假设(命题)“ $\theta \in \Theta_0$ ”是否成立. 通过样本对一个假设作出“对”或“不对”的具体判断规则就称为该假设的一个检验或检验法则. 检验的结果若是否定该命题, 则称拒绝这个假设, 否则就称接受该假设.

(5) 若假设可用一个参数的集合表示, 该假设检验问题称为参数假设检验问题, 否则称为非参数假设检验问题. 例 7.1.2 就是一个参数假设检验问题, 而对假设“总体为正态分布”作出检验的问题就是一个非参数假设检验问题.

7.1.2 假设检验的基本步骤

接下来我们来叙述假设检验的基本步骤.

一、建立假设

这里主要叙述参数假设检验问题. 设有来自某一个参数分布族 $\{F(x, \theta) | \theta \in \Theta\}$ 的样本 $x_1, x_2, \dots, x_n$, 其中 Θ 为参数空间, 设 $\Theta_0 \subset \Theta$, 且 $\Theta_0 \neq \emptyset$, 则命题 $H_0: \theta \in \Theta_0$ 称为一个假设或原假设或零假设 (null hypothesis), 若有另一个 Θ_1 ($\Theta_1 \subset \Theta, \Theta_1 \cap \Theta_0 = \emptyset$), 常见的一种情况是 $\Theta_1 = \Theta - \Theta_0$), 则命题 $H_1: \theta \in \Theta_1$ 称为 H_0 的对立假设或备择假设 (alternative hypothesis). 于是, 我们感兴趣的一对假设就是

$$H_0: \theta \in \Theta_0 \quad \text{vs} \quad H_1: \theta \in \Theta_1 \quad (7.1.1)$$

其中“vs”是 versus 的缩写, 是“对”的意思, 即表示 H_0 对 H_1 的假设检验问题.

对于假设 (7.1.1), 如果 Θ_0 只含一个点, 则我们称之为简单 (simple) 原假设, 否则就称为复杂 (composite) 或复合原假设. 同样, 对于备择假设也有简单与复杂之别. 当 H_0 为简单假设时, 其形式可写成 $H_0: \theta = \theta_0$. 此时的备择假设通常有如下三种可能:

$$H'_1: \theta \neq \theta_0, \quad H''_1: \theta < \theta_0, \quad H'''_1: \theta > \theta_0.$$

我们称 H_0 vs H'_1 为双侧假设或双边假设 (因备择假设分散在原假设两侧而得名), H_0 vs H''_1 以及 H_0 vs H'''_1 为单侧假设或单边假设 (因备择假设位于原假设的一侧而得名).

在假设检验中,通常将不宜轻易加以否定的假设作为原假设.在例 7.1.2 中,我们可建立如下—对假设:

$$H_0: \theta \in \Theta_0 = \{ \theta: \theta \geq 110 \} \quad \text{vs} \quad H_1: \theta \in \Theta_1 = \{ \theta: \theta < 110 \}$$

或简写为

$$H_0: \theta \geq 110 \quad \text{vs} \quad H_1: \theta < 110.$$

二、选择检验统计量,给出拒绝域形式

对于假设(7.1.1)的检验就是指这样的一个法则:当有了具体的样本后,按该法则就可决定是接受 H_0 还是拒绝 H_0 ,即检验就等价于把样本空间划分成两个互不相交的部分 W 和 $\bar{W}$,当样本属于 W 时,拒绝 H_0 ;否则接受 H_0 .于是,我们称 W 为该检验的拒绝域,而 $\bar{W}$ 称为接受域.

由样本对原假设进行检验总是通过一个统计量完成的,该统计量称为检验统计量.比如,在例 7.1.2 中,样本均值 $\bar{x}$ 就是一个很好的检验统计量,因为要检验的假设是正态总体均值,在方差已知场合,样本均值 $\bar{x}$ 是总体均值的充分统计量.在例 7.1.2 中,总体均值 θ 越大, $\bar{x}$ 取大值的概率越大.亦即, $\bar{x}$ 越大越支持原假设, $\bar{x}$ 越小越支持备择假设,所以拒绝域形如

$$W = \{ (x_1, x_2, \dots, x_n) : \bar{x} \leq c \} = \{ \bar{x} \leq c \}$$

是合理的,其中临界值 c 待定.

当拒绝域确定了,检验的判断准则跟着也确定了:

- 如果 $(x_1, x_2, \dots, x_n) \in W$, 则拒绝 H_0 .
- 如果 $(x_1, x_2, \dots, x_n) \in \bar{W}$, 接受 H_0 .

由此可见,一个拒绝域 W 唯一确定一个检验法则,反之,一个检验法则也唯一确定一个拒绝域.在两个观测值 ($n=2$) 场合,图 7.1.1 给出拒绝域的示意图.

通常我们将注意力放在拒绝域上.正如在数学上不能用一个例子去证明一个结论一样,用一个样本(例子)不能证明一个命题(假设)是成立的,但可以用一个例子(样本)推翻一个命题.因此,从逻辑上看,注重拒绝域是适当的.事实上,在“拒绝原假设”和“拒绝备择假设(从而接受原假设)”之间还有一个模糊域,如今我们把它并入接受域(参

见图 7.1.1),所以接受域是复杂的,将之称为保留域也许更恰当,但习惯上已把它称为接受域,没有必要再进行改变,只是应注意它的含义.




图 7.1.1 拒绝域示意图

三、选择显著性水平

由于样本是随机的,故当我们应用某种检验作判断时,可能做出正确的判断,也可能做出错误的判断,因此,可能犯如下两种错误:当 $\theta \in \Theta_0$ 时,样本由于随机性却落入了拒绝域 W ,于是我们采取了拒绝 H_0 的错误决策,称这样的错误为第一类错误(type

I error); 当 $\theta \in \Theta_1$ 时, 样本却落入了接受域 $\bar{W}$, 于是我们采取了接受 H_0 的错误决策, 称这样的错误为第二类错误 (type II error). 具体的可见表 7.1.1.

表 7.1.1 检验的两类错误

观测数据情况	总体情况	
	H_0 为真	H_1 为真
$(x_1, x_2, \cdots, x_n) \in W$	犯第一类错误	正确
$(x_1, x_2, \cdots, x_n) \in \bar{W}$	正确	犯第二类错误

在实际中, 分别称第一类、第二类错误为拒真错误与取伪错误.

由于检验结果受样本的影响, 具有随机性, 于是, 可用总体分布定义犯第一类、第二类错误概率如下:

犯第一类错误概率: $\alpha(\theta) = P_\theta\{X \in W\}, \theta \in \Theta_0$.

犯第二类错误概率: $\beta(\theta) = P_\theta\{X \in \bar{W}\}, \theta \in \Theta_1$.

事实上, 每一个检验都无法避免犯错误的可能, 那能否找到一个检验, 使其犯两类错误的概率都尽可能地小呢? 实际上, 我们也做不到这一点. 为了说明其原因, 先引进如下的势函数或功效函数 (power function) 的概念.

定义 7.1.1 设检验问题

$$H_0: \theta \in \Theta_0 \quad \text{vs} \quad H_1: \theta \in \Theta_1$$

的拒绝域为 W , 则样本观测值 X 落在拒绝域 W 内的概率称为该检验的势函数, 记为

$$g(\theta) = P_\theta(X \in W), \quad \theta \in \Theta = \Theta_0 \cup \Theta_1. \tag{7.1.2}$$

显然, 势函数 $g(\theta)$ 是定义在参数空间 Θ 上的一个函数. 当 $\theta \in \Theta_0$ 时, $g(\theta) = \alpha(\theta)$, 当 $\theta \in \Theta_1$ 时 $g(\theta) = 1 - \beta(\theta)$. 由此可见, 犯两类错误的概率都是参数 θ 的函数, 并可由势函数得到, 即

$$g(\theta) = \begin{cases} \alpha(\theta), & \theta \in \Theta_0, \\ 1 - \beta(\theta), & \theta \in \Theta_1, \end{cases} \quad \text{或} \quad \begin{cases} \alpha(\theta) = g(\theta), & \theta \in \Theta_0, \\ \beta(\theta) = 1 - g(\theta), & \theta \in \Theta_1. \end{cases}$$

下面通过例 7.1.2 说明无法使一个检验犯第一类、第二类错误概率同时变小. 对例 7.1.2, 其拒绝域为 $W = \{\bar{x} \leq c\}$, 由 (7.1.2) 可以算出该检验的势函数

$$g(\theta) = P_\theta(\bar{x} \leq c) = P_\theta\left(\frac{\bar{x} - \theta}{4/5} \leq \frac{c - \theta}{4/5}\right) = \Phi\left(\frac{c - \theta}{4/5}\right),$$

注意到 $\bar{x} \sim N(\theta, 16/25)$, 这个势函数是 θ 的减函数 (见图 7.1.2).




图 7.1.2 例 7.1.2 的势函数 $g(\theta)$

利用这个势函数容易写出其犯两类错误的概率分别为

$$\alpha(\theta) = \Phi\left(\frac{c-\theta}{4/5}\right), \quad \theta \in \Theta_0, \quad (7.1.3)$$

$$\beta(\theta) = 1 - \Phi\left(\frac{c-\theta}{4/5}\right), \quad \theta \in \Theta_1. \quad (7.1.4)$$

由上述两个式子可以看出犯两类错误的概率 $\alpha(\theta), \beta(\theta)$ 间的关系:

- 当 $\alpha(\theta)$ 减小时, 由 (7.1.3) 知, c 也随之减小, 再由 (7.1.4) 知, c 的减小必导致 $\beta(\theta)$ 的增大.
- 当 $\beta(\theta)$ 减小时, 由 (7.1.4) 知, c 会增大, 再由 (7.1.3) 知, c 的增大必导致 $\alpha(\theta)$ 的增大.

这一现象说明: 在样本量给定的条件下, $\alpha(\theta)$ 与 $\beta(\theta)$ 中一个减小必导致另一个增大, 这不是偶然的, 而具有一般性. 这进一步说明: 在样本量一定的条件下不可能找到一个使 $\alpha(\theta), \beta(\theta)$ 都小的检验. 还应注意, 犯第二类错误的概率在不少场合不易求出.

既然我们不可能同时控制一个检验的犯第一类、第二类错误的概率, 在此背景下, 只能采取折中方案. 通常的做法是仅限制犯第一类错误的概率, 这就是费希尔的显著性检验, 下面给出正式定义.

定义 7.1.2 对检验问题 $H_0: \theta \in \Theta_0$ vs $H_1: \theta \in \Theta_1$, 如果一个检验满足对任意的 $\theta \in \Theta_0$, 都有

$$g(\theta) \leq \alpha,$$

则称该检验是显著性水平为 α 的显著性检验, 简称水平为 α 的检验.

提出显著性检验的概念就是要控制犯第一类错误的概率 α , 但也不能使得 α 过小 (α 过小会导致 β 过大), 在适当控制 α 中制约 β . 最常用的选择是 $\alpha = 0.05$, 有时也选择 $\alpha = 0.10$ 或 $\alpha = 0.01$.

四、给出拒绝域

在确定显著性水平后, 我们可以定出检验的拒绝域 W . 在例 7.1.2 中, 对给定的显著性水平 α , 则要求对任意的 $\theta \geq 110$ 有 $g(\theta) = \Phi\left(\frac{5(c-\theta)}{4}\right) \leq \alpha$, 由于 $g(\theta)$ 是关于 θ 的单调减函数 (见图 7.1.2), 只需要

$$g(110) = \Phi\left(\frac{5(c-110)}{4}\right) = \alpha$$

成立即可. 用标准正态分布分位数可把上式改写为 $\frac{5(c-110)}{4} = u_\alpha$, 从而 c 的值为 $c = 110 + 0.8u_\alpha$, 检验的拒绝域为

$$W = \{\bar{x} \leq 110 + 0.8u_\alpha\}.$$

若取 $\alpha = 0.05$, 则 $u_{0.05} = -u_{0.95}$, 具体 c 值为

$$c = 110 + 0.8u_{0.05} = 110 - 0.8 \times 1.645 = 108.684.$$

所以, 检验的拒绝域为

$$W = \{\bar{x} \leq 108.684\}.$$

若令 $u = \frac{\bar{x}-110}{4/5}$, 则拒绝域有另一种表示, 即

$$W = \{u \leq u_{0.05}\} = \{u \leq -1.645\}.$$

今后主要用检验统计量 u 表示拒绝域.

五、做出判断

在有了明确的拒绝域 W 后, 根据样本观测值我们可以作出判断:

- 当 $u \leq -1.645$ 时, 则拒绝 H_0 , 即接受 H_1 .
- 当 $u > -1.645$ 时, 则接受 H_0 .

在例 7.1.2 中, 由于

$$u_0 = \frac{108.2-110}{4/5} = -2.25 < -1.645$$

因此拒绝原假设, 即认为该日生产不正常.

综上, 一般情况下, 寻找某对假设的显著性检验的步骤如下:

- 根据实际问题, 建立统计假设 H_0 vs H_1 .
- 选取一个合适的检验统计量 $T(X)$, 使当 H_0 成立时 (或 H_0 中某个具体参数下), T 的分布完全已知, 并根据 H_0 及 H_1 的特点, 确定拒绝域 W 的形式.
- 选择合适的显著性水平 α , 确定具体的拒绝域 W .
- 由样本观测值 $x_1, x_2, \dots, x_n$, 计算检验统计量的 $T(x_1, x_2, \dots, x_n)$, 由 $T(x_1, x_2, \dots, x_n)$ 是否属于 W , 作出最终判断.

7.1.3 检验的 p 值

假设检验的结论通常是简单的. 在给定的显著性水平下, 不是拒绝原假设就是接受原假设. 然而有时也会出现这样的情况: 在一个较大的显著性水平 (比如 $\alpha = 0.05$) 下得到拒绝原假设的结论, 而在一个较小的显著性水平 (比如 $\alpha = 0.01$) 下却会得到相反的结论. 这种情况在理论上很容易解释: 因为显著性水平变小后会导致检验的拒绝域变小, 于是原来落在拒绝域中的观测值就可能落入接受域, 但这种情况在应用中会带来一些麻烦: 假如这时一个人主张选择显著性水平 $\alpha = 0.05$, 而另一个人主张选 $\alpha = 0.01$, 则第一个人的结论是拒绝 H_0 , 而后一个人的结论是接受 H_0 , 我们该如何处理这一问题呢? 下面用例 7.1.2 来讨论这个问题.

在上一小节中, 我们给出了例 7.1.2 的检验统计量及拒绝域 $W = \{\bar{x} \leq 110 + 0.8u_\alpha\}$, 或表示为 $W = \{u \leq u_\alpha\}$, 其中 $u_0 = 1.25(\bar{x} - 110) = -2.25$. 对一些显著性水平, 表 7.1.2 列出了相应的拒绝域和检验结论.

表 7.1.2 例 7.1.2 中的拒绝域

显著性水平	拒绝域	对应的结论 ($u_0 = -2.25$)
$\alpha = 0.1$	$u \leq -1.282$	拒绝 H_0
$\alpha = 0.05$	$u \leq -1.645$	拒绝 H_0
$\alpha = 0.025$	$u \leq -1.96$	拒绝 H_0

续表

显著性水平	拒绝域	对应的结论 ($u_0 = -2.25$)
$\alpha = 0.01$	$u \leq -2.326$	接受 H_0
$\alpha = 0.005$	$u \leq -2.576$	接受 H_0

我们看到,不同的 α 有不同的结论.

现在换一个角度来看,在 $\mu = 110$ 时,检验统计量 u 的分布是 $N(0, 1)$. 此时由样本可算得 u 的值 $u_0 = -2.25$, 据此可算得一个概率 $p = P(u \leq u_0) = P(u \leq -2.25) = \Phi(-2.25) = 0.0122$, 若以此为基准来看上述检验问题, 亦可作出判断, 具体如下:

- 当 $\alpha < 0.0122$ 时, $u_\alpha < -2.25$, 由于拒绝域为 $W = \{u \leq u_\alpha\}$, 于是观测值 $u_0 = -2.25$ 不在拒绝域里, 应接受原假设.
- 当 $\alpha \geq 0.0122$ 时, $u_\alpha \geq -2.25$, 由于拒绝域为 $W = \{u \leq u_\alpha\}$, 于是观测值 $u_0 = -2.25$ 落在拒绝域里, 应拒绝原假设.

由此可以看出, 0.0122 是能用观测值 $u_0 = -2.25$ 作出“拒绝 H_0 ”的最小的显著性水平, 这就是 p 值.

定义 7.1.3 在一个假设检验问题中, 利用样本观测值能够作出拒绝原假设的最小显著性水平称为**检验的 p 值**.

由检验的 p 值与人们心目中的显著性水平 α 进行比较可以很容易作出检验的结论:

- 如果 $p \leq \alpha$, 则在显著性水平 α 下拒绝 H_0 .
- 如果 $p > \alpha$, 则在显著性水平 α 下接受 H_0 .

p 值在实际中很有用, 如今的统计软件中对检验问题一般都会给出检验的 p 值.

我们后面的检验可从两方面进行, 其一是建立拒绝域, 考察样本观测值是否落入拒绝域而加以判断; 其二是根据样本观测值计算检验的 p 值, 通过将 p 值与事先设定的显著性水平 α 比较大小而作出判断. 两者是等价的, 哪个方便用哪个.

实际中, p 很小时 (如 $p \leq 0.001$) 即可拒绝原假设, p 很大时 (如 $p > 0.5$) 即可接受原假设. 只有当 p 与 α 接近时才需比较. 这样至少可减少部分争论.

习 题 7.1

1. 设 $x_1, x_2, \dots, x_n$ 是来自 $N(\mu, 1)$ 的样本, 考虑如下假设检验问题
- $$H_0: \mu = 2 \quad \text{vs} \quad H_1: \mu = 3,$$
- 若检验由拒绝域为 $W = \{\bar{x} \geq 2.6\}$ 确定.
- (1) 当 $n = 20$ 时求检验犯两类错误的概率;
 - (2) 如果要使得检验犯第二类错误的概率 $\beta \leq 0.01$, n 最小应取多少?
 - (3) 证明: 当 $n \rightarrow \infty$ 时, $\alpha \rightarrow 0, \beta \rightarrow 0$.
2. 设 $x_1, x_2, \dots, x_{10}$ 是来自 $0-1$ 总体 $b(1, p)$ 的样本, 考虑如下检验问题:
- $$H_0: p = 0.2 \quad \text{vs} \quad H_1: p = 0.4,$$
- 取拒绝域为 $W = \{\bar{x} \geq 0.5\}$, 求该检验犯两类错误的概率.