

§ 8.1 方差分析

8.1.1 问题的提出

前面几章我们讨论的都是一个总体或两个总体的统计分析问题,在实际工作中我们还会经常碰到多个总体均值的比较问题,处理这类问题通常采用所谓的方差分析方法.本节将叙述这个方法,先看一个例子.

例 8.1.1 在饲料养鸡增肥的研究中,某研究所提出三种饲料配方: A_1 是以鱼粉为主的饲料, A_2 是以槐米粉为主的饲料, A_3 是以苜蓿粉为主的饲料.为比较三种饲料的效果,特选 24 只相似的雏鸡随机均分为三组,每组各喂一种饲料,60 天后观察它们的质量.试验结果如表 8.1.1 所示:

表 8.1.1 鸡饲料试验数据

单位:g

饲料 A	鸡的质量							
A_1	1 073	1 009	1 060	1 001	1 002	1 012	1 009	1 028
A_2	1 107	1 092	990	1 109	1 090	1 074	1 122	1 001
A_3	1 093	1 029	1 080	1 021	1 022	1 032	1 029	1 048

本例中,我们要比较的是三种饲料对鸡的增肥作用是否相同.为此,把饲料称为因子,记为 A ,三种不同的配方称为因子 A 的三个水平,记为 A_1, A_2, A_3 ,使用配方 A_i 下第 j 只鸡 60 天后的质量用 y_{ij} 表示, $i=1, 2, 3, j=1, 2, \dots, 8$.我们的目的是比较三种饲料配方下鸡的平均质量是否相等,为此,需要做一些基本假定,把所研究的问题归结为一个统计问题,然后用方差分析的方法进行分析.若相等,可任选一种饲料,特别可选廉价饲料;若不等,应选增肥效果好的饲料.

8.1.2 单因子方差分析的统计模型

在例 8.1.1 中我们只考察了一个因子,称其为单因子试验.通常,在单因子试验中,记因子为 A ,设其有 r 个水平,记为 $A_1, A_2, \dots, A_r$,在每一水平下考察的指标可以看成一

个总体,现有 r 个水平,故有 r 个总体,假定:

(1) 每一总体均为正态总体,记为 $N(\mu_i, \sigma_i^2), i=1, 2, \dots, r$.

(2) 各总体的方差相同,记为 $\sigma_1^2 = \sigma_2^2 = \dots = \sigma_r^2 = \sigma^2$.

(3) 从每一总体中抽取的样本是相互独立的,即所有的试验结果 y_{ij} 都相互独立.

这三个假定都可以用统计方法进行验证.譬如,利用正态性检验(§ 7.5 节)验证(1)成立,利用后面 § 8.3 的方差齐性检验验证(2)成立,而试验结果 y_{ij} 的独立性可由随机化实现,这里的随机化是指所有试验按随机次序进行.

我们要做的工作是比较各水平下的均值是否相同,即要对如下的一个假设进行检验:

$$H_0: \mu_1 = \mu_2 = \dots = \mu_r, \quad (8.1.1)$$

其备择假设为

$$H_1: \mu_1, \mu_2, \dots, \mu_r \text{ 不全相等,}$$

在不会引起误解的情况下, H_1 通常可省略不写.

如果 H_0 成立,因子 A 的 r 个水平均值相同,称因子 A 的 r 个水平间没有显著差异,简称因子 A 不显著;反之,当 H_0 不成立时,因子 A 的 r 个水平均值不全相同,这时称因子 A 的不同水平间有显著差异,简称因子 A 显著.

为对假设(8.1.1)进行检验,需要从每一水平下的总体抽取样本,设从第 i 个水平下的总体获得 m 个试验结果(简单起见,这里先假设各水平下试验的重复数相同,后面会看到,重复数不同的处理方法与此基本一致,略有差异),用 y_{ij} 表示第 i 个总体的第 j 次重复试验结果,共得如下 $r \times m$ 个试验结果:

$$y_{ij}, \quad i = 1, 2, \dots, r, \quad j = 1, 2, \dots, m,$$

其中 r 为水平数, m 为重复数, i 为水平编号, j 为重复序号.

水平 A_i 下的试验结果 y_{ij} 与该水平下的指标均值 μ_i 总是有差距的,记 $\varepsilon_{ij} = y_{ij} - \mu_i$, ε_{ij} 称为随机误差.于是有

$$y_{ij} = \mu_i + \varepsilon_{ij}. \quad (8.1.2)$$

(8.1.2) 式称为试验结果 y_{ij} 的数据结构式.把三个假定用于数据结构式就可以写出单因子方差分析的统计模型:

$$\begin{cases} y_{ij} = \mu_i + \varepsilon_{ij}, & i = 1, 2, \dots, r, \quad j = 1, 2, \dots, m, \\ \text{诸 } \varepsilon_{ij} \text{ 相互独立, 且都服从 } N(0, \sigma^2). \end{cases} \quad (8.1.3)$$

为了能更好地描述数据,常在方差分析中引入总均值与水平效应的概念.诸 μ_i 的平均(所有试验结果的均值的平均)

$$\mu = \frac{1}{r}(\mu_1 + \mu_2 + \dots + \mu_r) = \frac{1}{r} \sum_{i=1}^r \mu_i \quad (8.1.4)$$

称为总均值,也称一般平均.第 i 个水平下的均值 μ_i 与总均值 μ 的差

$$a_i = \mu_i - \mu, \quad i = 1, 2, \dots, r \quad (8.1.5)$$

称为因子 A 的第 i 个水平的主效应,简称为 A_i 的水平效应.

容易看出

$$\sum_{i=1}^r a_i = 0, \quad (8.1.6)$$

$$\mu_i = \mu + a_i, \tag{8.1.7}$$

这表明第 i 个总体的均值是由总均值与该水平的效应叠加而成的,从而模型(8.1.3)可以改写为

$$\begin{cases} y_{ij} = \mu + a_i + \varepsilon_{ij}, & i = 1, 2, \cdots, r, j = 1, 2, \cdots, m, \\ \sum_{i=1}^r a_i = 0, \\ \text{诸 } \varepsilon_{ij} \text{ 相互独立, 且都服从 } N(0, \sigma^2). \end{cases} \tag{8.1.8}$$

假设(8.1.1)可改写为

$$H_0: a_1 = a_2 = \cdots = a_r = 0, \tag{8.1.9}$$

其备择假设为

$$H_1: a_1, a_2, \cdots, a_r \text{ 不全为 } 0.$$

8.1.3 平方和分解

对两个正态总体均值间有无差异可用 t 检验,但对三个及以上正态总体均值间有无差异再用 t 检验就行不通了. 费希尔等人另辟思路,改用数据的平方和及其分解导出 F 分布来进行显著性检验. 下面我们介绍这个思想.

一、试验数据

通常在单因子方差分析中可将试验数据列成如下表格形式.

表 8.1.2 单因子方差分析试验数据

因子水平	试验数据				和	均值
A_1	y_{11}	y_{12}	$\cdots$	y_{1m}	T_1	$\bar{y}_{1\cdot}$
A_2	y_{21}	y_{22}	$\cdots$	y_{2m}	T_2	$\bar{y}_{2\cdot}$
$\vdots$	$\vdots$	$\vdots$		$\vdots$	$\vdots$	$\vdots$
A_r	y_{r1}	y_{r2}	$\cdots$	y_{rm}	T_r	$\bar{y}_{r\cdot}$
					T	$\bar{y}$

表 8.1.2 中的最后两列的和与均值的含义如下:

$$T_i = \sum_{j=1}^m y_{ij}, \quad \bar{y}_{i\cdot} = \frac{T_i}{m}, \quad i = 1, 2, \cdots, r,$$
$$T = \sum_{i=1}^r T_i, \quad \bar{y} = \frac{T}{r \cdot m} = \frac{T}{n},$$

$n = r \cdot m =$ 总试验次数.

二、组内偏差与组间偏差

数据间是有差异的.数据 y_{ij} 与总均值 $\bar{y}$ 间的偏差可用 $y_{ij} - \bar{y}$ 表示,它可分解为两个偏差之和

$$y_{ij} - \bar{y} = (y_{ij} - \bar{y}_{i\cdot}) + (\bar{y}_{i\cdot} - \bar{y}). \tag{8.1.10}$$

记

$$\bar{\varepsilon}_{i\cdot} = \frac{1}{m} \sum_{j=1}^m \varepsilon_{ij}, \quad \bar{\varepsilon} = \frac{1}{r} \sum_{i=1}^r \bar{\varepsilon}_{i\cdot} = \frac{1}{n} \sum_{i=1}^r \sum_{j=1}^m \varepsilon_{ij}.$$

由于

$$y_{ij} - \bar{y}_{i\cdot} = (\mu_i + \varepsilon_{ij}) - (\mu_i + \bar{\varepsilon}_{i\cdot}) = \varepsilon_{ij} - \bar{\varepsilon}_{i\cdot}, \quad (8.1.11)$$

所以 $y_{ij} - \bar{y}_{i\cdot}$ 仅反映组内数据与组内均值的随机误差,称为组内偏差.而

$$\bar{y}_{i\cdot} - \bar{y} = (\mu_i + \bar{\varepsilon}_{i\cdot}) - (\mu + \bar{\varepsilon}) = \alpha_i + \bar{\varepsilon}_{i\cdot} - \bar{\varepsilon}, \quad (8.1.12)$$

$\bar{y}_{i\cdot} - \bar{y}$ 除了反映随机误差外,还反映了第 i 个水平效应,称为组间偏差.

三、偏差平方和及其自由度

在统计学中,把 k 个数据 $y_1, y_2, \dots, y_k$ 分别对其均值 $\bar{y} = (y_1 + y_2 + \dots + y_k)/k$ 的偏差平方和

$$Q = (y_1 - \bar{y})^2 + (y_2 - \bar{y})^2 + \dots + (y_k - \bar{y})^2 = \sum_{i=1}^k (y_i - \bar{y})^2$$

称为 k 个数据的偏差平方和,有时简称平方和.偏差平方和常用来度量若干个数据分散的程度,它是用来度量若干个数据间差异(即波动)的大小的一个重要的统计量.

在构成偏差平方和 Q 的 k 个偏差 $y_1 - \bar{y}, y_2 - \bar{y}, \dots, y_k - \bar{y}$ 间有一个恒等式

$$\sum_{i=1}^k (y_i - \bar{y}) = 0,$$

这说明在 Q 中独立的偏差只有 $k-1$ 个.在统计学中把平方和中独立偏差个数称为该平方和的自由度,常记为 f ,如 Q 的自由度为 $f_Q = k-1$.自由度是偏差平方和的一个重要参数.

四、总平方和分解公式

各 y_{ij} 间总的差异大小可用总偏差平方和 S_T 表示

$$S_T = \sum_{i=1}^r \sum_{j=1}^m (y_{ij} - \bar{y})^2, \quad f_T = n - 1, \quad (8.1.13)$$

仅由随机误差引起的数据间的差异可以用组内偏差平方和表示,也称为误差偏差平方和,记为 S_e ,即

$$S_e = \sum_{i=1}^r \sum_{j=1}^m (y_{ij} - \bar{y}_{i\cdot})^2, \quad f_e = r(m-1) = n - r. \quad (8.1.14)$$

由于组间差异除了随机误差外,还反映了效应间的差异,故效应不同引起的数据差异可用组间偏差平方和表示,也称为因子 A 的偏差平方和,记为 S_A ,即

$$S_A = m \sum_{i=1}^r (\bar{y}_{i\cdot} - \bar{y})^2, \quad f_A = r - 1. \quad (8.1.15)$$

定理 8.1.1 在上述符号下,总平方和 S_T 可以分解为因子平方和 S_A 与误差平方和 S_e 之和,其自由度也有相应分解公式,具体为

$$S_T = S_A + S_e, \quad f_T = f_A + f_e, \quad (8.1.16)$$

(8.1.16)式通常称为总平方和分解式.

证明 注意到

$$\sum_{i=1}^r \sum_{j=1}^m (y_{ij} - \bar{y}_{i\cdot}) (\bar{y}_{i\cdot} - \bar{y}) = \sum_{i=1}^r [(\bar{y}_{i\cdot} - \bar{y}) \sum_{j=1}^m (y_{ij} - \bar{y}_{i\cdot})] = 0,$$

故有

$$\begin{aligned} S_T &= \sum_{i=1}^r \sum_{j=1}^m (y_{ij} - \bar{y})^2 = \sum_{i=1}^r \sum_{j=1}^m [(y_{ij} - \bar{y}_{i\cdot}) + (\bar{y}_{i\cdot} - \bar{y})]^2 \\ &= S_e + S_A + 2 \sum_{i=1}^r \sum_{j=1}^m (y_{ij} - \bar{y}_{i\cdot})(\bar{y}_{i\cdot} - \bar{y}) = S_e + S_A, \end{aligned}$$

诸自由度间的等式是显然的.

8.1.4 检验方法

偏差平方和 Q 的大小与数据个数(或自由度)有关,一般说来,数据越多,其偏差平方和越大.为了便于在诸偏差平方和间进行比较,统计上引入了均方的概念,它定义为

$$MS = \frac{Q}{f_Q},$$

其意为平均每个自由度上有多少平方和.

如今要对因子平方和 S_A 与误差平方和 S_e 进行比较,用其均方

$$MS_A = \frac{S_A}{f_A}, \quad MS_e = \frac{S_e}{f_e}$$

进行比较更为合理,因为均方排除了自由度不同所产生的干扰.故用

$$F = \frac{MS_A}{MS_e} = \frac{S_A/f_A}{S_e/f_e} \quad (8.1.17)$$

作为检验 H_0 的统计量,为给出检验拒绝域,我们需要如下定理:

定理 8.1.2 在单因子方差分析模型(8.1.8)及前述符号下,有

- (1) $S_e/\sigma^2 \sim \chi^2(n-r)$, 从而 $E(S_e) = (n-r)\sigma^2$;
- (2) $E(S_A) = (r-1)\sigma^2 + m \sum_{i=1}^r a_i^2$, 进一步,若 H_0 成立,则有 $S_A/\sigma^2 \sim \chi^2(r-1)$;
- (3) S_A 与 S_e 独立.

证明 由(8.1.11)式和(8.1.14)式, $S_e = \sum_{i=1}^r \sum_{j=1}^m (\varepsilon_{ij} - \bar{\varepsilon}_{i\cdot})^2$, 在单因子方差分析模型(8.1.8)下,我们知道,诸 $\varepsilon_{ij} (i=1, 2, \dots, r, j=1, 2, \dots, m)$ 独立同分布于 $N(0, \sigma^2)$, 由定理 5.4.1 知, $\frac{1}{\sigma^2} \sum_{j=1}^m (\varepsilon_{ij} - \bar{\varepsilon}_{i\cdot})^2 (i=1, 2, \dots, r)$ 相互独立,其共同分布为 $\chi^2(m-1)$, 由 χ^2 分布的可加性,有 $\frac{S_e}{\sigma^2} \sim \chi^2(n-r)$, 这给出 $E(S_e/\sigma^2) = n-r = f_e$, (1)得证.

类似地,由(8.1.12)式和(8.1.15)式,有

$$S_A = m \sum_{i=1}^r (a_i + \bar{\varepsilon}_{i\cdot} - \bar{\varepsilon})^2.$$

由定理 5.4.1 知,对每个 i , 平方和 $\sum_{j=1}^m (\varepsilon_{ij} - \bar{\varepsilon}_{i\cdot})^2$ 与均值 $\bar{\varepsilon}_{i\cdot}$ 独立,从而 $\bar{\varepsilon}_{1\cdot}, \bar{\varepsilon}_{2\cdot}, \dots, \bar{\varepsilon}_{r\cdot}$ 与 S_e 独立,而 S_A 只是 $\bar{\varepsilon}_{1\cdot}, \bar{\varepsilon}_{2\cdot}, \dots, \bar{\varepsilon}_{r\cdot}$ 的函数,由此(3)得证.

在模型(8.1.8)下, S_A 的期望是

$$E(S_A) = m \sum_{i=1}^r a_i^2 + E \left[m \sum_{i=1}^r (\bar{\varepsilon}_{i.} - \bar{\varepsilon})^2 \right],$$

由于诸误差均值 $\bar{\varepsilon}_{1.}, \bar{\varepsilon}_{2.}, \dots, \bar{\varepsilon}_{r.}$ 独立同分布于 $N(0, \sigma^2/m)$, 从而由诸误差均值组成的偏差平方和除以 σ^2/m 服从 χ^2 分布, 即

$$\frac{1}{\sigma^2} \sum_{i=1}^r m(\bar{\varepsilon}_{i.} - \bar{\varepsilon})^2 \sim \chi^2(r-1),$$

于是

$$E \left[\sum_{i=1}^r m(\bar{\varepsilon}_{i.} - \bar{\varepsilon})^2 \right] = (r-1)\sigma^2.$$

在 H_0 成立下, $S_A/\sigma^2 \sim \chi^2(r-1)$, 这就完成了(2)的证明.

由定理 8.1.2 知, 若 H_0 成立, 则(8.1.17)定义的检验统计量 F 服从自由度为 f_A 和 f_e 的 F 分布, 考虑到统计量 F 的值愈大愈倾向于拒绝原假设, 故该检验的拒绝域为

$$W = \{ F \geq F_{1-\alpha}(f_A, f_e) \}. \tag{8.1.18}$$

通常将上述计算过程列成一张表格, 称为方差分析表, 见表 8.1.3.

表 8.1.3 单因子方差分析表

来源	平方和	自由度	均方	F 比	p 值
因子	S_A	$f_A = r-1$	$MS_A = S_A/f_A$	$F = MS_A/MS_e$	p
误差	S_e	$f_e = n-r$	$MS_e = S_e/f_e$		
总和	S_T	$f_T = n-1$			

对给定的 α , 可作如下判断:

- 如果 $F \geq F_{1-\alpha}(f_A, f_e)$, 则认为因子 A 显著.
- 若 $F < F_{1-\alpha}(f_A, f_e)$, 则说明因子 A 不显著.

该检验的 p 值也可利用统计软件求出, 若以 Y 记服从 $F(f_A, f_e)$ 的随机变量, 则检验的 p 值为 $p = P(Y \geq F)$. 利用 p 值进行判断与第七章相同.

经过简单推导, 可以给出常用的各偏差平方和的计算公式如下:

$$\begin{aligned} S_T &= \sum_{i=1}^r \sum_{j=1}^m y_{ij}^2 - \frac{T^2}{n}, \\ S_A &= \frac{1}{m} \sum_{i=1}^r T_i^2 - \frac{T^2}{n}, \\ S_e &= S_T - S_A. \end{aligned} \tag{8.1.19}$$

一般可将计算过程列表进行, 见下例.

例 8.1.2 采用例 8.1.1 的数据, 由偏差平方和的公式可以看出, 对数据作一个线性变换是不影响方差分析的结果的, 本例中, 我们将原始数据同时减去 1 000, 并用列表(如表 8.1.4)的办法给出计算过程:

表 8.1.4 鸡饲料试验数据及计算表

水平	数 据(原始数据-1 000)								T_i	T_i^2	$\sum_{j=1}^m y_{ij}^2$
A_1	73	9	60	1	2	12	9	28	194	37 636	10 024
A_2	107	92	-10	109	90	74	122	1	585	342 225	60 355
A_3	93	29	80	21	22	32	29	48	354	125 316	20 984
和									1 133	505 177	91 363

利用(8.1.19),可算得各偏差平方和为:

$$S_T = 91\,363 - \frac{1\,133^2}{24} = 37\,875.96, \qquad f_T = 24 - 1 = 23,$$

$$S_A = \frac{505\,177}{8} - \frac{1\,133^2}{24} = 9\,660.08, \qquad f_A = 3 - 1 = 2,$$

$$S_e = S_T - S_A = 37\,875.96 - 9\,660.08 = 28\,215.88, \qquad f_e = 3(8 - 1) = 21.$$

把上述诸平方和及其自由度填入方差分析表,并继续计算得到各均方以及 F 比, p 值, 见表 8.1.5.

表 8.1.5 鸡饲料试验的方差分析表

来 源	平方和	自由度	均方	F 比	p 值
因子 A	9 660.08	2	4 830.04	3.59	0.045 6
误差 e	28 215.88	21	1 343.61		
总和 T	37 875.96	23			

若取 $\alpha=0.05$, 则 $F_{0.95}(2, 21) = 3.47$, 由于 $F = 3.59 > 3.47$, 故认为因子 A (饲料) 是显著的, 即三种饲料对鸡的增肥作用有明显的差别.

本例中 p 值为 0.045 6, 由于 p 值小于 α , 故拒绝原假设.

8.1.5 参数估计

在检验结果为显著时, 我们可进一步求出总均值 μ 、各水平效应 a_i 和误差方差 σ^2 的估计.

一、点估计

由模型(8.1.8)知诸 y_{ij} 相互独立, 且 $y_{ij} \sim N(\mu + a_i, \sigma^2)$, 因此, 可使用最大似然方法求出总均值 μ 、各水平效应 a_i 和误差方差 σ^2 的估计.

首先, 写出似然函数

$$L(\mu, a_1, a_2, \cdots, a_r, \sigma^2) = \prod_{i=1}^r \prod_{j=1}^m \left\{ \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left\{ -\frac{(y_{ij} - \mu - a_i)^2}{2\sigma^2} \right\} \right\},$$

其对数似然函数为

$$l(\mu, a_1, a_2, \cdots, a_r, \sigma^2) = -\frac{n}{2} \ln(2\pi\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^r \sum_{j=1}^m (y_{ij} - \mu - a_i)^2,$$

求偏导,得似然方程为

$$\begin{cases} \frac{\partial l}{\partial \mu} = \frac{1}{\sigma^2} \sum_{i=1}^r \sum_{j=1}^m (y_{ij} - \mu - a_i) = 0, \\ \frac{\partial l}{\partial a_i} = \frac{1}{\sigma^2} \sum_{j=1}^m (y_{ij} - \mu - a_i) = 0, \quad i = 1, 2, \dots, r, \\ \frac{\partial l}{\partial \sigma^2} = -\frac{n}{2\sigma^2} + \frac{1}{2\sigma^4} \sum_{i=1}^r \sum_{j=1}^m (y_{ij} - \mu - a_i)^2 = 0. \end{cases}$$

考虑到约束条件(8.1.6),可求出前述各参数的最大似然估计为

$$\begin{aligned} \hat{\mu} &= \bar{y}, \\ \hat{a}_i &= \bar{y}_{i\cdot} - \bar{y}, \quad i = 1, 2, \dots, r, \\ \hat{\sigma}_M^2 &= \frac{1}{n} \sum_{i=1}^r \sum_{j=1}^m (y_{ij} - \bar{y}_{i\cdot})^2 = \frac{S_e}{n}. \end{aligned} \quad (8.1.20)$$

由最大似然估计的不变性,各水平均值 μ_i 的最大似然估计为

$$\hat{\mu}_i = \bar{y}_{i\cdot}, \quad (8.1.21)$$

由于 $\hat{\sigma}_M^2$ 不是 σ^2 的无偏估计,实用中通常采用如下误差方差的无偏估计

$$\hat{\sigma}^2 = MS_e. \quad (8.1.22)$$

二、置信区间

以下讨论各水平均值 μ_i 的置信区间.由定理 8.1.2 知, $\bar{y}_{i\cdot} \sim N(\mu_i, \sigma^2/m)$, $S_e/\sigma^2 \sim \chi^2(f_e)$, 且两者独立,故

$$\frac{\sqrt{m}(\bar{y}_{i\cdot} - \mu_i)}{\sqrt{S_e/f_e}} \sim t(f_e),$$

由此给出 A_i 的水平均值 μ_i 的 $1-\alpha$ 的置信区间为

$$[\bar{y}_{i\cdot} \pm t_{1-\alpha/2}(f_e) \hat{\sigma}/\sqrt{m}], \quad (8.1.23)$$

其中 $\hat{\sigma}^2$ 由(8.1.22)给出.

例 8.1.3 我们在例 8.1.2 中已经检验出饲料因子是显著的,此处我们给出诸水平均值的估计.因子 A 的三个水平均值的估计分别为

$$\begin{aligned} \hat{\mu}_1 &= 1\,000 + \frac{194}{8} = 1\,024.25, \\ \hat{\mu}_2 &= 1\,000 + \frac{585}{8} = 1\,073.13, \\ \hat{\mu}_3 &= 1\,000 + \frac{354}{8} = 1\,044.25, \end{aligned}$$

从点估计来看,水平 A_2 (以槐米粉为主的饲料)是最优的.误差方差的无偏估计为

$$\hat{\sigma}^2 = MS_e = 1\,343.61.$$

进一步,利用(8.1.23)可以给出诸水平均值的置信区间.此处, $\hat{\sigma} = \sqrt{1\,343.61} = 36.66$, 若

取 $\alpha = 0.05$, 则 $t_{1-\alpha/2}(f_r) = t_{0.975}(21) = 2.0796$, $t_{0.975}(21) \hat{\sigma} / \sqrt{8} = 26.95$, 于是三个水平均值的 0.95 置信区间分别为

$$\mu_1: [1024.25 \pm 26.95] = [997.30, 1051.20],$$

$$\mu_2: [1073.13 \pm 26.95] = [1046.18, 1100.08],$$

$$\mu_3: [1044.25 \pm 26.95] = [1017.30, 1071.20],$$

至此, 我们可以看到: 在单因子试验的数据分析中可得到如下三个结果:

- 因子 A 是否显著.
- 试验的误差方差 σ^2 的估计.
- 诸水平均值 μ_i 的点估计与区间估计.

在因子 A 显著时, 通常只需对较优的水平均值作参数估计, 在因子 A 不显著场合, 参数估计无需进行.

8.1.6 重复数不等情形

有时, 每个水平下重复试验次数不全相等, 在此情况下进行方差分析与重复数相等情况下的方差分析极为相似, 只在几处略有差别. 下面我们指出差异之处.

一、数据

设从第 i 个水平下的总体获得 m_i 个试验结果, 记为 $y_{i1}, y_{i2}, \dots, y_{im_i}$, $i = 1, 2, \dots, r$, 故总试验次数为 $n = m_1 + m_2 + \dots + m_r$, 从而, 其统计模型为

$$\begin{cases} y_{ij} = \mu_i + \varepsilon_{ij}, & i = 1, 2, \dots, r, \quad j = 1, 2, \dots, m_i, \\ \text{各 } \varepsilon_{ij} \text{ 相互独立, 且都服从 } N(0, \sigma^2). \end{cases} \quad (8.1.24)$$

二、总均值

诸 μ_i 的加权平均(所有试验结果的均值的平均)

$$\mu = \frac{1}{n} (m_1 \mu_1 + m_2 \mu_2 + \dots + m_r \mu_r) = \frac{1}{n} \sum_{i=1}^r m_i \mu_i \quad (8.1.25)$$

称为总均值, 它是所有观测值期望的平均. 第 i 个水平下的均值 μ_i 与总均值 μ 的差

$$a_i = \mu_i - \mu, \quad i = 1, 2, \dots, r \quad (8.1.26)$$

称为因子 A 的第 i 个水平效应.

三、效应约束条件

由 (8.1.25) 和 (8.1.26) 容易看出关于效应的约束条件为

$$\begin{aligned} \sum_{i=1}^r m_i a_i &= 0, \\ \mu_i &= \mu + a_i, \end{aligned}$$

这表明第 i 个总体的均值是由总均值与该水平的效应叠加而成的. 类似于 (8.1.8), 有

$$\begin{cases} y_{ij} = \mu + a_i + \varepsilon_{ij}, & i = 1, 2, \dots, r, \quad j = 1, 2, \dots, m_i, \\ \sum_{i=1}^r m_i a_i = 0, \\ \text{诸 } \varepsilon_{ij} \text{ 相互独立, 且都服从 } N(0, \sigma^2). \end{cases} \quad (8.1.27)$$

四、各平方和的计算

要考虑的问题仍是检验(8.1.9)给出的假设.整个分析思路与方法基本一样,重要的区别是计算公式稍有不同,特别要注意 S_A 的计算公式.类似地记

$$T_i = \sum_{j=1}^{m_i} y_{ij}, \quad \bar{y}_{i\cdot} = \frac{T_i}{m_i},$$
$$T = \sum_{i=1}^r \sum_{j=1}^{m_i} y_{ij} = \sum_{i=1}^r T_i, \quad \bar{y} = \frac{T}{n},$$

则

$$S_T = \sum_{i=1}^r \sum_{j=1}^{m_i} (y_{ij} - \bar{y})^2 = \sum_{i=1}^r \sum_{j=1}^{m_i} y_{ij}^2 - \frac{T^2}{n}, \quad f_T = n - 1,$$
$$S_A = \sum_{i=1}^r m_i (\bar{y}_{i\cdot} - \bar{y})^2 = \sum_{i=1}^r \frac{T_i^2}{m_i} - \frac{T^2}{n}, \quad f_A = r - 1, \tag{8.1.28}$$
$$S_e = \sum_{i=1}^r \sum_{j=1}^{m_i} (y_{ij} - \bar{y}_{i\cdot})^2 = S_T - S_A, \quad f_e = n - r.$$

方差分析表以及参数估计是一样的.

例 8.1.4 某食品公司对一种食品设计了四种新包装.为考察哪种包装最受顾客欢迎,选了 10 个地段繁华程度相似、规模相近的商店做试验,其中两种包装各指定两个商店销售,另两种包装各指定三个商店销售.在试验期内各店货架排放的位置、空间都相同,营业员的促销方法也基本相同,经过一段时间,记录其销售量数据,列于表 8.1.6 左侧,其相应的计算结果列于右侧.

表 8.1.6 销售量数据及计算表

包装类型	销售量数据			m_i	T_i	T_i^2/m_i	$\sum_{j=1}^{m_i} y_{ij}^2$
A_1	12	18		2	30	450	468
A_2	14	12	13	3	39	507	509
A_3	19	17	21	3	57	1 083	1 091
A_4	24	30		2	54	1 458	1 476
和				$n = 10$	$T = 180$	$\sum_{i=1}^r \frac{T_i^2}{m_i} = 3\,498$	$\sum_{i=1}^r \sum_{j=1}^{m_i} y_{ij}^2 = 3\,544$

由此可求得各类偏差平方和如下(其中 $\frac{T^2}{n} = \frac{180^2}{10} = 3\,240$)

$$S_T = 3\,544 - 3\,240 = 304, \quad f_T = 10 - 1 = 9,$$
$$S_A = 3\,498 - 3\,240 = 258, \quad f_A = 4 - 1 = 3,$$
$$S_e = 304 - 258 = 46, \quad f_e = 10 - 4 = 6.$$

方差分析表如表 8.1.7 所示.

表 8.1.7 销售量的方差分析表

来 源	平方和	自由度	均方	F 比	p 值
因子 A	258	3	86	11.21	0.007 1
误差 e	46	6	7.67		
总和 T	304	9			

若取 $\alpha=0.01$, 由于 p 值为 0.007 1, 小于 α , 故我们可认为各水平间有显著差异.

由于因子显著, 我们还可以给出诸水平平均值的估计. 因子 A 的四个水平平均值的估计分别为

$$\begin{aligned}\hat{\mu}_1 &= 30/2 = 15, & \hat{\mu}_2 &= 39/3 = 13, \\ \hat{\mu}_3 &= 57/3 = 19, & \hat{\mu}_4 &= 54/2 = 27,\end{aligned}$$

由此可见, 第四种包装方式效果最好. 误差方差的无偏估计为

$$\hat{\sigma}^2 = MS_e = 7.67.$$

进一步, 利用 (8.1.23) 也可以给出诸水平平均值的置信区间, 只是在这里要用不同的 m_i 代替那里相同的 m . 此处, $\hat{\sigma} = \sqrt{7.67} = 2.769\ 5$, 若取 $\alpha = 0.05$, 则 $t_{1-\alpha/2}(f_e) = t_{0.975}(6) = 2.446\ 9$, $t_{0.975}(6)\hat{\sigma} = 6.776\ 7$, 于是效果较好的第四个水平平均值的 0.95 置信区间为

$$\mu_4: [27 \pm 6.776\ 7/\sqrt{2}] = [22.21, 31.79].$$

习 题 8.1

1. 在一个单因子试验中, 因子 A 有三个水平, 每个水平下各重复 4 次, 具体数据如下:

水平	数据			
一水平	8	5	7	4
二水平	6	10	12	9
三水平	0	1	5	2

试计算误差平方和 S_e 、因子 A 的平方和 S_A 、总平方和 S_T , 并指出它们各自的自由度.

2. 在一个单因子试验中, 因子 A 有 4 个水平, 每个水平下重复次数分别为 5, 7, 6, 8. 那么误差平方和、 A 的平方和及总平方和的自由度各是多少?

3. 在单因子试验中, 因子 A 有 4 个水平, 每个水平下各重复 3 次试验, 现已求得每个水平下试验结果的样本标准差分别为 1.5, 2.0, 1.6, 1.2, 则其误差平方和为多少? 误差的方差 σ^2 的估计值是多少?

4. 在单因子方差分析中, 因子 A 有三个水平, 每个水平各做 4 次重复试验, 请完成下列方差分析表, 并在显著性水平 $\alpha=0.05$ 下对因子 A 是否显著作出检验.