

§ 8.4 一元线性回归

8.4.1 变量间的两类关系

早在 19 世纪,英国生物学家兼统计学家高尔顿(Galton)在研究父与子身高的遗传问题时,观察了 1 078 对父与子,用 x 表示父亲身高, y 表示成年儿子的身高,发现将 (x, y) 点在直角坐标系中,这 1 078 个点基本在一条直线附近,并求出了该直线的方程(单位:英寸,1 英寸 = 2.54 cm):

$$\hat{y} = 33.73 + 0.516x.$$

这表明:

- 父亲身高每增加 1 个单位,其儿子的身高平均增加 0.516 个单位.
- 高个子父辈生的儿子平均身高也高,但子辈的身高间的差距低于父辈间的身高差距(为 0.516 倍).

这便是子代的平均高度有向中心回归的趋势,使得一段时间内人的身高相对稳定.之后回归分析的思想渗透到了数理统计的其他分支中.随着计算机的发展,各种统计软件包的出现,回归分析的应用就越来越广泛.

回归分析处理的是变量与变量间的关系.变量间常见的关系有两类:一类称为**确定性关系**:这些变量间的关系是完全确定的,可以用函数 $y=f(x)$ 来表示, x (可以是向量)给定后, y 的值就唯一确定了.譬如正方形的面积 S 与边长 a 之间有关系 $S=a^2$,电路中有欧姆定律 $V=IR$ 等.另一类称为**相关关系**:变量间有关系,但是不能用函数来表示.譬如,人的身高 x 与体重 y 两者间有相关关系,一般来讲,身高较高的人体重也较重,但是同样身高的人的体重可以是不同的,医学上就利用这两个变量间的相关关系,给出了一些经验公式来确定一个人是否过于“肥胖”或“瘦小”;人的脚掌的长度 x 与身高 y 两者间也有相关关系,一般来讲,脚掌较长的人身高也较高,但是同样脚掌长度的人的身高可以是不同的,早期公安机关在破案时,常常根据罪犯留下的脚印来推测罪犯的身高.

变量间的相关关系不能用完全确定的函数形式表示,但在平均意义下有一定的定量关系表达式,寻找这种定量关系表达式就是回归分析的主要任务.

回归分析便是研究变量间相关关系的一门学科.它通过对客观事物中变量的大量观察或试验获得的数据,去寻找隐藏在数据背后的相关关系,给出它们的表达式——回归函数的估计.

8.4.2 一元线性回归模型

设 y 与 x 间有相关关系,称 x 为**自变量**(预报变量), y 为**因变量**(响应变量),在知道 x 取值后, y 的取值并不是确定的,它是一个随机变量,因此有一个分布,这个分布是在知道 x 的取值后 Y 的条件密度函数 $p(y|x)$,我们关心的是 y 的均值 $E(Y|x)$,它是 x

的函数,这个函数是确定性的:

$$f(x) = E(Y | x) = \int_{-\infty}^{\infty} yp(y | x) dy. \tag{8.4.1}$$

这便是 y 关于 x 的回归函数——条件期望,也就是我们要寻找的相关关系的表达式.

以上的叙述是在 x 与 y 均为随机变量场合进行的,这是一类回归问题.实际中还有第二类回归问题,其自变量 x 是可控变量(一般变量),只有 y 是随机变量,它们之间的相关关系可用下式表示:

$$y = f(x) + \varepsilon,$$

其中 ε 是随机误差,一般假设 $\varepsilon \sim N(0, \sigma^2)$. 由于 ε 的随机性,导致 y 是随机变量.本节主要研究第二类回归问题.

进行回归分析首先是回归函数形式的选择,当只有一个自变量时,通常可采用画散点图的方法进行选择,具体见下例.

例 8.4.1 由专业知识知道,合金钢的强度 y (单位: 10^7 Pa) 与合金钢中碳的含量 x (单位: %) 有关. 为了生产强度满足用户需要的合金钢,在冶炼时如何控制碳的含量? 如果在冶炼过程中通过化验得知了碳的含量,能否预测这炉合金钢的强度?

为解决这类问题就需要研究两个变量间的关系. 首先是收集数据,我们把收集到的数据记为 $(x_i, y_i) (i=1, 2, \cdots, n)$. 本例中,我们收集到 12 组数据,列于表 8.4.1 中.

表 8.4.1 合金钢强度 y 与碳含量 x 的数据

序号	x	y	序号	x	y
1	0.10	42.0	7	0.16	49.0
2	0.11	43.0	8	0.17	53.0
3	0.12	45.0	9	0.18	50.0
4	0.13	45.0	10	0.20	55.0
5	0.14	45.0	11	0.21	55.0
6	0.15	47.5	12	0.23	60.0

为找出两个变量间存在的回归函数的形式,可以画一张图:把每一数对 (x_i, y_i) 看成直角坐标系中的一个点,在图上画出 n 个点,称这张图为散点图,见图 8.4.1.




图 8.4.1 合金钢强度及碳含量的散点图

从散点图我们可以看出,12个点基本在一条直线附近,这说明两个变量之间有一个线性相关关系,若记 y 轴方向上的误差为 ε ,这个相关关系可以表示为

$$y = \beta_0 + \beta_1 x + \varepsilon. \quad (8.4.2)$$

这便是 y 关于 x 的一元线性回归的数据结构式.这里总假定 x 为一般变量,是非随机变量,其值是可以精确测量或严格控制的, β_0, β_1 为未知参数, β_1 是直线的斜率,它表示 x 每增加一个单位 $E(y)$ 的增加量. ε 是随机误差,通常假定

$$E(\varepsilon) = 0, \quad \text{Var}(\varepsilon) = \sigma^2, \quad (8.4.3)$$

在对未知参数作区间估计或假设检验时,还需要假定误差服从正态分布,即

$$y \sim N(\beta_0 + \beta_1 x, \sigma^2). \quad (8.4.4)$$

显然,假定(8.4.4)比(8.4.3)要强.

由于 β_0, β_1 均未知,需要我们从收集到的数据 $(x_i, y_i) (i=1, 2, \dots, n)$ 出发进行估计.在收集数据时,我们一般要求观测独立地进行,即假定 $y_1, y_2, \dots, y_n$ 相互独立.综合上述诸项假定,我们可以给出最简单、常用的一元线性回归的统计模型

$$\begin{cases} y_i = \beta_0 + \beta_1 x_i + \varepsilon_i, & i = 1, 2, \dots, n, \\ \text{各 } \varepsilon_i \text{ 独立同分布, 其分布为 } N(0, \sigma^2). \end{cases} \quad (8.4.5)$$

由数据 $(x_i, y_i) (i=1, 2, \dots, n)$ 可以获得 β_0, β_1 的估计 $\hat{\beta}_0, \hat{\beta}_1$,称

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x \quad (8.4.6)$$

为 y 关于 x 的经验回归函数,简称为回归方程,其图形称为回归直线.给定 $x=x_0$ 后,称

$\hat{y}_0 = \hat{\beta}_0 + \hat{\beta}_1 x_0$ 为回归值(在不同场合也称其为拟合值、预测值).

8.4.3 回归系数的最小二乘估计

一般采用最小二乘方法估计模型(8.4.5)中的 β_0, β_1 .令

$$Q(\beta_0, \beta_1) = \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2,$$

$\hat{\beta}_0, \hat{\beta}_1$ 应该满足

$$Q(\hat{\beta}_0, \hat{\beta}_1) = \min_{\beta_0, \beta_1} Q(\beta_0, \beta_1),$$

这样得到的 $\hat{\beta}_0, \hat{\beta}_1$ 称为 β_0, β_1 的最小二乘估计,记为LSE.

由于 $Q \geq 0$,且对 β_0, β_1 的导数存在,因此最小二乘估计可以通过求偏导数并令其为0而得到

$$\begin{cases} \frac{\partial Q}{\partial \beta_0} = -2 \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i) = 0, \\ \frac{\partial Q}{\partial \beta_1} = -2 \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i) x_i = 0. \end{cases} \quad (8.4.7)$$

这组方程称为正规方程组,经过整理,可得

$$\begin{cases} n \beta_0 + n \bar{x} \beta_1 = n \bar{y}, \\ n \bar{x} \beta_0 + \sum x_i^2 \beta_1 = \sum x_i y_i, \end{cases} \quad (8.4.8)$$

(今后凡是不作说明“ $\sum$ ”都表示“ $\sum_{i=1}^n$ ”.) 记

$$\bar{x} = \frac{1}{n} \sum x_i, \quad \bar{y} = \frac{1}{n} \sum y_i,$$

$$l_{xy} = \sum (x_i - \bar{x})(y_i - \bar{y}) = \sum x_i y_i - n \bar{x} \cdot \bar{y} = \sum x_i y_i - \frac{1}{n} \sum x_i \sum y_i,$$

$$l_{xx} = \sum (x_i - \bar{x})^2 = \sum x_i^2 - n \bar{x}^2 = \sum x_i^2 - \frac{1}{n} (\sum x_i)^2,$$

$$l_{yy} = \sum (y_i - \bar{y})^2 = \sum y_i^2 - n \bar{y}^2 = \sum y_i^2 - \frac{1}{n} (\sum y_i)^2.$$

解(8.4.8)可得

$$\begin{cases} \hat{\beta}_1 = \frac{l_{xy}}{l_{xx}}, \\ \hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}. \end{cases} \quad (8.4.9)$$

这就是参数的最小二乘估计,其计算通常可列表进行,见表 8.4.2.

例 8.4.2 使用例 8.4.1 中合金钢强度和碳含量数据,我们可求得回归方程,见表 8.4.2.

表 8.4.2 合金钢强度和碳含量数据的计算表

$\sum x_i = 1.90$	$n = 12$	$\sum y_i = 589.5$
$\bar{x} = 0.158\ 3$		$\bar{y} = 49.125$
$\sum x_i^2 = 0.319\ 4$	$\sum x_i y_i = 95.805$	$\sum y_i^2 = 29\ 304.25$
$n \bar{x}^2 = 0.300\ 8$	$n \bar{x} \bar{y} = 93.337\ 5$	$n \bar{y}^2 = 28\ 959.19$
$l_{xx} = 0.018\ 6$	$l_{xy} = 2.467\ 5$	$l_{yy} = 345.06$
$\hat{\beta}_1 = l_{xy}/l_{xx} = 132.66$		
$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x} = 28.12$		

(l_{yy} 在后面将会用到)由此给出回归方程为

$$\hat{y} = 28.12 + 132.66x.$$

关于最小二乘估计的一些性质罗列在如下定理之中:

定理 8.4.1 在模型(8.4.5)下,有

$$(1) \hat{\beta}_0 \sim N\left(\beta_0, \left(\frac{1}{n} + \frac{\bar{x}^2}{l_{xx}}\right) \sigma^2\right), \quad \hat{\beta}_1 \sim N\left(\beta_1, \frac{\sigma^2}{l_{xx}}\right);$$

$$(2) \text{Cov}(\hat{\beta}_0, \hat{\beta}_1) = -\frac{\bar{x}}{l_{xx}} \sigma^2;$$

$$(3) \text{对给定的 } x_0, \hat{y}_0 = \hat{\beta}_0 + \hat{\beta}_1 x_0 \sim N\left(\beta_0 + \beta_1 x_0, \left(\frac{1}{n} + \frac{(x_0 - \bar{x})^2}{l_{xx}}\right) \sigma^2\right).$$

证明 利用 $\sum (x_i - \bar{x}) = 0$, 可把 $\hat{\beta}_1$ 和 $\hat{\beta}_0$ 改写为

$$\hat{\beta}_1 = \frac{l_{xy}}{l_{xx}} = \sum \frac{x_i - \bar{x}}{l_{xx}} y_i,$$

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x} = \sum \left[\frac{1}{n} - \frac{(x_i - \bar{x})\bar{x}}{l_{xx}} \right] y_i.$$

它们是独立正态变量 $y_1, y_2, \dots, y_n$ 的线性组合, 故都服从正态分布, 下面分别求其期望与方差.

$$E(\hat{\beta}_1) = \sum \frac{x_i - \bar{x}}{l_{xx}} E(y_i) = \sum \frac{x_i - \bar{x}}{l_{xx}} (\beta_0 + \beta_1 x_i) = \beta_1,$$

$$\text{Var}(\hat{\beta}_1) = \sum \left(\frac{x_i - \bar{x}}{l_{xx}} \right)^2 \text{Var}(y_i) = \sum \frac{(x_i - \bar{x})^2}{l_{xx}^2} \sigma^2 = \frac{\sigma^2}{l_{xx}},$$

$$E(\hat{\beta}_0) = E(\bar{y}) - E(\hat{\beta}_1) \bar{x} = \beta_0 + \beta_1 \bar{x} - \beta_1 \bar{x} = \beta_0,$$

$$\text{Var}(\hat{\beta}_0) = \sum \left[\frac{1}{n} - \frac{(x_i - \bar{x})\bar{x}}{l_{xx}} \right]^2 \text{Var}(y_i) = \left(\frac{1}{n} + \frac{\bar{x}^2}{l_{xx}} \right) \sigma^2,$$

这就证明了(1). 进一步, 考虑到诸 y_i 之间的独立性, 可得

$$\text{Cov}(\hat{\beta}_0, \hat{\beta}_1) = \text{Cov} \left(\sum \left[\frac{1}{n} - \frac{(x_i - \bar{x})\bar{x}}{l_{xx}} \right] y_i, \sum \frac{x_i - \bar{x}}{l_{xx}} y_i \right) = \sum \left[\frac{1}{n} - \frac{(x_i - \bar{x})\bar{x}}{l_{xx}} \right] \frac{x_i - \bar{x}}{l_{xx}} \sigma^2 = -\frac{\bar{x}}{l_{xx}} \sigma^2,$$

这就证明了(2). 为证明(3), 注意到 $\hat{y}_0 = \hat{\beta}_0 + \hat{\beta}_1 x_0$ 也是 $y_1, y_2, \dots, y_n$ 的线性组合, 它也服从正态分布, 只需求出其期望与方差即可.

$$E(\hat{y}_0) = E(\hat{\beta}_0) + E(\hat{\beta}_1) x_0 = \beta_0 + \beta_1 x_0 = E(y_0),$$

$$\begin{aligned} \text{Var}(\hat{y}_0) &= \text{Var}(\hat{\beta}_0) + \text{Var}(\hat{\beta}_1) x_0^2 + 2\text{Cov}(\hat{\beta}_0, \hat{\beta}_1) x_0 \\ &= \left[\left(\frac{1}{n} + \frac{\bar{x}^2}{l_{xx}} \right) + \frac{x_0^2}{l_{xx}} - 2 \frac{x_0 \bar{x}}{l_{xx}} \right] \sigma^2 = \left[\frac{1}{n} + \frac{(x_0 - \bar{x})^2}{l_{xx}} \right] \sigma^2, \end{aligned}$$

证明完成.

定理 8.4.1 说明:

- $\hat{\beta}_0, \hat{\beta}_1$ 分别是 β_0, β_1 的无偏估计;
- $\hat{y}_0$ 是 $E(y_0) = \beta_0 + \beta_1 x_0$ 的无偏估计.
- 除 $\bar{x} = 0$ 外, $\hat{\beta}_0$ 与 $\hat{\beta}_1$ 是相关的.
- 要提高 $\hat{\beta}_0, \hat{\beta}_1$ 的估计精度 (即降低它们的方差) 就要求 n 大, l_{xx} 大 (即要求 $x_1, x_2, \dots, x_n$ 较分散).

8.4.4 回归方程的显著性检验

从回归系数的 LSE 可以看出, 对任意给出的 n 对数据 (x_i, y_i) , 都可以求出 $\hat{\beta}_0, \hat{\beta}_1$,

从而可写出回归方程 $\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x$, 但是这样给出的回归方程不一定有意义.

在使用回归方程以前, 首先应对回归方程是否有意义进行判断. 什么叫回归方程有意义呢? 我们知道, 建立回归方程的目的是寻找 y 的均值随 x 变化的规律, 即找出回归方程 $E(y) = \beta_0 + \beta_1 x$. 如果 $\beta_1 = 0$, 那么不管 x 如何变化, $E(y)$ 不随 x 的变化作线性变化, 那么这时求得的一元线性回归方程就没有意义, 或称回归方程不显著. 如果 $\beta_1 \neq 0$, 那么当 x 变化时, $E(y)$ 随 x 的变化作线性变化, 那么这时求得的回归方程就有意义, 或称回归方程是显著的.

综上, 对回归方程是否有意义作判断就是要对如下的检验问题作出判断:

$$H_0: \beta_1 = 0 \quad \text{vs} \quad H_1: \beta_1 \neq 0, \quad (8.4.10)$$

拒绝 H_0 表示回归方程是显著的.

在一元线性回归中有三种等价的检验方法, 使用中只要任选其中之一即可. 下面分别加以介绍.

一、F 检验

采用方差分析的思想, 我们从数据出发研究各 y_i 不同的原因. 首先引入记号并称

$\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_i$ 为 x_i 处的回归值, 又称 $y_i - \hat{y}_i$ 为 x_i 处的残差.

数据总的波动用总偏差平方和

$$S_T = \sum (y_i - \bar{y})^2 = l_{yy}$$

表示. 引起各 y_i 不同的原因主要有两类因素: 其一是 H_0 可能不真, 即 $\beta_1 \neq 0$, 从而 $E(y) = \beta_0 + \beta_1 x$ 随 x 的变化而变化, 即在每一个 x 的观测值处的回归值不同, 其波动用回归平方和

$$S_R = \sum (\hat{y}_i - \bar{y})^2 \quad (8.4.11)$$

表示; 其二是其他一切因素, 包括随机误差、 x 对 $E(y)$ 的非线性影响等, 这样在得到回归值以后, y 的观测值与回归值之间还有差距, 这可用残差平方和

$$S_e = \sum (y_i - \hat{y}_i)^2 \quad (8.4.12)$$

表示.

为对上述诸平方和实施方差分析, 下面我们要证明重要的平方和分解式, 为此首先注意到 $\hat{\beta}_0, \hat{\beta}_1$ 满足正规方程组 (8.4.7), 因此有

$$\sum (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i) = 0 \Rightarrow \sum (y_i - \hat{y}_i) = 0,$$

$$\sum (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i) x_i = 0 \Rightarrow \sum (y_i - \hat{y}_i) x_i = 0.$$

利用 $\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_i = \bar{y} + \hat{\beta}_1 (x_i - \bar{x})$, 可得

$$\sum (y_i - \hat{y}_i) (\hat{y}_i - \bar{y}) = \sum (y_i - \hat{y}_i) [\hat{\beta}_1 (x_i - \bar{x})] = \hat{\beta}_1 [\sum (y_i - \hat{y}_i) x_i - \sum (y_i - \hat{y}_i) \bar{x}] = 0,$$

从而

$$S_T = \sum (y_i - \bar{y})^2 = \sum (y_i - \hat{y}_i + \hat{y}_i - \bar{y})^2 = \sum (y_i - \hat{y}_i)^2 + \sum (\hat{y}_i - \bar{y})^2,$$

即

$$S_T = S_R + S_e, \quad (8.4.13)$$

上式就是一元线性回归场合下的平方和分解式.

关于 S_R 和 S_e 所含有的成分可由如下定理说明.

定理 8.4.2 设 $y_i = \beta_0 + \beta_1 x_i + \varepsilon_i$, 其中 $\varepsilon_1, \varepsilon_2, \dots, \varepsilon_n$ 相互独立, 且

$$E(\varepsilon_i) = 0, \quad \text{Var}(\varepsilon_i) = \sigma^2, \quad i = 1, 2, \dots, n,$$

沿用上面的记号, 有

$$E(S_R) = \sigma^2 + \beta_1^2 l_{xx}, \quad (8.4.14)$$

$$E(S_e) = (n-2)\sigma^2, \quad (8.4.15)$$

(8.4.15) 式说明 $\hat{\sigma}^2 = S_e / (n-2)$ 是 σ^2 的无偏估计.

证明 首先我们可以写出 S_R 的简化公式:

$$S_R = \sum (\hat{y}_i - \bar{y})^2 = \sum [\bar{y} + \hat{\beta}_1(x_i - \bar{x}) - \bar{y}]^2 = \hat{\beta}_1^2 l_{xx}, \quad (8.4.16)$$

从而

$$E(S_R) = E(\hat{\beta}_1^2) l_{xx} = [\text{Var}(\hat{\beta}_1) + (E(\hat{\beta}_1))^2] l_{xx} = \left(\frac{\sigma^2}{l_{xx}} + \beta_1^2 \right) l_{xx} = \sigma^2 + \beta_1^2 l_{xx},$$

这就证明了 (8.4.14). 另外

$$\begin{aligned} S_e &= \sum (y_i - \hat{y}_i)^2 = \sum (\beta_0 + \beta_1 x_i + \varepsilon_i - \hat{\beta}_0 - \hat{\beta}_1 x_i)^2 \\ &= \sum [(\hat{\beta}_0 - \beta_0)^2 + x_i^2 (\hat{\beta}_1 - \beta_1)^2 + \varepsilon_i^2 + 2(\hat{\beta}_0 - \beta_0)(\hat{\beta}_1 - \beta_1)x_i - 2(\hat{\beta}_0 - \beta_0)\varepsilon_i - 2(\hat{\beta}_1 - \beta_1)x_i \varepsilon_i], \end{aligned}$$

故

$$\begin{aligned} E(S_e) &= n \text{Var}(\hat{\beta}_0) + \sum x_i^2 \text{Var}(\hat{\beta}_1) + n \text{Var}(\varepsilon_i) + 2n \bar{x} \text{Cov}(\hat{\beta}_0, \hat{\beta}_1) - \\ &\quad 2 \sum E(\hat{\beta}_0 \varepsilon_i) - 2 \sum x_i E(\hat{\beta}_1 \varepsilon_i). \end{aligned}$$

将 $\hat{\beta}_0, \hat{\beta}_1$ 写成 $y_1, y_2, \dots, y_n$ 的线性组合, 利用 y_j 与 $\varepsilon_i (i \neq j)$ 的独立性, 有

$$E(\hat{\beta}_0 \varepsilon_i) = E \left[\varepsilon_i \sum_j \left(\frac{1}{n} - \frac{(x_j - \bar{x}) \bar{x}}{l_{xx}} \right) y_j \right] = \left(\frac{1}{n} - \frac{(x_i - \bar{x}) \bar{x}}{l_{xx}} \right) \sigma^2,$$

$$E(\hat{\beta}_1 \varepsilon_i) = E \left[\varepsilon_i \sum_j \frac{x_j - \bar{x}}{l_{xx}} y_j \right] = \frac{x_i - \bar{x}}{l_{xx}} \sigma^2,$$

由此即有

$$\sum E(\hat{\beta}_0 \varepsilon_i) = \sigma^2, \quad \sum x_i E(\hat{\beta}_1 \varepsilon_i) = \sigma^2.$$

从而

$$E(S_e) = n \left(\frac{1}{n} + \frac{\bar{x}^2}{l_{xx}} \right) \sigma^2 + \sum \frac{x_i^2}{l_{xx}} \sigma^2 + n \sigma^2 - \frac{2n \bar{x}^2}{l_{xx}} \sigma^2 - 2 \sigma^2 - 2 \sigma^2$$

$$= (1+n-4)\sigma^2 + \frac{1}{l_{xx}} \sum (x_i - \bar{x})^2 \sigma^2 = (n-2)\sigma^2,$$

这就完成了证明.

进一步,有关 S_R 和 S_e 的分布,有如下定理.

定理 8.4.3 设 $y_1, y_2, \dots, y_n$ 相互独立,且 $y_i \sim N(\beta_0 + \beta_1 x_i, \sigma^2), i=1, 2, \dots, n$, 则在上述记号下,有

- (1) $S_e/\sigma^2 \sim \chi^2(n-2)$;
- (2) 若 H_0 成立, 则有 $S_R/\sigma^2 \sim \chi^2(1)$;
- (3) S_R 与 $S_e, \bar{y}$ 独立 (或 $\hat{\beta}_1$ 与 $S_e, \bar{y}$ 独立).

证明 取 $n \times n$ 正交矩阵 A 具有如下形式:

$$A = \begin{pmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ \vdots & \vdots & & \vdots \\ a_{n-2,1} & a_{n-2,2} & \cdots & a_{n-2,n} \\ x_1 - \bar{x} & x_2 - \bar{x} & \cdots & x_n - \bar{x} \\ \frac{\sqrt{l_{xx}}}{\sqrt{n}} & \frac{\sqrt{l_{xx}}}{\sqrt{n}} & \cdots & \frac{\sqrt{l_{xx}}}{\sqrt{n}} \\ \frac{1}{\sqrt{n}} & \frac{1}{\sqrt{n}} & \cdots & \frac{1}{\sqrt{n}} \end{pmatrix},$$

由正交性,可得如下一些约束条件:

$$\begin{aligned} \sum_j a_{ij} &= 0, \quad \sum_j a_{ij} x_j = 0, \quad \sum_j a_{ij}^2 = 1, \quad i=1, 2, \dots, n-2, \\ \sum_k a_{ik} a_{jk} &= 0, \quad 1 \leq i < j \leq n-2, \end{aligned}$$

这里矩阵 A 共有 $n(n-2)$ 个未知参数, 约束条件有 $3(n-2) + \binom{n-2}{2} = (n-2)(n+3)/2$

个, 只要 $n \geq 3$, 未知参数个数就不少于约束条件数, 因此正交矩阵 A 必存在. 令

$$Z = \begin{pmatrix} z_1 \\ z_2 \\ \vdots \\ z_n \end{pmatrix} = AY = A \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix} = \begin{pmatrix} \sum_j a_{1j} y_j \\ \vdots \\ \sum_j a_{n-2,j} y_j \\ \sum_j \frac{x_j - \bar{x}}{\sqrt{l_{xx}}} y_j \\ \sum_j \frac{1}{\sqrt{n}} y_j \end{pmatrix},$$

其中

$$z_{n-1} = \frac{\sum (x_i - \bar{x}) y_i}{\sqrt{l_{xx}}} = \frac{\sum (x_i - \bar{x}) (y_i - \bar{y})}{\sqrt{l_{xx}}} = \frac{l_{xy}}{\sqrt{l_{xx}}} = \sqrt{l_{xx}} \hat{\beta}_1,$$
$$z_n = \frac{1}{\sqrt{n}} \sum y_i = \sqrt{n} \bar{y},$$

则 Z 仍然服从 n 维正态分布,且其期望与协方差阵分别为

$$E(Z) = \begin{pmatrix} 0 \\ \vdots \\ 0 \\ \beta_1 \sqrt{l_{xx}} \\ \sqrt{n}(\beta_0 + \beta_1 \bar{x}) \end{pmatrix}, \quad \text{Var}(Z) = A \text{Var}(Y) A^T = \sigma^2 I_n,$$

这表明 $z_1, z_2, \dots, z_n$ 相互独立, $z_1, z_2, \dots, z_{n-2}$ 的共同分布为 $N(0, \sigma^2)$, $z_{n-1} \sim N(\beta_1 \sqrt{l_{xx}}, \sigma^2)$, $z_n \sim N(\sqrt{n}(\beta_0 + \beta_1 \bar{x}), \sigma^2)$.

由于 $\sum z_i^2 = \sum y_i^2 = S_T + n \bar{y}^2 = S_R + S_e + n \bar{y}^2$, 而 $z_n = \sqrt{n} \bar{y}$, $z_{n-1} = \sqrt{l_{xx}} \hat{\beta}_1 = \sqrt{S_R}$, 于是有 $z_1^2 + z_2^2 + \dots + z_{n-2}^2 = S_e$, 所以 $S_e, S_R, \bar{y}$ 三者相互独立. 并有

$$S_e / \sigma^2 = \sum_{i=1}^{n-2} (z_i / \sigma)^2 \sim \chi^2(n-2),$$

在 $\beta_1 = 0$ 时,

$$S_R / \sigma^2 = \left(\frac{z_{n-1}}{\sigma} \right)^2 \sim \chi^2(1),$$

证明完成.

如同方差分析那样,我们可以考虑采用如下 F 作为检验问题(8.4.10)的检验统计量:

$$F = \frac{S_R}{S_e / (n-2)}.$$

在 $\beta_1 = 0$ 时, $F \sim F(f_R, f_e)$, 其中 $f_R = 1, f_e = n-2$. 对于给定的显著性水平 α , 其拒绝域为

$$F \geq F_{1-\alpha}(1, n-2).$$

整个检验也可列成一张方差分析表. 检验也可用 p 值进行.

例 8.4.3 在合金钢强度的例 8.4.2 中, 我们已求出了回归方程, 这里我们考虑关于回归方程的显著性检验. 经计算有

$$S_T = l_{yy} = 345.06, \quad f_T = 11,$$
$$S_R = \hat{\beta}_1^2 l_{xx} = 132.66^2 \times 0.0186 = 327.34, \quad f_R = 1,$$
$$S_e = S_T - S_R = 345.06 - 327.34 = 17.72, \quad f_e = 10.$$

把各平方和与自由度移入方差分析表, 继续进行计算, 具体见表 8.4.3.

表 8.4.3 合金钢强度与碳含量回归方程的方差分析表

来源	平方和	自由度	均方	F 比	p 值
回归	$S_R = 327.34$	$f_R = 1$	$MS_R = 327.34$	184.94	0.000 0

续表

来源	平方和	自由度	均方	F 比	p 值
残差	$S_e = 17.72$	$f_e = 10$	$MS_e = 1.77$		
总计	$S_T = 345.06$	$f_T = 11$			

这里 p 值很小, 因此, 在显著性水平 0.01 下回归方程是显著的.

二、 t 检验

对 $H_0: \beta_1 = 0$ 的检验也可基于 t 分布进行. 由于 $\hat{\beta}_1 \sim N\left(\beta_1, \frac{\sigma^2}{l_{xx}}\right)$, $\frac{S_e}{\sigma^2} \sim \chi^2(n-2)$, 且与 $\hat{\beta}_1$ 相互独立, 因此在 H_0 为真时, 有

$$t = \frac{\hat{\beta}_1}{\hat{\sigma} / \sqrt{l_{xx}}} \sim t(n-2), \quad (8.4.17)$$

其中 $\hat{\sigma} = \sqrt{S_e / (n-2)}$, 由于 $\sigma_{\hat{\beta}_1} = \frac{\sigma}{\sqrt{l_{xx}}}$, 因此称 $\hat{\sigma}_{\hat{\beta}_1} = \frac{\hat{\sigma}}{\sqrt{l_{xx}}}$ 为 $\hat{\beta}_1$ 的标准误, 即 $\hat{\beta}_1$ 的标准差的估计. (8.4.17) 式表示的 t 统计量可用来检验假设 H_0 . 对给定的显著性水平 α , 拒绝域为

$$W = \{ |t| > t_{1-\alpha/2}(n-2) \}.$$

注意到 $t^2 = F$, 因此, t 检验与 F 检验是等同的.

以例 8.4.2 中数据为例, 可以计算得到

$$t = \frac{132.66}{\sqrt{1.77} / \sqrt{0.0186}} = 13.5991.$$

若取 $\alpha = 0.01$, 则 $t_{0.995}(10) = 3.1693$, 由于 $13.5991 > 3.1693$, 因此, 在显著性水平 0.01 下回归方程是显著的.

三、相关系数检验

考察一元线性回归方程能否反映两个随机变量 x 与 y 间的线性相关关系时, 它的显著性检验还可通过对二维总体相关系数 ρ 的检验进行. 它的一对假设是

$$H_0: \rho = 0 \quad \text{vs} \quad H_1: \rho \neq 0. \quad (8.4.18)$$

所用的检验统计量为样本相关系数

$$r = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum (x_i - \bar{x})^2 \sum (y_i - \bar{y})^2}} = \frac{l_{xy}}{\sqrt{l_{xx} l_{yy}}}, \quad (8.4.19)$$

其中 $(x_i, y_i) (i=1, 2, \dots, n)$ 是容量为 n 的二维样本.

利用施瓦茨不等式可以证明: 样本相关系数也满足 $|r| \leq 1$, 其中等号成立的条件是存在两个实数 a 与 b , 使得对 $i=1, 2, \dots, n$ 几乎处处有 $y_i = a + bx_i$. 由此可见, n 个点 $(x_i, y_i) (i=1, 2, \dots, n)$ 在散点图上的位置与样本相关系数 r 有关, 譬如:

- $r = \pm 1$, n 个点完全在一条上升或下降的直线上.
- $r > 0$, 当 x 增加时, y 有线性增加趋势, 此时称正相关.
- $r < 0$, 当 x 增加时, y 反而有线性减少趋势, 此时称负相关.

- $r=0$, n 个点可能杂乱无章,也可能呈某种曲线趋势,此时称不相关.

根据样本相关系数的上述性质,检验(8.4.18)中原假设 $H_0: \rho=0$ 的拒绝域为 $W = \{|r| \geq c\}$,其中临界值 c 可由 $H_0: \rho=0$ 成立时样本相关系数的分布定出,该分布与自由度 $n-2$ 有关.

对给定的显著性水平 α ,由 $P(W) = P(|r| \geq c) = \alpha$ 知,临界值 c 应是 $H_0: \rho=0$ 成立下 $|r|$ 的分布的 $1-\alpha$ 分位数,故可记为 $c = r_{1-\alpha}(n-2)$.我们还可以用 F 分布来确定临界值 c ,下面加以叙述.

由样本相关系数的定义可以得到统计量 r 与 F 之间的关系

$$r^2 = \frac{l_{xy}^2}{l_{xx}l_{yy}} = \frac{S_R}{S_T} = \frac{S_R}{S_R + S_e} = \frac{S_R/S_e}{S_R/S_e + 1},$$

而

$$F = \frac{MS_R}{MS_e} = \frac{S_R}{S_e/(n-2)} = \frac{(n-2)S_R}{S_e}.$$

两者综合,可得

$$r^2 = \frac{F}{F + (n-2)}.$$

这表明, $|r|$ 是 F 的严格单调增函数,故可以从 F 分布的 $1-\alpha$ 分位数 $F_{1-\alpha}(1, n-2)$ 得到 $|r|$ 的 $1-\alpha$ 分位数为

$$c = r_{1-\alpha}(n-2) = \sqrt{\frac{F_{1-\alpha}(1, n-2)}{F_{1-\alpha}(1, n-2) + n-2}}.$$

譬如,对 $\alpha=0.01, n=12$,查表知 $F_{0.99}(1, 10) = 10.04$,于是

$$r_{0.99}(10) = \sqrt{\frac{10.04}{10.04 + 10}} = 0.7078.$$

为实际使用方便,人们已对 $r_{1-\alpha}(n-2)$ 编制了专门的表,见附表 9.

以例 8.4.2 中数据为例,可以计算得到

$$r = \frac{2.4675}{\sqrt{0.0186 \times 345.06}} = 0.9740.$$

若取 $\alpha=0.01$,查附表 9 知则 $r_{0.99}(10) = 0.708$,由于 $0.9740 > 0.708$,因此,在显著性水平 0.01 下回归方程是显著的.

注:上述三个检验在考察一元线性回归时是等价的,但在多元线性回归场合,经推广 F 检验仍可用,另两个检验就无法使用了.

8.4.5 估计与预测

当回归方程经过检验是显著的后,可用来作估计和预测.这是两个不同的问题:

- 当 $x=x_0$ 时,寻求均值 $E(y_0) = \beta_0 + \beta_1 x_0$ 的点估计与区间估计(注意这里 $E(y_0)$ 是常量),这是估计问题.

- 当 $x=x_0$ 时, y_0 的观测值在什么范围内? 由于 y_0 是随机变量,一般只求一个区间,使 y_0 落在这一区间的概率为 $1-\alpha$,即要求 δ ,使 $P(|y_0 - \hat{y}_0| \leq \delta) = 1-\alpha$,称区间 $[\hat{y}_0 -$