

$\delta, \hat{y}_0 + \delta]$ 为 y_0 的概率为 $1-\alpha$ 的预测区间, 这是预测问题.

一、 $E(y_0)$ 的估计

在 $x=x_0$ 时, 其对应的因变量 y_0 是一个随机变量, 有一个分布, 我们经常需要对该分布的均值给出估计. 我们知道, 该分布的均值 $E(y_0) = \beta_0 + \beta_1 x_0$, 因此, 一个直观的估计应为

$$\hat{E}(y_0) = \hat{\beta}_0 + \hat{\beta}_1 x_0.$$

简单起见, 我们习惯上将上述估计记为 $\hat{y}_0$ (注意, 作为估计这里 $\hat{y}_0$ 表示的是 $E(y_0)$ 的估计, 而不表示 y_0 的估计, 因为 y_0 是随机变量, 它不能被估计, 但对其可以作预测. 事实上, 若预测 y_0 的最可能取值, 则 y_0 的点预测也是 $\hat{y}_0$). 由于 $\hat{\beta}_0, \hat{\beta}_1$ 分别是 β_0, β_1 的无偏估计, 因此, $\hat{y}_0$ 也是 $E(y_0)$ 的无偏估计.

为得到 $E(y_0)$ 的区间估计, 我们需要知道 $\hat{y}_0$ 的分布. 由定理 8.4.1 可得

$$\hat{y}_0 = \hat{\beta}_0 + \hat{\beta}_1 x_0 \sim N\left(\beta_0 + \beta_1 x_0, \left(\frac{1}{n} + \frac{(x_0 - \bar{x})^2}{l_{xx}}\right) \sigma^2\right),$$

又由定理 8.4.3 知, $S_e/\sigma^2 \sim \chi^2(n-2)$, 且与 $\hat{y}_0 = \bar{y} + \hat{\beta}_1(x_0 - \bar{x})$ 相互独立, 记

$$\hat{\sigma}^2 = \frac{S_e}{n-2},$$

则

$$\frac{(\hat{y}_0 - E(y_0)) / \sqrt{\frac{1}{n} + \frac{(x_0 - \bar{x})^2}{l_{xx}}} \sigma}{\sqrt{\frac{S_e}{\sigma^2}} / (n-2)} = \frac{\hat{y}_0 - E(y_0)}{\hat{\sigma} \sqrt{\frac{1}{n} + \frac{(x_0 - \bar{x})^2}{l_{xx}}}} \sim t(n-2).$$

于是 $E(y_0)$ 的 $1-\alpha$ 的置信区间是

$$[\hat{y}_0 - \delta_0, \hat{y}_0 + \delta_0], \quad (8.4.20)$$

其中

$$\delta_0 = t_{1-\alpha/2}(n-2) \hat{\sigma} \sqrt{\frac{1}{n} + \frac{(x_0 - \bar{x})^2}{l_{xx}}}. \quad (8.4.21)$$

二、 y_0 的预测区间

(8.4.20) 式给出了 $x=x_0$ 时对应的因变量的均值 $E(y_0)$ 的区间估计, 实用中往往更关心 $x=x_0$ 时对应的因变量 y_0 的取值范围. 我们举一个不是非常贴切的例子说明这两者之间的差别: 设想你要去买一台某厂生产的某种型号的液晶电视, 则你很关心液晶电视的寿命——它能正常使用多长时间, 液晶电视的寿命是一个随机变量, 该厂生产的该型号的液晶电视寿命有一个分布, 其均值就是它的平均寿命, 当然, 这是一个重要的质量指标, 我们可以对它给出估计, 譬如, 平均寿命的 0.95 置信区间为 (3, 7) (单位: 万小时). 然而, 作为消费者, 我们更关心的可能是所购买的这台液

晶电视的寿命在一个什么范围内,我们所购买的这台液晶电视的寿命是一个随机变量,能否对该随机变量的取值给出一个预测区间呢?这就是我们这里要讨论的预测问题.

事实上, $y_0 = E(y_0) + \varepsilon$, 由于通常假定 $\varepsilon \sim N(0, \sigma^2)$, 因此, y_0 的最可能取值仍然为 $\hat{y}_0$, 于是, 我们可以使用以 $\hat{y}_0$ 为中心的一个区间

$$[\hat{y}_0 - \delta, \hat{y}_0 + \delta] \quad (8.4.22)$$

作为 y_0 的取值范围, 为确定 δ 的值, 我们需要如下的结果: 由于 y_0 与 $\hat{y}_0$ 独立, 故

$$y_0 - \hat{y}_0 \sim N\left(0, \left(1 + \frac{1}{n} + \frac{(x_0 - \bar{x})^2}{l_{xx}}\right) \sigma^2\right).$$

因此有

$$\frac{y_0 - \hat{y}_0}{\hat{\sigma} \sqrt{1 + \frac{1}{n} + \frac{(x_0 - \bar{x})^2}{l_{xx}}}} \sim t(n-2),$$

从而(8.4.22)表示的预测区间中 δ 的表达式为

$$\delta = \delta(x_0) = t_{1-\alpha/2}(n-2) \hat{\sigma} \sqrt{1 + \frac{1}{n} + \frac{(x_0 - \bar{x})^2}{l_{xx}}}. \quad (8.4.23)$$

上述预测区间与 $E(y_0)$ 的置信区间(8.4.21)的差别就在于根号里多个 1, 计算时要注意到这个差别, 这个差别导致预测区间要比置信区间宽很多.

由(8.4.23)式可以看出预测区间的长度 2δ 与样本量 n , x 的偏差平方和 l_{xx} , x_0 到 $\bar{x}$ 的距离 $|x_0 - \bar{x}|$ 有关. x_0 愈远离 $\bar{x}$, 预测精度就愈差. 当 $x_0 \notin [x_{(1)}, x_{(n)}]$ 时, 预测精度可能变得很差, 在这种情况下的预测称作外推, 需要特别小心. 另外, 若 $x_1, x_2, \dots, x_n$ 较为集中时, 那么 l_{xx} 就较小, 也会导致预测精度的降低. 因此, 在收集数据时要使 $x_1, x_2, \dots, x_n$ 尽量分散, 这对提高精度有利. 图 8.4.2(a) 给出在不同的 x 值上预测区间的示意图: 在 $x = \bar{x}$ 处预测区间最短, 远离 $\bar{x}$ 的预测区间愈来愈长, 两端呈喇叭状.




图 8.4.2 预测区间示意图

当 n 较大时(如 $n>30$), t 分布可以用正态分布近似, 进一步, 若 x_0 与 $\bar{x}$ 相差不大时, δ 可以近似取为

$$\delta \approx u_{1-\alpha/2} \hat{\sigma}, \tag{8.4.24}$$

其中 $u_{1-\alpha/2}$ 是标准正态分布的 $1-\alpha/2$ 分位数, 见图 8.4.2(b).

例 8.4.4 在例 8.4.2 中, 如果 $x_0=0.16$, 则得预测值为

$$\hat{y}_0 = 28.12 + 132.66 \times 0.16 = 49.35.$$

若取 $\alpha=0.05$, 则 $t_{0.975}(10)=2.228\ 1$, 又 $\hat{\sigma}=\sqrt{17.72/(12-2)}=1.331\ 2$, 应用(8.4.21)式,

$$\delta_0 = 2.228\ 1 \times 1.331\ 2 \times \sqrt{\frac{1}{12} + \frac{(0.16 - 0.158\ 3)^2}{0.018\ 6}} = 0.86.$$

故 $x_0=0.16$ 对应因变量 y_0 的均值 $E(y_0)$ 的 0.95 置信区间为

$$[49.35 \pm 0.86] = [48.49, 50.21].$$

应用(8.4.23)式,

$$\delta = 2.228\ 1 \times 1.331\ 2 \times \sqrt{1 + \frac{1}{12} + \frac{(0.16 - 0.158\ 3)^2}{0.018\ 6}} = 3.09,$$

从而 y_0 的概率为 0.95 的预测区间为

$$[49.35 \pm 3.09] = [46.26, 52.44].$$

我们可以清楚地看到, $E(y_0)$ 的 0.95 置信区间比 y_0 的概率为 0.95 的预测区间窄很多, 这是因为随机变量的均值相对于随机变量本身而言波动更小.

如果求近似预测区间, 则可按(8.4.24)式计算, 由于 $u_{0.975}=1.96$, 故有 $\delta \approx 1.96 \times 1.331\ 2=2.61$, 则所求区间为

$$[49.35 - 2.61, 49.35 + 2.61] = [46.74, 51.96].$$

此处近似预测区间与精确预测区间相差较大, 主要是因为 n 较小的原因.

下面我们以一个完整的例子把本节内容重新梳理一遍.

例 8.4.5 在动物学研究中, 有时需要找出某种动物的体积与质量的关系. 因为动物的质量相对而言容易测量, 而测量体积比较困难, 因此, 人们希望用动物的质量预测其体积. 下面是 18 只某种动物的体积与质量数据, 在这里, 动物质量被看作自变量, 用 x 表示, 单位为 kg, 动物体积则作为因变量, 用 y 表示, 单位为 dm^3 , 18 组数据列于表 8.4.4 中.

表 8.4.4 18 只某种动物的体积 y 与质量 x 数据

x	y	x	y	x	y
10.4	10.2	15.1	14.8	16.5	15.9
10.5	10.4	15.1	15.1	16.7	16.6
11.9	11.6	15.1	14.5	17.1	16.7
12.1	11.9	15.7	15.7	17.1	16.7
13.8	13.5	15.8	15.2	17.8	17.6
15.0	14.5	16.0	15.8	18.4	18.3

为能用动物质量估计动物体积,必须建立动物体积 y 关于动物质量 x 的回归方程. 首先,我们用这 18 组数据画出散点图,见图 8.4.3.




图 8.4.3 动物体积与动物质量的散点图

从散点图我们发现 18 个点基本在一条直线附近,这说明两个变量之间在质量为 10 kg 到 20 kg 内有一个线性相关关系,下面求该线性回归方程,计算过程见表 8.4.5.

表 8.4.5 动物体积与质量数据的计算表

$\sum x_i = 270.1$	$n = 18$	$\sum y_i = 265.0$
$\bar{x} = 15.005\ 6$		$\bar{y} = 14.722\ 2$
$\sum x_i^2 = 4\ 149.39$	$\sum x_i y_i = 4\ 071.71$	$\sum y_i^2 = 3\ 996.14$
$n \bar{x}^2 = 4\ 053.000\ 6$	$n \bar{x} \bar{y} = 3\ 976.472\ 2$	$n \bar{y}^2 = 3\ 901.388\ 9$
$l_{xx} = 96.389\ 4$	$l_{xy} = 95.237\ 8$	$l_{yy} = 94.751\ 1$
$\hat{\beta}_1 = l_{xy}/l_{xx} = 0.988\ 1$		
$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x} = -0.104\ 8$		

由此给出回归方程为

$$\hat{y} = -0.104\ 8 + 0.988\ 1x. \tag{8.4.25}$$

接下来我们考虑关于回归方程的显著性检验.经计算有

$$\begin{aligned} S_T &= l_{yy} = 94.751\ 1, & f_T &= 17, \\ S_R &= \hat{\beta}_1^2 l_{xx} = 0.988\ 1^2 \times 96.389\ 4 = 94.109\ 0, & f_R &= 1, \\ S_e &= S_T - S_R = 0.642\ 1, & f_e &= 16. \end{aligned}$$

把诸平方和移入方差分析表上,继续计算,具体见表 8.4.6.

表 8.4.6 动物体积与质量回归方程的方差分析表

来源	平方和	自由度	均方	F 比	p 值
回归	$S_R = 94.109\ 0$	$f_R = 1$	$MS_R = 94.109\ 0$	2 346.9	0.000 0
残差	$S_e = 0.642\ 1$	$f_e = 16$	$MS_e = 0.040\ 1$		
总计	$S_T = 94.751\ 1$	$f_T = 17$			

因 p 值很小,在显著性水平 0.01 下回归方程是显著的.

如果测得某动物的质量为 $x_0 = 17.6\text{ kg}$,则由 (8.4.25) 式,该质量对应动物平均体积的估计值为

$$\hat{y}_0 = -0.104\ 8 + 0.988\ 1 \times 17.6 = 17.285\ 8.$$

若取 $\alpha = 0.05$,则 $t_{0.975}(16) = 2.119\ 9$,又 $\hat{\sigma} = \sqrt{0.040\ 1} = 0.200\ 2$,应用 (8.4.23) 式,

$$\delta = 2.119\ 9 \times 0.200\ 2 \times \sqrt{1 + \frac{1}{18} + \frac{(17.6 - 15.005\ 6)^2}{96.389\ 4}} = 0.450\ 2,$$

从而该质量对应动物体积的概率为 0.95 的预测区间为

$$[17.285\ 8 - 0.450\ 2, 17.285\ 8 + 0.450\ 2] = [16.835\ 6, 17.736\ 0].$$

用 (8.4.24) 式可以求近似预测区间,由于 $u_{0.975} = 1.96$,故有 $\delta \approx 1.96 \times 0.200\ 2 = 0.392\ 4$,则所求区间为

$$[17.285\ 8 - 0.392\ 4, 17.285\ 8 + 0.392\ 4] = [16.893\ 4, 17.678\ 2].$$

此处近似预测区间与精确预测区间差距已不大了,当 n 更大一些,两者差距会更小一些.

习 题 8.4

1. 假设回归直线过原点,即一元线性回归模型为

$$y_i = \beta x_i + \varepsilon_i, \quad i = 1, 2, \cdots, n,$$

$E(\varepsilon_i) = 0, \text{Var}(\varepsilon_i) = \sigma^2$, 诸观测值相互独立.

- (1) 写出 β 的最小二乘估计和 σ^2 的无偏估计;
 - (2) 对给定的 x_0 , 其对应的因变量均值的估计为 $\hat{y}_0$, 求 $\text{Var}(\hat{y}_0)$.
2. 设回归模型为

$$\begin{cases} y_i = \beta_0 + \beta_1 x_i + \varepsilon_i, i = 1, 2, \cdots, n, \\ \text{各 } \varepsilon_i \text{ 独立同分布, 其分布为 } N(0, \sigma^2). \end{cases}$$

试求 β_0, β_1 的最大似然估计, 它们与其最小二乘估计一致吗?

3. 在回归分析计算中,常对数据进行变换

$$\tilde{y}_i = \frac{y_i - c_1}{d_1}, \quad \tilde{x}_i = \frac{x_i - c_2}{d_2}, \quad i = 1, 2, \cdots, n,$$

其中 $c_1, c_2, d_1 (d_1 > 0), d_2 (d_2 > 0)$ 是适当选取的常数.

(1) 试建立由原始数据和变换后数据得到的最小二乘估计、总平方和、回归平方和以及残差平方和之间的关系;

后经核对,发现有一组数据记录错误,正确数据为(1.2,32.6),记录为(1.5,32.3).

- (1) 求 β_0, β_1 修正后的 LSE;
- (2) 对回归方程作显著性检验 ($\alpha=0.05$);
- (3) 若 $x_0=1.1$, 给出对响应变量的 0.95 预测区间.

10. 在生产中积累了 32 组某种铸件在不同腐蚀时间 x 下腐蚀深度 y 的数据,求得回归方程为

$$\hat{y} = -0.4441 + 0.002263x,$$

且误差方差的无偏估计为 $\hat{\sigma}^2=0.001452$,总偏差平方和为 0.1246.

- (1) 对回归方程作显著性检验 ($\alpha=0.05$),列出方差分析表;
- (2) 求样本相关系数;
- (3) 若腐蚀时间 $x=870$, 试给出 y 的 0.95 近似预测区间.

11. 我们知道营业税税收总额 y 与社会商品零售总额 x 有关.为能从社会商品零售总额去预测税收总额,需要了解两者之间的关系.现收集了如下 9 组数据(单位:亿元):

序号	社会商品零售总额	营业税税收总额
1	142.08	3.93
2	177.30	5.96
3	204.68	7.85
4	242.68	9.82
5	316.24	12.50
6	341.99	15.55
7	332.69	15.79
8	389.29	16.39
9	453.40	18.45

- (1) 画散点图;
- (2) 建立一元线性回归方程,并作显著性检验(取 $\alpha=0.05$),列出方差分析表;
- (3) 若已知某年社会商品零售总额为 300 亿元,试给出营业税税收总额的概率为 0.95 的预测区间;
- (4) 若已知回归直线过原点,试求回归方程,并在显著性水平 0.05 下作显著性检验.

§ 8.5 一元非线性回归

有时,回归函数并非是自变量的线性函数,若通过变换可以将之化为线性函数,从而可用一元线性回归方法对其分析,这是处理非线性回归问题的一种常用方法.下面以一个例子说明上述非线性回归的分析步骤.

例 8.5.1 炼钢厂出钢水时用的钢包,在使用过程中由于钢水及炉渣对耐火材料的侵蚀,其容积不断增大.钢包的容积用盛满钢水时的质量 y (单位:kg)表示,相应的使

用次数用 x 表示.数据见表 8.5.1,要找出 y 与 x 的定量关系表达式.

表 8.5.1 钢包的质量 y 与使用次数 x 数据

序号	x	y	序号	x	y
1	2	106.42	8	11	110.59
2	3	108.20	9	14	110.60
3	4	109.58	10	15	110.90
4	5	109.50	11	16	110.76
5	7	110.00	12	18	111.00
6	8	109.93	13	19	111.20
7	10	110.49			

下面我们分三步进行.

8.5.1 确定可能的函数形式

为对数据进行分析,首先描出数据的散点图,判断两个变量之间可能的函数关系,图 8.5.1 是本例的散点图.




图 8.5.1 钢包质量与使用次数散点图

观察这 13 个点形成的散点图,我们可以看到它们并不接近一条直线,用曲线拟合这些点应该是更恰当的.这里就涉及如何选择曲线函数形式的问题,首先,如果可由专业知识确定回归函数形式,则应尽可能利用专业知识.若不能由专业知识加以确定函数形式,则可将散点图与一些常见的函数关系的图形进行比较,选择几个可能的函数形式,然后使用统计方法在这些函数形式之间进行比较,最后确定合适的曲线回归方程.为此,必须了解常见的曲线函数的图形,见图 8.5.2.

本例中,散点图呈现一个明显的向上且上凸的趋势,可能选择的函数关系有很多,比如,参照图 8.5.2,我们可以给出如下四个曲线函数:

- (1) $\frac{1}{y} = a + \frac{b}{x},$ (8.5.1)
- (2) $y = a + b \ln x,$ (8.5.2)
- (3) $y = a + b\sqrt{x},$ (8.5.3)
- (4) $y - 100 = ae^{-b/x} \ (b > 0).$ (8.5.4)

函数名称	函数表达式	图 像	线性化方法
双曲线函数	$\frac{1}{y} = a + \frac{b}{x}$		$v = \frac{1}{y}$ $u = \frac{1}{x}$
幂函数	$y = ax^b$		$v = \ln y$ $u = \ln x$
指数函数	$y = ae^{bx}$		$v = \ln y$ $u = x$
	$y = ae^{b/x}$		$v = \ln y$ $u = \frac{1}{x}$
对数函数	$y = a + b \ln x$		$v = y$ $u = \ln x$
S 形曲线	$y = \frac{1}{a + be^{-x}}$		$v = \frac{1}{y}$ $u = e^{-x}$

图 8.5.2 部分常见的曲线函数的图形

在初步选出可能的函数关系(即方程)后,我们必须解决两个问题:

- 如何估计所选方程中的参数? 这在 8.5.2 中讨论.
- 如何评价所选不同方程的优劣? 这在 8.5.3 中介绍.

8.5.2 参数估计

对形如(8.5.1)式至(8.5.4)式的非线性函数,参数估计最常用的方法是“线性化”方法,即通过某种变换,将方程化为一元线性方程的形式.

以(8.5.1)式为例,为了能采用一元线性回归分析方法,我们作如下变换:

$$u = \frac{1}{x}, \quad v = \frac{1}{y},$$

则(8.5.1)的曲线函数就化为如下的直线:

$$v = a + bu,$$

这是理论回归函数.对数据而言,回归方程为

$$v_i = a + bu_i + \varepsilon_i,$$

于是可用一元线性回归的方法估计出 a, b .图 8.5.3 给出变换后的数据的散点图.

从图 8.5.3 上看出可以认为所有的点近似在一条直线上波动,因此,建立一元线性回归方程是可行的.整个计算过程及估计列于表 8.5.2 和表 8.5.3 中.




图 8.5.3 变换后数据的散点图

表 8.5.2 钢包数据的变换值

x	y	$u = 1/x$	$v = 1/y$	u^2	uv
2	106.42	0.500 000	0.009 397	0.250 000	0.004 698
3	108.20	0.333 333	0.009 242	0.111 111	0.003 081
4	109.58	0.250 000	0.009 126	0.062 500	0.002 281

续表					
x	y	$u = 1/x$	$v = 1/y$	u^2	uv
5	109.50	0.200 000	0.009 132	0.040 000	0.001 826
7	110.00	0.142 857	0.009 091	0.020 408	0.001 299
8	109.93	0.125 000	0.009 097	0.015 625	0.001 137
10	110.49	0.100 000	0.009 051	0.010 000	0.000 905
11	110.59	0.090 909	0.009 042	0.008 264	0.000 822
14	110.60	0.071 429	0.009 042	0.005 102	0.000 646
15	110.90	0.066 667	0.009 017	0.004 444	0.000 601
16	110.76	0.062 500	0.009 029	0.003 906	0.000 564
18	111.00	0.055 556	0.009 009	0.003 086	0.000 501
19	111.20	0.052 632	0.008 993	0.002 770	0.000 473
合计		2.050 881 94	0.118 266 72	0.537 217 98	0.018 834 95
均值		0.157 760 15	0.009 097 44		

注:为了下面的计算需要,表中合计与均值两行取 8 位小数.

表 8.5.3 参数估计计算表

$\sum u_i = 2.050\ 881\ 94$	$n = 13$	$\sum v_i = 0.118\ 266\ 72$
$\bar{u} = 0.157\ 760\ 15$		$\bar{v} = 0.009\ 097\ 44$
$\sum u_i^2 = 0.537\ 217\ 98$	$\sum u_i v_i = 0.018\ 834\ 95$	
$n \bar{u}^2 = 0.323\ 547\ 44$	$n \bar{u} \bar{v} = 0.018\ 657\ 78$	
$l_{uu} = 0.213\ 670\ 54$	$l_{uv} = 0.000\ 177\ 17$	
	$\hat{b} = l_{uv} / l_{uu} = 0.000\ 829\ 17$	
	$\hat{a} = \bar{v} - \hat{b} \bar{u} = 0.008\ 966\ 63$	
	$\hat{y} = \frac{x}{0.000\ 829\ 17 + 0.008\ 966\ 63x}$	

用类似的方法可以得出其他三个曲线回归方程,它们分别是

$$\begin{aligned}\hat{y} &= 106.314\ 7 + 3.946\ 6 \ln x, \\ \hat{y} &= 106.301\ 3 + 1.194\ 7 \sqrt{x}, \\ \hat{y} &= 100 + 11.750\ 6 e^{-1.125\ 6/x}.\end{aligned}$$

8.5.3 曲线回归方程的比较

我们上面得到了四个曲线回归方程,在这四个方程中,哪一个更好一点呢? 通常

可采用如下两个指标进行选择.

(1) 决定系数 R^2 . 类似于一元线性回归方程中相关系数, 决定系数定义为

$$R^2 = 1 - \frac{\sum (y_i - \hat{y}_i)^2}{\sum (y_i - \bar{y})^2}. \tag{8.5.5}$$

R^2 越大, 说明残差越小, 回归曲线拟合越好, R^2 从总体上给出一个拟合好坏程度的度量.

(2) 剩余标准差 s . 类似于一元线性回归中标准差的估计公式, 此剩余标准差可用平均残差平方和来获得, 即

$$s = \sqrt{\frac{\sum (y_i - \hat{y}_i)^2}{n-2}}. \tag{8.5.6}$$

s 为诸观测点 y_i 与由曲线给出的拟合值 $\hat{y}_i$ 间的平均偏离程度的度量, s 越小, 方程越好.

在观测数据给定后, 不同的曲线选择不会影响 $\sum_{i=1}^n (y_i - \bar{y})^2$ 的取值, 但会影响到残差平方和 $\sum_{i=1}^n (y_i - \hat{y}_i)^2$ 的取值. 因此, 对选择的曲线而言, 决定系数和剩余标准差都取决于残差平方和 $\sum_{i=1}^n (y_i - \hat{y}_i)^2$, 从而两种选择准则是一致的, 只是从两个不同侧面作出评价.

表 8.5.4 给出第一个曲线回归方程的残差平方和的计算过程. 由于 $n = 13$, $\sum_{i=1}^{13} (y_i - \bar{y})^2 = 21.210\ 5$, 故其决定系数及剩余标准差分别为

$$R^2 = 1 - \frac{0.574\ 3}{21.210\ 5} = 0.972\ 9, \quad s = \sqrt{\frac{0.574\ 3}{13 - 2}} = 0.228\ 5.$$

其他三个方程的决定系数及剩余标准差可同样计算, 我们将它们列在表 8.5.5 中.

表 8.5.4 第一个方程的残差平方和计算表

y_i	$\hat{y}_i$	$\hat{e}_i = y_i - \hat{y}_i$	$\hat{e}_i^2$	y_i	$\hat{y}_i$	$\hat{e}_i = y_i - \hat{y}_i$	$\hat{e}_i^2$
106.42	106.596	-0.176 001	0.030 976	110.59	110.595	-0.004 890	0.000 024
108.20	108.190	0.010 252	0.000 105	110.60	110.793	-0.192 810	0.037 176
109.58	109.005	0.575 373	0.331 054	110.90	110.841	0.058 701	0.003 446
109.50	109.499	0.000 526	0.000 000	110.76	110.884	-0.123 761	0.015 317
110.00	110.071	-0.070 543	0.004 976	111.00	110.955	0.045 397	0.002 061
109.93	110.250	-0.320 225	0.102 544	111.20	110.984	0.215 541	0.046 458
110.49	110.503	-0.012 769	0.000 163		和		0.574 3

注: $\hat{y}_i$ 用 3 位小数, 实际计算中用的是 $\hat{y}_i$ 的 6 位小数.

表 8.5.5 四种曲线回归的决定系数及剩余标准差

模型编号	1	2	3	4
R^2	0.972 9	0.877 3	0.785 1	0.962 3
s	0.228 5	0.486 4	0.643 7	0.269 6

从表 8.5.5 中可以看出,第一个曲线方程的决定系数最大,剩余标准差最小,在这四个曲线回归方程中,不论用哪个标准,都是第一个方程拟合得最好.因此,近似得比较好的定量关系式就是

$$\hat{y} = \frac{x}{0.000\ 829\ 17 + 0.008\ 966\ 63x}.$$

习 题 8.5

1. 设曲线函数形式为 $y=a+b\ln x$, 试给出一个变换将之化为一元线性回归的形式.
2. 设曲线函数形式为 $y=a+b\sqrt{x}$, 试给出一个变换将之化为一元线性回归的形式.
3. 设曲线函数形式为 $y-100=ae^{-x/b}$ ($b>0$), 试给出一个变换将之化为一元线性回归的形式.
4. 设曲线函数形式为 $y=a+e^{bx}$, 问能否找到一个变换将之化为一元线性回归的形式? 若能, 试给出; 若不能, 说明理由.
5. 设曲线函数形式为 $y=\frac{1}{a+be^{-x}}$, 问能否找到一个变换将之化为一元线性回归的形式? 若能, 试给出; 若不能, 说明理由.
6. 设曲线函数形式为 $y=ae^{bx}$, 问能否找到一个变换将之化为一元线性回归的形式? 若能, 试给出; 若不能, 说明理由.
7. 为了检验 X 射线的杀菌作用, 用 200 kV 的 X 射线照射杀菌, 每次照射 6 min, 照射次数为 x , 照射后所剩细菌数为 y , 下表是一组试验结果:

x	y	x	y	x	y
1	783	8	154	15	28
2	621	9	129	16	20
3	433	10	103	17	16
4	431	11	72	18	12
5	287	12	50	19	9
6	251	13	43	20	7
7	175	14	31		

根据经验知道 y 关于 x 的曲线回归方程形如

$$\hat{y} = ae^{bx},$$

试给出具体的回归方程, 并求其对应的决定系数 R^2 和剩余标准差 s .

