



第五讲 区间估计

袁洪松

内容概要:

置信区间, 枢轴量法, 正态总体参数的区间估计

预习内容:

浙大《概率论与数理统计》P72-77 (第49-53讲)

<https://www.bilibili.com/video/av20027947?p=72>

<https://www.bilibili.com/video/av20027947?p=73>

<https://www.bilibili.com/video/av20027947?p=74>

<https://www.bilibili.com/video/av20027947?p=75>

<https://www.bilibili.com/video/av20027947?p=76>

<https://www.bilibili.com/video/av20027947?p=77>

课本相关章节:

Hogg Section 4.2

1 置信区间

1.1 置信区间的定义

定义 (置信区间, **confidence interval, CI**) 设总体 X 的分布函数为 $F(x; \theta)$, 其中 θ 未知。对给定的 $0 < \alpha < 1$, 如果统计量 $L = L(X_1, \dots, X_n)$ 与 $U = U(X_1, \dots, X_n)$ 满足

$$P\{L(X_1, \dots, X_n) < \theta < U(X_1, \dots, X_n)\} = 1 - \alpha,$$

则称 (L, U) 为 θ 的置信水平为 $(1 - \alpha)$ 的置信区间。

说明:

- 1) 参数 θ 虽然未知, 但是确定的值。而 L, U 为统计量, 是随机的, 依赖于样本。
- 2) 对于某一组样本值, θ 不一定会落在区间之内。但大量重复抽样试验后 (即重复抽样多次, 每次抽样的样本容量均为 n), θ 落在区间之内的次数比例为 $1 - \alpha$ 。
- 3) 应该取较小的 α 值。通常的选择是 $\alpha = 5\%$ 或 $\alpha = 1\%$ 。

例 设总体 $X \sim N(\mu, 4)$, μ 未知。样本为 $X_1, \dots, X_4$ 。我们知道 $\bar{X} \sim N(\mu, 1)$ 。考虑区间 $(\bar{X} - 2, \bar{X} + 2)$ 。可以算出

$$P(\bar{X} - 2 < \mu < \bar{X} + 2) = P(-2 < \bar{X} - \mu < 2) = \Phi(2) - \Phi(-2) = 2\Phi(2) - 1 = 0.9544.$$

所以 $(\bar{X} - 2, \bar{X} + 2)$ 是 μ 的置信水平为 0.9544 的置信区间。

若真实值 $\mu = 0.5$, 并假设重复抽样试验三次(即做三次抽样, 每次抽样 4 个), 得到的样本均值 $\bar{x}$ 依次为 3, 2, 1。对应的区间具体值为

$$(1, 5), \quad (0, 4), \quad (-1, 3).$$

那么第一个区间没有覆盖真实 μ 值, 而后两个区间覆盖了真实 μ 值。 $\square$

定义 (单侧置信上/下限) 如果统计量 $L = L(X_1, \dots, X_n)$ 满足

$$P\{L(X_1, \dots, X_n) < \theta\} = 1 - \alpha,$$

则称 L 为 θ 的置信水平为 $(1 - \alpha)$ 的单侧置信下限。

如果统计量 $U = U(X_1, \dots, X_n)$ 满足

$$P\{\theta < U(X_1, \dots, X_n)\} = 1 - \alpha,$$

则称 U 为 θ 的置信水平为 $(1 - \alpha)$ 的单侧置信上限。

说明: 单侧置信上/下限也可看做是单侧置信区间 (L, ∞) 或 $(-\infty, U)$ 的端点。

例 在上例中, 考虑区间 $(\bar{X} - 2, \infty)$ 。可以算出

$$P(\bar{X} - 2 < \mu) = P(\bar{X} - \mu < 2) = \Phi(2) = 0.9772.$$

所以 $\bar{X} - 2$ 是 μ 的置信水平为 0.9772 的置信下限。

定义 (精确度, efficiency) 置信区间 (L, U) 的平均长度 $E(U - L)$ 可表示区间的精确度: $E(U - L)$ 越小, 区间的精确度越高。

说明: 在给定的样本容量下, 置信水平和精确度通常是互相制约的。比如, 在上例中, $(\bar{X} - 2, \bar{X} + 2)$ 是 μ 的置信水平为 0.9544 的置信区间。而 $(\bar{X} - 1, \bar{X} + 1)$ 是 μ 的置信水平为 0.6826 的置信区间。前者置信水平高, 但精确度低; 后者置信水平低, 但精确度高。

在相同的置信水平下, 置信区间不唯一。比如, 在上例中, $(\bar{X} - 2, \bar{X} + 2)$ 是 μ 的置信水平为 0.9544 的置信区间。而

$$P(\bar{X} - 1.89 < \mu < \bar{X} + 2.14) = P(-2.14 < \bar{X} - \mu < 1.89) = \Phi(1.89) - \Phi(-2.14) = 0.9544.$$

所以 $(\bar{X} - 1.89, \bar{X} + 2.14)$ 也是 μ 的置信水平为 0.9544 的置信区间。

但 $(\bar{X} - 2, \bar{X} + 2)$ 区间长度小于 $(\bar{X} - 1.89, \bar{X} + 2.14)$ 的区间长度, 所以精确度更高。

1.2 枢轴量法

问题：如何得到未知参数 θ 满足给定置信度 $1 - \alpha$ 的置信区间？

一般步骤：枢轴量法

- 1) 找到一个随机变量 G ，它是未知参数 θ 和样本 $X_1, \dots, X_n$ 的函数，并且分布已知（即分布不依赖于参数 θ ）。
- 2) 找到 $a < b$ ，使得 $P(a < G < b) = 1 - \alpha$ 。（若要求单侧置信上/下限，则可让 $a = -\infty$ 或 $b = \infty$ ）
- 3) 从 $a < G < b$ 中解出 $L < \theta < U$ 。

定义 (枢轴量, pivot) 设总体 X 有概率密度函数/概率质量函数 $f(x; \theta)$ ，其中 θ 是待估的未知参数。设 $X_1, \dots, X_n$ 为样本，若随机变量

$$G = G(X_1, \dots, X_n; \theta)$$

的分布已知（即不依赖于任何未知参数），则称 G 为枢轴量。

说明：枢轴量与统计量的区别：

- 1) 枢轴量是样本和待估参数的函数；其分布不依赖于任何未知参数。
- 2) 统计量只是样本的函数；其分布可依赖于未知参数。

例 总体 $X \sim N(\mu, \sigma^2)$ ，其中 μ, σ^2 均为未知参数，要估计参数 μ 。设 $X_1, \dots, X_n$ 为一个样本。试分析下面三个量

$$\bar{X}, \quad \frac{\bar{X} - \mu}{\sigma/\sqrt{n}}, \quad \frac{\bar{X} - \mu}{S/\sqrt{n}}$$

哪些是枢轴量，哪些是统计量。

首先，从表达式可以知道 $\bar{X}$ 为统计量，其余两个量不是统计量。

其次，我们知道 $\bar{X} \sim N(\mu, \sigma^2/n)$ ，分布依赖于未知参数 μ, σ ，所以不是枢轴量。另外 $(\bar{X} - \mu)/(\sigma/\sqrt{n})$ 包含了除 μ 外的另一未知参数 σ ，所以也不是枢轴量。而 $(\bar{X} - \mu)/(S/\sqrt{n})$ 只是样本和 μ 的函数，且服从 $t(n-1)$ 分布，分布与未知参数无关，所以它是枢轴量。□

例 (正态分布) 假设总体 $X \sim N(\mu, \sigma^2)$ ，其中 μ, σ 均未知。样本为 $X_1, \dots, X_n$ ，求 μ 的置信水平为 $1 - \alpha$ 的双侧置信区间。

对于正态总体， μ 的极大似然估计为 $\bar{X}$ ，且 $(\bar{X} - \mu)/(\sigma/\sqrt{n}) \sim N(0, 1)$ 。但 σ 未知时， $(\bar{X} - \mu)/(\sigma/\sqrt{n})$ 并非枢轴量。选择枢轴量

$$G = \frac{\bar{X} - \mu}{S/\sqrt{n}} \sim t(n-1).$$

希望求 a, b 使得

$$P\left(a < \frac{\bar{X} - \mu}{S/\sqrt{n}} < b\right) = 1 - \alpha.$$

由此得到 μ 的置信区间为

$$\left(\bar{X} - b \frac{S}{\sqrt{n}}, \bar{X} - a \frac{S}{\sqrt{n}}\right).$$

满足条件的 a, b 并不唯一, 我们希望找使区间精确度最高的 a, b 取值, 即要求 $b-a$ 最小。可以证明, 当 $b = -a$ 时, $b - a$ 最小。此时 $b = -a = t_{\alpha/2}(n-1)$, 置信区间为

$$\left(\bar{X} - t_{\alpha/2}(n-1) \frac{S}{\sqrt{n}}, \bar{X} + t_{\alpha/2}(n-1) \frac{S}{\sqrt{n}} \right).$$

以下做 $b = -a$ 的推导 (不要求掌握)。我们记 $t(n-1)$ 分布的累积分布函数为 $F(x)$ 。让 $\alpha_1 = P(G \leq a)$, $\alpha_2 = P(G \geq b)$, 则有

$$\alpha_1 + \alpha_2 = P(G \leq a \text{ 或 } G \geq b) = \alpha.$$

按照累积分布函数的定义,

$$\alpha_1 = F(a), \quad 1 - \alpha_2 = F(b).$$

把函数逆过来, 就得到

$$a = F^{-1}(\alpha_1), \quad b = F^{-1}(1 - \alpha_2).$$

后面一式利用 t -分布关于0对称这一性质可变为 $b = -F^{-1}(\alpha_2)$ 。于是

$$b - a = -F^{-1}(\alpha_2) - F^{-1}(\alpha_1) = -F^{-1}(\alpha - \alpha_1) - F^{-1}(\alpha_1).$$

上式中唯一自由的变量是 α_1 。为了最小化上式, 我们让它对 α_1 的导数为0, 这样得到

$$\frac{1}{F'\{F^{-1}(\alpha - \alpha_1)\}} - \frac{1}{F'\{F^{-1}(\alpha_1)\}} = 0 \quad (\text{利用反函数求导法则}).$$

注意到 $F'(x) = f(x)$ (密度函数), 我们可以得到

$$f(F^{-1}\{\alpha - \alpha_1\}) = f\{F^{-1}(\alpha_1)\}.$$

由于 $f(x)$ 关于0对称, 于是有以下两种可能性:

$$\text{i) } F^{-1}(\alpha - \alpha_1) = F^{-1}(\alpha_1)$$

$$\text{ii) } F^{-1}(\alpha - \alpha_1) = -F^{-1}(\alpha_1)$$

其中 i) 即可推出 $\alpha - \alpha_1 = \alpha_1$, 即 $\alpha_1 = \alpha_2 = \alpha/2$ 。进一步可以推出 $b = -a$ 。对于 ii), 再度利用分布关于0对称得到 $\alpha - \alpha_1 = 1 - \alpha_1$, 即推出 $\alpha = 1$, 与实际情况不符。 $\square$

说明: 上面关于 $b = -a$ 的推导, 只要枢轴量 G 的分布关于0对称 (例如 $N(0, 1)$ 分布), 就成立。很多情况下, 即使 G 的分布关于0不对称, 一般为了简便我们也选择 a, b 满足

$$P(G \leq a) = P(G \geq b) = \alpha/2.$$

例 (指数分布) 假设总体 $X \sim \text{Exp}(\theta)$, 其中 θ 未知。样本为 $X_1, \dots, X_n$, 求 θ 的置信水平为 $1 - \alpha$ 的双侧置信区间。

首先, 由指数分布的性质, $\theta X \sim \text{Exp}(1)$. 因此 $G = \theta n \bar{X} = \sum_{i=1}^n (\theta X_i) \sim \Gamma(n, 1)$, 为枢轴量。

记 $\Gamma(n, 1)$ 分布的上- α 分位数为 $\Gamma_\alpha(n, 1)$. 我们选择 a, b 满足 $P(G \leq a) = P(G \geq b) = \alpha/2$, 则应有 $a = \Gamma_{1-\alpha/2}(n, 1)$, $b = \Gamma_{\alpha/2}(n, 1)$. 由 $a < G < b$ 可以得到 θ 的置信区间

$$\left(\frac{\Gamma_{1-\alpha/2}(n, 1)}{n\bar{X}}, \frac{\Gamma_{\alpha/2}(n, 1)}{n\bar{X}} \right).$$

2 正态总体的区间估计

2.1 单个正态总体的均值

设总体 $X \sim N(\mu, \sigma^2)$, 样本为 $X_1, \dots, X_n$. 用 $\bar{X}$ 和 S^2 分别表示样本均值和样本方差. 取置信水平 $1-\alpha$, 求 μ 的置信区间。

情况一: $\sigma^2 = \sigma_0^2$ 已知。

此时可取枢轴量

$$G = \frac{\bar{X} - \mu}{\sigma_0/\sqrt{n}} \sim N(0, 1).$$

所以需要找到常数 a, b 满足

$$P(a < G < b) = 1 - \alpha.$$

由于 $N(0, 1)$ 分布关于0对称, 按照上节的推导, 使区间长度最小的 a, b 应满足 $P(G \leq a) = P(G \geq b) = \alpha/2$. 于是 $b = -a = z_{\alpha/2}$ (标准正态分布的上 $\alpha/2$ -分位数), 得到的置信区间为

$$\left(\bar{X} - z_{\alpha/2} \frac{\sigma_0}{\sqrt{n}}, \bar{X} + z_{\alpha/2} \frac{\sigma_0}{\sqrt{n}} \right).$$

置信区间的长度为 $2z_{\alpha/2}\sigma_0/\sqrt{n}$. 如果要求置信水平 $1 - \alpha$ 提高, 则 $z_{\alpha/2}$ 会增加, 意味着置信区间长度增加, 置信区间精确度降低。

若考虑置信度为 $1 - \alpha$ 的单侧置信下限, 即形如 (L, ∞) 的单侧置信区间, 那么需要找到常数 a 使得

$$P(G < a) = 1 - \alpha.$$

容易知道 $a = z_\alpha$. 由此得到的置信区间为

$$\left(\bar{X} - z_\alpha \frac{\sigma_0}{\sqrt{n}}, \infty \right).$$

若考虑置信度为 $1 - \alpha$ 的单侧置信上限, 即形如 $(-\infty, U)$ 的单侧置信区间, 则同样推理可得置信区间

$$\left(-\infty, \bar{X} + z_\alpha \frac{\sigma_0}{\sqrt{n}} \right).$$

情况二: σ^2 未知。

此时用 S^2 代替 σ^2 , 可得枢轴量

$$G = \frac{\bar{X} - \mu}{S/\sqrt{n}} \sim t(n-1).$$

按与情况一同样的推理, 可得双侧置信区间

$$\left(\bar{X} - t_{\alpha/2}(n-1) \frac{S}{\sqrt{n}}, \bar{X} + t_{\alpha/2}(n-1) \frac{S}{\sqrt{n}} \right).$$

相应地, 单侧置信区间为

$$\left(\bar{X} - t_{\alpha}(n-1) \frac{S}{\sqrt{n}}, \infty \right) \quad \text{与} \quad \left(-\infty, \bar{X} + t_{\alpha}(n-1) \frac{S}{\sqrt{n}} \right).$$

2.2 成对数据差的均值

例 为考察某种降压药的降压效果, 测试了 n 个高血压病人在服药前后的血压 (收缩压) 分别为

$$(X_1, Y_1), \dots, (X_n, Y_n).$$

注意数据里同一病人的 X_i 与 Y_i 不互相独立。

将数据做差 $D_i = X_i - Y_i, i = 1, \dots, n$, 表示服药前后的血压变化。则 $D_1, \dots, D_n$ 互相独立, 可以看做来自同一正态总体 $N(\mu_D, \sigma_D^2)$ 的样本。那么 μ_D 的置信区间为

$$\left(\bar{D} - t_{\alpha/2}(n-1) \frac{S_D}{\sqrt{n}}, \bar{D} + t_{\alpha/2}(n-1) \frac{S_D}{\sqrt{n}} \right),$$

其中

$$\bar{D} = \bar{X} - \bar{Y}, \quad S_D = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (D_i - \bar{D})^2}.$$

2.3 单个正态总体的方差

设总体 $X \sim N(\mu, \sigma^2)$, 其中 μ, σ^2 未知, 样本为 $X_1, \dots, X_n$ 。用 $\bar{X}$ 和 S^2 分别表示样本均值和样本方差。取置信水平 $1 - \alpha$, 求 σ^2 的置信区间。

我们已经知道 S^2 为 σ^2 的一个无偏估计。根据学生定理, 可以取枢轴量

$$G = \frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1).$$


虽然 $\chi^2(n-1)$ 分布不是关于0对称的, 我们仍然可以选 a, b 使得

$$P(G \leq a) = \alpha/2, \quad P(G \geq b) = \alpha/2.$$

于是知道, $a = \chi_{1-\alpha/2}^2(n-1)$ (即 $\chi^2(n-1)$ 分布的上 $(1-\alpha/2)$ -分位数), $b = \chi_{\alpha/2}^2(n-1)$ (即 $\chi^2(n-1)$ 分

布的上 $\alpha/2$ -分位数)。所以 σ^2 的置信区间为

$$\left(\frac{(n-1)S^2}{\chi_{\alpha/2}^2(n-1)}, \frac{(n-1)S^2}{\chi_{1-\alpha/2}^2(n-1)} \right).$$



同样道理，可以知道单侧置信区间为

$$\left(\frac{(n-1)S^2}{\chi_{\alpha}^2(n-1)}, \infty \right) \quad \text{与} \quad \left(0, \frac{(n-1)S^2}{\chi_{1-\alpha}^2(n-1)} \right).$$

2.4 两个正态总体

设样本 $X_1, \dots, X_{n_1}$ 与 $Y_1, \dots, Y_{n_2}$ 分别来自总体 $X \sim N(\mu_1, \sigma_1^2)$ 与 $Y \sim N(\mu_2, \sigma_2^2)$ ，且它们互相独立。样本均值分别为 $\bar{X}$ 与 $\bar{Y}$ ，样本方差分别为 S_1^2 与 S_2^2 。置信水平取 $1 - \alpha$ 。

问题一：求 $\mu_1 - \mu_2$ 的置信区间，假设 σ_1^2, σ_2^2 已知。

首先， $\mu_1 - \mu_2$ 的一个估计量为 $\bar{X} - \bar{Y}$ 。容易知道 $\bar{X} - \bar{Y}$ 服从正态分布，并且

$$\begin{aligned} E(\bar{X} - \bar{Y}) &= E(\bar{X}) - E(\bar{Y}) = \mu_1 - \mu_2 \\ \text{Var}(\bar{X} - \bar{Y}) &= \text{Var}(\bar{X}) + \text{Var}(\bar{Y}) = \sigma_1^2/n_1 + \sigma_2^2/n_2, \end{aligned}$$

即 $\bar{X} - \bar{Y} \sim N(\mu_1 - \mu_2, \sigma_1^2/n_1 + \sigma_2^2/n_2)$ 。将其标准化就可得枢轴量

$$\frac{(\bar{X} - \bar{Y}) - (\mu_1 - \mu_2)}{\sqrt{\sigma_1^2/n_1 + \sigma_2^2/n_2}} \sim N(0, 1).$$

下面取 $b = -a = z_{\alpha/2}$ ，可以知道

$$P \left\{ a < \frac{(\bar{X} - \bar{Y}) - (\mu_1 - \mu_2)}{\sqrt{\sigma_1^2/n_1 + \sigma_2^2/n_2}} < b \right\} = 1 - \alpha.$$

于是 $\mu_1 - \mu_2$ 的双侧置信区间为

$$\left(\bar{X} - \bar{Y} - z_{\alpha/2} \sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}, \bar{X} - \bar{Y} + z_{\alpha/2} \sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}} \right).$$

问题二：求 $\mu_1 - \mu_2$ 的置信区间，假设 $\sigma_1^2 = \sigma_2^2 = \sigma^2$ 未知。

在问题一的枢轴量中，考虑用

$$S_w^2 = \frac{(n_1 - 1)S_1^2 + (n_2 - 1)S_2^2}{n_1 + n_2 - 2}$$

代替 σ^2 。在第三讲中已经证明

$$\frac{(\bar{X} - \bar{Y}) - (\mu_1 - \mu_2)}{S_w \sqrt{1/n_1 + 1/n_2}} \sim t(n_1 + n_2 - 2).$$

选取 $b = -a = t_{\alpha/2}(n_1 + n_2 - 2)$ ，可以知道

$$P \left\{ a < \frac{(\bar{X} - \bar{Y}) - (\mu_1 - \mu_2)}{S_w \sqrt{1/n_1 + 1/n_2}} < b \right\} = 1 - \alpha.$$

于是 $\mu_1 - \mu_2$ 的双侧置信区间为

$$\left(\bar{X} - \bar{Y} - t_{\alpha/2}(n_1 + n_2 - 2) S_w \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}, \bar{X} - \bar{Y} + t_{\alpha/2}(n_1 + n_2 - 2) S_w \sqrt{\frac{1}{n_1} + \frac{1}{n_2}} \right).$$

问题三：求 $\mu_1 - \mu_2$ 的置信区间，假设 $\sigma_1^2 \neq \sigma_2^2$ ，且均未知。(略)

问题四：求 σ_1^2/σ_2^2 的置信区间，假设 μ_1, μ_2 未知。

首先知道， σ_1^2/σ_2^2 的一个估计量是 S_1^2/S_2^2 。第三讲已经证明

$$\frac{S_1^2/\sigma_1^2}{S_2^2/\sigma_2^2} \sim F(n_1 - 1, n_2 - 1),$$

所以为枢轴量。取 $a = F_{1-\alpha/2}(n_1 - 1, n_2 - 1)$, $b = F_{\alpha/2}(n_1 - 1, n_2 - 1)$ ，则

$$P \left\{ a < \frac{S_1^2/\sigma_1^2}{S_2^2/\sigma_2^2} < b \right\} = 1 - \alpha.$$

于是 σ_1^2/σ_2^2 的双侧置信区间为

$$\left(\frac{S_1^2}{S_2^2} \cdot \frac{1}{F_{\alpha/2}(n_1 - 1, n_2 - 1)}, \frac{S_1^2}{S_2^2} \cdot \frac{1}{F_{1-\alpha/2}(n_1 - 1, n_2 - 1)} \right).$$