



第八讲 单因素方差分析，一元线性回归

袁洪松

内容概要:

单因素方差分析，一元线性回归

预习内容:

1. 浙大《概率论与数理统计》P86-89 (第61-64讲)

<https://www.bilibili.com/video/av20027947?p=86>

<https://www.bilibili.com/video/av20027947?p=87>

<https://www.bilibili.com/video/av20027947?p=88>

<https://www.bilibili.com/video/av20027947?p=89>

2. 疫情预测模型与回归

<https://www.bilibili.com/video/BV167411D7P9>

<https://www.bilibili.com/video/BV1m7411t7QA>

课本相关章节:

无

1 单因素方差分析

定义 (方差分析, analysis of variance, ANOVA) 方差分析是推断两个或两个以上总体均值是否有差异的检验方法。

在方差分析中, 通常把考察的试验结果称为试验指标, 对试验指标产生影响的原因称为因素 (factor), 因素中各个不同的状态称为水平 (level)。

单因素方差分析 (one-way ANOVA) 就是仅考虑一个因素对试验指标的影响。假设因素 A 有 r 个水平, 分别第 i 个水平下进行了多次独立观测。设所得到的试验指标的数据为

因素水平	总体分布	数据个数	数据
A_1	$N(\mu_1, \sigma^2)$	n_1	$X_{11} \quad X_{12} \quad \cdots \quad X_{1n_1}$
A_2	$N(\mu_2, \sigma^2)$	n_2	$X_{21} \quad X_{22} \quad \cdots \quad X_{2n_2}$
$\vdots$	$\vdots$	$\vdots$	$\cdots$
A_r	$N(\mu_r, \sigma^2)$	n_r	$X_{r1} \quad X_{r2} \quad \cdots \quad X_{rn_r}$

假设各总体间相互独立。可以用如下数学模型描述

$$X_{ij} = \mu_i + \epsilon_{ij}, \quad i = 1, \dots, r, \quad j = 1, \dots, n_i,$$

其中 $\epsilon_{ij} \sim N(0, \sigma^2)$ ，且互相之间都独立。方差分析的目的就是要检验各个水平下的总体均值是否都相等，即检验问题

$$H_0 : \mu_1 = \mu_2 = \dots = \mu_r \quad \text{vs} \quad H_1 : \mu_1, \mu_2, \dots, \mu_r \text{ 不全相等}.$$

注意当 $r = 2$ 时，可运用两个正态总体均值的假设检验，即 t -检验。

记

$$\begin{aligned} n &= \sum_{i=1}^r n_i, \\ \bar{X}_{i\cdot} &= \frac{1}{n_i} \sum_{j=1}^{n_i} X_{ij}, \\ \bar{X} &= \frac{1}{n} \sum_{i=1}^r \sum_{j=1}^{n_i} X_{ij}. \end{aligned}$$

定义如下三个量：

$$\begin{aligned} S_T &= \sum_{i=1}^r \sum_{j=1}^{n_i} (X_{ij} - \bar{X})^2, \\ S_A &= \sum_{i=1}^r n_i (\bar{X}_{i\cdot} - \bar{X})^2, \\ S_E &= \sum_{i=1}^r \sum_{j=1}^{n_i} (X_{ij} - \bar{X}_{i\cdot})^2. \end{aligned}$$

我们把 S_T 称为总离差平方和 (total sum of squares)，把 S_A 称为效应平方和 (sum of squares of treatments) 或组间平方和 (sum of squares between groups)，把 S_E 称为误差平方和 (sum of squares of error) 或组内平方和 (sum of squares within groups)。

定理

$$1) \quad S_T = S_A + S_E.$$

$$2) \quad S_E / \sigma^2 \sim \chi^2(n - r).$$

$$3) \quad S_A \text{ 与 } S_E \text{ 相互独立。且当 } H_0 \text{ 为真时， } S_A / \sigma^2 \sim \chi^2(r - 1). \text{ 此时}$$

$$F = \frac{S_A / (r - 1)}{S_E / (n - r)} \sim F(r - 1, n - r).$$

证明： (仅要求理解，不要求掌握)

1) 首先对 S_T 做变化

$$\begin{aligned} S_T &= \sum_{i=1}^r \sum_{j=1}^{n_i} (X_{ij} - \bar{X})^2 = \sum_{i=1}^r \sum_{j=1}^{n_i} (X_{ij} - \bar{X}_{i\cdot} + \bar{X}_{i\cdot} - \bar{X})^2 \\ &= \sum_{i=1}^r \sum_{j=1}^{n_i} (X_{ij} - \bar{X}_{i\cdot})^2 + \sum_{i=1}^r \sum_{j=1}^{n_i} (\bar{X}_{i\cdot} - \bar{X})^2 + \sum_{i=1}^r \sum_{j=1}^{n_i} 2(X_{ij} - \bar{X}_{i\cdot})(\bar{X}_{i\cdot} - \bar{X}). \end{aligned}$$

其中第一项即为 S_E 。第二项中 $(\bar{X}_{i\cdot} - \bar{X})^2$ 与 j 无关，所以

$$\sum_{i=1}^r \sum_{j=1}^{n_i} (\bar{X}_{i\cdot} - \bar{X})^2 = \sum_{i=1}^r n_i (\bar{X}_{i\cdot} - \bar{X})^2 = S_A.$$

而第三项中 $\bar{X}_{i\cdot} - \bar{X}$ 也与 j 无关，所以

$$\begin{aligned} \sum_{i=1}^r \sum_{j=1}^{n_i} 2(X_{ij} - \bar{X}_{i\cdot})(\bar{X}_{i\cdot} - \bar{X}) &= 2 \sum_{i=1}^r (\bar{X}_{i\cdot} - \bar{X}) \sum_{j=1}^{n_i} (X_{ij} - \bar{X}_{i\cdot}) \\ &= 2 \sum_{i=1}^r (\bar{X}_{i\cdot} - \bar{X}) \left(\sum_{j=1}^{n_i} X_{ij} - n_i \bar{X}_{i\cdot} \right) = 0. \end{aligned}$$

由此 $S_T = S_A + S_E$ 得证。

2) 在 S_E 中，由学生定理可知， $\sum_{j=1}^{n_i} (X_{ij} - \bar{X}_{i\cdot})^2 / \sigma^2 \sim \chi^2(n_i - 1)$ 。由于各水平的样本之间相互独立，根据 χ^2 分布的性质，

$$S_E / \sigma^2 = \sum_{i=1}^r \sum_{j=1}^{n_i} (X_{ij} - \bar{X}_{i\cdot})^2 / \sigma^2 \sim \chi^2 \left(\sum_{i=1}^r (n_i - 1) \right) = \chi^2(n - r).$$

3) 从表达式来看， S_E 仅依赖于每个水平的样本方差，而 S_A 仅依赖于每个水平的样本均值 $\bar{X}_{i\cdot}$ （其实 S_A 还依赖于总的均值 $\bar{X}$ ，但由于 $\bar{X} = \sum_{i=1}^r n_i \bar{X}_{i\cdot} / n$ ，所以还是只依赖于每个水平的样本均值）。根据学生定理，正态分布的样本方差与样本均值互相独立，所以 S_E 与 S_A 互相独立。

当 H_0 为真时， $\mu_1 = \mu_2 = \cdots = \mu_r$ ，即所有样本都来自于同一正态分布。由学生定理可知 $S_T / \sigma^2 \sim \chi^2(n - 1)$ 。再结合1)2)可得， $S_A / \sigma^2 \sim \chi^2(r - 1)$ 。

最后根据 F -分布的定义，

$$F = \frac{S_A / (r - 1)}{S_E / (n - r)} \sim F(r - 1, n - r). \quad \square$$

由直观上看，若 H_0 为真，则 $\bar{X}_{i\cdot}, i = 1, \dots, r$ 都应该接近于 $\bar{X}$ ，所以 S_A 应该较小。由上面定理，可以选择 F 为检验统计量，拒绝域形如 $\{F \geq c\}$ 。为使显著水平为 α ，应取 $c = F_\alpha(r - 1, n - r)$ 。因此拒绝域为

$$\left\{ \frac{S_A / (r - 1)}{S_E / (n - r)} \geq F_\alpha(r - 1, n - r) \right\}.$$

可以制作一张方差分析表 (ANOVA table):

方差来源	平方和	自由度	均方	F	p -值	临界值
因素A	S_A	$r - 1$	$MS_A = S_A / (r - 1)$	MS_A / MS_E	$P\{F(r - 1, n - r) \geq f_0\}$	$F_\alpha(r - 1, n - r)$
误差	S_E	$n - r$	$MS_E = S_E / (n - r)$			
总和	S_T	$n - 1$				

当表中的 F 值大于等于临界值，或者 p -值小于等于 α 时，拒绝原假设。上表的英文版:

Source	Sum of squares	Degree of freedom	Mean squares	F	p -value	F crit
Between groups	S_A	$r - 1$	$MS_A = S_A / (r - 1)$	MS_A / MS_E	$P\{F(r - 1, n - r) \geq f_0\}$	$F_\alpha(r - 1, n - r)$
Within groups	S_E	$n - r$	$MS_E = S_E / (n - r)$			
Total	S_T	$n - 1$				

例 保险公司为了了解某一险种在四个不同地区索赔额情况是否存在差异，搜集了四个不同地区一年的索赔情况记录，如表所示。试判断在四个不同地区索赔额有无显著的差异？

地区	索赔额
A1	1.60, 1.61, 1.65, 1.68, 1.70, 1.70, 1.78
A2	1.50, 1.64, 1.40, 1.70, 1.75
A3	1.64, 1.55, 1.60, 1.62, 1.64, 1.60, 1.74, 1.80
A4	1.51, 1.52, 1.53, 1.57, 1.64, 1.60

首先计算基本的组内数据 (具体计算过程见Excel表格“ANOVA.xlsx”)

组	观测数	样本均值	样本方差
A1	7	1.674	0.0038
A2	5	1.598	0.0210
A3	8	1.649	0.0067
A4	6	1.562	0.0026
所有	26	1.626	0.0086

然后得到方差分析表

方差来源	平方和	自由度	均方	F	p -值	临界值
因素A	0.0492	3	0.0164	2.1659	0.1208	3.0491
误差	0.1666	22	0.0076			
总和	0.2158	25				

由于 F -值小于临界值，故接受原假设。也可以依靠 p -值大于0.05判断接受原假设。 □

在方差分析模型中，参数 σ^2 与 μ_i 的无偏估计分别是

$$\hat{\sigma}^2 = \frac{S_E}{n-r} = MS_E$$

$$\hat{\mu}_i = \bar{X}_{i\cdot}, \quad i = 1, \dots, r.$$

若拒绝了 $\mu_1 = \mu_2 = \dots = \mu_r$ 的假设，则可进一步检验两两水平之间是否相等。对于某一对 $1 \leq i \neq j \leq r$ ，考虑检验问题

$$H_0: \mu_i = \mu_j \quad \text{vs} \quad H_1: \mu_i \neq \mu_j.$$

可以取检验统计量


$$T_{ij} = \frac{\bar{X}_{i\cdot} - \bar{X}_{j\cdot}}{\sqrt{MS_E(1/n_i + 1/n_j)}}.$$

可以证明，当 H_0 成立时（这里 H_0 指 $\mu_i = \mu_j$ ）， $T_{ij} \sim t(n-r)$ 。于是显著水平为 α 的拒绝域为

$$\{|T_{ij}| \geq t_{\alpha/2}(n-r)\}.$$

2 一元线性回归简介

考虑变量之间的相关性关系：设有自变量 x （标量）与因变量 Y ，其中 Y 具有随机性。即对自变量 x 的同一值，在不同的观测中因变量 Y 可以取不同的值。自变量与因变量之间的相关性关系可以用**散点图** (scatter plot) 来表示。



假设 Y 的值中包含两部分：一部分是 x 的确定性函数，另一部分是随机因素。若确定性函数为线性函数，则称此模型为**一元线性回归模型** (simple linear regression model)。


若观测到样本 $(x_1, y_1), \dots, (x_n, y_n)$ ，一元线性回归模型的具体假设为

$$y_i = \beta_0 + \beta_1 x_i + \epsilon_i,$$

其中 $\epsilon_i \sim N(0, \sigma^2)$ 且相互独立， $\beta_0, \beta_1, \sigma^2$ 为未知参数。称 β_0, β_1 为回归系数 (regression coefficient)。

一元线性回归模型要解决的问题包括：

- 1) 参数的点估计： $\beta_0, \beta_1, \sigma^2$ 的点估计
- 2) 区间估计：回归系数 β_0, β_1 的置信区间
- 3) 假设检验：线性假设的显著性检验
- 4) 预测：因变量 Y 的点预测



这里只考虑 $\beta_0, \beta_1, \sigma^2$ 的点估计。忽略自变量 x 的随机性，即把 $x_1, \dots, x_n$ 看做是确定的常数。则模型中的随机性仅来自于 Y_i ，也可以说仅来自于 ϵ_i 。由模型假设， $\epsilon_1, \dots, \epsilon_n$ 为取自 $N(0, \sigma^2)$ 分布的样本，而 ϵ_i 的观测值为 $y_i - \beta_0 - \beta_1 x_i$ 。于是可写出似然函数

$$L(\beta_0, \beta_1, \sigma) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} \exp \left\{ -\frac{1}{2\sigma^2} (y_i - \beta_0 - \beta_1 x_i)^2 \right\}.$$

对数似然函数为

$$l(\beta_0, \beta_1, \sigma) = \sum_{i=1}^n \left\{ -\frac{1}{2} \log(2\pi\sigma^2) - \frac{1}{2\sigma^2} (y_i - \beta_0 - \beta_1 x_i)^2 \right\}.$$

为求极大似然估计，可令 $l(\beta_0, \beta_1, \sigma)$ 对三个参数的偏导都为0。首先，对 σ 求偏导

$$\frac{l(\beta_0, \beta_1, \sigma)}{\partial \sigma} = \sum_{i=1}^n \left\{ -\frac{1}{\sigma} + \frac{1}{\sigma^3} (y_i - \beta_0 - \beta_1 x_i)^2 \right\} = 0.$$

可以推出

$$\sigma^2 = \frac{1}{n} \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2.$$

将其代回 $l(\beta_0, \beta_1, \sigma)$ ，得到

$$\begin{aligned} l(\beta_0, \beta_1, \sigma) &= -\frac{n}{2} \log(2\pi\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2 \\ &= -\frac{n}{2} \log(2\pi) - \frac{n}{2} \log \left\{ \frac{1}{n} \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2 \right\} - \frac{n}{2}. \end{aligned}$$

因此，最大化 $l(\beta_0, \beta_1, \sigma)$ 转化为最小化 $\sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2$ 。

令 $Q(\beta_0, \beta_1) = \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2$ ，则需解决

$$\min_{\beta_0, \beta_1} Q(\beta_0, \beta_1).$$

这称为**最小二乘法 (ordinary least squares)**。问题的解 $\hat{\beta}_0, \hat{\beta}_1$ 称为 β_0, β_1 的最小二乘估计。

进一步对 β_0, β_1 求偏导，可得

$$\begin{aligned} \frac{Q(\beta_0, \beta_1)}{\beta_0} &= -2 \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i) = 0, \\ \frac{Q(\beta_0, \beta_1)}{\beta_1} &= -2 \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i) x_i = 0. \end{aligned}$$

可以解出

$$\begin{aligned} \hat{\beta}_0 &= \bar{y} - \bar{x} \hat{\beta}_1, \\ \hat{\beta}_1 &= s_{xy} / s_{xx}, \end{aligned}$$

其中

$$\begin{aligned} \bar{x} &= \frac{1}{n} \sum_{i=1}^n x_i, \quad \bar{y} = \frac{1}{n} \sum_{i=1}^n y_i, \\ s_{xx} &= \sum_{i=1}^n (x_i - \bar{x})^2, \quad s_{xy} = \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}). \end{aligned}$$

由此可知, σ^2 的极大似然估计为

$$\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i)^2.$$

可以证明

$$E \left\{ \sum_{i=1}^n (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i)^2 \right\} = (n-2)\sigma^2,$$

所以 $\hat{\sigma}^2$ 是有偏的。对其纠偏可得 σ^2 的无偏估计

$$s^2 = \frac{1}{n-2} \sum_{i=1}^n (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i)^2.$$

我们称 $\hat{e}_i = y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i$ 为**残差 (residual)**, 称 $\sum_{i=1}^n (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i)^2$ 为**残差平方和 (residual sum of squares)**。