

第六章总结

一、第六章的总主题：从样本出发，推断总体参数

第六章研究的是**参数估计** (parameter estimation)。

所谓“参数”，不要狭义地只理解成分布里写出来的字母。整章里，参数大体包括三类：

第一类，是分布本身的未知参数，比如 Bernoulli 分布 $b(1, p)$ 中的 p ，正态分布 $N(\mu, \sigma^2)$ 中的 μ, σ^2 。

第二类，是参数的函数，比如 $P(X \leq a)$ 、分位数 (quantile)、可靠度函数、失效概率等。

第三类，是总体的某些特征数 (characteristics)，如均值 (mean)、方差 (variance)、中位数 (median)、标准差 (standard deviation) 等。

所以第六章并不只是“估一个字母”，而是在研究：

给定样本 $X_1, \dots, X_n$ ，怎样构造一个统计量 (statistic) 去估计我们关心的未知量。

整章分成两大块看最清楚：

- 前半章主要是**点估计** (point estimation)：给出一个数去估参数。
- 后半章主要是**区间估计** (interval estimation)：给出一个范围去表达不确定性。

更细一点说，第六章的逻辑链是：

- 6.1 先讲“什么叫估计量，怎么评价它最基本是否合理”；
- 6.2 讲“怎么构造估计量，尤其是矩估计”；
- 6.3 讲“最大似然估计这套最核心的方法”；
- 6.4 讲“如果同一个参数有很多估计量，谁更好”；
- 6.5 讲“如果有先验信息，怎么做贝叶斯估计”；
- 6.6 讲“点估计不够，要进一步给出区间估计”。

所以这一章不是杂乱的六节，而是一个完整的估计理论体系。

二、6.1 点估计的概念与无偏性：先回答“什么叫一个估计量”

1. 点估计 (point estimation) 到底是什么

设样本为 $X_1, \dots, X_n$ ，未知参数为 θ 。如果我们构造了一个统计量 $\hat{\theta} = \hat{\theta}(X_1, \dots, X_n)$ 来估计 θ ，那么这个 $\hat{\theta}$ 就叫做 θ 的**估计量** (estimator)。

一旦样本观测值出来，变成 $x_1, \dots, x_n$ ，就可以算出具体数值 $\hat{\theta}(x_1, \dots, x_n)$ ，这个具体数值叫做**估计值** (estimate)。

这两个词一定要分清：

- $\hat{\theta}$ 是随机变量，是“规则”；
- $\hat{\theta}(x_1, \dots, x_n)$ 是具体数字，是“结果”。

这是整章最基础、也最容易被忽略的点。后面讲无偏性、方差、MSE、相合性、渐近正态性，其实全都在研究**估计量这个随机变量**的性质。

2. 为什么估计量一定是随机变量

因为样本本身是随机的，而估计量是样本的函数，所以估计量自然也是随机变量。

这件事在统计里非常关键。因为估计不是“解方程求真值”，而是：

构造一个随机机制，让它随着抽样重复，能以某种理想方式围绕真值工作。

所以统计学研究估计量，核心总是这两件事：

- 平均位置对不对；
- 波动大小大不大。

这就引出了无偏性和有效性。

3. 无偏性 (unbiasedness)：最基础的有限样本标准

如果对任意参数值 θ 都有 $E_{\theta}(\hat{\theta}) = \theta$ ，则称 $\hat{\theta}$ 是 θ 的**无偏估计** (unbiased estimator)。

如果不等于，则称为**有偏估计** (biased estimator)。

无偏性的直观含义是：

估计量没有系统性偏差 (systematic bias)。

它不是说每次抽样都很准，而是说：

- 有时高估；
- 有时低估；
- 但长期平均不偏向某一边。

所以无偏关注的是“平均位置”，不关注“分散程度”。

4. 样本均值为什么是总体均值的无偏估计

样本均值 $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$ 是总体均值 $\mu = E(X)$ 的无偏估计，因为

$$E(\bar{X}) = E\left(\frac{1}{n} \sum_{i=1}^n X_i\right) = \frac{1}{n} \sum_{i=1}^n E(X_i) = \mu。$$

这是最重要、最基础的无偏估计例子。

更一般地，若总体的 k 阶原点矩（raw moment about origin）存在，则对应的样本原点矩通常也是该总体原点矩的无偏估计。

这说明：样本均值在统计中之所以核心，不只是“好算”，更因为它天然契合期望的线性结构。

5. 样本方差为什么会出现 $n - 1$

这一点是第六章最经典的细节之一。

如果定义

$$s_n^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2,$$

则它不是总体方差 σ^2 的无偏估计，因为

$$E(s_n^2) = \frac{n-1}{n} \sigma^2。$$

所以它系统性偏小。

原因是：你不是围绕真实均值 μ 去算离差，而是围绕样本均值 $\bar{X}$ 去算。由于 $\bar{X}$ 本身是用样本“贴着数据长出来的中心”，所以离差平方和会被压小一点。

于是要做自由度修正（degrees of freedom correction），得到

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2,$$

这才满足 $E(s^2) = \sigma^2$ 。

所以这里你一定要建立一个长期有效的理解：

- 分母是 n 的版本，常常和 MLE 有关；
 - 分母是 $n - 1$ 的版本，常常和无偏性有关。
-

6. 渐近无偏（asymptotically unbiased）

若 $E(\hat{\theta}_n) \rightarrow \theta$ ，则称 $\hat{\theta}_n$ 是 θ 的渐近无偏估计（asymptotically unbiased estimator）。

比如刚才的 s_n^2 ，虽然不是严格无偏，但因为 $\frac{n-1}{n} \rightarrow 1$ ，所以它是 σ^2 的渐近无偏估计。

这说明：

- 无偏是有限样本精确性质；
- 渐近无偏是大样本近似性质。

很多实际中常用的估计量不是严格无偏，但只要大样本下偏差消失，依然很重要。

7. 无偏性不具有不变性 (invariance)

这是一个特别容易考、也特别容易误解的点。

若 $\hat{\theta}$ 是 θ 的无偏估计，一般并不能推出 $g(\hat{\theta})$ 是 $g(\theta)$ 的无偏估计，除非 g 是线性函数。

因为通常有

$$E[g(\hat{\theta})] \neq g(E[\hat{\theta}])。$$

最典型的例子就是：

- s^2 可以是 σ^2 的无偏估计；
- 但 s 一般不是 σ 的无偏估计。

所以“先无偏再做函数变换”这条路通常走不通。

和这一点形成鲜明对比的是：后面 6.3 里 MLE 却具有不变性。这两个性质恰好构成一个很强的对比，你一定要记住。

8. 刀切法 (jackknife)：一种减小偏差的思想

如果某个估计量存在偏差，而且这种偏差大约是 $O(1/n)$ 级别，那么可以考虑用**刀切法** (jackknife) 进行偏差修正。

它的思想是：

- 每次删去一个观测值；
- 在删一后的样本上重新计算估计量；
- 把原估计和这些“留一估计”做适当组合；
- 抵消原估计的一阶偏差。

本质上，这是一种**重抽样修偏** (resampling-based bias reduction) 方法。

你不一定要死记公式，但一定要理解：

它不是改变估计准则，而是在原估计量基础上做偏差修正。

9. 可估性 (estimability)：不是所有参数都有无偏估计

教材特别强调：并非所有参数都存在无偏估计。

如果某个参数存在无偏估计，则称该参数是**可估的** (estimable)；否则称为**不可估的** (inestimable)。

这件事很重要，因为很多同学会默认“反正总能构造一个无偏估计”。其实不是。无偏性是一个很强的要求，有些参数函数根本无法由有限样本的期望精确表示出来。

所以你要有一个观念：

无偏性很好，但不是所有问题都能拥有它。

10. 有效性 (efficiency)：无偏还不够，还要看波动

若 $\hat{\theta}_1, \hat{\theta}_2$ 都是 θ 的无偏估计，并且对所有 θ 都有

$$\text{Var}(\hat{\theta}_1) \leq \text{Var}(\hat{\theta}_2),$$

且至少在某些地方严格小于，那么称 $\hat{\theta}_1$ 比 $\hat{\theta}_2$ **更有效** (more efficient)。

这说明：无偏只是第一层，接下来还要看“谁更稳”。

直观上：

- 无偏：平均打在靶心附近；
- 有效：弹着点更集中。

所以第六章前半一开始，就已经在搭建“如何评价一个估计量”的最早框架：

- 先看偏不偏；
 - 再看散不散。
-

三、6.2 矩估计及相合性：先学会“怎么构造估计量”

1. 替换原理 (substitution principle)

这一节先讲的是估计构造思想。

所谓替换原理，就是：

- 用**样本矩** (sample moments) 替换**总体矩** (population moments)；
- 用样本矩的函数替换总体矩函数。

它背后真正的统计思想是：

样本分布应当近似总体分布，所以样本特征数应当近似总体特征数。

这个思想的理论背景是大数定律（law of large numbers）以及经验分布函数对总体分布函数的逼近。

2. 什么是矩估计（method of moments, MoM）

若总体分布含有 k 个未知参数 $\theta_1, \dots, \theta_k$ ，并且这 k 个参数可以用前 k 阶总体矩表示，那么就把对应总体矩换成样本矩，从而解出参数估计。

具体套路是：

第一步，写出总体矩方程。

第二步，把总体矩换成样本矩。

第三步，解方程得到参数估计。

这是做矩估计题最标准的模板。

3. 样本矩与总体矩

样本 k 阶原点矩通常写成

$$a_k = \frac{1}{n} \sum_{i=1}^n X_i^k。$$

若总体的前几阶原点矩分别为 $\mu'_1, \mu'_2, \dots$ ，而参数满足

$$\theta_j = \theta_j(\mu'_1, \dots, \mu'_k)，$$

那么矩估计就是

$$\hat{\theta}_j = \theta_j(a_1, \dots, a_k)。$$

如果要估的是某个函数 $\eta = g(\theta_1, \dots, \theta_k)$ ，则可直接代入得到

$$\hat{\eta} = g(\hat{\theta}_1, \dots, \hat{\theta}_k)。$$

4. 矩估计的典型例子

指数分布

若 $X \sim \text{Exp}(1/\lambda)$ ，则 $E(X) = 1/\lambda$ ，于是由 $\bar{X}$ 替换 $E(X)$ ，得到

$$\hat{\lambda} = \frac{1}{\bar{X}}。$$

这是单参数矩估计最经典的例子。

均匀分布 $U(a, b)$

若参数有两个，就用两个矩方程。例如

$$E(X) = \frac{a+b}{2}, \text{Var}(X) = \frac{(b-a)^2}{12}。$$

用 $\bar{X}$ 和 s^2 代替后，就能解出 a, b 的矩估计。

这个例子非常重要，因为它体现了多参数矩估计的一般模式：

参数有几个，就配几个矩方程。

5. 矩估计的优点与局限

优点

构造简单，思路直接，不需要复杂优化。

局限

不一定高效，不一定无偏，也不一定唯一。

同一个参数可能能写成不同矩的函数，于是可能得到不同形式的矩估计。

所以矩估计更像：

一种“容易上手的通用构造法”

而不是最优方法。

6. 相合性 (consistency)：大样本下最终会不会逼近真值

如果对任意 $\varepsilon > 0$ ，都有

$$\lim_{n \rightarrow \infty} P(|\hat{\theta}_n - \theta| \geq \varepsilon) = 0,$$

则称 $\hat{\theta}_n$ 是 θ 的**相合估计** (consistent estimator)。

这其实就是

$$\hat{\theta}_n \xrightarrow{P} \theta$$

即依概率收敛 (convergence in probability) 到真值。

相合性的直观含义非常重要：

样本量越来越大时，估计量应该越来越贴近真值。

这是现代统计里比无偏更根本的要求。

7. 为什么相合性比无偏更根本

无偏只是说“平均位置对”，但如果方差一直不变，那么估计量哪怕无偏，也可能始终很飘，不一定真能逼近真值。

相合则要求：

- 不只是平均上对；
- 而是整个随机变量序列最终要收敛到真值。

所以很多统计学家会认为：

一个估计量可以有偏，但不能不相合。

8. 判断相合性的两个实用定理

定理一：渐近无偏 + 方差趋于 0

若

$$E(\hat{\theta}_n) \rightarrow \theta$$

且

$$\text{Var}(\hat{\theta}_n) \rightarrow 0,$$

则 $\hat{\theta}_n$ 是相合的。

这个结论通常借助切比雪夫不等式（Chebyshev inequality）来证明。

你可以把它记成：

渐近无偏 + 波动消失 $\Rightarrow$ 相合。

定理二：连续函数下相合性保持

若 $\hat{\theta}_{n1}, \dots, \hat{\theta}_{nk}$ 分别相合于 $\theta_1, \dots, \theta_k$ ，而 g 是连续函数，则

$$g(\hat{\theta}_{n1}, \dots, \hat{\theta}_{nk})$$

相合于

$g(\theta_1, \dots, \theta_k)$ 。

这条定理极其重要，因为很多参数估计其实都是“先估基本参数，再代入函数”。

9. 为什么矩估计通常相合

这是 6.2 最后最重要的结论之一。

原因是：

- 样本矩由大数定律收敛到总体矩；
- 参数是总体矩的连续函数；
- 所以由连续映射思想，矩估计也会收敛到真值。

因此，矩估计虽然未必最优，但通常有一个很好的大样本性质：

一般具有相合性。

这也是矩估计之所以长期重要的根本原因之一。

四、6.3 最大似然估计与 EM 算法：从“最像产生这组数据”的角度估参数

这一节是整章最核心的一节之一。

1. 最大似然原理（maximum likelihood principle）

它回答的问题是：

已经观测到了这组样本，那么什么参数值最能解释这组样本会出现？

所以最大似然估计（MLE）的思想不是“替换矩”，也不是“先追求无偏”，而是：

反过来看，哪个参数值让当前样本的出现最有可能。

2. 似然函数（likelihood function）

若总体密度或概率函数为 $p(x; \theta)$ ，样本为 $x_1, \dots, x_n$ ，则似然函数是

$$L(\theta) = \prod_{i=1}^n p(x_i; \theta)。$$

要强调：

- 概率 (probability) 是参数固定、样本随机；
- 似然 (likelihood) 是样本固定、参数变化。

形式上可能长得一样，但思想方向完全不同。

3. 对数似然 (log-likelihood)

实际计算时，通常最大化

$$\ell(\theta) = \ln L(\theta)$$

而不是直接最大化 $L(\theta)$ 。

因为：

- 乘积变求和；
- 求导更方便；
- 与参数无关的常数项可以删掉。

这构成了 MLE 计算的标准套路：

1. 写似然；
 2. 取对数；
 3. 求导；
 4. 解似然方程；
 5. 检查是否极大。
-

4. 典型 MLE 结果

Bernoulli 分布

$$\hat{p} = \bar{X}。$$

正态分布

$$\hat{\mu} = \bar{X}, \hat{\sigma}^2 = \frac{1}{n} \sum (X_i - \bar{X})^2。$$

注意这里方差的 MLE 分母是 n ，不是 $n - 1$ 。

这再次说明：

MLE 不一定无偏。

均匀分布 $U(0, \theta)$

$$\hat{\theta} = X_{(n)}.$$

这个例子特别重要，因为它说明求 MLE 不一定靠求导。
当参数出现在支持集（support）中时，最大值往往出现在边界。

5. MLE 的不变性 (invariance property)

若 $\hat{\theta}$ 是 θ 的 MLE，那么对任意函数 $g(\theta)$ ， $g(\hat{\theta})$ 是 $g(\theta)$ 的 MLE。

这是 MLE 极其强大的一个性质。

它意味着：

你只要先把基本参数估出来，再把函数代进去，就能得到函数参数的 MLE。

要特别和前面的无偏性作对比：

- 无偏性一般**不具有**不变性；
- MLE **具有**不变性。

这两个结论很容易一起考。

6. EM 算法 (EM algorithm)

当似然函数太复杂，尤其模型中存在：

- 潜变量 (latent variables)
- 缺失数据 (missing data)
- 混合结构 (mixture structure)

时，MLE 往往不好直接求。此时可用 EM 算法。

EM 的两步是：

E 步 (Expectation step)

在当前参数值下，求“完全数据对数似然”的条件期望。

M 步 (Maximization step)

极大化这个条件期望，更新参数。

所以 EM 不是一种新的估计准则，它只是：

求 MLE 的一种迭代算法。

这一点必须和贝叶斯方法区分开。

7. 渐近正态性 (asymptotic normality)

这一节最后讲的是：MLE 不仅好算，而且大样本下还有很强的理论性质。

一般在正则条件下，

$$\hat{\theta}_n \sim AN\left(\theta, \frac{1}{nI(\theta)}\right),$$

其中 $I(\theta)$ 是费希尔信息量 (Fisher information)。

这意味着：

- MLE 通常是相合的；
- 且误差量级是 $1/\sqrt{n}$ ；
- 大样本下近似正态。

这个结论极其重要，因为后面很多区间估计和检验，实际上都依赖这种渐近正态性。

五、6.4 最小方差无偏估计：在无偏估计中，谁最好

这一节进入估计量的“优选问题”。

1. 均方误差 (mean squared error, MSE)

定义：

$$MSE(\hat{\theta}) = E(\hat{\theta} - \theta)^2。$$

它可以分解为

$$MSE(\hat{\theta}) = Var(\hat{\theta}) + [E(\hat{\theta}) - \theta]^2。$$

这就是非常核心的**偏差-方差分解** (bias-variance decomposition)。

它说明一个估计的误差来源有两个：

- 随机波动大；
- 系统偏差大。

若估计量无偏，则偏差项为 0，于是

$$MSE(\hat{\theta}) = Var(\hat{\theta})。$$

所以在无偏估计类中，比 MSE 就等价于比方差。

2. 有偏估计可能比无偏估计更好

这一点教材专门通过 $U(0, \theta)$ 的最大值估计例子说明了。

结论是：

在 MSE 标准下，有时有偏估计可能优于无偏估计。

这就是以后会反复出现的**偏差—方差权衡**（bias-variance tradeoff）。

所以你一定要记住：

- “无偏”不是绝对最优；
 - 它只是一个特定估计类中的好性质。
-

3. UMVUE：一致最小方差无偏估计

如果 $\hat{\theta}$ 是 θ 的无偏估计，并且在所有无偏估计中，对每个参数值都具有最小方差，则称它为

一致最小方差无偏估计（uniformly minimum variance unbiased estimator, UMVUE）。

这个名字可以拆开理解：

- uniformly：对所有参数值都成立；
- minimum variance：方差最小；
- unbiased estimator：限制在无偏估计类中比较。

所以 UMVUE 是：

无偏估计类里的“最优者”。

4. UMVUE 的判别：协方差正交条件

教材给出一个重要结论：

一个无偏估计是 UMVUE，当且仅当它与任意零均值扰动 $\varphi(X)$ 都满足

$$\text{Cov}(\hat{\theta}, \varphi) = 0。$$

直观上，这表示：

你已经不能再沿任何“保持无偏”的方向把方差调得更小了。

这是一个非常漂亮的最优性条件。

5. 充分性原则 (principle of sufficiency) 与 Rao–Blackwell 改进

若 T 是参数的**充分统计量** (sufficient statistic)，而 $\hat{\theta}$ 是任一无偏估计，则

$$\tilde{\theta} = E(\hat{\theta} | T)$$

仍然无偏，且

$$\text{Var}(\tilde{\theta}) \leq \text{Var}(\hat{\theta})。$$

这就是 Rao–Blackwell 思想。

它告诉你：

| 估计问题只需要在充分统计量的函数里找就够了。

因为充分统计量已经压缩了样本中关于参数的全部信息；而把原估计对充分统计量条件化，相当于把与参数无关的随机噪声平均掉，从而降低方差。

这是构造 UMVUE 最重要的工具之一。

6. Cramér–Rao 不等式 (Cramér–Rao inequality)

若 T 是 $g(\theta)$ 的无偏估计，则在正则条件下有

$$\text{Var}(T) \geq \frac{[g'(\theta)]^2}{nI(\theta)}。$$

特别地，若 $g(\theta) = \theta$ ，则

$$\text{Var}(\hat{\theta}) \geq \frac{1}{nI(\theta)}。$$

这个下界叫 **Cramér–Rao 下界** (Cramér–Rao lower bound, CRLB)。

它的含义是：

| 任何无偏估计的方差，都不能低于模型本身决定的一个极限。

所以它给出了无偏估计精度的理论极限。

7. 有效估计 (efficient estimator)

若某无偏估计恰好达到 C-R 下界，则称其为**有效估计**（efficient estimator）。

逻辑关系是：

- 有效估计 $\Rightarrow$ UMVUE
- UMVUE $\nRightarrow$ 有效估计

也就是说：

达到 C-R 下界一定是最优无偏估计；
但最优无偏估计不一定能达到那个下界。

这点你一定要和 UMVUE 区分开。

六、6.5 贝叶斯估计：把先验信息和样本信息合起来

这一节的世界观和前面很不同。

1. 频率学派 vs 贝叶斯学派

前面一直默认：

- 参数是固定但未知的常数；
- 样本是随机的。

而贝叶斯学派则认为：

未知参数也可以视为随机变量，用概率分布来描述其不确定性。

这个分布就叫**先验分布**（prior distribution）。

2. 三类信息

贝叶斯统计强调统计推断应综合三类信息：

- 总体信息（模型信息）
- 样本信息
- 先验信息（prior information）

所以它和经典方法最大的区别就在于：

是否显式利用先验信息。

3. 联合分布与后验分布

若先验分布为 $\pi(\theta)$ ，样本条件分布为 $p(X | \theta)$ ，则参数和样本的联合分布为

$$h(X, \theta) = p(X | \theta)\pi(\theta)。$$

后验分布 (posterior distribution) 为

$$\pi(\theta | X) = \frac{p(X|\theta)\pi(\theta)}{\int p(X|\theta)\pi(\theta)d\theta}。$$

最重要的口头表达一定要记住：

后验分布 $\propto$ 似然函数 $\times$ 先验分布。

这就是贝叶斯统计的核心公式。

4. 贝叶斯估计 (Bayesian estimation)

有了后验分布后，可以按不同规则给点估计：

- 后验众数：MAP (maximum a posteriori)
- 后验中位数
- 后验均值

其中最常用的是**后验均值** (posterior mean)，通常也被简称为贝叶斯估计。

原因是：在平方损失 (squared loss) 下，后验均值能使后验风险最小。

5. 典型例子：Beta-Binomial

若 $X | \theta \sim b(n, \theta)$ ，先验取 $\theta \sim Be(a, b)$ ，则后验分布为

$$\theta | x \sim Be(x + a, n - x + b)。$$

所以后验均值即贝叶斯估计为

$$\hat{\theta}_B = \frac{x+a}{n+a+b}。$$

特别地，均匀先验 $U(0, 1)$ 就是 $Be(1, 1)$ ，此时

$$\hat{\theta}_B = \frac{x+1}{n+2}。$$

这和 MLE $\frac{x}{n}$ 的差异很值得注意：

- MLE 只看样本；
- 贝叶斯估计还会自动做平滑 (smoothing) 或收缩 (shrinkage)。

6. 共轭先验 (conjugate prior)

若先验与后验属于同一分布族，则称该先验为**共轭先验** (conjugate prior)。

典型例子：

- Binomial 参数的共轭先验是 Beta
- 已知方差时正态均值的共轭先验是 Normal

共轭先验的价值在于：

- 计算方便；
- 后验形式整齐；
- 更新规则清楚。

这在实际建模中非常重要。

七、6.6 区间估计：从“给一个数”到“给一个范围”

1. 为什么点估计不够

点估计只告诉你“估多少”，但不告诉你“这个估计有多不确定”。

所以区间估计要解决的是：

在一定置信水平下，给出参数可能落入的范围。

2. 置信区间 (confidence interval) 的频率解释

设区间端点是统计量 $\hat{\theta}_L, \hat{\theta}_U$ 。

若对任意 θ 都有

$$P_{\theta}(\hat{\theta}_L \leq \theta \leq \hat{\theta}_U) \geq 1 - \alpha,$$

则称 $[\hat{\theta}_L, \hat{\theta}_U]$ 为 θ 的置信水平 $1 - \alpha$ 的置信区间。

最重要的理解是：

不是说“参数落在这个已算出的区间里的概率是 $1 - \alpha$ ”；
而是说“如果重复抽样 many times，用同样方法构造区间，那么约有 $1 - \alpha$ 的区间会覆盖真值”。

这是频率学派对置信区间的根本解释。

3. 枢轴量法 (pivotal quantity method)

构造区间最核心的方法是枢轴量法。

若能找到一个函数

$$G = G(X_1, \dots, X_n, \theta)$$

其分布不依赖于未知参数 θ ，那么它就是枢轴量 (pivotal quantity)。

然后：

1. 利用其分布找常数 c, d ，使得 $P(c \leq G \leq d) = 1 - \alpha$ ；
2. 再把不等式反解为关于 θ 的区间。

这就是绝大多数经典区间估计公式的来源。

4. 单总体正态参数的置信区间

这是最常用的部分。

均值 μ ， σ 已知

用标准正态枢轴量

$$\frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim N(0, 1),$$

区间为

$$\bar{X} \pm u_{1-\alpha/2} \frac{\sigma}{\sqrt{n}}.$$

均值 μ ， σ 未知

用 t 枢轴量

$$\frac{\sqrt{n}(\bar{X} - \mu)}{S} \sim t(n-1),$$

区间为

$$\bar{X} \pm t_{1-\alpha/2}(n-1) \frac{s}{\sqrt{n}}.$$

方差 σ^2

用

$$\frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1),$$

区间为

$$\left[\frac{(n-1)s^2}{\chi^2_{1-\alpha/2}(n-1)}, \frac{(n-1)s^2}{\chi^2_{\alpha/2}(n-1)} \right]。$$

这里一定要记住：

- 均值区间通常对称；
 - 方差区间由于来自 χ^2 分布，通常不对称。
-

5. 大样本近似区间

当找不到精确枢轴量时，可利用渐近正态性构造近似区间。

最典型的是比例 p 的区间：

$$\bar{X} \pm u_{1-\alpha/2} \sqrt{\frac{\bar{X}(1-\bar{X})}{n}}。$$

它是近似区间，因为：

- 用了中心极限定理；
- 还把未知 p 用 $\bar{X}$ 替代了。

所以使用时要注意样本量是否足够大。

6. 样本量设计 (sample size determination)

若希望比例估计区间半径不超过 d_0 ，则最保守设计下有

$$n \geq \left(\frac{u_{1-\alpha/2}}{2d_0} \right)^2。$$

这里的关键思想是：

- 置信水平越高，所需样本量越大；
- 区间越窄，所需样本量越大。

所以“更稳、更准”永远要付出更多样本成本。

7. 两个正态总体下的区间估计

这一部分要点在于分情形。

均值差 $\mu_1 - \mu_2$

要区分：

- 两方差已知
- 两方差未知但可视为相等
- 两方差未知且不一定相等
- 大样本近似
- Behrens–Fisher / Welch 型近似

方差比 σ_1^2 / σ_2^2

利用

$$\frac{S_1^2 / \sigma_1^2}{S_2^2 / \sigma_2^2} \sim F(m-1, n-1)$$

构造 F 分布区间。

所以做两总体区间问题时，最重要的不是套公式，而是先判断：

方差信息已知到什么程度？
是否可假设相等？
样本量是否足够大？

八、第六章的整体知识网络：你必须把这些关系真正串起来

现在把整章压缩成一张逻辑图。

第一层：先定义估计问题

从样本构造统计量去估未知参数。

第二层：先讲点估计的基本品质

- 无偏性 (unbiasedness)
- 渐近无偏
- 有效性 (efficiency)
- 相合性 (consistency)

第三层：学习如何构造估计

- 矩估计 (method of moments)
- 最大似然估计 (MLE)
- EM 算法 (求复杂 MLE)
- 贝叶斯估计 (Bayesian estimation)

第四层：在众多估计量中比较优劣

- MSE
- UMVUE
- 充分性原则
- C-R 下界
- 有效估计

第五层：从点估计推进到区间估计

- 置信区间
- 枢轴量
- 正态总体经典区间
- 大样本区间
- 两总体区间

所以你可以把整章概括成一句话：

第六章研究的是：如何构造参数估计量、如何评价其好坏、以及如何把一个点估计提升为带不确定性说明的区间估计。

九、第六章最容易混淆的概念，我给你集中澄清

1. 估计量 vs 估计值

- 估计量：随机变量
- 估计值：样本给定后的具体数

2. 无偏 vs 相合

- 无偏： $E(\hat{\theta}) = \theta$
- 相合： $\hat{\theta}_n \xrightarrow{P} \theta$

无偏不一定相合，相合也不一定无偏。

3. 无偏 vs 有效

- 无偏：平均位置对
- 有效：在无偏类中方差更小

4. MLE vs 无偏估计

- MLE 追求“让样本最像出现”
- 无偏估计追求“平均恰好等于真值”

二者有时一致，有时不一致。

5. UMVUE vs 有效估计

- UMVUE：无偏类中方差最小
- 有效估计：达到 C-R 下界

有效估计一定是 UMVUE，但 UMVUE 不一定有效。

6. MLE 的不变性 vs 无偏性的不变性

- MLE 有不变性
- 无偏性一般没有

这组对比非常重要。

7. 贝叶斯后验 vs 似然函数

- 似然函数：只来自样本
- 后验分布：似然 $\times$ 先验，再归一化

十、第六章做题时的“方法判断图”

你以后遇到题目，可以这样判断。

1. 题目让你“构造一个估计”

先想：

- 能否直接用样本均值、方差、频率？
- 是否适合矩估计？
- 是否适合 MLE？

2. 题目问“这个估计是否无偏”

就算 $E(\hat{\theta})$ ，看是否等于真值。

3. 题目问“是否相合”

优先想两条路：

- 看均值趋于真值、方差趋于 0
- 或直接用大数定律和连续函数保持性

4. 题目问“哪个估计更好”

先问评价标准：

- 若是 MSE，就用 $MSE = Var + Bias^2$
- 若限定无偏，就比方差
- 若问是否达到理论极限，就看 C-R 下界

5. 题目问“求 UMVUE”

常规思路是：

1. 找一个无偏估计
2. 找充分统计量
3. 做条件期望改进
4. 若还能结合完全性，则更强

6. 题目问“求置信区间”

先判断：

- 单总体还是双总体
- 正态还是大样本近似
- 方差已知还是未知
- 用正态、 t 、 χ^2 还是 F

十一、如果把第六章压缩成最核心的十句话

第一句：

点估计是用样本构造统计量去估未知参数。

第二句：

无偏性表示估计量平均上不偏，关注的是“中心是否对”。

第三句：

相合性表示样本量增大时估计量会逼近真值，这是更根本的大样本要求。

第四句：

矩估计用样本矩替换总体矩，优点是简单，通常相合。

第五句：

最大似然估计通过最大化似然函数，寻找最能解释当前样本的参数值。

第六句：

MLE 有不变性，但不一定无偏。

第七句：

MSE 同时衡量偏差和波动，公式是 $MSE = Var + Bias^2$ 。

第八句：

UMVUE 是无偏估计类中方差一致最小的估计。

第九句：

贝叶斯估计把参数看作随机变量，用后验分布综合样本信息和先验信息。

第十句：

区间估计不是给参数一个“概率区间”，而是给出一种有固定覆盖率的随机区间构造方法。

附录

下面给你一份第六章“做题判别清单”。目标不是再按课本顺序讲一遍，而是让你看到题目先判断该走哪条路：

- 用矩估计 (method of moments, MoM)
- 用最大似然估计 (maximum likelihood estimation, MLE)
- 用UMVUE / Rao-Blackwell / C-R 下界
- 用贝叶斯估计 (Bayesian estimation)
- 还是直接做置信区间 (confidence interval)

我会按“先判断题型，再套公式”的方式整理。

一、先做总判断：这题到底在问什么

拿到题目，先不要急着算，先问自己这 5 个问题。

1. 它要你给一个点估计，还是一个区间？

- 只要一个数，比如“求 θ 的估计”
→ 点估计问题，优先在 6.1 到 6.5 里找方法。
 - 要一个范围，比如“求 μ 的 95 置信区间” → 区间估计问题，走 6.6。
-

2. 题目有没有明确指定方法？

常见关键词：

- “求矩估计”
→ 直接用矩估计。
 - “求最大似然估计”
→ 直接写似然函数。
 - “求贝叶斯估计”
→ 必须写先验、后验。
 - “求最小方差无偏估计”或“求 UMVUE”
→ 不能只写一个无偏估计，要继续做优化。
 - “求无偏估计”
→ 重点看 $E(\hat{\theta}) = \theta$ 。
 - “比较两个估计哪个更好”
→ 先看比较标准：无偏？方差？MSE？相合？C-R 下界？
-

3. 题目有没有给出分布模型？

- 给了具体分布，如 $b(1, p)$ 、 $P(\lambda)$ 、 $Exp(1/\theta)$ 、 $N(\mu, \sigma^2)$ 、 $U(0, \theta)$
→ 可以做参数化估计，MoM、MLE、UMVUE、Bayes 都有可能。
 - 只给样本，没有明确分布
→ 一般不能做精确 MLE 或 UMVUE 推导；若要区间，通常只能做大样本近似，或题目本身不在第六章常规范围内。
-

4. 题目有没有给先验信息？

典型表述：

- “已知先验分布为 $\pi(\theta)$ ”
- “根据历史经验， θ 服从某分布”
- “取共轭先验”

只要出现这些

→ 优先想到贝叶斯估计。

5. 题目是在问“怎么构造”，还是在问“哪个最优”？

- 问“构造一个估计”
→ MoM 或 MLE 最常见。
 - 问“无偏且方差最小”
→ UMVUE / Rao–Blackwell / C-R。
 - 问“考虑小样本误差哪个更小”
→ MSE。
 - 问“大样本是否收敛到真值”
→ 相合性 (consistency)。
 - 问“样本很多时分布近似什么”
→ 渐近正态性 (asymptotic normality)。
-

二、点估计题：先按这个分流

A. 题目明确说“求矩估计” → 用矩估计 (MoM)

什么时候用

- 题目直接要求“矩估计”
- 或者题目只让你“构造一个估计”，而 MLE 不好做、矩关系很好写

标准步骤

第一步

数未知参数个数。

- 1 个未知参数 → 写 1 个矩方程
- 2 个未知参数 → 写 2 个矩方程
- k 个未知参数 → 写 k 个矩方程

第二步

写总体矩和参数的关系。

最常用是：

- $E(X)$
- $E(X^2)$
- $Var(X)$

第三步

把总体矩换成样本矩：

- $E(X)$ 用 $\bar{X} = \frac{1}{n} \sum X_i$
- $E(X^2)$ 用 $a_2 = \frac{1}{n} \sum X_i^2$
- $Var(X)$ 常用 $s_n^2 = \frac{1}{n} \sum (X_i - \bar{X})^2$

第四步

解方程得到估计量。

常用模板

1. 单参数

若 $E(X) = m(\theta)$ ，则令 $m(\theta) = \bar{X}$ ，解出 $\hat{\theta}$ 。

2. 双参数

若 $E(X) = m_1(\theta_1, \theta_2)$ ， $Var(X) = m_2(\theta_1, \theta_2)$ ，则令 $m_1(\theta_1, \theta_2) = \bar{X}$ ， $m_2(\theta_1, \theta_2) = s^2$ ，解出 $\hat{\theta}_1, \hat{\theta}_2$ 。

典型结果

- Bernoulli $b(1, p)$ ： $\hat{p}_{MoM} = \bar{X}$
- Poisson $P(\lambda)$ ： $\hat{\lambda}_{MoM} = \bar{X}$
- 指数分布 $Exp(1/\lambda)$ 若参数是率 λ ： $\hat{\lambda}_{MoM} = 1/\bar{X}$
- 均匀分布 $U(a, b)$ ：由 $\bar{X} = \frac{a+b}{2}$ 和 $s^2 \approx \frac{(b-a)^2}{12}$ 解 a, b

看到题目时的信号词

- “用样本矩替换总体矩”
- “由前两阶矩构造估计”
- “用替换原理”
- “不用似然，直接构造”

B. 题目明确说“求最大似然估计” → 用 MLE

什么时候用

- 题目明确要求 MLE
- 给了完整分布模型，且样本独立同分布
- 想找“最能解释当前样本”的参数

标准步骤

第一步：写似然函数

若样本独立同分布，

$$L(\theta) = \prod_{i=1}^n p(x_i; \theta)。$$

第二步：取对数

$$\ell(\theta) = \ln L(\theta)。$$

第三步：求导

解似然方程：

$$\frac{d}{d\theta} \ell(\theta) = 0$$

或多参数时解偏导方程组：

$$\frac{\partial \ell}{\partial \theta_j} = 0。$$

第四步：判定极大值

- 看二阶导数是否小于 0
- 或看单调性与边界

什么时候不能机械求导

如果参数出现在**支持集**（support）里，比如 $U(0, \theta)$ ，往往最大值在边界，不要直接套“导数等于 0”。

典型结果

1. Bernoulli $b(1, p)$

$$L(p) = p^{\sum x_i} (1-p)^{n-\sum x_i}$$

解得 $\hat{p} = \bar{X}$ 。

2. Poisson $P(\lambda)$

$$L(\lambda) = \prod \frac{e^{-\lambda} \lambda^{x_i}}{x_i!}$$

解得 $\hat{\lambda} = \bar{X}$ 。

3. 正态 $N(\mu, \sigma^2)$

- $\hat{\mu} = \bar{X}$
- $\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$

注意这里方差 MLE 分母是 n ，不是 $n-1$ 。

4. 均匀分布 $U(0, \theta)$

$$L(\theta) = \theta^{-n} I_{x_{(n)} < \theta}$$

解得 $\hat{\theta} = X_{(n)}$ 。

MLE 的一个必背性质：不变性 (invariance)

若 $\hat{\theta}$ 是 θ 的 MLE，则 $g(\hat{\theta})$ 是 $g(\theta)$ 的 MLE。

所以：

- 先求 $\hat{\mu}, \hat{\sigma}^2$
- 再写 $\hat{\sigma} = \sqrt{\hat{\sigma}^2}$
- 再写分位数、概率、函数参数的 MLE

不用重新最大化。

看到题目时的信号词

- “likelihood”
- “最可能产生样本”
- “最大似然”
- “估计参数函数 $g(\theta)$ 的 MLE”
→ 先求 $\hat{\theta}$ 再代入

C. 题目出现“缺失数据、潜变量、混合模型” → 想到 EM 算法

什么时候用

- 题目明确提 EM
- 或原似然特别复杂，但能补出“完全数据”
- 有潜变量 (latent variables) 或不完整数据 (incomplete data)

标准框架

E 步 (Expectation)

算

$$Q(\theta | \theta^{(t)}) = E[\ell_c(\theta) | \text{observed data}, \theta^{(t)}]$$

M 步 (Maximization)

令

$$\theta^{(t+1)} = \arg \max_{\theta} Q(\theta | \theta^{(t)})$$

然后迭代到收敛。

一定要记住

EM 不是另一种估计准则，它是求 MLE 的算法。

D. 题目给了先验分布 → 用贝叶斯估计 (Bayesian estimation)

什么时候用

- 明确给了先验 $\pi(\theta)$
- 要求贝叶斯估计、后验分布、MAP
- 明确出现“共轭先验”

标准步骤

第一步：写先验

$$\pi(\theta)$$

第二步：写似然

$$p(X | \theta)$$

第三步：写后验

$$\pi(\theta | X) \propto p(X | \theta)\pi(\theta)$$

第四步：根据题目要什么输出

- 贝叶斯估计：常取后验均值 $E(\theta | X)$
- MAP：取后验众数
- 后验区间：取后验分位点

典型结果

1. Binomial + Beta

若 $\theta \sim Be(a, b)$, $X | \theta \sim b(n, \theta)$, 则
 $\theta | x \sim Be(x + a, n - x + b)$ 。

于是：

- 后验均值： $\hat{\theta}_B = \frac{x+a}{n+a+b}$
- MAP： $\frac{x+a-1}{n+a+b-2}$ (参数条件合适时)

2. Uniform 先验 $Be(1, 1)$

$$\hat{\theta}_B = \frac{x+1}{n+2}$$

3. 正态均值 (方差已知) + 正态先验

后验仍是正态，后验均值是样本均值与先验均值的加权平均。

看到题目时的信号词

- “先验分布”
 - “后验分布”
 - “MAP”
 - “共轭先验”
 - “历史资料”
-

E. 题目要求“无偏估计” → 先做无偏性检验

标准动作

构造候选估计量后，直接算 $E(\hat{\theta})$ ，看是否等于 θ 。

常用结论

- $\bar{X}$ 常常是总体均值的无偏估计
- $s^2 = \frac{1}{n-1} \sum (X_i - \bar{X})^2$ 是 σ^2 的无偏估计
- $s_n^2 = \frac{1}{n} \sum (X_i - \bar{X})^2$ 一般不是无偏，但渐近无偏
- 对非线性函数，不能想当然认为“代进去仍无偏”

高频提醒

无偏性不具有不变性：

若 $\hat{\theta}$ 无偏，一般 $g(\hat{\theta})$ 对 $g(\theta)$ 不无偏。

F. 题目要求“最小方差无偏估计 / UMVUE” → 走 UMVUE 路线

这是第六章最容易乱的一类题，我给你整理成固定流程。

UMVUE 标准流程

第一步：先找一个无偏估计

这是“毛坯”。

第二步：找充分统计量（sufficient statistic）

通常用分解定理（factorization theorem）或由分布结构直接看出。

第三步：做 Rao–Blackwell 改进

令

$$\tilde{\theta} = E(\hat{\theta} | T),$$

则它仍无偏，且方差不增。

第四步：若题目还能结合完全性（completeness），则常可直接断定是 UMVUE

你当前提纲里重点是充分性原则，完全性可作进一步加强理解。

常见结论

- Bernoulli 中， $T = \sum X_i$ 常是充分统计量
- 指数分布中， $T = \sum X_i$ 常是充分统计量
- 对 p^2 这类参数，可先构造粗糙无偏估计，再对 T 条件化

什么时候能用 C-R 下界辅助

若你已经有一个无偏估计，并且它的方差恰好达到 C-R 下界，则可直接判定：

- 它是有效估计（efficient estimator）
- 因而也是 UMVUE

G. 题目问“哪个估计更好” → 先问比较标准

这一点极其重要。题目不说标准，就不能乱比。

1. 若比较标准是无偏

算 $E(\hat{\theta})$ 。

2. 若在无偏估计中比较优劣

比方差 $Var(\hat{\theta})$ 。

3. 若比较一般估计优劣

比均方误差（MSE）：

$$MSE(\hat{\theta}) = Var(\hat{\theta}) + [E(\hat{\theta}) - \theta]^2$$

4. 若问“大样本下谁更好”

看相合性、渐近方差、渐近正态性。

5. 若问“是否达到理论最优”

看是否达到 C-R 下界。

三、核心评价公式清单：做题随时调用

下面这些是第六章最核心的“评价型公式”。

1. 无偏性

$$E(\hat{\theta}) = \theta$$

2. 偏差 (bias)

$$Bias(\hat{\theta}) = E(\hat{\theta}) - \theta$$

3. 均方误差 (MSE)

$$MSE(\hat{\theta}) = E(\hat{\theta} - \theta)^2 = Var(\hat{\theta}) + [Bias(\hat{\theta})]^2$$

4. 相合性

$$\hat{\theta}_n \xrightarrow{P} \theta$$

常用充分条件：

- $E(\hat{\theta}_n) \rightarrow \theta$
- $Var(\hat{\theta}_n) \rightarrow 0$

5. 渐近正态性

若

$$\frac{\hat{\theta}_n - \theta}{\sigma_n(\theta)} \xrightarrow{d} N(0, 1),$$

则称 $\hat{\theta}_n$ 渐近正态。

6. MLE 的渐近正态性

在正则条件下，

$$\hat{\theta}_n \sim AN\left(\theta, \frac{1}{nI(\theta)}\right)$$

7. C-R 下界

若 T 是 $g(\theta)$ 的无偏估计，则

$$Var(T) \geq \frac{[g'(\theta)]^2}{nI(\theta)}$$

特别地，估计 θ 本身时，

$$Var(\hat{\theta}) \geq \frac{1}{nI(\theta)}$$

四、核心模型公式清单：最常用的分布别混

这是做题时最常用的一组。

1. Bernoulli / Binomial

模型

$$X_i \sim b(1, p), \text{ 或 } X \sim b(n, p)$$

点估计

- 矩估计: $\hat{p} = \bar{X}$
- MLE: $\hat{p} = \bar{X} = \frac{x}{n}$

贝叶斯

若先验 $\theta \sim Be(a, b)$, 则后验
 $\theta | x \sim Be(x + a, n - x + b)$

后验均值

$$\hat{p}_B = \frac{x+a}{n+a+b}$$

Uniform 先验时:

$$\hat{p}_B = \frac{x+1}{n+2}$$

大样本区间

p 的近似区间:

$$\bar{X} \pm u_{1-\alpha/2} \sqrt{\frac{\bar{X}(1-\bar{X})}{n}}$$

样本量设计

$$n \geq \left(\frac{u_{1-\alpha/2}}{2d_0} \right)^2$$

2. Poisson

模型

$$X_i \sim P(\lambda)$$

点估计

- 矩估计: $\hat{\lambda} = \bar{X}$

- MLE: $\hat{\lambda} = \bar{X}$

渐近正态

$$\hat{\lambda} \sim AN(\lambda, \lambda/n)$$

Fisher 信息

$$I(\lambda) = 1/\lambda$$

C-R 下界

$$Var(\hat{\lambda}) \geq \lambda/n$$

3. 指数分布

注意课本里常有两种参数化方式。

若写成 $Exp(1/\theta)$ ，则

- 均值 $E(X) = \theta$
- 方差 $Var(X) = \theta^2$

点估计

- 矩估计: $\hat{\theta} = \bar{X}$
- MLE: $\hat{\theta} = \bar{X}$

UMVUE

$\bar{X}$ 常常就是 θ 的 UMVUE

Fisher 信息

$$I(\theta) = 1/\theta^2$$

C-R 下界

$$Var(\hat{\theta}) \geq \theta^2/n$$

若写成率参数 λ 形式，即 $f(x) = \lambda e^{-\lambda x}$

- $E(X) = 1/\lambda$

点估计

- 矩估计: $\hat{\lambda} = 1/\bar{X}$
 - MLE: $\hat{\lambda} = 1/\bar{X}$
-

4. 正态分布 $N(\mu, \sigma^2)$

点估计

均值

- 无偏估计: $\bar{X}$
- MLE: $\hat{\mu} = \bar{X}$

方差

- 无偏估计: $s^2 = \frac{1}{n-1} \sum (X_i - \bar{X})^2$
- MLE: $\hat{\sigma}^2 = \frac{1}{n} \sum (X_i - \bar{X})^2$

已知均值为 μ_0 时

- $\hat{\sigma}^2 = \frac{1}{n} \sum (X_i - \mu_0)^2$ 是 σ^2 的无偏估计
- 特别地, 若 $\mu_0 = 0$, 则 $\hat{\sigma}^2 = \frac{1}{n} \sum X_i^2$

区间估计

μ, σ 已知

$$\bar{X} \pm u_{1-\alpha/2} \frac{\sigma}{\sqrt{n}}$$

μ, σ 未知

$$\bar{X} \pm t_{1-\alpha/2}(n-1) \frac{s}{\sqrt{n}}$$

$$\sigma^2$$

$$\left[\frac{(n-1)s^2}{\chi_{1-\alpha/2}^2(n-1)}, \frac{(n-1)s^2}{\chi_{\alpha/2}^2(n-1)} \right]$$

贝叶斯 (已知方差)

若先验 $\mu \sim N(\theta, \tau^2)$, 则后验仍为正态, 后验均值是样本均值与先验均值的加权平均。

5. 均匀分布 $U(0, \theta)$

MLE

$$\hat{\theta}_{MLE} = X_{(n)}$$

无偏估计

$$\hat{\theta} = \frac{n+1}{n} X_{(n)}$$

MSE 更优的有偏估计

$$\hat{\theta} = \frac{n+2}{n+1} X_{(n)}$$

区间估计

基于枢轴量 $\frac{X_{(n)}}{\theta}$

常见最短型区间：

$$\left[X_{(n)}, \frac{X_{(n)}}{\alpha^{1/n}} \right]$$

这个分布特别适合拿来考你：

- MLE 在边界
- 无偏估计修正
- MSE 与无偏的区别
- 枢轴量法做区间

五、区间估计做题判别清单：看到区间问题就按这个走

A. 单总体均值 μ 的区间

1. 已知正态，且 σ 已知

用标准正态：

$$\bar{X} \pm u_{1-\alpha/2} \frac{\sigma}{\sqrt{n}}$$

2. 已知正态，且 σ 未知

用 t ：

$$\bar{X} \pm t_{1-\alpha/2}(n-1) \frac{s}{\sqrt{n}}$$

3. 只知道样本大

用大样本近似正态。

B. 单总体方差 σ^2 的区间

若总体正态，用 χ^2 ：

$$\left[\frac{(n-1)s^2}{\chi^2_{1-\alpha/2}(n-1)}, \frac{(n-1)s^2}{\chi^2_{\alpha/2}(n-1)} \right]$$

C. 比例 p 的区间

样本量足够大时：

$$\bar{X} \pm u_{1-\alpha/2} \sqrt{\frac{\bar{X}(1-\bar{X})}{n}}$$

注意这是近似区间，不是精确区间。

D. 两总体均值差 $\mu_1 - \mu_2$

先问四件事：

1. 两总体正态吗？

若是，继续。

2. 两方差已知吗？

若已知，用正态。

3. 两方差未知但可认为相等吗？

若相等，用 pooled t 。

4. 两方差未知且不一定相等吗？

- 样本大：大样本近似
 - 样本不大：Welch / Behrens–Fisher 近似
-

E. 两总体方差比 σ_1^2 / σ_2^2

若两总体正态，用 F ：

$$\left[\frac{s_1^2/s_2^2}{F_{1-\alpha/2}(m-1, n-1)}, \frac{s_1^2/s_2^2}{F_{\alpha/2}(m-1, n-1)} \right]$$

六、最实用的“看到题目怎么选方法”总结版

下面给你一版最像考场速用的。

1. 题目说“求估计量”，但没指定方法

优先顺序建议

- 矩关系很好写 → 先考虑矩估计
 - 给了完整分布、似然好写 → MLE 往往更标准
 - 有先验 → 贝叶斯
 - 题目强调无偏 → 先构造无偏估计
 - 题目强调最优无偏 → UMVUE 路线
-

2. 题目说“求最优估计”但没说标准

先找题目有没有这些词：

- “无偏” → 在无偏类中比方差
- “均方误差” → 比 MSE
- “一致最小方差无偏” → UMVUE
- “达到下界” → C-R
- “贝叶斯” → 后验均值或 MAP

没有标准，不能直接说谁更好。

3. 题目让你“比较 $\hat{\theta}_1, \hat{\theta}_2$ ”

按这个顺序：

第一步，算偏差：

$$Bias(\hat{\theta}) = E(\hat{\theta}) - \theta$$

第二步，算方差：

$$Var(\hat{\theta})$$

第三步，算 MSE：

$$MSE = Var + Bias^2$$

第四步，看题目到底比哪一个。

4. 题目让你“证明相合”

优先走两条路之一：

路线一

证明

$$E(\hat{\theta}_n) \rightarrow \theta \text{ 且 } Var(\hat{\theta}_n) \rightarrow 0$$

路线二

先证明基本样本量如 $\bar{X}, a_k$ 相合，再用连续函数保持性推出目标参数相合。

5. 题目让你“求 UMVUE”

优先流程：

1. 先找无偏估计
 2. 找充分统计量
 3. 做 $E(\hat{\theta} | T)$
 4. 若还能证明达到 C-R 下界，则直接说明它有效，因此是 UMVUE
-

6. 题目给“先验 + 样本”，问参数估计

固定流程：

1. 写先验 $\pi(\theta)$
 2. 写似然 $p(X | \theta)$
 3. 写后验 $\pi(\theta | X) \propto p(X | \theta)\pi(\theta)$
 4. 求后验均值 / 后验众数 / 后验分布
-

7. 题目问“求置信区间”

先判断：

- 单总体 / 双总体
- 正态 / 大样本
- 方差已知 / 未知
- 参数是均值 / 方差 / 比例 / 方差比

然后再选：

- $N(0, 1)$
 - t
 - χ^2
 - F
-

七、最后给你一版“考前最后一分钟速记版”

点估计怎么选

- 指定矩估计 $\rightarrow$ 写矩方程
- 指定 MLE $\rightarrow$ 写似然
- 给先验 $\rightarrow$ 贝叶斯
- 强调无偏 $\rightarrow$ 算期望
- 强调最优无偏 $\rightarrow$ UMVUE
- 缺失 / 潜变量 $\rightarrow$ EM

比较估计怎么比

- 无偏：看 $E(\hat{\theta})$
- 有效：在无偏类中比 Var
- 一般优劣：比 MSE
- 大样本：看相合与渐近方差

区间怎么选

- μ, σ 已知 $\rightarrow$ 正态
- μ, σ 未知 $\rightarrow t$
- $\sigma^2 \rightarrow \chi^2$
- $\sigma_1^2 / \sigma_2^2 \rightarrow F$
- 比例 p , 大样本 $\rightarrow$ 正态近似

绝对高频公式

- $MSE = Var + Bias^2$
 - $s^2 = \frac{1}{n-1} \sum (X_i - \bar{X})^2$
 - $\hat{\sigma}_{MLE}^2 = \frac{1}{n} \sum (X_i - \bar{X})^2$
 - $\pi(\theta | X) \propto p(X | \theta) \pi(\theta)$
 - $Var(T) \geq \frac{[g'(\theta)]^2}{nI(\theta)}$
-