



第九讲 估计的Rao-Cramer下界与有效性

袁洪松

内容概要:

估计的Rao-Cramer下界与有效性

预习内容:

Hogg Sections 6.1, 6.2

1 极大似然估计回顾

极大似然估计回顾: 假设总体有密度函数 (连续型) 或者概率质量函数 (离散型) $f(x; \theta), \theta \in \Omega$, 样本为 $X_1, \dots, X_n$ 。则似然函数为

$$L(\theta) = \prod_{i=1}^n f(X_i; \theta).$$

对数似然函数为

$$\ell(\theta) = \sum_{i=1}^n \log f(X_i; \theta).$$

极大似然估计(maximum likelihood estimator, MLE)为

$$\hat{\theta} = \arg \max_{\theta \in \Omega} L(\theta) = \arg \max_{\theta \in \Omega} \ell(\theta).$$

例 (拉普拉斯分布, Laplace distribution) 若 $X_1, \dots, X_n$ 为取自以下密度函数的样本:

$$f(x; \theta) = \frac{1}{2} e^{-|x-\theta|}, x \in \mathbb{R}, \theta \in \mathbb{R}.$$

此分布称为拉普拉斯分布或者双指数分布(double exponential distribution)。

首先, 对数似然函数可写为

$$\ell(\theta) = -n \log(2) - \sum_{i=1}^n |X_i - \theta|.$$

对 θ 求导可得

$$\frac{\partial \ell}{\partial \theta}(\theta) = \sum_{i=1}^n \text{sgn}(X_i - \theta),$$

其中

$$\text{sgn}(t) = \begin{cases} -1, & t < 0, \\ 0, & t = 0, \\ 1, & t > 0. \end{cases}$$

可以知道, $\partial \ell(\theta)/\partial \theta = 0$ 的解为 $\hat{\theta} = Q_2$ (样本中位数)。 $\square$

例 (logistic分布) 若 $X_1, \dots, X_n$ 为取自以下密度函数的样本

$$f(x; \theta) = \frac{\exp\{-(x - \theta)\}}{[1 + \exp\{-(x - \theta)\}]^2}, x \in \mathbb{R}, \theta \in \mathbb{R}.$$

此分布称为logistic分布。

对数似然函数可写为

$$\ell(\theta) = n\theta - n\bar{X} - 2 \sum_{i=1}^n \log [1 + \exp\{-(X_i - \theta)\}].$$

对 θ 求导可得

$$\frac{\partial \ell}{\partial \theta}(\theta) = n - 2 \sum_{i=1}^n \frac{\exp\{-(X_i - \theta)\}}{1 + \exp\{-(X_i - \theta)\}}.$$

可以看出 $\partial \ell(\theta)/\partial \theta = 0$ 没有显示解, 只能通过数值方法求解。 $\square$

例 (Bernoulli分布) 假设 $X_1, \dots, X_n$ 取自 Bernoulli(θ) 分布。其 p.m.f 可以写为

$$f(x; \theta) = \theta^x (1 - \theta)^{1-x}, x = 0, 1.$$

对数似然函数为

$$\ell(\theta) = \sum_{i=1}^n X_i \log \theta + \sum_{i=1}^n (1 - X_i) \log(1 - \theta).$$

求导, 并令导数为0, 可得

$$\frac{\partial \ell}{\partial \theta}(\theta) = \frac{1}{\theta} \sum_{i=1}^n X_i - \frac{1}{1 - \theta} \sum_{i=1}^n (1 - X_i) = 0.$$

两边同除以 n 可得:

$$\frac{1}{\theta} \bar{X} = \frac{1}{1 - \theta} (1 - \bar{X}),$$

即解得 $\hat{\theta} = \bar{X}$ 。

若加限制条件 $0 \leq \theta \leq 1/3$ 。当 $\bar{X} \leq 1/3$ 时, MLE 仍为 $\bar{X}$ 。当 $\bar{X} > 1/3$ 时, 由函数单调性知道, 对 $0 \leq \theta \leq 1/3$, $\frac{\partial \ell}{\partial \theta}(\theta) > 0$ 。所以 $\hat{\theta} = 1/3$ 。综合起来, $\hat{\theta} = \min\{\bar{X}, 1/3\}$ 。 $\square$

定理 (Hogg Theorem 6.1.2) 若 $\hat{\theta}$ 为 θ 的 MLE, 且 $\eta = g(\theta)$ 。则 $\hat{\eta} = g(\hat{\theta})$ 为 η 的 MLE。 $\square$

2 Rao-Cramer下界与有效性

回顾衡量估计量的评价准则：

1. 无偏性 (期望)：偏差= $E(\hat{\theta}) - \theta$
2. 有效性 (方差)：方差= $\text{Var}(\hat{\theta})$

定义 (Fisher信息量, Fisher information) Fisher信息量定义为下面数量：

$$I(\theta) = E \left[\left\{ \frac{\partial \log f(X; \theta)}{\partial \theta} \right\}^2 \right].$$

直观意义： $\partial \log f(X; \theta) / \partial \theta$ 表示 $\log f(X; \theta)$ 随 θ 的变化率。它越大，则对于同样的样本，可以获得关于 θ 的更多信息。

性质：如果以下条件(R0)–(R3)成立：

- (R0) 分布函数可区分。即 $\theta \neq \theta'$ 时， $F(X_i; \theta) \neq F(X_i; \theta')$ 。
- (R1) 对所有 θ ，密度函数有共同的支撑。即集合 $\{x : f(x; \theta) \neq 0\}$ 与 θ 无关。
- (R2) p.d.f. $f(x; \theta)$ 为 θ 的二次可微函数。
- (R3) 积分 $\int f(x, \theta) dx$ 在积分号下对 θ 二次可微(即积分和导数可交换顺序)。

那么

1)

$$I(\theta) = \text{Var} \left[\frac{\partial \log f(X; \theta)}{\partial \theta} \right].$$

2)

$$I(\theta) = -E \left[\frac{\partial^2 \log f(X; \theta)}{\partial \theta^2} \right].$$

证明：

1) 首先有

$$\begin{aligned} E \left\{ \frac{\partial \log f(X; \theta)}{\partial \theta} \right\} &= \int \frac{\partial \log f(x; \theta)}{\partial \theta} f(x; \theta) dx \\ &= \int \frac{\partial f(x; \theta) / \partial \theta}{f(x; \theta)} f(x; \theta) dx \\ &= \int \frac{\partial f(x; \theta)}{\partial \theta} dx. \end{aligned}$$

由 $\int f(x; \theta) dx = 1$ (密度函数积分为1), 结合(R4)可得

$$\int \frac{\partial f(x; \theta)}{\partial \theta} dx = \frac{\partial}{\partial \theta} \int f(x, \theta) dx = 0.$$

于是

$$\begin{aligned} \text{Var} \left\{ \frac{\partial \log f(X; \theta)}{\partial \theta} \right\} &= E \left[\left\{ \frac{\partial \log f(X; \theta)}{\partial \theta} \right\}^2 \right] - \left[E \left\{ \frac{\partial \log f(X; \theta)}{\partial \theta} \right\} \right]^2 \\ &= E \left[\left(\frac{\partial \log f(X; \theta)}{\partial \theta} \right)^2 \right] \\ &= I(\theta). \end{aligned}$$

2) 在上面已经得出

$$E \left\{ \frac{\partial \log f(X; \theta)}{\partial \theta} \right\} = \int \frac{\partial \log f(x; \theta)}{\partial \theta} f(x; \theta) dx = 0.$$

对其求导, 可得

$$\int \frac{\partial^2 \log f(x; \theta)}{\partial \theta^2} f(x; \theta) dx + \int \frac{\partial \log f(x; \theta)}{\partial \theta} \frac{\partial f(x; \theta)}{\partial \theta} dx = 0$$

于是

$$\begin{aligned} E \left\{ \frac{\partial^2 \log f(X; \theta)}{\partial \theta^2} \right\} &= \int \frac{\partial^2 \log f(x; \theta)}{\partial \theta^2} f(x; \theta) dx \\ &= - \int \frac{\partial \log f(x; \theta)}{\partial \theta} \cdot \frac{\partial f(x; \theta)}{\partial \theta} dx \\ &= - \int \frac{\partial \log f(x; \theta)}{\partial \theta} \cdot \frac{\partial \log f(x; \theta)}{\partial \theta} f(x; \theta) dx \\ &= -E \left[\left\{ \frac{\partial \log f(X; \theta)}{\partial \theta} \right\}^2 \right] \\ &= -I(\theta). \quad \square \end{aligned}$$

说明: $\partial \log f(x; \theta) / \partial \theta$ 称为得分函数(score function)。

例 (Bernoulli分布) $X \sim \text{Bernoulli}(\theta)$, 其中p.m.f可写为 $f(x; \theta) = \theta^x (1 - \theta)^{1-x}$ 。用三种方法计算Fisher信息量。

首先计算得分函数:

$$\begin{aligned} \log f(x; \theta) &= x \log \theta + (1 - x) \log(1 - \theta), \\ \frac{\partial \log f(x; \theta)}{\partial \theta} &= \frac{x}{\theta} - \frac{1 - x}{1 - \theta}. \end{aligned}$$

方法一：

$$\begin{aligned}
 I(\theta) &= \mathbb{E} \left[\left\{ \frac{\partial \log f(X; \theta)}{\partial \theta} \right\}^2 \right] = \mathbb{E} \left(\frac{X}{\theta} - \frac{1-X}{1-\theta} \right)^2 \\
 &= \mathbb{E} \left\{ \frac{X}{\theta(1-\theta)} - \frac{1}{1-\theta} \right\}^2 \\
 &= \frac{1}{\theta^2(1-\theta)^2} \mathbb{E} X^2 - \frac{2}{\theta(1-\theta)^2} \mathbb{E} X + \frac{1}{(1-\theta)^2} \\
 &= \frac{1}{\theta^2(1-\theta)^2} \theta - \frac{2}{\theta(1-\theta)^2} \theta + \frac{1}{(1-\theta)^2} \\
 &= \frac{1}{\theta(1-\theta)}.
 \end{aligned}$$

方法二：

$$\begin{aligned}
 I(\theta) &= \text{Var} \left\{ \frac{\partial \log f(X; \theta)}{\partial \theta} \right\} = \text{Var} \left(\frac{X}{\theta} - \frac{1-X}{1-\theta} \right) \\
 &= \text{Var} \left\{ \frac{X}{\theta(1-\theta)} - \frac{1}{1-\theta} \right\} = \frac{1}{\theta^2(1-\theta)^2} \text{Var}(X) \\
 &= \frac{1}{\theta^2(1-\theta)^2} \theta(1-\theta) = \frac{1}{\theta(1-\theta)}.
 \end{aligned}$$

方法三：

$$\begin{aligned}
 \frac{\partial^2 \log f(x, \theta)}{\partial^2 \theta} &= -\frac{x}{\theta^2} - \frac{1-x}{(1-\theta)^2}, \\
 I(\theta) &= -\mathbb{E} \left\{ \frac{\partial^2 \log f(X, \theta)}{\partial^2 \theta} \right\} = \mathbb{E} \left\{ \frac{X}{\theta^2} + \frac{1-X}{(1-\theta)^2} \right\} \\
 &= \frac{\theta}{\theta^2} + \frac{1-\theta}{(1-\theta)^2} = \frac{1}{\theta(1-\theta)}. \quad \square
 \end{aligned}$$

例 (location family) 样本 $X_1, \dots, X_n$ 满足

$$X_i = \theta + e_i, i = 1, \dots, n,$$

其中 $e_1, \dots, e_n$ 为 i.i.d., 有共同的 p.d.f. $f(x), x \in \mathbb{R}$ 。这称为一个 location family。

首先，每个 X_i 的密度函数均为

$$f_X(x; \theta) = f(x - \theta).$$

Fisher信息量为

$$\begin{aligned}
 I(\theta) &= E \left[\left\{ \frac{\partial \log f_X(X; \theta)}{\partial \theta} \right\}^2 \right] \\
 &= E \left[\left\{ \frac{f'(X - \theta)}{f(X - \theta)} \right\}^2 \right] \\
 &= \int_{-\infty}^{+\infty} \left\{ \frac{f'(x - \theta)}{f(x - \theta)} \right\}^2 f(x - \theta) dx \quad (\text{期望转换为积分}) \\
 &= \int_{-\infty}^{+\infty} \left\{ \frac{f'(z)}{f(z)} \right\}^2 f(z) dz \quad (\text{做变量替换 } z = x - \theta).
 \end{aligned}$$

它与参数 θ 无关。

对于之前提到的拉普拉斯分布，有 $f(z) = \frac{1}{2}e^{-|z|}$ 。所以

$$\begin{aligned}
 f'(z) &= -\frac{1}{2} \text{sgn}(z) e^{-|z|}, \\
 \left\{ \frac{f'(z)}{f(z)} \right\}^2 &= \{-\text{sgn}(z)\}^2 = 1, \\
 I(\theta) &= \int_{-\infty}^{+\infty} \left\{ \frac{f'(z)}{f(z)} \right\}^2 f(z) dz \\
 &= \int_{-\infty}^{\infty} f(z) dz = 1. \quad \square
 \end{aligned}$$

定理 (Hogg Theorem 6.2.1, Rao-Cramer下界) 假设 $X_1, \dots, X_n$ 为i.i.d.且有共同的密度函数 $f(x; \theta)$ 。

假设(R0)-(R4)成立。若 $Y = u(X_1, \dots, X_n)$ 为期望为 $k(\theta)$ 的统计量，则

$$\text{Var}(Y) \geq \frac{[k'(\theta)]^2}{nI(\theta)}.$$

证明：假设总体为连续性随机变量(离散型同理)。可以知道

$$\begin{aligned}
 k(\theta) &= E \{u(X_1, \dots, X_n)\} \\
 &= \int_{-\infty}^{+\infty} \cdots \int_{-\infty}^{\infty} u(x_1, \dots, x_n) f(x_1; \theta) \cdots f(x_n; \theta) dx_1 \cdots dx_n \quad (\text{期望转为积分}).
 \end{aligned}$$

对 θ 求导可得

$$k'(\theta) = \int_{-\infty}^{\infty} \cdots \int_{-\infty}^{+\infty} u(x_1, \dots, x_n) \frac{\partial}{\partial \theta} \{f(x_1; \theta) \cdots f(x_n; \theta)\} dx_1 \cdots dx_n.$$

其中

$$\begin{aligned}
& \frac{\partial}{\partial \theta} \{f(x_1; \theta) \cdots f(x_n; \theta)\} \\
&= \frac{\partial f(x_1; \theta)}{\partial \theta} f(x_2; \theta) \cdots f(x_n; \theta) + f(x_1; \theta) \frac{\partial f(x_2; \theta)}{\partial \theta} f(x_3; \theta) \cdots f(x_n; \theta) + \cdots + f(x_1; \theta) f(x_2; \theta) \cdots \frac{\partial f(x_n; \theta)}{\partial \theta} \\
&= f(x_1; \theta) \cdots f(x_n; \theta) \left\{ \frac{1}{f(x_1; \theta)} \cdot \frac{\partial f(x_1; \theta)}{\partial \theta} + \cdots + \frac{1}{f(x_n; \theta)} \cdot \frac{\partial f(x_n; \theta)}{\partial \theta} \right\} \\
&= f(x_1; \theta) \cdots f(x_n; \theta) \left\{ \frac{\partial \log f(x_1; \theta)}{\partial \theta} + \cdots + \frac{\partial \log f(x_n; \theta)}{\partial \theta} \right\}.
\end{aligned}$$

令 $Z = \sum_{i=1}^n \partial \log f(X_i; \theta) / \partial \theta$ 。则

$$\begin{aligned}
k'(\theta) &= \int_{-\infty}^{+\infty} \cdots \int_{-\infty}^{+\infty} u(x_1, \dots, x_n) \left\{ \frac{\partial \log f(x_1; \theta)}{\partial \theta} + \cdots + \frac{\partial \log f(x_n; \theta)}{\partial \theta} \right\} f(x_1; \theta) \cdots f(x_n; \theta) dx_1 \cdots dx_n \\
&= E(YZ).
\end{aligned}$$

关于 Z ，我们有

$$\begin{aligned}
E(Z) &= nE \left\{ \frac{\partial \log f(X; \theta)}{\partial \theta} \right\} = 0, \\
\text{Var}(Z) &= n\text{Var} \left\{ \frac{\partial \log f(X; \theta)}{\partial \theta} \right\} = nI(\theta).
\end{aligned}$$

于是

$$\begin{aligned}
k'(\theta) &= E(YZ) \\
&= \text{Cov}(Y, Z) + E(Y)E(Z) \quad (\text{协方差的定义}) \\
&= \text{Cov}(Y, Z) \quad (\text{利用 } E(Z) = 0) \\
&= \rho(Y, Z) \sqrt{\text{Var}(Y)} \sqrt{\text{Var}(Z)} \quad (\rho(Y, Z) \text{ 为相关系数}).
\end{aligned}$$

所以

$$\rho^2(Y, Z) = \frac{\{k'(\theta)\}^2}{\text{Var}(Y)\text{Var}(Z)} \leq 1 \quad (\text{相关系数在-1与1之间}).$$

最后得到

$$\text{Var}(Y) \geq \frac{\{k'(\theta)\}^2}{\text{Var}(Z)} = \frac{\{k'(\theta)\}^2}{nI(\theta)}. \quad \square$$

推论 (Hogg Corollary 6.2.1) 在定理6.2.1的条件下，若 $Y = u(X_1, \dots, X_n)$ 为 θ 的无偏估计 (即 $k(\theta) = \theta$)，则

$$\text{Var}(Y) \geq \frac{1}{nI(\theta)}. \quad \square$$

例 (Bernoulli分布) 对于Bernoulli(θ)的样本, MLE为 $\hat{\theta} = \bar{X}$ 。而 $\text{Var}(\bar{X}) = \theta(1 - \theta)/n$, 正好达到 $1/\{nI(\theta)\}$, 即Rao-Cramer下界。 $\square$

定义(Hogg Definition 6.2.1, 有效估计量, efficient estimator) 若 Y 为 θ 的一个无偏估计量, 称 Y 为有效估计量, 如果 Y 的方差达到Rao-Cramer下界(简称为RCB)。

定义(Hogg Definition 6.2.2, 有效性, efficiency) 若 Y 为 θ 的一个无偏估计, 则 $1/\{nI(\theta)\text{Var}(Y)\}$ 称为 Y 的有效性。

例 (Poisson分布) 若样本 $X_1, \dots, X_n$ 取自Poisson(θ)分布。

首先计算MLE:

$$\begin{aligned} f(x; \theta) &= \frac{1}{x!} \theta^x e^{-\theta}, \\ \ell(\theta; \mathbf{X}) &= \sum_{i=1}^n \{-\log(X_i!) + X_i \log \theta - \theta\}, \\ \frac{\partial \ell}{\partial \theta}(\theta; \mathbf{X}) &= \frac{\sum_{i=1}^n X_i}{\theta} - n, \\ \hat{\theta} &= \bar{X}. \end{aligned}$$

其次计算Fisher信息量:

$$\begin{aligned} I(\theta) &= \text{E} \left[\left\{ \frac{\partial \log f(X; \theta)}{\partial \theta} \right\}^2 \right] = \text{E} \left(\frac{X}{\theta} - 1 \right)^2 \\ &= \frac{1}{\theta^2} \text{E}(X - \theta)^2 = \frac{1}{\theta^2} \text{Var}(X) = \frac{1}{\theta}. \end{aligned}$$

而又有

$$\text{Var}(\hat{\theta}) = \frac{1}{n} \text{Var}(X) = \frac{\theta}{n} = \frac{1}{nI(\theta)},$$

达到RCB。 $\square$

例 (正态分布) 若样本 $X_1, \dots, X_n$ 取自正态分布 $N(\theta, \sigma_0^2)$, σ_0 已知。其具有密度函数

$$f(x; \theta) = \frac{1}{\sigma_0 \sqrt{2\pi}} \exp \left\{ -\frac{1}{2\sigma_0^2} (x - \theta)^2 \right\}.$$

首先, MLE为 $\bar{X}$ 。其次计算Fisher信息量:

$$\begin{aligned} \log f(x; \theta) &= -\frac{1}{2} \log(2\pi) - \frac{1}{2} \log(\sigma_0^2) - \frac{1}{2\sigma_0^2} (x - \theta)^2, \\ I(\theta) &= \text{E} \left[\left\{ \frac{\partial \log f(X; \theta)}{\partial \theta} \right\}^2 \right] = \text{E} \left(\frac{X - \theta}{\sigma_0^2} \right)^2 = \frac{1}{\sigma_0^4} \text{Var}(X) = \frac{1}{\sigma_0^2}. \end{aligned}$$

所以,

$$\text{Var}(\hat{\theta}) = \frac{1}{n} \sigma_0^2 = \frac{1}{nI(\theta)},$$

达到RCB。 □

例 (beta分布) 若样本 $X_1, \dots, X_n$ 取自 $\text{beta}(\theta, 1)$ 分布, 其密度函数为

$$f(x; \theta) = \theta x^{\theta-1}, \quad 0 < x < 1,$$

其中参数 $\theta > 0$, 样本数 $n > 2$ 。

首先计算MLE

$$\begin{aligned} l(\theta; \mathbf{X}) &= n \log \theta + (\theta - 1) \sum_{i=1}^n \log X_i, \\ \frac{\partial l}{\partial \theta}(\theta; \mathbf{X}) &= \frac{n}{\theta} + \sum_{i=1}^n \log X_i, \\ \hat{\theta} &= -\frac{n}{\sum_{i=1}^n \log X_i}. \end{aligned}$$

其次计算Fisher信息量

$$\begin{aligned} \log f(x; \theta) &= \log \theta + (\theta - 1) \log x, \\ \frac{\partial \log f(x; \theta)}{\partial \theta} &= \frac{1}{\theta} + \log x, \\ \frac{\partial^2 \log f(x; \theta)}{\partial \theta^2} &= -\frac{1}{\theta^2}, \\ I(\theta) &= -E \left[\frac{\partial^2 \log f(X; \theta)}{\partial \theta^2} \right] = \frac{1}{\theta^2}. \end{aligned}$$

可以证明, $-\log X_i \sim \Gamma(1, 1/\theta)$, 所以 $-\sum_{i=1}^n \log X_i \sim \Gamma(n, 1/\theta)$ 。可以进一步证明

$$\begin{aligned} E(\hat{\theta}) &= \frac{n}{n-1} \theta \quad (\text{有偏}), \\ \text{Var}(\hat{\theta}) &= \frac{n^2}{(n-1)^2(n-2)} \theta^2. \end{aligned}$$

为了纠偏, 构造 $\tilde{\theta} = (n-1)\hat{\theta}/n$, 则 $\tilde{\theta}$ 即为无偏估计。而

$$\text{Var}(\tilde{\theta}) = \left(\frac{n-1}{n} \right)^2 \text{Var}(\hat{\theta}) = \frac{1}{n-2} \theta^2 > \frac{1}{nI(\theta)}$$

所以 $\tilde{\theta}$ 并非有效估计量, 其效率为

$$\frac{\theta^2/n}{\theta^2/(n-2)} = \frac{n-2}{n} \rightarrow 1 \quad (n \rightarrow \infty).$$

称 $\tilde{\theta}$ 为渐进有效的 (asymptotically efficient)。 □