



第十讲 极大似然检验

袁洪松

内容概要:

极大似然检验

预习内容:

Hogg Section 6.3

1 极大似然检验

假设 X 有密度函数 $f(x; \theta), \theta \in \Omega$ (概率质量函数同理)。考虑双侧检验问题

$$H_0 : \theta = \theta_0 \text{ vs } H_1 : \theta \neq \theta_0.$$

问题: 有没有不凭借直观的, 系统的检验方法?

定理 (Hogg Theorem 6.1.1) 令 θ_0 表示 θ 的真实值, 且 $E_{\theta_0}[f(X_i; \theta)/f(X_i; \theta_0)]$ 存在。假设条件(R0)-(R2)成立:

(R0) θ_0 为 Ω 的内点。

(R1) 分布函数可区分。即 $\theta \neq \theta'$ 时, $F(X_i; \theta) \neq F(X_i; \theta')$ 。

(R2) 对所有 θ , 密度函数有共同的支撑。即集合 $\{x : f(x; \theta) \neq 0\}$ 与 θ 无关。

则

$$\lim_{n \rightarrow \infty} P_{\theta_0}[L(\theta_0) > L(\theta)] = 1, \quad \forall \theta \neq \theta_0.$$

证明: 根据大数定律,

$$\frac{1}{n} \sum_{i=1}^n \log \left\{ \frac{f(X_i; \theta)}{f(X_i; \theta_0)} \right\} \xrightarrow{P} E_{\theta_0} \log \left\{ \frac{f(X_1; \theta)}{f(X_1; \theta_0)} \right\}.$$

由琴生不等式(Jensen's inequality)可知,

$$\begin{aligned} E_{\theta_0} \log \left\{ \frac{f(X_1; \theta)}{f(X_1; \theta_0)} \right\} &< \log E_{\theta_0} \left\{ \frac{f(X_1; \theta)}{f(X_1; \theta_0)} \right\} \\ &= \log \int \frac{f(x; \theta)}{f(x; \theta_0)} \cdot f(x; \theta_0) dx \\ &= \log \int f(x; \theta) dx \\ &= 0. \end{aligned}$$

于是,

$$\lim_{n \rightarrow \infty} P_{\theta_0} \left[\frac{1}{n} \sum_{i=1}^n \log \left\{ \frac{f(X_i; \theta)}{f(X_i; \theta_0)} \right\} < 0 \right] = 1. \quad \square$$

思路: 考虑似然函数或对数似然函数

$$L(\theta, \mathbf{X}) = \prod_{i=1}^n f(X_i; \theta) \text{ 或 } \ell(\theta, \mathbf{X}) = \sum_{i=1}^n \log f(X_i; \theta).$$

用 $\hat{\theta}$ 表示 θ 的MLE。如果 H_0 为真, 则 $L(\hat{\theta})$ 会非常接近于 $L(\theta_0)$ (定理6.1.1)。

方法: 考虑两个似然函数之比

$$\Lambda = L(\theta_0) / L(\hat{\theta}).$$

显然, $\Lambda \leq 1$ 。如果 H_0 为真, 则 Λ 接近于1, 否则 Λ 会远离1。所以可取拒绝域 $\{\Lambda \leq c\}$, 其中 c 使得 $P_{\theta_0}(\Lambda \leq c) = \alpha$ 。这种检验方法称为似然比检验 (likelihood ratio test, **LRT**)。

例 (指数分布) $X_1, \dots, X_n$ 为来自指数分布 $\text{Exp}(1/\theta)$ 的样本, 密度为

$$f(x; \theta) = \frac{1}{\theta} e^{-x/\theta}, \quad x > 0.$$

检验 $H_0: \theta = \theta_0$ vs $H_1: \theta \neq \theta_0$ 。

首先, 似然函数为

$$L(\theta) = \prod_{i=1}^n \frac{1}{\theta} e^{-X_i/\theta} = \frac{1}{\theta^n} e^{-n\bar{X}/\theta}.$$

可以知道, θ 的MLE为 $\hat{\theta} = \bar{X}$ 。

其次，LRT统计量为

$$\begin{aligned}\Lambda &= L(\theta_0) / L(\hat{\theta}) \\ &= \frac{e^{-n\bar{X}/\theta_0} / \theta_0^n}{e^{-n\bar{X}/\bar{X}} / \bar{X}^n} \\ &= e^n \left(\frac{\bar{X}}{\theta_0} \right)^n e^{-n\bar{X}/\theta_0}.\end{aligned}$$

拒绝域形如 $\{\Lambda \leq c\}$ 。令 $g(t) = t^n e^{-nt}$, $t > 0$, 于是 $\Lambda = e^n g(\bar{X}/\theta_0)$ 。可以算出

$$g'(t) = ne^{-nt} t^{n-1} (1-t).$$

可以知道, $g(t)$ 在 $t < 1$ 时为增, 在 $t > 1$ 时为减。所以 $\{\Lambda \leq c\}$ 等价于 $\{\bar{X}/\theta_0 \leq c_1\} \cup \{\bar{X}/\theta_0 \geq c_2\}$ 。




Figure 6.3.1: Plot for Example 6.3.1, showing that the function $g(t) \leq c$ if and only if $t \leq c_1$ or $t \geq c_2$.

在 H_0 下, $\sum_{i=1}^n X_i \sim \Gamma(n, \theta_0)$, $\frac{2}{\theta_0} \sum_{i=1}^n X_i \sim \Gamma(n, 2) = \chi^2(2n)$ 。故可取拒绝域

$$\left\{ \frac{2}{\theta_0} \sum_{i=1}^n X_i \leq \chi_{1-\frac{\alpha}{2}}^2(2n) \right\} \cup \left\{ \frac{2}{\theta_0} \sum_{i=1}^n X_i \geq \chi_{\frac{\alpha}{2}}^2(2n) \right\}. \quad \square$$

例 (正态分布, 方差已知) $X_1, \dots, X_n$ 为来自正态分布 $N(\theta, \sigma_0^2)$ 的样本, 其中 σ_0 已知。检验

$$H_0 : \theta = \theta_0 \text{ vs } H_1 : \theta \neq \theta_0.$$

首先, MLE为 $\hat{\theta} = \bar{X}$ 。其次, 似然函数为

$$\begin{aligned}L(\theta) &= \prod_{i=1}^n \frac{1}{\sigma_0 \sqrt{2\pi}} \exp \left\{ -\frac{1}{2\sigma_0^2} (X_i - \theta)^2 \right\} \\ &= \left(\frac{1}{\sigma_0 \sqrt{2\pi}} \right)^n \exp \left\{ -\frac{1}{2\sigma_0^2} \sum_{i=1}^n (X_i - \theta)^2 \right\}.\end{aligned}$$

所以LTR统计量为

$$\begin{aligned}\Lambda &= L(\theta_0) / L(\hat{\theta}, \mathbf{X}) \\ &= \left(\frac{1}{\sigma_0 \sqrt{2\pi}} \right)^n \exp \left\{ -\frac{1}{2\sigma_0^2} \sum_{i=1}^n (X_i - \theta_0)^2 \right\} / \left(\frac{1}{\sigma_0 \sqrt{2\pi}} \right)^n \exp \left\{ -\frac{1}{2\sigma_0^2} \sum_{i=1}^n (X_i - \bar{X})^2 \right\} \\ &= \exp \left\{ -\frac{n}{2\sigma_0^2} (\bar{X} - \theta_0)^2 \right\}.\end{aligned}$$

故 $\{\Lambda \leq c\}$ 等价于 $\{|\bar{X} - \theta_0| \geq c_1\}$ 。在显著水平 α 下，应取 $c_1 = z_{\alpha/2} \sigma_0 / \sqrt{n}$ 。所以拒绝域为

$$\left\{ |\bar{X} - \theta_0| \geq \frac{\sigma_0}{\sqrt{n}} z_{\alpha/2} \right\}. \quad \square$$

2 Λ 的渐进分布

定理 (Hogg Theorem 6.3.1) 假设(R0)-(R5)成立。在 H_0 下，

$$-2 \log \Lambda \xrightarrow{D} \chi^2(1). \quad (\text{依分布收敛})$$

引理一 (Hogg Theorem 6.1.3) 假设(R0)-(R2)成立。在 H_0 下，

$$\hat{\theta} \xrightarrow{P} \theta_0. \quad (\text{依概率收敛})$$

引理二 (Hogg Theorem 6.2.2) 假设(R0)-(R5)成立。在 H_0 下，

$$\sqrt{n} (\hat{\theta} - \theta_0) \xrightarrow{D} N \left(0, \frac{1}{I(\theta_0)} \right).$$

定理6.3.1证明：首先，为了表明渐进性，我们把 $\hat{\theta}$ 记为 $\hat{\theta}_n$ 。按照定义有

$$-2 \log \Lambda = 2 \left\{ \ell(\hat{\theta}_n) - \ell(\theta_0) \right\}.$$

将 $\ell(\theta)$ 在 θ_0 附近做Taylor展开，得到

$$\ell(\hat{\theta}_n) = \ell(\theta_0) + (\hat{\theta}_n - \theta_0) \ell'(\theta_0) + \frac{1}{2} (\hat{\theta}_n - \theta_0)^2 \ell''(\theta_n^*),$$

其中 θ_n^* 在 θ_0 与 $\hat{\theta}_n$ 之间。

由于 $\hat{\theta}_n \xrightarrow{P} \theta_0$ (引理一), 于是 $\theta_n^* \xrightarrow{P} \theta_0$ 。则

$$\begin{aligned} \frac{1}{n} \ell''(\theta_n^*) &= \frac{1}{n} \sum_{i=1}^n \frac{\partial^2 \log f(X_i, \theta_n^*)}{\partial \theta^2} \\ &\xrightarrow{P} E \left[\frac{\partial^2 \log f(X; \theta_n^*)}{\partial \theta^2} \right] \\ &\xrightarrow{P} E \left[\frac{\partial^2 \log f(X; \theta_0)}{\partial \theta^2} \right] \\ &= -I(\theta_0). \end{aligned}$$

故

$$\frac{1}{2}(\hat{\theta}_n - \theta_0)^2 \ell''(\theta_n^*) \sim -\frac{1}{2} n I(\theta_0) (\hat{\theta}_n - \theta_0)^2.$$

又因为 $\hat{\theta}_n$ 为对数似然函数的最大值点, 有 $\ell'(\hat{\theta}_n) = 0$ 。由Taylor展开,

$$0 = \ell'(\hat{\theta}_n) = \ell'(\theta_0) + (\hat{\theta}_n - \theta_0) \ell''(\theta_0) + \frac{1}{2} (\hat{\theta}_n - \theta_0)^2 \ell'''(\theta_n^{**}).$$

于是

$$(\hat{\theta}_n - \theta_0) \ell'(\theta_0) = -(\hat{\theta}_n - \theta_0)^2 \ell''(\theta_0) - \frac{1}{2} (\hat{\theta}_n - \theta_0)^3 \ell'''(\theta_n^{**}) \sim n I(\theta_0) (\hat{\theta}_n - \theta_0)^2 + o(1).$$

所以

$$2 \left\{ \ell(\hat{\theta}_n) - \ell(\theta_0) \right\} \sim n I(\theta_0) (\hat{\theta}_n - \theta_0)^2 + o(1).$$

再利用

$$\sqrt{n I(\theta_0)} (\hat{\theta}_n - \theta_0) \xrightarrow{D} N(0, 1) \quad (\text{引理二})$$

得到

$$2 \left\{ \ell(\hat{\theta}_n) - \ell(\theta_0) \right\} \xrightarrow{D} \chi^2(1). \quad \square$$

令 $\chi_L^2 = -2 \log \Lambda$ 。根据上面定理, 渐近显著水平为 α 的拒绝域为

$$\{\chi_L^2 \geq \chi_\alpha^2(1)\}.$$

3 Wald型检验与得分型检验

1. Wald型检验。由于在 H_0 下

$$\sqrt{nI(\theta_0)} (\hat{\theta}_n - \theta_0) \xrightarrow{D} N(0, 1) \quad (\text{引理二}),$$

考虑统计量

$$\chi_W^2 = nI(\hat{\theta}_n) (\hat{\theta}_n - \theta_0)^2.$$

则 χ_W^2 近似服从 $\chi^2(1)$ 分布。渐近显著水平为 α 的拒绝域为

$$\{\chi_w^2 \geq \chi_\alpha^2(1)\}.$$

这称为Wald型检验 (Wald-type test)。

2. 得分型检验。在 H_0 下, 还有

$$\ell'(\theta_0) \sim nI(\theta_0) (\hat{\theta}_n - \theta_0).$$

于是

$$\frac{\ell'(\theta_0)}{\sqrt{nI(\theta_0)}} \sim \sqrt{nI(\theta_0)} (\hat{\theta}_n - \theta_0).$$

定义

$$\chi_R^2 = \left\{ \frac{\ell'(\theta_0)}{\sqrt{nI(\theta_0)}} \right\}^2,$$

则

$$\chi_R^2 \sim nI(\theta_0) (\hat{\theta}_n - \theta_0)^2 \xrightarrow{D} \chi^2(1).$$

所以渐近显著水平为 α 的拒绝域为

$$\{\chi_R^2 \geq \chi_\alpha^2(1)\}.$$

这称为得分型检验 (score-type test) (因为 $\ell'(\theta_0)$ 为得分函数之和)。

例 (beta分布) $X_1, \dots, X_n$ 取自beta分布 $\text{beta}(\theta, 1)$, 其密度函数为

$$f(x; \theta) = \theta x^{\theta-1}, 0 < x < 1.$$




图 1: 似然比检验、Wald型检验与得分型检验比较

检验

$$H_0 : \theta = 1 \text{ vs } H_1 : \theta \neq 1.$$

在 H_0 下, $\text{beta}(\theta, 1)$ 分布为 $(0, 1)$ 上的均匀分布。可知

$$\ell(\theta) = \theta \sum_{i=1}^n \log X_i - \sum_{i=1}^n \log X_i + n \log \theta.$$

而 θ 的MLE为 $\hat{\theta} = -n/(\sum_{i=1}^n \log X_i)$ 。故

$$\ell(\hat{\theta}) = -n - \sum_{i=1}^n \log X_i + n \log \left(-\frac{n}{\sum_{i=1}^n \log X_i} \right).$$

又因为 $\ell(\theta_0) = 0$, 所以

$$\begin{aligned} \chi_L^2 &= -2 \log \Lambda = 2 \left(\ell(\hat{\theta}) - \ell(\theta_n) \right) \\ &= 2 \left\{ -n - \left(\sum_{i=1}^n \log X_i \right) + n \log \left(-\frac{n}{\sum_{i=1}^n \log X_i} \right) \right\}. \end{aligned}$$

因为 $I(\theta) = 1/\theta^2$ (上一讲已证), 所以Wald型统计量为

$$\chi_W^2 = \left\{ \sqrt{n I(\hat{\theta})} (\hat{\theta} - \theta_0) \right\}^2 = \left\{ \sqrt{\frac{n}{\hat{\theta}^2}} (\hat{\theta} - 1) \right\}^2 = n \left(1 - \frac{1}{\hat{\theta}} \right)^2.$$

因为 $\ell'(\theta) = \sum_{i=1}^n \log X_i + n/\theta$ ，所以得分型统计量为

$$\chi_R^2 = \left\{ \frac{\ell'(\theta_0)}{\sqrt{nI(\theta_0)}} \right\}^2 = \left(\frac{\sum_{i=1}^n \log X_i + n}{\sqrt{n}} \right)^2 = n \left(1 - \frac{1}{\bar{\theta}} \right)^2. \quad \square$$

例 (拉普拉斯location family) $X_1, \dots, X_n$ 符合location模型

$$X_i = \theta + e_i, \quad i = 1, \dots, n$$

其中 e_i 服从i.i.d.拉普拉斯分布，具有密度函数

$$f(x) = \frac{1}{2} e^{-|x|}, \quad -\infty < x < \infty.$$

检验

$$H_0 : \theta = \theta_0 \text{ vs } \theta \neq \theta_0.$$

首先， X 的密度函数为

$$f(x, \theta) = \frac{1}{2} e^{-|x-\theta|}, \quad -\infty < x < \infty.$$

于是

$$\begin{aligned} \ell(\theta) &= - \sum_{i=1}^n |X_i - \theta| - n \log 2, \\ \ell'(\theta) &= - \sum_{i=1}^n \text{sgn}(X_i - \theta). \end{aligned}$$

$\ell'(\theta) = 0$ 的解为 $\hat{\theta} = \text{median}(X_1, \dots, X_n) = Q_2$ ，此为MLE。进而

$$\ell(\hat{\theta}) = - \sum_{i=1}^n |X_i - Q_2| - n \log 2.$$

故

$$\chi_L^2 = 2 \left(\sum_{i=1}^n |X_i - \theta_0| - \sum_{i=1}^n |X_i - Q_2| \right).$$

另外， $I(\theta) = 1$ (上一讲已证)。所以

$$\chi_W^2 = \{ \sqrt{n} (Q_2 - \theta_0) \}^2.$$

又由 $\ell'(\theta) = \sum_{i=1}^n \text{sgn}(X_i - \theta)$, 得到

$$\chi_R^2 = \frac{1}{n} \left\{ \sum_{i=1}^n \text{sgn}(X_i - \theta_0) \right\}^2. \quad \square$$