



第十一讲 多参数估计与检验

袁洪松

内容概要:

多参数估计与检验

预习内容:

Hogg Section 6.4, 6.5

1 多参数情形：估计

假设 $X_1, \dots, X_n$ 的 p.d.f. 或 p.m.f. 为 $f(x; \theta)$, 其中 $\theta \in \Omega \subset \mathbb{R}^p$ 。似然函数与对数似然函数为

$$L(\theta) = \prod_{i=1}^n f(X_i; \theta),$$
$$l(\theta) = \sum_{i=1}^n \log f(X_i; \theta).$$

MLE 需要满足

$$\frac{\partial L}{\partial \theta_k} = 0 \quad \text{或者} \quad \frac{\partial l}{\partial \theta_k} = 0, \quad k = 1, \dots, p.$$

例(正态分布) 设样本 $X_1, \dots, X_n$ 取自 $N(\mu, \sigma^2)$, μ, σ 未知。令 $v = \sigma^2$, 参数写为 $\theta = (\mu, v)^\top$, 且 $\Omega = (-\infty, +\infty) \times (0, +\infty)$ 。对数似然函数为

$$l(\theta) = -\frac{n}{2} \log 2\pi - \frac{n}{2} \log v - \frac{1}{2v} \sum_{i=1}^n (X_i - \mu)^2.$$

取关于 μ 和 v 的偏导, 令其为 0, 得到

$$\frac{\partial L}{\partial \mu} = \frac{1}{v} \sum_{i=1}^n (X_i - \mu) = 0$$
$$\frac{\partial L}{\partial v} = -\frac{n}{2v} + \frac{1}{2v^2} \sum_{i=1}^n (X_i - \mu)^2 = 0.$$

可解得

$$\hat{\mu} = \bar{X} \quad (\text{无偏})$$

$$\hat{v} = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2 \quad (\text{有偏}). \quad \square$$

例 (一般拉普拉斯分布) 设样本 $X_1, \dots, X_n$ 取自一般拉普拉斯分布, p.d.f. 为

$$f_X(x) = \frac{1}{2b} e^{-|x-a|/b}, \quad -\infty < x < +\infty,$$

参数为 $\boldsymbol{\theta} = (a, b)^\top \in \Omega = (-\infty, +\infty) \times (0, +\infty)$ 。

对数似然函数为

$$l(a, b) = -n \log 2 - n \log b - \sum_{i=1}^n \frac{|X_i - a|}{b}.$$

取关于 a 和 b 的偏导, 得到

$$\begin{aligned} \frac{\partial L}{\partial a} &= \frac{1}{b} \sum_{i=1}^n \text{sgn}(X_i - a) = 0, \\ \frac{\partial L}{\partial b} &= -\frac{n}{b} + \frac{1}{b^2} \sum_{i=1}^n |X_i - a| = 0. \end{aligned}$$

解得

$$\begin{aligned} \hat{a} &= \text{median}\{X_1, \dots, X_n\} = Q_2, \\ \hat{b} &= \frac{1}{n} \sum_{i=1}^n |X_i - Q_2|. \quad \square \end{aligned}$$

记 $\log f(X; \boldsymbol{\theta})$ 关于 $\boldsymbol{\theta}$ 的梯度为

$$\nabla \log f(X; \boldsymbol{\theta}) = \left(\frac{\partial}{\partial \theta_1} \log f(X; \boldsymbol{\theta}), \dots, \frac{\partial}{\partial \theta_p} \log f(X; \boldsymbol{\theta}) \right)^\top.$$

定义 (Fisher信息量) 在多参数情况下, Fisher信息量为以下 $p \times p$ 矩阵

$$\mathbf{I}(\boldsymbol{\theta}) = \text{Cov} \{ \nabla \log f(X; \boldsymbol{\theta}) \},$$

其中第 (j, k) 个分量为

$$I_{jk}(\boldsymbol{\theta}) = \text{Cov} \left\{ \frac{\partial}{\partial \theta_j} \log f(X; \boldsymbol{\theta}), \frac{\partial}{\partial \theta_k} \log f(X; \boldsymbol{\theta}) \right\}.$$

性质:

1)

$$I_{jk}(\boldsymbol{\theta}) = E \left\{ \frac{\partial}{\partial \theta_j} \log f(X; \boldsymbol{\theta}) \cdot \frac{\partial}{\partial \theta_k} \log f(X; \boldsymbol{\theta}) \right\}.$$

2)

$$I_{jk}(\boldsymbol{\theta}) = -E \left\{ \frac{\partial^2}{\partial \theta_j \partial \theta_k} \log f(X; \boldsymbol{\theta}) \right\}.$$

Rao-Cramer下界 (RCB): 若 $Y_j = u_j(X_1, \dots, X_n)$ 为 θ_j 的无偏估计, 则

$$\text{Var}(Y_j) \geq \frac{1}{n} \{ \mathbf{I}^{-1}(\boldsymbol{\theta}) \}_{jj},$$

其中 $\{ \mathbf{I}^{-1}(\boldsymbol{\theta}) \}_{jj}$ 为 $\mathbf{I}(\boldsymbol{\theta})$ 的逆矩阵的第 j 个对角元素。

有效估计量: 若 Y_j 为 θ_j 的无偏估计, 且 $\text{Var}(Y_j)$ 达到RCB, 则称 Y_j 为有效估计量。

有效性: 若 Y_j 为 θ_j 的无偏估计, 则称 $\{ \mathbf{I}^{-1}(\boldsymbol{\theta}) \}_{jj} / \{ n \text{Var}(Y_j) \}$ 为 Y_j 的有效性。

例 (正态分布) 设样本 $X_1, \dots, X_n$ 取自 $N(\mu, \sigma^2)$, μ, σ 未知。令 $v = \sigma^2$, 仍将参数写为 $\boldsymbol{\theta} = (\mu, v)^\top$ 。则

$$\log f(X; \boldsymbol{\theta}) = -\frac{1}{2} \log 2\pi - \frac{1}{2} \log v - \frac{1}{2v} (X - \mu)^2.$$

可求得 $\log f(X; \boldsymbol{\theta})$ 的偏导为

$$\begin{aligned} \frac{\partial \log f}{\partial \mu} &= \frac{1}{v} (X - \mu), \\ \frac{\partial \log f}{\partial v} &= -\frac{1}{2v} + \frac{1}{2v^2} (X - \mu)^2, \\ \frac{\partial^2 \log f}{\partial \mu^2} &= -\frac{1}{v}, \\ \frac{\partial^2 \log f}{\partial v^2} &= \frac{1}{2v^2} - \frac{1}{v^3} (X - \mu)^2, \\ \frac{\partial^2 \log f}{\partial \mu \partial v} &= -\frac{1}{v^2} (X - \mu). \end{aligned}$$

即

$$\begin{aligned} \mathbf{I}(\boldsymbol{\theta}) &= \begin{bmatrix} \frac{1}{v} & 0 \\ 0 & \frac{1}{2v^2} \end{bmatrix}, \\ \mathbf{I}(\boldsymbol{\theta})^{-1} &= \begin{bmatrix} v & 0 \\ 0 & 2v^2 \end{bmatrix}. \end{aligned}$$

根据MLE, $\hat{\mu} = \bar{X}$ (无偏), $\hat{v} = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$ (有偏)。而 $\text{Var}(\hat{\mu}) = v/n = \text{RCB}$, 故 $\hat{\mu}$ 为有效估计。

将 $\hat{v}$ 纠偏, 得到 v 的一个无偏估计 $S^2 = n\hat{v}/(n-1)$ 。因为 $(n-1)S^2/v \sim \chi^2(n-1)$, 所以

$$\text{Var} \{ (n-1)S^2/v \} = 2(n-1).$$

从而

$$\text{Var}(S^2) = \frac{2v^2}{n-1} > \text{RCB} = \frac{2v^2}{n}.$$

得到 S^2 的有效性为 $(n-1)/n$, 为渐进有效。 $\square$

例 (location and scale family) 假设样本 $X_1, \dots, X_n$ 满足

$$X_i = a + be_i,$$

其中 $(a, b) \in \Omega = (-\infty, +\infty) \times (0, +\infty)$, e_i 为i.i.d., 具有p.d.f. $f(z)$ 。这称为location and scale family model。

可以证明, X_i 有密度函数

$$f_X(x) = \frac{1}{b} f\left(\frac{x-a}{b}\right), \quad -\infty < x < +\infty.$$

首先求偏导

$$\begin{aligned} \frac{\partial \log f_X(x)}{\partial a} &= -\frac{1}{b} \cdot \frac{f'\left(\frac{x-a}{b}\right)}{f\left(\frac{x-a}{b}\right)}, \\ \frac{\partial \log f_X(x)}{\partial b} &= -\frac{1}{b} \left\{ 1 + \frac{\frac{x-a}{b} f'\left(\frac{x-a}{b}\right)}{f\left(\frac{x-a}{b}\right)} \right\}. \end{aligned}$$

然后求得

$$\begin{aligned} I_{11} &= \text{E} \left[\left\{ \frac{\partial \log f_X(X)}{\partial a} \right\}^2 \right] \\ &= \int_{-\infty}^{\infty} \frac{1}{b^2} \left\{ \frac{f'\left(\frac{x-a}{b}\right)}{f\left(\frac{x-a}{b}\right)} \right\}^2 \frac{1}{b} f\left(\frac{x-a}{b}\right) dx \\ &= \int_{-\infty}^{\infty} \frac{1}{b^2} \left\{ \frac{f'(z)}{f(z)} \right\}^2 \frac{1}{b} f(z) b dz \quad \left(\text{变量替换 } z = \frac{x-a}{b} \right) \\ &= \frac{1}{b^2} \int_{-\infty}^{\infty} \left\{ \frac{f'(z)}{f(z)} \right\}^2 f(z) dz. \end{aligned}$$

同理可得,

$$\begin{aligned} I_{22} &= \frac{1}{b^2} \int_{-\infty}^{\infty} \left\{ 1 + \frac{zf'(z)}{f(z)} \right\}^2 f(z) dz, \\ I_{12} &= \frac{1}{b^2} \int_{-\infty}^{\infty} z \left\{ \frac{f'(z)}{f(z)} \right\}^2 f(z) dz. \quad \square \end{aligned}$$

例 (多项分布) 假设一次试验在 k 个不同结果中会且仅会产生一种结果。每种结果产生的概率分别为 $p_1, \dots, p_k$ ($\sum_{j=1}^k p_j = 1$)。令 $X_j = I_{\{\text{试验生成第}j\text{种结果}\}}$, $j = 1, \dots, k$, 并让 $\mathbf{X} = (X_1, \dots, X_{k-1})^\top$ (X_k 完全

由 $X_1, \dots, X_{k-1}$ 决定, 因为 $\sum_{j=1}^k X_j = 1$, $\mathbf{p} = (p_1, \dots, p_{k-1})^\top$ 。 $\mathbf{X}$ 的p.m.f.为

$$f(\mathbf{x}; \mathbf{p}) = \left(\prod_{i=1}^{k-1} p_i^{x_i} \right) \left(1 - \sum_{j=1}^{k-1} p_j \right)^{1 - \sum_{j=1}^{k-1} x_j}$$

其中参数 $\mathbf{p} \in \Omega = \left\{ (p_1, \dots, p_{k-1})^\top : 0 < p_j < 1, j = 1, \dots, k-1, \sum_{j=1}^{k-1} p_j < 1 \right\}$ 。(注意: $k = 2$ 时即为Bernoulli分布)

先计算Fisher信息矩阵:

$$\begin{aligned} \log f(\mathbf{x}; \mathbf{p}) &= \sum_{i=1}^{k-1} x_i \log p_i + \left(1 - \sum_{j=1}^{k-1} x_j \right) \log \left(1 - \sum_{j=1}^{k-1} p_j \right), \\ \frac{\partial \log f}{\partial p_i} &= \frac{x_i}{p_i} - \frac{1 - \sum_{j=1}^{k-1} x_j}{1 - \sum_{j=1}^{k-1} p_j}, \\ \frac{\partial^2 \log f}{\partial p_i^2} &= -\frac{x_i}{p_i^2} - \frac{1 - \sum_{j=1}^{k-1} x_j}{(1 - \sum_{j=1}^{k-1} p_j)^2}, \\ \frac{\partial^2 \log f}{\partial p_i \partial p_h} &= -\frac{1 - \sum_{j=1}^{k-1} x_j}{\left(1 - \sum_{j=1}^{k-1} p_j \right)^2}, \quad i \neq h. \end{aligned}$$

所以

$$\begin{aligned} I_{ii} &= -\mathbb{E} \left(\frac{\partial^2 \log f}{\partial p_i^2} \right) = \mathbb{E} \left\{ \frac{X_i}{p_i^2} + \frac{1 - \sum_{j=1}^{k-1} X_j}{(1 - \sum_{j=1}^{k-1} p_j)^2} \right\} \\ &= \frac{p_i}{p_i^2} + \frac{1 - \sum_{j=1}^{k-1} p_j}{(1 - \sum_{j=1}^{k-1} p_j)^2} = \frac{1}{p_i} + \frac{1}{1 - \sum_{j=1}^{k-1} p_j} = \frac{1}{p_i} + \frac{1}{p_k}, \\ I_{ih} &= -\mathbb{E} \left(\frac{\partial^2 \log f}{\partial p_i \partial p_h} \right) = \mathbb{E} \left\{ \frac{1 - \sum_{j=1}^{k-1} X_j}{\left(1 - \sum_{j=1}^{k-1} p_j \right)^2} \right\} \\ &= \frac{1 - \sum_{j=1}^{k-1} p_j}{(1 - \sum_{j=1}^{k-1} p_j)^2} = \frac{1}{p_k}. \end{aligned}$$

即

$$\mathbf{I}(\mathbf{p}) = \begin{bmatrix} \frac{1}{p_1} + \frac{1}{p_k} & \frac{1}{p_k} & \cdots & \frac{1}{p_k} \\ \frac{1}{p_k} & \frac{1}{p_2} + \frac{1}{p_k} & \cdots & \frac{1}{p_k} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{1}{p_k} & \frac{1}{p_k} & \cdots & \frac{1}{p_{k-1}} + \frac{1}{p_k} \end{bmatrix}.$$

可以算出

$$\mathbf{I}^{-1}(\mathbf{p}) = \begin{bmatrix} p_1(1-p_1) & -p_1p_2 & \cdots & -p_1p_{k-1} \\ -p_1p_2 & p_2(1-p_2) & \cdots & -p_2p_{k-1} \\ & & \ddots & \\ -p_1p_{k-1} & -p_2p_{k-1} & \cdots & p_{k-1}(1-p_{k-1}) \end{bmatrix}.$$

下面计算MLE。记样本为 $\mathbf{X}_1, \dots, \mathbf{X}_n$ ，其中 $\mathbf{X}_i = (X_{1i}, \dots, X_{k-1,i})^\top$ 。对数似然函数为

$$\begin{aligned} l(\mathbf{p}) &= \sum_{i=1}^n \left\{ \sum_{j=1}^{k-1} X_{ji} \log p_j + \left(1 - \sum_{j=1}^{k-1} X_{ji} \right) \log \left(1 - \sum_{j=1}^{k-1} p_j \right) \right\} \\ &= \sum_{j=1}^{k-1} T_j \log p_j + \left(n - \sum_{j=1}^{k-1} T_j \right) \log \left(1 - \sum_{j=1}^{k-1} p_j \right). \end{aligned}$$

其中 $T_j = \sum_{i=1}^n X_{ji}$ 。对 $p_h (h = 1, \dots, k-1)$ 求偏导得

$$\frac{\partial l}{\partial p_h} = \frac{T_h}{p_h} - \frac{n - \sum_{j=1}^{k-1} T_j}{1 - \sum_{j=1}^{k-1} p_j} = 0.$$

解得

$$\hat{p}_h = \frac{T_h}{n}, \quad h = 1, \dots, k-1.$$

可以知道， $T_h = \sum_{i=1}^n X_{hi} \sim \text{Bin}(n, p_h)$ 。故

$$\begin{aligned} \mathbb{E}(\hat{p}_h) &= \frac{1}{n} \mathbb{E}(T_h) = \frac{1}{n} \cdot np_h = p_h \quad (\text{无偏}). \\ \text{Var}(\hat{p}_h) &= \frac{1}{n^2} \text{Var}(T_h) \\ &= \frac{1}{n^2} np_h(1-p_h) \\ &= \frac{1}{n} p_h(1-p_h) \\ &= \frac{1}{n} \{\mathbf{I}(\mathbf{p})\}_{hh}^{-1} = \text{RCB}. \end{aligned}$$

所以 $\hat{p}_h$ 为 p_h 的有效估计。 $\square$

2 多参数情形：检验

假设 $X_1, \dots, X_n$ 的p.d.f.为 $f(x; \boldsymbol{\theta})$ ，其中 $\boldsymbol{\theta} \in \Omega \subset \mathbb{R}^p$ 。考虑检验问题

$$H_0 : \boldsymbol{\theta} = \boldsymbol{\theta}_0 \text{ vs } H_1 : \boldsymbol{\theta} \neq \boldsymbol{\theta}_0.$$

三种检验方法仍然成立：

1) 似然比检验(LRT)

$$\chi_L^2 = -2 \log \Lambda = 2 \left\{ l(\hat{\boldsymbol{\theta}}) - l(\boldsymbol{\theta}_0) \right\} \xrightarrow{D} \chi^2(p).$$

2) Wald型检验

$$\chi_W^2 = (\hat{\boldsymbol{\theta}} - \boldsymbol{\theta}_0)^\top \left\{ n\mathbf{I}(\hat{\boldsymbol{\theta}}) \right\} (\hat{\boldsymbol{\theta}} - \boldsymbol{\theta}_0) \xrightarrow{D} \chi^2(p).$$

3) 得分型检验

$$\chi_R^2 = \{ \nabla l(\boldsymbol{\theta}_0) \}^\top \left\{ n\mathbf{I}(\hat{\boldsymbol{\theta}}_0) \right\}^{-1} \{ \nabla l(\boldsymbol{\theta}_0) \} \xrightarrow{D} \chi^2(p).$$

现在考虑检验问题

$$H_0 : \boldsymbol{\theta} \in \omega \text{ vs } H_1 : \boldsymbol{\theta} \in \Omega \cap \omega^c,$$

其中 ω 被 q 个约束 ($0 < q \leq p$) 定义:

$$\begin{cases} g_1(\boldsymbol{\theta}) &= a_1, \\ &\dots \\ g_q(\boldsymbol{\theta}) &= a_q, \end{cases}$$

其中 $g_1, \dots, g_q$ 连续可微。

似然比检验统计量:

$$\Lambda = \frac{\max_{\boldsymbol{\theta} \in \omega} L(\boldsymbol{\theta})}{\max_{\boldsymbol{\theta} \in \Omega} L(\boldsymbol{\theta})}.$$

拒绝域形如 $\{\Lambda \leq c\}$ 。对于检验水平 α , 选取 c 使得

$$\alpha = \max_{\boldsymbol{\theta} \in \omega} P_{\boldsymbol{\theta}}(\Lambda \leq c).$$

若令 $\hat{\boldsymbol{\theta}}_0 = \operatorname{argmax}_{\boldsymbol{\theta} \in \omega} L(\boldsymbol{\theta})$, $\hat{\boldsymbol{\theta}} = \operatorname{argmax}_{\boldsymbol{\theta} \in \Omega} L(\boldsymbol{\theta})$, 我们记 $L(\hat{\omega}) = L(\hat{\boldsymbol{\theta}}_0)$, $L(\hat{\Omega}) = L(\hat{\boldsymbol{\theta}})$, 那么

$$\Lambda = \frac{L(\hat{\omega})}{L(\hat{\Omega})}.$$

例(正态分布, 方差未知) $X_1, \dots, X_n \sim N(\mu, \sigma^2)$, σ^2 未知. 检验

$$H_0 : \mu = \mu_0 \text{ vs } H_1 : \mu \neq \mu_0.$$

可知 $\Omega = \{(\mu, \sigma) : -\infty < \mu < +\infty, 0 < \sigma < +\infty\}$, $\omega = \{(\mu, \sigma) : \mu = \mu_0, 0 < \sigma < +\infty\}$ 。

在 Ω 中极大化似然函数, 得到

$$\hat{\mu} = \bar{X}, \quad \hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2.$$

在 ω 中极大化似然函数, 得到

$$\hat{\mu}_0 = \mu_0, \quad \hat{\sigma}_0^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \mu_0)^2.$$

于是

$$\begin{aligned} L(\hat{\Omega}) &= \frac{1}{(2\pi\hat{\sigma}^2)^{n/2}} e^{-\frac{n}{2}}, \\ L(\hat{\omega}) &= \frac{1}{(2\pi\hat{\sigma}_0^2)^{n/2}} e^{-\frac{n}{2}}, \\ \Lambda &= \frac{L(\hat{\omega})}{L(\hat{\Omega})} = \left(\frac{\hat{\sigma}^2}{\hat{\sigma}_0^2} \right)^{n/2} = \left\{ \frac{\sum_{i=1}^n (X_i - \bar{X})^2}{\sum_{i=1}^n (X_i - \mu_0)^2} \right\}^{\frac{n}{2}}. \end{aligned}$$

由于

$$\begin{aligned} \sum_{i=1}^n (X_i - \mu_0)^2 &= \sum_{i=1}^n (X_i - \bar{X} + \bar{X} - \mu_0)^2 \\ &= \sum_{i=1}^n (X_i - \bar{X})^2 + \sum_{i=1}^n (\bar{X} - \mu_0)^2 + 2 \sum_{i=1}^n (X_i - \bar{X})(\bar{X} - \mu_0) \\ &= \sum_{i=1}^n (X_i - \bar{X})^2 + n(\bar{X} - \mu_0)^2 + 2(\bar{X} - \mu_0) \sum_{i=1}^n (X_i - \bar{X}) \\ &= \sum_{i=1}^n (X_i - \bar{X})^2 + n(\bar{X} - \mu_0)^2. \end{aligned}$$

故

$$\Lambda = \left\{ \frac{\sum_{i=1}^n (X_i - \bar{X})^2}{\sum_{i=1}^n (X_i - \mu_0)^2} \right\}^{\frac{n}{2}} = \left\{ \frac{1}{1 + \frac{n(\bar{X} - \mu_0)^2}{\sum_{i=1}^n (X_i - \bar{X})^2}} \right\}^{\frac{n}{2}}.$$

所以 $\{\Lambda \leq c\}$ 等价于 $\left\{ \frac{n(\bar{X} - \mu_0)^2}{\sum_{i=1}^n (X_i - \bar{X})^2} \geq c_1 \right\}$, 又进一步等价于

$$\left\{ \frac{\sqrt{n}|\bar{X} - \mu_0|}{\sqrt{\sum_{i=1}^n (X_i - \bar{X})^2 / (n-1)}} \geq c_2 \right\}, \quad \text{即} \left\{ \frac{|\bar{X} - \mu_0|}{S/\sqrt{n}} \geq c_2 \right\}.$$

此即为 t -检验。 $\square$

例(单因素方差分析) 假设有 r 个互相独立的正态总体 $N(\mu_1, \sigma^2), \dots, N(\mu_r, \sigma^2)$. 第 i 个总体有样本 $X_{i,1}, \dots, X_{i,n_i}$. 记总样本数为 $n = n_1 + \dots + n_r$. 检验

$$H_0 : \mu_1 = \dots = \mu_r \text{ vs } H_1 : \mu_1, \dots, \mu_r \text{ 不全相等.}$$

首先写出总的似然函数 (即各组似然函数的乘积)

$$L(\mu_1, \dots, \mu_r, \sigma) = \prod_{i=1}^r \prod_{j=1}^{n_i} \frac{1}{\sigma\sqrt{2\pi}} \exp \left\{ -\frac{1}{2\sigma^2} (X_{ij} - \mu_i)^2 \right\}.$$

对数似然函数为

$$l(\mu_1, \dots, \mu_r, \sigma) = - \sum_{i=1}^r \sum_{j=1}^{n_i} \left\{ \log \sqrt{2\pi} + \log \sigma + \frac{1}{2\sigma^2} (X_{ij} - \mu_i)^2 \right\}.$$

无约束的极大似然估计量为

$$\hat{\mu}_i = \frac{1}{n_i} \sum_{j=1}^{n_i} X_{ij} = \bar{X}_{i\cdot}, \quad \hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^r \sum_{j=1}^{n_i} (X_{ij} - \bar{X}_{i\cdot})^2.$$

相应的对数似然函数值为

$$l(\hat{\mu}_1, \dots, \hat{\mu}_r, \hat{\sigma}) = -n \log \sqrt{2\pi} - \frac{n}{2} \log(\hat{\sigma}^2) - \frac{n}{2}.$$

而在 H_0 的约束下, 可以得到极大似然估计量为

$$\hat{\mu} = \frac{1}{n} \sum_{i=1}^r \sum_{j=1}^{n_i} X_{ij} = \bar{X}, \quad \hat{\sigma}'^2 = \frac{1}{n} \sum_{i=1}^r \sum_{j=1}^{n_i} (X_{ij} - \bar{X})^2.$$

相应的对数似然函数值为

$$l(\hat{\mu}, \dots, \hat{\mu}, \hat{\sigma}') = -n \log \sqrt{2\pi} - \frac{n}{2} \log(\hat{\sigma}'^2) - \frac{n}{2}.$$

于是计算出

$$\chi_L^2 = 2 \{l(\hat{\mu}_1, \dots, \hat{\mu}_r, \hat{\sigma}) - l(\hat{\mu}, \dots, \hat{\mu}, \hat{\sigma}')\} = n \log(\hat{\sigma}'^2 / \hat{\sigma}^2).$$

注意到

$$\hat{\sigma}^2 = \frac{1}{n} S_E, \quad \hat{\sigma}'^2 = \frac{1}{n} S_T = \frac{1}{n} (S_E + S_A),$$

所以

$$\chi_L^2 = n \log \left(1 + \frac{S_A}{S_E} \right).$$

而 $\{\chi_L^2 \geq c\}$ 等价于 $\{S_A/S_E \geq c'\}$. 经过证明 F -统计量

$$F = \frac{S_A/(r-1)}{S_E/(n-r)}$$

在 H_0 下的分布为 $F(r-1, n-r)$, 我们得到最终的 (精确) 拒绝域 $\{F \geq F_\alpha(r-1, n-r)\}$. 若用渐进理论, 还可以得到一个近似拒绝域 $\{\chi_L^2 \geq \chi_\alpha^2(r-1)\}$.

定理 (Hogg Theorem 6.5.1) 假设 $X_1, \dots, X_n$ 为i.i.d., 具有p.d.f. $f(x; \boldsymbol{\theta})$, 其中 $\boldsymbol{\theta} \in \Omega \subset \mathbb{R}^p$. 假设技术性条件成立. 让 $\hat{\boldsymbol{\theta}}$ 为似然方程 (即关于 $\boldsymbol{\theta}$ 的偏导为0) 的解, 且为 $\boldsymbol{\theta}$ 的一致估计. 让 $\hat{\boldsymbol{\theta}}_0$ 为在含 q 个约束

的 ω 中似然方程的解，且为 θ 的一致估计。若 Λ 为LRT统计量，则在 H_0 下，

$$-2 \log \Lambda \xrightarrow{D} \chi^2(q).$$

例 (总统选举) 假设总统选举中有 $k = 3$ 位候选人。民意调查中，每个被调查者能且仅能提交一位支持的候选人，且问卷之间互相独立。用 $\mathbf{X} = (X_1, X_2)^\top$ 表示问卷总体，其中 $X_j = I_{\{\text{被调查者支持候选人 } j\}}$ ， $j = 1, 2$ 。则p.m.f.为

$$f(\mathbf{x}; \mathbf{p}) = p_1^{x_1} p_2^{x_2} (1 - p_1 - p_2)^{1-x_1-x_2},$$

其中 $x_i = 0, 1$ ， $i = 1, 2$ ， $x_1 + x_2 \leq 1$ 。参数 $\mathbf{p} = (p_1, p_2)^\top \in \Omega = \{(p_1, p_2) : 0 < p_i < 1, i = 1, 2, p_1 + p_2 < 1\}$ 。

用 $\mathbf{X}_1 = (X_{11}, X_{21})^\top, \dots, \mathbf{X}_n = (X_{1n}, X_{2n})^\top$ 表示问卷样本。考虑检验

$$H_0 : p_1 = p_2 \text{ vs } H_1 : p_1 \neq p_2.$$

在 Ω 中极大似然估计为 $\hat{p}_j = T_j/n$ ，其中 $T_j = \sum_{i=1}^n X_{ji}$ ， $j = 1, 2$ 。则

$$l(\hat{\Omega}) = T_1 \log \hat{p}_1 + T_2 \log \hat{p}_2 + (n - T_1 - T_2) \log(1 - \hat{p}_1 - \hat{p}_2).$$

在 H_0 之下，用 p 表示 p_1 与 p_2 的共同值，则p.m.f.化为

$$f(\mathbf{x}; p) = p^{x_1+x_2} (1 - 2p)^{1-x_1-x_2}.$$

而对数似然函数化为

$$l(p) = (T_1 + T_2) \log p + (n - T_1 - T_2) \log(1 - 2p).$$

极大似然估计为

$$\hat{p} = \frac{1}{2n}(T_1 + T_2) = \frac{1}{2}(\hat{p}_1 + \hat{p}_2).$$

其中 $\hat{p}_1, \hat{p}_2$ 为 Ω 下的MLE。则

$$l(\hat{\omega}) = (T_1 + T_2) \log \left(\frac{\hat{p}_1 + \hat{p}_2}{2} \right) + (n - T_1 - T_2) \log(1 - \hat{p}_1 - \hat{p}_2).$$

可以算出

$$\chi_L^2 = 2 \left\{ l(\hat{\Omega}) - l(\hat{\omega}) \right\} = 2T_1 \log \left(\frac{2\hat{p}_1}{\hat{p}_1 + \hat{p}_2} \right) + 2T_2 \log \left(\frac{2\hat{p}_2}{\hat{p}_1 + \hat{p}_2} \right).$$

则渐进显著水平为 α 的拒绝域为 $\{\chi_L^2 > \chi_\alpha^2(1)\}$ 。 $\square$