



第十二讲 充分统计量的定义与性质

袁洪松

内容概要:

充分统计量的定义与性质

预习内容:

Hogg Sections 7.1, 7.2, 7.3

1 最小方差无偏估计量

定义 (最小方差无偏估计量, **minimum variance unbiased estimator, MVUE**) 对于给定的 n , 称 $Y = u(X_1, \dots, X_n)$ 为 θ 的最小方差无偏估计量, 如果 Y 的方差小于等于 θ 的任何其它无偏估计量的方差。

注意: 有效估计量一定是MVUE, 但反之不一定。

2 充分统计量

数据简化(**data reduction**)的想法: 能否用统计量 $Y_1 = u_1(X_1, \dots, X_n)$ 来代替原数据 $X_1, X_2, \dots, X_n$?

的确, 根据 Y_1 的值可以将原数据的取值空间划分成不同的集合。例如, $Y_1 = \bar{X}$, 令 $\bar{X} = 2.38$ 就可以挑出原数据的一个集合

$$\{(X_1, \dots, X_n) : (X_1 + \dots + X_n)/n = 2.38\}.$$

我们希望把所有这个集合里的样本都等同看待。

关于参数 θ 的统计推断 (即估计与检验) 中, 是可以这样做的, 但要求 Y_1 包含了关于 θ 全部信息。

例 (**Bernoulli分布**) $X_1, \dots, X_n$ 取自成功概率为 θ 的Bernoulli分布。其p.m.f.为

$$f(x; \theta) = \theta^x (1 - \theta)^{1-x}, x = 0, 1.$$

统计量 $Y_1 = \sum_{i=1}^n X_i$ 服从 $\text{Bin}(n, \theta)$, 具有p.m.f.

$$f_{Y_1}(y_1; \theta) = \binom{n}{y_1} \theta^{y_1} (1 - \theta)^{n-y_1}.$$

为考察 Y_1 是否包含了关于 θ 的全部信息，我们看 $X_1, \dots, X_n$ 在给定 $Y_1 = y_1$ 时的分布。这需要计算条件概率

$$P(X_1 = x_1, \dots, X_n = x_n | Y_1 = y_1).$$

按照贝叶斯公式，

$$P(X_1 = x_1, \dots, X_n = x_n | Y_1 = y_1) = \frac{P(X_1 = x_1, \dots, X_n = x_n, Y_1 = y_1)}{P(Y_1 = y_1)}.$$

分两种情况考虑：

情况一： $y_1 = \sum_{i=1}^n x_i$ 。那么

$$\begin{aligned} \frac{P(X_1 = x_1, \dots, X_n = x_n, Y_1 = y_1)}{P(Y_1 = y_1)} &= \frac{P(X_1 = x_1, \dots, X_n = x_n)}{P(Y_1 = y_1)} \\ &= \frac{f(x_1; \theta) \cdots f(x_n; \theta)}{f_{Y_1}(y_1; \theta)} \\ &= \frac{\theta^{x_1} (1 - \theta)^{1-x_1} \cdots \theta^{x_n} (1 - \theta)^{1-x_n}}{\binom{n}{y_1} \theta^{y_1} (1 - \theta)^{n-y_1}} \\ &= \frac{\theta^{\sum_{i=1}^n x_i} (1 - \theta)^{n - \sum_{i=1}^n x_i}}{\binom{n}{\sum_{i=1}^n x_i} \theta^{\sum_{i=1}^n x_i} (1 - \theta)^{n - \sum_{i=1}^n x_i}} \\ &= \frac{1}{\binom{n}{\sum_{i=1}^n x_i}} \end{aligned}$$

情况二： $y_1 \neq \sum_{i=1}^n x_i$ 。那么

$$\frac{P(X_1 = x_1, \dots, X_n = x_n, Y_1 = y_1)}{P(Y_1 = y_1)} = 0$$

在两种情况下，概率 $P(X_1 = x_1, \dots, X_n = x_n | Y_1 = y_1)$ 都与 θ 无关。即 $(X_1 = x_1, \dots, X_n = x_n) | (Y_1 = y_1)$ 的分布与 θ 无关。

定义(充分统计量) 若 $Y_1 = u_1(X_1, \dots, X_n)$ 为p.d.f.或p.m.f.是 $f_{Y_1}(y; \theta)$ 的统计量。称 Y_1 为充分统计量，如果

$$\frac{f(x_1; \theta) \cdots f(x_n; \theta)}{f_{Y_1}\{u_1(x_1, \dots, x_n); \theta\}} = H(x_1, \dots, x_n),$$

其中 $H(x_1, \dots, x_n)$ 不依赖于 θ 。

说明：

- 1) 上述条件即表示 $X_1, X_2, \dots, X_n | Y_1$ 的分布与 θ 无关。
- 2) 若 Y_1 为充分统计量，则对于任意其它统计量 $Y_2 = u_2(X_1, \dots, X_n)$ 来说， $Y_2 | Y_1 = y_1$ 的分布与 θ 无关。这表示 Y_2 不包含除 Y_1 以外关于 θ 的任何信息。换句话说， Y_1 包含了关于 θ 的所有信息。

例 (gamma分布) $X_1, \dots, X_n$ 取自gamma分布 $\Gamma(2, \theta), \theta > 0$ 。p.d.f.为

$$f(x; \theta) = \frac{1}{\Gamma(2)\theta^2} x e^{-x/\theta}, \quad x > 0.$$

统计量 $Y_1 = \sum_{i=1}^n X_i$ 服从 $\Gamma(2n, \theta)$ 分布，具有p.d.f.

$$f_{Y_1}(y_1; \theta) = \frac{1}{\Gamma(2n)\theta^{2n}} y_1^{2n-1} e^{-y_1/\theta}.$$

可以算出

$$\frac{f(x_1; \theta) \cdots f(x_n; \theta)}{f_{Y_1}\{u_1(x_1, \dots, x_n); \theta\}} = \frac{\prod_{i=1}^n \frac{1}{\Gamma(2)\theta^2} x_i e^{-x_i/\theta}}{\frac{1}{\Gamma(2n)\theta^{2n}} \sum_{i=1}^n x_i^{2n-1} e^{-\sum_{i=1}^n x_i/\theta}} = \frac{\Gamma(2n)}{\Gamma(2)^n} \cdot \frac{x_1 \cdots x_n}{\sum_{i=1}^n x_i^{2n-1}}$$

它与 θ 无关，所以 Y_1 为充分统计量。□

例 $X_1, \dots, X_n$ 有p.d.f.

$$f(x; \theta) = e^{-(x-\theta)}, x > \theta,$$

也可以写成

$$f(x; \theta) = e^{-(x-\theta)} I_{\{x \in (\theta, +\infty)\}}.$$

让 $Y_1 = \min_{1 \leq i \leq n} \{X_i\}$ 。可以算出

$$\begin{aligned} 1 - F_{Y_1}(y_1) &= P(Y_1 > y_1) = P(\min\{X_1, \dots, X_n\} > y_1) \\ &= P(X_1 > y_1, \dots, X_n > y_1) \\ &= \prod_{i=1}^n P(X_i > y_1) \\ &= \prod_{i=1}^n e^{-(y_1-\theta)} = e^{-n(y_1-\theta)}. \end{aligned}$$

所以 Y_1 的p.d.f.为

$$f_{Y_1}(y_1) = F'_{Y_1}(y_1) = n e^{-n(y_1-\theta)} I_{\{y_1 \in (\theta, +\infty)\}}.$$

于是可得

$$\begin{aligned} \frac{f(x_1; \theta) \cdots f(x_n; \theta)}{f_{Y_1}\{u_1(x_1, \dots, x_n); \theta\}} &= \frac{\prod_{i=1}^n e^{-(x_i-\theta)} I_{\{x_i \in (\theta, +\infty)\}}}{n e^{-n(\min x_i - \theta)} I_{\{\min x_i \in (\theta, +\infty)\}}} \\ &= \frac{e^{-\sum_{i=1}^n x_i + n\theta} I_{\{\min x_i \in (\theta, +\infty)\}}}{n e^{-n \min x_i + n\theta} I_{\{\min x_i \in (\theta, +\infty)\}}} \\ &= \frac{e^{-\sum_{i=1}^n x_i}}{n e^{-n \min x_i}}, \end{aligned}$$

它与 θ 无关，所以 Y_1 为充分统计量。

3 Neyman分解定理

定理 (Neyman分解定理, Hogg Theorem 7.2.1) 让 $X_1, \dots, X_n$ 为p.d.f.或p.m.f.为 $f(x; \theta)$ 的样本。统计量 $Y_1 = u_1(X_1, \dots, X_n)$ 为 θ 的充分统计量, 当且仅当我们能找到两个非负函数 k_1 和 k_2 , 使得

$$f(x_1; \theta) \cdots f(x_n; \theta) = k_1 \{u_1(x_1, \dots, x_n); \theta\} \cdot k_2(x_1, \dots, x_n),$$

其中 $k_2(x_1, \dots, x_n)$ 不依赖于 θ 。 $\square$

例 (正态分布) $X_1, \dots, X_n$ 为正态分布 $N(\theta, \sigma_0^2)$ 的样本, σ_0 已知。

可以求得

$$\begin{aligned} f(x_1; \theta) \cdots f(x_n; \theta) &= \left(\frac{1}{\sigma_0 \sqrt{2\pi}} \right)^n \exp \left\{ -\frac{1}{2\sigma_0^2} \sum_{i=1}^n (x_i - \theta)^2 \right\} \\ &= \left(\frac{1}{\sigma_0 \sqrt{2\pi}} \right)^n \exp \left[-\frac{1}{2\sigma_0^2} \left\{ \sum_{i=1}^n (x_i - \bar{x})^2 + n(\bar{x} - \theta)^2 \right\} \right] \\ &= \left(\frac{1}{\sigma_0 \sqrt{2\pi}} \right)^n \exp \left\{ -\frac{n(\bar{x} - \theta)^2}{2\sigma_0^2} \right\} \exp \left\{ -\frac{1}{2\sigma_0^2} \sum_{i=1}^n (x_i - \bar{x})^2 \right\} \end{aligned}$$

则 $Y_1 = \bar{X}$ 为充分统计量。 $\square$

例 $X_1, \dots, X_n$ 有p.d.f.

$$f(x; \theta) = \theta x^{\theta-1}, \quad 0 < x < 1.$$

可以求得

$$f(x_1; \theta) \cdots f(x_n; \theta) = \theta^n \left(\prod_{i=1}^n x_i \right)^{\theta} \frac{1}{\prod_{i=1}^n x_i}.$$

则 $Y_1 = \prod_{i=1}^n X_i$ 为充分统计量。 $\square$

例 $X_1, \dots, X_n$ 有p.d.f.

$$f(x, \theta) = e^{-(x-\theta)} I_{\{x \in (\theta, +\infty)\}}.$$

可以求得

$$f(x_1, \theta) \cdots f(x_n; \theta) = \prod_{i=1}^n e^{-(x_i - \theta)} I_{\{x_i \in (\theta, +\infty)\}} = e^{n\theta} I_{\{\min x_i \in (\theta, +\infty)\}} e^{-\sum_{i=1}^n x_i}.$$

则 $Y_1 = \min_{1 \leq i \leq n} X_i$ 为充分统计量。

4 充分统计量的性质

首先, 充分统计量并非唯一。如果 $Y_1 = u_1(X_1, \dots, X_n)$ 为 θ 的充分统计量, 并且 $Y_2 = g(Y_1)$, 其中 $g(\cdot)$ 为一对一的函数(即可逆函数), 则

$$f(x_1; \theta) \cdots f(x_n; \theta) = k_1 \{u_1(y_1); \theta\} \cdot k_2(x_1, \dots, x_n) = k_1 [u_1 \{g^{-1}(y_2)\}; \theta] \cdot k_2(x_1, \dots, x_n).$$

于是 Y_2 也是充分统计量 (根据Neyman分解定理)。

引理 (Hogg Theorem 2.3.1) 若 X_1 与 X_2 为随机变量, 且 X_2 方差存在。则

$$E(X_2) = E\{E(X_2|X_1)\},$$

且

$$\text{Var}(X_2) \geq \text{Var}\{E(X_2|X_1)\}.$$

定理 (Rao-Blackwell, Hogg Theorem 7.3.1) 让 $X_1, \dots, X_n$ 为 p.d.f. 或 p.m.f. 为 $f(x; \theta)$ 的样本, n 为固定整数。让 $Y_1 = u_1(X_1, \dots, X_n)$ 为 θ 的充分统计量, $Y_2 = u_2(X_1, \dots, X_n)$ 是 θ 的无偏估计量。那么 $E(Y_2|Y_1 = y_1) = \varphi(y_1)$ 定义了一个统计量 $\varphi(Y_1)$ 。此统计量为 θ 的充分统计量的函数; 为 θ 的无偏估计; 且它的方差小于等于 Y_2 的方差。

证明: 因为 Y_1 为充分统计量, 所以条件分布 $(X_1 = x_1, \dots, X_n = x_n)|(Y_1 = y_1)$ 与 θ 无关, 从而条件期望 $E(Y_2|Y_1 = y_1)$ 与 θ 无关。故 $\varphi(y_1)$ 为统计量 Y_1 的函数。

根据引理2.3.1得到

$$E\{\varphi(Y_1)\} = E\{E(Y_2|Y_1)\} = E(Y_2) = \theta.$$

再根据引理2.3.1, 得到

$$\text{Var}\{\varphi(Y_1)\} = \text{Var}\{E(Y_2|Y_1)\} \leq \text{Var}(Y_2). \quad \square$$

说明: 为什么要求 Y_1 为充分统计量? 因为不然 $\varphi(y_1)$ 可能依赖于 θ , 而 $\varphi(Y_1)$ 就不是统计量了。例如: $X_1, \dots, X_n \sim N(\mu, \sigma_0^2)$, σ_0 已知。让 $Y_1 = X_1, Y_2 = X_2$, 则 $\varphi(Y_1) = E(X_2|X_1) = E(X_2) = \mu$, 并非统计量。

定理 (唯一性) 若 θ 的 MVUE 存在, 则它是唯一的。(这里“唯一”是几乎必然意义上的唯一。即, 若有 Z 与 Z' 都为 θ 的 MVUE, 那么 $Z = Z'$ 几乎必然成立。)

证明: 假设 Z 与 Z' 都为 θ 的 MVUE。那么有 $E(Z) = E(Z') = \theta$, $\text{Var}(Z) = \text{Var}(Z')$ 。对任意实数 λ , 构造 $Z(\lambda) = Z + \lambda(Z' - Z)$, 那么

$$E\{Z(\lambda)\} = E(Z) + \lambda E(Z' - Z) = \theta,$$

因此 $Z(\lambda)$ 也为 θ 的无偏估计。根据 Z 为 MVUE,

$$\text{Var}(Z) \leq \text{Var}\{Z(\lambda)\} = \text{Var}(Z) + 2\lambda \text{Cov}(Z, Z' - Z) + \lambda^2 \text{Var}(Z' - Z),$$

于是

$$\lambda^2 \text{Var}(Z' - Z) + 2\lambda \text{Cov}(Z, Z' - Z) \geq 0.$$

此不等式需对所有实数 λ 均成立 (注意到左边是关于 λ 的二次函数), 因而要求 $\text{Cov}(Z, Z' - Z) = 0$ 。同理可得 (通过构造 $Z'(\lambda) = Z' + \lambda(Z - Z')$, 然后使用类似的推导), $\text{Cov}(Z', Z - Z') = 0$ 。因此,

$$\text{Var}(Z - Z') = \text{Cov}(Z - Z', Z - Z') = \text{Cov}(Z, Z - Z') + \text{Cov}(Z', Z' - Z) = 0.$$

最后我们得到, $Z - Z' = 0$ 几乎必然成立。 $\square$

说明: Rao-Blackwell定理与唯一性定理结合起来表明, 若充分统计量存在, 则MVUE必为它的函数。因为对任一无偏估计 Y_2 , 可以计算 $\varphi(Y_1) = E(Y_2|Y_1 = y_1)$, 则 $\varphi(Y_1)$ 为方差不超过 Y_2 的无偏估计量。

例 (Poisson分布) $X_1, \dots, X_n$ 服从 $\text{Po}(\lambda)$ 分布。因为

$$L(\theta, \mathbf{X}) = \prod_{i=1}^n \frac{\lambda^{X_i}}{X_i!} e^{-\lambda} = \lambda^{\sum_{i=1}^n X_i} e^{-n\lambda} \frac{1}{\prod_{i=1}^n X_i!},$$

故 $Y_1 = \sum_{i=1}^n X_i$ 为充分统计量。

显然, $Y_2 = X_1$ 为 λ 的无偏估计, 方差为 λ 。现在让

$$\varphi(y_1) = E(Y_2|Y_1 = y_1) = E\left(X_1 \middle| \sum_{i=1}^n X_i = y_1\right).$$

因为

$$\sum_{i=1}^n E\left(X_i \middle| \sum_{i=1}^n X_i\right) = E\left(\sum_{i=1}^n X_i \middle| \sum_{i=1}^n X_i = y_1\right) = y_1,$$

由对称性得到 $\varphi(y_1) = y_1/n$ 。即 $\varphi(Y_1) = Y_1/n = \bar{X}$ 。它显然无偏, 且方差仅为 λ/n 。 $\square$

例 (Poisson分布, 估计 λ 的函数) $X_1, \dots, X_n$ 服从 $\text{Po}(\lambda)$ 分布, 要估计 $\theta = e^{-\lambda}$ 。

由于 $\theta = P(X = 0)$, 故 $Y_2 = I_{\{X_1=0\}}$ 为无偏估计。可以算得

$$\begin{aligned} \varphi(y_1) &= E(Y_2|Y_1 = y_1) = P\left(X_1 = 0 \middle| \sum_{i=1}^n X_i = y_1\right) \\ &= \frac{P(X_1 = 0, \sum_{i=1}^n X_i = y_1)}{P(\sum_{i=1}^n X_i = y_1)} = \frac{P(X_1 = 0, \sum_{i=2}^n X_i = y_1)}{P(\sum_{i=1}^n X_i = y_1)} \\ &= \frac{e^{-\lambda} \{(n-1)\lambda\}^{y_1} \cdot e^{-(n-1)\lambda}/y_1!}{(n\lambda)^{y_1} e^{-n\lambda}/y_1!} = \left(\frac{n-1}{n}\right)^{y_1}. \end{aligned}$$

故 $\varphi(Y_1) = \left(\frac{n-1}{n}\right)^{\sum_{i=1}^n X_i}$, 为一个方差更小的无偏估计。 $\square$

例 (均匀分布) $X_1, \dots, X_n$ 服从 $[0, \theta]$ 上的均匀分布。

由于

$$L = \prod_{i=1}^n \frac{1}{\theta} I_{\{X_i \in [0, \theta]\}} = \frac{1}{\theta^n} I_{\{\max X_i \in (0, \theta)\}}$$

故 $Y_1 = \max X_i$ 为充分统计量。

由于 $E(X_1) = \theta/2$, 所以 $Y_2 = 2X_1$ 为无偏估计。可以算得

$$\varphi(y_1) = E(2X_1 | Y_1 = y_1) = 2 \left\{ \frac{1}{n} y_1 + \left(1 - \frac{1}{n}\right) \frac{y_1}{2} \right\} = \frac{n+1}{n} y_1.$$

(理由: X_1 有 $\frac{1}{n}$ 的概率为最大。而当它不是最大时, 其期望值为最大值的一半。)

故 $\varphi(Y_1) = (n+1) \max X_i / n$, 为一个方差更小的无偏估计。 $\square$

定理 (Hogg 7.3.2) 让 $X_1, \dots, X_n$ 为有 p.d.f. 或 p.m.f. $f(x; \theta)$ 的样本。如果 θ 的充分统计量 $Y_1 = u_1(X_1, \dots, X_n)$ 存在, 并且 θ 的极大似然估计 $\hat{\theta}$ 存在且唯一, 则 $\hat{\theta}$ 为 $Y_1 = u_1(X_1, \dots, X_n)$ 的函数。

证明: 让 $f_{Y_1}(y_1)$ 为 Y_1 的 p.d.f. 或 p.m.f.。根据充分统计量的定义, 似然函数可写为

$$L(\theta; \mathbf{X}) = f(X_1; \theta) \cdots f(X_n, \theta) = f_{Y_1}\{u_1(X_1, \dots, X_n); \theta\} \cdot H(X_1, \dots, X_n),$$

其中 $H(X_1, \dots, X_n)$ 不依赖于 θ 。 $\hat{\theta}$ 最大化 $L(\theta; X_1, \dots, X_n)$, 则 $\hat{\theta}$ 最大化 $f_{Y_1}\{u_1(X_1, \dots, X_n); \theta\}$ 。由于只有一个最优解 $\hat{\theta}$, 那么 $\hat{\theta}$ 一定为 $u_1(X_1, \dots, X_n)$ 的函数。 $\square$

例 (指数分布) $X_1, \dots, X_n$ 为来自 $\text{Exp}(\theta)$ 分布的样本, 其 p.d.f. 为

$$f(x; \theta) = \theta e^{-\theta x}, x > 0.$$

似然函数为

$$L(\theta; \mathbf{X}) = \theta^n e^{-\theta \sum_{i=1}^n X_i},$$

故 $Y_1 = \sum_{i=1}^n X_i$ 为充分统计量。又知 θ 的 MLE 为 $Y_2 = 1/\bar{X}$, 的确为 Y_1 的函数, 印证定理 7.3.2。

为了计算 $E(Y_2)$, 我们有 $Y_1 \sim \Gamma(n, 1/\theta)$ 。可以算出

$$E(Y_2) = nE\left(\frac{1}{Y_1}\right) = \frac{n}{n-1}\theta.$$

于是, $(n-1)Y_2/n = (n-1)/\sum_{i=1}^n X_i$ 为 θ 的无偏估计。(暂时还无法推断它为 MVUE, 下一讲再讲。)

$\square$

例 (指数分布, 另一种参数表示) $X_1, \dots, X_n$ 为 $\text{Exp}(1/\theta)$, 其 p.d.f. 为

$$f(x; \theta) = \frac{1}{\theta} e^{-x/\theta}, x > 0.$$

似然函数为

$$L(\theta, \mathbf{X}) = \frac{1}{\theta^n} e^{-\sum_{i=1}^n X_i/\theta},$$

故 $Y_1 = \sum_{i=1}^n X_i$ 为充分统计量。又 θ 的MLE为 $\bar{X} = Y_1/n$ ，是 Y_1 的函数，且为 θ 的无偏估计。
其实，由于 $\bar{X}$ 的方差达到了RCB，它即为MVUE。 $\square$