



第十四讲 参数的函数，多参数情形，最小充分性与从属统计量

袁洪松

内容概要：

参数的函数，多参数情形，最小充分性与从属统计量

预习内容：

Hogg Sections 7.6, 7.7, 7.8

1 参数的函数

问题：如何找到参数 θ 的一个函数 $g(\theta)$ 的MVUE?

两种方法：

1) 直接计算完备充分统计量 Y_1 的某一函数的期望值，有必要的话再纠偏。(Lehmann-Scheffe定理)

2) 先找到一个无偏统计量 Y_2 ，再计算 $E(Y_2|Y_1)$ 。(Rao-Blackwell定理)

例(Bernoulli分布) 设 $X_1, \dots, X_n \sim \text{Bernoulli}(\theta)$ 。要寻找 $\delta = \theta(1 - \theta)$ 的MVUE。

首先，一个完备充分统计量为 $Y = \sum_{i=1}^n X_i$ 。

我们先用Lehmann-Scheffe定理去求。可以知道， δ 的MLE为 $\tilde{\delta} = (1 - Y/n)Y/n$ 。试计算

$$\begin{aligned} E(\tilde{\delta}) &= \frac{1}{n}E(Y) - \frac{1}{n^2}E(Y^2) \\ &= \frac{1}{n}n\theta - \frac{1}{n^2}\{(n\theta)^2 + n\theta(1 - \theta)\} \\ &= \frac{n-1}{n}\theta(1 - \theta). \end{aligned}$$

于是， $\hat{\delta} = n\tilde{\delta}/(n-1)$ 为 δ 的MVUE。 □

我们再用Rao-Blackwell定理去求。我们知道 $X_1 + X_2 \sim \text{Bin}(2, \theta)$ ，因此 $P(X_1 + X_2 = 1) = 2\theta(1 - \theta)$ 。

我们让

$$Y_2 = \frac{1}{2}I_{\{X_1 + X_2 = 1\}},$$

则 Y_2 为 $\theta(1-\theta)$ 的无偏估计。下面计算

$$\begin{aligned} E(Y_2 | Y = y) &= \frac{1}{2} P(X_1 + X_2 = 1 | Y = y) \\ &= \frac{1}{2} \frac{P(X_1 + X_2 = 1, Y = y)}{P(Y = y)} \\ &= \frac{1}{2} \frac{P(X_1 + X_2 = 1, \sum_{i=3}^n X_i = y-1)}{P(Y = y)}. \end{aligned}$$

由于 $X_1 + X_2 \sim \text{Bin}(2, \theta)$, $\sum_{i=3}^n X_i \sim \text{Bin}(n-2, \theta)$, $\sum_{i=1}^n X_i \sim \text{Bin}(n, \theta)$, 我们得到

$$\begin{aligned} E(Y_2 | Y = y) &= \frac{1}{2} \frac{2\theta(1-\theta) \cdot \binom{n-2}{y-1} \theta^{y-1} (1-\theta)^{n-y-1}}{\binom{n}{y} \theta^y (1-\theta)^{n-y}} \\ &= \frac{\binom{n-2}{y-1}}{\binom{n}{y}} = \frac{(n-2)!}{(y-1)!(n-y-1)!} \cdot \frac{y!(n-y)!}{n!} \\ &= \frac{y(n-y)}{n(n-1)}. \end{aligned}$$

根据Rao-Blackwell定理, $\theta(1-\theta)$ 的MVUE为

$$\frac{Y(n-Y)}{n(n-1)} = \hat{\delta}.$$

两种方法得到的MVUE一致。 $\square$

例(正态分布) 设 $X_1, \dots, X_n \sim N(\theta, 1)$ 。要寻找 θ^2 的MVUE。首先, θ 的一个完备充分统计量为 $\bar{X}$ 。

我们先用Lehmann-Shceffe定理来求。可以知道, $E(\bar{X})$ 为 θ 的无偏估计。又可以计算出

$$E(\bar{X}^2) = (E\bar{X})^2 + \text{Var}(\bar{X}) = \theta^2 + 1/n.$$

于是 $\bar{X}^2 - 1/n$ 为 θ^2 的无偏估计量。它即为MVUE。

再用Rao-Blackwell定理去求。由于 $E(X_1^2) = (EX_1^2) + \text{Var}(X_1) = \theta^2 + 1$, 所以 $Y_2 = X_1^2 - 1$ 为 θ^2 的一个无偏估计。

为计算 $E(Y_2|\bar{X})$, 考虑 $(X_1, \bar{X})$ 的联合分布。由于

$$\begin{bmatrix} X_1 \\ \bar{X} \end{bmatrix} = \begin{bmatrix} 1 & 0 & \cdots & 0 \\ \frac{1}{n} & \frac{1}{n} & \cdots & \frac{1}{n} \end{bmatrix} \begin{bmatrix} X_1 \\ \vdots \\ X_n \end{bmatrix},$$

根据多元正态分布的性质, $(X_1, \bar{X})^\top$ 为二元正态分布, 且 (参考第一周课件“多元正态分布”部分)

$$E \begin{bmatrix} X_1 \\ \bar{X} \end{bmatrix} = \begin{bmatrix} 1 & 0 & \cdots & 0 \\ \frac{1}{n} & \frac{1}{n} & \cdots & \frac{1}{n} \end{bmatrix} \begin{bmatrix} \theta \\ \vdots \\ \theta \end{bmatrix} = \begin{bmatrix} \theta \\ \theta \end{bmatrix},$$

$$\begin{aligned} \text{Cov} \begin{bmatrix} X_1 \\ \bar{X} \end{bmatrix} &= \begin{bmatrix} 1 & 0 & \cdots & 0 \\ \frac{1}{n} & \frac{1}{n} & \cdots & \frac{1}{n} \end{bmatrix} \cdot \text{Cov} \begin{bmatrix} X_1 \\ \vdots \\ X_n \end{bmatrix} \cdot \begin{bmatrix} 1 & 0 & \cdots & 0 \\ \frac{1}{n} & \frac{1}{n} & \cdots & \frac{1}{n} \end{bmatrix}^\top \\ &= \begin{bmatrix} 1 & 0 & \cdots & 0 \\ \frac{1}{n} & \frac{1}{n} & \cdots & \frac{1}{n} \end{bmatrix} \cdot I \cdot \begin{bmatrix} 1 & 0 & \cdots & 0 \\ \frac{1}{n} & \frac{1}{n} & \cdots & \frac{1}{n} \end{bmatrix}^\top \\ &= \begin{bmatrix} 1 & \frac{1}{n} \\ \frac{1}{n} & \frac{1}{n} \end{bmatrix}. \end{aligned}$$

所以

$$\begin{bmatrix} X_1 \\ \bar{X} \end{bmatrix} \sim N \left(\begin{bmatrix} \theta \\ \theta \end{bmatrix}, \begin{bmatrix} 1 & \frac{1}{n} \\ \frac{1}{n} & \frac{1}{n} \end{bmatrix} \right).$$

进一步知道

$$\begin{aligned} f_{X_1|\bar{X}}(x_1|\bar{x}) &= \frac{f_{X_1, \bar{X}}(x_1, \bar{x})}{f_{\bar{X}}(\bar{x})} \quad (\text{条件密度, 参考Hogg Section 2.3}) \\ &= \frac{1}{2\pi \frac{1}{\sqrt{n}} \sqrt{1 - \frac{1}{n}}} \exp \left[-\frac{1}{2 \left(1 - \frac{1}{n}\right)} \left\{ (x_1 - \theta)^2 - 2(x_1 - \theta)(\bar{x} - \theta) + n(\bar{x} - \theta)^2 \right\} \right] \\ &\quad / \frac{\sqrt{n}}{\sqrt{2\pi}} \exp \left\{ -\frac{n}{2}(\bar{x} - \theta)^2 \right\} \\ &= \frac{1}{\sqrt{2\pi}} \sqrt{\frac{n}{n-1}} \exp \left\{ -\frac{n}{2(n-1)}(x_1 - \bar{x})^2 \right\}. \end{aligned}$$

所以, $X_1|\bar{X} = \bar{x}$ 的分布为 $N(\bar{x}, (n-1)/n)$ 。

于是

$$\begin{aligned} E(Y_2|\bar{X} = \bar{x}) &= E(X_1^2|\bar{X} = \bar{x}) - 1 \\ &= [E(X_1|\bar{X} = \bar{x})]^2 + \text{Var}(X_1|\bar{X} = \bar{x}) - 1 \\ &= \bar{x}^2 + \frac{n-1}{n} - 1 \\ &= \bar{x}^2 - \frac{1}{n}. \end{aligned}$$

于是 θ^2 的MVUE 为 $\bar{X}^2 - \frac{1}{n}$ 。

例(正态分布) 设 $X_1, \dots, X_n \sim N(\theta, 1)$ 。要寻找以下 θ 的函数的MVUE:

$$P(X \leq c) = \int_{-\infty}^c \frac{1}{\sqrt{2\pi}} e^{-(x-\theta)^2/2} dx = \Phi(c - \theta),$$

其中 c 是固定的常数, $\Phi(\cdot)$ 为标准正态分布的c.d.f.。

首先, 一个完备充分统计量为 $\bar{X}$ 。考虑函数 $u(x) = I_{\{x \in (-\infty, c]\}}$, 则

$$E\{u(X_1)\} = E(I_{\{X_1 \in (-\infty, c]\}}) = P(-\infty < X_1 \leq c) = \Phi(c - \theta),$$

即 $u(X_1)$ 是一个无偏估计量。

上例中已经计算出 $X_1 | \bar{X} = \bar{x}$ 的分布为 $N(\bar{x}, (n-1)/n)$ 。于是

$$\begin{aligned} E\{u(X_1) | \bar{X} = \bar{x}\} &= P\left\{N\left(\bar{x}, \frac{n-1}{n}\right) \leq c\right\} \\ &= P\left\{N(0, 1) \leq \sqrt{\frac{n}{n-1}}(c - \bar{x})\right\} \\ &= \Phi\left\{\sqrt{\frac{n}{n-1}}(c - \bar{x})\right\}. \end{aligned}$$

于是唯一的MVUE为

$$\Phi\left\{\sqrt{\frac{n}{n-1}}(c - \bar{X})\right\}.$$

例 (单个样本的Poisson分布) 设 $X_1 \sim \text{Po}(\theta)$, 仅有这1个样本。要寻找 $e^{-2\theta}$ 的MVUE。

首先, X_1 即为完备充分统计量。考虑 $Y = (-1)^{X_1}$, 则

$$E(Y) = \sum_{x=0}^{\infty} (-1)^x \frac{\theta^x e^{-\theta}}{x!} = e^{-\theta} \sum_{x=0}^{\infty} \frac{(-\theta)^x}{x!} = e^{-2\theta}.$$

于是, Y 即为 $e^{-2\theta}$ 的MVUE。

但是, 用 Y 来估计 $e^{-2\theta}$ 显然不够好。也许它还没有极大似然估计 e^{-2X_1} 好, 尽管极大似然估计是有偏的。

例 (均匀分布) 设 $X_1, \dots, X_n$ 服从 $[0, \theta]$ 上的均匀分布。要寻找 $g(\theta)$ 的MVUE, 其中 $g(\theta)$ 为某个可微函数。

首先, 一个完备充分统计量为 $Y = \max\{X_1, \dots, X_n\}$ (见上一讲的例子), 其p.d.f.为

$$f_Y(y; \theta) = \frac{ny^{n-1}}{\theta^n}, \quad 0 \leq y \leq \theta.$$

希望找到函数 $u(\cdot)$, 使得 $E\{u(Y)\} = g(\theta)$ 对任意 θ 成立, 即

$$g(\theta) = \int_0^\theta u(y) \frac{ny^{n-1}}{\theta^n} dy.$$

从而得到

$$\theta^n g(\theta) = \int_0^\theta u(y) n y^{n-1} dy.$$

两边对 θ 求导得

$$n\theta^{n-1}g(\theta) + \theta^n g'(\theta) = u(\theta)n\theta^{n-1}.$$

于是

$$u(\theta) = g(\theta) + \frac{\theta g'(\theta)}{n}.$$

所以, $g(\theta)$ 的MVUE为 $u(Y) = g(Y) + Yg'(Y)/n$. $\square$

2 多参数情形

定义 (联合充分统计量, jointly sufficient statistics) 假设 $X_1, \dots, X_n$ 有p.d.f或p.m.f $f(x; \theta)$, 其中 $\theta \in \Omega \subset \mathbb{R}^p$. 让 S 表示 X 的支撑集. 设 $\mathbf{Y} = (Y_1, \dots, Y_m)^\top$ 为 m 维统计量, 其中 $Y_i = u_i(x_1, \dots, x_n)$. 用 $f_{\mathbf{Y}}(y; \theta)$ 表示 $\mathbf{Y}$ 的联合p.d.f或p.m.f. 称 $\mathbf{Y}$ 为 θ 的联合充分统计量, 如果

$$\prod_{i=1}^n f(x_i; \theta) = f_{\mathbf{Y}}(\mathbf{y}; \theta) H(x_1, \dots, x_n), \quad x \in S,$$

其中 $H(x_1, \dots, x_n)$ 不依赖于 θ .

Neyman分解定理: $\mathbf{Y}$ 为联合充分统计量, 当且仅当

$$\prod_{i=1}^n f(x_i; \theta) = k_1(\mathbf{y}; \theta) k_2(x_1, \dots, x_n),$$

其中 $k_1(x_1, \dots, x_n)$ 不依赖于 θ .

例 设 $X_1, \dots, X_n$ 有p.d.f.

$$f(x; \theta_1, \theta_2) = \frac{1}{2\theta_2}, \quad \theta_1 - \theta_2 \leq x \leq \theta_1 + \theta_2,$$

其中 $-\infty < \theta_1 < \infty, 0 < \theta_2 < \infty$.

因为

$$\begin{aligned} \prod_{i=1}^n f(x_i; \theta_1, \theta_2) &= \prod_{i=1}^n \frac{1}{2\theta_2} I_{\{x_i \in [\theta_1 - \theta_2, \theta_1 + \theta_2]\}} \\ &= \frac{1}{(2\theta_2)^n} I_{\{\min x_i \in [\theta_1 - \theta_2, \theta_1 + \theta_2]\}} I_{\{\max x_i \in [\theta_1 - \theta_2, \theta_1 + \theta_2]\}}. \end{aligned}$$

于是 $\mathbf{Y} = (\min X_i, \max X_i)^\top$ 为联合充分统计量。 $\square$

例 设 $X_1, \dots, X_n \sim N(\theta, \theta^2)$, 其中 $-\infty < \theta < \infty$.

因为

$$\begin{aligned} \prod_{i=1}^n f(x_i; \theta) &= \prod_{i=1}^n \frac{1}{\sqrt{2\pi\theta^2}} \exp \left\{ -\frac{1}{2\theta^2} (X_i - \theta)^2 \right\} \\ &= \left(\frac{1}{\sqrt{2\pi\theta^2}} \right)^n \exp \left\{ -\frac{1}{2\theta^2} \sum_{i=1}^n X_i^2 + \frac{n}{\theta} \bar{X} - \frac{n}{2} \right\}, \end{aligned}$$

所以 $\mathbf{Y} = (\sum_{i=1}^n X_i^2, \bar{X})^\top$ 为联合充分统计量。 $\square$

完备性的定义: 设 $\mathbf{V} = (v_1, \dots, v_k)^\top$ 为统计量组成的向量, 分布属于分布族 $\{f(v_1 \dots v_k; \boldsymbol{\theta}) : \boldsymbol{\theta} \in \Omega\}$ 。若条件 “ $E\{u(V_1, \dots, V_k)\} = 0$ 对于每个 $\boldsymbol{\theta} \in \Omega$ 都成立” 要求 “对于每个 $\boldsymbol{\theta} \in \Omega$ 都有 $u(V_1, \dots, V_k) = 0$ 在除了一个概率为0的集合之外都成立”, 那么称 $\{f(v_1, \dots, v_k; \boldsymbol{\theta}) : \boldsymbol{\theta} \in \Omega\}$ 为一个完备族。

Lehmann-Scheffe定理: 若 $\mathbf{Y}$ 为完备充分统计量, $T(\mathbf{Y})$ 为 $\delta = g(\boldsymbol{\theta})$ 的无偏估计, 则 $T(\mathbf{Y})$ 为 δ 的MVUE。

3 指数分布类

定义 (指数分布类, exponential class) 设 X 有 p.d.f. 或 p.m.f. $f(x; \boldsymbol{\theta})$, 其中 $\boldsymbol{\theta} \in \Omega \subset \mathbb{R}^m$ 。支撑集记为 S , 在 X 为连续型随机变量时, $S = (a, b)$, 其中 a 或 b 可为 $-\infty$ 或 $+\infty$; 在 X 为离散型随机变量时, $S = \{a_1, a_2, \dots\}$ 。称 X 的分布属于 **指数分布类**, 如果

$$f(x; \boldsymbol{\theta}) = \exp \left\{ \sum_{j=1}^m p_j(\boldsymbol{\theta}) K_j(x) + H(x) + q(\boldsymbol{\theta}) \right\}, \quad x \in S.$$

称 X 的分布属于 **正则指数分布类**, (**regular exponential class**), 如果另外有

1. X 的支撑集 S 不依赖于 $\boldsymbol{\theta}$ 。
2. 空间 Ω 包含一个非空 m 维的开长方体。
3. $p_j(\boldsymbol{\theta})$ 为非平凡的连续函数, 且作为函数无关。
4. 如果 X 为连续型随机变量, 则 m 个导数 $K_j'(x)$, $j = 1, \dots, m$ 都在 $a < x < b$ 上连续, 且没有一个可以写成另外的其次线性函数。并且 $H(x)$ 为 $a < x < b$ 上的连续函数。
如果 X 为离散型随机变量, 则 $K_j(x)$, $j = 1, \dots, m$ 在 S 上为 x 的非平凡函数, 且没有一个可以写成另外的其次线性函数。

对指数分布类, 可以求出似然函数为

$$\prod_{i=1}^n f(X_i; \boldsymbol{\theta}) = \exp \left\{ \sum_{j=1}^m p_j(\boldsymbol{\theta}) \sum_{i=1}^n K_j(X_i) + nq(\boldsymbol{\theta}) \right\} \exp \left\{ \sum_{i=1}^n H(X_i) \right\}.$$

那么

$$Y_1 = \sum_{i=1}^n K_1(X_i), \quad \dots, \quad Y_m = \sum_{i=1}^n K_m(X_i)$$

为 $\boldsymbol{\theta}$ 的联合充分统计量。

可以证明, $\mathbf{Y} = (Y_1, \dots, Y_m)^\top$ 的联合p.d.f.或p.m.f.形如

$$R(\mathbf{y}) \exp \left\{ \sum_{j=1}^m p_j(\boldsymbol{\theta}) y_j + nq(\boldsymbol{\theta}) \right\}.$$

可以进一步证明, $\mathbf{Y}$ 为 $\boldsymbol{\theta}$ 的完备充分统计量。

例 (正态分布) 设 $X_1, \dots, X_n \sim N(\theta_1, \theta_2)$, 其中 $-\infty < \theta_1 < \infty$, $0 < \theta_2 < \infty$ 。

首先, 可以将p.d.f.写为

$$\begin{aligned} f(x; \theta_1, \theta_2) &= \frac{1}{\sqrt{2\pi\theta_2}} \exp \left\{ -\frac{1}{2\theta_2} (x - \theta_1)^2 \right\} \\ &= \exp \left\{ -\frac{1}{2\theta_2} x^2 + \frac{\theta_1}{\theta_2} x - \frac{\theta_1^2}{2\theta_2} - \log \sqrt{2\pi\theta_2} \right\}. \end{aligned}$$

可以知道, $S = (-\infty, \infty)$, $K_1 = x^2$, $K_2 = x$, $p_1(\boldsymbol{\theta}) = -1/(2\theta_2)$, $p_2(\boldsymbol{\theta}) = \theta_1/\theta_2$, $H(x) = 0$, $q(\boldsymbol{\theta}) = -\theta_1^2/(2\theta_2) - \log \sqrt{2\pi\theta_2}$. 所以属于指数分布类。于是可知, $Y_1 = \sum_{i=1}^n X_i^2$ 与 $Y_2 = \sum_{i=1}^n X_i$ 联合起来为完备充分统计量。

让

$$Z_1 = \frac{Y_2}{n} = \bar{X}, \quad Z_2 = \frac{Y_1 - Y_2^2/n}{n-1} = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2.$$

因为 $(Y_1, Y_2) \rightarrow (Z_1, Z_2)$ 为一一对应, 故 Z_1, Z_2 联合起来也为完备充分统计量。由于 $E(Z_1) = \theta_1$, $E(Z_2) = \theta_2$, 故 Z_1 为 θ_1 的MVUE, Z_2 为 θ_2 的MVUE。 $\square$

下面进一步考虑 $\mathbf{X}$ 为多维的情况。这里仅考虑正则指数分布类。假设 $\mathbf{X}$ 为 k 维随机向量, 其p.d.f.或p.m.f.为 $f(\mathbf{x}; \boldsymbol{\theta})$, 其中 $\boldsymbol{\theta} \in \Omega \subset \mathbb{R}^p$ 。让 S 为 $\mathbf{X}$ 的支撑集。如果 $f(\mathbf{x}; \boldsymbol{\theta})$ 形如

$$f(\mathbf{x}; \boldsymbol{\theta}) = \exp \left\{ \sum_{j=1}^m p_j(\boldsymbol{\theta}) K_j(\mathbf{x}) + H(\mathbf{x}) + q(\boldsymbol{\theta}) \right\},$$

就称 $\mathbf{X}$ 的分布属于指数分布类。如果此外 $p = m$, 支撑集 S 不依赖于 $\boldsymbol{\theta}$, 且与前面类似的正则条件成立,

则称 $\mathbf{X}$ 的分布展于正则指数分布类。

若 $\mathbf{X}_1, \dots, \mathbf{X}_n$ 为正则指数分布类中的样本，则统计量

$$Y_j = \sum_{i=1}^n K_j(\mathbf{X}_i), \quad j = 1, \dots, m$$

联合起来为 $\boldsymbol{\theta}$ 的完备充分统计量。假设希望估计 $\delta = g(\boldsymbol{\theta})$ 。如果 $T = h(\mathbf{Y})$ 对某个函数 $h(\cdot)$ 成立且 $E\{h(\mathbf{Y})\} = \delta$, 则 T 为 δ 的MVUE。

例 (多项分布) 假设一次试验在 k 个不同结果中会且仅会产生一个结果。每种结果产生的概率分别为 $p_1, \dots, p_k$ ($\sum_{i=1}^k p_j = 1$)。令 $X_j = I_{\{\text{试验生成第}j\text{种结果}\}}$, $j = 1, \dots, k$, 并让 $\mathbf{X} = (X_1, \dots, X_{k-1})^\top$ (X_k 完全由 $X_1, \dots, X_{k-1}$ 决定, 因为 $\sum_{j=1}^k X_j = 1$), $\mathbf{p} = (p_1, \dots, p_{k-1})^\top$ 。 $\mathbf{X}$ 的p.m.f.为

$$f(\mathbf{x}; \boldsymbol{\theta}) = \left(\prod_{i=1}^{k-1} p_i^{x_i} \right) \left(1 - \sum_{j=1}^{k-1} p_j \right)^{1 - \sum_{j=1}^{k-1} x_j},$$

其中参数 $\mathbf{p} \in \Omega = \left\{ (p_1, \dots, p_{k-1})^\top : 0 < p_j < 1, j = 1, \dots, k-1, \sum_{j=1}^{k-1} p_j < 1 \right\}$ 。现在记样本为 $\mathbf{X}_1, \dots, \mathbf{X}_n$, 其中 $\mathbf{X}_i = (X_{1i}, \dots, X_{k-1,i})^\top$ 。

首先, p.m.f.可以写成

$$\begin{aligned} f(\mathbf{x}; \mathbf{p}) &= \exp \left\{ \sum_{i=1}^{k-1} x_i \log p_i + \left(1 - \sum_{j=1}^{k-1} x_j \right) \log \left(1 - \sum_{j=1}^{k-1} p_j \right) \right\} \\ &= \exp \left\{ \sum_{i=1}^{k-1} x_i \log \left\{ \frac{p_i}{1 - \sum_{j=1}^{k-1} p_j} \right\} + \log \left(1 - \sum_{j=1}^{k-1} p_j \right) \right\}. \end{aligned}$$

故为正则指数分布类。并且完备充分统计量为

$$Y_j = \sum_{i=1}^n X_{ji}, \quad j = 1, \dots, k-1,$$

其中每个 Y_j 都是二项分布 $\text{Bin}(n, p_j)$, 故 $E(Y_j) = np_j$ 。则 p_j 的MVUE即为 Y_j/n 。

如果要找 $p_j p_\ell, j \neq \ell$ 的MVUE。注意到它的MLE为 $Y_j Y_\ell / n^2$, 所以我们试求 $E(Y_j Y_\ell / n^2)$ 。先利用一个

结论：给定 Y_ℓ , Y_j 为二项分布 $\text{Bin}\{n - Y_\ell, p_j/(1 - p_\ell)\}$ (参考Hogg 3.1节)。于是

$$\begin{aligned} E\left(\frac{1}{n^2} Y_j Y_\ell\right) &= \frac{1}{n^2} E\{E(Y_j Y_\ell | Y_\ell)\} \\ &= \frac{1}{n^2} E\{Y_\ell E(Y_j | Y_\ell)\} \\ &= \frac{1}{n^2} E\left\{Y_\ell (n - Y_\ell) \frac{p_j}{1 - p_\ell}\right\} \\ &= \frac{1}{n^2} \frac{p_j}{1 - p_\ell} E\{n Y_\ell - Y_\ell^2\} \\ &= \frac{n - 1}{n} p_j p_\ell. \end{aligned}$$

所以, $p_j p_\ell$ 的MVUE为 $n Y_j Y_\ell / (n - 1)$ 。 $\square$

例 (多元正态分布) 设 $X_1, \dots, X_n$ 为 k 元正态分布 $N(\boldsymbol{\mu}, \Sigma)$, 其p.d.f.为

$$f_{\mathbf{X}}(\mathbf{x}; \boldsymbol{\theta}) = \frac{1}{(\sqrt{2\pi})^k |\Sigma|^{1/2}} \exp\left\{-\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu})^\top \Sigma^{-1}(\mathbf{x} - \boldsymbol{\mu})\right\},$$

其中 $|\Sigma|$ 表示 Σ 的行列式。如果把未知参数 $\boldsymbol{\mu}, \Sigma$ 的元素全部排成一列, 参数个数为 $k + k(k + 1)/2$ 。

首先, p.d.f.可以写为

$$\begin{aligned} f_{\mathbf{X}}(\mathbf{x}; \boldsymbol{\theta}) &= \exp\left\{-\frac{1}{2}\mathbf{x}^\top \Sigma^{-1}\mathbf{x} + \boldsymbol{\mu}^\top \Sigma^{-1}\mathbf{x} - \frac{1}{2}\boldsymbol{\mu}^\top \Sigma^{-1}\boldsymbol{\mu} - \frac{1}{2}\log|\Sigma| - \frac{k}{2}\log(2\pi)\right\} \\ &= \exp\left\{-\frac{1}{2}\text{tr}(\mathbf{x}\mathbf{x}^\top \cdot \Sigma^{-1}) + \boldsymbol{\mu}^\top \Sigma^{-1}\mathbf{x} - \frac{1}{2}\boldsymbol{\mu}^\top \Sigma^{-1}\boldsymbol{\mu} - \frac{1}{2}\log|\Sigma| - \frac{k}{2}\log(2\pi)\right\}, \end{aligned}$$

故为正态指数分布类。并且完备充分统计量为

$$\mathbf{Y}_1 = \sum_{i=1}^n \mathbf{X}_i, \quad \mathbf{Y}_2 = \sum_{i=1}^n \mathbf{X}_i \mathbf{X}_i^T.$$

由于 $\mathbf{Y}_2$ 为 k 阶对称矩阵, 除去冗余的分量, $\mathbf{Y}_1, \mathbf{Y}_2$ 中总的统计量个数为 $k + k(k + 1)/2$, 与未知参数个数相等。

让 X_{ij} 表示 $\mathbf{X}_i$ 的第 j 个分量, 并让 $\bar{X}_j = \sum_{i=1}^n X_{ij} / n$ 。容易知道

$$E(\bar{X}_j) = E\left(\frac{1}{n} \sum_{i=1}^n X_{ij}\right) = \mu_j, \quad E\left\{\frac{1}{n-1} \sum_{i=1}^n (X_{ij} - \bar{X}_j)^2\right\} = \sigma_j^2.$$

所以 $\bar{X}_j$ 为 μ_j 的MVUE, $\sum_{i=1}^n (X_{ij} - \bar{X}_j)^2 / (n - 1)$ 为 σ_j^2 的MVUE。

4 最小充分性与从属统计量

从数据简化的角度, 保证充分性的前提下, 统计量数量越少越好。

例如：设 $X_1, \dots, X_n \sim N(\theta_1, \theta_2)$ 。已经证明， $\bar{X}$ 与 S^2 为联合充分统计量。而 $(X_1, \dots, X_n)^\top$ 本身亦为联合充分统计量。显然前者个数更少，更节省空间。

定义 (最小充分统计量, minimal sufficient statistic) 若一组联合充分统计量总是可以表示为其余任何一组联合充分统计量的函数，则称其为最小充分统计量。

问题：对于参数 $\theta \in \mathbb{R}^k$ ，最小充分统计量的维度是否一定为 k ？

答案：不一定。

例 (均匀分布) $X_1, \dots, X_n$ 服从 $[\theta - 1, \theta + 1]$ 上的均匀分布，p.d.f. 为

$$f(x, \theta) = \frac{1}{2} I_{\{x \in [\theta - 1, \theta + 1]\}}.$$

似然函数为

$$\prod_{i=1}^n \frac{1}{2} I_{\{X_i \in [\theta - 1, \theta + 1]\}} = \frac{1}{2^n} I_{\{\min X_i \in [\theta - 1, \theta + 1]\}} I_{\{\max X_i \in [\theta - 1, \theta + 1]\}}.$$

所以 $\min X_i$ 与 $\max X_i$ 为联合充分统计量，不可能再减少了。 $\square$

定理 7.3.2 表明，MLE 唯一存在时，它是充分统计量的函数。所以若 MLE 也为充分统计量，则它必为最小充分统计量。于是

- 1) $X_1, \dots, X_n \sim N(\theta, \sigma_0^2)$, σ_0 已知。MLE $\hat{\theta} = \bar{X}$ 为最小充分统计量。
- 2) $X_1, \dots, X_n \sim \text{Po}(\theta)$ 。MLE $\hat{\theta} = \bar{X}$ 为最小充分统计量。
- 3) $X_1, \dots, X_n \sim [0, \theta]$ 上的均匀分布。MLE $\hat{\theta} = \max X_i$ 为最小充分统计量。
- 4) $X_1, \dots, X_n \sim N(\theta_1, \theta_2)$ ，MLE $\hat{\theta}_1 = \bar{X}$ ， $\hat{\theta}_2 = (n-1)S^2/n$ 为联合最小充分统计量。

例 (均匀分布) $X_1, \dots, X_n$ 服从 $[\theta - 1, \theta + 1]$ 上的均匀分布。 $\min X_i$ 与 $\max X_i$ 为联合充分统计量。MLE 可为 $\min X_i$ 到 $\max X_i$ 之间的任何数。取 MLE: $\hat{\theta} = (\min X_i + \max X_i)/2$ ，但 $\hat{\theta}$ 并非一个充分统计量。
 $\square$

Lehmann and Scheffe (1950) 的结论：完备充分统计量必然是最小充分统计量，反之不一定。

“是最小充分统计量但不是完备充分统计量”的例子：在 $[\theta - 1, \theta + 1]$ 上的均匀分布中，让

$$u(y_1, y_2) = \frac{y_2 - y_1}{2} - \frac{n-1}{n+1},$$

则

$$E\{u(\min X_i, \max X_i)\} = \frac{1}{2} \{E(\max X_i) - E(\min X_i)\} - \frac{n-1}{n+1} = 0.$$

故 $(\min X_i, \max X_i)^\top$ 并非完备的。

定义 (从属统计量, **ancillary statistic**) 若统计量 Z 的分布与参数 θ 无关, 则称 Z 为从属统计量。

例 (正态分布) 设 $X_1, \dots, X_n \sim N(\theta, 1)$, 则

$$Z = S^2, \quad Z = X_2 - X_1, \quad Z = X_1 - \bar{X}$$

均为从属统计量。

例 (正态分布) 设 $X_1, \dots, X_n \sim N(0, \sigma^2)$, 则

$$Z = X_2/X_1, \quad Z = X_1/\bar{X}$$

均为从属统计量。