

大数定律与中心极限定理

第四章：大数定律与中心极限定理

一、这一章到底在研究什么

前三章你学的，大多还是“一个随机变量”或者“有限个随机变量”：

- 一个变量的分布、期望、方差；
- 两个变量的联合分布、边缘分布、协方差；
- 若干变量的和、差、函数分布。

第四章一下子把视角拉远了。它开始研究一系列随机变量

$$X_1, X_2, \dots, X_n, \dots$$

当 n 越来越大时，会发生什么。

这件事听起来抽象，但其实特别自然。因为现实里大量问题本来就是“重复做很多次试验”：

- 不停抛硬币；
- 不断测量零件长度；
- 持续抽样调查；
- 一次次记录一天收益率、点击率、不良率。

于是，我们最关心的不是某一次单独试验，而是：

1. 做很多次以后，平均结果会不会稳定下来？
2. 这种稳定是怎么发生的？
3. 在稳定之前，波动是什么形状？

这三个问题分别通向：

- 收敛理论；
- 大数定律；
- 中心极限定理。

茆书这一章的主线非常清楚：先用两种收敛把“极限”这个语言准备好，再用特征函数作为工具，最后分别研究大数定律与中心极限定理。

第一部分：随机变量序列与两种收敛

二、什么是随机变量序列

随机变量序列 (sequence of random variables) 就是一串随机变量：

$$X_{n \geq 1}.$$

比如抛硬币：

- 第1次结果记为 X_1 ；
- 第2次结果记为 X_2 ；
- ...
- 第 n 次结果记为 X_n 。

如果正面记 1，反面记 0，那么 X_n 就是一列 0-1 随机变量。

注意，这里最重要的不是“这一列写出来很长”，而是：

我们终于可以讨论“当 $n \rightarrow \infty$ 时，随机现象会不会出现某种稳定规律”。

而这正是概率论从“静态分布”走向“极限规律”的入口。

三、为什么随机变量的“收敛”不像普通数列那么简单

普通数列 $a_n \rightarrow a$ 的意思很简单，就是 $|a_n - a| \rightarrow 0$ 。

但随机变量 X_n 是带随机性的。你不能简单说：

$$X_n - X \rightarrow 0$$

因为这句话要问清楚：**是对每个样本点都趋于0，还是大多数时候趋于0，还是它的分布越来越像0？**

于是概率论里就出现了多种收敛方式。茆书第四章重点讲的是两种：

- 依概率收敛
- 按分布收敛（弱收敛）

书中也明确说，本章的大数定律涉及依概率收敛，中心极限定理涉及按分布收敛。

这两个概念是这一章真正的地基。

四、依概率收敛：看“值是不是越来越接近”

1. 定义

若对任意 $\varepsilon > 0$ ，都有

$$P(|X_n - X| < \varepsilon) \rightarrow 1$$

等价地，

$$P(|X_n - X| \geq \varepsilon) \rightarrow 0,$$

那么称 X_n 依概率收敛于 X ，记作

$$X_n \xrightarrow{P} X.$$

这就是“偏离 X 超过任意固定误差 ε 的概率趋于 0”。茆书在 4.1 节正是围绕这个思想展开的。

2. 直观理解

依概率收敛不是说：

从某一项开始， X_n 每次都非常接近 X 。

它说的是：

当 n 很大时， X_n 偏得很远这件事越来越不容易发生。

所以它强调的是“大偏差越来越罕见”。

3. 一个很贴切的理解方式

假设 X 是某个真实参数， X_n 是用 n 个样本得到的估计。

那么 $X_n \xrightarrow{P} X$ 的意思就是：

- 你样本越大，
- 估计偏得很离谱的概率越小，
- 所以估计越来越“稳”。

这正是统计学里“相合性（consistency）”的思想基础。

五、按分布收敛：看“分布是不是越来越像”

1. 为什么不能要求处分都收敛

这是本章第一个容易卡住的地方。

茆书在 4.1.2 里通过例子说明：如果要求分布函数 $F_n(x)$ 对每个 x 都收敛到 $F(x)$ ，要求会太强；尤其在极限分布函数的间断点处，往往会出问题。于是书里给出启发：只在 $F(x)$ 的连续点上讨论收敛。

这个思想非常重要。因为分布函数本来就可能有跳跃，跳跃点是“概率质量集中”的位置，在这些点逐点比较，要求不自然。

2. 定义

设 X_n 的分布函数为 $F_n(x)$ ， X 的分布函数为 $F(x)$ 。若对 $F(x)$ 的任一连续点 x 都有

$$F_n(x) \rightarrow F(x),$$

则称：

- 分布函数列 F_n **弱收敛**到 F ；
- 随机变量列 X_n **按分布收敛**到 X ，

记作

$$X_n \xrightarrow{L} X$$

或写作

$$F_n \Rightarrow F.$$

茆书明确区分了“分布函数列的弱收敛”和“随机变量列的按分布收敛”，但本质含义是一样的。

3. 直观理解

按分布收敛不要求 X_n 和 X 在同一次试验里取值接近，它只要求：

X_n 的整体概率结构、统计外形、分布轮廓越来越像 X 。

比如：

- 直方图越来越像；
- 分布函数曲线越来越贴近；
- 标准化后的随机和越来越像正态曲线。

这就是中心极限定理使用它的原因。

六、两种收敛的关系

1. 依概率收敛比按分布收敛强

茆书给出定理：若

$$X_n \xrightarrow{P} X,$$

则必有

$$X_n \xrightarrow{L} X.$$

也就是说：

数值上越来越接近，必然推出分布上越来越接近。

2. 反过来一般不成立

书里给了经典反例：令 X 取值为 ± 1 ，概率各为 $1/2$ ，再令 $X_n = -X$ 。则 X_n 和 X 同分布，所以按分布收敛成立；但 $|X_n - X|$ 不会变小，因此不依概率收敛。

这个反例值得反复咀嚼，因为它揭示了本质区别：

- 按分布收敛只管“分布长得像不像”；
- 依概率收敛真的要求“值本身越来越贴近”。

3. 极限是常数时，两者等价

茆书还给出一个很重要的结论：

若极限是常数 c ，那么

$$X_n \xrightarrow{L} c \iff X_n \xrightarrow{P} c.$$

这点很关键，因为大数定律的极限往往正是常数 μ 。

第二部分：特征函数——为什么这一节会插在中间

七、特征函数在这一章里的角色

很多同学学到这里会问：

我在学大数定律和中心极限定理，为什么中间突然插入“特征函数”？

答案是：因为中心极限定理最经典、最标准的证明工具就是特征函数。

茆书把第四章安排成

- 4.1 收敛
- 4.2 特征函数
- 4.3 大数定律
- 4.4 中心极限定理

这个结构非常合理。因为 4.4 中需要一个能方便处理“随机变量和”的工具，而特征函数正好有这个能力。

八、什么是特征函数

若随机变量 X 的分布函数为 $F(x)$ ，则它的特征函数（characteristic function）定义为

$$\varphi_X(t) = E(e^{itX}), \quad t \in \mathbb{R}.$$

这里 i 是虚数单位，满足 $i^2 = -1$ 。

你可以先把它看成：

用一个复值函数，把随机变量的分布信息整体打包编码起来。

它和矩母函数有点像，但比矩母函数更稳，因为特征函数总是存在，而矩母函数不一定存在。

这一点虽然你原文里提得不多，但非常值得补充：

因为 $|e^{itX}| = 1$ ，所以 $E(e^{itX})$ 总是有意义；而 $E(e^{tX})$ 可能因为尾部太重而发散。茆书在 4.2 节先给出定义，再列举了一些常见分布的特征函数。

九、为什么特征函数这么有用

特征函数最重要的价值有三点：

1. 它唯一决定分布

这意味着：

知道了特征函数，就等于知道了分布。

茆书在 4.2.3 节专门讲“特征函数唯一决定分布函数”。

这是一个非常深的事实。因为它说明：

- 比起直接研究分布函数，
- 我们可以转而研究特征函数；
- 只要证明特征函数收敛到某个目标特征函数，就能推出分布收敛。

这正是 CLT 的标准路线。

2. 它把“和”的问题变成“积”的问题

若 X, Y 独立，则

$$\varphi_{X+Y}(t) = \varphi_X(t)\varphi_Y(t).$$

这个性质是整章最关键的工具之一。茆书也把它列为特征函数的核心性质。

为什么它厉害？因为中心极限定理讨论的恰恰就是

$$S_n = X_1 + \cdots + X_n.$$

一旦用了特征函数，和就变成了乘积，乘积再取极限，就容易多了。

3. 它能读出矩

若 $E(X^l)$ 存在，则特征函数可以求导，而且有

$$\varphi_X^{(k)}(0) = i^k E(X^k).$$

特别地，可以由导数求出均值和方差。茆书在 4.2.2 中给出了这一性质，并说明可由它求数学期望和方差。

这说明特征函数不仅能“编码分布”，还能“提取矩信息”。

十、特征函数的几个核心性质

根据茆书 4.2.2，可重点掌握以下几条。

性质1：模长不超过1

$$|\varphi_X(t)| \leq \varphi_X(0) = 1.$$

这说明特征函数有界，不会乱跑。

性质2：线性变换公式

若 $Y = aX + b$ ，则

$$\varphi_Y(t) = e^{ibt} \varphi_X(at).$$

这在做标准化时非常有用，因为 CLT 里不断在处理

$$\frac{S_n - E(S_n)}{\sqrt{\text{Var}(S_n)}}.$$

性质3：独立和对应乘积

若 X, Y 独立，则

$$\varphi_{X+Y}(t) = \varphi_X(t) \varphi_Y(t).$$

这是最重要的一条。

性质4：导数给出矩

若矩存在，则

$$\varphi_X^{(k)}(0) = i^k E(X^k).$$

特别地，

$$E(X) = \frac{\varphi_X'(0)}{i}, \quad \text{Var}(X) = -\varphi_X''(0) + (E(X))^2.$$

十一、特征函数与中心极限定理之间的桥梁

这里你需要把逻辑链真正连起来：

1. 我们想证明某个标准化随机变量列按分布收敛；
2. 按分布收敛直接证，往往很难；
3. 于是转而研究它们的特征函数；
4. 若特征函数收敛到某个分布的特征函数；
5. 再利用“特征函数唯一决定分布”；
6. 就推出原随机变量列按分布收敛到那个分布。

所以特征函数在这一章里不是旁枝，而是 **CLT 的主工具**。

第三部分：大数定律——平均为什么会稳定

十二、大数定律的核心思想

大数定律 (law of large numbers) 研究的是：

当试验次数很多时，样本平均会不会稳定到某个确定值。

设

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i.$$

大数定律关注的就是：在什么条件下，

$$\bar{X}_n \xrightarrow{P} \mu$$

或更一般地，

$$\bar{X}_n - \frac{1}{n} \sum_{i=1}^n E(X_i) \xrightarrow{P} 0.$$

茆书在 §4.4 前的过渡中明确说：大数定律讨论的是“在什么条件下，随机变量序列的算术平均依概率收敛到其均值的算术平均”。

十三、先从最简单的：伯努利大数定律

1. 场景

设某事件 A 每次试验发生的概率为 p 。定义

$$X_i = \begin{cases} 1, & A \text{ 在第 } i \text{ 次中发生} \\ 0, & A \text{ 在第 } i \text{ 次中不发生} \end{cases}.$$

则 X_i 是伯努利随机变量，且

$$S_n = \sum_{i=1}^n X_i$$

表示前 n 次中事件 A 的发生次数，所以频率为

$$\frac{S_n}{n}.$$

2. 定理内容

伯努利大数定律说：对任意 $\varepsilon > 0$,

$$P\left(\left|\frac{S_n}{n} - p\right| \geq \varepsilon\right) \rightarrow 0.$$

也就是

$$\frac{S_n}{n} \xrightarrow{P} p.$$

3. 直观含义

它说的是：

频率会稳定到概率。

这句话太经典了，几乎可以看作整个统计推断的原点。

比如一种彩票中奖率是 p ，做的次数越多，中奖频率越靠近 p 。

比如产品不合格率是 p ，抽样越多，样本不合格比例越接近 p 。

茆书特别指出：伯努利大数定律为“用频率确定概率”提供了理论依据；例如估计产品不合格率时，随机抽取很多件，不合格品比例可作为不合格率的估计。

4. 它最容易被误解的地方

它不是说：

前面正面多了，后面就一定要出反面补回来。

它说的是：

随着总次数变大，前面那一点偏差会被分母稀释掉。

这是“稀释”，不是“补偿”。

十四、切比雪夫大数定律：从0-1变量推广到一般独立变量

1. 为什么需要推广

伯努利大数定律只适用于 0-1 变量。现实中我们往往测量的是：

- 长度；
- 价格；
- 收益；
- 温度；
- 误差。

这些不再是0和1，而是一般随机变量。

2. 一个标准版本

若 $X_1, X_2, \dots$ 相互独立，且存在常数 C 使得

$$\text{Var}(X_i) \leq C, \quad i = 1, 2, \dots,$$

那么

$$\frac{1}{n} \sum_{i=1}^n (X_i - E(X_i)) \xrightarrow{P} 0.$$

等价地，

$$\bar{X}_n - \frac{1}{n} \sum_{i=1}^n E(X_i) \xrightarrow{P} 0.$$

3. 证明背后的核心思想

因为独立，所以

$$\begin{aligned} \text{Var}(\bar{X}_n) &= \text{Var}\left(\frac{1}{n} \sum_{i=1}^n X_i\right) \\ &= \frac{1}{n^2} \sum_{i=1}^n \text{Var}(X_i) \\ &\leq \frac{C}{n} \rightarrow 0 \end{aligned}$$

再用切比雪夫不等式：

$$P(|\bar{X}_n - E(\bar{X}_n)| \geq \varepsilon) \leq \frac{\text{Var}(\bar{X}_n)}{\varepsilon^2} \rightarrow 0.$$

所以样本平均依概率收敛。

4. 直观理解

它告诉你：

只要每个样本的波动别太离谱，而且彼此独立，那么平均以后波动就会被 n 压扁。

这就是“平均能消灭噪声”的数学版本。

十五、马尔可夫大数定律：更一般地看“平均的方差是否趋于0”

马尔可夫大数定律常见的思想形式是：

若

$$\text{Var}\left(\frac{1}{n}\sum_{i=1}^n X_i\right) \rightarrow 0,$$

则

$$\frac{1}{n}\sum_{i=1}^n X_i - \frac{1}{n}\sum_{i=1}^n E(X_i) \xrightarrow{P} 0.$$

也就是说，大数定律的真正核心条件可以概括成一句：

样本平均的方差趋于 0。

这一定律的意义在于，它把大数定律的“实质”暴露出来了。
独立、同分布、有界方差这些条件，本质上都是为了保证

$$\text{Var}(\bar{X}_n) \rightarrow 0.$$

所以它让你从“背具体版本”提升到“抓住根本机制”。

十六、辛钦大数定律：i.i.d. 下最经典也最强的弱大数定律之一

1. 定理内容

若 $X_1, X_2, \dots$ 独立同分布，且

$$E(X_1) = \mu$$

存在，那么

$$\bar{X}_n \xrightarrow{P} \mu.$$

2. 这条定理厉害在哪里

它只要求数学期望存在，并不显式要求方差存在。

这比切比雪夫型版本更强，因为切比雪夫往往依赖方差。

3. 直观理解

辛钦大数定律告诉你：

只要每次试验的“中心位置”有定义，而且每次试验相互独立且同分布，那么长期平均就会稳定到这个中心位置。

这非常符合统计学直觉：

总体均值 μ 存在，那么样本均值 $\bar{X}_n$ 就会成为它的好估计。

十七、这几个大数定律之间是什么关系

建议你这样看，不要孤立记忆：

1. 伯努利大数定律

是最早、最特殊的版本，处理 0-1 变量，即频率问题。

2. 切比雪夫大数定律

把伯努利推广到一般独立变量，强调“有界方差”。

3. 马尔可夫大数定律

告诉你大数定律的本质条件：平均的方差要收缩。

4. 辛钦大数定律

在 i.i.d. 情形下进一步放宽要求，只要期望存在即可。

所以它们不是彼此割裂的，而是在不断回答同一个问题：

平均值为什么会稳定？在什么条件下会稳定？

十八、大数定律的现实意义

1. 频率估计概率

这是最直接的：

- 不合格率；
- 中奖率；
- 点击率；
- 转化率。

本质上都是“用样本频率估总体概率”。

2. 样本均值估总体均值

比如：

- 平均身高；
- 平均收入；
- 平均误差；
- 平均耗时。

这都是“用样本平均估总体期望”。

3. 蒙特卡罗方法

茆书在伯努利大数定律后面专门举了蒙特卡罗积分的例子：把定积分转化成某个区域中的概率，再用随机投点的频率来近似积分值。

这个思想特别重要，因为它告诉你：

大量随机样本的平均，本身就是一个数值计算工具。

这在计算机模拟、统计物理、金融工程里都极其常见。

第四部分：中心极限定理——波动为什么会变成正态

十九、为什么大数定律还不够

大数定律告诉你：

$$\bar{X}_n \xrightarrow{P} \mu.$$

也就是样本均值会靠近真均值。

但它没有告诉你：

- 靠近得有多快？
- 偏差大概是什么量级？
- 偏差的分布长什么样？

这些问题就由中心极限定理回答。

所以你可以把两者理解成：

- **大数定律**：告诉你“会不会准”；
 - **中心极限定理**：告诉你“误差长啥样”。
-

二十、为什么研究和的时候要先标准化

设

$$S_n = X_1 + \cdots + X_n.$$

如果 X_i 独立同分布，且 $E(X_i) = \mu$, $Var(X_i) = \sigma^2$ ，那么

$$E(S_n) = n\mu, \quad Var(S_n) = n\sigma^2.$$

这意味着：

- 随着 n 增大，分布中心在移动；
- 分布宽度也在变大。

所以直接研究 S_n 的极限分布没意义。必须把它“扶正、缩放”，即标准化：

$$Z_n = \frac{S_n - n\mu}{\sigma\sqrt{n}}.$$

或者写成样本均值的形式：

$$Z_n = \frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}}.$$

这一步很重要。它说明 CLT 研究的不是原始和，而是**标准化后的和**。

二十一、独立同分布下的中心极限定理（林德伯格—莱维 CLT）

1. 定理内容

若 $X_1, X_2, \dots$ 独立同分布，且

$$E(X_i) = \mu, \quad Var(X_i) = \sigma^2 > 0,$$

则

$$\frac{X_1 + \cdots + X_n - n\mu}{\sigma\sqrt{n}} \xrightarrow{L} N(0, 1).$$

等价地，

$$\frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} \xrightarrow{L} N(0, 1).$$

茆书在 4.4.2 中给出的就是这一经典结果。

2. 它到底在说什么

它说的是：

虽然 $\bar{X}_n$ 会趋向于 μ ，但它不是一下子贴上去的，而是会在 μ 附近随机波动；这种波动经过合适放大以后，最终会呈现标准正态分布。

这是一种极其深刻的普适现象。

3. 为什么这里是“按分布收敛”而不是“依概率收敛”

因为标准化后的变量并不收敛到某个固定值，而是收敛到一个分布：

$$N(0, 1).$$

所以这里关心的是“分布形状”，不是“数值贴近”。

二十二、中心极限定理最核心的直观含义

你可以从三个角度理解它。

1. 误差尺度是 $1/\sqrt{n}$

从

$$\frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} \xrightarrow{L} N(0, 1)$$

可以看出， $\bar{X}_n - \mu$ 的典型量级是

$$\frac{\sigma}{\sqrt{n}}.$$

这比大数定律更细。大数定律只说“趋于0”，CLT 进一步告诉你“趋于0的速度大约是 $1/\sqrt{n}$ ”。

2. 大量独立小因素叠加后会变正态

这是它最深的物理直觉。

身高、测量误差、考试总分、很多自然波动都近似正态，不是因为它们本身天生正态，而是因为它们常常是很多微小独立因素叠加的结果。

3. 正态分布是“宏观稳定形状”

原始变量 X_i 可以不是正态，甚至很偏、很怪，只要满足独立同分布且方差有限，标准化后的和就会逐步“磨”成正态。

茆书也强调：这个定理只假设独立同分布且方差存在，不管原来的分布是什么，只要 n 充分大，都可以用正态分布去逼近随机变量和的分布，因此应用非常广。

二十三、CLT 与 LLN 的关系

把两条公式放在一起最清楚：

大数定律

$$\bar{X}_n \xrightarrow{P} \mu$$

中心极限定理

$$\frac{\sqrt{n}(\bar{X}_n - \mu)}{\sigma} \xrightarrow{L} N(0, 1)$$

它们研究的是同一个对象 $\bar{X}_n$ ，但关注点不同：

- 大数定律关注“最后去哪儿”；
- 中心极限定理关注“去的过程中怎么抖”。

这个框架一定要在脑子里立住。

第五部分：二项分布的正态近似

二十四、狄莫弗—拉普拉斯中心极限定理

若

$$S_n \sim B(n, p),$$

则

$$\frac{S_n - np}{\sqrt{np(1-p)}} \xrightarrow{L} N(0, 1).$$

这就是二项分布的正态近似，也叫狄莫弗—拉普拉斯中心极限定理。茆书指出，它是历史上第一个中心极限定理。

二十五、它为什么重要

因为很多题目最后都会落到“成功次数”上：

- 抽样中不合格个数；
- 投票中赞成票数；
- 点击中转化人数；
- 硬币中正面个数。

这些都服从二项分布。

而当 n 大时，直接算二项概率很麻烦，正态近似就成了高效工具。

二十六、为什么要做连续性修正

茆书特别强调：二项分布是离散分布，正态分布是连续分布，所以近似时通常要做 0.5 修正。

例如：

$$P(k_1 \leq S_n \leq k_2)$$

通常近似成

$$P(k_1 - 0.5 < S_n < k_2 + 0.5).$$

直观理解

因为离散分布的“一个点”其实对应一根柱子，而连续分布没有单点面积。所以要把整数点附近的半格宽度补进去，才能让连续曲线更好地模仿离散柱形。

二十七、什么时候二项分布用正态近似比较好

茆书给出常见经验条件：

$$np > 5, \quad n(1-p) > 5.$$

此时正态近似较好；若 p 很小，则泊松近似往往更合适。

这也是考试里很常见的判断标准。

第六部分：独立不同分布下的中心极限定理

二十八、为什么还要研究“不同分布”

现实里，很多随机变量虽然独立，但不一定同分布。

比如一个总误差可能来自：

- 仪器误差；
- 读数误差；
- 环境温度影响；
- 操作误差。

这些因素独立，但不一定服从相同分布。

所以需要更一般的中心极限定理。

二十九、最核心的直觉：不能有“独裁变量”

对于

$$S_n = \sum_{i=1}^n X_i,$$

要想标准化后仍然趋向正态，核心要求是：

没有任何单个变量的波动能主宰总波动。

如果某一项方差特别大，整个和的形状就被它拖走了，正态近似会失效。

所以更一般 CLT 的思想，可以概括成一句话：

每一项都要相对“均匀地小”。

三十、林德伯格条件

设独立随机变量 $X_1, X_2, \dots$ 满足

$$E(X_i) = \mu_i, \quad \text{Var}(X_i) = \sigma_i^2,$$

并记

$$s_n^2 = \sum_{i=1}^n \sigma_i^2.$$

林德伯格条件是：对任意 $\varepsilon > 0$,

$$\frac{1}{s_n^2} \sum_{i=1}^n E\left[(X_i - \mu_i)^2, I(|X_i - \mu_i| > \varepsilon s_n)\right] \rightarrow 0.$$

若该条件成立，则

$$\frac{\sum_{i=1}^n (X_i - \mu_i)}{s_n} \xrightarrow{L} N(0, 1).$$

直观意义

这个条件看起来复杂，其实本质上在做一件事：

- 把“偏差特别大”的那部分贡献挑出来；
- 要求它们相对于总方差来说越来越可以忽略。

换句话说，就是防止少数异常大波动破坏正态性。

三十一、李雅普诺夫条件

它是一个更容易验证的充分条件。若存在某个 $\delta > 0$ ，使得

$$\frac{1}{s_n^{2+\delta}} \sum_{i=1}^n E|X_i - \mu_i|^{2+\delta} \rightarrow 0,$$

则也有

$$\frac{\sum_{i=1}^n (X_i - \mu_i)}{s_n} \xrightarrow{L} N(0, 1).$$

直观理解

它要求高阶矩不要太大，意思是：

尾巴不能太重，极端值不能太夸张。

所以李雅普诺夫条件比林德伯格条件更容易算，但一般更强。

第七部分：中心极限定理的应用和现实意义

三十二、为什么 CLT 是统计学的发动机

因为统计里几乎所有“大样本近似”都靠它：

- 样本均值近似正态；
- 样本比例近似正态；
- 估计量的渐近正态性；
- 大样本置信区间；
- 大样本假设检验。

如果没有 CLT，很多统计方法只能在正态总体这种很理想的前提下做；有了 CLT，很多方法就可以在更一般的总体下成立。

三十三、样本均值的近似分布

若 X_i i.i.d.，则对大样本，

$$\bar{X}_n \approx N\left(\mu, \frac{\sigma^2}{n}\right).$$

这条式子特别实用。它意味着：

- 均值在 μ 附近；

- 波动方差是 σ^2/n ;
- 样本量越大，分布越集中。

这就是为什么“大样本均值更稳定”。

三十四、样本比例的近似分布

若 $X_i \sim \text{Bernoulli}(p)$ ，则

$$\bar{X}_n = \frac{S_n}{n}$$

就是样本比例，且对大样本有

$$\bar{X}_n \approx N\left(p, \frac{p(1-p)}{n}\right).$$

这在问卷调查、A/B测试、点击率、转化率问题里极其常见。

三十五、正态随机数的产生

茆书在 CLT 后给了一个很有意思的应用：用均匀随机数生成近似正态随机数。因为均匀分布变量求和再标准化后，会近似正态。

这说明 CLT 不只是“理论结果”，它还能直接变成算法。

第八部分：这一章最常见的误区

三十六、“样本量大于30就一定正态”——错在哪里

错在它把结论说得太绝对。

CLT 说的是：

- 标准化后的和或样本均值近似正态；
- 而不是原始数据一定正态。

而且“30”只是经验值，不是普适定理。

若原总体极度偏斜、重尾， $n = 30$ 可能远远不够。

三十七、“大数定律说明未来会补偿过去”——错在哪里

大数定律并不要求“补偿”，而是“稀释”。

前面偏离很大，不代表后面会刻意反向纠正；
只是随着总样本量增大，前面的偏差占比越来越小。

三十八、“中心极限定理说明原始总体必须是正态”——也错

恰恰相反，CLT 最有力量的地方就在于：

原始总体不必正态。

只要满足适当条件，标准化后的和就会近似正态。

第九部分：把整章压缩成一个真正能记住的框架

最后给你一个适合复习和内化的总框架。

1. 本章的对象

随机变量序列 X_n ，以及由它们构成的

$$S_n = \sum_{i=1}^n X_i, \quad \bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i.$$

2. 本章的两种收敛

- 依概率收敛：数值越来越稳；
- 按分布收敛：分布越来越像。

3. 收敛关系

$$X_n \xrightarrow{P} X \Rightarrow X_n \xrightarrow{L} X,$$

但逆命题一般不成立；若极限为常数，则二者等价。

4. 特征函数的作用

$$\varphi_X(t) = E(e^{itX})$$

它：

- 总是存在；
- 唯一决定分布；
- 把独立和变成乘积；
- 可提取矩信息。

5. 大数定律的核心

样本平均会稳定：

$$\bar{X}_n \xrightarrow{P} \mu.$$

代表版本：

- 伯努利大数定律；
- 切比雪夫大数定律；
- 马尔可夫大数定律；
- 辛钦大数定律。

6. 中心极限定理的核心

样本均值的误差在 $\sqrt{n}$ 量级放大后近似正态：

$$\frac{\sqrt{n}(\bar{X}_n - \mu)}{\sigma} \xrightarrow{L} N(0, 1).$$

代表版本：

- 林德伯格—莱维 CLT；
- 狄莫弗—拉普拉斯 CLT；
- 林德伯格 CLT；
- 李雅普诺夫 CLT。

最后一句总结

这一章的灵魂其实可以压缩成两句话：

- **大数定律说：**大量重复以后，平均值会稳定到真值附近。
- **中心极限定理说：**这种稳定不是死板地靠近，而是在正态规律支配下波动着靠近。

也就是说，随机世界里既有“趋于确定”的一面，也有“波动有形状”的一面。第四章就是把这两面第一次系统地讲清楚。