



第二讲 简单线性回归

袁洪松

内容概要:

简单线性回归

课本章节:

Weisberg Chapter 2

1 简单线性回归模型

假设自变量 X , 因变量 Y 均为标量, 如何建立 X 与 Y 的联系? 思路: 建立 Y 的分布与 X 之间的联系。

假设给定 $X = x$ 时, Y 服从一个正态分布 $N(\beta_0^* + \beta_1^*x, \sigma_*^2)$, 其中 $\beta_0^*, \beta_1^*, \sigma_*^2$ 为常数 (通常未知)。若样本为 $(x_1, y_1), \dots, (x_n, y_n)$, 则上述假设可表示为

$$\begin{aligned} y_i &= \beta_0^* + \beta_1^*x_i + e_i, \quad i = 1, \dots, n, \\ e_1, \dots, e_n &\stackrel{i.i.d.}{\sim} N(0, \sigma_*^2). \end{aligned} \quad (1)$$

这称为一个简单线性回归模型 (simple linear regression model)。其中, β_0^* 称为截距 (intercept), β_1^* 称为斜率 (slope), $e_1, \dots, e_n$ 称为统计误差 (statistical error)。

我们通常不考虑样本中自变量的随机性, 即假设 $x_1, \dots, x_n$ 为确定的数, 故模型中 y_i 的随机性都来自于 e_i , 那么 $y_1, \dots, y_n$ 互相独立。

2 最小二乘估计

对于模型(1), 希望估计其中的未知参数 $\beta_0^*, \beta_1^*, \sigma_*^2$. 采用极大似然估计法。由于 $y_i \sim N(\beta_0^* + \beta_1^*x_i, \sigma_*^2)$, 似然函数可以写为

$$L(\beta_0, \beta_1, \sigma) = \prod_{i=1}^n \frac{1}{\sigma\sqrt{2\pi}} \exp \left\{ -\frac{1}{2\sigma^2} (y_i - \beta_0 - \beta_1 x_i)^2 \right\}.$$

对数似然函数为

$$l(\beta_0, \beta_1, \sigma) = -n \log \sigma - \frac{n}{2} \log(2\pi) - \frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2.$$

为求 $l(\beta_0, \beta_1, \sigma)$ 的极大值, 先将其对 σ 求偏导, 并令偏导等于0, 得到

$$\frac{\partial l}{\partial \sigma} = -\frac{n}{\sigma} + \frac{1}{\sigma^3} \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2 = 0.$$

于是

$$\sigma^2 = \frac{1}{n} \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2. \quad (2)$$

将此式代入 $l(\beta_0, \beta_1, \sigma)$ 可得

$$l(\beta_0, \beta_1, \sigma) = -\frac{n}{2} \log \left\{ \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2 \right\} - \frac{n}{2} \log(2\pi) - \frac{n}{2}.$$

于是最大化 $l(\beta_0, \beta_1, \sigma)$ 等价于最小化

$$f(\beta_0, \beta_1) = \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2.$$

以最小化 $f(\beta_0, \beta_1)$ 为目标的参数估计方法称为**最小二乘法(ordinary least squares)**。

将 $f(\beta_0, \beta_1)$ 对 β_0, β_1 求偏导, 并令偏导等于0, 得到

$$\begin{aligned} \frac{\partial f}{\partial \beta_0} &= -2 \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i) = 0, \\ \frac{\partial f}{\partial \beta_1} &= -2 \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i) x_i = 0. \end{aligned}$$

求得解为

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}, \quad \hat{\beta}_1 = \frac{SXY}{SXX}.$$

其中, $\bar{x} = \sum_{i=1}^n x_i / n$, $\bar{y} = \sum_{i=1}^n y_i / n$,

$$\begin{aligned} SXX &= \sum_{i=1}^n (x_i - \bar{x})^2 = \sum_{i=1}^n x_i (x_i - \bar{x}), \\ SXY &= \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) = \sum_{i=1}^n x_i (y_i - \bar{y}) = \sum_{i=1}^n (x_i - \bar{x}) y_i. \end{aligned}$$

我们称 $\hat{e}_i = y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i$ 为**残差(residual)**, 称 $f(\hat{\beta}_0, \hat{\beta}_1) = \sum_{i=1}^n \hat{e}_i^2$ 为**残差平方和 (residual sum of squares, RSS)**。

由(2)可知, σ_*^2 的极大似然估计为 $\hat{\sigma}^2 = \text{RSS}/n$ 。

3 参数估计的性质

定理 1 极大似然估计 $\hat{\beta}_0, \hat{\beta}_1$ 有如下性质:

1)

$$\hat{\beta}_1 \sim N\left(\beta_1^*, \frac{\sigma_*^2}{\text{SXX}}\right), \quad \hat{\beta}_0 \sim N\left\{\beta_0^*, \sigma_*^2 \left(\frac{1}{n} + \frac{\bar{x}^2}{\text{SXX}}\right)\right\}$$

2)

$$\text{Cov}(\hat{\beta}_1, \hat{\beta}_0) = -\sigma_*^2 \frac{\bar{x}}{\text{SXX}}$$

证明: 将估计量 $\hat{\beta}_1$ 与 $\hat{\beta}_0$ 分别作变换得

$$\begin{aligned}\hat{\beta}_1 &= \sum_{i=1}^n \left(\frac{x_i - \bar{x}}{\text{SXX}} \right) y_i \\ \hat{\beta}_0 &= \sum_{i=1}^n \left\{ \frac{1}{n} - \frac{\bar{x}(x_i - \bar{x})}{\text{SXX}} \right\} y_i.\end{aligned}$$

可以看出 $\hat{\beta}_1, \hat{\beta}_0$ 均为 $y_1, \dots, y_n$ 的线性组合。由于 $y_1, \dots, y_n$ 是互相独立的正态随机变量, 则 $\hat{\beta}_1, \hat{\beta}_0$ 也服从正态分布。令

$$c_i = \frac{x_i - \bar{x}}{\text{SXX}}, \quad d_i = \frac{1}{n} - \frac{\bar{x}(x_i - \bar{x})}{\text{SXX}} = \frac{1}{n} - \bar{x}c_i,$$

则有如下等式:

$$\begin{aligned}\sum_{i=1}^n c_i &= \frac{\sum_{i=1}^n (x_i - \bar{x})}{\text{SXX}} = 0 \\ \sum_{i=1}^n c_i x_i &= \frac{\sum_{i=1}^n (x_i - \bar{x})x_i}{\text{SXX}} = 1 \\ \sum_{i=1}^n d_i &= 1 - \bar{x} \sum_{i=1}^n c_i = 1 \\ \sum_{i=1}^n d_i x_i &= \frac{\sum_{i=1}^n x_i}{n} - \bar{x} \sum_{i=1}^n c_i x_i = \bar{x} - \bar{x} = 0 \\ \sum_{i=1}^n c_i^2 &= \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{\text{SXX}^2} = \frac{1}{\text{SXX}} \\ \sum_{i=1}^n d_i^2 &= \frac{1}{n} - \frac{2\bar{x} \sum_{i=1}^n (x_i - \bar{x})}{n\text{SXX}} + \frac{\bar{x}^2 \sum_{i=1}^n (x_i - \bar{x})^2}{\text{SXX}^2} = \frac{1}{n} + \frac{\bar{x}^2}{\text{SXX}} \\ \sum_{i=1}^n c_i d_i &= \frac{\sum_{i=1}^n (x_i - \bar{x})}{n\text{SXX}} - \frac{\bar{x} \sum_{i=1}^n c_i (x_i - \bar{x})}{\text{SXX}} = -\frac{\bar{x}}{\text{SXX}}.\end{aligned}$$

于是可以得到

$$\begin{aligned}
E(\hat{\beta}_1) &= \sum_{i=1}^n c_i E(y_i) = \sum_{i=1}^n c_i (\beta_0^* + \beta_1^* x_i) = \left(\sum_{i=1}^n c_i \right) \beta_0^* + \left(\sum_{i=1}^n c_i x_i \right) \beta_1^* = \beta_1^* \\
E(\hat{\beta}_0) &= \sum_{i=1}^n d_i E(y_i) = \sum_{i=1}^n d_i (\beta_0^* + \beta_1^* x_i) = \left(\sum_{i=1}^n d_i \right) \beta_0^* + \left(\sum_{i=1}^n d_i x_i \right) \beta_1^* = \beta_0^* \\
\text{Var}(\hat{\beta}_1) &= \sum_{i=1}^n c_i^2 \text{Var}(y_i) = \sigma_*^2 \sum_{i=1}^n c_i^2 = \frac{\sigma_*^2}{\text{SXX}} \\
\text{Var}(\hat{\beta}_0) &= \sum_{i=1}^n d_i^2 \text{Var}(y_i) = \sigma_*^2 \sum_{i=1}^n d_i^2 = \sigma_*^2 \left(\frac{1}{n} + \frac{\bar{x}^2}{\text{SXX}} \right) \\
\text{Cov}(\hat{\beta}_1, \hat{\beta}_0) &= \sum_{i=1}^n c_i d_i \text{Var}(y_i) = \sigma_*^2 \sum_{i=1}^n c_i d_i = -\sigma_*^2 \frac{\bar{x}}{\text{SXX}}. \quad \square
\end{aligned}$$

下面讨论极大似然估计 $\hat{\sigma}^2$ 的性质。

定理 2 (回归版本的“学生定理”) 对于 $\text{RSS} = \sum_{i=1}^n (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i)^2$, 有以下结论:

- 1) $\text{RSS}/\sigma_*^2 \sim \chi^2(n-2)$
- 2) RSS 与 $\hat{\beta}_0$ 互相独立, 与 $\hat{\beta}_1$ 互相独立。

证明: 略。 $\square$

由定理2的1)可知, $E(\text{RSS}/\sigma_*^2) = n-2$ 。于是 $E(\hat{\sigma}^2) = E(\text{RSS}/n) = (n-2)\sigma_*^2/n$, 故 $\hat{\sigma}^2$ 作为 σ_*^2 的估计量是有偏的。而 σ_*^2 的一个无偏估计是

$$\hat{\sigma}^2 = \frac{\text{RSS}}{n-2}.$$

由于 $\text{Var}(\hat{\beta}_1)$ 与 $\text{Var}(\hat{\beta}_0)$ 中的 σ_*^2 未知, 我们可以用无偏估计 $\hat{\sigma}^2$ 代替它, 得到“近似的”方差

$$\begin{aligned}
\widehat{\text{Var}}(\hat{\beta}_1) &= \frac{\hat{\sigma}^2}{\text{SXX}} \\
\widehat{\text{Var}}(\hat{\beta}_0) &= \hat{\sigma}^2 \left(\frac{1}{n} + \frac{\bar{x}^2}{\text{SXX}} \right)
\end{aligned}$$

以上两个量的平方根称为参数估计的**标准误 (standard error)**, 记为

$$\begin{aligned}
\text{se}(\hat{\beta}_1) &= \sqrt{\widehat{\text{Var}}(\hat{\beta}_1)} = \frac{\hat{\sigma}}{\sqrt{\text{SXX}}} \\
\text{se}(\hat{\beta}_0) &= \sqrt{\widehat{\text{Var}}(\hat{\beta}_0)} = \hat{\sigma} \sqrt{\frac{1}{n} + \frac{\bar{x}^2}{\text{SXX}}}.
\end{aligned}$$

4 区间估计

为了找到 $\hat{\beta}_1$ 的置信区间，考虑

$$G = \frac{\hat{\beta}_1 - \beta_1^*}{\text{se}(\hat{\beta}_1)}.$$

稍作变换可知

$$G = \frac{\hat{\beta}_1 - \beta_1^*}{\hat{\sigma}/\sqrt{\text{SXX}}} = \frac{\frac{\hat{\beta}_1 - \beta_1^*}{\sigma^*/\sqrt{\text{SXX}}}}{\hat{\sigma}/\sigma^*} = \frac{\frac{\hat{\beta}_1 - \beta_1^*}{\sigma^*/\sqrt{\text{SXX}}}}{\sqrt{\frac{\text{RSS}}{(n-2)\sigma_*^2}}}.$$

由定理1可知，

$$\frac{\hat{\beta}_1 - \beta_1^*}{\sigma^*/\sqrt{\text{SXX}}} \sim N(0, 1).$$

由定理2可知， $\text{RSS}/\sigma_*^2 \sim \chi^2(n-2)$ 且与 $\frac{\hat{\beta}_1 - \beta_1^*}{\sigma^*/\sqrt{\text{SXX}}}$ 与互相独立。于是

$$G \sim t(n-2).$$

故而 G 可以作为枢轴量。对于置信度 $(1-\alpha)$ ，有

$$P\{-t_{\alpha/2}(n-2) \leq G \leq t_{\alpha/2}(n-2)\} = 1 - \alpha,$$

其中 $t_{\alpha/2}(n-2)$ 为 $t(n-2)$ 分布的上 $\alpha/2$ -分位数 (即，使得 $P\{t(n-2) > x\} = \alpha/2$ 的 x 值)。于是可得到 β_1^* 置信度为 $(1-\alpha)$ 的置信区间为

$$\left[\hat{\beta}_1 - \text{se}(\hat{\beta}_1) \cdot t_{\alpha/2}(n-2), \quad \hat{\beta}_1 + \text{se}(\hat{\beta}_1) \cdot t_{\alpha/2}(n-2) \right].$$

同理， β_0^* 置信度为 $(1-\alpha)$ 的置信区间为

$$\left[\hat{\beta}_0 - \text{se}(\hat{\beta}_0) \cdot t_{\alpha/2}(n-2), \quad \hat{\beta}_0 + \text{se}(\hat{\beta}_0) \cdot t_{\alpha/2}(n-2) \right].$$

5 假设检验

对于已知常数 b_1 ，考虑检验问题

$$H_0 : \beta_1^* = b_1 \text{ vs } H_1 : \beta_1^* \neq b_1.$$

采用检验统计量

$$T = \frac{\hat{\beta}_1 - b_1}{\text{se}(\hat{\beta}_1)},$$

这称为 t -统计量。由上一节的分析，在 H_0 成立时， $T \sim t(n-2)$ 。所以在显著水平 α 下，检验的拒绝域为

$$\{T > t_{\alpha/2}(n-2) \text{ or } T < -t_{\alpha/2}(n-2)\}.$$

这个检验方法称为 t -检验。

若统计量 T 的样本值为 t_0 ，则检验的 p -值为

$$2P\{t(n-2) > |t_0|\}$$

最常见的一种情况是 $b_1 = 0$ 。当接受 H_0 时，即认为 Y 与 X 的线性关系不成立；当拒绝 H_0 时，即认为 Y 与 X 的线性关系成立。

对于 β_0^* 的检验，用同样的方法可以得到类似的结果。

6 预测

对于一个新观察到的自变量值 x_{new} ，因变量的点预测 (point prediction) 是

$$\hat{y}_{\text{new}} = \hat{\beta}_0 + \hat{\beta}_1 x_{\text{new}}.$$

7 可决系数

首先定义如下量：

- 1) 总平方和 (total sum of squares): $\text{SYY} = \sum_{i=1}^n (y_i - \bar{y})^2$.
- 2) 回归平方和 (sum of squares due to regression): $\text{SSreg} = \text{SYY} - \text{RSS}$

可决系数 (coefficient of determination)或 R^2 (**R squared**) 定义为

$$R^2 = \frac{\text{SSreg}}{\text{SYY}} = 1 - \frac{\text{RSS}}{\text{SYY}}.$$

例 (Weisberg Section 2.1, Forbes's Data) 见R程序.