



第三讲 多元线性回归

袁洪松

内容概要:

多元线性回归

课本章节:

Weisberg Chapter 3

1 多元线性回归

1.1 模型设定

假设有自变量 $X_1, \dots, X_p$, 因变量为 Y 。假设给定 $X_1 = x_1, \dots, X_p = x_p$ 时, Y 服从正态分布 $N(\beta_0^* + \beta_1^*x_1 + \dots + \beta_p^*x_p, \sigma_*^2)$, 其中 $\beta_0^*, \beta_1^*, \dots, \beta_p^*, \sigma_*^2$ 为常数。若样本为 $(x_{11}, \dots, x_{1p}; y_1), \dots, (x_{n1}, \dots, x_{np}; y_n)$, 则上述假设可表示为

$$\begin{aligned} y_i &= \beta_0^* + \beta_1^*x_{i1} + \dots + \beta_p^*x_{ip} + e_i, \quad i = 1, \dots, n, \\ e_1, \dots, e_n &\stackrel{i.i.d.}{\sim} N(0, \sigma_*^2). \end{aligned} \quad (1)$$

这称为一个多元线性回归模型 (multiple linear regression model)。其中 $\beta_0^*, \beta_1^*, \dots, \beta_p^*$ 为待估参数, $e_1, \dots, e_n$ 为统计误差。

这里我们不考虑自变量的随机性, 即假设 $(x_{11}, \dots, x_{1p}), \dots, (x_{n1}, \dots, x_{np})$ 均为确定的数, 故模型中 y_i 的随机性都来自于 e_i , 那么 $y_1, \dots, y_n$ 互相独立。

1.2 最小二乘估计

我们把样本及参数用一些矩阵和向量表示。令

$$\mathbf{Y} = \begin{bmatrix} y_1 \\ \vdots \\ y_n \end{bmatrix}, \quad \mathbf{X} = \begin{bmatrix} 1 & x_{11} & \cdots & x_{1p} \\ \vdots & \vdots & \ddots & \vdots \\ 1 & x_{n1} & \cdots & x_{np} \end{bmatrix}, \quad \boldsymbol{\beta}^* = \begin{bmatrix} \beta_0^* \\ \beta_1^* \\ \vdots \\ \beta_p^* \end{bmatrix}, \quad \mathbf{e} = \begin{bmatrix} e_1 \\ \vdots \\ e_n \end{bmatrix}.$$

注意 $\mathbf{Y} \in \mathbb{R}^n$, $\mathbf{X} \in \mathbb{R}^{n \times (p+1)}$, $\boldsymbol{\beta} \in \mathbb{R}^{p+1}$, $\mathbf{e} \in \mathbb{R}^n$ 。这里假设 $n > p$ 且 $\mathbf{X}$ 为满秩 (秩为 $p+1$)。回归模型可以写为

$$\mathbf{Y} = \mathbf{X}\boldsymbol{\beta}^* + \mathbf{e}.$$

采用极大似然估计法。类似于简单线性回归，极大似然估计法会转化成最小二乘法，即需要最小化

$$f(\beta) = \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_{i1} - \cdots - \beta_p x_{ip})^2 = \|\mathbf{Y} - \mathbf{X}\beta\|^2.$$

对 β 求偏导，令其为0，得到

$$\frac{\partial f}{\partial \beta} = -2\mathbf{X}^\top (\mathbf{Y} - \mathbf{X}\beta) = 0.$$

可以解得

$$\hat{\beta} = \begin{bmatrix} \hat{\beta}_0 \\ \hat{\beta}_1 \\ \vdots \\ \hat{\beta}_p \end{bmatrix} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{Y}.$$

可以进一步求得残差

$$\hat{\mathbf{e}} = \begin{bmatrix} \hat{e}_1 \\ \vdots \\ \hat{e}_n \end{bmatrix} = \begin{bmatrix} y_1 - \hat{\beta}_0 - \hat{\beta}_1 x_{11} - \cdots - \hat{\beta}_p x_{1p} \\ \vdots \\ y_n - \hat{\beta}_0 - \hat{\beta}_1 x_{n1} - \cdots - \hat{\beta}_p x_{np} \end{bmatrix} = \mathbf{Y} - \mathbf{X}\hat{\beta},$$

以及残差平方和 $\text{RSS} = \|\hat{\mathbf{e}}\|^2$ 。

1.3 参数估计的性质

定理 1 估计量 $\hat{\beta}$ 的分布为

$$\hat{\beta} \sim N\{\beta^*, \sigma_*^2 (\mathbf{X}^\top \mathbf{X})^{-1}\}.$$

证明：首先知道

$$\begin{aligned} \hat{\beta} &= (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{Y} \\ &= (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top (\mathbf{X}\beta^* + \mathbf{e}) \\ &= (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{X}\beta^* + (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{e} \\ &= \beta^* + (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{e} \end{aligned}$$

由于 $\mathbf{e} \sim N(0, \sigma_*^2 \mathbf{I})$ ，所以 $\hat{\beta}$ 服从多元正态分布。可以算出

$$\begin{aligned} E(\hat{\beta}) &= E\{\beta^* + (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{e}\} \\ &= \beta^* + (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top E(\mathbf{e}) \\ &= \beta^*. \end{aligned}$$

而

$$\begin{aligned}
\text{Cov}(\hat{\beta}) &= \text{Cov}\{\beta^* + (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{e}\} \\
&= \text{Cov}\{(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{e}\} \\
&= (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \text{Cov}(\mathbf{e}) \{(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top\}^\top \\
&= (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top (\sigma_*^2 \mathbf{I}) \mathbf{X} (\mathbf{X}^\top \mathbf{X})^{-1} \\
&= \sigma_*^2 (\mathbf{X}^\top \mathbf{X})^{-1}. \quad \square
\end{aligned}$$

我们用 c_{jk} 表示 $(\mathbf{X}^\top \mathbf{X})^{-1}$ 在 $(j+1, k+1)$ 位置上的元素 ($0 \leq j \leq p, 0 \leq k \leq p$)。于是可以知道

$$\begin{aligned}
\text{Var}(\hat{\beta}_j) &= \sigma_*^2 c_{jj}, \quad 0 \leq j \leq p \\
\text{Cov}(\hat{\beta}_j, \hat{\beta}_k) &= \sigma_*^2 c_{jk}, \quad 0 \leq j \leq p, 0 \leq k \leq p.
\end{aligned}$$

定理 2 (多元回归版“学生定理”) 对于 $\text{RSS} = \|\hat{\mathbf{e}}\|^2$, 有以下结论:

- 1) $\text{RSS}/\sigma_*^2 \sim \chi^2(n-p-1)$
- 2) RSS 与 $\hat{\beta}$ 互相独立。

证明: 略。 $\square$

由定理2的1)可知, $E(\text{RSS}/\sigma_*^2) = n-p-1$ 。故 σ_*^2 的一个无偏估计是

$$\hat{\sigma}^2 = \frac{\text{RSS}}{n-p-1}.$$

在 $\text{Cov}(\beta)$ 中用 $\hat{\sigma}^2$ 代替 σ_*^2 , 得到“近似的”协方差矩阵

$$\widehat{\text{Cov}}(\hat{\beta}) = \hat{\sigma}^2 (\mathbf{X}^\top \mathbf{X})^{-1}$$

注意到 $c_{00}, c_{11}, \dots, c_{pp}$ 表示 $(\mathbf{X}^\top \mathbf{X})^{-1}$ 的对角元, 那么 $\hat{\beta}_j$ ($0 \leq j \leq p$) 的标准误为

$$\text{se}(\hat{\beta}_j) = \hat{\sigma} \sqrt{c_{jj}}.$$

1.4 区间估计

为了找到 $\hat{\beta}_j$ ($0 \leq j \leq p$) 的置信区间, 考虑

$$G = \frac{\hat{\beta}_j - \beta_j^*}{\text{se}(\hat{\beta}_j)}.$$

作变换可知

$$G = \frac{\hat{\beta}_j - \beta_j^*}{\hat{\sigma} \sqrt{c_{jj}}} = \frac{\frac{\hat{\beta}_j - \beta_j^*}{\sigma^* \sqrt{c_{jj}}}}{\hat{\sigma} / \sigma^*} = \frac{\frac{\hat{\beta}_j - \beta_j^*}{\sigma^* \sqrt{c_{jj}}}}{\sqrt{\frac{\text{RSS}}{(n-p-1)\sigma_*^2}}}.$$

由定理1可知,

$$\frac{\hat{\beta}_j - \beta_j^*}{\sigma^* \sqrt{c_{jj}}} \sim N(0, 1).$$

由定理2可知, $\text{RSS}/\sigma_*^2 \sim \chi^2(n-p-1)$ 且与 $\frac{\hat{\beta}_j - \beta_j^*}{\sigma^* \sqrt{c_{jj}}}$ 与互相独立。于是

$$G \sim t(n-p-1).$$

故而 G 可以作为枢轴量。对于置信度 $(1-\alpha)$, 有

$$P\{-t_{\alpha/2}(n-p-1) \leq G \leq t_{\alpha/2}(n-p-1)\} = 1-\alpha,$$

其中 $t_{\alpha/2}(n-p-1)$ 为 $t(n-p-1)$ 分布的上 $\alpha/2$ -分位数。于是可得到 β_j^* 置信度为 $(1-\alpha)$ 的置信区间为

$$\left[\hat{\beta}_j - \text{se}(\hat{\beta}_j) \cdot t_{\alpha/2}(n-p-1), \quad \hat{\beta}_j + \text{se}(\hat{\beta}_j) \cdot t_{\alpha/2}(n-p-1) \right].$$

1.5 假设检验

对于已知常数 b_j , 考虑检验问题

$$H_0 : \beta_j^* = b_j \text{ vs } H_1 : \beta_j^* \neq b_j.$$

采用 t -统计量

$$T = \frac{\hat{\beta}_j - b_j}{\text{se}(\hat{\beta}_j)},$$

在 H_0 成立时, $T \sim t(n-p-1)$ 。所以在显著水平 α 下, 检验的拒绝域为

$$\{T > t_{\alpha/2}(n-p-1) \text{ or } T < -t_{\alpha/2}(n-p-1)\}.$$

若统计量 T 的样本值为 t_0 , 则检验的 p -值为

$$2P\{t(n-p-1) > |t_0|\}$$

最常见的情况是 $b_j = 0$ 。当接受 H_0 时, 即认为变量 X_j 在线性关系中不显著; 当拒绝 H_0 时, 即认为变量 X_j 在线性关系中显著。

1.6 预测

对于新观察到的自变量值 $(x_{\text{new},1}, \dots, x_{\text{new},p})$ ，因变量的点预测是

$$\hat{y}_{\text{new}} = \hat{\beta}_0 + \hat{\beta}_1 x_{\text{new},1} + \dots + \hat{\beta}_p x_{\text{new},p}.$$

1.7 可决系数

与简单线性回归一样，总平方和仍然为 $\text{SYY} = \sum_{i=1}^n (y_i - \bar{y})^2$ ，回归平方和仍然为 $\text{SSreg} = \text{SYY} - \text{RSS}$ ，而可决系数仍然为

$$R^2 = \frac{\text{SSreg}}{\text{SYY}} = 1 - \frac{\text{RSS}}{\text{SYY}}.$$

例 (Weisberg Section 3.1, United Nations Data) 见R程序。

例 (Weisberg Section 3.3, Fuel Data) 见R程序。

2 中心化

将最小二乘法的目标函数 $f(\beta_0, \beta_1, \dots, \beta_p)$ 先对 β_0 求偏导，并令其为0，得到

$$\frac{\partial f}{\partial \beta_0} = -2 \sum_{i=1}^n (y_i - \beta_0 - \sum_{j=1}^p x_{ij} \beta_j) = 0.$$

于是知道

$$\beta_0 = \bar{y}_i - \sum_{j=1}^p \bar{x}_j \beta_j,$$

其中 $\bar{y}_i = \sum_{i=1}^n y_i / n$ (因变量样本均值)， $\bar{x}_j = \sum_{i=1}^n x_{ij} / n$ (第 j 个自变量的样本均值)。代回目标函数，得到

$$\sum_{i=1}^n \left\{ (y_i - \bar{y}) - \sum_{j=1}^p (x_{ij} - \bar{x}_j) \beta_j \right\}^2.$$

现在让

$$\mathcal{Y} = \begin{bmatrix} y_1 - \bar{y} \\ \vdots \\ y_n - \bar{y} \end{bmatrix}, \quad \mathcal{X} = \begin{bmatrix} x_{11} - \bar{x}_1 & \cdots & x_{1p} - \bar{x}_p \\ \vdots & \vdots & \vdots \\ x_{n1} - \bar{x}_1 & \cdots & x_{np} - \bar{x}_p \end{bmatrix}, \quad \mathbf{b} = \begin{bmatrix} \beta_1 \\ \vdots \\ \beta_p \end{bmatrix}.$$

注意 $\mathcal{Y} \in \mathbb{R}^n$ ， $\mathcal{X} \in \mathbb{R}^{n \times p}$ ， $\mathbf{b} \in \mathbb{R}^p$ 。我们可以将 $\mathcal{Y}$ 与 $\mathcal{X}$ 视作“中心化”之后的数据。此时目标函数变为

$$\|\mathcal{Y} - \mathcal{X}\mathbf{b}\|^2,$$

相当于用中心化之后的数据做一个不含截距的回归。对 $\mathbf{b}$ 求偏导，令其为0，得到

$$-2\mathcal{X}^\top(\mathcal{Y} - \mathcal{X}\mathbf{b}) = 0.$$

于是解为

$$\hat{\mathbf{b}} = (\hat{\beta}_1, \dots, \hat{\beta}_p)^\top = (\mathcal{X}^\top \mathcal{X})^{-1} \mathcal{X}^\top \mathcal{Y}, \quad \hat{\beta}_0 = \bar{y}_i - \sum_{j=1}^p \bar{x}_j \hat{\beta}_j.$$

这个解应该与 $\hat{\beta} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{Y}$ 完全相同。

3 多重共线性

若自变量之间线性相关或接近线性相关，则称自变量存在多重共线性 (multicollinearity) 问题。

- 如果自变量之间线性相关，则 $\mathbf{X}^\top \mathbf{X}$ 不满秩，OLS无解。注意当 $p+1 > n$ 时， $\mathbf{X}^\top \mathbf{X}$ 肯定不满秩，因为 $\text{rank}(\mathbf{X}^\top \mathbf{X}) \leq \text{rank}(\mathbf{X}) \leq n < p+1$ 。
- 如果自变量之间接近线性相关，则 $\mathbf{X}^\top \mathbf{X}$ 接近奇异。假设 $\mathbf{X}^\top \mathbf{X}$ 的特征值为 $\lambda_1 \geq \dots \geq \lambda_{p+1} \geq 0$ ，其最小特征值 λ_{p+1} 会非常小。根据参数估计的性质， $\text{Cov}(\hat{\beta}) = \sigma_*^2 (\mathbf{X}^\top \mathbf{X})^{-1}$ 。而

$$\text{tr}((\mathbf{X}^\top \mathbf{X})^{-1}) = \sum_{j=1}^{p+1} \frac{1}{\lambda_j}$$

会非常大。因此至少有参数的估计量的方差会很大，造成估计不稳定。

方差膨胀因子 (variance inflation factor, VIF) 可以用来检测多重共线性。假设回归

$$X_j \sim X_1 + \dots + X_{j-1} + X_{j+1} + \dots + X_p$$

得到的 R^2 为 $R_{(j)}^2$ 。定义 X_j 的VIF为

$$\text{VIF}_j = \frac{1}{1 - R_{(j)}^2}.$$

如果 $\text{VIF}_j > 10$ (即 $R_{(j)}^2 > 0.9$)，则可认为存在共线性 (有时也可以 $\text{VIF}_j > 5$ 判断)。

也可以用自变量矩阵 $\mathbf{X}$ 的条件数 (condition number) 来判断。 $\mathbf{X}$ 的条件数定义为

$$\kappa = \frac{\sigma_{\max}(\mathbf{X})}{\sigma_{\min}(\mathbf{X})},$$

其中 $\sigma_{\min}(\mathbf{X})$, $\sigma_{\max}(\mathbf{X})$ 分别为 $\mathbf{X}$ 的最小与最大奇异值。一般认为， $\kappa < 10$ 时，无明显共线性； $10 \leq \kappa \leq 30$ 时，有中等共线性； $\kappa > 30$ 时，有高度共线性。

存在多重共线性时的修正方法:

1. 去掉某些自变量
2. 采用降维方法提取有效信息 (如主成分分析)

例 (blood pressure data) 见R程序。

4 加权最小二乘

如果 $e_1, \dots, e_n$ 方差各自不同, 则称模型具有异方差性 (heteroscedasticity)。假设 $\text{Var}(e_i) = \sigma_{i*}^2, i = 1, \dots, n$. 如果还是使用OLS, 仍然有

$$E(\hat{\beta}) = E\{\beta^* + (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{e}\} = \beta^* + (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top E(\mathbf{e}) = \beta^*,$$

即OLS估计量还是无偏的。但其有效性无法保证。更确切地说, OLS估计量不再是最优线性无偏估计量 (best linear unbiased estimator, BLUE)。

假设我们有一些方差的先验信息, 例如已知 $\text{Var}(e_i) = \sigma_*^2/w_i$, 其中 w_i 为已知权重, σ_*^2 为未知参数。可以通过极大似然估计法得出WLS估计量

$$\hat{\beta}^{\text{WLS}} = (\mathbf{X}^\top \mathbf{W} \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{W} \mathbf{Y},$$

其中 $\mathbf{W} = \text{diag}(w_1, \dots, w_n) \in \mathbb{R}^{n \times n}$. 可以证明 $\hat{\beta}^{\text{WLS}}$ 也为 β^* 的无偏估计量, 且是BLUE。(参见Weisberg Chapter 7.1)

5 F-检验 (不要求)

5.1 F-检验的问题与方法

对于 $q < p$, 考虑检验问题

$$H_0 : \beta_{p-q+1}^* = \dots = \beta_p^* = 0 \text{ vs } H_1 : \beta_{p-q+1}^*, \dots, \beta_p^* \text{ 不全为0.}$$

将 $\mathbf{X}$ 的列记为

$$X_{\langle 0 \rangle} = \begin{bmatrix} 1 \\ \vdots \\ 1 \end{bmatrix}, \quad X_{\langle 1 \rangle} = \begin{bmatrix} x_{11} \\ \vdots \\ x_{n1} \end{bmatrix}, \quad \dots, \quad X_{\langle p \rangle} = \begin{bmatrix} x_{1p} \\ \vdots \\ x_{np} \end{bmatrix}.$$

则最小二乘法可以写为

$$\min_{\beta_0, \beta_1, \dots, \beta_p} \left\| \mathbf{Y} - \sum_{j=0}^p \beta_j X_{(j)} \right\|^2. \quad (2)$$

注意到 $\sum_{j=0}^p \beta_j X_{(j)}$ 可以看作是 $X_{(0)}, \dots, X_{(p)}$ 的一个线性组合。将 $X_{(0)}, \dots, X_{(p)}$ 张成的向量空间表示为

$$L = \left\{ \sum_{j=0}^p \alpha_j X_{(j)} : \alpha_j \in \mathbb{R}, 0 \leq j \leq p \right\}.$$

那么最小二乘法即是要找 L 中与 $\mathbf{Y}$ 距离最近的元素，即找 $\mathbf{Y}$ 在 L 上的投影。若最小二乘法的解为 $\hat{\beta}_0, \dots, \hat{\beta}_p$ ，则 $\hat{\mathbf{Y}} = \sum_{j=0}^p \hat{\beta}_j X_{(j)}$ 即为 $\mathbf{Y}$ 在 L 上的投影，而残差 $\hat{\mathbf{e}} = \mathbf{Y} - \hat{\mathbf{Y}}$ 的模的平方 $\|\hat{\mathbf{e}}\|^2 = \text{RSS}$ 即为要找的最短距离。

现在假设 H_0 为真，则最小二乘法写为

$$\min_{\beta_0, \beta_1, \dots, \beta_{p-q}} \left\| \mathbf{Y} - \sum_{j=0}^{p-q} \beta_j X_{(j)} \right\|^2. \quad (3)$$

将 $X_{(0)}, \dots, X_{(p-q)}$ 张成的向量空间表示为

$$L_0 = \left\{ \sum_{j=0}^{p-q} \alpha_j X_{(j)} : \alpha_j \in \mathbb{R}, 0 \leq j \leq p-q \right\}.$$

此最小二乘法则等同于寻找 $\mathbf{Y}$ 在 L_0 上的投影。假设此投影为 $\hat{\mathbf{Y}}_0$ ，残差为 $\hat{\mathbf{e}}_0 = \mathbf{Y} - \hat{\mathbf{Y}}_0$ ，残差平方和为 $\text{RSS}_0 = \|\hat{\mathbf{e}}_0\|^2$ 。

由于 L_0 是 L 的子空间，则 $\hat{\mathbf{e}}$ 与 $\hat{\mathbf{e}}_0 - \hat{\mathbf{e}}$ 互相“垂直”，即其内积为0。图1中， $\hat{\mathbf{e}}$ 与 $\hat{\mathbf{e}}_0 - \hat{\mathbf{e}}$ 互相垂直，因此 $\hat{\mathbf{e}}$ 、 $\hat{\mathbf{e}}_0 - \hat{\mathbf{e}}$ 与 $\hat{\mathbf{e}}_0$ 构成的三角形（即图中三条虚线所构成的三角形）满足勾股定理

$$\|\hat{\mathbf{e}}_0\|^2 = \|\hat{\mathbf{e}}\|^2 + \|\hat{\mathbf{e}}_0 - \hat{\mathbf{e}}\|^2.$$

还可以进一步证明， $\hat{\mathbf{e}}$ 与 $\hat{\mathbf{e}}_0 - \hat{\mathbf{e}}$ 互相独立。我们已经知道， $\|\hat{\mathbf{e}}\|^2 / \sigma_*^2 \sim \chi^2(n-p-1)$ ， $\|\hat{\mathbf{e}}_0\|^2 / \sigma_*^2 \sim \chi^2(n-p-1+q)$ ，因此有结论

$$\begin{aligned} \frac{\|\hat{\mathbf{e}}\|^2}{\sigma_*^2} &\sim \chi^2(n-p-1), & \frac{\|\hat{\mathbf{e}}_0\|^2 - \|\hat{\mathbf{e}}\|^2}{\sigma_*^2} &\sim \chi^2(q) \\ \frac{\|\hat{\mathbf{e}}\|^2}{\sigma_*^2} &\text{与 } \frac{\|\hat{\mathbf{e}}_0\|^2 - \|\hat{\mathbf{e}}\|^2}{\sigma_*^2} &&\text{互相独立.} \end{aligned}$$

选取统计量

$$F = \frac{(\|\hat{\mathbf{e}}_0\|^2 - \|\hat{\mathbf{e}}\|^2) / q}{\|\hat{\mathbf{e}}\|^2 / (n-p-1)},$$

这称为一个 F -统计量。在 H_0 成立时， $F \sim F(q, n-p-1)$ (F -分布)。显著水平为 α 时，检验的拒绝域




图 1: 最小二乘法的几何意义

为

$$\{F > F_{\alpha}(q, n - p - 1)\},$$

其中 $F_{\alpha}(q, n - p - 1)$ 为 $F(q, n - p - 1)$ 分布的上 α -分位数。若 F -统计量的观测值为 f_0 , 则检验的 p -值为

$$P(F(q, n - p - 1) > f_0).$$

综上所述, F -检验的步骤为:

- 1) 做最小二乘法(2), 即将所有变量包括在内做一次回归, 得到残差平方和 RSS
- 2) 做最小二乘法(3), 即将 H_0 中的变量排除在外再做一次回归, 得到残差平方和 RSS_0
- 3) 计算 F -统计量的值

$$f_0 = \frac{(RSS_0 - RSS)/q}{RSS/(n - p - 1)}.$$

根据 f_0 是否落在拒绝域内, 或者 p -值的大小判断是否接受 H_0 。

5.2 似然比检验视角

我们还可以用似然比检验的视角来看 F -检验。在原回归的最小二乘估计 $\hat{\beta}$ 下, 可以知道对数似然函数的值为

$$l(\hat{\beta}) = -\frac{n}{2} \log(\text{RSS}) - \frac{n}{2} \log(2\pi) - \frac{n}{2}.$$

在 H_0 约束回归的最小二乘估计 $\hat{\beta}'$ 下, 可以知道对数似然函数的值为

$$l(\hat{\beta}') = -\frac{n}{2} \log(\text{RSS}_0) - \frac{n}{2} \log(2\pi) - \frac{n}{2}.$$

此检验的似然比检验统计量为

$$W = -2 \log \left\{ \frac{L(\hat{\beta}')}{L(\hat{\beta})} \right\} = 2 \left\{ l(\hat{\beta}) - l(\hat{\beta}') \right\} = n \log \left(\frac{\text{RSS}_0}{\text{RSS}} \right).$$

似然比检验的拒绝域为 $\{W > c\}$, 它等价于 $\{F > c'\}$. 因此 F -检验本质上是似然比检验。