上海财经大学
信息管理与工程学院
《高维数据分析》讲义

第四讲　复杂自变量

袁洪松

内容概要：
分类变量，多项式回归，样条函数，主成分分析

课本章节：
Weisberg Chapter 5

1　分类变量

1.1　单个分类变量

分类变量(categorical variable 或 factor)，是指只有有限个取值，每个值对应一个类别，且类别间无排序的变量。

假设自变量F为分类变量，有d个不同的可能取值$\{1, 2, \ldots, d\}$ (即d个类别)，这些取值称为F的d个**levels**。另外假设有因变量Y。设样本为$(f_1, y_1), \ldots, (f_n, y_n)$。则$Y \sim F$的一元回归模型可以写为

$$y_i = \begin{cases} \alpha_1^* + e_i, & \text{if } f_i = 1, \\ \cdots & \\ \alpha_d^* + e_i, & \text{if } f_i = d. \end{cases}$$

其中$\alpha_1^*, \ldots, \alpha_d^*$为每个level对应的均值，$e_i$为统计误差。一种等价的写法为

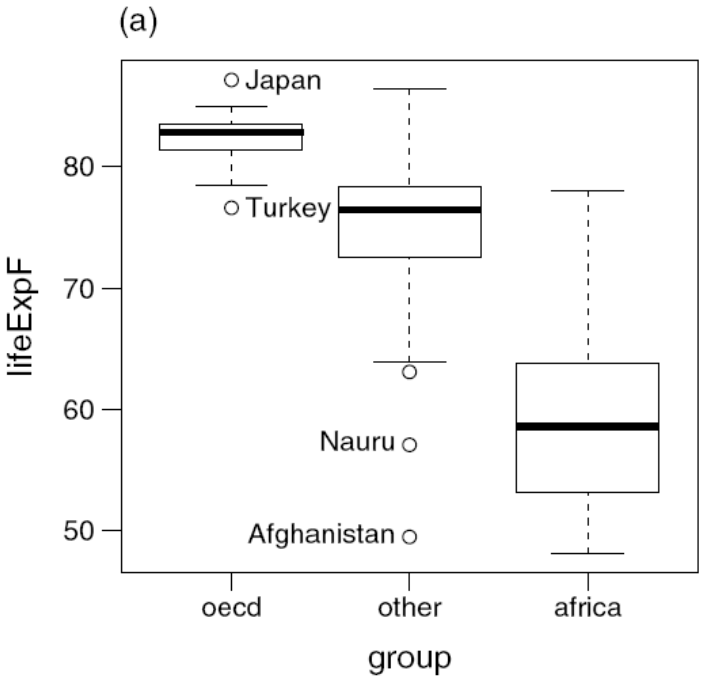
$$y_i = \sum_{k=1}^{d} \alpha_k^* I_{\{f_i=k\}} + e_i, \quad i = 1, \ldots, n. \tag{1}$$

其中$I_{\{\cdot\}}$为示性函数，$I_{\{f_i=k\}}$表示的含义是

$$I_{\{f_i=k\}} = \begin{cases} 1, & \text{if } f_i = k, \\ 0, & \text{otherwise.} \end{cases}$$

直观上，每一个level均值的估计应该就是自变量取值为该level的所有样本的y_i的平均数 (即每个level内

图 1: 箱线图示例 (Weisberg Figure 5.1)



部y_i的样本均值)。可以表示为

$$\hat{\alpha}_k = \frac{\sum_{i=1}^n I_{\{f_i=k\}} y_i}{\sum_{i=1}^n I_{\{f_i=k\}}}. \tag{2}$$

我们可以用箱线图 (boxplot) 来表示每个level内部y_i的分布情况。其中：

1) 中间粗线表示中位数 (即50%分位数)

2) 长方形的上下两条边分别表示25%, 75%分位数

3) 长方形外的上下两道横线表示离中位数至少1.5倍IQR的最近的样本 (IQR全称是inter-quartile range，为75%分位数与25%分位数之差)

4) 在上下两道横线之外的样本用圆圈单独标出

为了在线性回归框架内研究此问题，我们引入虚拟变量 (dummy variables)：若分类变量F有d个类别$\{1,\ldots,d\}$，则引入$(d-1)$个虚拟变量$U_2,\ldots,U_d$，其中

$$U_k = I_{\{F=k\}}, \quad k = 2,\ldots,d.$$

对于样本$(f_1,y_1),\ldots,(f_n,y_n)$，这些虚拟变量的值分别记为$(u_{12},\ldots,u_{1d}),\ldots,(u_{n2},\ldots,u_{nd})$。则模型

可以写成以下的线性回归模型的标准形式

$$y_i = \beta_0^* + \sum_{k=2}^{d} \beta_k^* u_{ik} + e_i, \quad i = 1, \ldots, n. \tag{3}$$

模型(3)的参数与模型(1)的参数应该有如下对应关系：

$$\begin{aligned} \alpha_1^* &= \beta_0^*, \\ \alpha_k^* &= \beta_0^* + \beta_k^*, \quad k = 2, \ldots, d. \end{aligned}$$

若用最小二乘法得到模型(3)的参数估计$\hat{\beta}_0, \hat{\beta}_1, \ldots, \hat{\beta}_d$，则也应与参数估计(2)有对应关系：

$$\begin{aligned} \hat{\alpha}_1 &= \hat{\beta}_0 \\ \hat{\alpha}_k &= \hat{\beta}_0 + \hat{\beta}_k, \quad k = 2, \ldots, d. \end{aligned}$$

1.2 单个分类变量加连续变量

假设自变量包括一个含有d个类别的分类变量F和一个连续变量X，以及一个因变量Y。可以对F的每个类别内部分别设定一个$Y \sim X$的回归模型，这样会得到d个不同的线性回归模型：

$$y_i = \begin{cases} \alpha_{01}^* + \alpha_{11}^* x_i + e_i, & \text{if } f_i = 1, \\ \cdots \\ \alpha_{0d}^* + \alpha_{1d}^* x_i + e_i, & \text{if } f_i = d. \end{cases}$$

如果引入虚拟变量$U_2, \ldots, U_d$，那么可以合成一个线性回归模型

$$y_i = \beta_0^* + \sum_{k=2}^{d} \beta_{0k}^* u_{ik} + \beta_1^* x_i + \sum_{k=2}^{d} \beta_{1k}^* u_{ik} x_i + e_i.$$

我们把$\beta_0^* + \sum_{k=2}^{d} \beta_{0k}^* u_{ik} + \beta_1^* x_i$称为**主效应 (main effects)**，$\sum_{k=2}^{d} \beta_{1k}^* u_{ik} x_i$称为**交互效应 (interactions)**。

显然，以上两个模型参数之间有对应关系：

$$\begin{aligned} \alpha_{01}^* &= \beta_0^* \\ \alpha_{0k}^* &= \beta_0^* + \beta_{0k}^*, \quad k = 2, \ldots, d \\ \alpha_{11}^* &= \beta_1^* \\ \alpha_{1k}^* &= \beta_1^* + \beta_{1k}^*, \quad k = 2, \ldots, d \end{aligned}$$

有时为了简便，可以只考虑保留主效应项，则得到一个主效应模型 (main effects model)：

$$y_i = \beta_0^* + \sum_{k=2}^{d} \beta_{0k}^* u_{ik} + \beta_1^* x_i + e_i.$$

例 (Weisberg Section 5.1.1, UN Data) 见R程序。

1.3 多个分类变量

假设自变量为m个分类变量$F_1, \ldots, F_m$，类别数分别为$d_1, \ldots, d_m$. 定义虚拟变量

$$U_{jk} = I_{\{F_j = k\}}, \quad j = 1, \ldots, m, \quad k = 2, \ldots, d_j.$$

可以考虑以下模型之一：

1) 主效应模型 (main effects model)或一阶模型 (first-order model)：

$$y_i = \beta_0^* + \sum_{j=1}^{m} \sum_{k=2}^{d_j} \beta_{jk}^* \cdot u_{ijk} + e_i$$

2) 二阶模型 (second-order model)：

$$y_i = \beta_0^* + \sum_{j=1}^{m} \sum_{k=2}^{d_j} \beta_{jk}^* \cdot u_{ijk} + \sum_{1 \le j_1 < j_2 \le m} \sum_{k_1=2}^{d_{j_1}} \sum_{k_2=2}^{d_{j_2}} \beta_{j_1 j_2 k_1 k_2}^* \cdot u_{ij_1k_1} \cdot u_{ij_2k_2} + e_i$$

3) 三阶模型

...

m) 全模型 (full model) 或m阶模型：即考虑m个变量各个类别的所有组合之乘积。此模型共有$\prod_{j=1}^{m} d_j$个参数。

我们可以用**Wilkinson-Rogers表示法**来说明模型中包含了哪些项。例如，在UN Data中，主效应模型可表示为

$$\text{lifeExpF} \sim \text{group} + \log(\text{ppgdp}),$$

带交互效应的模型可表示为

$$\text{lifeExpF} \sim \text{group} + \log(\text{ppgdp}) + \text{group} : \log(\text{ppgdp}).$$

在Wool Data中，主效应模型可表示为

$$\log(\text{cycles}) \sim \text{len} + \text{amp} + \text{load},$$

二阶模型可表示为

$$\log(\text{cycles}) \sim \text{len} + \text{amp} + \text{load} + \text{len} : \text{amp} + \text{len} : \text{load} + \text{amp} : \text{load},$$

全模型可表示为

$$\log(\text{cycles}) \sim \text{len} + \text{amp} + \text{load} + \text{len} : \text{amp} + \text{len} : \text{load} + \text{amp} : \text{load} + \text{len} : \text{amp} : \text{load}.$$

例 (Weisberg Section 5.2, Wool Data) 见R程序。

2 多项式回归

假设只有一个连续自变量X，可以考虑d阶多项式回归模型：

$$y_i = \beta_0^* + \beta_1^* x_i + \cdots + \beta_d^* x_i^d + e_i.$$

假设有m个连续变量$X_1, \ldots, X_m$。可以考虑一个二阶模型

$$y_i = \beta_0^* + \sum_{j=1}^{m} \beta_j^* \cdot x_{ij} + \sum_{1 \le j_1 \le j_2 \le m} \beta_{j_1 j_2}^* \cdot x_{ij_1} \cdot x_{ij_2} + e_i.$$

也可以考虑更高阶的模型。

3 样条函数

3.1 三次样条

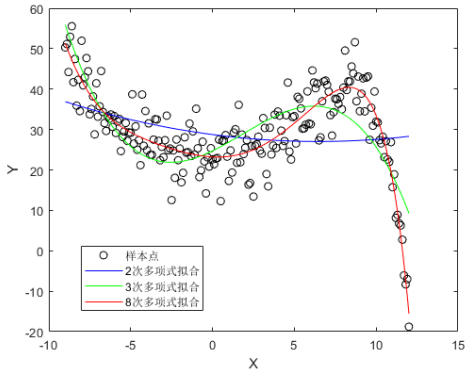
仍然假设只有一个连续自变量X。多项式回归的问题：在多项式阶数d太大时，在样本$x_1, \ldots, x_n$的范围之外，多项式函数可能会给出超出常理的y值 (即出现了**过拟合，overfitting**)。如图2所示，8次多项式对样本点的拟合更优 (图(a))，但在X超出样本点取值范围时 (负方向)，其形状明显不够合理 (图(b))。

一个改进的想法：用分段的低阶多项式做拟合。假设在X的取值范围(a, b)内有K个结点 (knots) $a < \xi_1 < \cdots < \xi_K < b$ (a可能为$-\infty$，b可能为∞)，函数$f(x)$在所有区间$(a, \xi_1), (\xi_1, \xi_2), \ldots, (\xi_K, b)$之内都是 d 阶多项式，且在K个结点处都有0到$(d-1)$阶的连续导数：

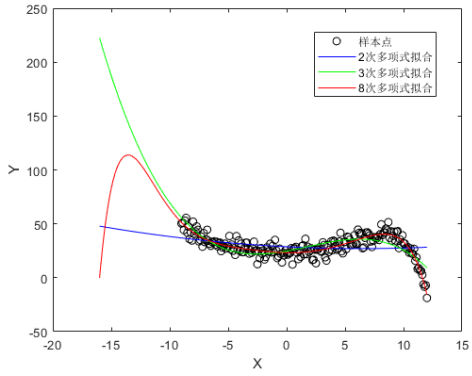
$$f^{(l)}(\xi_k+) = f^{(l)}(\xi_k-), \quad k = 1, \ldots, K, \quad l = 0, 1, \ldots, d-1,$$

其中$f^{(l)}(\xi_k+)$与$f^{(l)}(\xi_k-)$分别表示ξ_k处的l阶左导数与右导数，那么$f(x)$叫做一个d **次样条 (spline)** 函数。

最常见的样条函数是**三次样条 (cubic spline)**，即取$d = 3$。那么$f(x)$符合两个特征：



(a) 2次，3次与8次多项式在样本点附近的形状



(b) 2次，3次与8次多项式在更大范围内的形状

图 2: 多项式回归的拟合效果

1) $f(x)$在所有区间之内为三次多项式

2) $f(x)$在结点$\xi_1, \ldots, \xi_K$处连续，且有连续的1阶和2阶导数

可以进一步证明，$f(x)$可以写为以下形式

$$f(x) = \beta_0 + \beta_1 x + \beta_2 x^2 + \beta_3 x^3 + \beta_4 (x - \xi_1)_+^3 + \cdots + \beta_{K+3} (x - \xi_K)_+^3, \tag{4}$$

其中

$$(x - \xi)_+ = \begin{cases} x - \xi, & \text{if } x \geq \xi, \\ 0, & \text{otherwise.} \end{cases}$$

于是，函数$f(x)$可以看做是一组**基函数 (basis functions)** $\left\{1, x, x^2, x^3, (x - \xi_1)_+^3, \ldots, (x - \xi_K)_+^3\right\}$的线性组合。

当取定结点$\xi_1, \ldots, \xi_K$时，参数$\beta_0, \beta_1, \ldots, \beta_{K+3}$可以由最小二乘法来估计：

$$\min_{\beta_0, \beta_1, \ldots, \beta_{K+3}} \sum_{i=1}^{n} \left\{y_i - f(x_i)\right\}^2.$$

为了保证$x < \xi_1$和$x > \xi_K$时函数不超出合理范围，我们可以加上约束：$f(x)$在$x < \xi_1$和$x > \xi_K$时为线性函数。此时$f(x)$称为**自然三次样条 (natural cubic spline)** 函数。

对于如何选择结点$\xi_1, \ldots, \xi_K$，通常有两种取法：

1) $\xi_1 = \min\{x_1, \ldots, x_n\}$, $\xi_K = \max\{x_1, \ldots, x_n\}$. 对于$2 \leq k \leq K-1$，第$k$个结点为 $\{x_1, \ldots, x_n\}$的样本第$(k-1)/(K-1)$分位数。

2) $\xi_1 = \min\{x_1, \ldots, x_n\}$, $\xi_K = \max\{x_1, \ldots, x_n\}$. 中间的$K-2$个结点均匀分布在$\xi_1$与$\xi_K$之间。

而K的取值，则通常利用交叉验证 (cross validation) 来选取 (将在第五讲介绍)。

从一个更一般的角度来看数据的拟合，理想的情况是找到一个函数$f(x)$ (不假设任何形式，不一定是多项式或者分段多项式)，使得$f(x)$既能够贴合观测到的样本，又有一定的光滑性。因此考虑一个带“惩罚项”的最小二乘法：

$$\min_f \left[\sum_{i=1}^n \{y_i - f(x_i)\}^2 + \lambda \int f''(x)^2 \right], \tag{5}$$

其中$\lambda > 0$, 而$\lambda \int f''(x)^2$项是为$f(x)$的非光滑性做的惩罚。可以证明，(5)的解就是一个以$\xi_1 = x_1, \ldots, \xi_n = x_n$为结点的自然三次样条，称为一个**平滑样条 (smoothing spline)** 函数。(5)中的λ通常利用交叉验证来选取。

例 (Wage Data) 见R程序。

3.2 基函数

由(4)可以看出，将$f(x)$写成一组基函数的线性组合，就可以用最小二乘法估计系数。一般地，若有一组基函数$\{\phi_1(x), \ldots, \phi_M(x)\}$，可以做线性组合

$$f(x) = \sum_{m=1}^M \beta_m \phi_m(x).$$

那么可以用最小二乘法

$$\min_{\beta_1,\ldots,\beta_M} \sum_{i=1}^n \left\{ y_i - \sum_{m=1}^M \beta_m \phi_m(x_i) \right\}^2.$$

这等价于解一个多元线性回归问题。

三次样条，的另外一组基函数就是B-样条 (B-splines)，详见Weisberg Section 5.4。

4 主成分分析

假设有p个连续自变量$X_1, \ldots, X_p$ (均视作随机变量)，我们希望构造变量的线性组合，可以尽量多的代表出这些变量的“信息”。考虑系数$\mathbf{a} = (a_1, \ldots, a_p)^\top \in \mathbb{R}^p$，构造随机变量

$$Z = \sum_{j=1}^p a_j X_j,$$

那么Z中所代表的关于$X_1, \ldots, X_p$的“信息”可用Z的方差来衡量。因此要解

$$\max_{\mathbf{a}} \mathrm{Var}(Z)$$
$$\text{s.t.} \|\mathbf{a}\| = 1.$$

若记$(X_1,\ldots,X_p)$的协方差矩阵为$\mathbf{\Gamma}\in\mathbb{R}^{p\times p}$ (即$\mathbf{\Gamma}_{jk}=\mathrm{Cov}(X_j,X_k)$)，那么$\mathrm{Var}(Z)=\mathbf{a}^\top\mathbf{\Gamma}\mathbf{a}$. 假设$\mathbf{\Gamma}$的特征值按从大到小排序为$\lambda_1\geq\cdots\geq\lambda_p\geq 0$，相应的特征向量为$\mathbf{u}_1=(u_{11},\ldots,u_{p1})^\top,\ldots,\mathbf{u}_p=(u_{1p},\ldots,u_{pp})^\top$。可以证明，上述优化问题的解为$\hat{\mathbf{a}}=\mathbf{u}_1$。我们把$Z_1=\sum_{j=1}^p u_{j1}X_j$称为**第一个主成分(the first principal component)**，而把$u_{11},\ldots,u_{p1}$称为它的**载荷 (loadings)**。而目标函数的最优值即为$\mathrm{Var}(Z_1)=\lambda_1$。

接下来，希望求解

$$\begin{aligned}&\max_{\mathbf{a}}\mathrm{Var}(Z)\\ &\text{s.t.}\|\mathbf{a}\|=1\\ &<\mathbf{a},\mathbf{u}_1>=0.\end{aligned}$$

可以证明，解为$\hat{\mathbf{a}}=\mathbf{u}_2$。我们把$Z_2=\sum_{j=1}^p u_{j2}X_j$称为**第二个主成分**，而$\mathrm{Var}(Z_2)=\lambda_2$。

一直进行下去，可以得到第三至第p个主成分$Z_3,\ldots,Z_p$，且有$\mathrm{Var}(Z_j)=\lambda_j$。于是

$$\sum_{j=1}^p\mathrm{Var}(Z_j)=\sum_{j=1}^p\lambda_j=\mathrm{tr}(\mathbf{\Gamma})=\sum_{j=1}^p\mathrm{Var}(X_j),$$

即p个主成分$Z_1,\ldots,Z_p$合起来包括了原变量$X_1,\ldots,X_p$的所有“信息”。若只取前$q\leq p$个主成分$Z_1,\ldots,Z_q$，那么代表的“信息”占比为

$$\sum_{j=1}^q\lambda_j/\sum_{j=1}^p\lambda_j.$$

若观测到样本$(x_{11},\ldots,x_{1p}),\ldots,(x_{n1},\ldots,x_{np})$，则可计算样本协方差矩阵$\widehat{\mathbf{\Gamma}}\in\mathbb{R}^{p\times p}$，即

$$\widehat{\Gamma}_{jk}=\frac{1}{n-1}\sum_{i=1}^n(x_{ij}-\bar{x}_j)(x_{ik}-\bar{x}_k),\quad 1\leq j,k\leq p$$

其中$\bar{x}_j=\sum_{i=1}^n x_{ij}/n$, $\bar{x}_k=\sum_{i=1}^n x_{ik}/n$。对$\widehat{\mathbf{\Gamma}}$进行特征值分解，得到特征值$\hat{\lambda}_1\geq\cdots\geq\hat{\lambda}_p$及相应的特征向量$\hat{\mathbf{u}}_1=(\hat{u}_{11},\ldots,u_{p1})^\top,\ldots,\hat{\mathbf{u}}_p=(\hat{u}_{1p},\ldots,u_{pp})^\top$。于是可以进一步得到第$j$个主成分$\hat{Z}_j$及其样本值

$$\hat{Z}_j=\sum_{k=1}^p\hat{u}_{kj}X_k\xrightarrow{\text{样本值}}\begin{bmatrix}\hat{z}_{1j}\\ \vdots\\ \hat{z}_{nj}\end{bmatrix}=\begin{bmatrix}\sum_{k=1}^p\hat{u}_{kj}x_{1k}\\ \vdots\\ \sum_{k=1}^p\hat{u}_{kj}x_{nk}\end{bmatrix}.$$

这些样本值$\hat{z}_{1j},\ldots,\hat{z}_{nj}$称为第$j$个主成分的**得分 (score)**。

很多时候，还可以对样本$(x_{11},\ldots,x_{1p}),\ldots,(x_{n1},\ldots,x_{np})$的相关系数矩阵进行特征值分解得到主成分，而这等价于将每一个变量先进行“标准化”(即减去该变量均值，再除以该变量的标准差)，再对标准化之后的变量进行主成分分析。

例 (Weisberg Section 5.5, Professor Ratings) 见R程序。