上海财经大学
信息管理与工程学院
《高维数据分析》讲义

第五讲　变量选择

袁洪松

内容概要：

Bias-variance Tradeoff，模型选择准则，逐步回归

课本章节：

Weisberg Chapter 10

1　Bias-variance Tradeoff

假设一个线性回归模型

$$y_i = \beta_0^* + \sum_{j=1}^{p^*} x_{ij}\beta_j^* + e_i, \quad 1 \le i \le n,$$

其中$\mathrm{Var}(e_i) = \sigma_*^2$。但现有数据中除了以上$p^*$个自变量以外，还有其它自变量。假设数据中一共有$p > p^*$个自变量，该如何从中选择自变量加入模型？

由多元线性回归的知识可知，自变量加的个数越多，回归的残差平方和RSS越小，回归的R^2越大，表明回归拟合得越好。但是预测的效果如何？

记$\mathbf{x}_i = (x_{i1}, \ldots, x_{ip})^\top$, $f^*(\mathbf{x}_i) = \beta_0^* + \sum_{j=1}^{p^*} x_{ij}\beta_j^*$，则真实模型记为$y_i = f^*(\mathbf{x}_i) + e_i$。假设由样本$(\mathbf{x}_1, y_1), \ldots, (\mathbf{x}_n, y_n)$估计出来的均值函数为$\hat{f}(\mathbf{x}_i)$ (估计时可能没有用到全部p个自变量)。对于新观测到的自变量$\mathbf{x}_{\mathrm{new}}$，其因变量的真实值应为

$$y_{\mathrm{new}}^* = f^*(\mathbf{x}_{\mathrm{new}}) + e_{\mathrm{new}}.$$

而按照估计的均值函数，我们对均值函数的预测值为$\hat{y}_{\mathrm{new}} = \hat{f}(\mathbf{x}_{\mathrm{new}})$。因此可以定义**预测误差 (Prediction Error)**

$$\mathrm{PE} = \mathrm{E}\left(\hat{y}_{\mathrm{new}} - y_{\mathrm{new}}^*\right)^2.$$

可以得到

$$\begin{aligned}
\mathrm{PE} &= \mathrm{E}\left\{\hat{f}(\mathbf{x}_{\mathrm{new}}) - f^*(\mathbf{x}_{\mathrm{new}}) - e_{\mathrm{new}}\right\}^2 \\
&= \mathrm{E}\left\{\hat{f}(\mathbf{x}_{\mathrm{new}}) - f^*(\mathbf{x}_{\mathrm{new}})\right\}^2 + \mathrm{Var}(e_{\mathrm{new}}) \\
&= \mathrm{E}\left\{\hat{f}(\mathbf{x}_{\mathrm{new}}) - \mathrm{E}\hat{f}(\mathbf{x}_{\mathrm{new}}) + \mathrm{E}\hat{f}(\mathbf{x}_{\mathrm{new}}) - f^*(\mathbf{x}_{\mathrm{new}})\right\}^2 + \sigma_*^2 \\
&= \mathrm{E}\left\{\hat{f}(\mathbf{x}_{\mathrm{new}}) - \mathrm{E}\hat{f}(\mathbf{x}_{\mathrm{new}})\right\}^2 + \mathrm{E}\left\{\mathrm{E}\hat{f}(\mathbf{x}_{\mathrm{new}}) - f^*(\mathbf{x}_{\mathrm{new}})\right\}^2 \\
&+ 2\mathrm{E}\left[\left\{\hat{f}(\mathbf{x}_{\mathrm{new}}) - \mathrm{E}\hat{f}(\mathbf{x}_{\mathrm{new}})\right\}\left\{\mathrm{E}\hat{f}(\mathbf{x}_{\mathrm{new}}) - f^*(\mathbf{x}_{\mathrm{new}})\right\}\right] + \sigma_*^2 \\
&= \mathrm{Var}\left\{\hat{f}(\mathbf{x}_{\mathrm{new}})\right\} + \left\{\mathrm{E}\hat{f}(\mathbf{x}_{\mathrm{new}}) - f^*(\mathbf{x}_{\mathrm{new}})\right\}^2 \\
&+ 2\left\{\mathrm{E}\hat{f}(\mathbf{x}_{\mathrm{new}}) - f^*(\mathbf{x}_{\mathrm{new}})\right\}\mathrm{E}\left\{\hat{f}(\mathbf{x}_{\mathrm{new}}) - \mathrm{E}\hat{f}(\mathbf{x}_{\mathrm{new}})\right\} + \sigma_*^2 \\
&= \mathrm{Var}\left\{\hat{f}(\mathbf{x}_{\mathrm{new}})\right\} + \left\{\mathrm{E}\hat{f}(\mathbf{x}_{\mathrm{new}}) - f^*(\mathbf{x}_{\mathrm{new}})\right\}^2 + \sigma_*^2.
\end{aligned}$$

其中$\mathrm{Var}\left\{\hat{f}(\mathbf{x}_{\mathrm{new}})\right\}$称为**方差项 (variance)**，$\left\{\mathrm{E}\hat{f}(\mathbf{x}_{\mathrm{new}}) - f^*(\mathbf{x}_{\mathrm{new}})\right\}^2$称为**偏差平方项 (bias^2)**，而$\sigma_*^2$称为**不可消减误差 (irreducible error)**。

说明：

1) 若对数据进行重新抽样，得到一组新的$(\mathbf{x}_1, y_1), \ldots, (\mathbf{x}_n, y_n)$，则会拟合出不同的$\hat{f}$，也就会有不同的预测值$\hat{f}(\mathbf{x}_{\mathrm{new}})$。大量不断重复抽样后得到所有$\hat{f}(\mathbf{x}_{\mathrm{new}})$的平均值即为$\mathrm{E}\hat{f}(\mathbf{x}_{\mathrm{new}})$。而重复抽样过程中$\hat{f}(\mathbf{x}_{\mathrm{new}})$与其均值的偏离程度可用$\mathrm{Var}\left\{\hat{f}(\mathbf{x}_{\mathrm{new}})\right\}$表示。

2) **模型灵活度 (model flexibility)** 越大 (例如拥有更多参数)，则偏差平方项越小，但方差项越大。例如，若取$\hat{f}(\mathbf{x}) \equiv 0$，即模型没有任何可调节的参数，则预测的方差项为0，但偏差会较大。若让模型中有至少n个参数，使得$\hat{f}(\mathbf{x}_i) = y_i$对所有$1 \le i \le n$都成立，则预测偏差会比较小，但方差会比较大 (因为一旦换一组$y_1, \ldots, y_n$，那么参数的值会变化较大，导致预测波动大)。

3) 通常很难做到方差项与偏差平方项都小，所以需要在两者间寻求一种权衡，使得总预测误差尽可能小。这种权衡叫做**bias-variance tradeoff**。

例 (多项式回归) 模型的bias和variance分别代表什么？举个多项式回归的例子。

假设只有一个自变量x，真实模型为

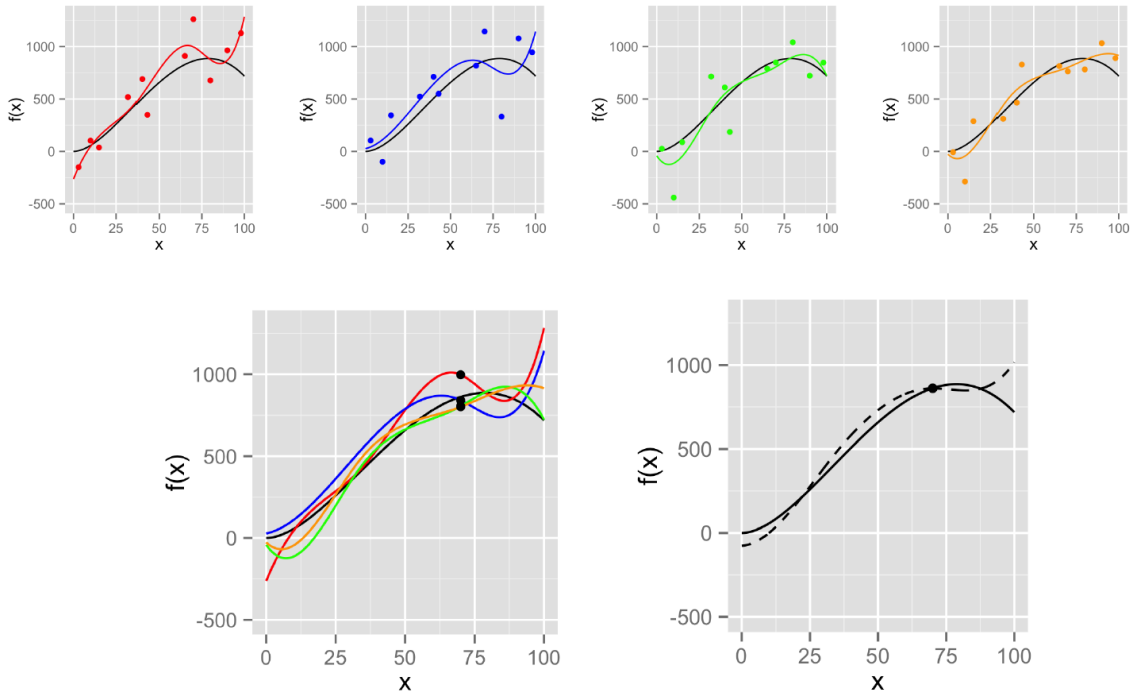
$$y_i = f^*(x_i) + e_i,$$

其中$f(x)$为d^*次多项式 ($f^*(\cdot)$的形状由图1中黑色实线给出)。现在用d次多项式函数拟合一组数据 (x_1, y_1), $\ldots$, (x_n, y_n)，可以得到$f^*(x)$的估计$\widehat{f}(x)$。

我们固定$x_1, \ldots, x_n$，而每次生成一组新的$y_1, \ldots y_n$，共生成四组数据，对应图1上排四张图中的彩色点。对于每组数据，得到的估计$\widehat{f}(x)$都会不同 (对应上排四张图中的彩色实线)。这样，对于某个x_{new}，预测值$\widehat{f}(x_{\mathrm{new}})$会有起伏，$\widehat{f}(x_{\mathrm{new}})$的方差就是variance。即

$$\mathrm{Variance} = \mathrm{Var}\left\{\widehat{f}(x_{\mathrm{new}})\right\}.$$

图 1: 多项式回归中bias与variance的含义



它可以由各组$\widehat{f}(x_{\text{new}})$值的样本方差来近似。

而Bias为预测值$\widehat{f}(x_{\text{new}})$的期望与真实值$f^*(x_{\text{new}})$的差，即

$$\text{Bias} = E\left\{\widehat{f}(x_{\text{new}})\right\} - f^*(x_{\text{new}}).$$

它可以由各组$\widehat{f}(x_{\text{new}})$样本均值减去真实值$f^*(x_{\text{new}})$来近似。(图1下排最后一张图中，四组数据对应的$\widehat{f}(x_{\text{new}})$的平均值与真实值$f^*(x_{\text{new}})$几乎重合于黑点，所以bias几乎为0。)

例 (多项式回归) 模型的flexibility与bias, variance分别是什么关系？也以多项式为例来说明。

一般来说，模型越flexible，则variance越大，而bias^{2}越小。反之，模型越不flexible，则variance越小，bias^{2}越大。模型的flexibility通常可以用参数的个数来衡量。

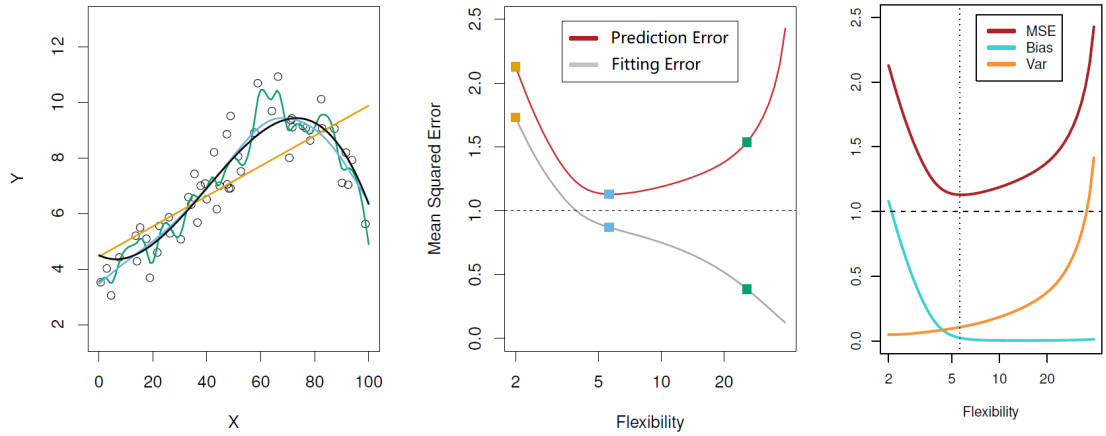
假设只有一个自变量，真实模型为

$$y_i = f^*(x_i) + e_i,$$

其中$f(x)$为d^*次多项式。图2的左图中，空心原点表示样本点，黑色实线代表真实均值函数$f^*(x)$，黄色实线代表线性拟合的函数 (最不flexible的模型)，蓝色实线代表低次多项式拟合 (适度flexible的模型)，而绿色实线代表高次多项式拟合 (过于flexible的模型)。可以看出，对于样本点来说，线性拟合效果最差，而高次多项式拟合效果最好。

图2的中图中，横轴flexibility为拟合的多项式次数，纵轴为均方误差 (mean squared error, MSE)。灰色实线表示拟合误差 (MSE即为RSS$/n$)，而红色实线代表预测误差 (MSE即为PE)。可以看出，拟合

图 2: 多项式回归中bias和variance与多项式次数的关系



误差随着flexibility的增加逐渐减小，而预测误差则先减后增。

图2的右图中，将预测误差 (红色线) 分解为bias^2 (青色线) 与variance (橙色线)。可以看出，随着flexibility的增加，bias^{2}逐渐减小，而variance则逐渐增大。

2 模型选择准则

想要决定哪些变量进入模型，这个过程叫做**模型选择 (model selection)**。以下我们介绍四个模型选择准则。

2.1 Adjusted R^2

假设线性模型中用了k个自变量 ($1 \le k \le p$)，得到的可决系数为R^2 (实际上，这里R^2依赖于k的取值以及选用了哪k个自变量，但我们在符号中忽略了这个依赖关系)。

Adjusted R^2定义为

$$R^2_{adj} = 1 - \frac{n-1}{n-k-1}(1-R^2).$$

说明：

1) R^2_{adj}不会随着k的增加一直增大，因为其中对较大的k起到了“惩罚”的作用。实际应用时，应选取使R^2_{adj}最大的k。

2) 我们有关系式$R^2_{\text{adj}} \le R^2$.

3) R^2_{adj}可能为负数，但不会超过1.

2.2 AIC

根据对变量个数进行“惩罚”的思想，Akaike (1973) 提出了**Akaike信息准则 (Akaike information criterion, AIC)**

$$\mathrm{AIC} = -2\log(\text{maximum likelihood}) + 2 \cdot \text{number of parameters}.$$

对于线性模型，对数似然函数的极大值为

$$-\frac{n}{2}\log(2\pi) - \frac{n}{2}\log\left(\frac{\mathrm{RSS}}{n}\right) - \frac{n}{2}$$

注意AIC是用来比较不同的变量选择方式的优劣，故应在意其相对大小，而非绝对大小。我们略去与变量选择无关的项，得到此时的AIC为

$$\mathrm{AIC} = n\log\left(\frac{\mathrm{RSS}}{n}\right) + 2(k+1).$$

其中$2(k+1)$可以视作对变量个数的“惩罚”。在使用AIC做模型选择时，应选用使得AIC最小的一组变量。

2.3 BIC

在许多时候，AIC中的“惩罚”项力度仍然不够。Schwartz (1978) 提出了**Bayes信息准则 (Bayes information criterion, BIC)**

$$\mathrm{BIC} = n\log\left(\frac{\mathrm{RSS}}{n}\right) + (k+1)\log n.$$

在使用BIC做模型选择时，应选用使得BIC最小的一组变量。若$\log n > 2$，则BIC选出的模型的变量个数不会大于AIC选出的模型的变量个数。

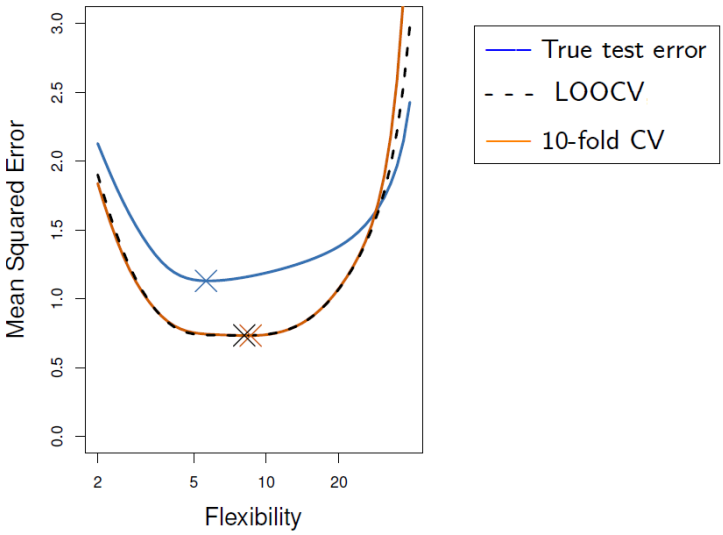
2.4 交叉验证

模型选择的另一种方法是利用现有数据估算出预测误差，再选取预测误差最小的模型。基本的想法是，将数据分为两部分，一部分用来拟合模型，另一部分用来预测因变量。前者称为**训练集 (training set)**，后者称为**验证集 (validation set)**。

假设一共有M个待选模型。我们将数据分为k份 (一般保持每份样本量相等或大致相等)。对于一个固定的$1 \le m \le M$, 对每一个$1 \le i \le k$，用除第i份数据之外的所有数据作为训练集来拟合模型，再用第i份数据作为验证集来计算拟合结果对验证集样本平均预测误差，记为$\widehat{\mathrm{PE}}_i(m)$。令

$$\mathrm{CV}(m) = \frac{1}{k}\sum_{i=1}^{k}\widehat{\mathrm{PE}}_i(m)$$

图 3: 多项式回归中CV的效果



最后选取使得CV(m)最小的模型，即

$$m^* = \arg \min_{1 \le m \le M} \mathrm{CV}(m).$$

这个过程称为**k-fold交叉验证 (k-fold cross validation, k-fold CV)**。

说明：

1) 通常取$k = 5$或$k = 10$。也可以取$k = n$，此时的交叉验证也成为留一法交叉验证 (leave-one-out CV)。

2) CV只能用于模型选择。选好模型m^*之后，需要再用全部数据当做训练集重新拟合参数，作为最终的模型。

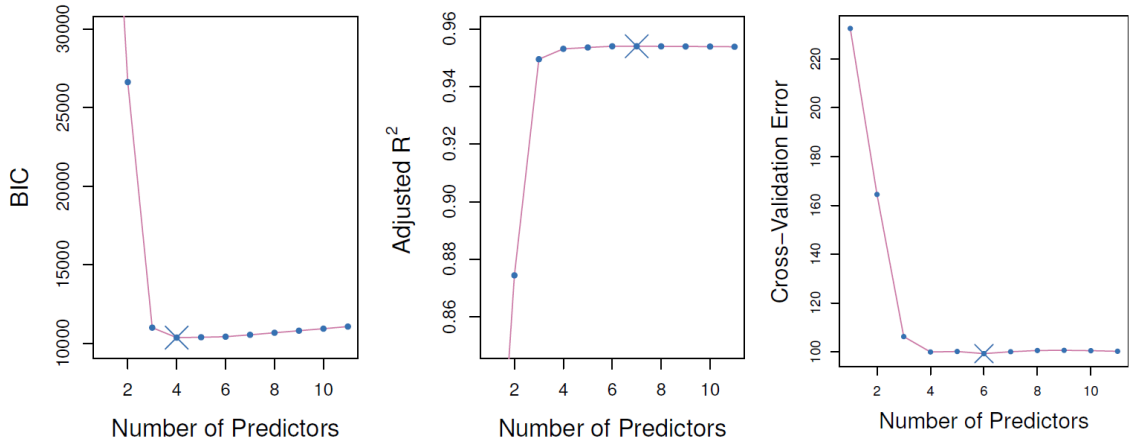
例 (多项式回归) 以多项式回归来说明CV如何帮助选拟合的次数。在图3中，蓝线表示真正样本外的预测误差，黑线表示留一法得到的CV值，而橙线表示10-fold交叉验证得到的CV值。可以看出，交叉验证的CV值与真正样本外的预测误差可能有较大差别，但交叉验证选择出的模型的样本外预测误差也十分接近于其最小值。

例 (几种模型选择准则的应用) 在线性回归中利用模型选择准则选择变量数，如图4。

在CV中，有时相近的模型之间的CV值会非常接近，为避免过拟合，可以遵循**“1标准误规则” (one standard error rule)**，即选取CV值在1标准误之内flexibility最小的模型。具体来说，可以先计算预测误差$\widehat{\mathrm{PE}}_i(m)$的样本标准差

$$\mathrm{SD}(m) = \sqrt{\frac{1}{k-1} \sum_{i=1}^{k} \left\{ \widehat{\mathrm{PE}}_i(m) - \mathrm{CV}(m) \right\}^2}.$$

图 4: BIC, Adjusted R^2, CV等几个模型选择准则选择变量数的对比



然后再计算CV的标准误

$$\mathrm{SE}(m) = \frac{1}{\sqrt{k}}\mathrm{SD}(m).$$

模型选择时，在所有满足$\mathrm{CV}(m) < \mathrm{CV}(m^*) + \mathrm{SE}(m^*)$的$m$中，选择flexibility最小的模型$m^*_{\mathrm{1se}}$。参考图5。

3 逐步回归

3.1 Forward Selection与Backward Elimination

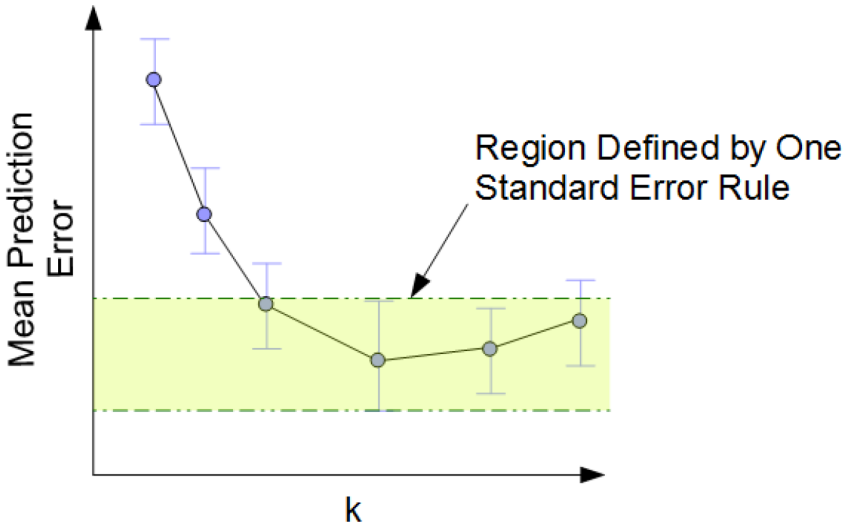
除了变量个数以外，我们还需要决定有哪些变量应加入模型。在穷举法计算量过大时，常见的做法是**逐步回归 (stepwise regression)**。而逐步回归又包括 **forward selection**，**backward elimination**以及**FS+BE**方法。

Forward selection的步骤为：

1. 拟合一个只有截距的模型。计算AIC (或BIC，或$-R^2_{adj}$)。
2. For $m = 1$ to M
   (a) 从p个变量中选取第j_m个变量，使得当前模型加入第j_m个变量后，(相对于加入其它变量) AIC (或残差平方和, 或BIC，或$-R^2_{adj}$) 最小。计算加入变量之后的AIC (或BIC，或$-R^2_{adj}$)。

   End for
3. 从1和2中得到的$M+1$个AIC (或BIC，或$-R^2_{adj}$)中，选取最小的AIC (或BIC，或$-R^2_{adj}$)。其对应的模型即为最终模型。

图 5: 1标准误规则



说明：若模型可能包括主效应项 (即一阶项) 和更高阶项，则在2中需要遵循marginality principle，即在所有低阶项都被选进来之前，不考虑选入更高阶项。(参考Weisberg p.240)

Backward elimination的步骤为：

1. 拟合一个包含所有p个变量的模型。计算AIC (或BIC，或$-R^2_{adj}$)。
2. For $m = 1$ to M

   (a) 从现有模型中去掉一个变量，使得当前模型去掉此变量后，(相对于去掉其它变量) AIC (或残差平方和, 或BIC，或$-R^2_{adj}$) 最小。计算去掉变量之后的AIC (或BIC，或$-R^2_{adj}$)。

   End for
3. 从1和2中得到的$M+1$个AIC (或BIC，或$-R^2_{adj}$)中，选取最小的AIC (或BIC，或$-R^2_{adj}$)。其对应的模型即为最终模型。

说明：

1) Backward elimination需要$p < n$成立才能执行。

2) 若模型可能包括主效应项和更高阶项，则在2中也需要遵循marginality principle，即在所有高阶项都被去掉之前，不考虑去掉更低阶项。(参考Weisberg p.240)

FS+BE的步骤为：

1. 拟合某个模型。计算AIC (或BIC，或$-R^2_{adj}$)。
2. For $m = 1$ to M

(a) 加入一个变量或去掉一个现有模型中的变量，使得加入或去掉此变量后，(相对于加入或去掉其它变量) AIC (或BIC，或$-R^2_{adj}$) 最小。计算加入或去掉变量之后的AIC (或BIC，或$-R^2_{adj}$)。

End for

3. 从1和2中得到的$M+1$个AIC (或BIC，或$-R^2_{adj}$)中，选取最小的AIC (或BIC，或$-R^2_{adj}$)。其对应的模型即为最终模型。

说明：若模型可能包括主效应项和更高阶项，则在2中亦需遵循marginality principle。(参考Weisberg p.240)

例 (Weisberg Section 10.2.2 Highway Accidents) 见R程序。

3.2 Orthogonal Greedy Algorithm (OGA) (不要求)

无论是FS或者BE，每一步都需要重新做OLS拟合一个多元回归模型。当变量数较大时，算法的计算成本很大。Ing and Lai [2011]提出一种orthogonal greedy algorithm (OGA)，利用Gram-Schimidt正交化法避免求矩阵的逆，改进计算效率。

OGA的步骤为：

1. 拟合一个只有截距的模型。取初始残差$\mathbf{e}^{(0)}$与入选变量集合$J^{(0)}=\emptyset$ (空集).

2. For $m=1$ to M

   (a) 从变量集合$\{1,\ldots,p\}\backslash J^{(m-1)}$中选取第$\widehat{j}_m$个变量，使得当前模型加入第$\widehat{j}_m$个变量后，(相对于加入其它变量) 残差平方和最小。

   (b) 若$m=1$, 令
   $$\widehat{X}^{\perp}_{\langle\widehat{j}_m\rangle}=X_{\langle\widehat{j}_m\rangle}.$$
   若$m>1$, 计算$X_{\langle\widehat{j}_m\rangle}$在$X^{\perp}_{\langle\widehat{j}_1\rangle},\ldots,X^{\perp}_{\langle\widehat{j}_{m-1}\rangle}$张成的线性空间上的投影$\widehat{X}_{\langle\widehat{j}_m\rangle}$, 并令
   $$\widehat{X}^{\perp}_{\langle\widehat{j}_m\rangle}=X_{\langle\widehat{j}_m\rangle}-\widehat{X}_{\langle\widehat{j}_m\rangle}.$$

   (c) 计算$\mathbf{e}^{(m-1)}$在$X^{\perp}_{\langle\widehat{j}_m\rangle}$上的投影$\widehat{\mathbf{e}}^{(m-1)}$, 并令
   $$\mathbf{e}^{(m)}=\mathbf{e}^{(m-1)}-\widehat{\mathbf{e}}^{(m-1)}$$

   (d) 令
   $$J^{(m)}=J^{(m-1)}\cup\left\{\widehat{j}_m\right\}.$$

   End For

3. 从2中得到的M个模型中，选取使得某个模型选择准则最优的模型。

图 6: OGA+HDIC与其它逐步选变量法的实验结果对比 (Ing and Lai [2011])

Table 1. Frequency, in 1,000 simulations, of including all five relevant variables (Correct), of selecting exactly the relevant variables (E), of selecting all relevant variables and i irrelevant variables (E+i), and of selecting the largest model, along the OGA path, which includes all relevant variables (E*).

η	n	p	Method	E	E+1	E+2	E+3	E+4	E+5	E*	Correct	MSPE
0	50	1,000	OGA+HDHQ	812	86	19	8	0	0	1	926	6.150
			OGA+HDBIC	862	52	7	1	0	0	0	922	6.550
			OGA+HDBIC+Trim	919	3	0	0	0	0	0	922	6.550
			OGA+BIC	0	0	0	0	0	0	926	926	8.310
			FR	0	0	0	0	0	0	926	926	8.300
	100	2,000	OGA+HDHQ	993	6	0	1	0	0	0	1,000	0.065
			OGA+HDBIC	999	0	0	1	0	0	0	1,000	0.064
			OGA+HDBIC+Trim	1,000	0	0	0	0	0	0	1,000	0.064
			OGA+BIC	0	0	0	0	0	0	1,000	1,000	1.320
			FR	0	0	0	0	0	0	1,000	1,000	1.729
	200	4,000	OGA+HDHQ	999	1	0	0	0	0	0	1,000	0.034
			OGA+HDBIC	1,000	0	0	0	0	0	0	1,000	0.034
			OGA+HDBIC+Trim	1,000	0	0	0	0	0	0	1,000	0.034
			OGA+BIC	0	0	0	0	0	0	1,000	1,000	0.796
			FR	0	0	0	0	0	0	1,000	1,000	1.612

在OGA的第m步中，算法将当前选出的变量对之前选出的变量集做正交化，即Gram-Schmidt正交化，得到一组正交基$X^{\perp}_{\langle \hat{j}_1 \rangle}, \ldots, X^{\perp}_{\langle \hat{j}_m \rangle}$. 注意在计算$X_{\langle \hat{j}_m \rangle}$的投影时，由于$X^{\perp}_{\langle \hat{j}_1 \rangle}, \ldots, X^{\perp}_{\langle \hat{j}_{m-1} \rangle}$各自互相正交，只需要做一系列一元线性回归$X_{\langle \hat{j}_m \rangle} \sim X^{\perp}_{\langle \hat{j}_1 \rangle}, \ldots, X_{\langle \hat{j}_m \rangle} \sim X^{\perp}_{\langle \hat{j}_{m-1} \rangle}$即可，不涉及到矩阵求逆，计算效率可以大大提升。

同时，Ing and Lai [2011]还将经典信息准则修改为高维信息准则 (high-dimensional information criteria, HDIC)，在高维变量时能更严格地控制变量的个数。定义high-dimensional AIC (HDAIC)：

$$\text{HDAIC} = n \log \left(\frac{\text{RSS}}{n} \right) + ck \log p.$$

定义high-dimensional BIC (HDBIC):

$$\text{HDBIC} = n \log \left(\frac{\text{RSS}}{n} \right) + k \log p \log n.$$

HDAIC, HDBIC为在原始AIC, BIC的惩罚项中加入乘子$\log p$, 对变量个数的惩罚更加严厉。

OGA模拟实验结果如图6与图7所示。

图 7: OGA+HDIC与正则化方法的实验结果对比 (Ing and Lai [2011])

Method	E	E+1	E+2	E+3	Correct	MSPE
OGA+HDHQ	980	18	1	1	1,000	0.067
OGA+HDBIC	982	16	1	1	1,000	0.067
OGA+HDBIC+Trim	1,000	0	0	0	1,000	0.066
SIS-SCAD	127	19	10	14	289	15.170
ISIS-SCAD	0	0	0	0	1,000	1.486
Adaptive Lasso	1,000	0	0	0	1,000	0.289
LARS	0	0	0	0	1,000	0.549
Lasso	0	0	0	0	1,000	0.625

References

C.-K. Ing and T. L. Lai. A stepwise regression method and consistent model selection for high-dimensional sparse linear models. *Statistica Sinica*, 21(4):1473–1513, 2011.