上海财经大学
Shanghai University of Finance & Economics

上海财经大学
信息管理与工程学院
《高维数据分析》讲义

第六讲　正则化方法与高维回归分析

袁洪松

内容概要：
正则化方法，高维回归分析示例

课本章节：
Weisberg Chapter 10.2.3

1　Stein缩减

考虑如下问题：假设总体服从正态分布$N(\mu,1)$, 观察到样本$\mathbf{Y}=(y_1,\ldots,y_n)^\top$，其中$n>2$. 那么如何估计$\mu$？如何预测一个新的样本$y^{\text{new}}$？预测效果如何？(James and Stein, 1960)

假设$\widehat{\mu}$为μ的任一个估计量。如果有新的样本y^{new}，我们可以先表示成$y^{\text{new}}=\mu+e^{\text{new}}$，其中$e^{\text{new}}$为$N(0,1)$。很自然地，可以用$\widehat{\mu}$来预测$z^{\text{new}}$. 根据预测误差的分解 (参考上一讲)，$\widehat{\mu}$的预测误差为

$$\begin{aligned}\text{PE}(\widehat{\mu}) &= \text{variance}(\widehat{\mu})+\text{bias}(\widehat{\mu})^2+\text{irreducible error}\\ &= \text{Var}(\widehat{\mu})+\{\text{E}(\widehat{\mu})-\mu\}^2+1.\end{aligned}$$

一个看上去很好的估计量是$\widehat{\mu}_0=\bar{y}=\sum_{i=1}^n y_i/n$. 显然，$\bar{y}$是$\mu$的无偏估计：$\text{E}(\bar{y})=\mu$, 故偏差项为0。而方差项为$\text{Var}(\bar{y})=1/n$。于是预测误差为$\text{PE}(\bar{y})=1+1/n$. 注意到，$\bar{y}$可以看做是如下问题的解：

$$\min_{\beta}\|\mathbf{Y}-\beta\mathbf{1}_n\|^2, \tag{1}$$

即一个以$\mathbf{Y}$为因变量，只有截距的最小二乘问题。

问题：能否“牺牲”一些无偏性，带来预测误差的整体减少？

想法：考虑将$\widehat{\mu}_0$“缩减” (shrink) c倍 $(0\le c\le 1)$，得到新的估计量$\widehat{\mu}_0'=c\widehat{\mu}_0$。则它的方差为$\text{Var}(\widehat{\mu}_0')=c^2/n$，偏差平方项为$\{\text{E}(\widehat{\mu}_0')-\mu\}^2=(1-c)^2\mu^2$，故预测误差为

$$\text{PE}(\widehat{\mu}_0')=c^2/n+(1-c)^2\mu^2+1.$$

当c取$c^*=\mu^2/(\mu^2+1/n)$时，$\text{PE}(\widehat{\mu}_0')$达到最小值

$$\frac{\mu^2}{\mu^2+1/n}\cdot\frac{1}{n}+1\le\text{PE}(\widehat{\mu}).$$

此时

$$\widehat{\mu}_0' = \frac{\mu^2}{\mu^2 + 1/n}\bar{y}.$$

如果用$\bar{y}^2$代替未知量μ^2，则得到一个缩减的估计量

$$\widehat{\mu}_0'' = \frac{\bar{y}^2}{\bar{y}^2 + 1/n}\bar{y}.$$

令$\lambda = 1/\bar{y}^2$，则$\widehat{\mu}_0''$可看做以下问题的解：

$$\min_{\beta} \|\mathbf{Y} - \beta \mathbf{1}_n\|^2 + \lambda|\beta|^2,$$

相当于最小二乘问题(1)加了一个惩罚项 (penalty term) $\lambda|\beta|^2$.

2 正则化方法

2.1 岭回归

收到Stein缩减法的启发，在线性回归模型中，我们考虑通过对最小二乘估计进行缩减引入一些偏差，从而减小整体预测误差。假设回归的样本为$(x_{11}, \ldots, x_{1p}; y_1), \ldots, (x_{n1}, \ldots, x_{np}; y_1)$，**岭回归 (ridge regression)**考虑如下问题：

$$\min_{\beta_0, \beta_1, \ldots, \beta_p} F(\beta_0, \beta_1, \ldots, \beta_p) = \sum_{i=1}^{n} \left(y_i - \beta_0 - \sum_{j=1}^{p} x_{ij}\beta_j \right)^2 + \lambda \sum_{j=1}^{p} \beta_j^2,$$

即最小二乘法的目标函数加上惩罚项$\lambda \sum_{j=1}^{p} \beta_j^2$，其中$\lambda > 0$称为一个tuning parameter。

将$F(\beta_0, \beta_1, \ldots, \beta_p)$对$\beta_0$求偏导，并令其为0，得到

$$\frac{\partial F}{\partial \beta_0} = -2 \sum_{i=1}^{n} (y_i - \beta_0 - \sum_{j=1}^{p} x_{ij}\beta_j) = 0.$$

于是知道

$$\beta_0 = \bar{y_i} - \sum_{j=1}^{p} \bar{x}_j \beta_j,$$

代回目标函数，得到

$$\sum_{i=1}^{n} \left\{ (y_i - \bar{y}) - \sum_{j=1}^{p} (x_{ij} - \bar{x}_j)\beta_j \right\}^2 + \lambda \sum_{j=1}^{p} \beta_j^2.$$

采用中心化之后的符号 (见第三讲)，则目标函数变为

$$\|\mathcal{Y} - \mathcal{X}\mathbf{b}\|^2 + \lambda \|\mathbf{b}\|^2.$$

对$\mathbf{b}$求偏导，令其为0，得到

$$-2\mathcal{X}^\top(\mathcal{Y}-\mathcal{X}\mathbf{b})+2\lambda\mathbf{b}=0.$$

可以解得估计量

$$\widehat{\mathbf{b}}^{\text{ridge}}=\left(\mathcal{X}^\top\mathcal{X}+\lambda\mathbf{I}\right)^{-1}\mathcal{X}^\top\mathcal{Y}.$$

另外可知，当$\lambda=0$时，此估计量为最小二乘估计量

$$\widehat{\mathbf{b}}^{\text{ols}}=\left(\mathcal{X}^\top\mathcal{X}\right)^{-1}\mathcal{X}^\top\mathcal{Y}.$$

现在，考虑一种理想化的情形。假设$\mathcal{X}$的所有p列都标准化 (即欧式模为1)，且列与列之间互相正交，则$\mathcal{X}^\top\mathcal{X}=\mathbf{I}$。此时$\widehat{\mathbf{b}}^{\text{ols}}=\mathcal{X}^\top\mathcal{Y}$，而

$$\widehat{\mathbf{b}}^{\text{ridge}}=\frac{1}{1+\lambda}\mathcal{X}^\top\mathcal{Y}=\frac{1}{1+\lambda}\widehat{\mathbf{b}}^{\text{ols}}.$$

可见，岭回归将最小二乘估计的各个分量都按照$1/(1+\lambda)$的比例缩减了，就想Stein缩减那样。

说明：如果$\lambda>0$，则岭回归对于$p>n$的情况依然有解。

2.2 Lasso

岭回归的缺点在于不能让回归系数变为0，从而起不到变量选择的作用。Tibshirani [1996] 提出了下面方法

$$\min_{\beta_0,\beta_1,\ldots,\beta_p}G(\beta_0,\beta_1,\ldots,\beta_p)=\frac{1}{2}\sum_{i=1}^{n}\left(y_i-\beta_0-\sum_{j=1}^{p}x_{ij}\beta_j\right)^2+\lambda\sum_{j=1}^{p}|\beta_j|,$$

这称为**lasso (least absolute shrinkage and selection operator)** 算法。

经过与岭回归类似的处理方式，可以将目标转化为

$$\min_{\mathbf{b}}\frac{1}{2}\|\mathcal{Y}-\mathcal{X}\mathbf{b}\|^2+\lambda\|\mathbf{b}\|_1,$$

其中$\|\mathbf{b}\|_1=\sum_{j=1}^{p}|\beta_j|$表示$\mathbf{b}$的$L_1$模。因此lasso也称为$L_1$-正则化法 ($L_1$-regularization)，而岭回归称为$L_2$-正则化法。

以上优化问题等价于

$$\begin{aligned}&\min_{\mathbf{b}}\frac{1}{2}\|\mathcal{Y}-\mathcal{X}\mathbf{b}\|^2\\&\text{s.t.}\|\mathbf{b}\|_1\le s.\end{aligned}$$

这里s可看做分配给$\beta_1,\ldots,\beta_p$的总配额。以$p=2$为例，约束$\|\mathbf{b}\|_1\le s$在(β_1,β_2)平面上形成一个正方形区域，而目标函数的等值线$\{\mathbf{b}:\|\mathcal{Y}-\mathcal{X}\mathbf{b}\|^2=c\}$在$(\beta_1,\beta_2)$平面形成一个椭圆，椭圆大小随着$c$的增

图 1: lasso与岭回归的几何解释 (来源：James et al., An Introduction to Statistical Learning 2nd edition, Figure 6.7)

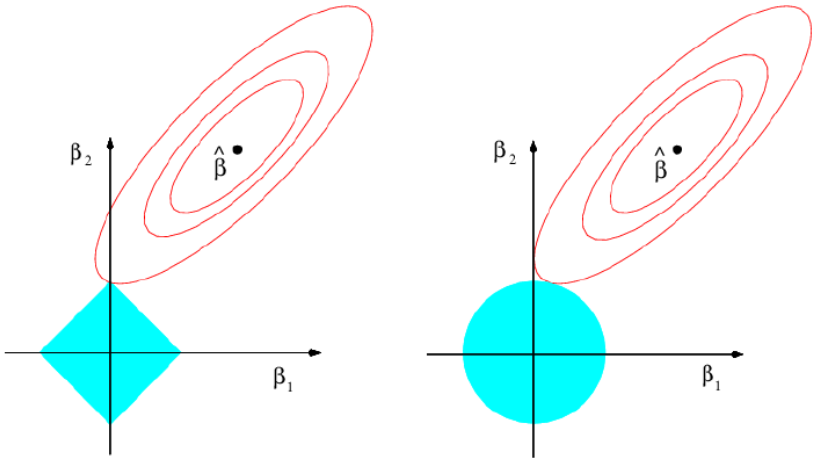


FIGURE 6.7. *Contours of the error and constraint functions for the lasso* (left) *and ridge regression* (right). *The solid blue areas are the constraint regions,* $|\beta_1| + |\beta_2| \le s$ *and* $\beta_1^2 + \beta_2^2 \le s$, *while the red ellipses are the contours of the RSS.*

加而增加。需要找到最小的c，使得椭圆与正方形相交。见图1。

如果$\mathcal{X}$的所有列都标准化，且列与列之间相互正交，则$\mathcal{X}^\top\mathcal{X} = \mathbf{I}$。此时时$\widehat{\mathbf{b}}^{\text{ols}} = \left(\widehat{\beta}_1^{\text{ols}}, \ldots, \widehat{\beta}_p^{\text{ols}}\right)^\top = \mathcal{X}^\top\mathcal{Y}$。而lasso的目标函数变为

$$\begin{aligned}\frac{1}{2}\|\mathcal{Y} - \mathcal{X}\mathbf{b}\|^2 + \lambda\|\mathbf{b}\|_1 &= \frac{1}{2}\left(\mathcal{Y}^\top\mathcal{Y} + \mathbf{b}^\top\mathcal{X}^\top\mathcal{X}\mathbf{b} - 2\mathbf{b}^\top\mathcal{X}^\top\mathcal{Y}\right) + \lambda\|\mathbf{b}\|_1 \\ &= \frac{1}{2}\left(\mathcal{Y}^\top\mathcal{Y} + \mathbf{b}^\top\mathbf{b} - 2\mathbf{b}^\top\mathcal{X}^\top\mathcal{Y}\right) + \lambda\|\mathbf{b}\|_1 \\ &= \frac{1}{2}\mathcal{Y}^\top\mathcal{Y} + \frac{1}{2}\sum_{j=1}^{p}\left(\beta_j^2 - 2\widehat{\beta}_j^{ols}\beta_j + 2\lambda|\beta_j|\right).\end{aligned}$$

可以对每个分项$\beta_j^2 - 2z_j\beta_j + 2\lambda|\beta_j|$单独优化，结果为

$$\hat{\beta}_j^{\text{lasso}} = \begin{cases}\text{sign}\left(\widehat{\beta}_j^{\text{ols}}\right)\left(|\widehat{\beta}_j^{\text{ols}}| - \lambda\right), & \text{if } |\widehat{\beta}_j^{\text{ols}}| \ge \lambda \\ 0, & \text{if } |\widehat{\beta}_j^{\text{ols}}| < \lambda.\end{cases}$$

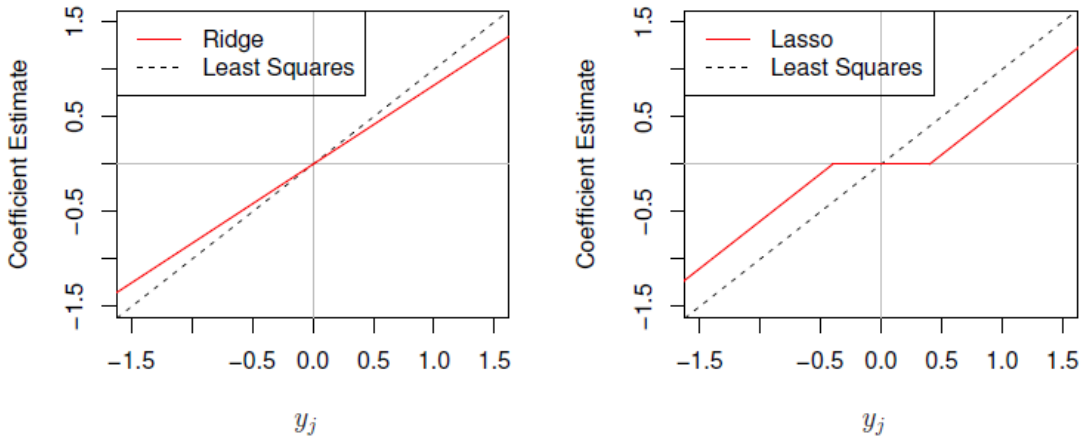
关于lasso与岭回归的缩减特性，见图2。

说明：

1) 可以看出，在输入变量为标准正交时，$\hat{\beta}_j^{\text{lasso}}$也是将$\hat{\beta}_j^{\text{ols}}$经过缩减后得到，且在$|\hat{\beta}_j^{\text{ols}}|$足够小时，会直接缩减到0。这样就可以起到变量选择的作用。

2) λ越大，对回归系数非零的惩罚越大，得到的lasso估计量中的0越多 (选出的变量个数越少)。

图 2: lasso与岭回归的缩减特性 (来源：James et al., An Introduction to Statistical Learning 2nd edition, Figure 6.10)



2.3 Elastic Net

Lasso的问题:

- 最多只能选出n个变量
- 在一组相关性很高的变量中，lasso通常只选其中一个，从而忽略其它的变量
- 在传统$n > p$的情况下，lasso预测效果不太好

Zou and Hastie (2005) 提出了elastic net方法

$$\min_{\mathbf{b}} \frac{1}{2}\|\mathcal{Y} - \mathcal{X}\mathbf{b}\|^2 + \lambda\left\{\alpha\|\mathbf{b}\|_1 + \frac{1}{2}(1-\alpha)\|\mathbf{b}\|_2^2\right\},$$

其中λ与α均为tuning parameter.

可以发现，elastic net的惩罚项为岭回归与lasso的线性组合。图3给出了当$p = 2$时，岭回归、lasso、elastic net惩罚项的等高线对比。

若自变量矩阵$\mathcal{X}$的列都标准正交，则可以求得elastic net的解为

$$\hat{\beta}_j^{\text{enet}} = \begin{cases} \text{sign}\left(\widehat{\beta}_j^{\text{ols}}\right)\frac{|\widehat{\beta}_j^{\text{ols}}|-\lambda\alpha}{1+\lambda(1-\alpha)}, & \text{if } |\widehat{\beta}_j^{\text{ols}}| \geq \lambda\alpha \\ 0, & \text{if } |\widehat{\beta}_j^{\text{ols}}| < \lambda\alpha. \end{cases}$$

其对回归系数的缩减特性见图4.

相对于lasso，elastic net的一个显著特点是一组相关性很高的变量的回归系数也会相似 (见图5, Zou and Hastie [2005])。

图 3: 岭回归、lasso、elastic net惩罚项对比 (Zou and Hastie [2005])

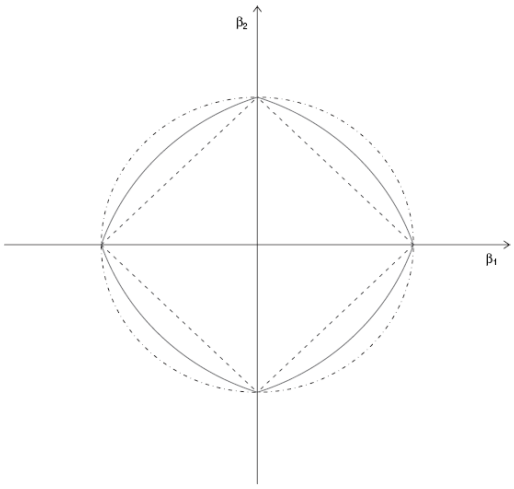


Fig. 1. Two-dimensional contour plots (level 1) (· - - - -, shape of the ridge penalty; -------, contour of the lasso penalty; ———, contour of the elastic net penalty with $\alpha = 0.5$): we see that singularities at the vertices and the edges are strictly convex; the strength of convexity varies with α

图 4: 岭回归、lasso、elastic net的缩减特征对比

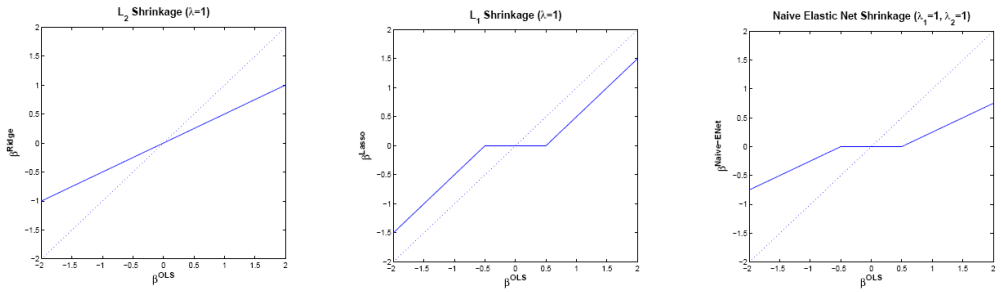


图 5: lasso vs elastic net选变量的特点

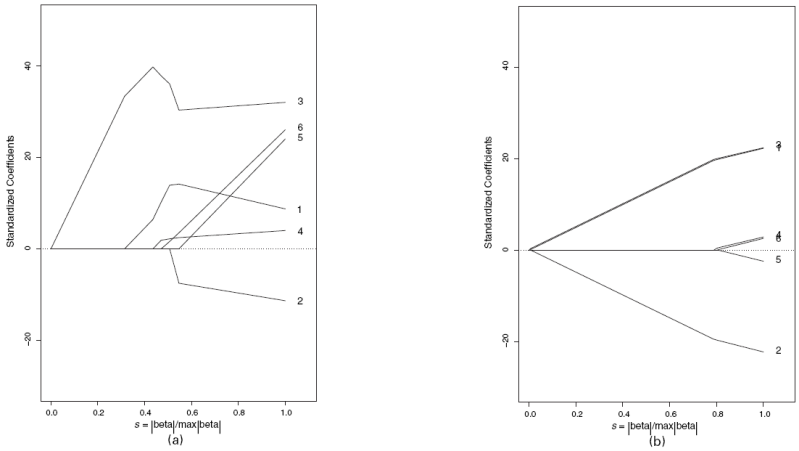


Fig. 5. (a) Lasso and (b) elastic net ($\lambda_2 = 0.5$) solution paths: the lasso paths are unstable and (a) does not reveal any correction information by itself; in contrast, the elastic net has much smoother solution paths, while clearly showing the 'grouped selection'—$\mathbf{x}_1$, $\mathbf{x}_2$ and $\mathbf{x}_3$ are in one 'significant' group and $\mathbf{x}_4$, $\mathbf{x}_5$ and $\mathbf{x}_6$ are in the other 'trivial' group; the decorrelation yields the grouping effect and stabilizes the lasso solution

2.4 Adaptive Lasso

Zou [2006]提出了adaptive lasso

$$\min_{\beta_1,\ldots,\beta_p} \frac{1}{2}\sum_{i=1}^{n}\left(y_i - \sum_{j=1}^{p} x_{ij}\beta_j\right)^2 + \lambda\sum_{j=1}^{p} w_j|\beta_j|,$$

其中$w_j > 0$为权重。

若$w_j = 1/|\beta_j|^\gamma(\gamma > 0)$, 则目标变为

$$\min_{\beta_1,\ldots,\beta_p} \frac{1}{2}\sum_{i=1}^{n}\left(y_i - \sum_{j=1}^{p} x_{ij}\beta_j\right)^2 + \lambda\sum_{j=1}^{p} |\beta_j|^{1-\gamma},$$

相当于用$L_{1-\gamma}$-模作为正则化项，通常会产生一个比lasso更稀疏的解。但以上目标函数非凸函数，求解比较困难。我们可以采用$w_j = 1/|\hat{\beta}_j|^\gamma$, 其中$\hat{\beta}_j$为一个已知的"先导"估计量

- 若$n > p$, 则可选$\hat{\beta}_j$为OLS估计量
- 若$n \le p$, 则可选$\hat{\beta}_j$为简单线性回归$Y \sim X_j$的斜率 (Huang et al. [2008])

图6 展示了Adaptive lasso的模拟实验结果

2.5 Group Lasso

如果有关于变量分组的信息，能否保证一组变量同时被选或者同时不选？例如：若变量中有factor，则希望代表这个factor的一组虚拟变量同时被选/不选。针对此问题，Yuan and Lin [2006]提出了group

图 6: Adaptive lasso的实验结果 (Zou [2006])

Table 1. Simulation Model 0: The Probability of Containing the True Model in the Solution Path

	$n = 60, \sigma = 9$	$n = 120, \sigma = 5$	$n = 300, \sigma = 3$
lasso	.55	.51	.53
adalasso($\gamma = .5$)	.59	.68	.93
adalasso($\gamma = 1$)	.67	.89	1
adalasso($\gamma = 2$)	.73	.97	1
adalasso(γ by cv)	.67	.91	1

NOTE: In this table "adalasso" is the adaptive lasso, and "γ by cv" means that γ was selected by five-fold cross-validation from three choices: $\gamma = .5$, $\gamma = 1$, and $\gamma = 2$.

Table 2. Simulation Models 1 and 2, Comparing the Median RPE Based on 100 Replications

	$\sigma = 1$	$\sigma = 3$	$\sigma = 6$
Model 1 ($n = 20$)			
Lasso	$.414_{(.046)}$	$.395_{(.039)}$	$.275_{(.026)}$
Adaptive lasso	$.261_{(.023)}$	$.369_{(.029)}$	$.336_{(.031)}$
SCAD	$.218_{(.029)}$	$.508_{(.044)}$	$.428_{(.019)}$
Garotte	$.227_{(.007)}$	$.488_{(.043)}$	$.385_{(.030)}$

lasso

$$\min_{\beta_1,\ldots,\beta_p} \frac{1}{2}\sum_{i=1}^{n}\left(y_i - \sum_{j=1}^{p} x_{ij}\beta_j\right)^2 + \lambda \sum_{\ell=1}^{L} \|\boldsymbol{\beta}_\ell\|_{K_\ell},$$

其中$\boldsymbol{\beta}_\ell$表示第ℓ组变量的系数，$\|\cdot\|_{K_\ell}$为某种模 (例如可以取L_2-模)。

当$p = 3$时，lasso, 岭回归与group lasso的惩罚项对比如图7所示。

2.6 SCAD

当λ比较大的时候，lasso的估计偏差通常会比较大。为了修正这个问题，Fan and Li [2001]提出了SCAD

$$\min_{\beta_1,\ldots,\beta_p} \frac{1}{2}\sum_{i=1}^{n}\left(y_i - \sum_{j=1}^{p} x_{ij}\beta_j\right)^2 + \sum_{j=1}^{p} f_\lambda(|\beta_j|),$$

其中

$$f'_\lambda(\theta) = \begin{cases} \lambda, & \text{if } \theta \le \lambda \\ \frac{(a\lambda - \theta)_+}{(a-1)}, & \text{if } \theta > \lambda \end{cases},$$

而$a > 2$为选定参数。

SCAD的惩罚项不是凸函数。图8画出了Lasso与SCAD惩罚项的对比。 若自变量矩阵$\mathbf{X}$的列都标准正

图 7: 当$p = 3$时，lasso, 岭回归与group lasso的惩罚项对比 (Yuan and Lin [2006])
(a): lasso penalty $|\beta_{11}| + |\beta_{12}| + |\beta_2|$
(i): ridge penalty $\beta_{11}^2 + \beta_{12}^2 + \beta_2^2$
(e): group lasso penalty $\sqrt{\beta_{11}^2 + \beta_{12}^2} + |\beta_2|$

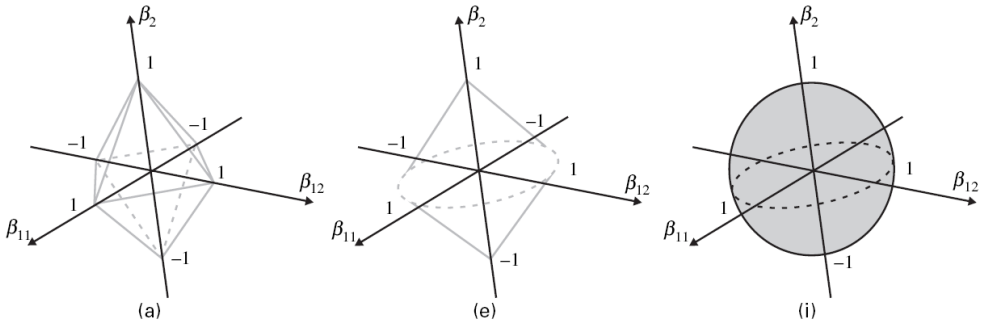
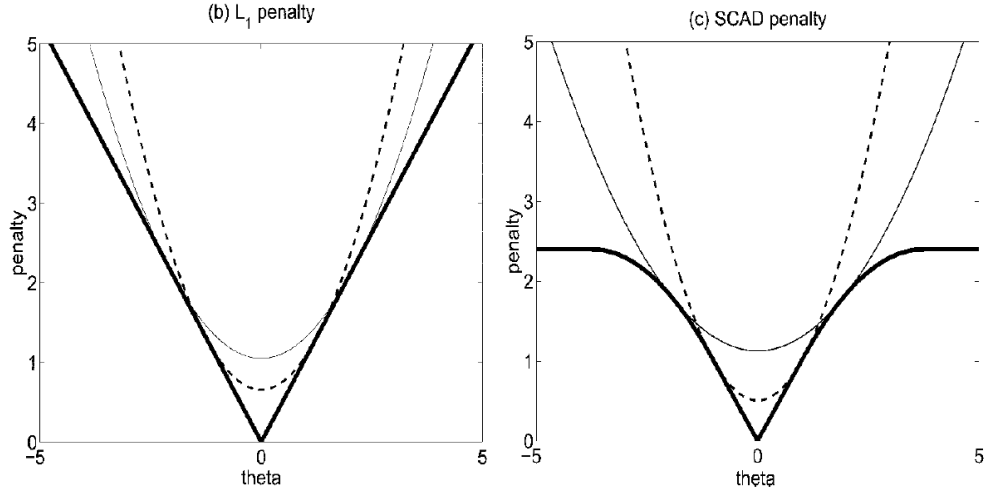


图 8: Lasso 与 SCAD 惩罚项对比 (Fan and Li [2001])

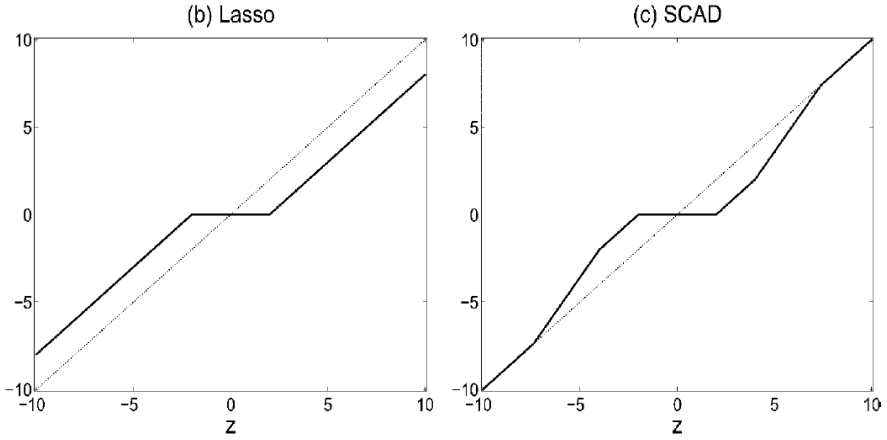


交，则可以求得SCAD的解为

$$\hat{\beta}_j^{\text{scad}} = \begin{cases} 0, & \text{if } |\widehat{\beta}_j^{\text{ols}}| \le \lambda \\ \text{sign}(\widehat{\beta}_j^{\text{ols}}) \left(|\widehat{\beta}_j^{\text{ols}}| - \lambda \right), & \text{if } \lambda < |\widehat{\beta}_j^{\text{ols}}| \le 2\lambda \\ \left\{ (a-1)\widehat{\beta}_j^{\text{ols}} - \text{sign}(\widehat{\beta}_j^{\text{ols}}) a\lambda \right\} / (a-2), & \text{if } 2\lambda < |\widehat{\beta}_j^{\text{ols}}| \le a\lambda \\ \widehat{\beta}_j^{\text{ols}}, & \text{if } |\widehat{\beta}_j^{\text{ols}}| > a\lambda. \end{cases}$$

可以看出，SCAD解的最后一段对OLS估计值较大的情况有一个偏差修正。图9展示了这种修正。

图 9: Lasso 与 SCAD 缩减特征对比 (Fan and Li [2001])



SCAD的模拟实验结果如图10所示。

2.7 Tuning Parameter的选取

正则化方法里的 tuning parameters 通常用交叉验证的方法来选取。具体来说，若只有一个tuning parameter λ，则可以选取一组λ的值$\{\lambda_1, \ldots, \lambda_M\}$。对于每一个$\lambda_m$，计算其对应的CV值 CV($\lambda_m$). 最后取使得CV($\lambda_m$)最小的$\lambda_m$即可。若有两个tuning parameter λ, α, 则各取一组值$\{\lambda_1, \ldots, \lambda_M\}$与$\{\alpha_1, \ldots, \alpha_L\}$。对于每一对$(\lambda_m, \alpha_l)$计算CV值 CV$(\lambda_m, \alpha_l)$, 最后选取使得CV$(\lambda_m, \alpha_l)$最小的数对$(\lambda_m, \alpha_l)$即可。此处“最小CV规则”可以代替为“1标准误规则”。

2.8 高维回归分析示例

例 (Hitters Data) 见R程序。

例 (Crime Data) 见R程序。

图 10: SCAD的实验结果 (Fan and Li [2001])

Table 1. Simulation Results for the Linear Regression Model

		Avg. No. of 0 Coefficients	
Method	*MRME (%)*	*Correct*	*Incorrect*
$n = 40, \sigma = 3$			
SCAD[1]	72.90	4.20	.21
SCAD[2]	69.03	4.31	.27
LASSO	63.19	3.53	.07
Hard	73.82	4.09	.19
Ridge	83.28	0	0
Best subset	68.26	4.50	.35
Garrote	76.90	2.80	.09
Oracle	33.31	5	0

References

J. Fan and R. Li. Variable selection via nonconcave penalized likelihood and its oracle properties. *Journal of the American Statistical Association*, 96(456):1348–1360, 2001.

J. Huang, S. Ma, and C.-H. Zhang. Adaptive lasso for sparse high-dimensional regression models. *Statistica Sinica*, 18:1603–1618, 2008.

R. Tibshirani. Regression shrinkage and selection via the lasso. *Journal of the Royal Statistical Society. Series B*, 58(4):267–288, 1996.

M. Yuan and Y. Lin. Model selection and estimation in regression with grouped variables. *Journal of the Royal Statistical Society. Series B*, 68:49–67, 2006.

H. Zou. The adaptive lasso and its oracle properties. *Journal of the American Statistical Association*, 101(476):1418–1429, 2006.

H. Zou and T. Hastie. Regularization and variable selection via the elastic net. *Journal of the Royal Statistical Society. Series B*, 67(2):301–320, 2005.